Universidad Internacional de Valencia

Análisis Metodológico Comparativo de la Respuesta Transcriptómica a la Infección Bacteriana en *Hermetia illucens*

Titulación: Maestría en Bioinformática Curso académico 2025 – 2026	Alumno/a: Castañeda Moreno, Didier Alfonso Cédula: 1010187140 Director/a de TFM: Dra. María Lairón-Peris	Convocatoria: Primera

De:
Planeta Formación y Universidades

1. Índice

3. Introducción **5**

4. Objetivos **9**

4.1. Objetivo principal: *9*

4.2. Objetivo secundario *9*

5. Materiales y Métodos **10**

5.1. Selección y descripción del conjunto de datos. *10*

5.2. Preprocesamiento de datos y control de calidad. *10*

5.3. Alineamiento y cuantificación génica *10*

5.4. Análisis de Expresión Diferencial y comparación metodológica *11*

6. Resultados **12**

6.1. Calidad de secuenciación y estadísticas de alineamiento *12*

6.2. Análisis exploratorio de los datos *14*

6.3. Expresión diferencial: Evaluación paralela con DESeq2 y edgeR *16*

6.4. Comparación metodológica: DESeq2 vs. edgeR *20*

6.5. Consenso biológico: Biomarcadores específicos de respuesta inmune *22*

7. Discusión **25**

7.1. Limitaciones y perspectivas futuras *27*

8. Conclusiones **28**

9. Referencias bibliográficas **29**

Lista de Abreviaturas

- **AMP**: Péptido Antimicrobiano (Antimicrobial Peptide).
- **BSF**: Black Soldier Fly
- **CTRL:** Condición Control (larvas no tratadas)
- **DEG**: Gen Diferencialmente Expresado (Differentially Expressed Gene)
- **FDR**: Tasa de Falsos Descubrimientos (False Discovery Rate).
- **Log2FC**: Magnitud de Cambio en Logaritmo base 2 (Log2 Fold Change).
- **PBS**: Solución Salina Tamponada con Fosfato (Phosphate-Buffered Saline).
- **PCA**: Análisis de Componentes Principales (Principal Component Analysis)
- **RNA-seq:** Secuenciación de ARN (*RNA sequencing*)
- **TFM**: Trabajo Final de Maestría
- **TMM**: Media Recortada de Valores M (Trimmed Mean of M-values)

Índice de Figuras

Figura 1. Porcentaje de adaptadores en lecturas crudas 12
Figura 2. Porcentaje de adaptadores tras procesado con fastp 13
Figura 3. Puntuación de calidad después del procesado con fastp 13
Figura 4. Porcentaje de mapeos únicos obtenido con el alineador STAR 14
Figura 5. Análisis de componentes principales (PCA) 14
Figura 6. Heatmap de Distancia Euclidiana entre muestras 16
Figura 7. Volcano plot DESeq2 – contraste BACT vs PBS 17
Figura 8. Heatmap Top 50 DEGs – Infección (DESeq2) 18
Figura 9. Volcano plot edgeR – contraste BACT vs PBS 19
Figura 10. Heatmap Top 50 DGEs – Infección (edgeR) 20
Figura 11. Diagrama de Venn - Intersección de DEGs para la condición de infección para DESeq2 y edgeR 21
Figura 12. Scatterplot de concordancia de LFC: DESeq2 vs edgeR 22
Figura 13. Diagrama de Venn – solapamiento robusto biológico para DESeq2 y edgeR 23
Figura 14. Scatterplot Especificidad de la Respuesta Inmune (Datos consenso) 24

2. Resumen

Hermetia illucens, Mosca Soldado Negro (MSN) o más conocida en inglés como Black Soldier Fly (BSF) es un organismo con un alto interés en biotecnología por su capacidad de valorizar residuos y producir proteína de alto valor en el proceso. Comprender el sistema inmunológico es crucial para que la cría a nivel industrial sea viable y segura. Frecuentemente los estudios transcriptómicos suelen implementar un único algoritmo para determinar la expresión diferencial, esto puede implicar sesgos metodológicos. El presente Trabajo de Fin de Master (TFM) tuvo como objetivo principal evaluar el impacto de la elección del software informático (DESeq2 vs edgeR) en la definición de la respuesta inmune de *H. illucens* frente a una infección Gram-Negativa por *pseudomonas protegens.* Mediante el re-analisis de un conjunto de datos públicos de Secuenciación de ARN (RNA-seq) (15 muestras, 13 horas post-tratamiento), se aislaron los efectos del daño físico (Herida estéril) frente a la infección pura. Los resultados arrojaron una elevada correlación cuantitativa (R =1) entre algoritmos, aunque edgeR demostró ser más conservador. Utilizando una aproximación de consenso, se pudo determinar que el efecto transcripcional de la herida es mínimo (16 genes), lo que permitió aislar una firma de 1245 biomarcadores de alta confianza específicos para la infección. El análisis funcional de esta firma, revelo un marcado *trade-off* metabólico: una hiperactivación del sistema inmune humoral, caracterizado por la síntesis masiva de péptidos antimicrobianos (familias de cecropinas, Magnitud de Cambio en Logaritmo base 2 (Log2FC) > 11), compensada por una represión drástica de trascritos asociados a la digestión, metabolismo basal y formación de cutícula (Log2FC < -8). Este trabajo demuestra que el uso de metodologías de consenso incrementa la robustez en la identificación de biomarcadores y confirma empíricamente el alto costo energético de la respuesta inmune.

Palabras clave: *Hermetia illucens*, Transcriptómica, DESeq2, edgeR, Respuesta Inmune, Péptidos Antimicrobianos, *Trade-off* metabólico.

3. Introducción

La mosca soldado negra (BSF), *Hermetia illucens* (Linnaeus, 1758) (Diptera: Stratiomyidae), es un insecto originario de regiones tropicales con centros de diversidad genética fuertemente definidos en el neotrópico, pero que se ha expandido a nivel global (1). Con el pasar del tiempo, esta especie se ha establecido como un modelo biológico de profundo interés en la biotecnología industrial moderna. El estudio de esta especie ha generado un gran impacto en el paradigma de la Economía Circular que la sociedad actual busca alcanzar, debido a su potencialidad en múltiples campos como la gestión de residuos orgánicos (2), la seguridad alimentaria y la transición energética.

A nivel morfológico, la mosca soldado negra tiene particularidades que han incrementado el interés en su uso industrial. Es una especie que, en su etapa adulta, no posee piezas bucales funcionales que le permitan alimentarse o masticar, limitándose estrictamente a la hidratación mediante la absorción de agua o fluidos azucarados. Por ello, no muerden ni presentan comportamientos de regurgitación sobre alimentos humanos (3). Esto, sumado a su comportamiento colonizador que le permite actuar como control biológico natural de *Musca domestica* (4), la convierte en una especie con un perfil de bioseguridad excepcional.

A nivel económico, numerosos estudios demuestran el potencial bromatológico de las larvas, que pueden llegar a contener más de un 40% de proteína en peso seco, además de múltiples nutrientes como aminoácidos y ácidos grasos esenciales (5). Su uso en la industria avícola, por ejemplo, ha optimizado de manera significativa los pesos, la calidad y los rendimientos frente a los piensos tradicionales, llevando a la industria de la BSF a competir directamente con fuentes de proteína convencionales como la siembra intensiva de soja(6). Asimismo, estudios de bioenriquecimiento (*gut-loading*) han demostrado su capacidad para bioacumular ácidos grasos poliinsaturados (PUFA), como el valioso Omega-3, en sus propios tejidos(7). Esta gran capacidad para aumentar su tamaño miles de veces y modificar su perfil lipídico mediante la manipulación de la dieta, abre la posibilidad de convertir su biomasa en biodiésel. Su ciclo de vida de 14 a 21 días compite ventajosamente con las plantas oleaginosas, que requieren ciclos de meses o años, lográndolo sin el uso de suelos fértiles, empleando en su lugar efluentes, estiércol, lodos de depuradora o residuos sólidos urbanos(8).

La gran cantidad de estudios sobre su supervivencia y bioconversión en todo tipo de residuos ha llevado a considerar a esta especie como un holobionte dinámico. Posee un sistema sinérgico, simbiótico y complejo con su microbiota que, mediante una modulación nutricional activa, abre un vasto abanico de posibilidades(9). Al ser un insecto holometábolo, la exuvia resultante de su metamorfosis de pupa a mosca constituye un excedente de proceso predecible y constante en las instalaciones de cría, exento de dilemas éticos. Su alto contenido en quitina de calidad lo hace muy valioso en la industria para la obtención de biopolímeros, como el versátil quitosano, expandiendo su interés hacia la industria farmacológica y cosmética(10) . Un dato revelador de su sostenibilidad es el impacto ambiental: el uso de la larva en el consumo de residuos orgánicos genera entre 12 y 17 kg de CO2 por tonelada(2) , frente a los abrumadores 772 kg de CO2 por tonelada que emiten los vertederos tradicionales(11).

Para que el su potencial bioindustrial sea sostenible y escalable, es fundamental garantizar la salud y el bienestar de las larvas frente a los diversos patógenos presentes en los residuos orgánicos, para ello es imprescindible comprensión profunda de su sistema inmunológico a nivel molecular. Los insectos son, incuestionablemente, uno de los grupos biológicos más exitosos en la carrera evolutiva, poseyendo la mayor diversidad filogenética y biomasa del planeta, lo que denota la extraordinaria eficacia de su sistema inmune innato(12). Especies modelo como *Drosophila melanogaster* han permitido entender cómo funciona este sistema frente a infecciones microbianas, fúngicas o parasitarias mediante una sofisticada red de mecanismos humorales y celulares. Estos incluyen la síntesis masiva de péptidos antimicrobianos (AMPs) y cascadas proteolíticas ejecutadas por hemocitos especializados(12)

El estudio detallado de estas dinámicas ha sido posible gracias a las tecnologías de secuenciación de nueva generación (NGS), que han dado lugar al auge de la transcriptómica. Impulsada por plataformas como Illumina y Oxford Nanopore, la secuenciación masiva permite el análisis paralelo de miles de millones de fragmentos de ADN y ARN (13). A nivel conceptual, el transcriptoma representa el conjunto integral de todos los transcritos de ARN expresados por un genoma bajo condiciones biológicas, ambientales o patológicas específicas(14). Su cuantificación revela qué genes presentan actividad metabólica activa o reprimida, permitiendo analizar las respuestas adaptativas ante condiciones de estrés y descifrando cómo los insectos orquestan sus defensas a través de vías de señalización como Toll, Imd y JAK/STAT(15,16). Comprender la respuesta inmune de *Hermetia illucens* a este nivel de detalle no solo amplía el conocimiento biológico,

sino que sienta las bases para desarrollar programas de monitoreo de salud en entornos industriales(16).

Sin embargo, la interpretación biológica de estos mecanismos está altamente ligada a la precisión analítica y estadística con la que se procesan los datos masivos de RNA-seq. Los datos obtenidos de estas tecnologías generan recuentos discretos de fragmentos (reads) alineados contra un genoma de referencia. Estos datos presentan desafíos propios, ya que dependen de la profundidad de secuenciación y no representan valores de abundancia absoluta, lo que hace imprescindible el uso de algoritmos matemáticos robustos para distinguir señales biológicas reales de artefactos técnicos(17,18).

El análisis de expresión génica diferencial (DGE) es el paso crítico de la transcriptómica, cuyo objetivo es identificar qué genes cambian sus niveles de expresión entre diferentes condiciones biológicas (por ejemplo, una herida mecánica frente a una infección bacteriana). Para la resolución de este análisis, la comunidad bioinformática ha desarrollado un ecosistema de herramientas en el lenguaje R, alojadas en el repositorio Bioconductor(17,18). En este ámbito, los algoritmos DESeq2 y edgeR han dominado indiscutiblemente la literatura científica reciente, definiendo los estándares metodológicos para el modelado de datos ómicos(17). Ambos paquetes han adoptado unánimemente la distribución Binomial Negativa (NB) sobre la distribución de Poisson, ya que la variabilidad biológica natural presenta sobredispersión, y manejar adecuadamente la subestimación del error estándar es fundamental para evitar la proliferación de falsos positivos(17,19) .

A pesar de estas similitudes fundamentales, los algoritmos difieren en aspectos clave de su procesamiento interno. Para la normalización y mitigación de sesgos, DESeq2 utiliza la "Mediana de proporciones" (*Median of Ratios*), que estandariza los valores generando una muestra de referencia (pseudo-referencia) para corregir los sesgos y obtener matrices de conteo normalizadas en escala logarítmica(20). Por su parte, edgeR emplea la "Media Recortada de Valores M" (TMM). En lugar de una pseudo-referencia, edgeR toma una muestra real del conjunto y calcula los valores M (proporción de expresión) y A (intensidad absoluta promedio), aplicando un recorte estadístico superior e inferior de los valores atípicos para calcular factores de normalización específicos (calcNormFactors)(21).

En cuanto al análisis de la dispersión, DESeq2 la estima gen por gen mediante Máxima Verosimilitud (MLE) e implementa un encogimiento empírico bayesiano (*shrinkage*) MAP (Máximo a Posteriori). Esto genera una curva de tendencia a priori hacia la cual se ajustan los genes con bajos conteos, mientras que aquellos con mucha información conservan sus estimaciones individuales(22). En contraste, edgeR utiliza la verosimilitud de perfil ajustada

Cox-Reid (CR), evaluando la dispersión en tres niveles: común (la más conservadora), por tendencia (*trended*) y gen a gen (*tagwise*), aplicando un encogimiento hacia la tendencia general(22).

Finalmente, para la prueba estadística, DESeq2 implementa la Prueba de Wald, que resulta precisa y potente para comparar dos grupos, aunque puede beneficiarse de una función de contracción adicional (lfcShrink()) para controlar mejor el ruido en genes poco expresados (22). EdgeR, por otro lado, emplea el F-test de Cuasi-Verosimilitud (QL), un enfoque metodológico considerado más conservador. Al utilizar una distribución F multiparamétrica, edgeR ofrece un control más estricto sobre el *False Discovery Rate* (FDR), resultando en intervalos de error más robustos, ideal para diseños con un número reducido de réplicas biológicas(22).

4. Objetivos

4.1. Objetivo principal:

En este trabajo, el objetivo principal es realizar un re-análisis de un dataset público (GSE263745) para comparar de forma crítica el impacto del uso de DESeq2 frente a edgeR en la identificación de genes de respuesta a la infección bacteriana en *H. illucens*.

4.2. Objetivo secundario

Determinar si la elección del software bioinformático (DESeq2 vs edgeR) altera las conclusiones biológicas sobre la respuesta inmune en *H. Illucens* a las 13hs post-infección

5. Materiales y Métodos

5.1. Selección y descripción del conjunto de datos.

Para el desarrollo del TFM se utilizaron datos públicos RNA-Seq alojados en el repositorio Gene Expression Omnibus (GEO) bajo el código de acceso GSE263745, correspondientes al BioProject PRJNA1099151. Estos datos provienen del estudio *Transcriptomic response of Hermetia illucens L. (Diptera: Stratiomyidae) to wounding and Gram-negative bacterial infection.*(16)*, Ver Anexo 1.* Para este TFM, se seleccionó un subconjunto específico de 15 muestras recolectadas a las 13 horas post-tratamiento (Anexo 1). Las muestras se distribuyen en tres condiciones experimentales, cada una con cinco réplicas biológicas: un grupo control (CTRL) de larvas no tratadas (SRR28624592 - SRR28624596), un grupo sometido a herida mediante inyección de solución salina estéril o PBS (SRR28624577 - SRR28624581), y un grupo infectado mediante inyección con la bacteria Gram-negativa Pseudomonas protegens Pf-5 (SRR28624562 - SRR28624566).

5.2. Preprocesamiento de datos y control de calidad.

Se utilizo un entorno Linux v21.3, con Conda (v25.9.1) para la gestión de entornos y dependencias. En primer lugar, los datos crudos en formato SRA fueron descargados mediante la herramienta prefetch (v3.2.1) y posteriormente convertidos a formato de secuencias pareadas (Paired-End) mediante fasterq-dump (v3.2.1), ambas herramientas pertenecientes al paquete SRA-Toolkit (Anexo 2) (23). La calidad de las lecturas crudas se evaluó utilizando FastQC (v0.12.1) (24) (Anexo 3), y los reportes individuales se unificaron para su evaluación global utilizando MultiQC (v1.33) (25). Una vez evaluada la calidad, se procedió a la eliminación de secuencias adaptadoras y filtrado de lecturas de baja calidad empleando el software fastp (v1.0.1) (26). E igualmente los reportes de fastp (v1.0.1) fueron unificados con MultiQC (v1.33) (Anexo 4)

5.3. Alineamiento y cuantificación génica

Las lecturas filtradas se alinearon contra el genoma de referencia de *Hermetia illucens* (ensamblaje GCF_905115235.1), publicado previamente por Generalovic (27) y

descargado desde la base de datos del NCBI (Anexo 5). El mapeo se realizó utilizando el alineador STAR (v2.7.11b) (28), generando previamente el índice del genoma ajustado para lecturas Paired-End de 150 pares de bases (Anexo 6 y 7). Finalmente, la cuantificación de la expresión, es decir, la asignación de lecturas mapeadas a características genómicas, se llevó a cabo utilizando la herramienta featureCounts (v2.1.1) del paquete Subread (29), con el objetivo de replicar la metodología de cuantificación del estudio original (Anexo 8).

5.4. Análisis de Expresión Diferencial y comparación metodológica

El análisis estadístico y la visualización de los datos se realizaron en R Studio (v4.5.2) (Anexo 9). La matriz de conteos crudos fue preprocesada para estandarizar los metadatos y limpiar los identificadores génicos (GeneID), sumando las isoformas detectadas y eliminando genes con baja expresión en todas las muestras. Se realizó un análisis exploratorio de los datos mediante el Análisis de Componentes Principales (PCA) y mapas de calor (heatmaps) de distancias muestrales para evaluar la concordancia entre réplicas biológicas.

Para evaluar el impacto del algoritmo estadístico, la matriz de conteos fue analizada en paralelo utilizando dos de los paquetes más establecidos en Bioconductor: DESeq2 (v1.48.2) (17) y edgeR (v4.6.3)(30). En ambos métodos se evaluaron dos contrastes biológicos principales: el efecto de la herida (PBS vs. CTRL) y el efecto de la infección (BACT vs. PBS). Se aplicó un filtrado estricto para definir a los Genes Diferencialmente Expresados (DEGs), estableciendo un umbral de significancia de FDR < 0.001 y un valor absoluto de Log2 Fold Change (LFC) > 2. La manipulación y visualización de los resultados se facilitó mediante los paquetes tidyverse (v2.0.0), ggplot2 (v4.0.2), ggrepel (v0.9.6) para los gráficos de tipo Volcano (Volcano plots), y pheatmap (v1.0.13) junto con RColorBrewer (v1.1-3) para la generación de mapas de calor de los 50 DEGs más significativos. Adicionalmente, se utilizó apeglm (v1.30.0) para la contracción de los valores de LFC en DESeq2. La comparación metodológica se visualizó mediante diagramas de Venn generados con ggVennDiagram (v1.5.7) y gráficos de dispersión (scatterplot) para evaluar la concordancia de los valores LFC entre ambos softwares. Finalmente, el análisis biológico consistió en la intersección de los genes detectados por ambos algoritmos (consenso) para identificar biomarcadores robustos asociados exclusivamente a la respuesta inmune contra la infección.

6. Resultados

6.1. Calidad de secuenciación y estadísticas de alineamiento

La evaluación previa de las 15 muestras mediante fastQC evidencio que el conjunto de datos crudos en general presenta una calidad sobresaliente con valores Phred (Q-scores) por encima de Q30 (99.9% de precisión). A destacar solamente hasta 5% de contenido de adaptadores en algunas lecturas (Figura 1)

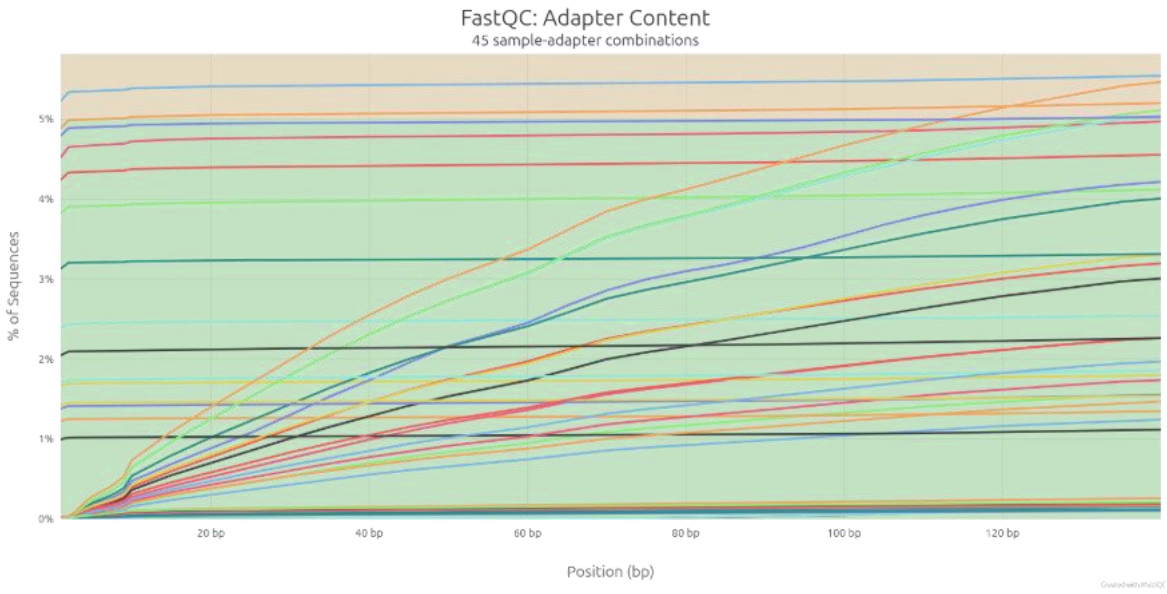

Figura 1. Porcentaje de adaptadores en lecturas crudas

Las lecturas crudas fueron filtradas y recortadas de manera estricta con fastp con parámetros para lecturas Paired-end, recorte de calidad Q20 y descarte de lecturas menores a 25pb. Después del procesado, el porcentaje de adaptadores se redujo hasta el 1% (Figura 2.) y la calidad se mantuvo con valores de hasta Q35 (Figura 3.)

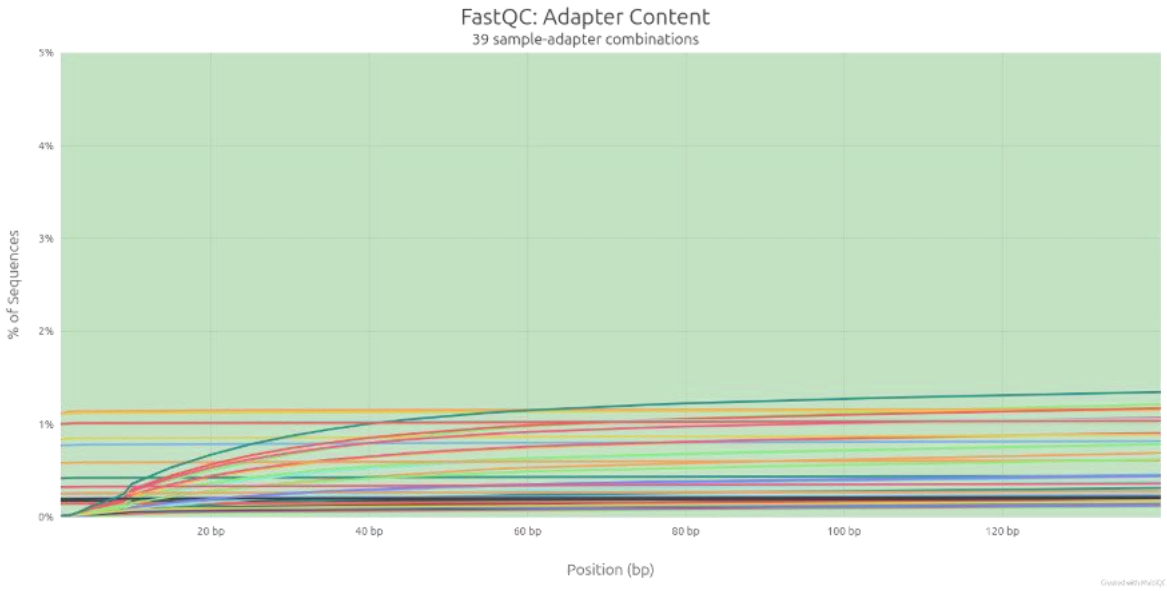

Figura 2. Porcentaje de adaptadores tras procesado con fastp

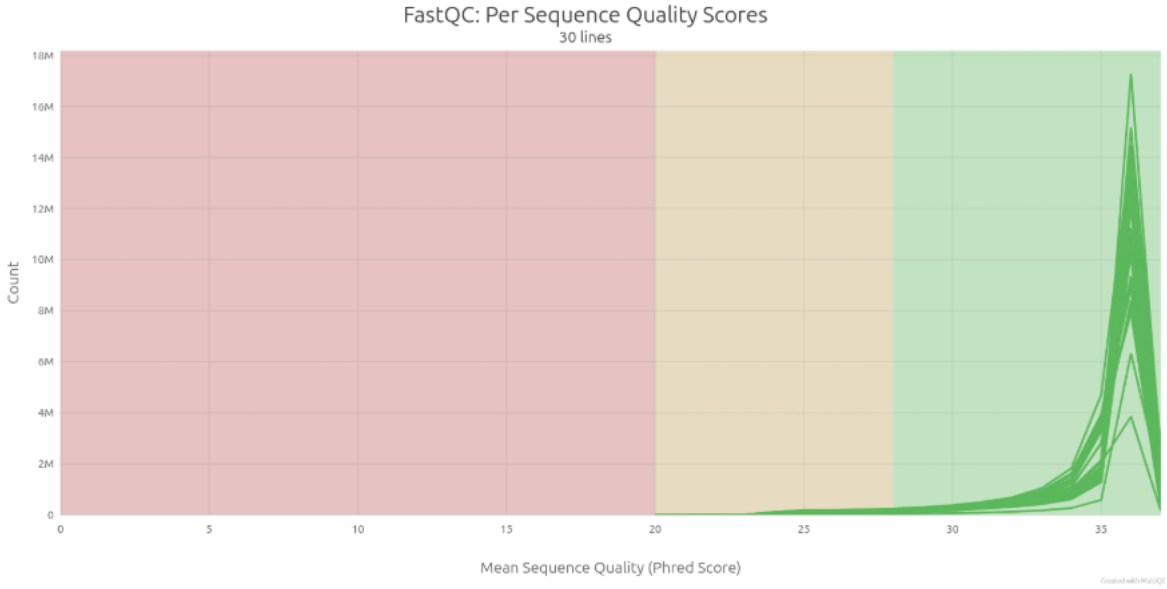

Figura 3. Puntuación de calidad después del procesado con fastp

Posteriormente las secuencias ya procesadas y limpiadas se alinearon contra el genoma de referencia. Como se detalla en la figura 4, la tasa de mapeo único (Uniquely mapped reads) obtenida con el algoritmo de STAR mostro valores en un rango entre 83.4% - 87.2% a lo largo de las muestras. Estos porcentajes de alineamiento elevados validan la efectividad del proceso de limpieza, así como del ensamblaje del genoma de referencia utilizado para la cuantificación génica.

Sample Name	Aligned	Uniq aligned
SRR28624562	95.9 %	86.2 %
SRR28624563	95.7 %	83.9 %
SRR28624564	95.3 %	84.9 %
SRR28624565	94.2 %	84.2 %
SRR28624566	93.7 %	84.4 %
SRR28624577	93.9 %	85.5 %
SRR28624578	97.2 %	86.8 %
SRR28624579	96.6 %	87.2 %
SRR28624580	96.0 %	84.1 %
SRR28624581	94.2 %	85.6 %
SRR28624592	94.1 %	84.2 %
SRR28624593	97.0 %	85.8 %
SRR28624594	96.5 %	85.5 %
SRR28624595	95.7 %	86.6 %
SRR28624596	94.6 %	83.4 %

Figura 4. Porcentaje de mapeos únicos obtenido con el alineador STAR

6.2. Análisis exploratorio de los datos

Se realizó un análisis exploratorio de los datos a partir de la matriz de conteos, sometida previamente a una transformación estabilizadora de varianza (VST) en DESeq2, con el objetivo de evaluar la similitud global entre las muestras y confirmar la reproducibilidad

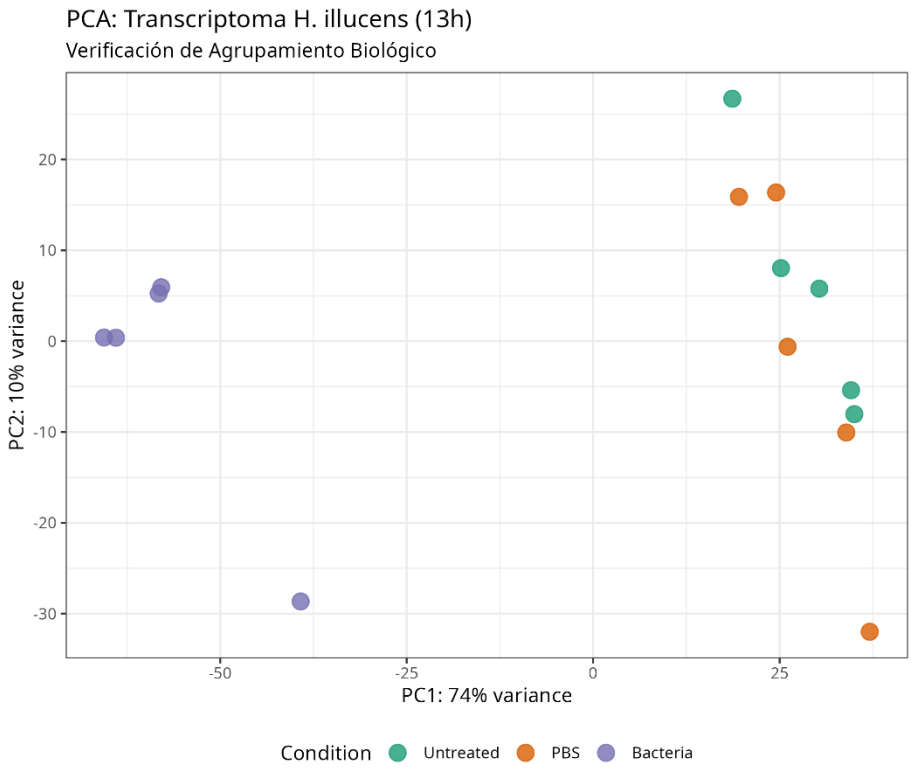

Figura 5. Análisis de componentes principales (PCA)

de las réplicas biológicas. El PCA (Figura 5) muestra una estructura y segregación clara de los datos.

El primer componente principal (PC1) captura la mayoría de la varianza biológica (74%), impulsada de manera exclusiva por el efecto de la infección. En este eje, las réplicas sometidas a infección bacteriana (BACT) se separan drásticamente de los otros dos grupos experimentales. El segundo componente principal (PC2) explica un 10% adicional de la varianza, reflejando una ligera dispersión intra-grupo dentro de las réplicas infectadas.

En este análisis exploratorio es relevante el comportamiento de las muestras a las 13 horas post-tratamiento: las muestras inyectadas con solución salina (PBS) y untreated (CTRL) no presentan una separación marcada en el PC1 y agrupan de manera conjunta. Esta agrupación confirma que, en este punto temporal tardío, la respuesta transcripcional asociada al estrés mecánico (la herida física) se ha atenuado casi por completo, permitiendo que el análisis posterior aísle con alta fidelidad la firma transcriptómica específica generada por la presencia de *P. protegens*."

Para complementar el análisis de componentes principales, se calculó la matriz de distancias euclidianas a partir de los datos transformados (VST) para así evaluar la diferencia transcripcional entre todas las muestras. El heatmap con agrupamiento jerárquico obtenido (Figura 6) corrobora visualmente la clara estructura poblacional de los datos.

El dendrograma obtenido divide las muestras en dos clados principales y perfectamente definidos. El primer clado agrupa de manera exclusiva a las cinco réplicas biológicas del grupo infectado con P. protegens (SRR28624562 a SRR28624566), las cuales exhiben una cohesión interna muy alta, denotada por distancias euclidianas cercanas a cero (color azul oscuro). El segundo clado engloba de forma conjunta a las 10 muestras correspondientes a los tratamientos de la herida física (PBS) y control (CTRL).

La agrupación de estos dos últimos tratamientos en un mismo clado reafirma la conclusión observada en el PCA: a las 13 horas post-tratamiento, el perfil de expresión derivado del daño mecánico es prácticamente indistinguible del estado basal. La ausencia total de muestras atípicas (outliers) y la consistencia intra-clado certifican la alta calidad técnica de

la secuenciación y validan de manera contundente el diseño experimental para la subsecuente identificación de biomarcadores específicos de la infección.

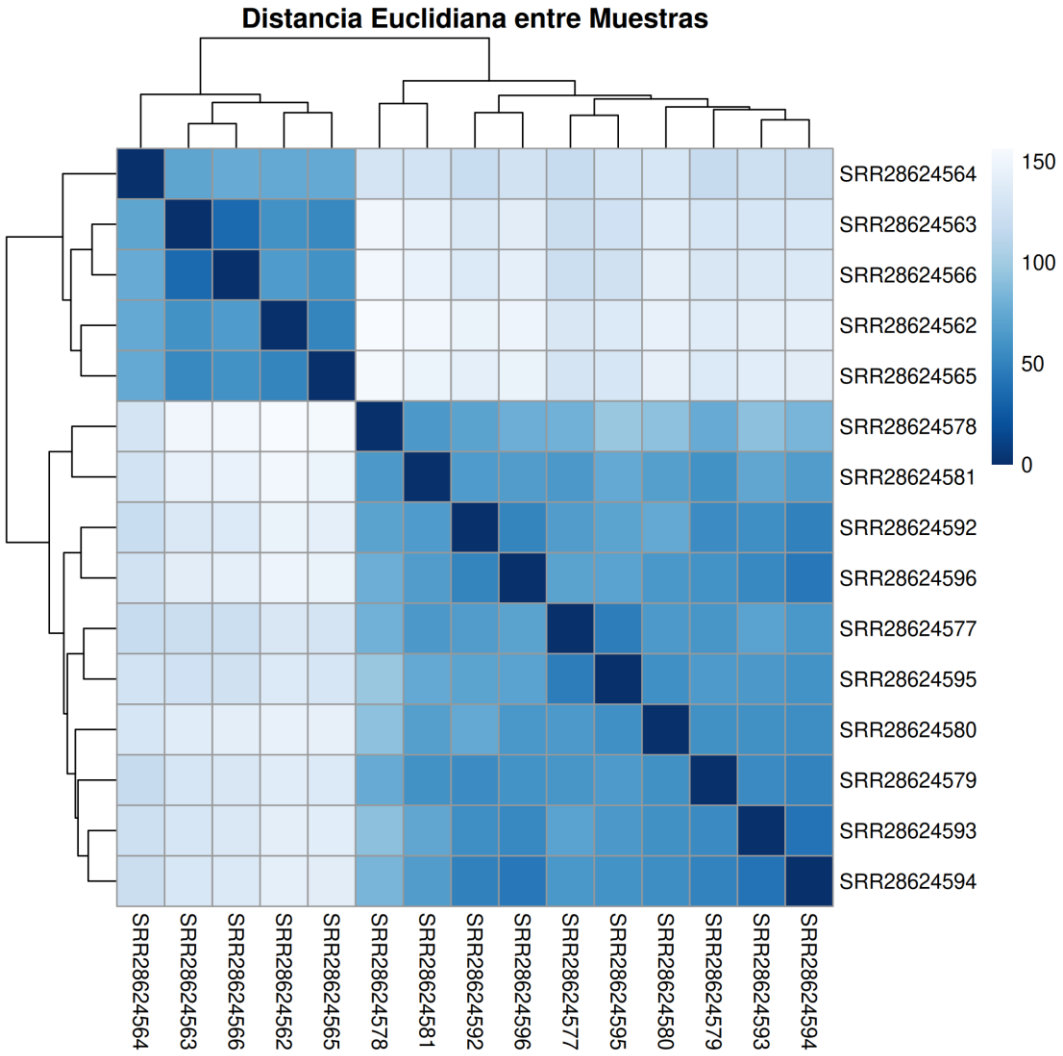

Figura 6. Heatmap de Distancia Euclidiana entre muestras

6.3. Expresión diferencial: Evaluación paralela con DESeq2 y edgeR

Para la identificación de los genes diferencialmente expresados (DEGs) en respuesta a la infección bacteriana por Pseudomonas protegens a las 13hs post-infeccion, se realizó un análisis comparativo en paralelo con dos de los algoritmos más sólidos y de mayor trayectoria y uso en la literatura: DESeq2 y edgeR. Siguiendo los lineamientos del estudio

original de Shah se aplicaron filtros estrictos y determinando la significancia de estos para los que mostraron un FDR < 0.001 y con un valor Log2FC > 2.

Al aislar el efecto específico de la infección mediante el contraste de las muestras infectadas frente al control de la herida física (BACT vs PBS), el análisis con DESeq2 identificó un total de 1.396 genes diferencialmente expresados. De este conjunto, 839 genes resultaron significativamente sobreexpresados (*up-regulated*), indicando una fuerte inducción de la respuesta transcripcional, mientras que 557 genes sufrieron una represión significativa (*down-regulated*).

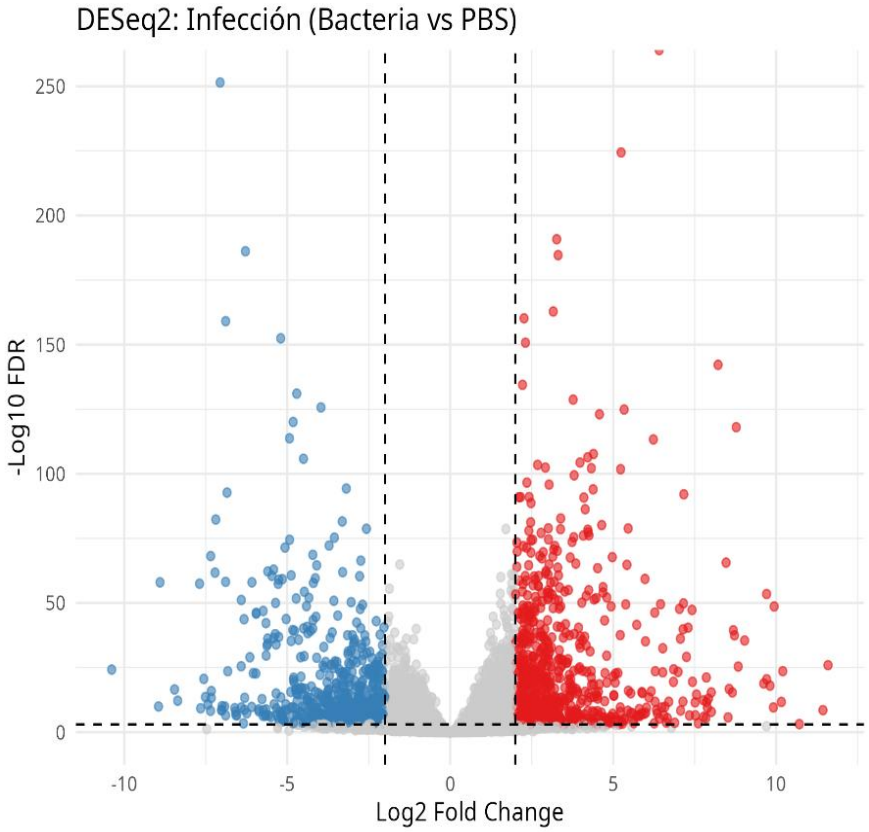

Figura 7. Volcano plot DESeq2 – contraste BACT vs PBS

La distribución, magnitud y significancia estadística de estos cambios se visualizan claramente en el Volcano Plot (Figura 7), donde se observa una notable asimetría con genes inducidos que alcanzan niveles de sobreexpresión muy elevados (Log2FC > 10).

Adicionalmente, para visualizar los patrones de expresión de los 50 genes con mayor significancia estadística, se generó un mapa de calor con agrupamiento jerárquico (Figura 8). Este Heatmap ilustra una diferenciación transcripcional muy clara: el perfil de expresión de las réplicas infectadas invierte radicalmente sus patrones en comparación con las réplicas control y PBS, las cuales mantienen perfiles basales virtualmente idénticos entre sí.

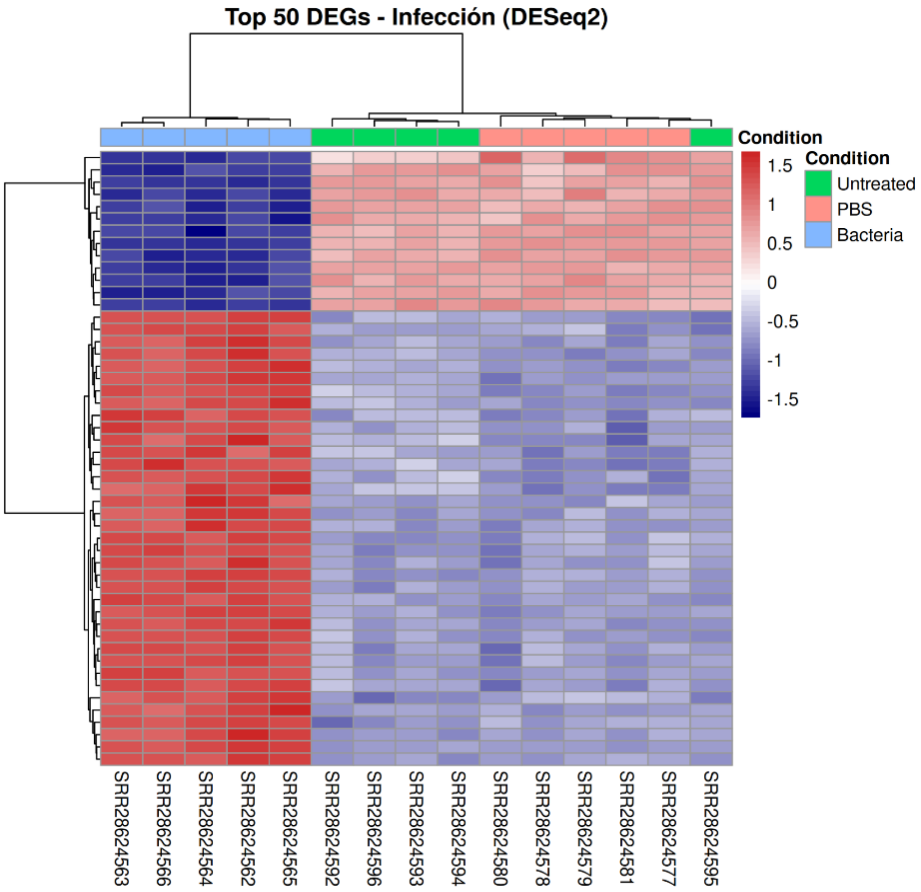

Figura 8. Heatmap Top 50 DEGs – Infección (DESeq2)

Paralelamente, se ejecutó el mismo análisis de expresión diferencial empleando el algoritmo edgeR, que utiliza la normalización TMM y el ajuste mediante un modelo lineal generalizado de cuasi-verosimilitud (QL). Bajo el mismo contraste de infección (BACT vs PBS) y aplicando idénticos umbrales de significancia (FDR < 0.001 y |Log2FC| > 2), edgeR detectó un total de 1.265 DEGs. En este modelo, 775 genes fueron clasificados como significativamente sobreexpresados y 490 como subexpresados.

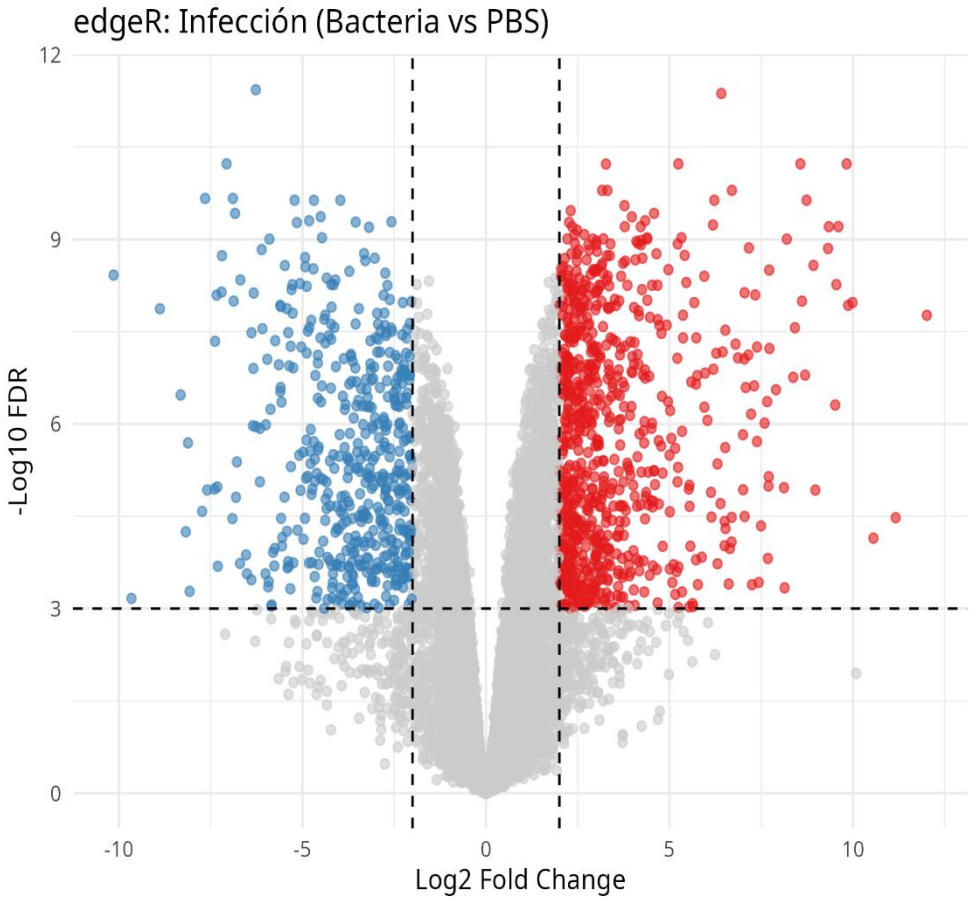

Figura 9. Volcano plot edgeR – contraste BACT vs PBS

La distribución de estos transcritos se visualiza en su respectivo Volcano Plot (Figura 9). Al comparar visualmente las escalas de significancia, se evidencia la particularidad de ser más conservador edgeR. Sin embargo, la visualización de los patrones de expresión para los 50 genes con mayor significancia estadística (Figura 10) reproduce la misma diferenciación robusta observada con DESeq2, separando de manera clara el transcriptoma infectado del estado basal.

Por otro lado, para confirmar el aislamiento de la firma inmunitaria, se evaluó el efecto transcripcional exclusivo de la herida física mediante el contraste de las muestras inyectadas con solución salina frente al control absoluto (PBS vs CTRL). El análisis reveló una respuesta biológica puramente residual, detectando únicamente 35 genes sobreexpresados y ningún gen subexpresado. Esta drástica reducción en el número

de DEGs concuerda plenamente con la atenuación temporal del estrés mecánico a las 13 horas post-tratamiento observada en el análisis de componentes principales, confirmando que la abrumadora mayoría de los cambios transcripcionales en el grupo BACT corresponden a una respuesta inmune activa y específica contra la bacteria.

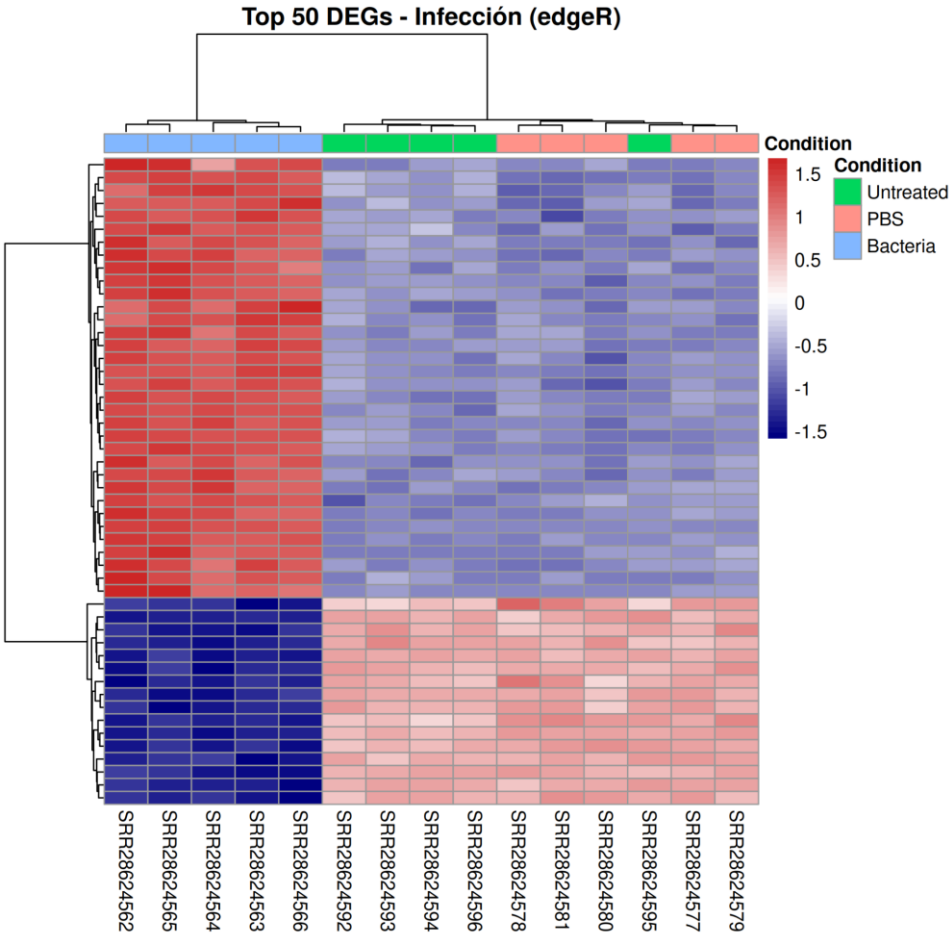

Figura 10. Heatmap Top 50 DGEs – Infección (edgeR)

6.4. Comparación metodológica: DESeq2 vs. edgeR

Para responder directamente al objetivo metodológico sobre el impacto de la elección del algoritmo estadístico en la detección de DEGs, se realizó un cruce de las listas de genes significativas obtenidas independientemente por cada paquete. Al comparar los resultados para la condición de infección (BACT vs PBS), se evidenció un grado de solapamiento muy alto. Un total de 1.250 genes fueron identificados de manera simultánea por ambos

métodos. Esta intersección representa el 89% del total de genes detectados por DESeq2 y el 98.8% de los reportados por edgeR (Figura 11).

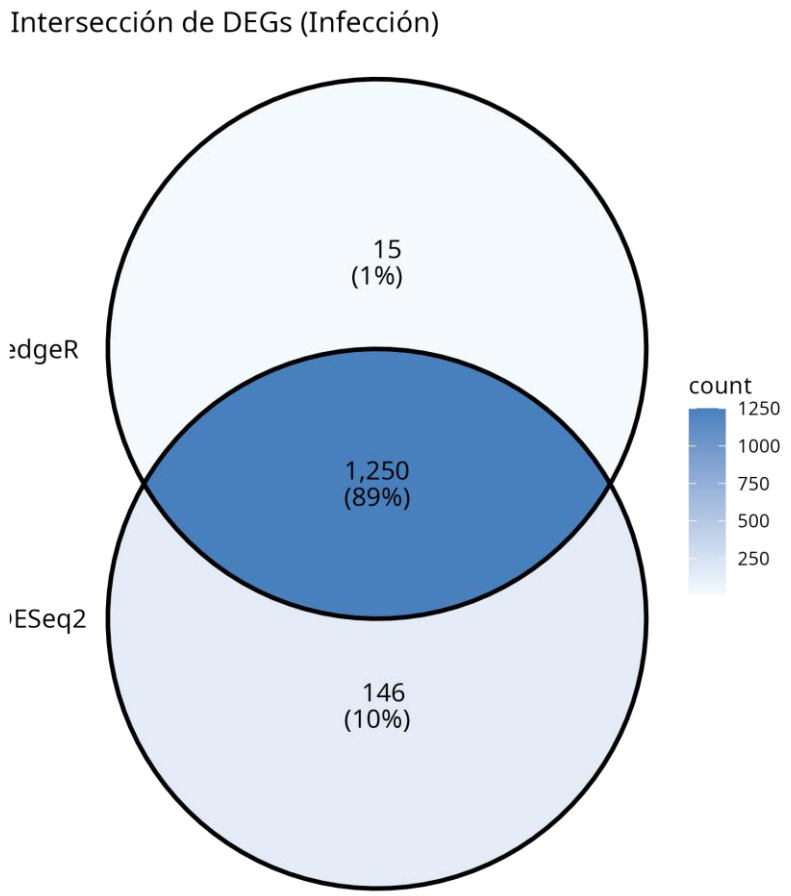

Figura 11. Diagrama de Venn - Intersección de DEGs para la condición de infección para DESeq2 y edgeR

Estos resultados indican que, bajo umbrales de filtrado estrictos (FDR < 0.001, |Log2FC| > 2), edgeR demostró un comportamiento más conservador, minimizando la tasa de potenciales falsos positivos frente a la varianza intra-grupo. Por su parte, DESeq2 exhibe una mayor sensibilidad estadística, identificando 146 genes adicionales. Más allá de las diferencias cualitativas en la clasificación de significancia, hay diferencias cuantitativas respecto a la magnitud del cambio transcripcional. Como se observa en el gráfico de dispersión (Scatterplot, Figura 12) los valores de Log2 Fold Change para los DEGs exhibieron una correlación lineal perfecta (Coeficiente de Pearson $R = 1$) entre ambos paquetes. Esta alta reproducibilidad confirma que, para los transcritos con una fuerte señal biológica diferencial, la cuantificación de la magnitud de expresión es virtualmente idéntica

e independiente del método de normalización utilizado (Media Recortada de Valores M en edgeR vs. Mediana de Proporciones en DESeq2)."

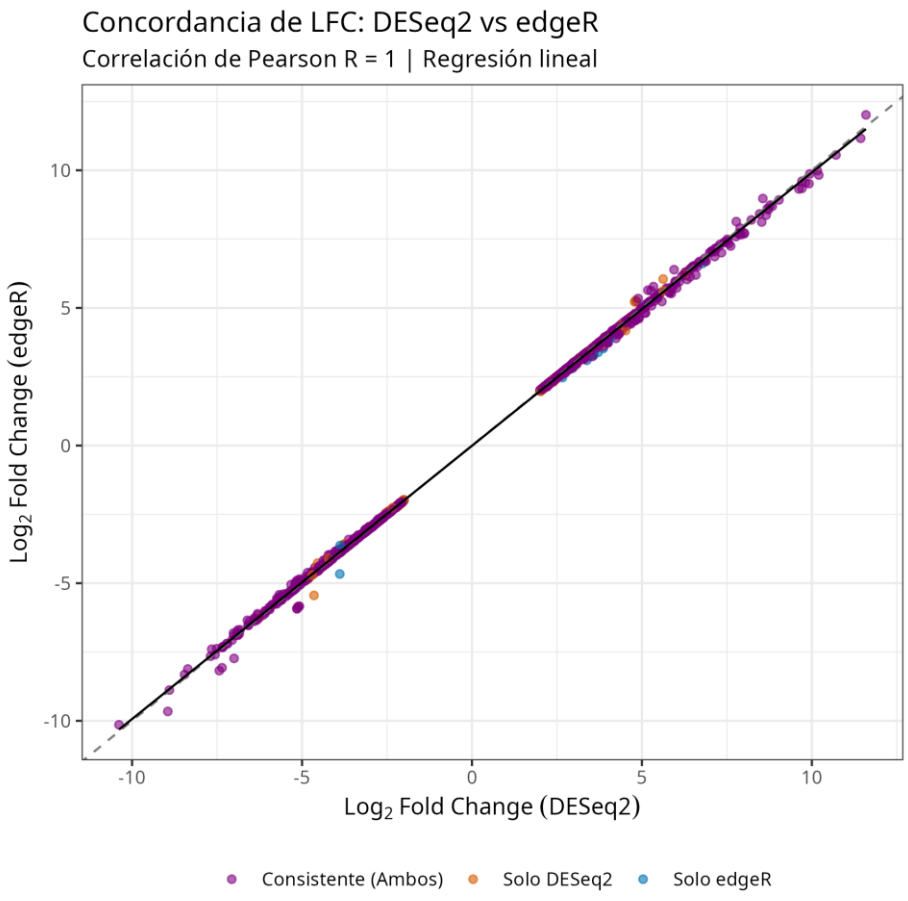

Figura 12. Scatterplot de concordancia de LFC: DESeq2 vs edgeR

6.5. Consenso biológico: Biomarcadores específicos de respuesta inmune

El consenso de ambos métodos estadísticos permite proponer un panel de genes de alta confianza exclusivos para la infección bacteriana, para ello se aisló el efecto específico del patógeno del efecto residual asociado al daño titular. La intersección de metodologías (1250 genes consenso asociados a la infección) contrastados contra los transcritos asociados al daño mecánico (16 genes consenso), permitió determinar el solapamiento biológico (Figura 13)

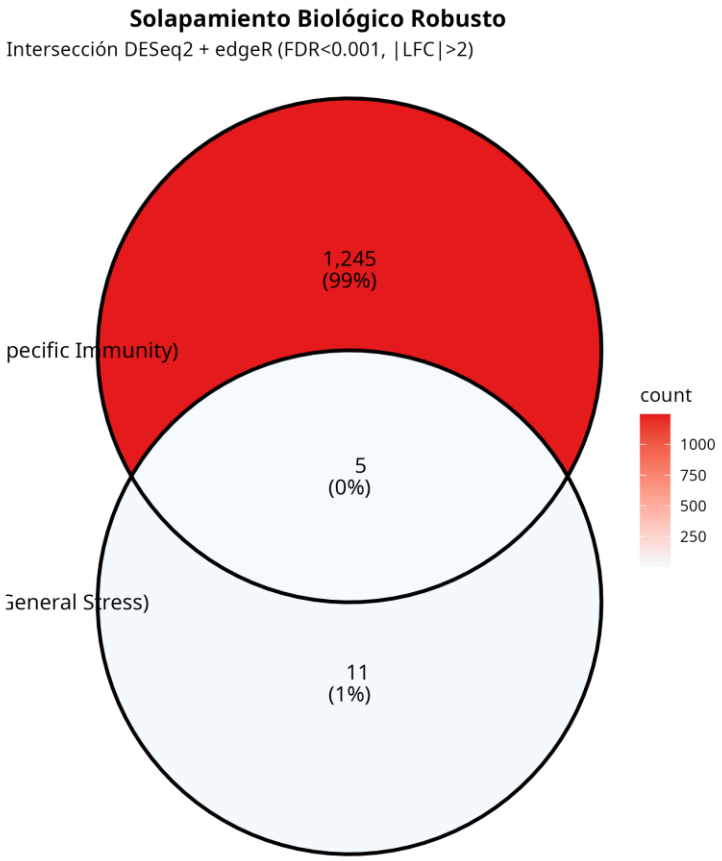

Figura 13. Diagrama de Venn – solapamiento robusto biológico para DESeq2 y edgeR

Se destaca que solamente 5 genes mostraron solapamiento entre el estrés físico de la herida y el estrés de la infección, lo que confirma que para las 13 horas post-tratamiento la respuesta transcriptómica asociada al daño es mínima, esto valida la disminución de la respuesta temporal causada por la herida. Excluyendo los 5 genes compartidos, la lista de genes curada puramente reactivos a la infección por *P. protegens* es de 1245 genes.

La especificidad, dirección y magnitud de la respuesta se visualiza en el gráfico de dispersión de contrastes biológicos (Figura 14). Al graficar el cambio de la expresión de la herida en el eje X y el generado por la infección bacteriana en el eje Y, se puede distinguir una distinción fenotípica clara. Los 1245 genes de alta confianza específicos de la infección (puntos en rojo) se posicionan a lo largo del eje Y en mayor concentración con valores cercanos más al cero en el eje X.

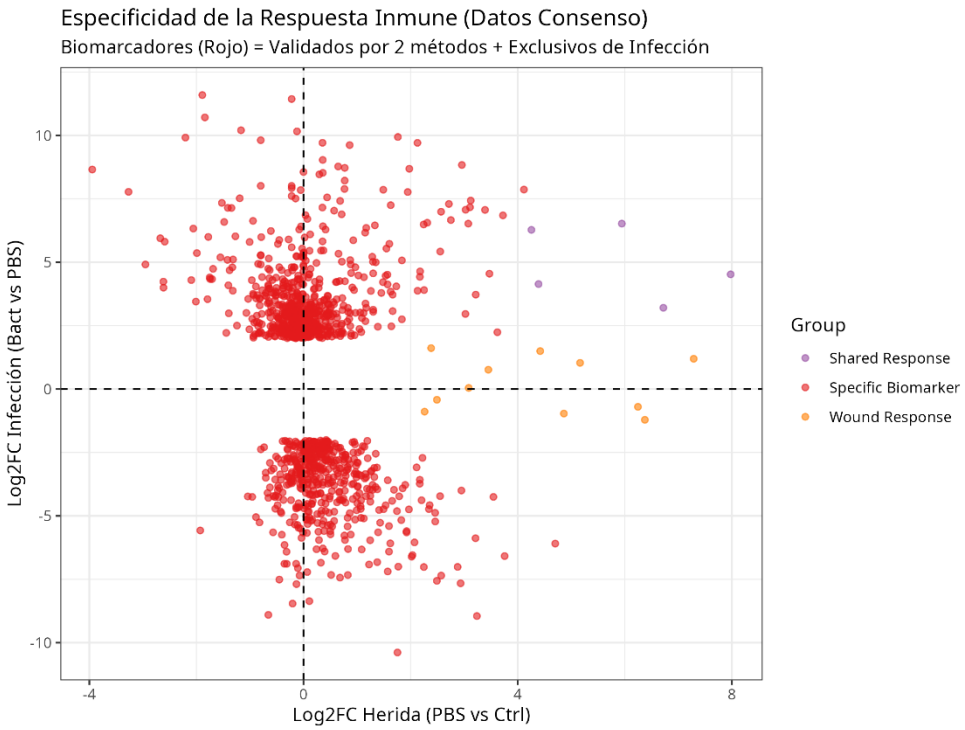

Figura 14. Scatterplot Especificidad de la Respuesta Inmune (Datos consenso)

La distribución en la gráfica es bimodal, hay una nube de genes en la parte superior fuertemente inducidos (Log2FC infección > 2) y una nube inferior de genes igualmente fuertemente reprimidos (Log2FC infección < -2). La interpretación de este patrón sugiere y confirma una reasignación masiva de recursos para la defensa contra la infección a costa de otros procesos biológicos. Estos biomarcadores en conjunto constituyen la diana principal para discutir los mecanismos de defensa de Hermetia illucens frente a patógenos gram-negativos.

7. Discusión

El análisis comparativo demuestra que tanto DESeq2 como edgeR son altamente efectivos en la detección de genes diferencialmente expresados (DEGs) frente a la infección bacteriana, demostrando que ambos tienen la capacidad de capturar la señal biológica principal. Evaluando la concordancia de la magnitud de cambio (Log2 Fold Change) entre los genes identificados por ambos paquetes, se observó un índice de correlación de Pearson de R = 1 (**Figura 12**). Esta correlación prácticamente perfecta confirma que, a nivel cuantitativo, ambas herramientas interpretan los cambios de expresión de las lecturas de manera equivalente para los genes con una señal transcripcional robusta.

Sin embargo, es importante destacar las diferencias en la cantidad de detecciones derivadas de los modelos estadísticos con los que cada paquete opera. Tal como se observa en el diagrama de intersección (**Figura 11**), DESeq2 identificó un total de 1,396 DEGs, presentando una capacidad de detección más amplia en comparación con los 1,265 DEGs detectados por edgeR. Esto evidencia que edgeR actúa como un algoritmo más conservador y restrictivo bajo los mismos parámetros de significancia (FDR < 0.001 y |Log2FC| > 2).

Estas diferencias permiten proponer una implicación crítica para los estudios transcriptómicos: un diseño experimental que aplique un único algoritmo, como el uso aislado de DESeq2 (típicamente empleado como estándar, incluyendo el estudio original del cual derivan estos datos), generará una lista de genes mayor, pero no necesariamente mejor. Aunque se aclara que los genes exclusivos detectados por DESeq2 no son biológicamente erróneos en sí mismos, sino que a nivel estadístico tienen mayor incertidumbre, asociándose a menudo con una mayor varianza o conteos crudos más bajos entre réplicas. Por ende, una estrategia metodológica que ejecute ambos métodos en paralelo, permite extraer una lista de consenso con una firma transcriptómica mucho más robusta, minimizando drásticamente la tasa de falsos positivos y garantizando que los biomarcadores seleccionados reflejen una respuesta biológica altamente robusta y doblemente verificada.

Suele ser un desafío en los estudios de transcriptómica que tienen en su diseño experimental una infección *in vivo* la distinción de la respuesta inmunitaria especifica del

patógeno del ruido transcripcional generado por el daño físico (punción en este caso). En el presente estudio, el análisis de consenso de ambos algoritmos demostró que el ruido a las 13hs exclusivo para la herida (PBS vs CTRL) es de solo 16 genes.

Biológicamente, esta drástica atenuación resulta coherente con la fisiología del insecto. En las primeras horas posteriores a un traumatismo, es urgente para la larva priorizar el control de la hemorragia y la reparación del tejido epitelial, ya que la pérdida de hemolinfa y la brecha física representan una amenaza de mayor letalidad, a menudo más inminente que la propia proliferación bacteriana, al menos en la etapa temprana. Una vez que la homeostasis física ha sido restaurada mediante procesos como la coagulación y la melanización, el organismo reorienta su maquinaria transcripcional hacia el control de la infección

Esta reorientación explica la muy marcada divergencia observada a las 13 horas, donde el esfuerzo metabólico se vuelca masivamente hacia la defensa contra la bacteria. Los datos evidencian una reacción en cadena y un marcado *trade-off* (compensación) fisiológico: es tan alto el costo energético que implica la defensa contra la bacteria que determina la activación de más de 1,245 genes específicos de infección, donde *Hermetia illucens* se ve obligada a reprimir simultáneamente funciones biológicas y metabólicas no esenciales en un esfuerzo por preservar su vida. Así que, aislar y descartar estos 16 genes asociados a la herida no solo refina la precisión estadística, sino que nos permite obtener una firma transcripcional 100% asociada a la respuesta antibacteriana pura frente a *Pseudomonas protegens*.

Tras establecer el consenso entre ambos algoritmos y aislar el efecto del daño físico, se extrajo la firma transcriptómica exclusiva de la infección en respuesta a *Pseudomonas protegens*. El análisis de los biomarcadores tanto sobre y sub expresados más significativos revela un cambio en el metabolismo extremo, validando la hipótesis del costo de la inmunidad o *trade-off* metabólico.

Por un lado, la respuesta adaptativa está dominada por una hiperactivación del sistema inmune humoral. Los transcritos con mayor magnitud de sobreexpresión diferencial corresponden a múltiples copias de AMPs, destacando cuatro variantes del gen **cecropin-like peptide 1** (ej. LOC119658402; Log2FC = 11.59 y LOC119656629; Log2FC = 11.43). Las cecropinas tienen acción lítica de alta especialización contra bacterias Gram-negativas,

como *P. protegens*. La magnitud de estos cambios, es de más de tres mil veces ($2^{11.59}$) respecto a las condiciones basales, esto evidencia que el cuerpo graso de *H. illucens* canaliza sus recursos en la defensa y síntesis contra la bacteria de manera casi exclusiva, lo que se alinea con los perfiles transcripcionales sugeridos por el estudio base (16).

En la misma proporción la larva reprime drásticamente las vías metabólicas y anabólicas no esenciales para sostener esta masiva demanda energética en defensa contra la infección. Los genes que presentan los menores niveles de subexpresión corresponden a enzimas asociadas a la digestión y asimilación de nutrientes, como **zinc carboxypeptidase-like** (LOC119651106; Log2FC = -10.38) y **lipoprotein lipase-like** (LOC119654859; Log2FC = -8.94). Adicionalmente, se observa un apagón de los procesos de desarrollo y mantenimiento basal, evidenciado por la fuerte represión de proteínas estructurales como la **cuticle protein 12.5-like** (Log2FC = -8.36) y enzimas del sistema de desintoxicación general (**cytochrome P450**, LOC119658411 y LOC119647044). Esta drástica caída transcriptómica confirma que *H. illucens* detiene temporalmente su crecimiento, digestión y metabolismo rutinario para maximizar sus probabilidades de supervivencia frente a la sepsis bacteriana.

7.1. Limitaciones y perspectivas futuras

El presente TFN se centró en la evaluación de los algoritmos y la definición de la firma transcripcional primaria, un paso lógico para futuras investigaciones será la realización del análisis de enriquecimiento funcional (gene Ontology y KEEG). Este análisis permitirá mapear las familias AMPs y enzimas metabólicas dentro de las redes de señalización biológica más complejas, confirmando las vías metabólicas precisas que coordinan este trade-off metabólico

Adicionalmente el siguiente paso como estándar en este tipo de estudios es la Validación Experimental, mediante RT-qPCR en laboratorio donde se podría validar la Firma de Alta Confianza Identificada, esto permitiría confirmar su utilidad biotecnológica como biomarcadores en la cría industrial de insectos.

Si bien el estudio original inyecto una dosis bacteriana letal, que es poco probable en entornos reales en la industria, el uso de una dosis menor, permitiría un estudio de mayor longitud con más puntos temporales (ej. 24hs, 48hs,72hs) para identificar en qué momento el insecto encuentra la homeostasis y revierte la represión de los genes metabólicos y de desarrollo.

8. Conclusiones

1. Robustez metodológica por consenso: El análisis comparativo demuestra que la elección del pipeline bioinformático influye cuantitativamente en los resultados. Si bien DESeq2 y edgeR mostraron una correlación de magnitud prácticamente perfecta (R = 1) en los genes compartidos, edgeR demostró ser más conservador. La integración de ambos algoritmos para generar una lista de consenso robusta es una estrategia metodológica superior para aislar genes con alta significancia biológica y minimizar falsos positivos estadísticos.

2. Atenuación del daño mecánico: Se demostró que a las 13 horas post-tratamiento, el impacto transcripcional exclusivo de la herida física (daño estéril) es estadísticamente marginal (identificando solo 16 genes de consenso). Esto valida la pertinencia del marco temporal elegido para un correcto aislamiento de la respuesta inmune pura frente a la infección.

3. Firma inmunitaria de alta confianza: Al filtrar el sesgo del software y el ruido de la herida, se logró identificar un núcleo robusto de 1,245 biomarcadores exclusivos de la infección por Pseudomonas protegens. Este núcleo está liderado por la sobreexpresión masiva de múltiples variantes del gen cecropin-like peptide 1.

4. Costo de la inmunidad (Trade-off metabólico): Los resultados transcriptómicos evidencian empíricamente un profundo trade-off fisiológico en *H. illucens.* La larva reasigna drásticamente sus recursos energéticos, priorizando la defensa frente a la infección mientras reprime simultáneamente genes esenciales para el metabolismo basal, como la asimilación de nutrientes (enzimas digestivas) y el desarrollo estructural (proteínas de cutícula).

9. Referencias bibliográficas

1. Wang YS, Shelomi M. Review of Black Soldier Fly (Hermetia illucens) as Animal Feed and Human Food. Foods. 18 de octubre de 2017;6(10):91. doi:10.3390/foods6100091 PubMed PMID: 29057841; PubMed Central PMCID: PMC5664030.
2. Larisa C. Waste-to-feed bioconversion using Hermetia illucens Larvae: Current insights and prospects. Open Vet J. noviembre de 2025;15(11):5427-48. doi:10.5455/OVJ.2025.v15.i11.1 PubMed PMID: 41630713; PubMed Central PMCID: PMC12861434.
3. Bonelli M. CHARACTERIZATION OF HERMETIA ILLUCENS (DIPTERA: STRATIOMYIDAE) MIDGUT [Doctoral Thesis] [Internet]. Università degli Studi di Milano; 2019 [citado 16 de febrero de 2026]. Disponible en: https://air.unimi.it/handle/2434/611925 doi:10.13130/bonelli-marco_phd2019-02-05
4. Furman DP, Young RD, Catts PaulE. Hermetia illucens (Linnaeus) as a Factor in the Natural Control of Musca domestica Linnaeus. J Econ Entomol. 1 de octubre de 1959;52(5):917-21. doi:10.1093/jee/52.5.917
5. Barragan-Fonseca KB, Dicke M, van Loon JJA. Influence of larval density and dietary nutrient concentration on performance, body protein, and fat contents of black soldier fly larvae (Hermetia illucens). Entomol Exp Appl. 2018;166(9):761-70. doi:10.1111/eea.12716
6. Abd El-Hack ME, Shafi ME, Alghamdi WY, Abdelnour SA, Shehata AM, Noreldin AE, et al. Black Soldier Fly (Hermetia illucens) Meal as a Promising Feed Ingredient for Poultry: A Comprehensive Review. Agriculture. agosto de 2020;10(8):339. doi:10.3390/agriculture10080339
7. St-Hilaire S, Cranfill K, McGuire MA, Mosley EE, Tomberlin JK, Newton L, et al. Fish Offal Recycling by the Black Soldier Fly Produces a Foodstuff High in Omega-3 Fatty Acids. J World Aquac Soc. 2007;38(2):309-13. doi:10.1111/j.1749-7345.2007.00101.x
8. Flores-Sánchez MA, Campos-Guillén J, Moure-Flores FJ de, González-Chávez MM, Galván-Camacho LA, Quezada-Morales DL, et al. Avances en el estudio de la modificación del contenido de ácidos grasos en las larvas de Hermetia illucens (Diptera: Stratiomyidae) para la producción de biodiésel a través de cambios bioquímicos en la

fuente de alimentación. TIP Rev Espec En Cienc Quím-Biológicas. 2024;27:0-0. doi:10.22201/fesz.23958723e.2024.638

9. Muchina P, Kinyua J, Khamis F, Tanga CM, Gebreyesus G, Cai Z, et al. The genomic landscape of Hermetia illucens: exploring the potential of the black soldier fly through molecular insights. J Insects Food Feed. 30 de abril de 2025;11(12):2049-74. doi:10.1163/23524588-bja10200
10. Antonov A, Ivanov G, Pastukhova N, Bovykina G. Production of chitin from dead Hermetia Illucens. IOP Conf Ser Earth Environ Sci. 23 de agosto de 2019;315:042003. doi:10.1088/1755-1315/315/4/042003
11. Hutton B. Quantifying the greenhouse impacts of landfill, composting and incineration: a review of IPCC and US EPA models, and implications for climate change policy [thesis] [Internet]. RMIT University; 2024 [citado 19 de febrero de 2026]. Disponible en: https://research-repository.rmit.edu.au/articles/thesis/Quantifying_the_greenhouse_impacts_of_landfill_composting_and_incineration_a_review_of_IPCC_and_US_EPA_models_and_implications_for_climate_change_policy/27596703/1 doi:10.25439/rmt.27596703
12. De Gregorio E, Spellman PT, Rubin GM, Lemaitre B. Genome-wide analysis of the Drosophila immune response by using oligonucleotide microarrays. Proc Natl Acad Sci U S A. 23 de octubre de 2001;98(22):12590-5. doi:10.1073/pnas.221458698 PubMed PMID: 11606746; PubMed Central PMCID: PMC60098.
13. Li F, Wang X, Zhou X. The Genomics Revolution Drives a New Era in Entomology. Annu Rev Entomol. 28 de enero de 2025;70(Volume 70, 2025):379-400. doi:10.1146/annurev-ento-013024-013420
14. Transcriptome Fact Sheet [Internet]. [citado 20 de febrero de 2026]. Disponible en: https://www.genome.gov/about-genomics/fact-sheets/Transcriptome-Fact-Sheet
15. Dunaevsky YE, Elpidina EN. Special Issue “Transcriptomics in the Study of Insect Biology”. Int J Mol Sci. 22 de noviembre de 2024;25(23):12582. doi:10.3390/ijms252312582 PubMed PMID: 39684294; PubMed Central PMCID: PMC11640794.
16. Shah PN, Maistrou S, Willemsen I, Loon JJA van, Dicke M. Transcriptomic response of Hermetia illucens L. (Diptera: Stratiomyidae) to wounding and Gram-negative bacterial infection. J Insects Food Feed. 1 de octubre de 2024;11(4):751-71. doi:10.1163/23524588-00001211

17. Love MI, Huber W, Anders S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. Genome Biol. 5 de diciembre de 2014;15(12):550. doi:10.1186/s13059-014-0550-8
18. thelovelab. GitHub [Internet]. [citado 23 de febrero de 2026]. DESeq2/vignettes/DESeq2.Rmd at devel · thelovelab/DESeq2. Disponible en: https://github.com/thelovelab/DESeq2/blob/devel/vignettes/DESeq2.Rmd
19. Robinson M, McCarthy D, Chen Y, Smyth GK. edgeR: differential expression analysis of digital gene expression data.
20. Piper MM Radhika Khetani, Mary. Introduction to DGE - ARCHIVED [Internet]. 2019 [citado 23 de febrero de 2026]. Count normalization with DESeq2. Disponible en: https://hbctraining.github.io/DGE_workshop_salmon/lessons/02_DGE_count_normalization.html
21. Maza E. In Papyro Comparison of TMM (edgeR), RLE (DESeq2), and MRN Normalization Methods for a Simple Two-Conditions-Without-Replicates RNA-Seq Experimental Design. Front Genet. 16 de septiembre de 2016;7:164. doi:10.3389/fgene.2016.00164 PubMed PMID: 27695478; PubMed Central PMCID: PMC5025571.
22. mikelove A. DESeq2 or edgeR. Mike Love's blog [Internet]. 28 de septiembre de 2016 [citado 23 de febrero de 2026]. Disponible en: https://mikelove.wordpress.com/2016/09/28/deseq2-or-edger/
23. Leinonen R, Sugawara H, Shumway M, on behalf of the International Nucleotide Sequence Database Collaboration. The Sequence Read Archive. Nucleic Acids Res. 1 de enero de 2011;39(suppl_1):D19-21. doi:10.1093/nar/gkq1019
24. Babraham Bioinformatics - FastQC A Quality Control tool for High Throughput Sequence Data [Internet]. [citado 25 de febrero de 2026]. Disponible en: https://www.bioinformatics.babraham.ac.uk/projects/fastqc/
25. Ewels P, Magnusson M, Lundin S, Käller M. MultiQC: summarize analysis results for multiple tools and samples in a single report. Bioinformatics. 1 de octubre de 2016;32(19):3047-8. doi:10.1093/bioinformatics/btw354
26. Chen S, Zhou Y, Chen Y, Gu J. fastp: an ultra-fast all-in-one FASTQ preprocessor. Bioinformatics. 1 de septiembre de 2018;34(17):i884-90. doi:10.1093/bioinformatics/bty560
27. Generalovic TN, McCarthy SA, Warren IA, Wood JMD, Torrance J, Sims Y, et al. A high-quality, chromosome-level genome assembly of the Black Soldier Fly (Hermetia

illucens L.). G3. 7 de mayo de 2021;11(5):jkab085. doi:10.1093/g3journal/jkab085 PubMed PMID: 33734373; PubMed Central PMCID: PMC8104945.

28. Dobin A, Davis CA, Schlesinger F, Drenkow J, Zaleski C, Jha S, et al. STAR: ultrafast universal RNA-seq aligner. Bioinformatics. 1 de enero de 2013;29(1):15-21. doi:10.1093/bioinformatics/bts635

29. Liao Y, Smyth GK, Shi W. featureCounts: an efficient general purpose program for assigning sequence reads to genomic features. Bioinformatics. 1 de abril de 2014;30(7):923-30. doi:10.1093/bioinformatics/btt656

30. Robinson MD, McCarthy DJ, Smyth GK. edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. Bioinformatics. 1 de enero de 2010;26(1):139-40. doi:10.1093/bioinformatics/btp616

10. Anexos:

Anexo 1. SRR_List_Final_15.txt . Descarga de srr files (13hs) por via ftp

```
(transcriptomics_env) didier@DidierBioInfo:~/Documents/TFM_Hermetia/01_data$
prefetch --option-file SRR_List_Final_15.txt
2026-02-24T06:30:10 prefetch.3.2.1: 1) Resolving 'SRR28624562'...
2026-02-24T06:30:13 prefetch.3.2.1: Current preference is set to retrieve SRA
Normalized Format files with full base quality scores
2026-02-24T06:30:14 prefetch.3.2.1: 1) Downloading 'SRR28624562'...
2026-02-24T06:30:14 prefetch.3.2.1:  SRA Normalized Format file is being
retrieved
2026-02-24T06:30:14 prefetch.3.2.1:  Downloading via HTTPS...
```

Anexo 2. 00_sra_to_fastq.sh : Conversion sra a fastq

```
#!/bin/bash
# ---------------------------------------------------------------------------
# Nombre: 00_sra_to_fastq.sh
# ---------------------------------------------------------------------------

# 1. Configuración de carpetas
DIR_SRA="01_data/raw_sra"          # carpeta origen con .sra files
DIR_FASTQ="01_data/raw_fastq"      # Carpeta destino con .fastq procesados
LISTA_IDS="01_data/SRR_List_Final_15.txt" # La lista de 15 IDs
filtrados(5d+13hs)

# Parametros de rendimiento
```

```
HILOS=18
MEMORIA="24000MB"

# 2. Bucle Principal: Leer cada ID línea por línea
while read -r SAMPLE_ID; do

    # Estructura de cada sra: raw_sra/SRRxxxxxx/SRRxxxxxx.sra
    ARCHIVO_SRA="${DIR_SRA}/${SAMPLE_ID}/${SAMPLE_ID}.sra"

    if [ -f "$ARCHIVO_SRA" ]; then

        fasterq-dump \
            --split-files \ # separacion lecturas forward y reverse
            --threads "$HILOS" \
            --mem "$MEMORIA" \
            --progress \
            --outdir "$DIR_FASTQ" \
            "$ARCHIVO_SRA"

        echo "Muestra $SAMPLE_ID convertida exitosamente."
    fi

done < "$LISTA_IDS"
```

Anexo 3. 01_fastqc.sh : Evaluación de la calidad de las lecturas Raw

```
#!/bin/bash
# ---------------------------------------------------------------------------
# Nombre: 01_fastqc.sh
# ---------------------------------------------------------------------------

# 1. Configuracion de carpetas
```

```
DIR_INPUT="01_data/raw_fastq"
DIR_OUTPUT="03_results/01_fastqc_raw"

# 2. Ejecutar FastQC
fastqc -t 18 -o "$DIR_OUTPUT" "$DIR_INPUT"/*.fastq

# 3. Ejecutar MultiQC - Unificacion de informes
multiqc "$DIR_OUTPUT" -o "$DIR_OUTPUT" -n "TFM_Raw_Data_Report"

echo "Reportes generados y Unificados"
```

Anexo 4. 02_fastp.sh : Procesamientos de muestras, recorte de calidad y adaptadores

```
#!/bin/bash
# ---------------------------------------------------------------------------
# Nombre: 02_fastp.sh
# ---------------------------------------------------------------------------

# 1. Configuracion de carpetas y rendimiento
DIR_INPUT="01_data/raw_fastq"
DIR_OUTPUT="03_results/02_fastp_cleaned"
DIR_REPORT="03_results/02_fastp_cleaned/reports"
THREADS=18

# 3. Bucle para procesar cada muestra
# Buscamos solo R1 (_1.fastq) para "anclar" R2 (_2.fastq)
for R1 in "$DIR_INPUT"/*_1.fastq; do

    # Obtener el nombre base sin ruta ni sufijo
    FILENAME=$(basename "$R1")
    SAMPLE_ID="${FILENAME%_1.fastq}"

    # Definir el nombre del par R2 (_2.fastq)
```

```
    R2="$DIR_INPUT/${SAMPLE_ID}_2.fastq"

    # Definir nombres de salida (Cleaned) en .gz
    OUT_R1="$DIR_OUTPUT/${SAMPLE_ID}_1.clean.fastq.gz"
    OUT_R2="$DIR_OUTPUT/${SAMPLE_ID}_2.clean.fastq.gz"

    # Definir reportes HTML y JSON por muestra
    HTML_R="$DIR_REPORT/${SAMPLE_ID}_fastp.html"
    JSON_R="$DIR_REPORT/${SAMPLE_ID}_fastp.json"

    # Parametros fastp
    # --detect_adapter_for_pe: Auto-detectar adaptadores para Paired-End
    # --qualified_quality_phred 20: Cortar si la calidad menor de Q20
    # --length_required 25: Descartar lecturas menores a 25bp tras cortar

    fastp \
        --in1 "$R1" \
        --in2 "$R2" \
        --out1 "$OUT_R1" \
        --out2 "$OUT_R2" \
        --thread "$THREADS" \
        --detect_adapter_for_pe \
        --qualified_quality_phred 20 \
        --length_required 25 \
        --html "$HTML_R" \
        --json "$JSON_R"

    echo "Muestra $SAMPLE_ID limpiada."
done

echo "=== Archivos procesados ==="
```

Anexo 5. Obtención del genoma de referencia y archivo de anotación:

```
cd 01_data/reference_genome/

# 1. Descarga del genoma de referencia

wget
https://ftp.ncbi.nlm.nih.gov/genomes/all/GCF/905/115/235/GCF_905115235.1_iHerIll2.2.curated.20191125/GCF_905115235.1_iHerIll2.2.curated.20191125_genomic.fna.gz

# 3. Descargar la Anotación (formato NCBI .gff)
wget
https://ftp.ncbi.nlm.nih.gov/genomes/all/GCF/905/115/235/GCF_905115235.1_iHerIll2.2.curated.20191125/GCF_905115235.1_iHerIll2.2.curated.20191125_genomic.gff.gz

# 4. Descomprimir
gunzip *.gz

# 5. Verificación
ls -lh
```

Anexo 6. 03_star_index.sh : Creación de índice

```
#!/bin/bash
# ---------------------------------------------------------------------------
# Nombre: 03_star_index.sh
# ---------------------------------------------------------------------------

GENOME_DIR="01_data/reference_genome/star_index"
FASTA_FILE=$(ls 01_data/reference_genome/*.fna)
ANNOTATION_FILE=$(ls 01_data/reference_genome/*.gff)
```

```
# Parametros STAR - Creacion de indice

STAR --runThreadN 18 \
    --runMode genomeGenerate \
    --genomeDir $GENOME_DIR \
    --genomeFastaFiles $FASTA_FILE \
    --sjdbGTFfile $ANNOTATION_FILE \
    --sjdbOverhang 149 \
    --genomeSAindexNbases 13

echo "Índice generado"
```

Anexo 7. 04_star_align : Alineamiento contra genoma de referencia

```
#!/bin/bash
# -------------------------------------------
# Nombre: 04_star_align.sh
# -------------------------------------------

# Configuración de carpetas y rendimiento
GENOME_DIR="01_data/reference_genome/star_index"
INPUT_DIR="03_results/02_fastp_cleaned"
OUTPUT_DIR="03_results/03_star_alignment"
THREADS=18

# Bucle para procesar cada muestra
for R1 in $INPUT_DIR/*_1.clean.fastq.gz; do

   # 1. Obtener nombres base sin ruta ni sufijo
   FILENAME=$(basename "$R1")
   SAMPLE_NAME="${FILENAME%_1.clean.fastq.gz}"
```

```
    # Definimos nombre del par R2 con misma estructura
    R2="$INPUT_DIR/${SAMPLE_NAME}_2.clean.fastq.gz"

    # Prefijo de salida
    OUT_PREFIX="$OUTPUT_DIR/${SAMPLE_NAME}_"

    echo "Procesando muestra: $SAMPLE_NAME"
    echo "Input R1: $R1"
    echo "Input R2: $R2"

    # 2. Parametros STAR
    # --readFilesCommand zcat : Archivos .gz

    STAR --runThreadN $THREADS \
        --genomeDir $GENOME_DIR \
        --readFilesIn "$R1" "$R2" \
        --readFilesCommand zcat \
        --outFileNamePrefix "$OUT_PREFIX" \
        --outSAMtype BAM SortedByCoordinate \
        --outSAMunmapped Within \
        --outSAMattributes Standard

    echo "Muestra: $SAMPLE_NAME procesada"
done

echo "ALINEAMIENTO COMPLETO"
```

Anexo 8. 04_featurecounts.sh : Cuantificación de la expresión génica

```
#!/bin/bash
```

```
# ------------------------------------------
# Nombre: 04_featurecounts.sh
# ------------------------------------------

# 1. Configuracion de carpetas
INPUT_DIR="03_results/03_star_alignment"
OUTPUT_DIR="03_results/04_featurecounts"
GENOME_GFF="01_data/reference_genome/GCF_905115235.1_iHerIll2.2.curated.20191
125_genomic.gff"

# 2. Configuración de featureCounts
# -p: Contar fragmentos (paired-end)
FEATURE_TYPE="exon" # Busqueda por exon
ATTR_TYPE="Dbxref" # Agrupacion de exones por gen

# 3. Ejecución
featureCounts \
   -p \
   --countReadPairs \
   -T 18 \
   -t $FEATURE_TYPE \
   -g $ATTR_TYPE \
   -a "$GENOME_GFF" \
   -o "$OUTPUT_DIR/counts_matrix.txt" \
   $INPUT_DIR/SRR*.bam

echo "Cuantificación completada"
```

Anexo 9. 05_dge_analysis.R : Cuantificación de la expresión génica

```
#==================================================================
======
#1. CONFIGURACION INICIAL DE LIBRERÍAS
```

```
=================================================================
======
if (!require("BiocManager", quietly = TRUE)) install.packages("BiocManager")

paquetes_necesarios <- c("DESeq2", "edgeR", "tidyverse", "ggplot2", "ggrepel",
"ggVennDiagram",                    "pheatmap", "RColorBrewer", "apeglm")

#Instalacion de librerias
for(p in paquetes_necesarios){
        if(!require(p, character.only = TRUE)) BiocManager::install(p)
}

#Carga de librerías
library(tidyverse)
library(DESeq2)
library(edgeR)
library(ggplot2)
library(ggrepel)
library(ggVennDiagram)
library(pheatmap)
library(RColorBrewer)
library(apeglm)

#Configuracion de carpetas
out_dir_plots <- "03_results/05_dge_analysis/plots/"
out_dir_tables <- "03_results/05_dge_analysis/tables/"


#=================================================================
======
# 2. CARGA Y LIMPIEZA DE DATOS
#=================================================================
======
#Rutas
```

```
ruta_counts <- "03_results/04_featurecounts/counts_matrix.txt"
ruta_metadata <- "01_data/SraRunTable.csv"

#A. Cargar Conteos
raw_counts <- read.table(file = ruta_counts, header = TRUE, sep = "\t", skip = 1)
colnames(raw_counts)[1] <- "GeneID"

#B. Limpieza de nombres de columnas
colnames(raw_counts) <- gsub(".(SRR[0-9]+).", "\1", colnames(raw_counts))

#C. Suma de isoformas y limpieza de GeneID
clean_counts <- raw_counts %>%
	mutate(GeneID = str_extract(GeneID, "(?<=GeneID:)\d+")) %>%
	filter(!is.na(GeneID)) %>% # eliminar filas que no cumplieron con el regex

	group_by(GeneID) %>% summarise(across(starts_with("SRR"), sum)) %>%
	column_to_rownames(var = "GeneID")

#==================================================================
======
# 3. PREPARACIÓN DE METADATOS (15 Muestras)
#==================================================================
======
raw_metadata <- read.csv(ruta_metadata, stringsAsFactors = FALSE)

metadata <- raw_metadata %>%
	filter(Developmental_Stage == "5 day + 13 h") %>%
	mutate(
		Run = as.character(Run),
		Condition = case_when(
			treatment == "Untreated control" ~ "Untreated",
			treatment == "PBS-injected control" ~ "PBS",
			treatment == "Pseudomonas protegens Pf-5-injected" ~ "Bacteria",
			TRUE ~ "Error"
```

```
                )
        ) %>%
        dplyr::select(Run, Condition)

#Verificar integridad
if(any(metadata$Condition == "Error")) stop("Error en nombres de tratamiento.")

#Alinear Muestras (Intersección Counts vs Metadatos)
common_samples <- intersect(colnames(clean_counts), metadata$Run)
if(length(common_samples) < 15) warning("Menos de 15 muestras detectadas.")

clean_counts_final <- clean_counts[, common_samples]
metadata_final <- metadata %>%
        filter(Run %in% common_samples) %>%
        arrange(match(Run,colnames(clean_counts_final))) %>%
        column_to_rownames("Run")

#Definir Factores
metadata_final$Condition <- factor(metadata_final$Condition,
                                   levels = c("Untreated", "PBS", "Bacteria"))

#=================================================================
======
# 4. ANÁLISIS EXPLORATORIO (PCA & Heatmap)
#=================================================================
======
#Creacion objeto DESeq para QC
dds_qc <- DESeqDataSetFromMatrix(countData = clean_counts_final,
                                 colData = metadata_final,
                                 design = ~ Condition)

#Transformación VST (Variance Stabilizing Transformation) para gráficos
vsd <- vst(dds_qc, blind = FALSE)
```

```
#--- FIGURA 2: PCA PLOT ---
pcaData <- plotPCA(vsd, intgroup = "Condition", returnData = TRUE)
percentVar <- round(100 * attr(pcaData, "percentVar"))

p_pca <- ggplot(pcaData, aes(PC1, PC2, color = Condition)) +
        geom_point(size = 4, alpha = 0.8) +
        scale_color_manual(values = c("Untreated"="#1B9E77", "PBS"="#D95F02",
                                      "Bacteria"="#7570B3")) +
        xlab(paste0("PC1: ", percentVar[1], "% variance")) +
        ylab(paste0("PC2: ", percentVar[2], "% variance")) +
        labs(title = "PCA: Transcriptoma H. illucens (13h)",
             subtitle = "Verificación de Agrupamiento Biológico") +
        theme_bw() +
        theme(legend.position = "bottom")

ggsave(paste0(out_dir_plots, "Figura2_PCA_Plot.png"), p_pca, width = 7, height = 6)

#--- FIGURA 3: HEATMAP DE DISTANCIAS ---
sampleDists <- dist(t(assay(vsd)))
sampleDistMatrix <- as.matrix(sampleDists)
colors <- colorRampPalette(rev(brewer.pal(9, "Blues")))(255)

pheatmap(sampleDistMatrix,
        clustering_distance_rows = sampleDists,
        clustering_distance_cols = sampleDists,
        col = colors,
        main = "Distancia Euclidiana entre Muestras",
        filename = paste0(out_dir_plots, "Figura3_Heatmap_Distancias.png"))



#==================================================================
======
# 5. PIPELINE A: DESeq2
```

```
#=================================================================
======
#A. Crear Objeto y Filtrar
dds <- DESeqDataSetFromMatrix(countData = clean_counts_final,
                                                colData = metadata_final,
                                                design = ~ Condition)
dds <- dds[rowSums(counts(dds)) > 20, ] # Filtro Shah et al.

#B. Ejecutar DESeq
dds <- DESeq(dds)

# --- CONTRASTES BIOLÓGICOS ---
# 1. Efecto Infección (Bacteria vs PBS)
res_infection_deseq <- results(dds, contrast = c("Condition", "Bacteria", "PBS"), alpha =
0.05)
# Shrinkage para visualización (LFC más precisos)
res_infection_lfc <- lfcShrink(dds, contrast = c("Condition", "Bacteria", "PBS"), type =
"normal")

2. Efecto Herida (PBS vs Untreated) *Relevante para consenso posterior
res_wound_deseq <- results(dds, contrast = c("Condition", "PBS", "Untreated"), alpha =
0.05)

# Guardar Tablas Crudas
write.csv(as.data.frame(res_infection_deseq), paste0(out_dir_tables,
"DESeq2_RAW_Infection_Bacteria_vs_PBS.csv"))

# --- FIGURA 4A: VOLCANO PLOT DESeq2 ---
# Función auxiliar para Volcano Plots consistentes
plot_volcano <- function(res_df, title) {
        df <- as.data.frame(res_df) %>%
                mutate(GeneID = rownames(.),
                        Type = case_when(
                                padj < 0.001 & log2FoldChange > 2 ~ "Up",
```

```
                                padj < 0.001 & log2FoldChange < -2 ~ "Down",
                                TRUE ~ "NS"
                        ))

ggplot(df, aes(x = log2FoldChange, y = -log10(padj), color = Type)) +
        geom_point(alpha = 0.6, size = 1.5) +
        scale_color_manual(values = c("Up" = "#E41A1C", "Down" = "#377EB8", "NS" =
"grey80")) +
        geom_vline(xintercept = c(-2, 2), linetype = "dashed") +
        geom_hline(yintercept = -log10(0.001), linetype = "dashed") +
        labs(title = title, x = "Log2 Fold Change", y = "-Log10 FDR") +
        theme_minimal() + theme(legend.position = "none")
}
p_volc_deseq <- plot_volcano(res_infection_deseq, "DESeq2: Infección (Bacteria vs
PBS)") ggsave(paste0(out_dir_plots, "Figura4A_Volcano_DESeq2.png"), p_volc_deseq,
width = 6, height = 5)

# ---------------------------------------------------------------------------
# 5.1. HEATMAP DESeq2 (Figura 4B)
# ---------------------------------------------------------------------------
top50_genes_deseq <- head(order(res_infection_deseq$padj), 50)
genes_id_deseq <- rownames(res_infection_deseq)[top50_genes_deseq]

mat_deseq <- assay(vsd)[genes_id_deseq, ]
mat_deseq <- t(scale(t(mat_deseq)))

# Añadir anotaciones de columnas (Condición)
df_col <- as.data.frame(colData(dds)[, c("Condition"), drop=FALSE])

pheatmap(mat_deseq,
        annotation_col = df_col,
        show_rownames = FALSE,
        main = "Top 50 DEGs - Infección (DESeq2)",
        color = colorRampPalette(c("navy", "white", "firebrick3"))(50),
```

```
filename = paste0(out_dir_plots, "Figura4B_Heatmap_Top50_DESeq2.png"))


#=================================================================
======
# 6. PIPELINE B: edgeR
#
=================================================================
====
#A. Crear Objeto DGEList
dge <- DGEList(counts = clean_counts_final, group = metadata_final$Condition)

#B. Filtrar (Mismos genes que DESeq2 para comparacion equivalente)
genes_in_deseq <- rownames(dds)
dge <- dge[genes_in_deseq, , keep.lib.sizes = FALSE]

# C. Normalización TMM
dge <- calcNormFactors(dge, method = "TMM")

#D. Diseño Experimental
design_edgeR <- model.matrix(~0 + Condition, data = metadata_final)
colnames(design_edgeR) <- levels(metadata_final$Condition)

# E. Estimación de Dispersión y Ajuste QL
dge <- estimateDisp(dge, design_edgeR)
fit <- glmQLFit(dge, design_edgeR)

# --- CONTRASTES BIOLOGICOS ---
# 1. Efecto Infeccion (Bacteria vs PBS)
contrast_infection <- makeContrasts(Bacteria - PBS, levels = design_edgeR)

# Test F (Quasi-Likelihood)
qlf_infection <- glmQLFTest(fit, contrast = contrast_infection)
```

```
# Tabla de Resultados edgeR
res_edgeR_table <- topTags(qlf_infection, n = Inf, sort.by = "none")$table
write.csv(res_edgeR_table, paste0(out_dir_tables,
"edgeR_RAW_Infection_Bacteria_vs_PBS.csv"))

# 2. Efecto herida (PBS vs Untreated) --- Consenso posterior
contrast_wound <- makeContrasts(PBS - Untreated, levels = design_edgeR)
qlf_wound <- glmQLFTest(fit, contrast = contrast_wound)
res_edgeR_wound_table <- topTags(qlf_wound, n = Inf, sort.by = "none")$table
# --- FIGURA 5A: VOLCANO PLOT edgeR --
df_edgeR_volc <- res_edgeR_table %>%
        rename(log2FoldChange = logFC, padj = FDR)

p_volc_edgeR <- plot_volcano(df_edgeR_volc, "edgeR: Infección (Bacteria vs PBS)")
ggsave(paste0(out_dir_plots, "Figura5A_Volcano_edgeR.png"), p_volc_edgeR, width = 6,
height = 5)

# ---------------------------------------------------------------------------
# 6.1. HEATMAP edgeR (Figura 5B)
# ---------------------------------------------------------------------------
top_edgeR <- res_edgeR_table %>% arrange(FDR) %>% head(50)
genes_id_edgeR <- rownames(top_edgeR)

mat_edgeR <- assay(vsd)[genes_id_edgeR, ]
mat_edgeR <- t(scale(t(mat_edgeR)))

pheatmap(mat_edgeR,
        annotation_col = df_col,
        show_rownames = FALSE,
        main = "Top 50 DEGs - Infección (edgeR)",
        color = colorRampPalette(c("navy", "white", "firebrick3"))(50),
        filename = paste0(out_dir_plots, "Figura5B_Heatmap_Top50_edgeR.png"))
```

```
#==================================================================
======
# 7. COMPARACIÓN METODOLÓGICA - Software
# 7.1 DESeq2 vs edgeR
#==================================================================
======
# A. Filtrado Estricto (FDR < 0.001, |LFC| > 2)
sig_deseq <- as.data.frame(res_infection_deseq) %>%
        filter(padj < 0.001 & abs(log2FoldChange) > 2) %>% rownames()

sig_edgeR <- res_edgeR_table %>%
        filter(FDR < 0.001 & abs(logFC) > 2) %>% rownames()

# B. Exportar Listas Finales Estrictas
write(sig_deseq, paste0(out_dir_tables, "Lista_Genes_DESeq2_Estricta.txt"))
write(sig_edgeR, paste0(out_dir_tables, "Lista_Genes_edgeR_Estricta.txt"))

# --- FIGURA 6: DIAGRAMA DE VENN --- DESeq2 vs edgeR
venn_list <- list(DESeq2 = sig_deseq, edgeR = sig_edgeR)
p_venn <- ggVennDiagram(venn_list, label_alpha = 0) +
        scale_fill_gradient(low = "#F4FAFE", high = "#4981BF") +
        labs(title = "Intersección de DEGs (Infección)")

ggsave(paste0(out_dir_plots, "Figura6_Venn_Comparison.png"), p_venn, width = 6, height
= 6)

--- FIGURA 7: SCATTERPLOT DE CONCORDANCIA DESeq2 vs edgeR ---
# 1. Union de resultados de ambos pipelines por GeneID
df_deseq_full <- as.data.frame(res_infection_deseq) %>%
rownames_to_column("GeneID") df_edger_full <- res_edgeR_table %>%
rownames_to_column("GeneID")

comparison_sig <- inner_join(df_deseq_full, df_edger_full, by="GeneID",
suffix=c("_DESeq2", "_edgeR")) %>%
```

```
        dplyr::rename(LFC_DESeq2 = log2FoldChange, LFC_edgeR = logFC)

# 2. Clasificación para colorear
comparison_sig <- comparison_sig %>%
        mutate(Clasificacion = case_when(
                GeneID %in% sig_deseq & GeneID %in% sig_edgeR ~ "Consistente
        (Ambos)",
                GeneID %in% sig_deseq ~ "Solo DESeq2",
                GeneID %in% sig_edgeR ~ "Solo edgeR",
                TRUE ~ "No significativo / Otro"
         )) %>%
         filter(Clasificacion != "No significativo / Otro") # Ignoramos genes no detectados
por ninguno

cor_val <- round(cor(comparison_sig$LFC_DESeq2, comparison_sig$LFC_edgeR,
method = "pearson"), 3)

# 3. Visualización
p_scatter <- ggplot(comparison_sig, aes(x = LFC_DESeq2, y = LFC_edgeR, color =
Clasificacion)) +
        geom_point(alpha = 0.6, size = 1.5) +
        geom_abline(intercept = 0, slope = 1, color = "gray50", linetype = "dashed") +
        geom_smooth(method = "lm", se = FALSE, color = "black", linetype = "solid",
linewidth =
        0.5) +
        scale_color_manual(values = c("Consistente (Ambos)" = "#800080",
                                       "Solo DESeq2" = "#D55E00",
                                        "Solo edgeR" = "#0072B2")) +
        labs(title = "Concordancia de LFC: DESeq2 vs edgeR",
                subtitle = paste0("Correlación de Pearson R = ", cor_val, " | Regresión
        lineal"),
                x = expression(Log[2]FoldChange(DESeq2)),
                y = expression(Log[2]FoldChange(edgeR))) +
        theme_bw() +
```

```
        theme(legend.position = "bottom", legend.title = element_blank())

ggsave(paste0(out_dir_plots, "Figura7_Scatterplot_Concordancia.png"), p_scatter, width =
6, height = 6)

#=================================================================
======
# 7. COMPARACIÓN METODOLÓGICA - Biologica
# 7.2 Herida vs Pinchazo (Analisis por consenso)
#=================================================================
======
# EXTRAER CONTRASTES BIOLÓGICOS (DESeq2 y edgeR)
# A. Efecto HERIDA (Wounding): PBS vs Untreated
res_wound <- results(dds, contrast = c("Condition", "PBS", "Untreated"), alpha = 0.05)
df_wound <- as.data.frame(res_wound) %>%
        filter(padj < 0.001 & abs(log2FoldChange) > 2) # Filtro Estricto
genes_wound_deseq <- rownames(df_wound)

genes_wound_edgeR <- res_edgeR_wound_table %>%
        filter(FDR < 0.001 & abs(logFC) > 2) %>% rownames()

#Consenso Herida (Intersección métodos)
consensus_wound <- intersect(genes_wound_deseq, genes_wound_edgeR)

# B. Efecto INFECCIÓN (Specific Immunity): Bacteria vs PBS
consensus_inf <- intersect(sig_deseq, sig_edgeR)

# Figura 8. DIAGRAMA DE VENN BIOLÓGICO
venn_data_bio <- list(
        "Herida (General Stress)" = consensus_wound,
        "Infección (Specific Immunity)" = consensus_inf
)

p_venn_bio <- ggVennDiagram(venn_data_bio, label_alpha = 0) +
```

```
        scale_fill_gradient(low = "#F4FAFE", high = "#E41A1C") +
        labs(title = "Solapamiento Biológico Robusto",
             subtitle = "Intersección DESeq2 + edgeR (FDR<0.001, |LFC|>2)") +
        theme(plot.title = element_text(hjust = 0.5, face = "bold"))

ggsave(paste0(out_dir_plots, "Figura8_Venn_Wound_vs_Infection_ROBUST.png"),
p_venn_bio, width = 7, height = 7)




#=====================================================================
======
# 8. IDENTIFICACIÓN DE BIOMARCADORES EXCLUSIVOS (High Confidence)
#=====================================================================
======
# Definición: Genes de Infeccion NO aparecen en Herida (despues de consenso)
biomarkers <- setdiff(consensus_inf, consensus_wound)

# Extraemos estadísticas (Usamos LFC de DESeq2 como referencia)
df_biomarkers <- as.data.frame(res_infection_deseq) %>%
        filter(rownames(.) %in% biomarkers) %>%
        dplyr::select(log2FoldChange, padj) %>%
        arrange(desc(log2FoldChange)) %>%
        mutate(Type = "High_Confidence_Infection_Specific")

#Guardar
write.csv(df_biomarkers, paste0(out_dir_tables,
"Biomarcadores_Infeccion_Consenso.csv"))


#=====================================================================
======
```

```
# 9. SCATTERPLOT DE RESPUESTAS (Visualizacion del Consenso)
#=================================================================
======
# Scatterplot de Correlación Biológica
df_scatter <- merge(as.data.frame(res_wound), as.data.frame(res_infection_deseq),
                    by = 0, suffixes = c("_Wound", "_Inf")) %>%
          column_to_rownames("Row.names")

df_scatter$Group <- "Not Significant / Other"
df_scatter[consensus_wound, "Group] <- "Wound Response"
df_scatter[consensus_inf, "Group"] <- "Infection Response"
df_scatter[intersect(consensus_wound, consensus_inf), "Group"] <- "Shared Response"
df_scatter[biomarkers, "Group"] <- "Specific Biomarker"

# Filtrado de puntos irrelevantes
df_plot <- df_scatter %>% filter(Group != "Not Significant / Other")

p_scatter_bio <- ggplot(df_plot, aes(x = log2FoldChange_Wound, y = log2FoldChange_Inf,
color = Group)) +
          geom_point(alpha = 0.6, size = 1.5) +
          scale_color_manual(values = c("Wound Response" = "#FF7F00",
                                        "Infection Response" = "#377EB8",
                                        "Shared Response" = "#984EA3",
                                        "Specific Biomarker" = "#E41A1C")) +
          geom_hline(yintercept = 0, linetype = "dashed") +
          geom_vline(xintercept = 0, linetype = "dashed") +
          labs(title = "Especificidad de la Respuesta Inmune (Datos Consenso)",
                    subtitle = "Biomarcadores (Rojo) = Validados por 2 métodos + Exclusivos
          de
                    Infección",
                    x = "Log2FC Herida (PBS vs Ctrl)",
                    y = "Log2FC Infección (Bact vs PBS)") +
          theme_bw()
```

```
ggsave(paste0(out_dir_plots, "Figura_Scatter_Biologico_Robust.png"), p_scatter_bio,
width = 8, height = 6)
```