Universidad Internacional de Valencia

Impacto de los polimorfismos del gen *APOE* en la progresión clínica de la enfermedad de Huntington

Titulación:	Alumno/a: de Lara Pérez, Daniel	Convocatoria:
Máster Universitario en Bioinformática	DNI: 71308977F	
Curso Académico 2025-2026	Director/a del TFT: Neef, Alexander	PRIMERA

De:
Planeta Formación y Universidades

Índice general

Índice de figuras 1

Índice de tablas 1

Lista de abreviaturas 5

1 Resumen 6

2 Abstract 7

3 Introducción 9

4 Objetivos 11
- 4.1 Objetivo general . . . 11
- 4.2 Objetivos específicos . . . 11

5 Metodología 12
- 5.1 Muestra . . . 12
- 5.2 Tipo y diseño de estudio . . . 15
- 5.3 Métodos . . . 15
- 5.4 Evaluación de la calidad del mapping y variant calling . . . 18
- 5.5 Análisis estadístico . . . 18

6 Resultados y discusión 31
- 6.1 Resultados de la Pipeline . . . 31
- 6.2 Resultados de Machine Learning . . . 33
- 6.3 Discusión . . . 37

7 Conclusiones 44

8 Limitaciones y Perspectivas futuras 45

9 Anexos 48
- 9.1 Repositorio en GitHub . . . 48
- 9.2 Pipeline completo . . . 48

Índice de figuras

5.1 Aumento del número de pacientes disponible con los años. En el eje X se observan los años desde la creación de la plataforma enroll-HD. En el eje Y se muestra el número de pacientes disponibles en su estudio 16
5.2 Representación esquemática del workflow del pipeline. 28
5.3 Representación esquemática del enlace entre los workflows que se realizaron en el trabajo. 29
5.4 Representación esquemática del workflow del análisis de datos mediante machine learning. 30

6.1 Resumen general de la comparativa entre los cuatro archivos de lecturas, forward y reverse, antes del pre procesado y después del pre procesado. 31
6.2 Comparativa de los reads durante el filtrado, marcado en azul los que pasaron el filtro, en negro los que no pasaron el filtro por baja calidad y en morado los que no pasaron el filtro por ser demasiado cortos. . . 32
6.3 Comparativa de la calidad media, se observa como los reads filtrados se mantienen en el área verde de calidad. 32
6.4 Comparativa del porcentaje de GC en los reads antes y después del filtrado. 33
6.5 En la figura se puede observar la salida de la pipeline, en un formato muy parecido al proporcionado por enroll-HD, conservando los logs. . 36
6.6 Gráfico summary plot de SHAP, en el eje Y se pueden observar las variables analizadas, ordenadas de mayor a menor importancia y en el eje X se observa el impacto de cada variable en la demencia de los pacientes, valores positivos aumentan la probabilidad de demencia, mientras que negativos la disminuyen. 42
6.7 Gráfico de feature importance, producido por Boruta, en este gráfico de cajas (Boxplot) se utiliza el Z-Score para comparar las variables reales con las variables sombra. Las variables marcadas en verde son aquellas aceptadas, mientras que las rojas, son las que el modelo rechaza o etiqueta como menos importantes a la hora de predecir la demencia. Las cajas azules son las pertenecientes a las variables sombra. En el eje Y se grafica la importancia de cada variable usando el z-score, mientras que en el eje X, se listan todas las variables estudiadas. 43

Índice de tablas

5.1 Información del dataset de secuenciación utilizado en este estudio. Los datos corresponden a secuenciación del genoma completo de una línea celular asociada a enfermedad de Huntington. 12
5.2 Metadatos de la muestra y archivos de secuenciación utilizados en el análisis WGS de una línea celular asociada a la enfermedad de Huntington. 17
5.3 En la tabla se puede observar el rango de valores que RandomSearch empleó para buscar la configuración de hiperparámetros óptima, empleando valores bajos, altos e intermedios. 24

6.1 Frecuencia alélica y validez para análisis estadístico estándar de variantes en chr19 (N=4460). 31
6.2 Resumen de estadísticas globales del alineamiento de lecturas. . . . 34
6.3 Contenido de bases en las lecturas alineadas (A, C, G, T y N). 34
6.4 Estadísticas de cobertura de las lecturas alineadas sobre el genoma de referencia. 35
6.5 Calidad del Mapeo 35
6.6 Indels y Mismatches 35
6.7 Mejores hiperparámetros obtenidos mediante random search y validación cruzada con 5 folds y 20 combinaciones evaluadas (100 ajustes totales). 37
6.8 Resultados del modelo de clasificación de demencia, se empleó para la creación de este, validación cruzada y los hiperparámetros calculados mediante random search. 37
6.9 Valores Mean absolute SHAP calculados para cada variable del modelo de clasificación. 38
6.10 Atributos confirmados importantes y no importantes para la predicción de demencia empleando el método BorutaSHAP. cccogage: Edad en la que las afecciones cognitivas empezaron a tener efectos en el día a día. isced: Escala de nivel de educación. hdiss_stage_imp: Estadía de la enfermedad según la escala hdiss. exfscore: Función ejecutiva según la escala de PBAs. motscore: Puntuación de la escala motora UHDRS. 39

6.11 Consistencia de variables: número de folds en los que cada variable fue aceptada como significativa para predecir demencia. age: Edad del paciente. cccogage: Edad en la que las afecciones cognitivas empezaron a tener efectos en el día a día. isced: Escala de nivel de educación. hdiss_stage_imp: Estadía de la enfermedad según la escala hdiss. exfscore: Función ejecutiva según la escala de PBAs. motscore: Puntuación de la escala motora UHDRS. ccvabage: Edad en la que los pacientes empezaron a demostrar comportamientos violentos o agresivos 40

Lista de abreviaturas

- AUC-ROC Area Under the Receiver Operating Characteristic Curve
- GWAS Genome-Wide Association Study
- ID - Identificador
- Indel - Inserciones y deleciones
- SHAP SHapley Additive exPlanations
- SNP Single Nucleotide Polymorphism
- WGS Whole Genome Sequencing

1. Resumen

La enfermedad de Huntington es un trastorno neurodegenerativo hereditario cuya progresión clínica puede estar modulada por factores genéticos adicionales al gen *HTT*. Entre estos posibles modificadores, el gen *APOE* resulta de especial interés debido a su papel en el metabolismo lipídico y en la homeostasis neuronal. Este trabajo evaluó la posible asociación entre polimorfismos del gen *APOE* y la progresión clínica de la enfermedad de Huntington mediante un enfoque bioinformático integrador.

Se desarrolló una pipeline reproducible para el procesamiento de datos de secuenciación genómica, desde archivos *FASTQ* hasta la detección de variantes y su análisis en formato PLINK. Posteriormente, se integraron estos datos con información clínica procedente de la plataforma Enroll-HD, que incluye variables demográficas, motoras, psiquiátricas y cognitivas de 2230 pacientes. Para el análisis se empleron modelos de *machine learning*, concretamente Extreme Gradient Boosting Trees, optimizados mediante *random search* y validados con *cross-validation*. La importancia de las variables se evaluó utilizando métodos interpretables basados en SHAP y BorutaSHAP.

Los resultados muestran que variables clínicas como el estado motor, el nivel educativo o el estadio de la enfermedad presentan mayor capacidad predictiva del deterioro cognitivo que las variantes analizadas del gen *APOE*. Aunque algunas variantes muestran cierto potencial informativo, ninguna aparece como factor determinante en la predicción de demencia. En conjunto, el estudio sugiere que los polimorfismos de *APOE* no actúan como modificadores principales del deterioro cognitivo en la enfermedad de Huntington dentro del conjunto de datos analizado.

Palabras clave: enfermedad de Huntington, APOE, polimorfismos genéticos, GWAS, bioinformática, machine learning, XGBoost, SHAP, Boruta

2. Abstract

Huntington's disease is a hereditary neurodegenerative disorder whose clinical progression may be modulated by genetic factors beyond the HTT gene. Among these potential modifiers, the APOE gene is of particular interest due to its role in lipid metabolism and neuronal homeostasis. This work evaluated the possible association between APOE gene polymorphisms and the clinical progression of Huntington's disease through an integrative bioinformatics approach.

A reproducible pipeline was developed for the processing of genomic sequencing data, from FASTQ files to variant detection and subsequent analysis in PLINK format. Subsequently, these data were integrated with clinical information from the Enroll-HD platform, which includes demographic, motor, psychiatric, and cognitive variables from 2,230 patients. For the analysis, machine learning models were employed, specifically Extreme Gradient Boosting (XGBoost), optimized through random search and validated using cross-validation. Variable importance was evaluated using interpretable methods based on SHAP and BorutaSHAP.

The results show that clinical variables such as motor status, educational level, or disease stage exhibit greater predictive capacity for cognitive decline than the analyzed APOE variants. Although some variants show certain informative potential, none emerges as a determining factor in dementia prediction. Overall, the study suggests that APOE polymorphisms do not act as major modifiers of cognitive decline in Huntington's disease within the analyzed dataset.

Keywords: Huntington's disease, APOE, genetic polymorphisms, GWAS, bioinformatics, machine learning, XGBoost, SHAP, Boruta

Agradecimientos

Me gustaría empezar esta sección agradeciendo al doctor Alexander Neef por su apoyo a lo largo de la elaboración de este trabajo, sobre todo durante los últimos días de elaboración incluso cuando la fecha de entrega se nos echaba encima, su apoyo y trabajo ha sido indispensable para la entrega de este trabajo.

También, por supuesto, agradecer a la doctora Esther Cubo, con la que, junto al equipo de Pest-pd de la Universidad de Burgos, me han ofrecido la oportunidad de iniciarme en la carrera investigadora, un camino igual de bonito y apasionante, como incierto.

Agradecer al equipo de investigación de la Universidad de Burgos, en especial a la doctora Miriam Saiz y, de nuevo, a la doctora Cubo por cederme unos datos tan potentes e interesantes para el desarrollo de este trabajo.

También agradecer a la VIU y, en especial, a sus docentes por la invaluable formación que se me ha ofrecido a lo largo del master y por las puertas que se me abren tras la obtención del título.

En una nota más personal, agradecer a mi padre por toda su guía en el camino de la investigación. A mi madre por su apoyo y ánimo constante. A mi hermana por las risas y su presencia en momentos difíciles. Y a mis amigos por hacer el tiempo entre tanto trabajo y esfuerzo agradable e inolvidable, en especial a Jose, Jorge, Celia, Fernando, Richard y Mario, por estar siempre ahí en las buenas y en las malas.

En general gracias a todos ya que sin vosotros esto no hubiera sido posible.

3. Introducción

La evidencia acumulada en los últimos años subraya que las alteraciones tempranas en el metabolismo del colesterol, junto con la disfunción astrocitaria, constituyen elementos clave en la fisiopatología de la enfermedad de Huntington. En este contexto, la reducción en la expresión y secreción de *APOE* por parte de los astrocitos adquiere un papel central, dado que esta apolipoproteína es esencial tanto para el transporte lipídico como para la homeostasis y reparación neuronal. La disminución de *APOE* podría, por tanto, agravar la escasez de colesterol disponible para las neuronas y contribuir secundariamente al deterioro mitocondrial observado en modelos experimentales de la enfermedad, reforzando la hipótesis de una interacción patogénica entre metabolismo lipídico y bioenergética celular. A partir de estas observaciones, surge un interés creciente por identificar estrategias terapéuticas dirigidas a restaurar o modular la función de *APOE*, incluidas intervenciones basadas en terapia génica o moléculas bioactivas que actúen sobre sus rutas regulatorias. En esta misma línea, resultaría especialmente valioso evaluar la presencia de polimorfismos que alteren la expresión de *APOE*, ya que podrían influir en la vulnerabilidad celular, modular la gravedad del fenotipo o incluso abrir nuevas aproximaciones de medicina personalizada orientadas a la intervención temprana en la enfermedad de Huntington.

Diversos polimorfismos en el gen *APOE* han sido objeto de estudio debido a su capacidad para modificar la expresión génica, la actividad promotora o la funcionalidad estructural de la proteína *APOE*. Entre los más relevantes se encuentran aquellos localizados en la región promotora, cuya variación puede influir directamente en los niveles de transcripción del gen. Uno de los polimorfismos mejor caracterizados en este ámbito es rs449647 (491 A/T, c.-558A>T), situado en la región promotora aproximadamente 2 kb aguas arriba del inicio de transcripción. Aunque su efecto exacto no está plenamente establecido, diversos estudios han documentado modulaciones en la actividad transcripcional del gen *APOE*, convirtiéndolo en un marcador de especial interés para evaluar variaciones en la expresión génica. De forma similar, el polimorfismo rs769446 (427 T/C, c.-494T>C), también ubicado en la región promotora, ha sido asociado a cambios en la actividad promotora y en los niveles de expresión de *APOE*, aun cuando la evidencia no es completamente consistente en todos los estudios. Ambos SNPs son ejemplos paradigmáticos de variantes no codificantes con potencial impacto regulador.

Otros polimorfismos de relevancia funcional incluyen aquellos cuya localización sugiere un papel regulador, aunque sus efectos no estén completamente definidos. Este es el caso de rs7259620 (c. -1334G>A), un SNP situado en la región 5 reguladora, cuya contribución a la expresión génica es incierta pero que ha sido repetidamente incluido en estudios sobre variantes reguladoras de *APOE*. Asimismo, la deleción rs538385866 (c.-779_-776del), localizada en una región promotora predicha, podría afectar la arquitectura reguladora del locus y, en consecuencia, la expresión génica, si bien su impacto funcional aún se encuentra por dilucidar. Entre las variantes con consecuencias más severas se encuentra la deleción estructural g.45408560_45410359del, que abarca el promotor y los exones 1 y 2 del gen, y que se ha predicho que elimina completamente la expresión de *APOE*, lo que la convierte en una de las alteraciones con mayor impacto funcional descrito hasta la fecha.

Junto a estas variantes reguladoras, los polimorfismos codificantes más estudiados rs429358 y rs7412 merecen también consideración, ya que determinan los alelos

estructurales 2, 3 y 4, los cuales configuran isoformas proteicas con diferencias claras en estabilidad, conformación y capacidad de unión a lípidos. Estas variantes definen tres isoformas con efectos funcionales contrastados: *APOE2*, asociada a protección relativa en procesos neurodegenerativos, *APOE3*, considerada la isoforma de referencia, y *APOE4*, cuya presencia está firmemente relacionada con alteración funcional de la proteína, cambios en su estructura y un impacto relevante en patologías como la enfermedad de Alzheimer. Así, aunque estos polimorfismos afectan la secuencia codificante y no la expresión génica per se, constituyen un componente esencial en el estudio de la funcionalidad global del sistema *APOE*.

El objetivo de este Trabajo Fin de Máster es examinar la posible asociación entre polimorfismos del gen *APOE* y variaciones en el fenotipo funcional de individuos afectados por enfermedad de Huntington, empleando para ello datos procedentes de estudios de asociación de genoma completo (GWAS) junto con medidas clínicas derivadas de escalas funcionales estandarizadas. De manera específica, se pretende identificar variantes genéticas en *APOE* tanto codificantes como reguladoras cuya presencia pueda correlacionarse con diferencias en la progresión clínica, el rendimiento funcional o la severidad de los síntomas, evaluados mediante instrumentos validados. Este análisis integrará metodologías de genética poblacional y estadística aplicada para determinar si la variabilidad genética en *APOE* actúa como modulador del fenotipo clínico, proporcionando así información relevante sobre el posible papel de este gen como factor modificador en la enfermedad de Huntington. En última instancia, el estudio aspira a generar evidencia preliminar que permita orientar futuras investigaciones mecanísticas sobre la influencia de *APOE* en rutas de vulnerabilidad neuronal y en el diseño de potenciales estrategias terapéuticas[1],[2].

4. Objetivos

4.1. Objetivo general

Evaluar, mediante un enfoque bioinformático, la asociación entre polimorfismos en el gen *APOE*, tanto codificantes como no codificantes y las variaciones en el fenotipo funcional de individuos afectados por enfermedad de Huntington, integrando datos de estudios de asociación de genoma completo (GWAS) con medidas clínicas obtenidas mediante escalas funcionales estandarizadas.

4.2. Objetivos específicos

1. Desarrollar y validar una pipeline bioinformática reproducible para el procesamiento y análisis de datos genómicos procedentes de estudios GWAS en pacientes diagnosticados con enfermedad de Huntington, orientada a la detección y estudio de las variantes del gen *APOE*.
2. Analizar la asociación estadística entre los polimorfismos identificados en el gen *APOE* y los metadatos funcionales, obtenidos mediante análisis clínicos estandarizados.
3. Evaluar el papel potencial de los polimorfismos en el gen *APOE* en la enfermedad de Huntington para apoyar a futuras investigaciones.

5. Metodología

5.1. Muestra

Para la realización de este trabajo se emplearon dos fuentes.

El dataset principal fue cedido por el hospital de Burgos, pero para completar este trabajo se empleó una pipeline de variant calling con datos de whole genome sequencing (WGS) para simular un flujo de trabajo completo, desde datos recién salidos del secuenciador en FASTQ, hasta asociaciones estadísticas con potentes modelos de machine learing.

Para la elaboración del pipeline se emplearon datos abiertos del SRA del NCBI, con las características disponibles en la tabla 5.1.

Tabla 5.1: Información del dataset de secuenciación utilizado en este estudio. Los datos corresponden a secuenciación del genoma completo de una línea celular asociada a enfermedad de Huntington.

Campo	**Descripción**
Accession experimento	SRX7216664
Run accession	SRR10532700
Proyecto	PRJNA591812
Study accession	SRP233259
Sample accession	SAMN13389757
Organismo	Homo sapiens
Tipo de estudio	Whole Genome Sequencing (WGS)
Plataforma de secuenciación	Illumina HiSeq X Ten
Estrategia	WGS
Fuente	Genomic DNA
Selección de librería	Random
Layout de lecturas	Paired-end
Nombre de librería	Q180_NA.wgs
Número de runs	1
Número de lecturas (spots)	346,978,673
Número total de bases	104.8 Gb
Tamaño de descarga	44.1 Gb
Fecha de publicación	18-03-2020
Institución	The Hospital for Sick Children
Descripción del estudio	DNA binding small molecule induces repeat contractions in Huntington's disease

Para el estudio del potencial estadístico de las variantes encontradas, se emplearon datos provenientes de Enroll-HD, la plataforma de investigación clínica en la enfermedad de Huntington más grande del mundo. Estos datos fueron cedidos al investigador de este trabajo por el hospital de Burgos, con el cuál colabora para la elaboración de este TFM.

Los datos se dividen en dos partes, siendo la primera datasets en formato excel con la información relativa a los sujetos del estudio cómo su identificador, edad, región etc

e información de interés analítico cómo puede ser la edad en la que se empezaron a desarrollar las afecciones neurológicas palpables cómo irritabilidad o problemas cognitivos.

La segunda parte incluye un estudio completo de variantes estructurales de los sujetos, en formato PLINK, es decir, que hay en total 66 archivos, en los cuales, los genotipos imputados fueron distribuidos en cada cromosoma, del 1 al 22. Cada cromosoma tiene 3 archivos (bed, bim y fam).

El archivo .bed, es binario, es el archivo principal y guarda información de los genotipos para cada individuo y cada Single Nucleotide Polimorphism (SNP), está comprimido en bits y, cómo es habitual en los archivos binarios, no es legible para los humanos como texto plano. Codifica los genotipos de la siguiente forma:

1. 00 = homocigoto alelo 1
2. 01 = missing
3. 10 = heterocigoto
4. 11 = homocigoto alelo 2

Los archivos en formato .bim, son archivos de texto, tabulares, separados por espacios o tabuladores.

Tiene 6 columnas obligatorias:

CM SNP_ID CM_position BP_position Allele1 Allele2

1. Chromosome: Código del cromosoma, pudiendo ser un número entero correspondiente al número del cromosoma, o caracteres alfanuméricos que indican información de este 'X'/'Y'/'XY'/'MT'
2. SNP ID: identificador de la variante o rsID, en ese caso se identificaron las variantes con el número del cromosoma en el que se encuentran, la posición en la que se encuentran, el alelo de referencia, el modificado y el alelo detectado, por ejemplo: 19_45410444_G_A_A
3. Genetic distance (cM): Distancia genética, en morgans o centimorgans, es seguro usar 0 si se desconoce.
4. Base-pair position: Posición física en el genoma
5. Allele 1: Alelo de referencia (A1)
6. Allele 2: Alelo alternativo (A2)

Por último también se encuentran los archivos fam, al igual que bim, son archivos de texto tabulares, separados por espacios o tabuladores que poseen:

FID IID PID MID Sex Phenotype

1. FID: ID familiar
2. ID: ID individual
3. PID: ID paternal, toma el valor 0 si se desconoce

4. MID: ID maternal, toma el valor 0 si se desconoce
5. Sex: Sexo del individuo
   a) 1 = masculino
   b) 2 = femenino
   c) 0 = desconocido
6. Phenotype: Fenotipo a estudiar del individuo, si se desconoce toma el valor -9, en los datos del estudio siempre tomarán el valor -9 ya que los rasgos a estudiar fueron tomados directamente desde los excel anteriormente descritos en este trabajo [3].

La obtención de los SNPs que se analizaron posteriormente está descrita por el artículo publicado por James F. Gusella [4].

Para la secuenciación de los individuos se emplearon los siguientes componentes:

1. InfiniumOmniExpressExome-8v1-3_A
2. Multi-EthnicGlobal-8_A1 arrays
3. Nextera XT Index Kit v2 Set A (96 indexes, 384 samples)
4. Nextera XT Index Kit v2 Set B (96 indexes, 384 samples)
5. Nextera XT Index Kit (24 indexes, 96 samples)
6. MiSeq Reagent Kit v3 (600 cycle)
7. QIAGEN LongRange PCR Kit (250)
8. AmpliTaq Gold DNA polymerase with BufferII, MgCl2 12x 250units

y los siguientes oligonucleótidos:

1. HD-1 5ATGAAGGCCTTCGAGTCCCTCAAGTCCTTC3
2. HD-3 5GGCGGTGGCGGCTGTTGCTGCTGCTGCTGC3
3. HTT ms_hd_f TCGTCGGCAGCGTCAGATGTGTATAAGAGACAGATG AAGGCCTTCGAGTCCC
4. HTT ms_hd_r GTCTCGTGGGCTCGGAGATGTGTATAAGAGACAGGG CTGAGGAAGCTGAGGA

El genoma de referencia empleado fue el GRCh37/hg19

El llamado de variantes se realizó basándose en el algoritmo de birdsuite.

Se aplicaron los siguientes filtros de control de calidad:

1. Valor de Rš de imputación <0,5
2. Tasa de genotipado 100%
3. p-valor del equilibrio de Hardy-Weinberg <1Œ10
4. frecuencia del alelo menor <0,1%

5.2. Tipo y diseño de estudio

El estudio, cómo se mencionó con anterioridad, proviene de la plataforma de investigación clínica Enroll-HD.

El objetivo de este estudio es recopilar información clínica y biológica sobre la enfermedad de Huntington con el fin de acelerar el progreso de la investigación para encontrar soluciones terapéuticas que curen, retrasen o hagan más sencilla la convivencia con la enfermedad de Huntington.

El estudio fue establecido en julio de 2012, ganando poco a poco una gran base de datos de todo tipo para el estudio de la enfermedad de Huntington, desarrollando una gran plataforma para apoyar la investigación, en este proyecto fue usada para la detección de posibles biomarcadores de consecuencias de la enfermedad, por ejemplo, SNPs que, en su presencia, se observe un efecto protector en cuanto a desarrollar alteraciones neurológicas graves cómo por ejemplo ira o deterioro cognitivo.

Los recursos disponibles en esta plataforma están orientados a toda la comunidad que rodea a esta enfermedad, esto incluye a familias, médicos, investigadores y cualquier persona afectada o que trabaje con la enfermedad.

Se clasifica como un registro de pacientes longitudinal y observacional prospectivo, del cual sólo se seleccionó una pequeña parte para el estudio, concretamente el dataset llamado Resultados de llamadas SNP imputadas a GWAS5".

El estudio tiene diferentes características:

1. El estudio presenta tanto casos como controles, sin embargo en el fragmento de datos que se empleó para la detección de variantes de riesgo o protectoras, se emplearon unicamente enfermos

2. Longitudinal y prospectivo: Los participantes son evaluados a lo largo del tiempo, con varias visitas clínicas, sin embargo, para el problema que se trató de resolver en este trabajo, solamente se ha empleado datos de la última visita de los pacientes para contar con la información más reciente y actualizada.

3. Multinacional: En el estudio se contó con individuos de múltiples naciones alrededor del mundo

4. Observacional: No se administran fármacos ni se introducen variables que modifiquen a la muestra, simplemente se limitó a observar el estado y la progresión de la enfermedad

5. Seguimiento continuo: De momento no hay ninguna fecha fija de finalización, aunque en páginas cómo clinicaltrials figura como estimación del fin del estudio el año 2062[5].

Como se observa en la Figura 5.1, el tamaño muestral del estudio ha crecido enormemente y se ha convertido en una gran plataforma para el estudio de la enfermedad de Huntington [6].

5.3. Métodos

Los datos obtenidos para el pipeline se obtuvieron según el informe presente en la Tabla 5.2.

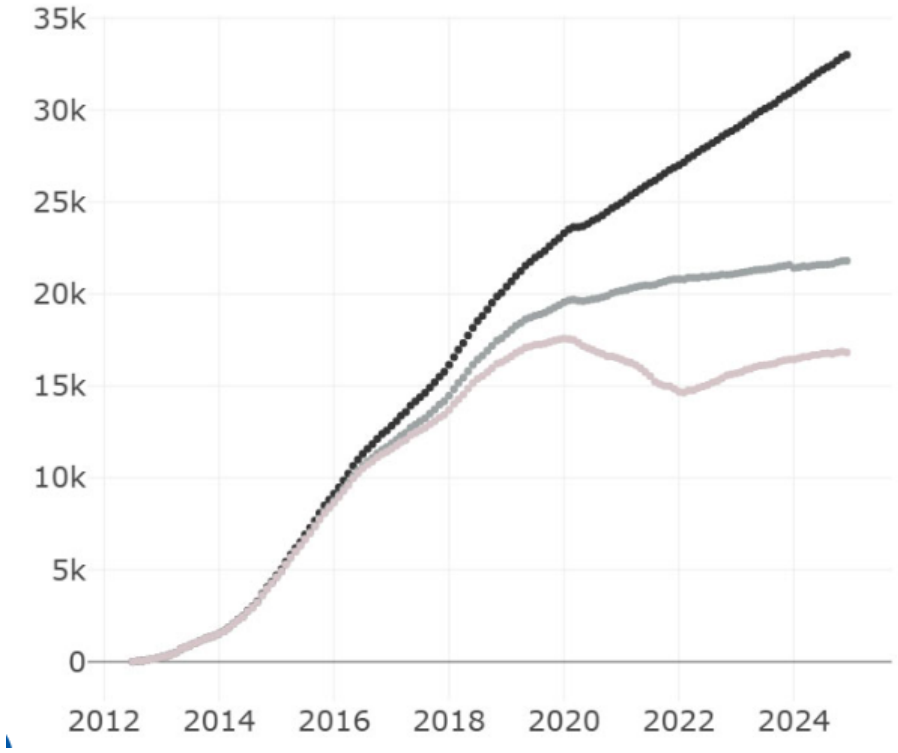

Figura 5.1: Aumento del número de pacientes disponible con los años. En el eje X se observan los años desde la creación de la plataforma enroll-HD. En el eje Y se muestra el número de pacientes disponibles en su estudio

La metodología técnica seguida se describe de forma esquemática en las figuras .

En el pipeline inicial, primero, como paso imprescindible se evaluaron las secuencias empleando el programa fastqc, que evalúa la calidad de las lecturas. Para el filtrado se empleó fastp, detectando de forma automática secuencias adaptadores y filtrando por Q20 para asegurar que las secuencias seleccionadas tienen un mínimo de calidad para trabajar con ellas, pero que no se pierde información biológica importante al ser demasiado estrictos con el filtro.

Los resultados, tanto antes del filtro como después del filtro son reportados mediante multiqc, un programa que permite la visualización conjunta de reportes fastqc, para facilitar las tareas de comparación y evaluación real de los efectos del filtro aplicado.

Tras el control de calidad se procede al mapeo frente a genoma de referencia, en este caso se empleó hg19 ya que fue el empleado en el estudo de enroll-HD, por lo que esta versión del genoma, aunque un poco anticuada, se asemeja más a la forma en la que los datos fueron tratados.

La herramienta con la que se aplicó el mapeado fue bwa, muy utilizada para el alineamiento frente a genomas de referencia grandes, como el humano. En este paso también se añadieron los read groups, útiles a la hora de manejar secuencias de distinta procedencia [7].

Para tratar los archivos .sam resultantes, se empleó samtools, que ordenó el archivo y lo convirtió en el formato binario .bam, mucho más manejable.

Para el marcaje de duplicados, se empleó Picard, una herramienta desarrollada en Java

Tabla 5.2: Metadatos de la muestra y archivos de secuenciación utilizados en el análisis WGS de una línea celular asociada a la enfermedad de Huntington.

Campo	Descripción
isolate	HUNTINGTON DISEASE
age	6y
biomaterial provider	Coriell Biorepositories
sex	male
tissue	skin
cell line	GM09197
library_id	Q180_NA.wgs
title	Whole genome of Homo sapiens: huntington cell line
library_strategy	WGS
library_source	GENOMIC
library_selection	RANDOM
library_layout	paired
platform	ILLUMINA
instrument_model	HiSeq X Ten
design_description	HD cell lines were treated with or without continuous exposure to 50 μM NA. Genomic DNA extracted from three independent experiments for each cell line, in presence or absence of NA, were pooled together and analysed through WGS.
filetype	fastq
filename	H37JFCCX2__Q180_NA_40_days_DNA_S4_L001_R1_001.fastq.gz
filename2	H37JFCCX2__Q180_NA_40_days_DNA_S4_L001_R2_001.fastq.gz
filename3	H37KVCCX2__Q180_NA_40_days_DNA_S5_L005_R1_001.fastq.gz
filename4	H37KVCCX2__Q180_NA_40_days_DNA_S5_L005_R2_001.fastq.gz
filename5	H37NNCCX2__Q180_NA_40_days_DNA_S8_L005_R1_001.fastq.gz
filename6	H37NNCCX2__Q180_NA_40_days_DNA_S8_L005_R2_001.fastq.gz

utilizada para identificar y marcar lecturas duplicadas en archivos de alineamiento en formato BAM previamente ordenados. El programa agrupa lecturas alineadas en la misma posición genómica en conjuntos de duplicados y selecciona una lectura representativa basándose en su puntuación de calidad. Las restantes lecturas del conjunto se marcan como duplicadas. Opcionalmente, estas lecturas pueden eliminarse. Este paso es fundamental para reducir posibles sesgos en análisis posteriores, como, en este caso, la llamada de variantes [8].

El paso de variant calling fue realizado mediante el software de bcf tools, que inicialmente surgió como una forma de dividir la carga de la costosa tarea del variant calling. Actualmente es un software mucho más profesional que cuenta con varios algoritmos para variant calling y sigue siendo uno de los variant callers más eficientes, por lo que, para la creación y validación de la pipeline, demuestra ser más que suficiente. También fue empleado para filtrado de variantes, eliminando aquellas con calidades menores de Q<30 [9].

Para tareas de compresión e indexado se empleó bgzip y tabix.

El archivo de variantes final fue convertido al formato plink y separado los tres archivos resultantes (.bed .bim y .fam) por cromosomas para asemejarse al formato de GWAS adoptado por la plataforma enroll-HD

Para el análisis de asociación, una vez obtenidos los datos en formato plink, se procedió a seleccionar aquellos que son de interés para el estudio, en este caso se filtraron las variantes pertenecientes al chr19, seleccionando únicamente la región del gen, buscado en el ucsc [10], con el siguiente comando en plink:

plink –bfile gwa5.mis3.enroll.chr19.qc –chr 19 –from-bp 45409053 –to-bp 45412650 –make-bed –out apoe_ucsc

El comando selecciona únicamente aquellas variantes que caigan dentro de la región especificada, es decir, dentro del gen *APOE* incluyendo las regiones no codificantes para el estudio de los efectos de las variantes intrónicas.

Para preparar las variantes en un formato con el que se pueda trabajar posteriormente en python, se recodificaron las variantes, para identificarlas junto con el identificador (ID) del paciente. Se trataron de la siguiente forma:

plink –bfile apoe_ucsc –recode A –out all_SNP tr ' ' ',' <all_SNP.raw >all_SNP.csv

El primero comando relacionó las variantes con el ID de sus portadores, mientras que el segundo reformateó el archivo a un .csv, fácilmente interpretable por el módulo pandas de pyhton, muy utilizado a la hora del análisis estadístico.

Los últimos pasos del análisis estadístico se explican en el subapartado de estadística, donde se define tanto el pre-procesado de los datos, como el análisis de los mismos.

5.4. Evaluación de la calidad del mapping y variant calling

Para el análisis de los resultados del pipeline se emplearon, la ya mencionada multiqc para evaluar la calidad de las secuencias iniciales y la calidad de las secuencias tras el filtrado.

La herramienta Qualimap fue la seleccionada para la evaluación de la calidad del mapeo.

Los resultados del variant calling no se evalúan ya que esta pipeline, en el caso de hacerse el análisis desde los datos crudos, desembocaría en el análisis de asociación que en este estudio se empleó mediante machine learning, por lo que se asume que el análisis del variant calling es toda la parte de machine learning de este trabajo y no será mencionado de forma explícita en los resultados.

5.5. Análisis estadístico

Para el análisis estadístico, primero se hizo una exploración inicial de los datasets con información por cada paciente. Ya que, por petición del Hospital de Burgos, quienes facilitaron los datos para este estudio, no se pueden publicar los datasets, se explicarán las decisiones tomadas.

Por el gran tamaño del dataset, la ambición del estudio y el reparto desigual de los datos entre las variables se optó por usar machine learning, que opera estudiando las relaciones entre las variables, incluyendo aquellas no lineales que la estadística clásica es incapaz de detectar, derivando el análisis en un estudio que busca encontrar aquellas variables que nos ayudarán a predecir el estado mental del paciente, observando si los polimorfismos del gen *APOE* previamente seleccionados, se encuentran entre las variantes que nos ayudan a

predecir el estado mental del paciente, o si, por lo contrario, es más eficaz tener en cuenta otras variables para predecirlo.

Primero se decidió en conjunto con el equipo de Neurología y el departamento de investigación de la universidad de Burgos las variables que se estudiarían en este trabajo. las variables de interés seleccionadas fueron:

Como variable dependiente se seleccionó Minimental, un test ampliamente usado por Neurólogos, que evalúa el estado cognitivo de cada paciente, se decidió desde el equipo de Neurología que se separaría en dos clases, si el sujeto tenía un score menor a 24 se le consideraría demente, mientras que si el score era de 24 o mayor, pasaría a formar parte del grupo de los sanos [11].

```
    condiciones = [
    df_grouped["caghigh"] < 28,
    (df_grouped["caghigh"] >= 28) & (df_grouped["caghigh"] <= 35),
    df_grouped["caghigh"] > 35
]

valores = [0, 1, 2]

df_grouped["caghigh_premut"] = np.select(condiciones, valores)

condiciones = [
    df_grouped["caghigh"] < 28,
    df_grouped["caghigh"] >= 28
]

valores = [0,1]

df_grouped["caghigh_mut"] = np.select(condiciones, valores)

condiciones = [
    df_grouped["caglow"] < 28,
    df_grouped["caglow"] >= 28
]

valores = [0,1]

df_grouped["caglow_mut"] = np.select(condiciones, valores)

df_grouped["mmdemencia"] = np.where(
    df_grouped["mmsetotal"] < 24,
    1,
    0
)
```

Como variables predictivas se seleccionaron las siguientes:

1. Edad del paciente

2. Sexo del paciente
3. Nivel educativo según la escala ISCED
4. Nivel motor evaluado por la escala UHDRS [12]
5. Nivel de síntomas psiquiátricos, entre los que se encuentran:
   a) Depresión
   b) Apatía
   c) Ira
   d) Psicosis
   e) Función ejecutiva
6. Edad de inicio de los síntomas psiquiátricos previamente mencionados
7. Estadío de la enfermedad según la escala HD-ISS [13]
8. Primer síntoma que sufrió el paciente
9. Raza del paciente
10. Región del paciente
11. Repeticiones de CAG del alelo menor
12. repeticiones de CAG del alelo mayor

Para el estudio estadístico se empleó Jupyter Notebook por su demostrada efectividad a la hora de realizar experimentos de inteligencia artificial ya que su enfoque por celdas lo convierte en ideal para ejecutar distintos bloques de código y realizar distintas pruebas, además que su integración en el entorno de conda, lo hace ideal para el control de versiones, pudiendo tener entornos virtuales con versiones específicas y evitar problemas de conflictos de versiones.

Primero se cargaron todos los datasets del estudio y se cruzaron todos los datos para obtener un único dataframe con el que poder trabajar

```
enroll = pd.read_excel("enroll.xlsx", header=1)
snps = pd.read_csv("all_SNP.csv")
profile = pd.read_excel("1. profile.xlsx")
profile_new = profile.rename(columns={'subjid': 'FID'})
enroll_new = enroll.rename(columns={'subjid': 'FID'})
df_temp = pd.merge(enroll_new, snps,on='FID')
df_snps = pd.merge(df_temp, profile_new,on='FID')
df_analisis = df_snps[['FID','age','sex','isced','motscore','depscore',
'irascore','psyscore','aptscore','exfscore','caghigh',
'caglow','ccdepage',
'ccirbage', 'ccvabage', 'ccaptage',
    'ccpobage', 'ccpsyage', 'cccogage','sxsubjm','race','region',
    'hdiss_stage_imp','mmsetotal','sdmt1','verfct5','scnt1','swrt1',
```

```
    "19_45409113_C_T_T",
    "19_45409167_C_G_C",
    "19_45409283_C_A_A",
    "19_45409579_C_T_T",
    "19_45409988_C_T_T",
    "19_45410002_G_A_A",
    "19_45410273_G_A_A",
    "19_45410444_G_A_A",
    "19_45410548_A_G_G",
    "19_45410911_T_G_G",
    "19_45411110_T_C_C",
    "19_45411722_G_A_A",
    "19_45411941_T_C_C",
    "19_45412040_C_T_T",
    "19_45412079_C_T_T"]]
```

Muchas de las variables eran categóricas, cómo por ejemplo la raza o la región, por lo que para su tratamiento se empleó la estrategia del One-Hot Encoding, una estrategia para convertir datos categóricos (Europeo) en un formato reconocible para hacer machine learning (Raza_Europeo = 1, Raza_asiatico = 0). Se aplicó el One-Hot Encoding en sexo, raza, región y primer síntoma [14].

El dataset consta de 2230 pacientes, cada uno con distinto número de visitas. Para solucionar el problema de las variantes numéricas se optó, tras una reunión con el equipo del Hospital de Burgos, en usar la media de estos datos ya que, lo que realmente estamos investigando, son el efecto que puedan tener los polimorfismos en que el paciente desarrolle o no demencia, por lo que perder información de evolución temporal, que en otro tipo de estudio sería crucial, en este no lo es tanto.

Para la limpieza de los datos, con el fin de convertirlos a un formato compatible con machine learning, se comenzó con el filtrado de strings. En las columnas de repetición de CAG, cuando las repeticiones superaban las 70 en el alelo mayor y las 28 en el alelo menor, se marcaban cómo '>70' o '>28'. Este tipo de datos no son interpretables por los modelos y al eliminarlos se perdería información muy valiosa, por lo que se optó en dejarlos como los enteros 71 y 29 respectivamente. Tras el filtrado, se aseguró que todos los valores que quedaban eran numéricos.

En valores desconocidos, en ocasiones, el dataset los marcaba con números exageradamente altos, cómo el 99997. Para evitar que estos valores introdujeran un sesgo irreal en el modelo, se eliminaron aquellos que superasen el umbral de 150 ya que ninguno de los datos conocidos y debidamente tipificados, superan dicho umbral.

```
cols_ohe = [
    'region', 'sex', 'race',
    'sxsubjm'
]

df_analisis = df_analisis.replace('>70', 71)
df_analisis = df_analisis.replace('>28', 29)
cols_numericas = df_analisis.select_dtypes(include=['number']).columns
df_analisis[cols_numericas] = df_analisis[cols_numericas].where
```

```
(df_analisis[cols_numericas] < 150)

df_analisis_ohe = pd.get_dummies(df_analisis, columns= cols_ohe, drop_first=False)
df_analisis_ohe["age"] = pd.to_numeric(df_analisis_ohe["age"], errors="coerce")
df_grouped = df_analisis_ohe.groupby("FID", as_index=False).mean(numeric_only=True)
```

Una vez terminado el preprocesamiento de los datos, se seleccionó el modelo. En este caso el elegido fue un Extreme Gradient Boost Tree, incluido en el módulo de Python XGBoost ya que es un modelo presente en varios estudios relacionados con el gen *APOE*, normalmente empleados en estudios de Alzheimer, en conjunto con SHAP para evaluar la importancia de las features seleccionadas, por lo que también se usó SHAP en el estudio.

En machine learning se dividen los datos en dos subsets, entrenamiento y evaluación. Los datos de entrenamiento son empleados para que el modelo aprenda de los patrones entre los datos y el subset de evaluación es empleado para comprobar lo bien que funciona el modelo con datos que no conoce y así evitar el overfitting, es decir, que el modelo se aprenda los datos de entrenamiento y falle al emplear datos que no haya visto durante el entrenamiento, sin captar información o patrones reales.

Los trees en machine learning se refieren a métodos de clasificación en las que el modelo explora los datos buscando relaciones y patrones entre ellos, para después construir decisiones ramificadas, un ejemplo simple sería una hipotética rama: Si tiene más de 75 años y sufre de depresión teniendo un alto número de CAG en su alelo mayor, lo clasifico como demencia. El conjunto de todas estas ramas es lo que se denomina un árbol de decisiones. La técnica de Gradient Boost Tree toma un enfoque iterativo en el uso de estos árboles, empezando con un árbol general que tendrá un gran número de errores en sus predicciones y se van produciendo iteraciones seleccionando aquellos modelos que reduzcan el error hasta que el error se reduzca menos de un pequeño umbral, con lo que concluiremos que nuestro algoritmo ha llegado al punto de convergencia [15].

Para reducir aún más el over-fitting se empleó una conocida técnica denominada cross validation o validación cruzada. Anteriormente se explicó que en machine learning se dividen los datos en entrenamiento y validación, sin embargo esta técnica lleva esto un paso más allá y realiza esta división varias veces, es decir, que selecciona al azar un conjunto de entrenamiento y otro de validación, entrena al modelo y obtiene las métricas. Sin embargo no se detiene ahí ya que vuelve a dividir los datos en entrenamiento y validación, usando grupos distintos y volviendo a entrenar el modelo, validarlo y obtener métricas. El proceso se repite según el número de folds que se definen previamente. Esta técnica garantiza una seguridad ya que evita que el modelo seleccione al azar, datos sencillos de entrenar, que causen un gran over-fitting al modelo.

Los modelos de machine learning necesitan unos parámetros de entrada que serán empleados en el entrenamiento de los modelos, estos son los conocidos como hiperparámetros y regulan aspectos tan importantes cómo el número de estimadores empleados. En ese estudio se emplearon los siguientes hiperparámetros:

1. n_estimators: Número de árboles con el que fue construido el modelo, valores altos tienden a sobreajustar el modelo.

2. learning_rate: Ratio con el que el modelo aprende, con valores altos cada modelo aprende más de los datos, pero hay más riesgo de sobreajuste.

3. max_depth: Profundidad del modelo, determina cuán complejo es cada modelo.

4. subsample: Porcentaje de muestras usado para construir cada arbol
5. colsample_bytree: Porcentaje de variables usadas por cada árbol
6. gamma: La facilidad con la que se puede dividir un modelo, un gamma más alto requerirá una mayor evidencia para hacer la división en las ramas de los árboles

Para conocer cuales son los hiperparámetros óptimos para el modelo de machine learning, hay varias formas de proceder. La más intuitiva es seleccionar los que el investigador haya decidido y simplemente pasarlos al modelo. La que se empleó en este trabajo fue la estrategia denominada Random Search, la cual consiste en evaluar el modelo empleando hiperparámetros aleatorios dentro de un rango predefinido, devolviendo la combinación de hiperparámetros óptima para el análisis.

```
from sklearn.model_selection import RandomizedSearchCV, StratifiedKFold
import numpy as np

param_dist = {
    'n_estimators': [100, 200, 500],
    'learning_rate': [0.01, 0.05, 0.1],
    'max_depth': [3, 5, 7, 10],
    'subsample': [0.6, 0.8, 1.0],
    'colsample_bytree': [0.6, 0.8, 1.0],
    'gamma': [0, 0.1, 0.2]
}

xgb_base = XGBClassifier(random_state=42, use_label_encoder=False,
eval_metric='logloss')

random_search = RandomizedSearchCV(
    estimator=xgb_base,
    param_distributions=param_dist,
    n_iter=20,
    scoring='roc_auc',
    cv=StratifiedKFold(n_splits=5),
    verbose=1,
    n_jobs=-1
)

random_search.fit(X_train, y_train)

#Mejor modelo
best_xgb = random_search.best_estimator_
print(f"Mejores parámetros encontrados: {random_search.best_params_}")
```

En este modelo se empleó el rango de hiperparámetros observados en la tabla 5.3, la filosofía seguida fue, seleccionar valores considerados bajos y altos, para encontrar los óptimos entre medias.

Tabla 5.3: En la tabla se puede observar el rango de valores que RandomSearch empleó para buscar la configuración de hiperparámetros óptima, empleando valores bajos, altos e intermedios.

Hyperparameter	Values
n_estimators	100, 200, 500
learning_rate	0.01, 0.05, 0.1
max_depth	3, 5, 7, 10
subsample	0.6, 0.8, 1.0
colsample_bytree	0.6, 0.8, 1.0
gamma	0, 0.1, 0.2

Para la evaluar cómo cada variable estaba afectando al modelo y medir la capacidad predictiva de cada variable, se empleó la metodología conocida como SHAP, por sus siglas, SHapley Additive exPlanations. Esta metodología basada en teoría de juegos, le da un valor a cada variable según lo que esta aporta al modelo, es decir, el peso que tienen en la predicción. El valor cuantificable se mide por medias absolutas de SHAP y para ensayos clínicos se suele tomar un umbral de 0,02.

```
import numpy as np
import pandas as pd
import xgboost as xgb
import shap
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split, KFold, cross_val_score
from sklearn.metrics import accuracy_score, classification_report,
roc_auc_score, confusion_matrix

df_grouped = df_grouped.dropna(subset=["mmdemencia"])

y = df_grouped["mmdemencia"]
X = df_grouped[[
    'age', 'sex_f', 'sex_m', 'isced', 'hdiss_stage_imp',
    'depscore','irascore','psyscore','aptscore','exfscore', 'motscore',
    'caghigh','caglow',
    'ccdepage', 'ccirbage', 'ccvabage', 'ccaptage', 'ccpobage', 'ccpsyage',
    'cccogage','sxsubjm_1.0','sxsubjm_2.0', 'sxsubjm_3.0', 'sxsubjm_4.0',
    'sxsubjm_5.0','sxsubjm_6.0',
    'race_1', 'race_2','race_3', 'race_6', 'race_8', 'race_15', 'race_16',
    'region_Australasia', 'region_Europe', 'region_Latin America',
    'region_Northern America',
    "19_45409113_C_T_T", "19_45409167_C_G_C", "19_45409283_C_A_A",
    "19_45409579_C_T_T", "19_45409988_C_T_T", "19_45410002_G_A_A",
    "19_45410273_G_A_A", "19_45410444_G_A_A", "19_45410548_A_G_G",
    "19_45410911_T_G_G", "19_45411110_T_C_C", "19_45411722_G_A_A",
    "19_45411941_T_C_C", "19_45412040_C_T_T", "19_45412079_C_T_T"
```

```
]]

model = xgb.XGBClassifier(**random_search.best_params_)

kf = KFold(n_splits=5, shuffle=True, random_state=42)

cv_accuracy = cross_val_score(model, X, y, scoring="accuracy", cv=kf)
cv_auc = cross_val_score(model, X, y, scoring="roc_auc", cv=kf)

print(f"CV Accuracy: {cv_accuracy.mean():.4f} +/- {cv_accuracy.std():.4f}")
print(f"CV AUC: {cv_auc.mean():.4f} +/- {cv_auc.std():.4f}")

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y # stratify asegura misma
    proporción de clases
)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
y_proba = model.predict_proba(X_test)[:, 1]

print("\n--- Reporte de Clasificación ---")
print(classification_report(y_test, y_pred))
print(f"Test AUC-ROC: {roc_auc_score(y_test, y_proba):.4f}")

explainer = shap.TreeExplainer(model)
shap_values = explainer.shap_values(X)

shap.summary_plot(shap_values, X)

importance_df = pd.DataFrame({
    "feature": X.columns,
    "mean_abs_shap": np.abs(shap_values).mean(axis=0)
}).sort_values(by="mean_abs_shap", ascending=False)

print("\n--- Variables por SHAP ---")
print(importance_df)
```

Con el fin de profundizar en el análisis, se empleó la técnica de BorutaSHAP, una técnica que busca encontrar aquellas variables realmente importantes, es decir, que están teniendo un impacto real en el efecto predictivo de nuestro modelo, con el fin de identificar si alguna de las variantes detectadas es identificada como métrica de gran valor predictivo.

```
from xgboost import XGBClassifier
import pandas as pd

Feature_Selector = BorutaShap.BorutaShap(model=model, importance_measure='shap',
classification=True)
```

```
Feature_Selector.fit(X=X_train, y=y_train, n_trials=100, sample=False)

Feature_Selector.plot(which_features='all')
```

Su funcionamiento consiste en la creación de las denominadas variables sombra, es decir, copias de las variables ya presentes en el modelo pero con los valores desordenados. Calcula la importancia de todas las variables empleando SHapley Additive exPlanations (SHAP) y, posteriormente, calcula cuanto varía la media absoluta de SHAP entre las variables originales y las variables sombra. Si se observa una diferencia considerable entre los valores sombra y los reales, se puede confirmar que la variable es significativa a la hora de generar predicciones, si, por el contrario, no hay un gran salto de calidad a la hora de predecir entre las variables reales y las ordenadas al azar, la asociación detectada, no puede determinarse cómo significativa ya que la asociación es, muy probablemente, determinada por el azar.

Este método presenta el improbable problema de que si a la hora de la creación de las variables sombra se ordenan de forma similar al original, o con un cierto sentido clínico, puede reportar cómo no significativa una variable que si que lo sea. Este problema disminuye en datasets grandes cómo en este estudio ya que la probabilidad de que esto pase, disminuye. Sin embargo, para reducir aún más la probabilidad de que esto suceda, se empleó, una vez más, cross-validation, reportando al final, en cuantos folds las variables habían sido reportadas como significativas [16].

```
from sklearn.model_selection import KFold

list_selected_features = []

kf = KFold(n_splits=5, shuffle=True, random_state=42)

for i, (train_index, val_index) in enumerate(kf.split(X_train)):
    print(f"--- Ejecutando BorutaShap en Fold {i+1} ---")

    X_fold = X_train.iloc[train_index]
    y_fold = y_train.iloc[train_index]

    Feature_Selector = BorutaShap.BorutaShap(
        model=best_xgb,
        importance_measure='shap',
        classification=True
    )

    Feature_Selector.fit(X=X_fold, y=y_fold, n_trials=50, sample=False, verbose=False)

    list_selected_features.append(Feature_Selector.accepted)

from collections import Counter
all_features = [item for sublist in list_selected_features for item in sublist]
feature_consistency = Counter(all_features)
```

```
print("\nConsistencia de variables (en cuántos folds fueron aceptadas):")
for feat, count in feature_consistency.items():
    print(f"{feat}: {count}/5")
```

Para la evaluación de los modelos de clasificación se emplearon las siguientes métricas:

1. Precision: Mide cuán confiable es una predicción de positivo, es decir, con una precisión del 90% y 100 observaciones marcadas como positivos, 90 son positivos reales y las otras 10 son falsos positivos
2. Recall: Mide la capacidad del modelo para identificar correctamente los casos positivos. Por ejemplo, con un recall del 90% y 100 casos positivos reales, el modelo identifica correctamente 90 de ellos mientras que los 10 restantes se clasifican erróneamente como falsos negativos.
3. F1-Score: Mide el equilibrio entre las escalas anteriores, importante en casos en los que el número de positivos y negativos está desequilibrado.
4. Support: Número de registros con los que se evaluó el modelo.
5. AUC-ROC: Area Under the Receiver Operating Characteristic Curve. Mide el potencial de discriminación del modelo, siendo 1, una capacidad de separar perfectamente a los positivos de los negativos y 0.5 que todas las clasificaciones fueron producidas aleatoriamente.
6. Accuracy: Precisión general del modelo, una Accuracy del 90% indica que de 100 registros, independientemente de su clasificación, 90 han sido los correctos.

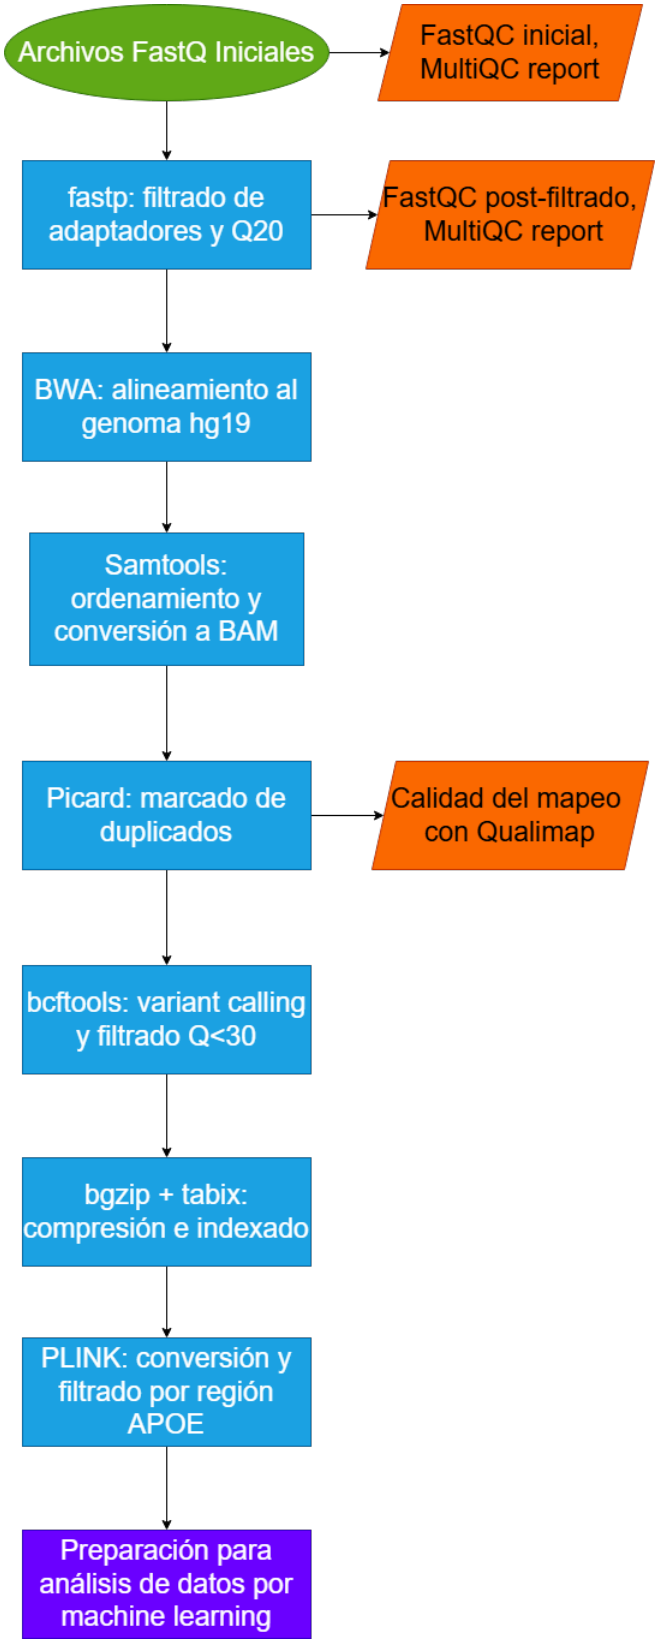

Figura 5.2: Representación esquemática del workflow del pipeline.

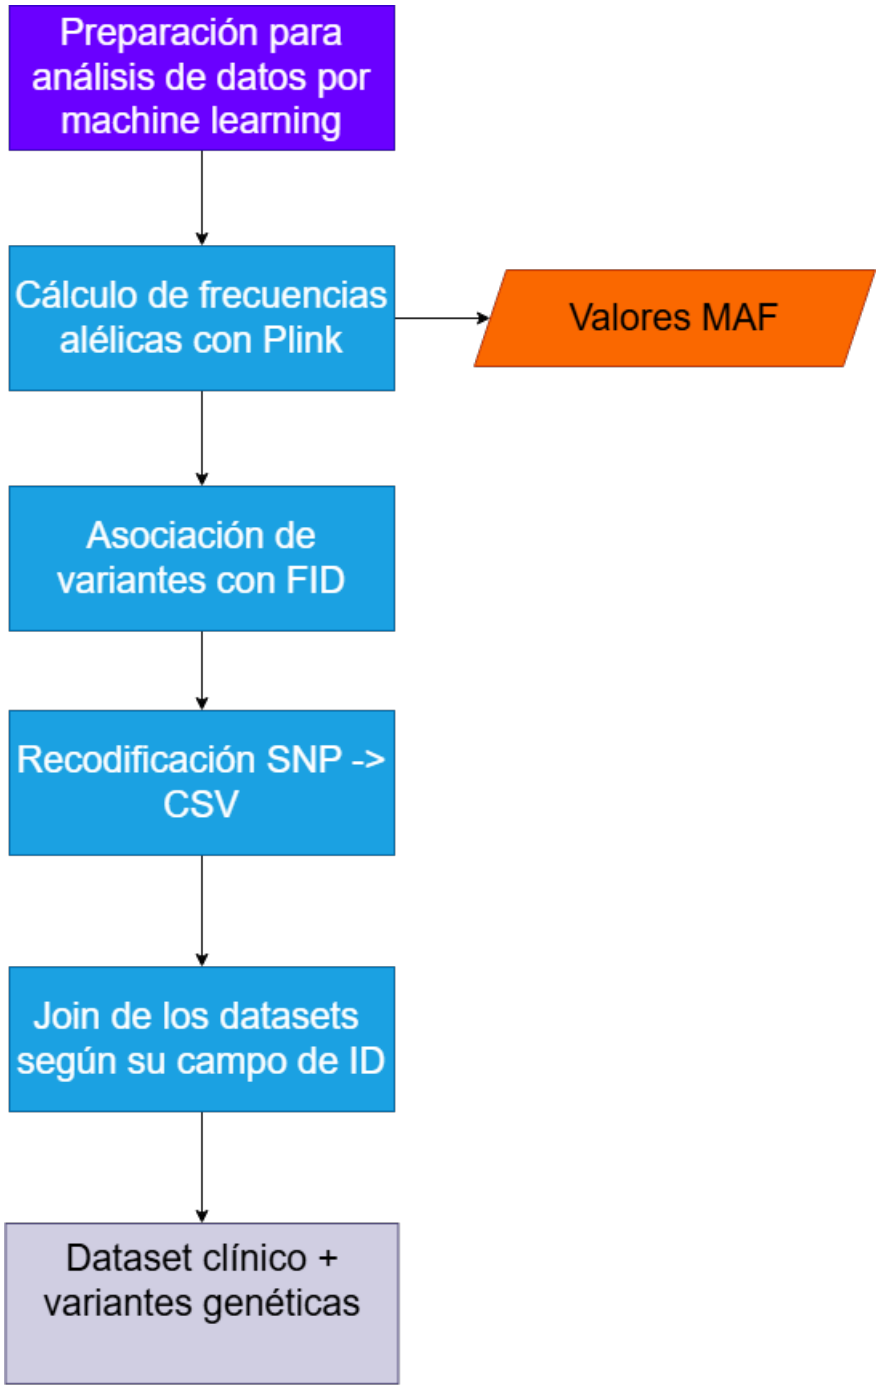

Figura 5.3: Representación esquemática del enlace entre los workflows que se realizaron en el trabajo.

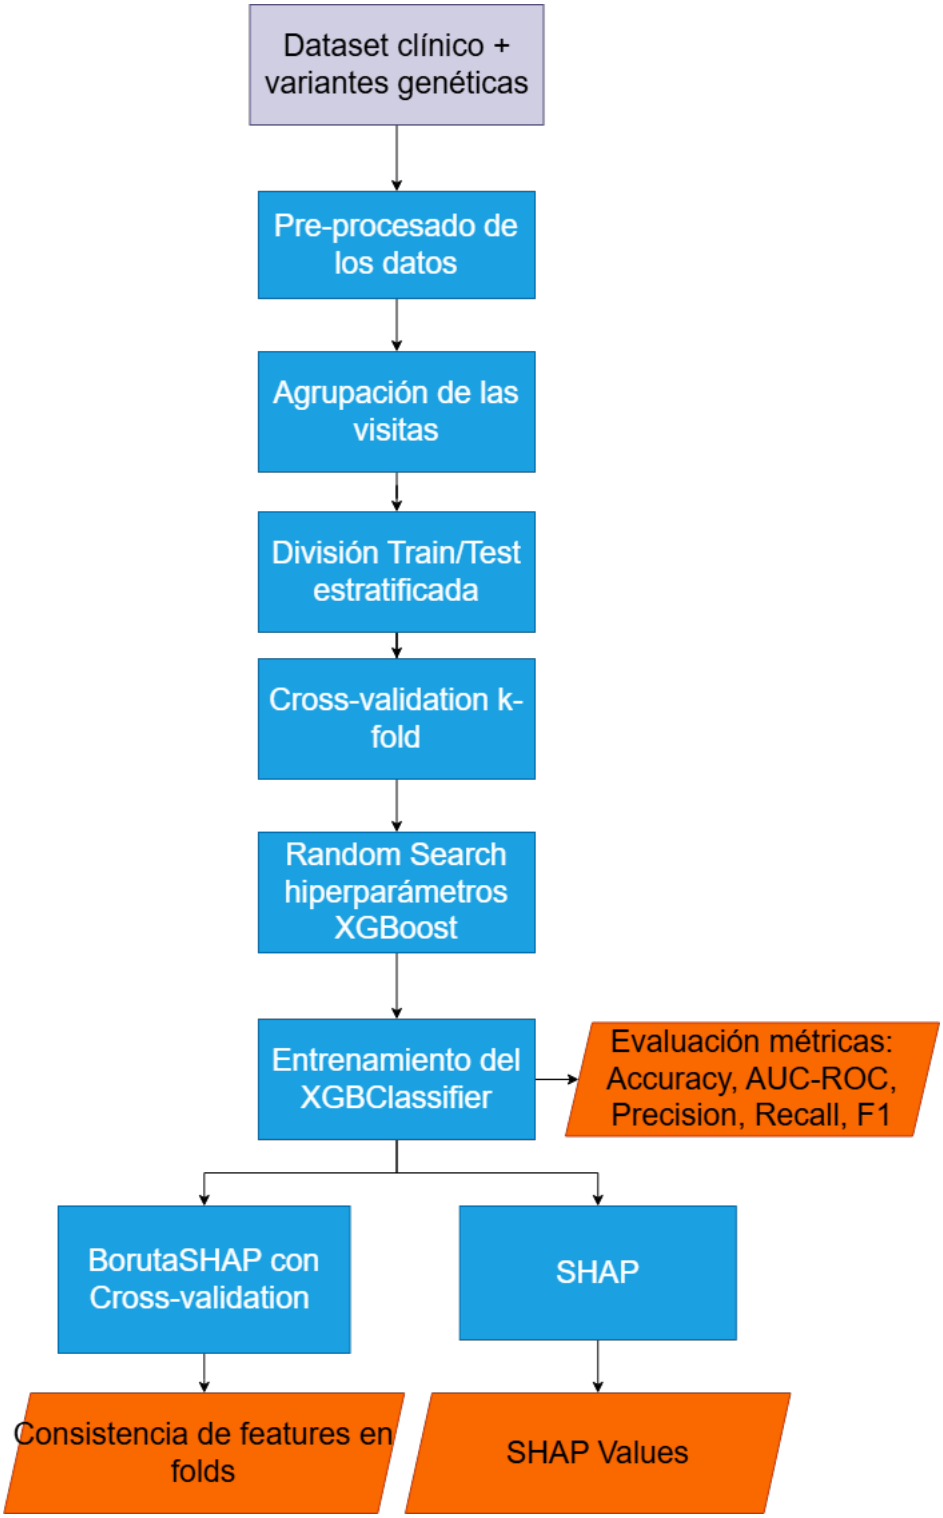

Figura 5.4: Representación esquemática del workflow del análisis de datos mediante machine learning.

6. Resultados y discusión

6.1. Resultados de la Pipeline

Tabla 6.1: Frecuencia alélica y validez para análisis estadístico estándar de variantes en chr19 (N=4460).

Variante	MAF	Alelos observados	Válida para análisis
19_45409113_C_T	0.0006726	6	No
19_45409167_C_G	0.3643	3248	Sí
19_45409283_C_A	0.0004484	4	No
19_45409579_C_T	0.02108	188	Sí (rara)
19_45409988_C_T	0.0004484	4	No
19_45410002_G_A	0.1141	1017	Sí
19_45410273_G_A	0.0006726	6	No
19_45410444_G_A	0.404	3610	Sí
19_45410548_A_G	0.0004484	4	No
19_45410911_T_G	0.00583	52	Rara
19_45411110_T_C	0.002242	20	Rara
19_45411722_G_A	0.0002242	2	No
19_45411941_T_C	0.1446	1289	Sí
19_45412040_C_T	0.0006726	6	No
19_45412079_C_T	0.0722	644	Sí (rara)

En la tabla 6.1 se pueden observar las frecuencias alélicas de las variantes proporcionadas por enroll-HD, información de suma importancia para desmentir artefactos estadísticos en pasos posteriores del análisis.

General Statistics

Copy table | Configure columns | Scatter plot | Violin plot | Export as CSV... | Showing 5/5 rows and 8/15 columns. | + Summarize table

Sample Name	% Duplication	Reads After Filtering	GC content	% PF	% Adapter	Dups	GC	Seqs
SRR10532700	1.6 %	6.8 M	39.9 %	84.8 %	6.9 %			
SRR10532700_1						9.4 %	40.0 %	4.0 M
SRR10532700_2						8.7 %	40.0 %	4.0 M
trimmed_fw						3.8 %	39.0 %	3.4 M
trimmed_rv						3.2 %	39.0 %	3.4 M

Figura 6.1: Resumen general de la comparativa entre los cuatro archivos de lecturas, forward y reverse, antes del pre procesado y después del pre procesado.

En las figuras 6.1, 6.2, 6.3 y 6.4 se observa de forma evidente como el filtrado por fastp mejoró considerablemente la calidad de las secuencias de entrada. Como se ve en la figura 6.2, el porcentaje de lecturas que se han sacrificado para obtener datos limpios de entrada es muy pequeño y todas las métricas mejoraron tras el recorte, por la presencia de secuencias

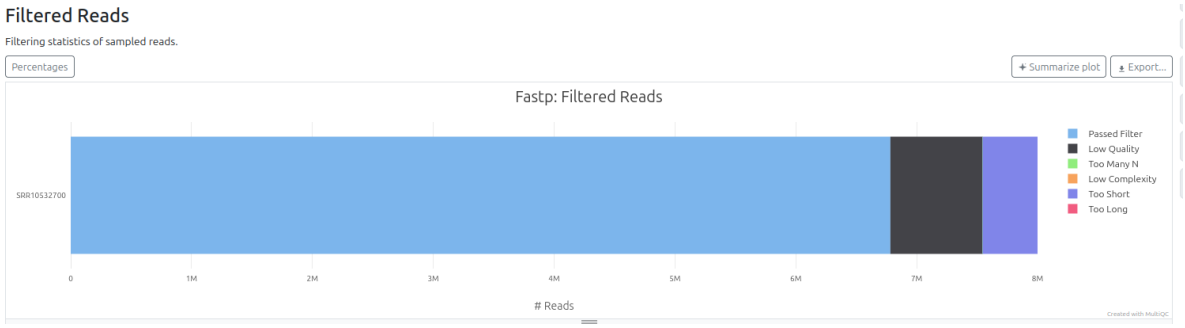

Figura 6.2: Comparativa de los reads durante el filtrado, marcado en azul los que pasaron el filtro, en negro los que no pasaron el filtro por baja calidad y en morado los que no pasaron el filtro por ser demasiado cortos.

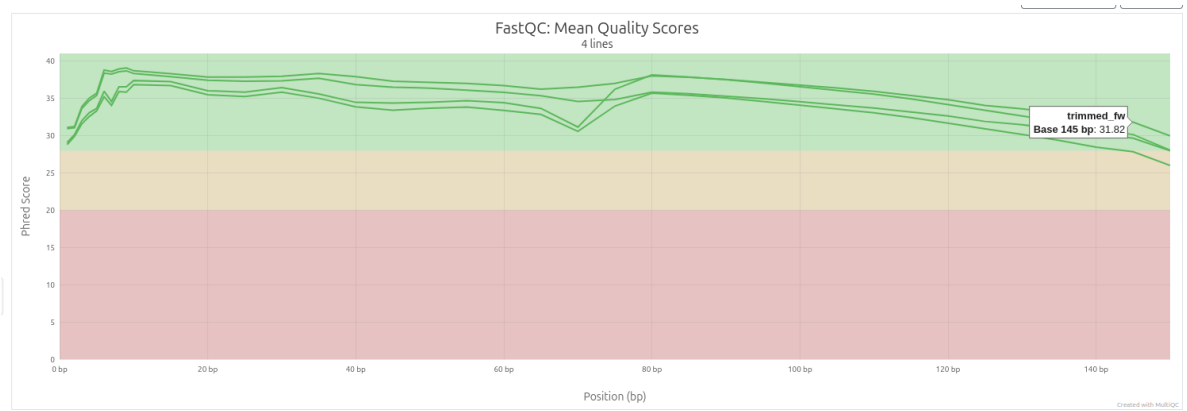

Figura 6.3: Comparativa de la calidad media, se observa como los reads filtrados se mantienen en el área verde de calidad.

sobre representadas y contaminación presente en el porcentaje de GC, es sensato asumir que estas regiones de mala calidad se debían a la presencia de adaptadores.

Se analizó el ensamblaje mediante Qualimap.

Como se ve en las tablas 6.2, 6.3, 6.4, 6.5 y 6.6 los resultados indican que la calidad del mapeo es bastante buena. El porcentaje de lecturas mapeadas es muy alto, alcanzando el 99,86%, con solo un 0,14% de lecturas no mapeadas, lo que sugiere que el alineamiento contra el genoma de referencia ha sido eficiente. Además, la ausencia de alineamientos secundarios y el bajo porcentaje de alineamientos suplementarios (0,46%) refuerzan la consistencia del mapeo, ya que indica que la mayoría de las lecturas tienen una única mejor posición de alineamiento. El valor medio de calidad de mapeo de 49,06 también es un indicador favorable, ya que refleja una alta confianza en la asignación de las lecturas al genoma de referencia.

Por otro lado, el porcentaje de lecturas duplicadas (5,59%) se mantiene en un rango aceptable, aunque podría sugerir la presencia de cierta redundancia posiblemente asociada al proceso de secuenciación o a la preparación de la librería. Asimismo, el porcentaje de lecturas recortadas es relativamente bajo (4,92%), lo que indica que no fue necesario eliminar una proporción significativa de bases por problemas de calidad en los extremos de las secuencias.

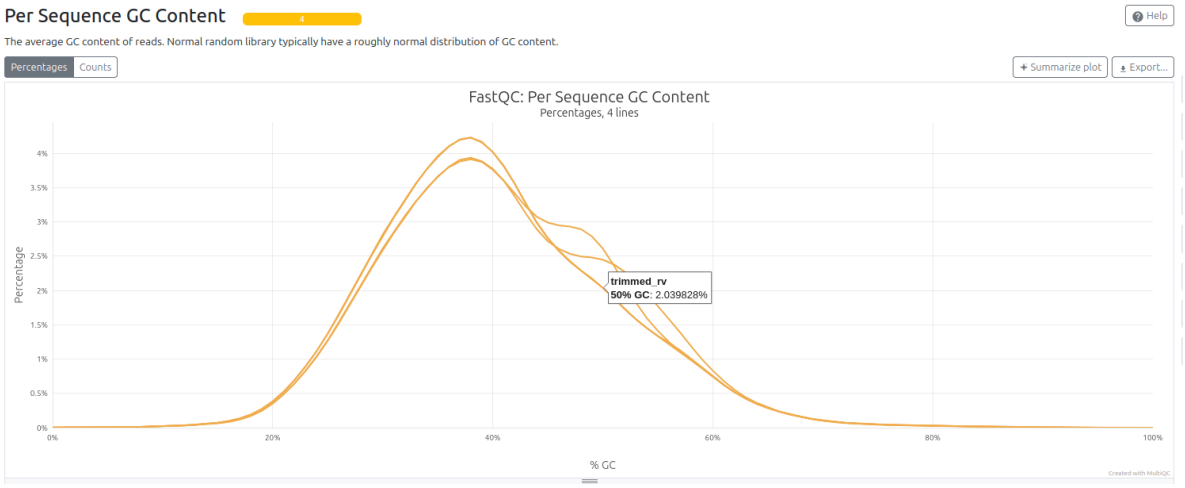

Figura 6.4: Comparativa del porcentaje de GC en los reads antes y después del filtrado.

Sin embargo, el valor medio de cobertura obtenido (0,3219) es bajo y presenta una desviación estándar elevada (4,1087), lo que indica que la cobertura del genoma no es homogénea y que existen regiones con una representación muy variable de lecturas. Probablemente debido a que se seleccionó un fragmento relativamente pequeño del genoma para la construcción de la pipeline.

Finalmente, la tasa de error general del 1% y el número de inserciones y deleciones (indels) y mismatches observados son relativamente bajos, aunque la elevada proporción de indels en homopolímeros (53,97%) sugiere que este tipo de regiones puede ser una fuente importante de errores de alineamiento, algo que es habitual en tecnologías de secuenciación con mayor dificultad para resolver repeticiones de una sola base.

tras la ejecución del pipeline se esperaba obtener una carpeta con los tres archivos de Plink por cromosoma y como se puede observar en la figura 6.5 se ha conseguido.

6.2. Resultados de Machine Learning

Para empezar, el resultado del random search se puede ver en la tabla 6.7, estos hiperparámetros serán los que se utilizaron en todos los modelos de clasificación.

Primero se entrenó un modelo de clasificación básico XGBT empleando los hiperparámetro ya calculados, el cual obtuvo los resultados presentes en la tabla 6.8. Viendo las métricas de accuracy, se puede determinar un buen rendimiento general del modelo ya que es de un 87%, valor muy cercano al 100% ideal y que habla muy bien del modelo entrenado, predice correctamente el 87% de las observaciones.

En las métricas de AUC-ROC también se observan valores altos, demostrando una gran capacidad de discriminación del modelo entrenado.

La mayor debilidad del modelo queda palpable viendo la columna de support entre clases, esto demuestra que las clases están desequilibradas, lo cual es congruente con los datos, ya que hay muchos menos casos de demencia, que casos clasificados como sanos, por lo que dicha diferencia se hace notable en los datos. El modelo es muy bueno prediciendo cuando un paciente no tiene demencia, pero no lo es tanto a la hora de clasificar

Tabla 6.2: Resumen de estadísticas globales del alineamiento de lecturas.

Métrica	**Valor**
Reference size	3.137.161.264
Number of reads	6.813.518
Mapped reads	6.803.932 / 99,86%
Unmapped reads	9.586 / 0,14%
Mapped paired reads	6.803.932 / 99,86%
Mapped reads, first in pair	3.401.533 / 49,92%
Mapped reads, second in pair	3.402.399 / 49,94%
Mapped reads, both in pair	6.801.521 / 99,82%
Mapped reads, singletons	2.411 / 0,04%
Secondary alignments	0
Supplementary alignments	31.328 / 0,46%
Read min/max/mean length	15 / 151 / 149,73
Duplicated reads (flagged)	380.820 / 5,59%
Clipped reads	335.372 / 4,92%

Tabla 6.3: Contenido de bases en las lecturas alineadas (A, C, G, T y N).

Base / Métrica	**Número / Porcentaje**
Number/percentage of A's	302.301.416 / 29,95%
Number/percentage of C's	201.999.918 / 20,01%
Number/percentage of T's	304.229.440 / 30,14%
Number/percentage of G's	200.865.597 / 19,9%
Number/percentage of N's	6.726 / 0%
GC Percentage	39,91%

a un paciente con demencia. El rendimiento para la clase minoritaria es más limitado, especialmente en el recall. Esto significa que el modelo no detecta todos los casos positivos reales, perdiendo aproximadamente un 35% de ellos.

En general, el modelo presenta un buen rendimiento. No obstante, dado que el objetivo principal no es emplearlo como herramienta predictiva definitiva, sino como un primer acercamiento al análisis de las variables del estudio, estos resultados deben interpretarse con cautela. En este contexto, el modelo permite evaluar el potencial predictivo de las variables analizadas en relación con la demencia. Aun así, sería necesario realizar pasos adicionales para desarrollar un modelo con fines predictivos más robustos, pero no es el objetivo de este trabajo.

Cómo se puede observar, tanto en la figura 6.6 como en la tabla 6.9 las variables que SHAP consideró más importantes han sido:

1. motscore
2. ccogage
3. hdiss_stage_imp
4. isced

Tabla 6.4: Estadísticas de cobertura de las lecturas alineadas sobre el genoma de referencia.

Métrica de cobertura	**Valor**
Mean	0,3219
Standard Deviation	4,1087

Tabla 6.5: Calidad del Mapeo

Mapping Quality	**Value**
Mean Mapping Quality	49,06

Tabla 6.6: Indels y Mismatches

Mismatches and Indels	**Value**
General error rate	1%
Mismatches	9.691.907
Insertions	123.248
Mapped reads with at least one insertion	1,71%
Deletions	137.890
Mapped reads with at least one deletion	1,9%
Homopolymer indels	53,97%

5. exfscore

Ninguna de las variantes presentes en el gen *APOE* aparece como importante a la hora de predecir la demencia en los pacientes y se quedan relegadas a los puestos inferiores, sin embargo si hay variantes más importantes que otras, entre las que destaca 19_45412079_C_T_T cómo la más importante, que equivale a la variante con el rsID rs7412, fundamental junto a rs429358 para determinar las variantes Epsilon del gen *APOE*, fundamentales en la progresión de la enfermedad de Alzheimer.

Entre las variables ya estudiadas previamente se encuentran dos 19_45410444_G_A_A y 19_45409167_C_G_C, estas variantes cuentan con menos potencial predictivo que rs7412, sin embargo, cuentan con un potencial predictivo superior a la variante rs429358, muy documentada y estudiada en el ámbito del progreso de las enfermedades neurológicas. Cómo se puede observar en la tabla 6.1, las variables identificadas tienen una frecuencia alélica suficiente como para no ser inmediatamente catalogadas como artefactos estadísticos, por lo cual, a la hora de continuar la investigación sobre variantes genómicas presentes en el gen *APOE*, influyentes en la enfermedad de parkinson, reportaría, no como biomarcadores inmediatos, si no como variantes que pueden ser interesantes a la hora de realizar más estudios específicos para dichas variantes a las variantes estudiadas rs429358 y rs7412 y a las variantes nuevas 19_45410444_G_A_A y 19_45409167_C_G_C.

Para continuar con la evaluación de las variantes de interés se realizó BorutaSHAP, en la tabla 6.10 se pueden observar las variables determinadas como realmente importantes para las clasificaciones del modelo.

Tanto en la figura 6.7, cómo en la tabla 6.10, se observa claramente como las variables aceptadas vuelvieron a ser las mencionadas con anterioridad, en este caso las

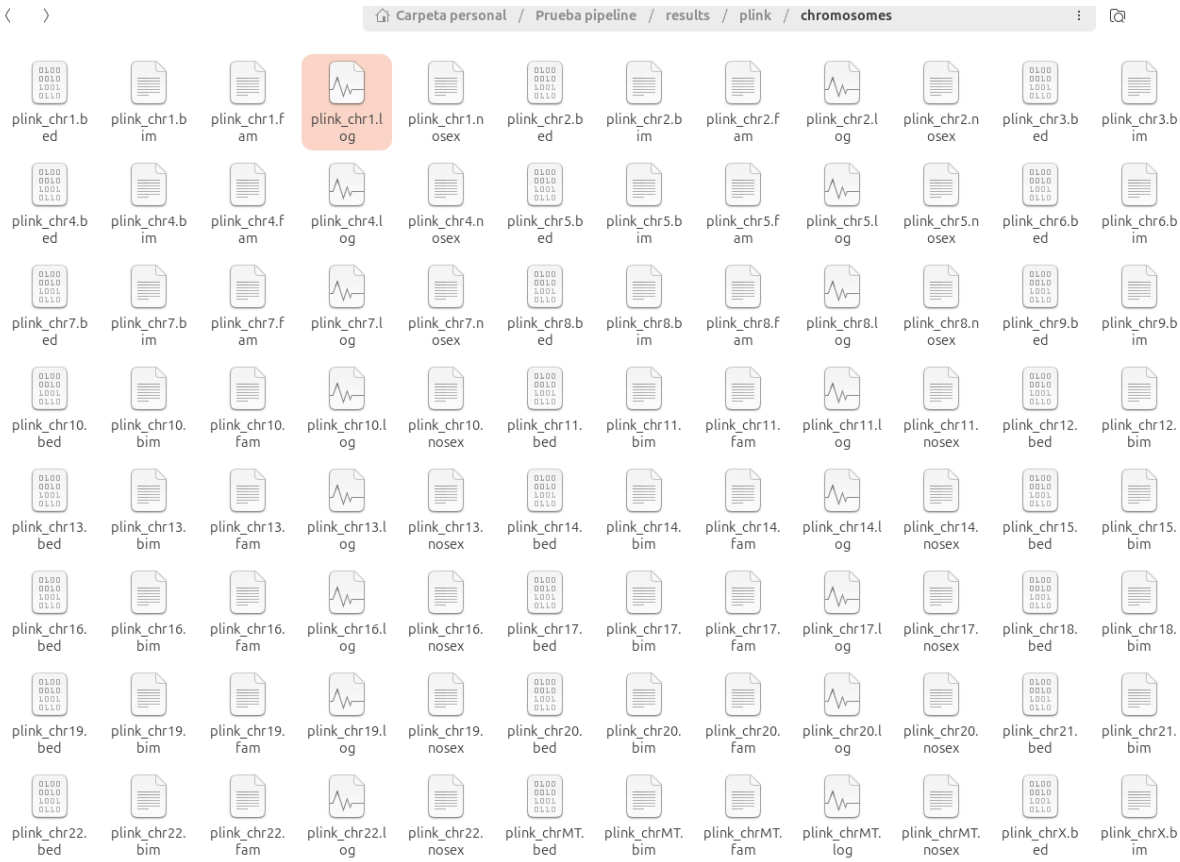

Figura 6.5: En la figura se puede observar la salida de la pipeline, en un formato muy parecido al proporcionado por enroll-HD, conservando los logs.

seleccionadas específicamente por Boruta fueron:

1. cccogage
2. isced
3. hdiss_stage_imp
4. motscore

Mientras que el resto de las variables, al no superar el umbral de diferencia con sus sombras, fueron clasificadas como ruido y poco importantes a la hora de predecir la demencia.

En la tabla 6.11, se pueden observar los resultados de aplicar validación cruzada a BorutaSHAP, en cada fold las variables detectadas como significativas varían, por lo tanto se estudió en una prueba con 5 folds, cuales eran las variables más repetidas.

Se confirma lo que ya se había planteado anteriormente y es que las variables motscore, isced, cccogage, hdiss_stage_imp y exfscore, sin embargo, en este estudio más completo aparece que un modelo, sin tener por que ser el mismo, seleccionó como importante age y ccvabage, siendo interesante estudiar su efecto en la demencia y no catalogarlo como ruido simplemente por que un estudio anterior lo hiciera.

Tabla 6.7: Mejores hiperparámetros obtenidos mediante random search y validación cruzada con 5 folds y 20 combinaciones evaluadas (100 ajustes totales).

Hiperparámetro	Valor óptimo
subsample	0.6
n_estimators	500
max_depth	3
learning_rate	0.01
gamma	0.1
colsample_bytree	1.0

Tabla 6.8: Resultados del modelo de clasificación de demencia, se empleó para la creación de este, validación cruzada y los hiperparámetros calculados mediante random search.

Clase	Precision	Recall	F1-score	Support
0	0.90	0.94	0.92	277
1	0.75	0.65	0.70	80
Accuracy			0.87	357
Macro Avg	0.83	0.79	0.81	357
Weighted Avg	0.87	0.87	0.87	357

Métrica	Valor
CV Accuracy	$0{,}8611 \pm 0{,}0145$
CV AUC	$0{,}9056 \pm 0{,}0075$
Test AUC-ROC	0.9139

Sin embargo ninguna de las variantes genéticas resultó ser de importancia predictiva tras todos los análisis, aunque se detectaron 2 nuevas variantes que pueden llegar a tener significado biológico, en especial, a la hora de estudiar el efecto de diversas enfermedades neurológicas.

6.3. Discusión

En este estudio no se observó una asociación significativa entre las variantes del gen *APOE* y la presencia de demencia en pacientes con enfermedad de Huntington. Estos resultados son consistentes con varios estudios previos que tampoco han encontrado una relación clara entre los alelos de *APOE* y la progresión clínica de la enfermedad. Por ejemplo, algunos trabajos han señalado que, a diferencia de lo que ocurre en otras enfermedades neurodegenerativas como la enfermedad de Alzheimer, el papel de polimorfismos del gen *APOE* en Huntington parece ser limitado[17], [18].

Estudios recientes revelan que modelos con la enfermedad de Huntington poseen una expresión reducida del gen *APOE* y de genes mitocondriales, sugiriendo un posible enlace entre complicaciones del metabolismo del colesterol y la función mitocondrial. La asociación del gen *APOE*, con la enfermedad de Huntington, ha sido objeto de investigación en la

Tabla 6.9: Valores Mean absolute SHAP calculados para cada variable del modelo de clasificación.

Feature	Mean Abs SHAP
motscore	1.526007
cccogage	0.274803
hdiss_stage_imp	0.212539
isced	0.167410
exfscore	0.159068
depscore	0.124795
age	0.117014
aptscore	0.063409
ccdepage	0.062798
psyscore	0.062133
race_1	0.056398
caghigh	0.056092
ccvabage	0.054602
ccpsyage	0.052922
irascore	0.048555
caglow	0.042725
ccirbage	0.038181
ccpobage	0.034470
region_Europe	0.018764
sex_f	0.017190
ccaptage	0.017035
sxsubjm_1.0	0.011343
19_45412079_C_T_T	0.009041
sxsubjm_6.0	0.008835
19_45410002_G_A_A	0.007889
19_45409167_C_G_C	0.007584
19_45410444_G_A_A	0.006859
19_45411941_T_C_C	0.005893
race_3	0.004836
race_6	0.003794
region_Northern America	0.002992
sxsubjm_3.0	0.002399
sxsubjm_2.0	0.002158
race_15	0.001927
region_Australasia	0.001284
19_45410911_T_G_G	0.000781
19_45410548_A_G_G	0.000000
19_45411722_G_A_A	0.000000

Tabla 6.10: Atributos confirmados importantes y no importantes para la predicción de demencia empleando el método BorutaSHAP. cccogage: Edad en la que las afecciones cognitivas empezaron a tener efectos en el día a día. isced: Escala de nivel de educación. hdiss_stage_imp: Estadía de la enfermedad según la escala hdiss. exfscore: Función ejecutiva según la escala de PBAs. motscore: Puntuación de la escala motora UHDRS.

Importantes	**No importantes 1**	**No importantes 2**
cccogage	race_16	sxsubjm_4.0
isced	19_45412079_C_T_T	19_45411110_T_C_C
hdiss_stage_imp	ccpsyage	sxsubjm_5.0
exfscore	19_45410273_G_A_A	19_45409579_C_T_T
motscore	race_1	race_2
	19_45412040_C_T_T	ccdepage
	region_Northern America	19_45410444_G_A_A
	region_Europe	19_45409113_C_T_T
	19_45411941_T_C_C	19_45409167_C_G_C
	psyscore	19_45410002_G_A_A
	sxsubjm_6.0	19_45410548_A_G_G
	race_6	ccirbage
	irascore	ccaptage
	sxsubjm_1.0	sxsubjm_3.0
	19_45409283_C_A_A	race_15
	19_45411722_G_A_A	region_Australasia
	age	caghigh
	aptscore	sex_m
	ccvabage	region_Latin America
	sxsubjm_2.0	sex_f
	ccpobage	caglow
		depscore

Tabla 6.11: Consistencia de variables: número de folds en los que cada variable fue aceptada como significativa para predecir demencia. age: Edad del paciente. cccogage: Edad en la que las afecciones cognitivas empezaron a tener efectos en el día a día. isced: Escala de nivel de educación. hdiss_stage_imp: Estadía de la enfermedad según la escala hdiss. exfscore: Función ejecutiva según la escala de PBAs. motscore: Puntuación de la escala motora UHDRS. ccvabage: Edad en la que los pacientes empezaron a demostrar comportamientos violentos o agresivos

Variable	**Folds aceptados**
age	1/5
cccogage	4/5
isced	4/5
hdiss_stage_imp	4/5
exfscore	3/5
motscore	5/5
ccvabage	1/5

literatura neurológica desde hace décadas, encontrándose numerosos estudios que han tratado de determinar su posible relación desde los años 2000 hasta artículos publicados en los meses anteriores a la realización de este trabajo. Sin embargo, en ninguno de estos estudios la asociación entre polimorfismos y la enfermedad es concluyente, mostrando en su mayoría y, empleando estadística clásica, resultados negativos. No obstante, en este trabajo, el emplear técnicas de análisis que se alejan de la estadística clásica, abordan posibles asociaciones nuevas, destacando relaciones no lineales[1].

Una posible explicación es que la enfermedad de Huntington tiene una etiología genética monogénica claramente definida, causada por la expansión de repeticiones CAG en el gen HTT, siendo medida en el estudio por las variables caghigh y caglow, que representan las repeticiones de CAG en el alelo mayor y menor, respectivamente. En este contexto, el efecto de genes modificadores como *APOE* podría ser menor que en enfermedades multifactoriales y poligénicas como la enfermedad de Alzheimer, en la que polimorfismos en los genes responsables, son variables mucho más importantes a la hora de estudiar el desarrollo de la patología.

Un aspecto relevante a considerar es el papel biológico del gen *APOE* en el sistema nervioso central. La apolipoproteína E participa en el transporte y metabolismo del colesterol en el cerebro, así como en procesos de reparación neuronal, plasticidad sináptica y respuesta inflamatoria [19]. Estas funciones han llevado a plantear que variantes en *APOE* podrían modular procesos neurodegenerativos más allá de la enfermedad de Alzheimer. De hecho, el alelo E4 constituye el principal factor genético de riesgo para la enfermedad de Alzheimer de inicio tardío [20] y se ha asociado con un deterioro cognitivo más acelerado y con alteraciones estructurales cerebrales en distintas regiones implicadas en la memoria y la función ejecutiva.

Estos resultados apoyan la idea de que las variantes genéticas implicadas en otras enfermedades neurodegenerativas pueden no desempeñar un papel relevante en la progresión cognitiva de la enfermedad de Huntington. La identificación de biomarcadores específicos de la enfermedad sigue siendo un área importante de investigación [21].

La relación tan fuerte detectada entre demencia y motscore, siendo la mejor variable

predictiva del modelo de forma contundente, puede deberse a que, en la enfermedad de Huntington, los síntomas motores son los primeros signos de la enfermedad, evolucionando de manera conjunta con esta. Existe la posibilidad de que el modelo haya encontrado la siguiente relación: Los enfermos de Huntington que empiezan a desarrollar demencia, ya han desarrollado síntomas motores y una demencia grave, se asocia a síntomas motores aún mas graves [22].

En este sentido, diversos estudios han sugerido que la progresión clínica de la enfermedad de Huntington está determinada principalmente por la longitud de la expansión CAG en el gen *HTT* [23], sin embargo no ha resultado tan determinante para la predicción de la demencia como otras covariables. Aunque se han propuesto múltiples genes modificadores que podrían influir en aspectos específicos del fenotipo clínico [24], su efecto suele ser moderado en comparación con el impacto directo de covariables como el motscore. Esto podría explicar por qué variantes en genes implicados en otras enfermedades neurodegenerativas, como *APOE*, no muestran asociaciones consistentes con la aparición de demencia en pacientes con Huntington.

Por otra parte, algunos trabajos recientes han destacado que, incluso en enfermedades donde *APOE* tiene un papel bien establecido, su efecto depende de complejas interacciones con otros factores genéticos y ambientales. Estudios de asociación genómica han identificado loci adicionales que modifican el deterioro cognitivo asociado al alelo E4, lo que sugiere que el impacto funcional de *APOE* se encuentra mediado por redes genéticas más amplias relacionadas con procesos inmunitarios, metabolismo lipídico y función sináptica. Este tipo de interacciones complejas podría pasar desapercibido en análisis basados exclusivamente en asociaciones lineales simples, lo que justifica la utilización de enfoques analíticos más flexibles capaces de detectar relaciones no lineales o dependencias de mayor orden.

Finalmente, también debe considerarse que muchos estudios sobre modificadores genéticos en la enfermedad de Huntington presentan tamaños muestrales relativamente limitados, lo que reduce la potencia estadística para detectar efectos pequeños o moderados. En este contexto, resultados negativos no necesariamente implican la ausencia total de efecto, sino que podrían reflejar la dificultad inherente a identificar moduladores genéticos secundarios en enfermedades dominadas por una causa genética principal. Por ello, este trabajo y futuros estudios integran, en la medida de lo posible, cohortes más amplias, análisis longitudinales y aproximaciones multi-ómicas podrían contribuir a esclarecer mejor el papel potencial de genes modificadores en la progresión cognitiva de la enfermedad.

En conjunto, los resultados obtenidos sugieren que las variantes del gen *APOE* no desempeñan un papel determinante en la aparición de demencia en pacientes con enfermedad de Huntington dentro de la cohorte analizada. Estos hallazgos son coherentes con gran parte de la literatura previa, que apunta a un efecto limitado de este gen en una enfermedad cuya etiología está dominada por la expansión de repeticiones CAG en el gen *HTT*. No obstante, la complejidad de los procesos neurodegenerativos y la posible interacción entre múltiples factores genéticos y ambientales hacen necesario continuar investigando el papel de genes modificadores mediante cohortes más amplias y enfoques analíticos integrativos.

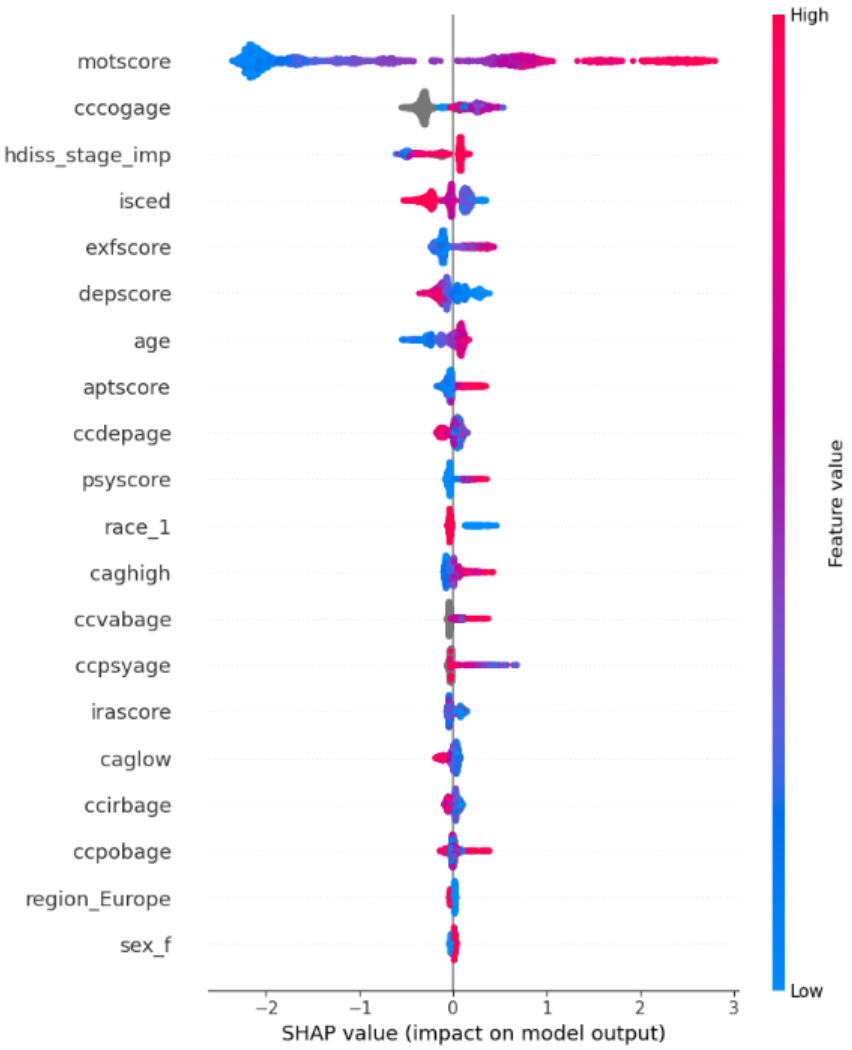

Figura 6.6: Gráfico summary plot de SHAP, en el eje Y se pueden observar las variables analizadas, ordenadas de mayor a menor importancia y en el eje X se observa el impacto de cada variable en la demencia de los pacientes, valores positivos aumentan la probabilidad de demencia, mientras que negativos la disminuyen.

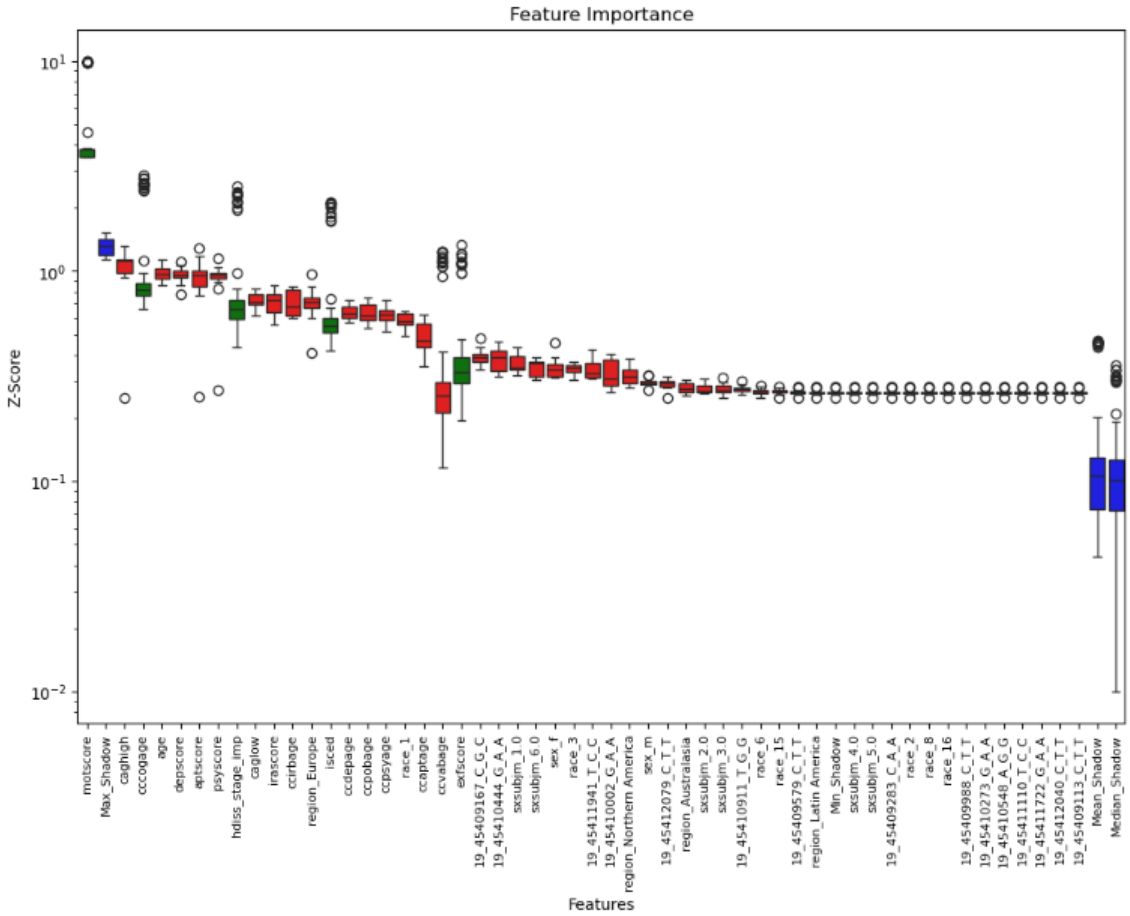

Figura 6.7: Gráfico de feature importance, producido por Boruta, en este gráfico de cajas (Boxplot) se utiliza el Z-Score para comparar las variables reales con las variables sombra. Las variables marcadas en verde son aquellas aceptadas, mientras que las rojas, son las que el modelo rechaza o etiqueta como menos importantes a la hora de predecir la demencia. Las cajas azules son las pertenecientes a las variables sombra. En el eje Y se grafica la importancia de cada variable usando el z-score, mientras que en el eje X, se listan todas las variables estudiadas.

7. Conclusiones

1. Se desarrolló e implementó una pipeline bioinformática reproducible para el procesamiento y análisis de datos genómicos procedentes de estudios de asociación de genoma completo (GWAS), permitiendo la identificación y preparación para estudio de variantes codificantes y no codificantes del gen *APOE* en pacientes con enfermedad de Huntington.
2. El análisis estadístico realizado no evidenció una asociación significativa entre los polimorfismos identificados en el gen *APOE* y las variaciones en el fenotipo funcional de los pacientes evaluados mediante escalas clínicas estandarizadas.
3. Los resultados obtenidos sugieren que, en la cohorte analizada, las variantes del gen *APOE* no desempeñan un papel determinante en la progresión clínica ni en la aparición de deterioro cognitivo asociado a la enfermedad de Huntington.
4. La metodología desarrollada demuestra la utilidad de los enfoques bioinformáticos integrados con modelos de machine learning, para el análisis de variantes genéticas en enfermedades neurodegenerativas, constituyendo una herramienta potencialmente aplicable a futuros estudios de modificadores genéticos en distintas patologías neurodegenerativas.
5. Aunque no se identificó una asociación significativa en este estudio, la exploración de variantes genéticas sigue siendo una línea de investigación relevante para comprender la progresión clínica de la enfermedad y apoyar el desarrollo de futuros biomarcadores y estrategias terapéuticas.

8. Limitaciones y Perspectivas futuras

Durante la realización de este trabajo se enfrentaron distintas dificultades entre las que destacan:

1. Coordinación de distintos grupos ajenos entre si, este trabajo se realizó gracias a los esfuerzos combinados del servicio de neurología, la unidad de investigación, el tutor de TFM y del redactor. En un trabajo que depende de tantas personas con horarios muy diferentes siempre hay que ajustar las expectativas al tiempo disponible.

Las principales limitaciones de este trabajo son las siguientes:

1. los datos con los que se trabajaron eran extensos y de muy buena calidad, sin embargo, no son de acceso público y para poder trabajar con ellos o aumentar el alcance del trabajo, hay que solicitar permiso de la plataforma Enroll-HD, lo que limita aspectos cómo un posible análisis transcriptómico de la expresión de *APOE*.
2. Al cederse los datos con el variant calling ya realizado se pierde flexibilidad a la hora de trabajar con los datos, por ejemplo, siendo imposible obtener más información siendo mas laxos con el pre-procesamiento, lo que podría haber otorgado conocimiento interesante, esto se subsanó mediante la elaboración de un pipeline para un hipotético procesamiento de las secuencias de los pacientes
3. La literatura específica sobre este tema es escasa ya que es un área en la que la aparición de nuevas tecnologías como el machine learning ha abierto muchas posibilidades de desarrollo aún por explotar.

Y por último las lineas de trabajo futuras para continuar desarrollando esta área con mucha información por explorar es:

1. Optimización del pipeline para trabajar con grandes volúmenes de datos, la versión actual está diseñada para trabajar con volúmenes no muy extensos ya que la capacidad de cálculo de los ordenadores disponibles para este trabajo fin de master es limitada, sin embargo, para escalar aún mas esta pipeline a proyectos de WGS reales, se necesitaría una capa de optimización para poder contar con tiempos de ejecución razonables.
2. La otra linea de trabajo futura pasa por el análisis transcriptómico de la expresión génica de *APOE* ya que hay varios artículos que discuten que la relación entre Huntington y *APOE* está marcada por los niveles de expresión.

Bibliografía

[1] Islam S, Noorani A, Sun Y, Michikawa M, Zou K. Multi-functional role of apolipoprotein E in neurodegenerative diseases. Frontiers in Aging Neuroscience. 2025 Jan;17. Available from: https://www.frontiersin.org/journals/aging-neuroscience/articles/10.3389/fnagi.2025.1535280/full.

[2] Yang LG, March ZM, Stephenson RA, Narayan PS. Apolipoprotein E in lipid metabolism and neurodegenerative disease. Trends in endocrinology and metabolism: TEM. 2023 Aug;34(8):430-45.

[3] Chang C. PLINK 1.9 file format reference; 2024. Available from: https://www.cog-genomics.org/plink/1.9/formats.

[4] Gusella JF. CAG Repeat Not Polyglutamine Length Determines Timing of Huntingtons Disease Onset. Cell. 2019 Aug;178(4):887-900.e14. Available from: https://pmc.ncbi.nlm.nih.gov/articles/PMC6700281/.

[5] CHDI Foundation, Inc . Enroll-HD: A prospective registry study in a global Huntington's disease cohort; 2024. Clinical trial registration: NCT01574053. Available from: https://clinicaltrials.gov/study/NCT01574053.

[6] Enroll-HD. Enroll-HD; 2024. Available from: https://www.enroll-hd.org/es/for-researchers/enroll-hd/.

[7] Li H. Aligning sequence reads, clone sequences and assembly contigs with BWA-MEM. arXiv; 2013. ArXiv:1303.3997 [q-bio]. Available from: http://arxiv.org/abs/1303.3997.

[8] Zhao Q. A Study on Optimizing MarkDuplicate in Genome Sequencing Pipeline. In: Proceedings of the 5th International Conference on Bioinformatics Research and Applications. ICBRA '18. New York, NY, USA: Association for Computing Machinery; 2018. p. 8-15. Available from: https://dl.acm.org/doi/10.1145/3309129.3309134.

[9] Danecek P. Twelve years of SAMtools and BCFtools;. Available from: https://academic.oup.com/gigascience/article/10/2/giab008/6137722?login=false&guestAccessKey=.

[10] UCSC Genome Browser. APOE gene (Homo sapiens); 2025. Available from: https://genome.ucsc.edu/cgi-bin/hgGene?db=hg19&hgg_gene=APOE.

[11] Butman J, Arizaga RL, Harris P, Drake M, Baumann D, de Pascale A, et al. El Mini - Mental State Examination en español. Normas para Buenos Aires. NEUROLOGÍA ARGENTINA. 2001;26.

[12] Group HS. Unified Huntingtons Disease Rating Scale - UHDRS Licensing;. Available from: https://huntingtonstudygroup.org/uhdrs-licensing/.

[13] Long JD, Gantman EC, Mills JA, Vaidya JG, Mansbach A, Tabrizi SJ, et al. Applying the Huntington's Disease Integrated Staging System (HD-ISS) to Observational Studies. Journal of Huntington's Disease. 2023;12(1):57-69.

[14] Poslavskaya E, Korolev A. Encoding categorical data: Is there yet anything 'hotter' than one-hot encoding?. arXiv; 2023. ArXiv:2312.16930 [cs]. Available from: http://arxiv.org/abs/2312.16930.

[15] Griffiths CS, Lebert JM, Sollini J, Bizley JK. Gradient boosted decision trees reveal nuances of auditory discrimination behavior. PLOS Computational Biology. 2024 Apr;20(4):e1011985. Available from: https://pmc.ncbi.nlm.nih.gov/articles/PMC11051626/.

[16] Ejiyi CJ, Qin Z, Ukwuoma CC, Nneji GU, Monday HN, Ejiyi MB, et al. Comparative performance analysis of Boruta, SHAP, and Borutashap for disease diagnosis: A study with multiple machine learning algorithms. Network: Computation in Neural Systems. 2025 Jul;36(3):507-44. Https://doi.org/10.1080/0954898X.2024.2331506. Available from: https://doi.org/10.1080/0954898X.2024.2331506.

[17] Kálmán J, Juhász A, Majtényi K, Rimanóczy , Jakab K, Gárdián G, et al. Apolipoprotein E polymorphism in Picks disease and in Huntingtons disease. Neurobiology of Aging. 2000 Jul;21(4):555-8. Available from: https://www.sciencedirect.com/science/article/pii/S0197458000001500.

[18] Maiti TK, Konar S, Bir S, Kalakoti P, Bollam P, Nanda A. Role of apolipoprotein E polymorphism as a prognostic marker in traumatic brain injury and neurodegenerative disease: a critical review. Neurosurgical Focus. 2015 Nov;39(5):E3. Available from: https://thejns.org/focus/view/journals/neurosurg-focus/39/5/article-pE3.xml.

[19] Liu CC, Kanekiyo T, Xu H, Bu G. Apolipoprotein E and Alzheimer disease: risk, mechanisms and therapy. Nature Reviews Neurology. 2013 Feb;9(2):106-18. Available from: https://www.nature.com/articles/nrneurol.2012.263.

[20] Corder EH, Saunders AM, Strittmatter WJ, Schmechel DE, Gaskell PC, Small GW, et al. Gene dose of apolipoprotein E type 4 allele and the risk of Alzheimer's disease in late onset families. Science. 1993 Aug;261(5123):921-3.

[21] Aqel S, Ahmad J, Saleh I, Fathima A, Al Thani AA, Mohamed WMY, et al. Advances in Huntingtons Disease Biomarkers: A 10-Year Bibliometric Analysis and a Comprehensive Review. Biology. 2025 Jan;14(2):129. Available from: https://pmc.ncbi.nlm.nih.gov/articles/PMC11852324/.

[22] Kirkwood SC, Su JL, Conneally PM, Foroud T. Progression of Symptoms in the Early and Middle Stages of Huntington Disease. Archives of Neurology. 2001 Feb;58(2):273-8. Available from: https://doi.org/10.1001/archneur.58.2.273.

[23] Langbehn DR, Brinkman RR, Falush D, Paulsen JS, Hayden MR, International Huntington's Disease Collaborative Group. A new model for prediction of the age of onset and penetrance for Huntington's disease based on CAG length. Clinical Genetics. 2004 Apr;65(4):267-77.

[24] Gusella JF, MacDonald ME, Lee JM. Genetic modifiers of Huntington's disease. Movement Disorders: Official Journal of the Movement Disorder Society. 2014 Sep;29(11):1359-65.

9. Anexos

9.1. Repositorio en GitHub

The code used to perform the analyses in this study is publicly available at the following GitHub repository:

https://github.com/danilp786/apoe-huntington-wgs-analysis

9.2. Pipeline completo

```
#!/bin/bash

set -e
set -o pipefail

# --- VARIABLES ---
RUN_ID=$1
SAMPLE=$2
PLATFORM=$3
LIBRARY_ID=$4
PLATFORM_UNIT=$5
REF=$6
R1=$7
R2=$8
THREADS=$9


echo "Sample: $SAMPLE"
echo "Referencia: $REF"
echo "Reads: $R1 $R2"
echo "Threads: $THREADS"

# --- 1. PREPARACIÓN DE CARPETAS ---
echo "--- Creando estructura de directorios ---"
mkdir -p results/reports/fastqc_raw
mkdir -p results/reports/fastqc_trimmed
mkdir -p results/reports/fastp
mkdir -p results/reports/multiqc
mkdir -p results/alignment
mkdir -p results/vcf
mkdir -p results/plink/logs
mkdir -p results/plink/chromosomes
mkdir -p results/reports/qualimap
```

```
# --- 2. QC INICIAL ---
echo "--- Paso 1: QC inicial con FastQC ---"
fastqc $R1 $R2 -o results/reports/fastqc_raw/

# --- 3. PRE-PROCESAMIENTO Y TRIMMING (fastp) ---
echo "--- Paso 2: Limpieza de lecturas con fastp ---"

fastp \
  -i $R1 -I $R2 \
  -o results/alignment/trimmed_fw.fastq \
  -O results/alignment/trimmed_rv.fastq \
  --detect_adapter_for_pe \
  -q 20 -u 30 \
  -h results/reports/fastp/fastp_report.html \
  -j results/reports/fastp/fastp_report.json

# --- 4. QC POST-TRIMMING ---
echo "--- Paso 3: QC después del trimming ---"

fastqc \
results/alignment/trimmed_fw.fastq \
results/alignment/trimmed_rv.fastq \
-o results/reports/fastqc_trimmed/

# --- 5. MULTIQC ---
echo "--- Paso 4: Generando reporte MultiQC ---"

multiqc results/reports/ -o results/reports/multiqc/

# --- 6. ALINEAMIENTO ---
echo "--- Paso 5: Alineamiento con BWA y ordenado ---"

bwa mem -t $THREADS \
-R "@RG\tID:${RUN_ID}\tSM:${SAMPLE}\tPL:${PLATFORM}\tLB:${LIBRARY_ID}\tPU:${PLATFORM_UNIT}"
$REF \
results/alignment/trimmed_fw.fastq \
results/alignment/trimmed_rv.fastq | \
samtools sort -@ $THREADS -o results/alignment/sorted.bam

# --- 7. MARCADO DE DUPLICADOS ---
echo "--- Paso 6: Marcado de duplicados ---"

picard MarkDuplicates \
I=results/alignment/sorted.bam \
O=results/alignment/alineamiento_marcado.bam \
M=results/alignment/metrics.txt \
REMOVE_DUPLICATES=false
```

```
samtools index results/alignment/alineamiento_marcado.bam

# eliminar BAM intermedio
rm results/alignment/sorted.bam

# --- 7b. QC DEL MAPEO---
echo "--- Paso 7b: QC del alineamiento con Qualimap ---"

qualimap bamqc \
-bam results/alignment/alineamiento_marcado.bam \
-outdir results/reports/qualimap \
-nt $THREADS

# --- 8. VARIANT CALLING ---
echo "--- Paso 7: Llamada de variantes ---"

bcftools mpileup -Ou -f $REF results/alignment/alineamiento_marcado.bam | \
bcftools call -mv -Ov -o results/vcf/variantes_raw.vcf

# --- 9. FILTRADO DE VARIANTES ---
echo "--- Paso 8: Filtrado de variantes ---"

bcftools filter \
-e 'QUAL<30 || DP<10' \
results/vcf/variantes_raw.vcf \
-o results/vcf/variantes_filtradas.vcf

# --- 10. COMPRESIÓN E INDEXADO ---
echo "--- Paso 9: Compresión e indexado del VCF ---"

bgzip -c results/vcf/variantes_filtradas.vcf > results/vcf/variantes_filtradas.vcf.gz
tabix -p vcf results/vcf/variantes_filtradas.vcf.gz

# --- 11. CONVERSIÓN A PLINK ---
echo "--- Paso 10: Conversión a PLINK ---"

for chr in {1..22} X Y MT; do
  plink \
    --vcf results/vcf/variantes_filtradas.vcf.gz \
    --chr $chr \
    --make-bed \
    --out results/plink/chromosomes/plink_chr${chr} \
    --allow-extra-chr \
    --double-id \
    --silent
done
```

```
# --- 12. LIMPIEZA FINAL ---
mv results/plink/*.log results/plink/*.nosex results/plink/logs/ 2>/dev/null
sed -i 's/0 -9/1 2/g' results/plink/*.fam


echo "PIPELINE COMPLETADO!"
```

USO DE DATOS EXPERIMENTALES EN EL TFM

Yo, Dra María Esther Cubo Delgado, con NIF__09181592S como persona que proporciona los datos a Don Daniel de Lara Pérez con NIF 71308977F, estudiante del Máster Bioinformática de la Universidad Internacional de Valencia, en el curso académico 2025-2026,

PONGO EN CONOCIMIENTO DE QUIEN LO REQUIERA QUE,

el mencionado alumno/a puede emplear con libertad los datos experimentales obtenidos en el grupo en el cual participo con el fin de elaborar su Trabajo Fin de Máster en la titulación y curso académico indicado anteriormente.

En _Burgos, a _09___ de ___Marzo_ de 2026___

Maria Esther Cubo Delgado

Firmado digitalmente por Maria Esther Cubo Delgado
Fecha: 2026.03.09 07:51:47 +01'00'

Firmado:
La persona que proporciona los datos al alumno