Caracterización genómica y funcional de una cepa nativa de *Ruminococcus* sp del consorcio Rumitec ® de Agrosavia: evidencia de una potencial nueva especie asociada a la degradación de celulosa en bovinos colombianos.

Titulación:
2026
Curso académico
2024 – 2026

Alumno/a: Isidro Miranda, Sylvana Alejandra
D.N.I: 1094269023

Director/a de TFM: Roxana Andreea Moldovan Moldovan

Convocatoria:

Primera

09 Marzo 2026

De:
Planeta Formación y Universidades

Agradecimientos

En primer lugar, agradezco a Dios, guía constante en cada etapa de este camino, quien me sostuvo en los momentos de incertidumbre y me permitió culminar este proceso con fortaleza y esperanza.

A mi madre, cuyo amor incondicional, apoyo y ejemplo han sido el pilar fundamental de mi vida. A ella dedico este logro con todo mi corazón.

Agradezco a Rocío Fenney Herrera León por su acompañamiento y apoyo durante el desarrollo de esta investigación. Asimismo, reconozco a los doctores Fernando Rodríguez y Hugo Rodolfo por su trayectoria y por la consolidación de la línea de investigación en microbiota ruminal en Agrosavia y Colombia, sobre la cual se sustenta este trabajo.

Extiendo mi gratitud a Andrés Moreno y a Ana Sofía Villa por su apoyo en distintos momentos del proceso.

Finalmente, agradezco al Ministerio de Agricultura y Desarrollo Rural (MADR) por el financiamiento brindado a través de los proyectos ejecutados en Agrosavia, que hicieron posible el desarrollo de esta investigación.

Universidad Internacional de Valencia

Índice

Indice de figuras 5
Resumen 7
3.1 Condiciones de cultivo de la cepa RF 12
3.2 Verificación de la identidad taxonómica por secuenciación del gen 16s rRNA. 14
3.3 Extracción y secuenciación del ADN genómico en plataformas de alto rendimiento . 15
3.4 Ensamblaje y anotación del genoma de la cepa RF. 17
3.4.1 Control de calidad de las secuencias. 17
3.4.2 Ensamblaje del genoma. 17
3.4.3 Clasificación taxonómica basada en genomas tipo TYGS/dDDH, ANI. 17
3.5 Identificación de genes asociados a la degradación de celulosa. 18
3.5.1 Análisis de la organización genómica de componentes celulosomales 20
3.6 Análisis comparativo de conservación proteica para la degradación de celulosa 21
3.6.1 Comparación de conservación proteica mediante BLASTp e integración de resultados de anotación funcional y análisis comparativo. 21
4.1 Crecimiento en cultivo sólido de RF. 22
4.2 Amplificación y secuenciación del gen 16s mediante la tecnología de sanger. 25
4.3 Determinación de calidad y secuenciación del ADN genómico de RF. 27
4.4 Ensamblaje y evaluación del genoma de la cepa RF 28
4.4.1 Ensamblaje del genoma. 28
4.4.2 Clasificación taxonómica basada en genomas tipo (TYGS/dDDH). 30
4.5 Identificación de genes asociados a la degradación de celulosa. 37
4.5.1 Análisis de la organización genómica de componentes celulosomales. 49
4.6 Análisis comparativo de conservación proteica para la degradación de celulosa. 52
4.6.1 Comparación de conservación proteica mediante BLASTp e integración de resultados de anotación funcional y análisis comparativo. 52
5. Conclusiones 53
6. Bibliografía 55
ANEXOS 60

Lista de abreviaturas

ADN Ácido Desoxirribonucleico

ANI Average Nucleotide Identity (identidad de nucleotidos promedio)

BON Blanco Orejinegro (Raza bovina criolla colombiana)

CAZy Carbohydrate-*Active enZYmes Database* (Base de datos de enzimas activas en carbohidratos)

CBM Carbohydrate-*Binding Module* (Módulo de unión a carbohidratos)

CDS Coding *DNA Sequence* (Secuencia codificante de proteínas)

dDDH *Digital DNA-DNA Hybridization* (Hibridación ADN-ADN digital)

DIN DNA *Integrity Number* (Número de integridad del ADN)

GH Glicósido Hidrolasa (también referido como Glicosilo Hidrolasa)

GT Glicosido Transferasas

GBDP *Genome BLAST Distance Phylogeny*

ICA Instituto Colombiano Agropecuario

Kbase *DOE Systems Biology Knowledgebase*

KEGG *Kyoto Encyclopedia of Genes and Genomes*

NCBI National Center for Biotechnology Information

NGS *Next-Generation Sequencing* (Secuenciación de nueva generación)

RAST *Rapid Annotation using Subsystem Technology*

RF Código de la cepa de estudio

rRNA Ácido Ribonucleico Ribosomal

SEM *Scanning Electron Microscopy* (Microscopía Electrónica de Barrido)

TYGS *Type Strain Genome Server*

Indice de tablas

Tabla 1: Programa de amplificación del para el gen 16S rRNA utilizando los primers 27F y 1492R. 15
Tabla 2: Comparación de métricas de calidad del ensamblaje genómico obtenido a partir de datos de secuenciación NovaSeq y MiSeq. 30
Tabla 3: Análisis comparativo entre el genoma de RF y los genomas de referencia conocidos.....31
Tabla 4: Múltiples entradas para tres códigos EC, implicadas en la degradación de celulosa por R. flavefaciens 39
Tabla 5: Glicosil hidrolasas de la familia GH5 anotadas mediante KBase–CAZy. 41
Tabla 6: Glicosil hidrolasas de la familia GH9 anotadas mediante KBase–CAZy. 42

Indice de figuras

Figura 1. Inventario de bovinos en Colombia por departamento 2025. Fuente ICA. Elaboración propia. 9
Figura 2. Sistema de incubación anaerobio diseñado para el crecimiento de RF en medio sólido GC. 14
Figura 3. Flujo de análisis bioinformático para la identificación de enzimas CAZy clave (GH5, GH9 y CBM) y dominios asociados. Elaboración propia. 20
Figura 4. Flujo de trabajo para la identificación y visualización de componentes celulosomales en RF. 21
Figura 5. Colonias de RF creciendo en medio GC después de 96 horas de incubación a 39°C bajo condiciones de atmósfera controlada. 23
Figura 6. Morfología y organización celular de la cepa RF observada por SEM. 24
Figura 7. Tubo Hungate con papel filtro como única fuente de carbono. 24
Figura 8. Gel de agarosa al 1,5 % con el fragmento 16s rRNA, ...25
Figura 9. Electroferograma obtenido después de la secuenciación por Sanger del gen 16S rRNA de la cepa RF. 25
Figura 10. Resultado del alineamiento BLASTn. 26
Figura 11. Dendograma de similitud de secuencia (BLAST Tree View). 27
Figura 12. Comparativa de métricas de calidad entre plataformas de secuenciación para un mismo genoma. 28
Figura 13. Control de calidad de las secuencias tras el procesamiento con fastp. 29
Figura 14. Árbol filogenético basado en distancias de genoma a genoma (dDDH) generado con TYGS. 33
Figura 15. Árbol filogenético basado en distancias evolutivas a nivel de proteoma a proteoma generado con el servidor TYGS. 34
Figura 16. Comparación de Average Nucleotide Identity (ANI) entre el genoma RF y genomas de referencia relacionados. 36
Figura 17. Distribución funcional de los genes anotados con RAST en la cepa RF. ...37
Figura 18. Distribución funcional de genes anotados mediante KEGG GhostKOALA en la cepa RF. 38
Figura 19. Ruta metabólica de almidón y sacarosa generada en KEGG GhostKOALA (enero 2025) a partir del ensamblaje de la cepa RF. 38
Figura 20. Distribuciónde Familias de Glicosil Hidrolasas (GH) en el Genoma de *Ruminococcus flavefaciens*, anotado con CAZy. 41
Figura 21. Predicción de péptidos señal en proteínas con dominios dockerina, según el análisis realizado con SignalP. 45
Figura 22. Abundancia porcentual de familias CAZy asociadas a celulosomas en el genoma de la cepa RF. 46
Figura 23. Distribución porcentual de dominios CBM implicados en la degradación de celulosa. 47
Figura 24. Distribución genómica de genes GH5 y dockerinas en el genoma de la cepa RF. 48
Figura 25. Organización genómica del scaffoldin celulosomal putativo en la cepa RF. 49

Figura 26. Co-localización de celulasas y dominios dockerina en la cepa RF. 50
Figura 27. Organización a nivel de contig de los componentes celulosomales putativos en la cepa RF. 51
Figura 28. Comparación del perfil de conservación funcional celulolítica entre seis genomas de *Ruminococcus flavefaciens*.....52

Resumen

El rumen bovino constituye un ecosistema microbiano altamente especializado, esencial para la degradación de la biomasa vegetal y el aprovechamiento de dietas ricas en fibra. En sistemas ganaderos tropicales de Colombia la eficiencia digestiva depende en gran medida de bacterias celulolíticas adaptadas a forrajes locales.

En este estudio se evaluó el potencial genómico y funcional de la cepa RF (*Ruminococcus* sp.), perteneciente al consorcio probiótico Rumitec® (Agrosavia), con el fin de identificar genes asociados a la degradación de celulosa y evaluar su posible estatus como nueva especie. La cepa mostró crecimiento bajo condiciones estrictas de anaerobiosis y elevada actividad celulolítica. El análisis del gen 16S rRNA confirmó su pertenencia al género *Ruminococcus*, con alta similitud a *R. flavefaciens*; sin embargo, los análisis genómicos comparativos (dDDH, ANI y filogenómica) indicaron que RF corresponde a un linaje genéticamente diferenciado. La anotación del genoma reveló un repertorio enzimático enriquecido en glicosil hidrolasas (GH5 y GH9), módulos de unión a carbohidratos (CBM) y dominios dockerina y cohesina, incluida la identificación de una proteína tipo scaffoldin, componente central en la organización de sistemas celulosómicos.

En conjunto, la cepa RF exhibe una arquitectura celulosomal especializada y un perfil genómico distintivo dentro del género *Ruminococcus*. Los análisis funcionales y comparativos respaldan su elevada capacidad celulolítica y sugieren que corresponde a un linaje taxonómicamente diferenciado, compatible con una potencial nueva especie con relevancia biotecnológica para sistemas ganaderos tropicales.

Palabras clave: RF, *Ruminococcus* sp., Rumitec®, microbiota ruminal, degradación de celulosa, celulosoma, GH5, GH9, CBM.

1.Introducción

En Colombia, la ganadería bovina ocupa un papel central dentro del sector agropecuario, con cerca de 38 millones de hectáreas destinadas a pasturas, lo que representa aproximadamente el 80 % del área agropecuaria nacional (1). El país cuenta con alrededor de 28 millones de cabezas de ganado, distribuidas principalmente en sistemas de doble propósito, especializados en carne o en leche, donde predominan los sistemas extensivos basados en pastoreo, aunque cada vez es más frecuente la suplementación con forrajes conservados y concentrados para mejorar la productividad (1,2).

Dentro de este contexto productivo, las razas criollas colombianas desempeñan un papel fundamental debido a su adaptación a condiciones tropicales, eficiencia reproductiva y rusticidad. Entre las más representativas se encuentran el Blanco Orejinegro (BON), el Hartón del Valle, el Costeño con Cuernos, el Chino Santandereano, el Romosinuano y el Sanmartinero, así como la raza Lucerna, desarrollada en el Valle del Cauca a partir del cruce entre ganado criollo y razas europeas, la cual combina aptitud cárnica y lechera con alta adaptación ambiental (3,4). Precisamente, la cepa de *Ruminococcus* sp. (RF) objeto de este estudio fue aislada de un ejemplar de raza Lucerna, lo que refuerza la relación entre la diversidad genética bovina nacional y la microbiota ruminal asociada.

La distribución del inventario bovino en Colombia es heterogénea y refleja la diversidad de sistemas productivos, condiciones agroecológicas y prácticas de manejo regionales. Los mayores inventarios se concentran en las regiones Caribe, Andina y Orinoquía, zonas históricamente estratégicas para la producción de carne y leche. Esta configuración territorial condiciona la oferta forrajera, el tipo de dieta y, en consecuencia, la estructura y funcionalidad de la microbiota ruminal. El inventario departamental presentado fue elaborado con base en información oficial del Instituto Colombiano Agropecuario (ICA) correspondiente al año 2025 (5).

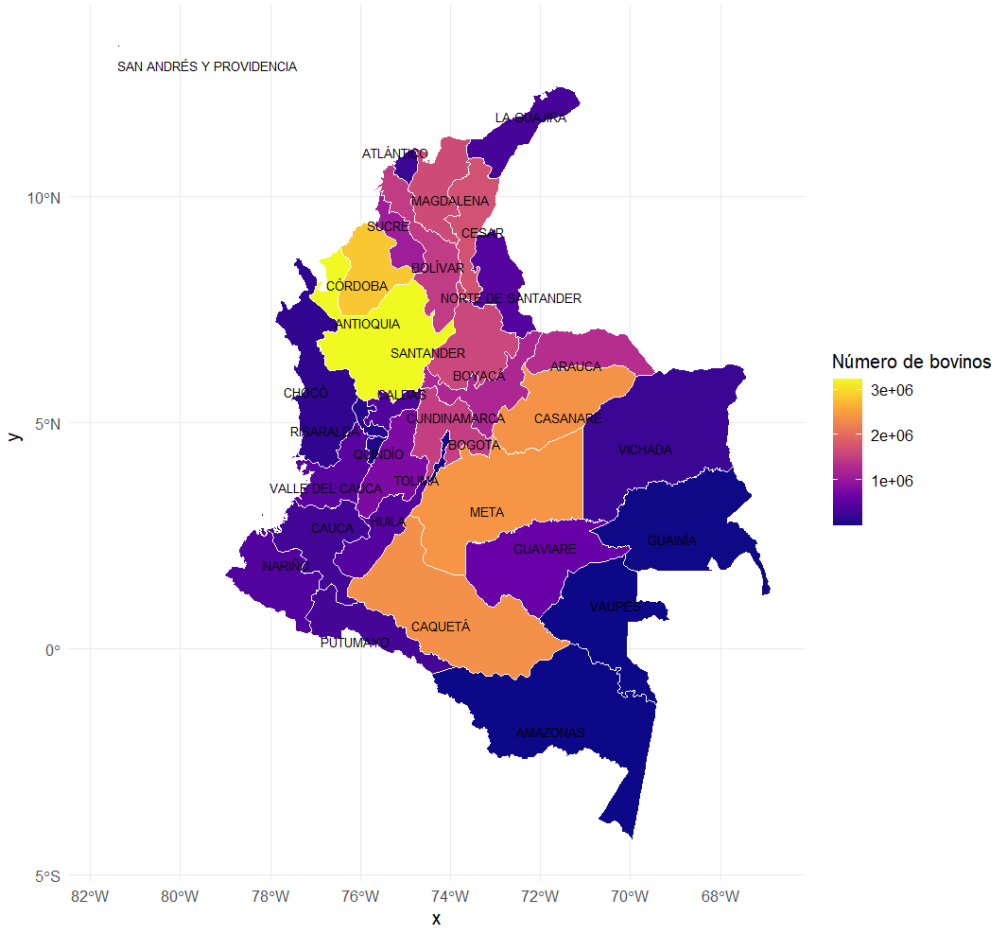

Figura 1. Inventario de bovinos en Colombia por departamento 2025. Fuente ICA. Elaboración propia.

El rumen bovino constituye un ecosistema microbiano complejo y altamente especializado, esencial para la degradación de polisacáridos estructurales de la biomasa vegetal y la obtención de energía a partir de dietas ricas en fibra. Este ecosistema alberga comunidades de bacterias, arqueas metanogénicas, hongos anaerobios, protozoos ciliados y, en menor proporción, virus bacteriófagos, los cuales desempeñan un papel regulador sobre la dinámica poblacional microbiana y el flujo de genes funcionales dentro del rumen (6–9).

Diversos estudios han demostrado que factores como la dieta, la raza bovina y el entorno productivo influyen de manera directa sobre la composición, diversidad y funcionalidad de la microbiota ruminal. En dietas basadas predominantemente en forrajes fibrosos, como las empleadas en sistemas tropicales, se favorece la abundancia de bacterias con capacidad celulolítica, responsables de la degradación de la celulosa y hemicelulosa presentes en las paredes celulares vegetales (6–8). Dentro de este grupo funcional, el género *Ruminococcus* ha

sido históricamente reconocido como uno de los principales actores en la degradación de la celulosa en el rumen bovino. Las especies de este género poseen rutas metabólicas altamente especializadas que permiten la hidrólisis de los enlaces β-1,4-glucosídicos mediante complejos multienzimáticos denominados celulosomas, los cuales están conformados por glicósido hidrolasas (GH), módulos de unión a carbohidratos (CBM) y proteínas estructurales tipo scaffoldin, organizadas a través de interacciones cohesina–dockerina (10–12).

A pesar de su importancia, los estudios sobre la diversidad y función de *Ruminococcus* sp. en el rumen experimentaron una notable disminución a partir de finales de la década de 1990, limitando el conocimiento actualizado sobre nuevas especies y su potencial biotecnológico. Esta falta de información resulta particularmente crítica en contextos tropicales, donde las condiciones de pH, temperatura y disponibilidad de forrajes difieren de los ambientes templados que tradicionalmente han sido más estudiados (13,14).

En este marco, el consorcio microbiano Rumitec®, desarrollado y patentado por Agrosavia–Corporación Colombiana de Investigación Agropecuaria, representa una estrategia innovadora orientada al aprovechamiento funcional de la microbiota ruminal para mejorar la eficiencia digestiva en sistemas ganaderos. La suplementación con consorcios microbianos funcionales favorece la maduración ruminal al estimular la fermentación de carbohidratos estructurales y la producción de ácidos grasos volátiles, particularmente butirato, metabolito clave para el desarrollo del epitelio ruminal y la transición temprana hacia dietas sólidas (15).

Adicionalmente el uso de probióticos en terneros se ha asociado con un incremento en la ganancia media diaria y la eficiencia alimentaria, así como con una reducción significativa en la incidencia y severidad de diarreas neonatales. Estos efectos se atribuyena la estabilización de la microbiota gastrointestinal, la exclusión competitiva de microorganismos patógenos y el fortalecimiento de la respuesta inmunitaria del hospedador (16,17).

El consorcio del Rumitec® está conformado por microorganismos ruminales seleccionados, entre los cuales se encuentra la cepa RF, perteneciente al género *Ruminococcus* sp. y objeto del presente estudio.

La cepa RF corresponde a un microorganismo ruminal aislado en Colombia, previamente identificado por su potencial celulolítico y por características fisiológicas que sugieren una alta

especialización en la degradación de polisacáridos estructurales. No obstante, la información disponible sobre su arquitectura genómica, organización funcional y relaciones filogenéticas dentro del género *Ruminococcus* no ha sido explorada aun, lo que plantea la necesidad de un análisis detallado desde un enfoque genómico y bioinformático.

En este contexto, el presente estudio se orienta a caracterizar el potencial genómico y funcional de la cepa RF, con el fin de profundizar en los mecanismos moleculares asociados a la degradación de celulosa y evaluar su posible estatus taxonómico dentro del género *Ruminococcus*. Este análisis busca fortalecer la base científica que sustenta el desarrollo y uso del consorcio Rumitec®, así como explorar el potencial biotecnológico de microorganismos ruminales nativos adaptados a sistemas ganaderos tropicales.

2. Objetivos

El objetivo principal del presente trabajo es el análisis del potencial genómico y funcional de una cepa de *Ruminococcus* sp perteneciente al consorcio Rumitec ® de Agrosavia, mediante la identificación de genes asociados a la degradación de celulosa y su comparación con genomas de referencia, con el fin de aportar evidencia sobre su posible clasificación como nueva especie. Para ello se plantean los siguientes objetivos específicos:

- Establecer las condiciones de cultivo idóneas para el crecimiento en medio sólido y anaerobio de la cepa RF de *Ruminococcus* sp, perteneciente al consorcio del probiótico Rumitec®.

- Determinar la identidad taxonómica de la cepa RF mediante la amplificación del gen 16S rRNA con los cebadores 27F y 1492R, y su secuenciación con la metodología de Sanger.

- Extraer ADN genómico de alta calidad de la cepa RF para su secuenciación con las plataformas de lecturas cortas (MiSeq y NovaSeq de Illumina).

- Ensamblar y anotar el genoma de RF para su análisis genómico y funcional.

- Identificar y caracterizar los genes asociados a la degradación de celulosa presentes en el genoma de RF.

- Comparar el genoma de RF con genomas de referencia de *Ruminococcus* sp. para establecer su relación filogenética y determinar su potencial como nueva especie.

3. Metodología

3.1 Condiciones de cultivo de la cepa RF.

La preparación de los medios de cultivo se realizó siguiendo el manual de laboratorio para estudios de microorganismos anaerobios obligados de Corpoica y CBB (18), así como la guía de medios de cultivo para el crecimiento de bacterias anaerobias ruminales. Inicialmente se prepararon medios de cultivo líquidos en frascos schott con fuentes de carbono glucosa-celobiosa (GC) al 1% cada una y otro con trozos de papel filtro cortados (4 cm de largo x 1 cm de ancho) como fuente principal de carbono; la consideración más relevante a la hora de trabajar estos medios anaerobios fue la utilización de CO_2 para la gasificación de los medios ya, que esto bloquea la entrada de oxígeno al medio, a su vez el uso de resarzurina (Sigma-Aldrich, EE. UU.) como indicador redox y HCl-cisteína (Sigma-Aldrich, EE. UU.), como agente reductor, ambos al 0,1 %.

La gasificación con CO_2 se hizo durante el proceso de preparación por 15 minutos, posteriormente se sirvieron 10 mL de medio ya reducido y gasificado en tubos hungate (con tapón y tapa rosca), se autoclavaron a 121 °C durante 15 minutos manteniendo una presión elevada de 15 ps.

Para los medios sólidos se utilizaron las mismas proporciones con la adición de agar base para bacterias anaerobias (Sigma-Aldrich, EE. UU.). Una vez reducidos los medios fueron tapados con cierre hermético y autoclavados bajo las mismas condiciones. Pasado el tiempo de esterilización, los tubos se invirtieron tres veces para verificar la ausencia de oxígeno (ausencia de viraje de color a rosado). En el caso de los medios sólidos, se vertieron en cajas de petri de

100 mm de diámetro por 25 mm de alto, las cuales fueron selladas con vinipel y almacenadas bajo refrigeración.

La cepa RF se tomó de crioviales conservados en medio de conservación con glicerol al 15% gasificado con CO_2 y almacenados a -80°C, se dejó 5 minutos en baño maría a 37°C y se reactivó en cabina de flujo laminar en medio liquido GC (previamente preparado), incubándose a 39 °C durante 24 horas. Pasado el tiempo de incubación se observaron láminas en el microscopio de fluorescencia Nikon Eclipse modelo E600 (Nikon, Japon), en el módulo de contraste de fases.

Adicionalmente, las células fueron fijadas (incluyendo pasos de deshidratación, secado de punto crítico) con glutaraldehído de acuerdo con el manual de laboratorio para estudios de microorganismos anaerobios obligados de Corpoica y el CBB (18), Las muestras fijadas se enviaron a la Universidad de los Andes para su análisis mediante microscopía electrónica de barrido (SEM) para la obtención de imágenes de alta resolución de la topografía superficial de las células.

A continuación, se realizó un pase de 1 mL a medio con papel filtro como única fuente de carbono, este fue incubado a las mismas condiciones mencionadas. Pasado el tiempo de incubación se sembró en superficie en medio sólido (glucosa y celobiosa al 1 %) dentro de una cámara de anaerobiosis Coy Chamber (Coy Laboratory Products, EE. UU.), que garantiza una atmósfera estrictamente libre de oxígeno con control de CO_2 y humedad.

Posteriormente, las cajas se introdujeron en bolsas herméticas previamente gasificadas con CO_2, que fueron selladas e infladas con un sobre generador de atmósfera anaerobia GasPak™ EZ (BD BBL, EE. UU) en su interior. Estas bolsas selladas se colocaron dentro de recipientes herméticos para sistemas GasPak (BD, EE. UU.), los cuales también fueron gasificados con CO_2 y equipados con una fuente interna de humedad y tiras indicadoras de anaerobiosis, asegurando así una atmósfera estricta y estable. Finalmente, los recipientes fueron incubados a 39 °C, condiciones bajo las cuales se obtuvo el crecimiento en medio sólido de la cepa RF. (Figura 2).

Figura 2. Sistema de incubación anaerobio diseñado para el crecimiento de RF en medio sólido GC.

Para confirmar nuevamente la degradación de celulosa, se realizó un repique de las colonias en medio liquido con papel filtro, pasado el tiempo de incubación se realizó la precipitación de células a 10.000 rpm durante 15 minutos, se descartó el sobrenadante, se lavaron 3 veces las células con PBS al 1X y se almacenaron en un tubo eppendorf de 1,5 mL a -20°C (pellet de células).

3.2 Verificación de la identidad taxonómica por secuenciación del gen 16s rRNA.

Se procedió con la extracción de ADN del pellet almacenado en el anterior paso utilizando el kit KIT ZR Fungi/Bacterial DNA (Zymo Research, EE.UU.). La concentración de ADN se midió por espectrofotometría con el equipo NanoDrop™ 2000/ 2000c (Thermoscientific, EE.UU.).

Para la amplificación del en 16S rRNA, se utilizó el Quick-Load® *Taq* 2X Master Mix (New England Biolabs, EE. UU.) y los primers universales 27F 5′-AGA GTT TGA TCC TGG CTC AG-3′ y 1492R 5′-GGT TAC CTT GTT ACG ACT T-3, previamente descritos por Weisburg et al. (19) y Lane (20). El ADN inicial se diluyó 1/10 y esta alícuota fue utilizada como *target* para la PCR y los cálculos para la *master mix* fueron los recomendados por el fabricante de la taq (new england biolabs). El protocolo en el termociclador SimpliAmp™ (Applied Biosystems, Thermo

Fisher Scientific, EE. UU.) fue programado como una PCR con dos fases de alineamiento (Tabla 1).

Tabla 1: Programa de amplificación del para el gen 16S rRNA utilizando los primers 27F y 1492R.

Paso	Temperatura (°C)	Duración (s)
Desnaturalización inicial	95	30
10 ciclos:	95	15
	46	30
	68	45
20 ciclos:	95	15
	56	30
	68	45
Extensión final	68	5
Incubación	12	∞

Una vez terminada la PCR se evaluaron los productos en un gel de agarosa al 1,5%, mediante electroforesis horizontal, utilizando Syber Safe (Thermo Fisher Scientific, EE. UU.) como agente intercalante de ADN. El gel fue revelado en el sistema de fotodocumentación Gel Doc™ XR+ (Bio-Rad, EE. UU.) y el producto amplificado fue enviado para su secuenciación por Sanger, utilizando el primer 1391R 5'-ACGGGCGGTGWGTRCA-3' (21) en el Laboratorio de Genética Molecular (Agrosavia, Colombia).

3.3 Extracción y secuenciación del ADN genómico en plataformas de alto rendimiento.

Considerando el filtro utilizado para la verificación de la pureza e identidad de la cepa RF en el apartado anterior, se procedió a la extracción de ADN de alta calidad a partir de un cultivo fresco

previamente crecido en medio GC. Se realizó la precipitación de células bajo las mismas condiciones de centrifugación y lavado mencionadas anteriormente. Se empleó el kit PureLink™ Genomic DNA Mini Kit de la casa comercial Invitrogen de EE. UU., Para la extracción del ácido nucleico, siguiendo las recomendaciones del fabricante para bacterias gram positivas.

La concentración y pureza del ADN se evaluaron con el equipo NanoDrop™ 2000 (Thermo Fisher Scientific, EE. UU.), y la cuantificación por fluorometría se llevó a cabo con el kit Qubit™ dsDNA BR Assay Kit (Thermo Fisher Scientific, EE. UU.) en el sistema Qubit™ (Thermo Fisher Scientific, EE. UU.). Finalmente, la integridad del ADN (DIN) fue verificada mediante el equipo TapeStation 4200 (Agilent Technologies, Alemania) con el kit Genomic DNA ScreenTape Assay (Agilent Technologies, Alemania).

Se procedió con el proceso de construcción de librerías mediante el kit NEBNext® Ultra™ II FS DNA Library Prep with Sample Purification Beads (New England Biolabs, EE. UU.), seleccionando fragmentos de 350–400 pb.

La concentración y calidad de la librería se evaluó con el equipo Qubit™ (Thermo Fisher Scientific, EE. UU.) utilizando el kit Qubit™ dsDNA HS Assay Kit (Thermo Fisher Scientific, EE. UU.), la verificación de los fragmentos ya seleccionados se realizó con el equipo TapeStation 4200 (Agilent Technologies, Alemania) y el kit High Sensitivity D1000 ScreenTape Assay (Agilent Technologies, Alemania).

Posteriormente, el genoma se secuenció en dos plataformas Illumina MiSeq™ (Illumina, San Diego, EE. UU.) con lecturas de 150 pb, siguiendo protocolos estandarizados y validados en Agrosavia en el marco del proyecto GHRU-AMR (Global Health Research Unit–Antimicrobial Resistance). La secuenciación adicional se llevó a cabo en la plataforma Illumina NovaSeq™ (Illumina, EE. UU.) con lecturas de 250 pb para aumentar la profundidad y complementar el ensamblaje genómico; la librería fue procesada en Azenta Life Sciences (EE. UU.).

3.4 Ensamblaje y anotación del genoma de la cepa RF.

3.4.1 Control de calidad de las secuencias.

Los datos crudos obtenidos mediante secuenciación de nueva generación (NGS) fueron sometidos a un control de calidad inicial empleando FastQC (v0.11.9) (22) y MultiQC (v1.13) (23) para su posterior visualización conjunta. Con el fin de comparar las dos tecnologías de secuenciación, NovaSeqX (Library65 R1 y R2) y MiSeq (RF_S25 R1 y R2), correspondientes al mismo genoma.

Posteriormente, se realizó una limpieza de las lecturas con fastp (v0.23.2) (24), eliminando adaptadores, secuencias sobrerrepresentadas, poli_G y poli_X, aplicando un umbral mínimo de longitud de 151 pb y una calidad media, inicial y final de Q25 para ambas plataformas. Finalmente, se repitió el análisis con FastQC (v0.11.9) (22) y la integración de reportes con MultiQC (v1.13) (23), para evaluar la calidad post-filtrado.

3.4.2 Ensamblaje del genoma.

Se llevó a cabo el ensamblaje *de novo* utilizando la herramienta SPAdes (v3.15.5) (25), diseñada específicamente para este tipo de análisis. Una vez obtenido el ensamblaje, se evaluó su calidad considerando los contigs y scaffolds generados, así como las lecturas limpiadas con Fastp. Para ello, se utilizó el programa QUAST (v5.2.0) (26).

Por otro lado, se evaluó el ensamblaje de novo empelando las herramientas BWA (v0.7.17) (27), Samtools (v1.15.1) (28) y Qualimap (v2.3) (29) mediante el mapeo de las lecturas frente a este ensamblaje (final_contigsNovSeq_RF.fasta) y la obtención de las estadísticas de calidad de mapeo.

3.4.3 Clasificación taxonómica basada en genomas tipo TYGS/dDDH, ANI.

Se emplearon servidores bioinformáticos como TYGS (del inglés Type Strain Genome Server) (2023 release) (30) para realizar en primera medida la identificación, comparación y clasificación

del genoma de estudio, así como determinar algunas relaciones filogenéticas con género y especie. La obtención de un reporte de análisis basado en la comparación del ensamblaje con otros genomas conocidos mediante dDDH (del inglés digital DNA-DNA hibridization) permitió establecer la relación taxonómica de la cepa en estudio con especies previamente descritas (31).

De manera complementaria, se calculó el ANI (del inglés Average Nucleotide Identity), entre el genoma RF y los genomas de referencia más cercanos identificados en el análisis filogenómico. El cálculo se realizó mediante el algoritmo OrthoANIu, el cual permite estimar la identidad nucleotídica promedio entre genomas completos a partir de fragmentos ortólogos conservado (32). Los valores obtenidos se interpretaron considerando el umbral de 95–96 % ANI propuesto para la delimitación de especies bacteriana, teniendo en cuenta además el porcentaje de cobertura del alineamiento para cada comparación genómica (33,34).

Con el fin de asegurar la transparencia y reproducibilidad de los análisis, el pipeline bioinformático completo, incluyendo la estructura metodológica y los scripts empleados, se encuentra documentado en el siguiente enlace: https://diligent-stretch-304.notion.site/Pipeline_RF-26f983d81fab80bba666fbf1f3cc85e1?pvs=141

3.5 Identificación de genes asociados a la degradación de celulosa.

El ensamblaje de la cepa RF se sometió a un proceso de identificación funcional empleando diferentes plataformas bioinformáticas con el fin de comparar la consistencia de los resultados.

En primera instancia, el genoma fue cargado en el servidor RAST (del inglés Rapid Annotation using Subsystem Technology) (35), seleccionando como taxón de referencia el identificador 1265.300, con el fin de proporcionar un punto de partida adecuado para la anotación automática. Esta configuración permitió que la herramienta identificara genes codificantes de proteínas (CDS) y los clasificara en subsistemas metabólicos, generando un panorama general de las funciones biológicas representadas en el genoma.

Posteriormente, las secuencias predichas de aminoácidos fueron procesadas en KEGG GhostKOALA (del inglés Kyoto Encyclopedia of Genes and Genomes) (36), lo cual facilitó la asignación de genes a rutas metabólicas conocidas. Esta anotación permitió la reconstrucción preliminar de rutas metabólicas involucradas en la degradación de carbohidratos y en la producción de energía.

De manera complementaria, se realizó la anotación en la plataforma KBase (del inglés DOE Systems Biology Knowledgebase) (v1.0) (37), utilizando la base de datos CAZy (del inglés Carbohydrate-Active enZYmes Database) para la identificación de genes relacionados con enzimas GH, glicosilo transferasas (GT) y otras enzimas implicadas en la degradación de carbohidratos estructurales.

Finalmente, el ensamblaje fue anotado con la herramienta Bakta (v1.x, base de datos v6.0) (38), ejecutada en un entorno Conda (v22.x) (39) y mediante un script en el sistema de colas SLURM (v23.x) (40). El análisis se realizó utilizando como entrada el archivo ensamblado en formato FASTA, lo que permitió la predicción de CDS, ARN ribosomales, ARN de transferencia y otros elementos genómicos. Bakta emplea un enfoque basado en reglas y nomenclatura estandarizada, en concordancia con las recomendaciones de GenBank/ENA/DDBJ, y se apoya en bases de datos actualizadas para mejorar la calidad de la anotación.

Adicionalmente, los archivos de proteínas predichas obtenidos tras la anotación con Bakta (RF_assembly.faa) fueron procesados en entorno local con dbCAN2 (v3.0.2) (41), ejecutado en un entorno Conda (v22.x) (39). Para este análisis se descargaron las bases de datos actualizadas de CAZy y se implementaron los módulos HMMER (v3.3) (42) y DIAMOND (v2.0) (43), lo que permitió la detección de CBM, módulos dockerina y GH implicadas en la degradación de la celulosa.

De manera complementaria, el archivo RF_assembly.faa generado por Bakta fue analizado en el servidor SignalP (v6.0, DTU Health Tech, Dinamarca) (44) para predecir la presencia de péptidos señal en proteínas candidatas a ser secretadas, prestando mayor atención en dockerinas, o en proteínas hipotéticas, que en el target de hmmer tuviesen relación con dockerina.

Los archivos de salida generados por dbCAN2 (diamond.tsv y hmmer.tsv) fueron analizados posteriormente en RStudio (v4.0.2) (45), empleando los paquetes tidyverse (v2.0.0) (46), stringr (v1.5.1) (47) y ggplot2 (v3.4.4) (48). El flujo de análisis que se tuvo en cuenta se muestra en la Figura 3.

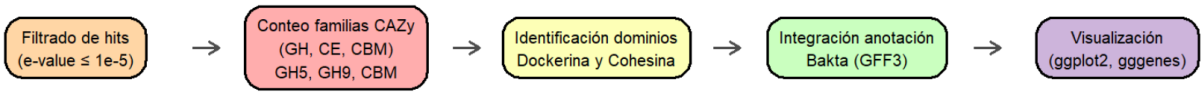

Figura 3. Flujo de análisis bioinformático para la identificación de enzimas CAZy clave (GH5, GH9 y CBM) y dominios asociados.
Elaboración propia.

3.5.1 Análisis de la organización genómica de componentes celulosomales

Para evaluar la organización genómica de los componentes asociados al celulosoma en la cepa RF, se combinó la visualización genómica manual con análisis bioinformático basado en el archivo de anotación funcional.

En primera instancia, el genoma ensamblado y anotado de la cepa RF fue visualizado mediante el software Artemis (v18.2.0) (49), utilizando los archivos FASTA y GFF3 generados por Bakta. Se inspeccionó la distribución de genes codificantes de dominios cohesina, dockerina y scaffoldin, así como los genes localizados corriente arriba y corriente abajo dentro de los mismos contigs.

Posteriormente, el archivo de anotación en formato GFF3 fue importado en RStudio (v4.0.2) (45), donde se realizó un filtrado de las anotaciones funcionales a partir de palabras clave asociadas a componentes celulosomales, incluyendo cohesin, dockerin, scaffoldin, putative cellulosomal y hypothetical protein. Las proteínas seleccionadas fueron organizadas por contig y ordenadas según su posición genómica (Figura 4).

Finalmente, se generaron representaciones gráficas de la organización genómica de estos elementos mediante RStudio (v4.0.2) (45), se visualizó la distribución y co-localización de los componentes celulosomales y proteínas hipotéticas dentro del genoma de la cepa RF.

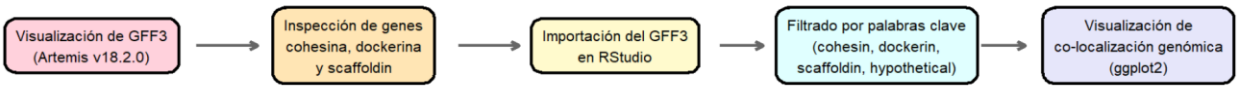

Figura 4. Flujo de trabajo para la identificación y visualización de componentes celulosomales en RF.
Elaboración propia

3.6 Análisis comparativo de conservación proteica para la degradación de celulosa

3.6.1 Comparación de conservación proteica mediante BLASTp e integración de resultados de anotación funcional y análisis comparativo.

Se realizó un análisis comparativo a nivel de secuencia proteica entre el genoma de estudio y cepas de referencia de *Ruminococcus flavefaciens*. Se seleccionaron las cepas FD-1, 17, ATCC 19208, Y1, YL228 y YAD2003, cuyos archivos proteicos anotados (.faa) fueron descargados desde la base de datos del NCBI (del inglés National Center for Biotechnology Information).

Los análisis de similitud se llevaron a cabo utilizando la herramienta BLASTp, ejecutada en el entorno Google Colab, empleando los archivos proteicos del genoma de estudio (RF) como secuencias consulta y las proteínas de cada cepa de referencia como bases de datos independientes. Los alineamientos se realizaron con un valor de corte de E-value ≤ 1e-5, generando archivos de salida en formato tabular (outfmt 6), que contienen información sobre el porcentaje de identidad, longitud del alineamiento y significancia estadística de cada hit.

Posteriormente, los archivos de salida generados por BLASTp (2.12.0+) (50) fueron procesados en el entorno RStudio (v4.0.2) (45). Para cada proteína del genoma de estudio, se seleccionó únicamente el mejor hit por cepa de referencia, es decir, el mayor porcentaje de identidad, con el fin de evitar redundancias y garantizar una comparación uniforme.

De manera paralela, se construyó una lista unificada de genes de interés del genoma de estudio, integrando los resultados de las anotaciones funcionales obtenidas mediante DIAMOND y HMMER. Esta lista incluyó exclusivamente proteínas asociadas a la degradación de celulosa y

a la arquitectura del celulosoma, específicamente aquellas pertenecientes a las familias GH5 y GH9, dominios de unión a carbohidratos (CBM), así como dominios dockerina y cohesina (Anexo 1).

Los resultados de BLASTp fueron cruzados con esta lista de genes de interés, permitiendo clasificar cada proteína según su grado de conservación en las cepas de referencia, de acuerdo con el porcentaje de identidad obtenido. Los niveles de conservación fueron categorizados como alta, media, baja o sin homólogo detectable (Anexo 1).

Finalmente, se calcularon las proporciones relativas de cada categoría de conservación por familia funcional y por cepa de referencia. Estos valores fueron representados gráficamente mediante diagramas de barras apiladas normalizadas, permitiendo una visualización comparativa del perfil de conservación proteica celulosómica entre las diferentes cepas analizadas.

4. Resultados y discusión.

4.1 Crecimiento en cultivo sólido de RF.

Inicialmente se observó turbidez en el tubo con medio GC así como cocos en duplas, lo que confirmó la pureza y viabilidad del microorganismo. En el tubo con papel filtro (única fuente de carbono) se evidenció la degradación del papel al haber transcurrido 12 horas, reflejando su actividad celulolítica.

Tras 96 horas de incubación en medio sólido (cajas petri con agar glucosa-celobiosa al 1 %), se logró por primera vez el crecimiento exitoso de la cepa RF, observándose colonias blancas, grandes y cremosas (Figura 5). Este resultado es especialmente relevante ya que fue posible establecer las condiciones idóneas de atmosfera controlada que permitieron su desarrollo en cultivo sólido sobre cajas de Petri.

Cabe resaltar que este comportamiento difiere de lo descrito en la literatura para otras especies del género *Ruminococcus* sp., como *R. albus* y *R. flavefaciens*, en las que se ha reportado crecimiento en medios sólidos como agar BHI suplementado con CMC bajo condiciones de anaerobiosis convencionales, con formación de halos de degradación de celulosa (51).

Asimismo, otros trabajos han documentado el crecimiento de especies de este género en agar mediante la técnica de roll tube (11,52,53). En contraste, la cepa RF mostró un fenotipo colonial más exigente, que requirió condiciones estrictas de CO_2 y humedad controlada para proliferar en cajas de petri, presentando colonias blancas y cremosas, distintas a las amarillentas descritas en otros reportes.

Figura 5. Colonias de RF creciendo en medio GC después de 96 horas de incubación a 39°C bajo condiciones de atmósfera controlada.

Por otra parte, las micrografías obtenidas mediante SEM, utilizando un microscopio Tescan Lyra 3 (TESCAN, República Checa), permitieron caracterizar la morfología celular de la cepa RF. En las imágenes se observaron células bacterianas de morfología cocoide, con diámetros aproximados entre 0.8 y 1.2 µm, dispuestas principalmente en pares (diplococos) y en pequeños agregados celulares (Figura 6A–C).

Las células presentaron una superficie celular rugosa y homogénea, rasgo característico de bacterias Gram positivas, sin evidencia de estructuras filamentosas externas, como flagelos o pili, ni signos visibles de daño celular o lisis. La organización celular observada sugiere un estado fisiológico activo, con adecuada integridad estructural bajo las condiciones de cultivo evaluadas.

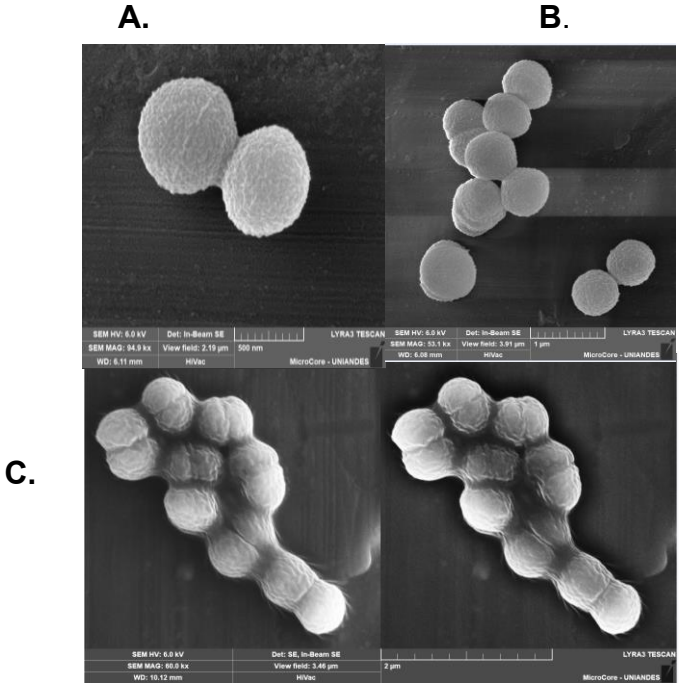

Figura 6. Morfología y organización celular de la cepa RF observada por SEM.

A. Células cocoides dispuestas en pares (diplococos). **B.** Organización celular en pequeños agregados. **C.** Formación de agregados celulares más complejos, evidenciando una estrecha interacción célula–célula. Las condiciones instrumentales específicas (voltaje de aceleración, aumento y barra de escala) se indican en cada micrografía.

Después de la selección de una colonia y su reinoculación en un tubo con papel filtro, se observó nuevamente la degradación efectiva del sustrato reafirmando su capacidad celulolítica (Figura 7).

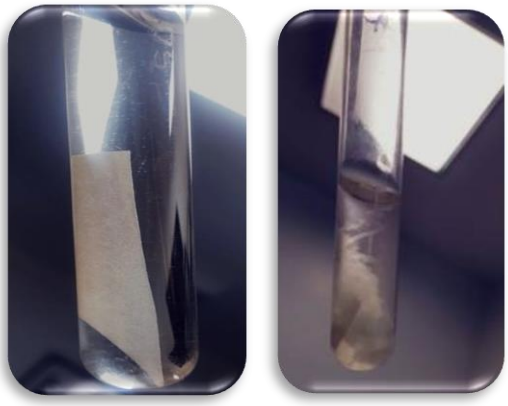

Figura 7. Tubo Hungate con papel filtro como única fuente de carbono.
Izquierda: medio sin inocular; derecha: medio inoculado con RF después de 12 horas de incubación a 39°C.

4.2 Amplificación y secuenciación del gen 16s mediante la tecnología de sanger.

El ADN extraído presentó valores de concentración de 70 ng/uL y ratios de calidad 260/280 de 1,8 y 260/230 de 2,2, los cuales estuvieron dentro de los rangos establecidos por los protocolos de Agrosavia; la amplificación del gen 16s rRNA fue exitosa y se obtuvo un fragmento de 1600 pb (Figura 8).

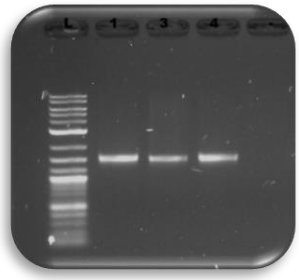

Figura 8. Gel de agarosa al 1,5 % con el fragmento 16s rRNA, amplificado para la cepa RF con los primer 27F y 1492R. L: Ladder 1 kb; muestras 1, 3 y 4: amplicones del gen 16s de RF (por triplicado).

El electroferograma obtenido después de secuenciar el fragmento con el primer 1391-R, presentó una única asignación de nucleótidos para cada posición, confirmando la pureza de la cepa RF (Figura 9).

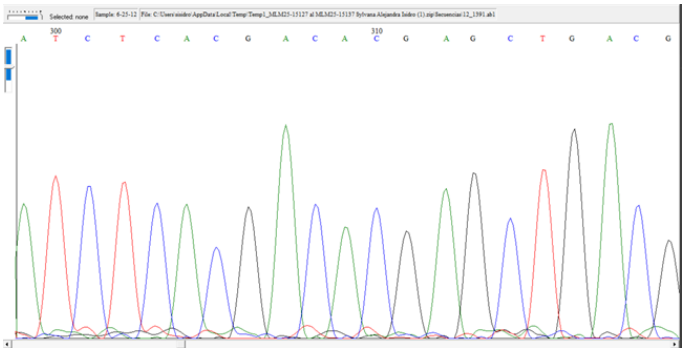

Figura 9. Electroferograma obtenido después de la secuenciación por Sanger del gen 16S rRNA de la cepa RF.

La secuencia obtenida fue analizada mediante BLASTn en la base de datos NCBI, mostrando una identidad del 99 (580 de 583 nucleótidos comparados). No se observaron inserciones ni deleciones (0% de gaps) y presentó una cobertura completa del fragmento alineado. El mayor nivel de similitud se observó con *Ruminococcus flavefaciens* strain FD1 (GenBank: AY445597.1), lo que confirma de forma la identidad taxonómica de la cepa, a nivel de género y posible especie, basada en la secuencia de su gen ribosomal. Esta primera aproximación proporciona un filtro clave para la subsecuente secuenciación y conformación taxonómica mediante NGS (Figura 10).

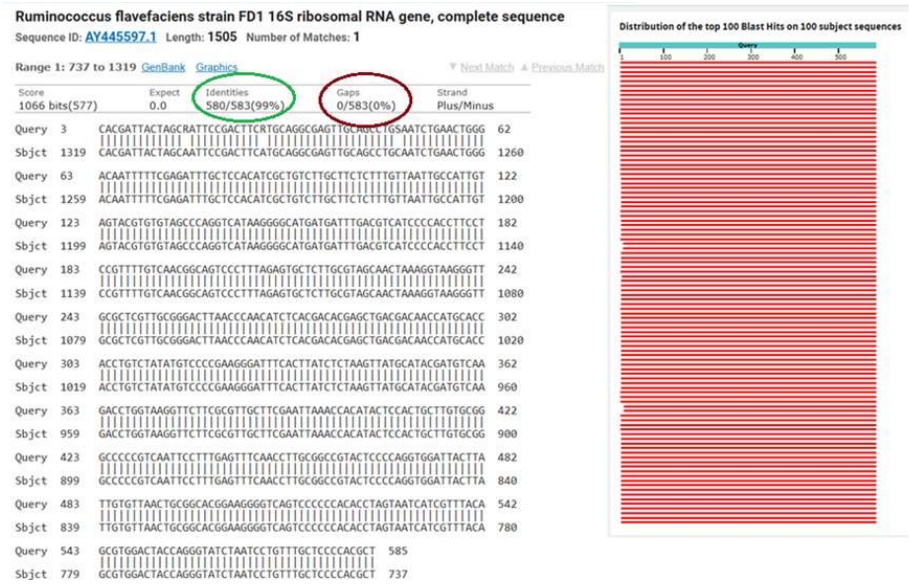

Figura 10. Resultado del alineamiento BLASTn.

Secuencia del gen 16S rRNA de la cepa RF con Ruminococcus flavefaciens strain FD1 (AY445597.1) mostrando un 99 % de identidad y un 0 % de gaps

Por otra parte, basado en la secuencia obtenida se analizó el árbol generado por NCBI BLAST Tree View, el cual es un árbol de vecinos más cercanos (*Neighbor-Joining*) generado a partir del alineamiento BLAST con los 100 organismos más similares a la secuencia 16S rRNA de RF (Figura 11).

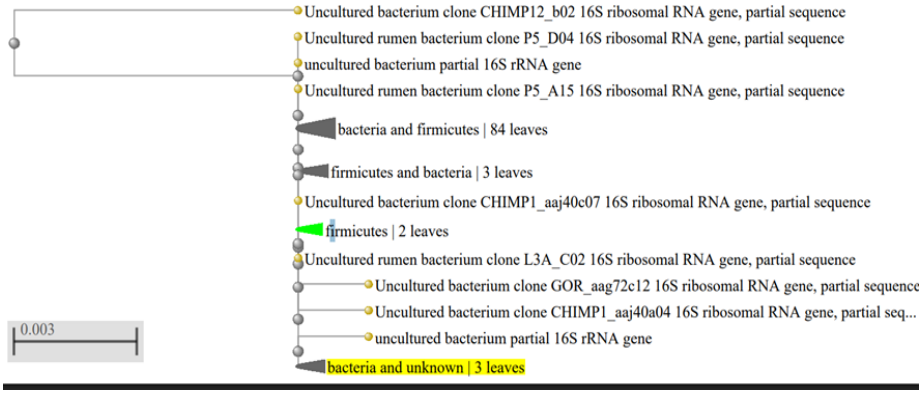

Figura 11. Dendograma de similitud de secuencia (BLAST Tree View). Se muestra la posición de la cepa RF en relación con *Ruminococcus flavefaciens* FD1 y otras bacterias del mismo phylum. Los puntos grises representan los nodos de ramificación o unión filogenética entre especies o aislados; los puntos amarillos representan una secuencia individual, por ejemplo:Uncultured bacterium clone L3A_C02; los triángulos (colapsados) representan los clados grandes comprimidos por claridad visual; el triángulo verde (firmicutes | 2 leaves): permitió observar donde probablemente cae RF, dado que esta cepa pertenece al phylum Firmicutes, finalmente la etiqueta amarilla ("bacteria and unknown | 3 leaves") representan a las secuencias similares pero que no tienen identificación clara aún.

4.3 Determinación de calidad y secuenciación del ADN genómico de RF.

Una vez verificada la pureza del cultivo, la extracción de ADN genómico presentó ratios de 1,8 (260/280) y 2,0 (260/230), con una concentración de 76 ng/µL determinada por fluorometría (Qubit). El DIN fue de 8,3, confirmando la alta calidad del material genómico. La construcción de la librería generó un fragmento con un tamaño de 380 pb. La cuantificación por Qubit arrojó una concentración de 25 ng/µL, y el análisis con TapeStation corroboró la ausencia de adaptadores residuales o exceso de ADN.

El control de calidad de las lecturas crudas mediante FastQC evidenció perfiles adecuados para ambas plataformas de secuenciación. La integración de resultados en MultiQC permitió la comparación entre las tecnologías NovaSeq (Library65 R1 y R2) y MiSeq (RF_S25 R1 y R2) para el mismo genoma (Figura 12).

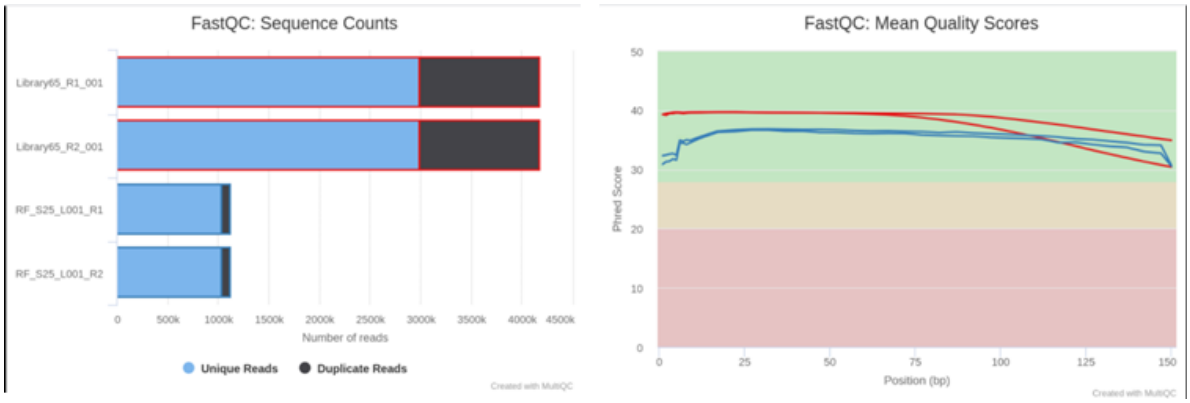

Figura 12. Comparativa de métricas de calidad entre plataformas de secuenciación para un mismo genoma.
El panel izquierdo muestra el recuento de secuencias, destacando la mayor profundidad de NovaSeqX (Library65) frente a MiSeq (RF_S25). El panel derecho muestra los perfiles de calidad Phred, donde ambas tecnologías mantienen valores óptimos ($>Q30$) a lo largo de 150 bp. Reporte generado mediante MultiQC.

Los reportes completos generados por FastQC, MultiQC, así como los códigos utilizados para el análisis, se encuentran disponibles de manera digital en el link (Notion) asociado a este trabajo (Anexo 1).

4.4 Ensamblaje y evaluación del genoma de la cepa RF.

4.4.1 Ensamblaje del genoma.

Tras la depuración con fastp (24), e eliminaron adaptadores y secuencias sobre-representadas, conservándose únicamente lecturas con una longitud ≥151 pb y calidad ≥Q25. Este proceso logró mitigar los artefactos detectados inicialmente, especialmente en el flujo de NovaSeq. Aunque la profundidad de lectura difiere significativamente entre plataformas con un predominio cuantitativo de NovaSeq X (~4M) sobre MiSeq (~550k), ambos perfiles mostraron una consistencia técnica adecuada tras el filtrado. Cabe destacar que la mayor tasa de lecturas duplicadas observada en la plataforma de alto rendimiento se considera un fenómeno esperado dada la naturaleza del dataset y la escala de secuenciación empleada (Figura 13) (Anexo 1).

Figura 13. Control de calidad de las secuencias tras el procesamiento con fastp. Se observa la eliminación de adaptadores y el filtrado de lecturas de baja calidad, manteniendo un perfil de calidad medio (Phred Score) por encima de Q25 y una longitud mínima de 151 pb.

Una vez obtenido el ensamblaje se evaluó su calidad considerando los contigs y scaffolds generados, así como las lecturas depuradas con Fastp. Para ello, se empleó el programa QUAST (26), cuyos resultados se resumen en el Anexo 1.

Las métricas de calidad del ensamblaje evidenciaron diferencias entre las plataformas de secuenciación empleadas. El ensamblaje generado a partir de datos de NovaSeq presentó una mayor continuidad global y una cobertura más uniforme en comparación con MiSeq, lo que se reflejó en valores superiores de N50 y en una mayor profundidad de secuenciación, acompañados de menores valores de L50 y L90, indicativos de una menor fragmentación del ensamblaje. Aunque ambos ensamblajes mostraron longitudes totales y contenidos de GC comparables, el ensamblaje de NovaSeq no presentó regiones ambiguas y alcanzó una cobertura ≥10× en prácticamente la totalidad del genoma. En contraste, el ensamblaje obtenido con MiSeq presentó menor cobertura y la presencia de regiones ambiguas. En conjunto, estos resultados indican que el ensamblaje generado con datos de NovaSeq es más robusto y confiable, por lo que fue seleccionado para los análisis posteriores (Tabla 2).

Tabla 2: Comparación de métricas de calidad del ensamblaje genómico obtenido a partir de datos de secuenciación NovaSeq y MiSeq.

Métrica	NovaSeq	MiSeq
Número total de lecturas	8,075,942	529,804
Número de contigs	505	439
Contigs ≥ 50 kb	30	25
Contig más largo (bp)	154,206	189,787
Longitud total del ensamblaje (bp)	4,556,404	4,526,514
N50 (bp)	61,673	41,208
L50	27	30
N90 (bp)	13,544	11,300
L90	94	105
Contenido GC (%)	45.09	45.00
Lecturas mapeadas (%)	99.87	100.52
Cobertura promedio (×)	218	17
Cobertura ≥10× (%)	99.28	88.19
Ns por 100 kbp	0	15.24
Mismatches	0	Presentes

Los reportes completos generados por SPAdes, QUAST, Samtools y Qualimap, así como las estadísticas de ensamblaje y mapeo, se encuentran disponibles en el repositorio digital (Notion) asociado a este trabajo (Anexo 1).

4.4.2 Clasificación taxonómica basada en genomas tipo (TYGS/dDDH).

El análisis comparativo mediante dDDH reveló que la cepa analizada RF presentó valores de similitud genómica claramente inferiores al umbral del 70% con respecto a todas las cepas de referencia evaluadas mediante TYGS (Tabla 3), lo que indica que no corresponde a ninguna de las especies actualmente descritas. Los valores obtenidos a partir de las fórmulas d0, d4 y d6 mostraron intervalos de confianza consistentes y estrechos, lo que respalda la robustez de la estimación y descarta una asignación ambigua a nivel de especie.

No obstante, las menores diferencias en el contenido GC observadas frente a cepas del género *Ruminococcus* sp, en comparación con otros géneros evaluados, sugieren una mayor cercanía filogenética a este grupo. En conjunto, los resultados indican que la cepa RF se encuentra filogenéticamente relacionada con especies del género *Ruminococcus* sp, aunque representa una entidad taxonómica diferenciada a nivel de especie.

Tabla 3: Análisis comparativo entre el genoma de RF y los genomas de referencia conocidos.

Type Strain Genome Server							
Cepa de referencia	**dDDH (d0, en %)**	**I.C (d0, in %)**	**dDDH (d4, en %)**	**I.C (d4, en %)**	**dDDH (d6, en %)**	**I.C (d6, in %)**	**Diferencia de contenido GC (en %)**
Ruminococcus flavefaciens ATCC 19208	15,7	[12.8 - 19.2]	23,5	[21.2 - 26.0]	15,9	[13.3 - 18.8]	1,92
Ruminococcus albus 7	13,2	[10.5 - 16.5]	24,9	[22.6 - 27.4]	13,6	[11.2 - 16.4]	1,48
Ruminococcus albus DSM 20455	13,2	[10.4 - 16.5]	24,7	[22.4 - 27.2]	13,5	[11.2 - 16.3]	1,48
Ruminococcus bicirculans 80/3	12,9	[10.2 - 16.2]	23,7	[21.4 - 26.1]	13,3	[10.9 - 16.0]	2,47
Ruminococcus champanellensis 18P13	12,9	[10.2 - 16.2]	23,1	[20.8 - 25.6]	13,3	[10.9 - 16.0]	8,35
Ruminococcus callidus ATCC 27760	12,8	[10.1 - 16.0]	23,2	[20.9 - 25.6]	13,1	[10.8 - 15.9]	3,98
Butyricicoccus porcorum DSM 104997	12,6	[9.9 - 15.9]	25,8	[23.5 - 28.3]	13	[10.7 - 15.7]	7,46
Angelakisella massiliensis Marseille-P3217	12,6	[9.9 - 15.8]	25,3	[23.0 - 27.8]	13	[10.6 - 15.7]	8,03
Candidatus Merdibacter merdavium CHK187-11901	12,5	[9.8 - 15.7]	31,1	[28.7 - 33.6]	12,9	[10.6 - 15.6]	7,73

Caproicibacter fermentans DSM 107079 T	12,5	[9.9 - 15.8]	30,7	[28.3 - 33.2]	12,9	[10.6 - 15.7]	6,13
Jeotgalibacillus alimentarius YKJ-13	12,5	[9.8 - 15.8]	25,2	[22.9 - 27.7]	12,9	[10.6 - 15.7]	1,97
Clostridium methylpentosum DSM 5476	12,5	[9.9 - 15.8]	21,9	[19.6 - 24.3]	12,9	[10.6 - 15.7]	6,72
Anaerocolumna xylanovorans DSM 12503	12,5	[9.8 - 15.8]	21,4	[19.1 - 23.8]	12,9	[10.6 - 15.6]	4,95
Cryobacterium melibiosiphilum CGMCC 1.11212	12,5	[9.8 - 15.7]	21,1	[18.9 - 23.6]	12,9	[10.6 - 15.6]	21,76
Arthrobacter halodurans DSM 21081	12,5	[9.8 - 15.7]	20,4	[18.2 - 22.8]	12,9	[10.6 - 15.6]	26,4
Ligaoa zhengdingensis NSJ-31	12,5	[9.9 - 15.8]	19,6	[17.4 - 22.0]	12,9	[10.6 - 15.7]	11,94

Con base a los resultados detallados en la Tabla 3, la cepa más cercana al ensamblaje fue *Ruminococcus flavefaciens* ATCC 19208, con valores de dDDH (d0: 15.7%, d4: 23.5%, d6: 15.9%). Sin embargo, los valores estuvieron muy por debajo del umbral típico del 70% requerido para clasificarlo como la misma especie. Lo que indica que la cepa de estudio RF no corresponde a ninguna de las cepas conocidas en la base de datos, siendo *Ruminococcus flavefaciens* ATCC 19208 es la especie más relacionada. Por otra parte, la diferencia del % GC fue de 1.91%, valor que está dentro del rango esperado para especies relacionadas, pero no idénticas.

Es importante mencionar que el género *Ruminococcus* ha sufrido múltiples reorganizaciones taxonómicas debido a la heterogeneidad filogenómica del grupo, el cual ha sido reconocido como polifilético, con especies distribuidas en distintos clados dentro de la familia *Ruminococcaceae* y otros grupos relacionados (54–56). Estos cambios en la nomenclatura, impulsados por análisis filogenéticos basados inicialmente en genes ribosomales y

posteriormente en genómica comparativa, explican la proximidad de RF con especies actualmente asignadas a diferentes géneros dentro del mismo clado evolutivo.

Con el fin de evaluar la similitud evolutiva y la relación de ancestros comunes, se construyeron árboles filogenéticos basados en genoma y proteoma mediante el servidor TYGS (Figuras 14 y 15). Las distancias filogenéticas fueron calculadas utilizando el método GBDP (Genome BLAST Distance Phylogeny), a partir de alineamientos de fragmentos genómicos.

Las ramas del árbol indican similitudes y diferencias evolutivas: ramas más cortas representan relaciones más cercanas, mientras que ramas más largas indican mayor distancia evolutiva, así mismo los nodos terminales representan cada una de las cepas incluidas en el análisis.

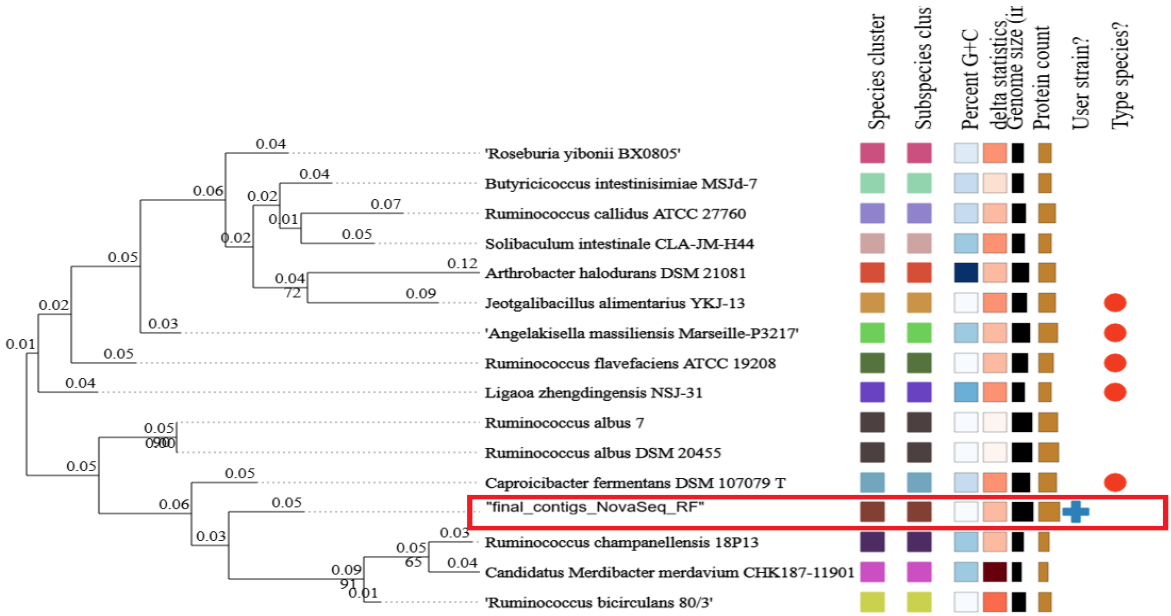

Figura 14. Árbol filogenético basado en distancias de genoma a genoma (dDDH) generado con TYGS.
La barra de escala indica sustituciones por sitio. Los símbolos y colores representan la clasificación en species/subspecies clusters, los valores de dDDH y las cepas tipo (círculos rojos). La cepa RF (en rojo) se ubica próxima a *Ruminococcus champanellensis 18P13*, aunque los valores de dDDH por debajo del umbral de especie, lo que sugiere un linaje potencialmente novedoso. El ensamblaje analizado se resalta con una cruz azul. Las columnas laterales muestran el species cluster, el contenido de G+C, el tamaño genómico y el estado LPS. En la escala de colores, los dos primeros tonos distinguen especies y, en los demás, la intensidad representa valores crecientes del parámetro indicado.

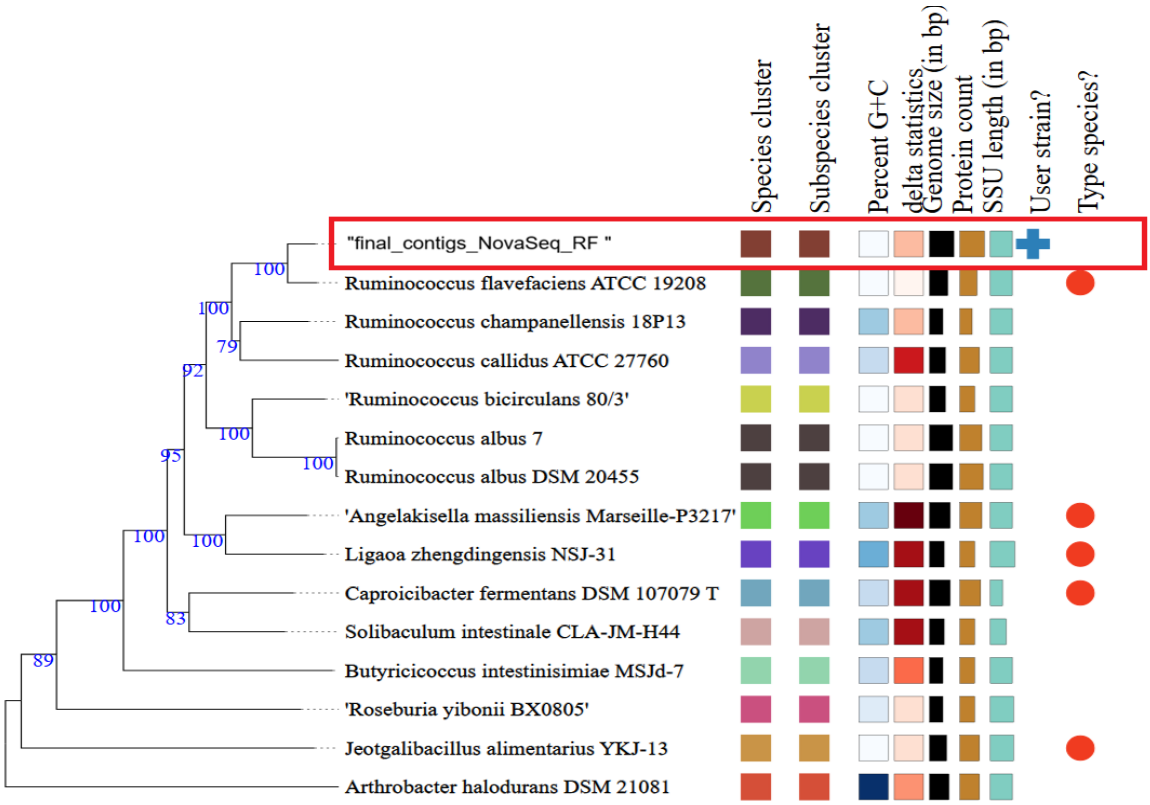

Figura 15. Árbol filogenético basado en distancias evolutivas a nivel de proteoma a proteoma generado con el servidor TYGS.
Los cuadros de colores indican la asignación a *species* y *subspecies clusters*, tamaño del genoma, número de proteínas y designación como cepa tipo (círculo rojo). La cepa RF (en rojo) se agrupó dentro del clado de *Ruminococcus flavefaciens*, mostrando alta afinidad proteómica, aunque con distancias que sugieren un linaje diferenciado.

El árbol filogenético basado en distancias genómicas generado mediante TYGS (Figura 14) mostró una estructuración en clústeres definidos, coherentes con la familia Ruminococcaceae. El genoma en estudio (final_contigs_NovaSeq_RF) se agrupó en un clado hermano con *Ruminococcus champanellensis* 18P13, compartiendo un ancestro común reciente, pero manteniéndose como un linaje independiente.

La distancia evolutiva observada (0,05 - 0,06) entre ambos genomas, sumada a los resultados de hibridación digital ADN-ADN, indica una relación filogenética cercana mas no una identidad de especie. En contraste, clados que agrupan a *R. albus*, *R. flavefaciens* y *R. bicirculans* presentaron una mayor divergencia genómica respecto a RF. Estos resultados respaldan la posición del microorganismo dentro del grupo de bacterias anaerobias ruminales y sustentan su

asignación como una potencial nueva especie, tal como lo propone el servidor TYGS mediante el clúster de especie diferenciado (color marrón).

En cuanto al árbol basado en proteomas completos (Figura 15), final_contigs_NovaSeq_RF se agrupa con una mayor proximidad filogenética a *Ruminococcus flavefaciens* ATCC 19208 en comparación con las demás cepas de referencia. Este análisis presenta un soporte de ramas del 97,7%, lo cual indica una alta confiabilidad en las relaciones evolutivas descritas. Asimismo, el soporte estadístico de bootstrap (100% en los nodos principales) robustece la topología del árbol, confirmando la estabilidad del clado donde se ubica el aislamiento RF dentro del género *Ruminococcus*.

En términos resumidos final_contigs_NovaSeq_RF parece estar más relacionado con *Ruminococcus flavefaciens* ATCC 19208, aunque los valores de dDDH (15,7 %) está por debajo del umbral para considerar que pertenezca a la misma especie lo que apunta a la posibilidad de una especie nueva, el perfil proteómico-metabólico mantiene una clara afinidad con *R. flavefaciens*; esta conclusión es coherente con el reporte generado por TYGS (Anexo 2), que sugiere la existencia de un linaje potencialmente novedoso dentro del género *Ruminococcus* sp.

Estos resultados adquieren mayor relevancia al compararlos con la evidencia fenotípica ya que esta cepa RF como se mencionó anteriormente mostró un crecimiento más exigente en medio sólido, requiriendo condiciones estrictas de atmósfera con CO_2 y presentando colonias blancas y cremosas, en contraste con las colonias amarillentas descritas para otras especies del género (*R. albus* y *R. flavefaciens*) bajo condiciones convencionales (51). En conjunto, la concordancia entre la diferenciación genómica y el comportamiento en cultivo apoya la propuesta de que RF constituye una especie potencialmente nueva dentro del género *Ruminococcus* sp, con rasgos fenotípicos y evolutivos propios.

Por otro lado, os valores de ANI (Figura 16) entre el genoma RF y los genomas de referencia oscilaron entre 63.15 % y 76.61 %, muy por debajo del umbral de 95–96 % establecido para la delimitación de especies bacterianas (33,34,57). El valor más alto se observó con *Ruminococcus flavefaciens* ATCC 19208 (76.61 %), indicando una relación filogenómica dentro del mismo clado pero una clara divergencia a nivel de especie.

a comparación con *R. flavefaciens* FD-1 mostró un valor de 99.92 % ANI, aunque con una cobertura genómica aproximada de 74 %, sugiriendo una alta similitud en las regiones alineadas, pero no necesariamente una identidad completa a nivel de genoma; la fracción del genoma efectivamente comparable entre ambos ensamblajes presentó una identidad nucleotídica elevada; sin embargo, aproximadamente un 26 % del genoma no fue alineado, lo que evidencia la presencia de regiones genómicas divergentes o ausentes en la comparación.

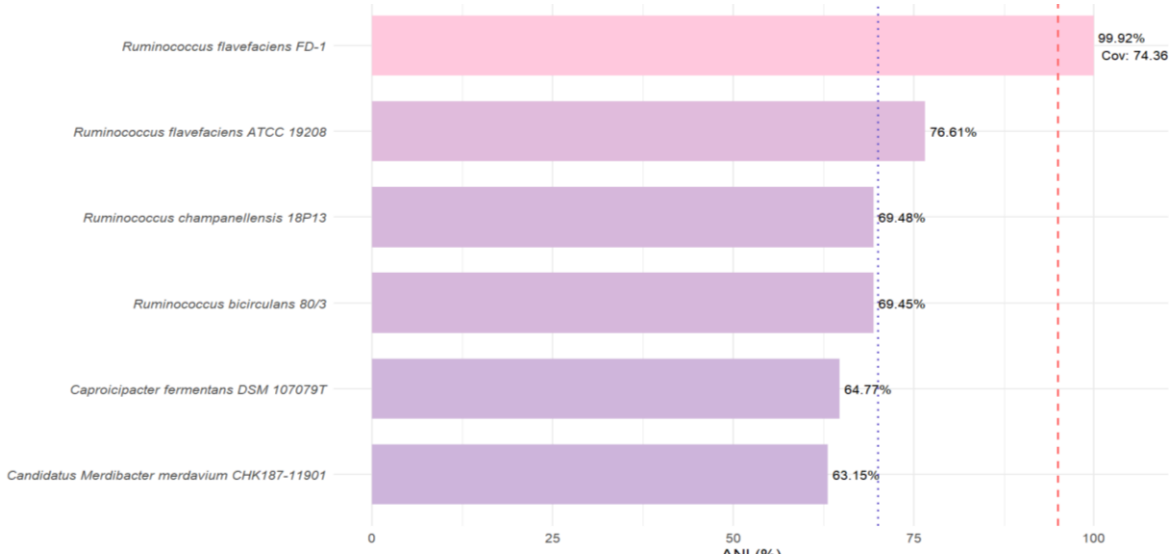

Figura 16. Comparación de Average Nucleotide Identity (ANI) entre el genoma RF y genomas de referencia relacionados.
La línea discontinua indica el umbral de delimitación de especies bacterianas (95–96 % ANI).
En *Ruminococcus flavefaciens* FD-1 se indica adicionalmente el porcentaje de cobertura del alineamiento genómico.
Elaboración propia

En este contexto, el porcentaje de cobertura constituyó un parámetro clave para interpretar los valores de ANI, ya que una identidad elevada restringida a una fracción del genoma no implica necesariamente equivalencia taxonómica entre los organismos comparados. En conjunto, los resultados de ANI concuerdan con los valores de dDDH obtenidos mediante TYGS (<70 %) (33,34) apoyando que la cepa RF representa un linaje genómicamente diferenciado dentro del clado asociado al género *Ruminococcus*.

4.5 Identificación de genes asociados a la degradación de celulosa.

La anotación de la cepa RF con el servidor RAST permitió identificar un total de 4570 *features*, de las cuales 4512 correspondieron a CDS. Estos genes fueron organizados en 25 subsistemas funcionales, dentro de los cuales el subsistema de carbohidratos reunió 127 funciones relacionadas con la utilización y degradación de carbohidratos complejos, incluyendo la celulosa (Figura 17).

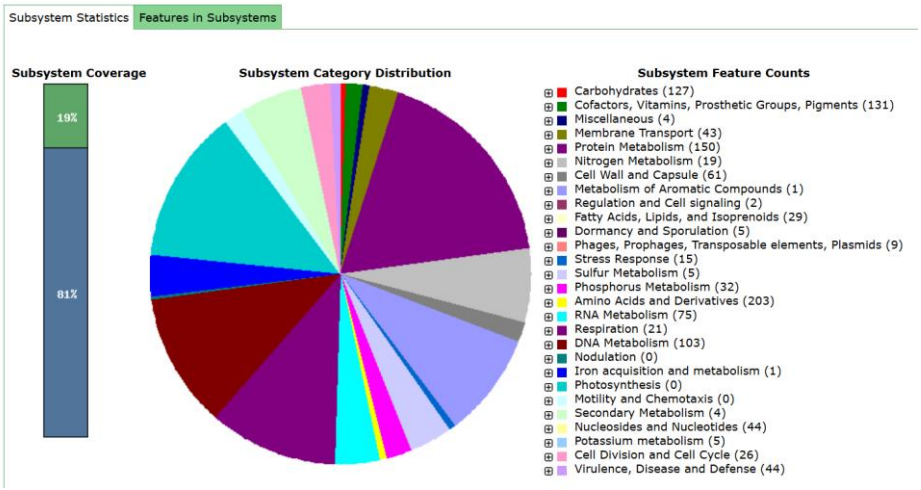

Figura 17. Distribución funcional de los genes anotados con RAST en la cepa RF. El 19 % de los genes predichos fueron clasificados en subsistemas metabólicos, destacándose las categorías de metabolismo de carbohidratos, aminoácidos y cofactores, mientras que el 81 % no se asignaron a subsistemas definidos. Esta distribución resalta el potencial de la cepa para la degradación de polisacáridos complejos y sugiere la existencia de funciones novedosas aún no caracterizadas en bases de datos.

Al procesar las secuencias de aminoácidos en KEGG GhostKOALA, se observó que el 31% de los CDS fueron asignados a ortólogos de KEGG (KO), asociados principalmente con rutas metabólicas de carbohidratos, aminoácidos y energía (Figura 18). Entre las rutas predichas, se destacó el metabolismo de la celulosa, dado que este compuesto proveniente de forrajes y pastos, constituye una fuente primaria de carbono en el rumen. La degradación inicial de la celulosa genera azúcares simples que alimentan la glucólisis, produciendo piruvato (58), un intermediario clave en la fermentación anaeróbica. A partir de este proceso se generan ácidos grasos volátiles, que representan la principal fuente de energía para el animal (10).

El metabolismo de *R. flavefaciens* comienza con la descomposición de celulosa en celobiosa y glucosa (enzimas: 3.2.1.4, 3.2.1.21) (Figura 19) y continúa con la glucólisis (59), donde la glucosa se transforma en piruvato. Finalmente, el piruvato es fermentado a acetato, propionato y butirato, que son la principal fuente de energía del bovino (60).

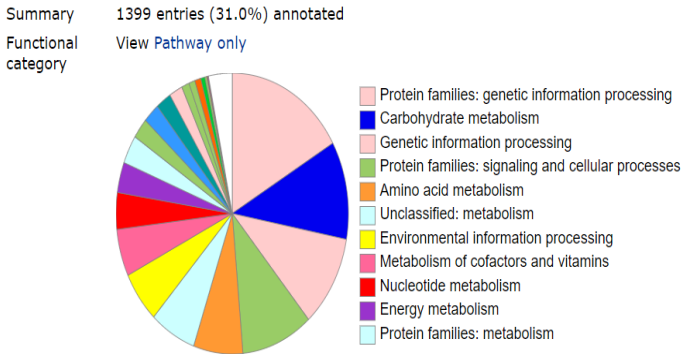

Figura 18. Distribución funcional de genes anotados mediante KEGG GhostKOALA en la cepa RF.
Se obtuvo un total de 1399 entradas (31 % de las predicciones) clasificadas en categorías metabólicas, destacándose aquellas relacionadas con el metabolismo de carbohidratos, aminoácidos y nucleótidos, así como con el procesamiento de la información genética.

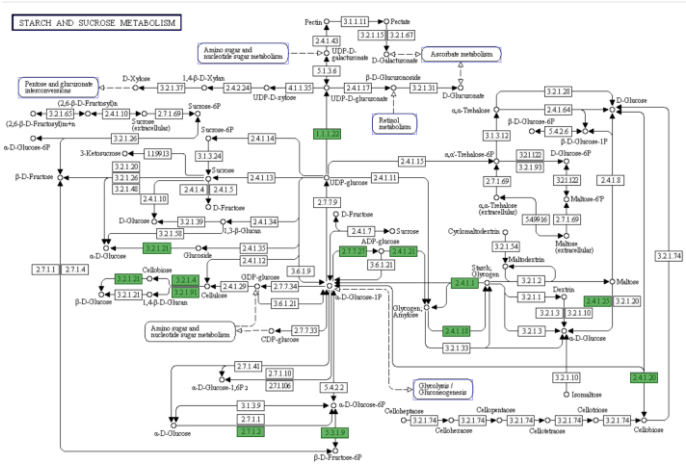

Figura 19. Ruta metabólica de almidón y sacarosa generada en KEGG GhostKOALA (enero 2025) a partir del ensamblaje de la cepa RF.
Se utilizó como referencia el genoma de *Ruminococcus flavefaciens*. En la parte izquierda-intermedia se visualiza el módulo correspondiente a la degradación de celulosa.

El análisis detallado de las enzimas detectadas evidenció múltiples genes asociados a las actividades de endoglucanasas (EC 3.2.1.4), celobiosidasas (EC 3.2.1.91) y β-glucosidasas (EC 3.2.1.21) (Tabla 4). Esta heterogeneidad a nivel enzimático se puede relacionar con un proceso de adaptación al ambiente del rumen, es decir, el rumen es un ecosistema complejo donde las

condiciones (pH o la disponibilidad de sustratos) pueden variar así que al tener varios genes que codifican la misma enzima confiere al microorganismo la capacidad de degradar la celulosa en una amplia variedad de condiciones, asegurando la disponibilidad de azúcares fermentables (61).

Tabla 4: Múltiples entradas para tres códigos EC, implicadas en la degradación de celulosa por *R. flavefaciens*

EC: 3.2.1.4		
Gen ID	**Genoma**	**Función**
fig|1265.300.peg.494	*Ruminococcus flavefaciens*	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)
fig|1265.300.peg.1649	*Ruminococcus flavefaciens*	Endoglucanase celA precursor (EC 3.2.1.4) (Endo-1,4-beta-glucanase) (Cellulase)
fig|1265.300.peg.2831	*Ruminococcus flavefaciens*	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)
fig|1265.300.peg.4121	*Ruminococcus flavefaciens*	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)
EC: 3.2.1.91		
Gen ID	**Genoma**	**Función**
fig|1265.300.peg.2408	*Ruminococcus flavefaciens*	Cellulose 1,4-beta-cellobiosidase (non-reducing end) (EC 3.2.1.91)
EC: 3.2.1.21		
Gen ID	**Genoma**	**Función**
fig|1265.300.peg.446	*Ruminococcus flavefaciens*	beta-glucosidase (EC 3.2.1.21)
fig|1265.300.peg.2380	*Ruminococcus flavefaciens*	beta-glucosidase (EC 3.2.1.21)

Se observan enzimas con actividad EC 3.2.1.4 (Endoglucanasas), que catalizan la ruptura de enlaces internos β-1,4 en la celulosa y otros glucanos siendo cruciales para iniciar la degradación de la celulosa y romperla en oligosacáridos más cortos (62,63). Una vez se realiza esta degradación las enzimas con actividad EC 3.2.1.91 (Exoglucanasas o celobiosidasas) catalizan la liberación de celobiosa desde los extremos no reductores de las cadenas de celulosa (63,64).

También se encuentran las enzimas con actividad EC 3.2.1.21 (β-glucosidasas) las cuales hidrolizan celobiosa y otros disacáridos derivados de celulosa en dos moléculas de glucosa, lo cual permite la entrada de la glucosa en la glucólisis para ser utilizada como fuente de energía o en otras rutas metabólicas (64). Considerando el número de entradas para cada EC, destaca nuevamente la adaptabilidad metabólica que asegura que el microorganismo pueda responder a cambios en la calidad o cantidad de la celulosa disponible (14).

De manera complementaria, el análisis en la plataforma KBase (37) empleando la base de datos CAZy confirmó la presencia de genes que codifican enzimas GH, destacándose las familias GH5 y GH9 (Figura 20, Tablas 5 y 6). Las enzimas de la familia GH5 mostraron mayor diversidad funcional y una amplia gama de actividades sobre celulosa y hemicelulosas, mientras que las GH9 presentaron alineamientos más largos, valores estadísticos más robustos y alta especificidad para funciones asociadas directamente a la degradación de celulosa.

Las enzimas con EC 3.2.1.4 (Beta-1,4-glucanase), que participan en la degradación de celulosa al hidrolizar los enlaces beta-1,4 de glucanos, también fueron detectadas en KEGG (36), esta actividad está integrada en la ruta del metabolismo de celulosa y glucosa (11).

Por otro lado EC 3.2.1.91 (Cellobianotaciones KEGG) fue detectada con CAZy siendo su función la hidrolisis de la celulosa terminal (no reductora), liberando unidades de celobiosa (36) y que se encuentra en el metabolismo de disacáridos conectando con pasos posteriores donde la celobiosa se convierte en glucosa mediante beta-glucosidasa; a su vez se detectó EC 3.2.1.21 (Beta-glucosidase) que convierte la celobiosa en glucosa y en KEGG, está directamente involucrada en la ruta de la glucosa-6-fosfato hacia el piruvato (65); teniendo en cuenta las dos anotaciones KEGG – CAZy, las rutas metabólicas en KEGG vinculan estas enzimas con el metabolismo de la celulosa y carbohidratos en el organismo.

La presencia conjunta de endoglucanasas, exoglucanasas y β-glucosidasas sugiere un sistema enzimático sinérgico capaz de despolimerizar la celulosa y generar azúcares fermentables que

podrían alimentar rutas centrales como la glucólisis.

Figura 20. Distribuciónde Familias de Glicosil Hidrolasas (GH) en el Genoma de *Ruminococcus flavefaciens*, anotado con CAZy.

Tabla 5: Glicosil hidrolasas de la familia GH5 anotadas mediante KBase–CAZy.
GEN ID: identificador del gen; Función: actividad enzimática asignada; Genoma: genoma analizado; ALN_LEN: longitud del alineamiento respecto a la proteína de referencia; E-value: significancia estadística del alineamiento; Bit score: calidad del alineamiento; H_beg–H_end: posiciones del alineamiento dentro de la proteína consulta.

GEN ID	FUNCION	GENOMA	ALN_ LEN	i-EVALUE	BIT SCORE	H_BEG-H_END
			Hits to GH5			
CDS.2907	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)	GENOME_RF_KBASE_RAST	219 (79.6 %)	1.5e-49	167.0	63-345
CDS.2907	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)	GENOME_RF_KBASE_RAST	240 (87.3 %)	1.4e-34	117.9	545-796
CDS.1876	Endo-1,4-beta-xylanase (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	239 (86.9 %)	1.2e-51	173.9	51-409
CDS.1877	Endo-1,4-beta-xylanase (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	239 (86.9 %)	5.1e-51	171.8	82-430
CDS.1878	Endo-1,4-beta-xylanase (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	244 (88.7 %)	2.9e-50	169.3	54-456

CDS.2635	Endo-1,4-beta-xylanase (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	240 (87.3 %)	6.3e-49	165.0	51-418
CDS.2642	hypothetical protein	GENOME_RF_KBASE_RAST	230 (83.6 %)	2.1e-47	160.0	8-303
CDS.3978	Endo-1,4-beta-xylanase A precursor (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	221 (80.4 %)	3.1e-47	159.4	386-664
CDS.4224	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)	GENOME_RF_KBASE_RAST	209 (76.0 %)	4.7e-45	152.3	103-389
CDS.3134	N/A	GENOME_RF_KBASE_RAST	219 (79.6 %)	3.2e-43	146.2	80-363
CDS.3204	Mannan endo-1,4-beta-mannosidase (EC 3.2.1.78)	GENOME_RF_KBASE_RAST	239 (86.9 %)	5.4e-38	129.1	543-793
CDS.2569	Endo-1,4-beta-xylanase A precursor (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	211 (76.7 %)	9.3e-35	118.5	71-357

Tabla 6: Glicosil hidrolasas de la familia GH9 anotadas mediante KBase–CAZy.
GEN ID: identificador del gen; Función: actividad enzimática asignada; Genoma: genoma analizado; ALN_LEN: longitud del alineamiento respecto a la proteína de referencia; E-value: significancia estadística del alineamiento; Bit score: calidad del alineamiento; H_beg–H_end: posiciones del alineamiento dentro de la proteína consulta.

GEN ID	FUNCION	GENOMA	ALN_LEN	i-EVALUE	BIT SCORE	H_BEG-H_END
			Hits to GH9			

CDS.3098	glycoside hydrolase, family 9	GENOME_RF_KBASE_RAST	418 (100.0%)	4,00E-128	426.3	44-636
CDS.446	glycoside hydrolase, family 9	GENOME_RF_KBASE_RAST	418 (100.0%)	1.7e-120	401.2	44-525
CDS.3377	Chitinase (EC 3.2.1.14)	GENOME_RF_KBASE_RAST	416 (99.5%)	7.9e-118	392.4	315-800
CDS.2182	Endo-1,4-beta-xylanase A precursor (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	417 (99.8%)	6.7e-115	382.8	35-465
CDS.3776	beta-1,4-glucanase (cellulase) (EC 3.2.1.4)	GENOME_RF_KBASE_RAST	416 (99.5%)	2.7e-108	361.0	290-713
CDS.2659	Cellulose 1,4-beta-cellobiosidase (non-reducing end) (EC 3.2.1.91)	GENOME_RF_KBASE_RAST	414 (99.0%)	1.4e-107	358.7	367-912
CDS.2658	Endo-1,4-beta-xylanase A precursor (EC 3.2.1.8)	GENOME_RF_KBASE_RAST	417 (99.8%)	1.1e-106	355.8	35-486
CDS.2768	glycoside hydrolase, family 9	GENOME_RF_KBASE_RAST	344 (82.3%)	4.6e-85	284.5	54-464
CDS.4151	Chitinase (EC 3.2.1.14)	GENOME_RF_KBASE_RAST	414 (99.0%)	5.3e-91	304.0	365-905
CDS.1933	Chitinase (EC 3.2.1.14)	GENOME_RF_KBASE_RAST	412 (98.6%)	7,00E-89	297.1	369-897

CDS.1094	hypothetical protein	GENOME_RF_KBASE_RAST	391 (93.5 %)	5.6e-85	284.2	1425-1821
CDS.3767	glycoside hydrolase, family 9	GENOME_RF_KBASE_RAST	418 (100.0%)	4.3e-88	294.5	49-437

Según los resultados de CAZy (Tablas 4 y 5), las enzimas GH5 presentaron alineamientos de 209–244 aa (76–88.7% de cobertura), con i-Evalues entre 1.5e-49 y 9.3e-35 y bit scores moderados.

En contraste, las GH9 mostraron alineamientos más largos (344–418 aa) con coberturas cercanas al 100%, i-Evalues más significativos (4.00e-128 a 4.6e-85) y bit scores más altos (294.5–426.3), lo que indica mayor robustez estadística y especificidad funcional. En conjunto, GH9 exhibe predicciones más confiables, mientras que GH5 refleja mayor diversidad en actividades sobre hemicelulosa y celulosa secundaria.

En conjunto, los resultados obtenidos por RAST, KEGG y CAZy evidencian que la cepa RF posee un repertorio enzimático diverso y robusto para la degradación de polisacáridos estructurales de la celulosa, lo que concuerda con su origen ruminal y su potencial papel en la digestión de forrajes por parte del hospedero bovino.

La anotación con Bakta permitió identificar un repertorio más amplio y diverso de genes asociados a la degradación de polisacáridos en comparación con las plataformas en línea RAST, KEGG y KBase. Entre los genes detectados se incluyeron múltiples copias de endoglucanasas (EC 3.2.1.4), celobiosidasas (EC 3.2.1.91) y β-glucosidasas (EC 3.2.1.21), además de proteínas pertenecientes a las familias GH5 y GH9.

Estas enzimas desempeñan un papel clave en la hidrólisis de enlaces β-1,4 y constituyen el eje central en la despolimerización de la celulosa. La abundancia de copias génicas, más allá de una redundancia, refleja un mecanismo adaptativo característico de bacterias ruminales, que les

permite mantener la degradación de polisacáridos bajo condiciones de variación en el pH o disponibilidad de sustratos (10,61,66).

El análisis con dbCAN2 corroboró la presencia de genes de familias GH (principalmente GH5 y GH9), varios CBM (CBM2, CBM3, CBM4, CBM22 y CBM37), así como un número significativo de dockerinas; módulos distintivos en la arquitectura de los celulosomas. La combinación de estas unidades modulares sugiere que la cepa RF está equipada para ensamblar complejos multienzimáticos especializados, capaces de anclarse a la fibra vegetal y optimizar la hidrólisis de celulosa.

Este hallazgo coincide con estudios previos en *Ruminococcus flavefaciens* FD-1 y otras cepas celulolíticas, donde la organización en celulosomas ha sido descrita como una estrategia esencial para la colonización de la fibra y la cooperación enzimática (11,13,14,58).

El análisis de péptido señal mediante SignalP mostró que aproximadamente el 88% (Figura 21). de las proteínas con dominios dockerina poseen predicciones positivas de secreción con una probabilidad superior a 0,7. Este resultado indica que la mayoría de estas proteínas estarían destinadas al espacio extracelular, lo que respalda su rol en la formación de celulosomas anclados a la superficie celular (58,67) (Anexo 1).

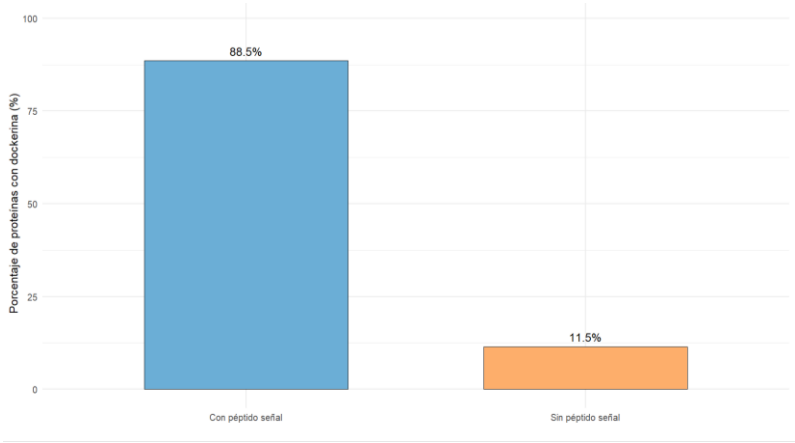

Figura 21. Predicción de péptidos señal en proteínas con dominios dockerina, según el análisis realizado con SignalP.
El alto porcentaje de proteínas con predicción positiva de secreción sugiere que la mayoría de las proteínas con dominios dockerina están destinadas al espacio extracelular, lo que respalda su participación en la formación de complejos celulosómicos.

En términos funcionales, este hallazgo sugiere un refinamiento adaptativo, ya que la exportación de estas enzimas maximiza la eficiencia en la captura y degradación de fibras vegetales, fenómeno ampliamente descrito en bacterias fibrolíticas del rumen (13,58).

Finalmente, se evaluó la abundancia relativa de las familias enzimáticas (Figura 22). Se observó que GH5 y GH9 constituyen la mayoría de los genes hidrolíticos, mientras que CBM3 y CBM2 (Figura 23) fueron los dominios de unión a carbohidratos más frecuentes, revelando una especialización masiva hacia la degradación de polímeros estructurales. Estas familias representan más del 80% del arsenal hidrolítico total, lo cual es indicativo de un sistema enzimático altamente eficiente para la hidrólisis de celulosa y hemicelulosa (68).

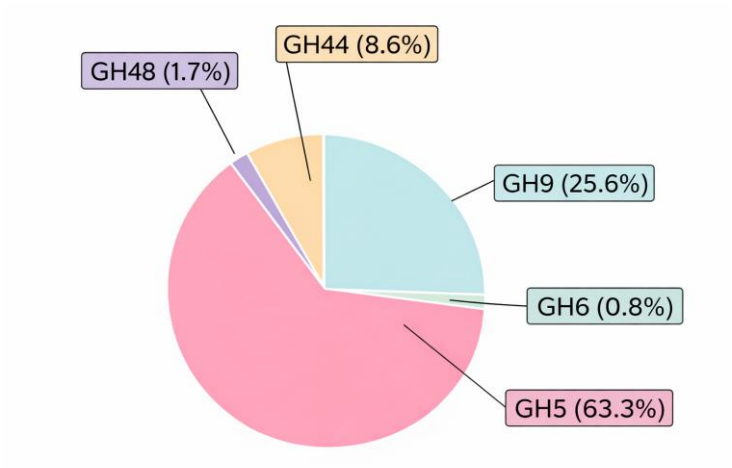

Figura 22. Abundancia porcentual de familias CAZy asociadas a celulosomas en el genoma de la cepa RF.
Distribución de genes anotados como glicosil hidrolasas (GH5, GH9) identificados mediante el análisis combinado de DIAMOND y HMMER contra la base de datos CAZy (dbCAN v3.0.2). Se observa una marcada predominancia de la familia GH5, lo que sugiere su papel central en la degradación de celulosa, complementada por la presencia GH9, típicamente asociados a complejos multiproteicos tipo celulosoma.

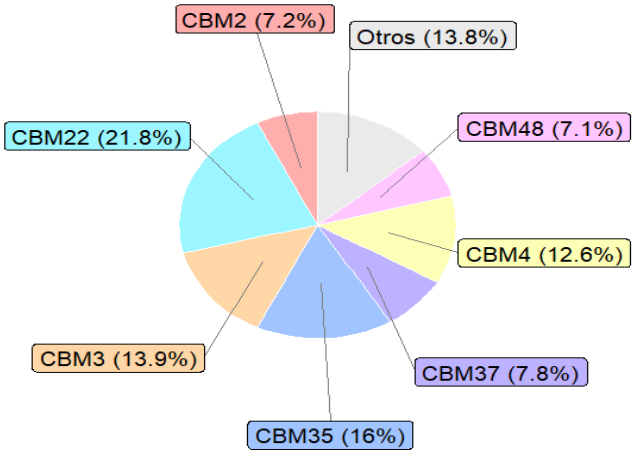

Figura 23. Distribución porcentual de dominios CBM implicados en la degradación de celulosa. Se muestra la distribución relativa de los dominios de unión a carbohidratos (CBM) identificados en el genoma de la cepa en estudio, obtenida a partir de la anotación funcional mediante DIAMOND. Se observa la presencia de múltiples familias de CBM asociadas principalmente a la unión a celulosa cristalina y amorfa.

El perfil genómico de la cepa RF revela una notable inversión genética en módulos de unión a carbohidratos, fundamentales para la degradación eficiente de la biomasa vegetal. La distribución porcentual muestra una predominancia de las familias CBM22 (21.8%) y CBM35 (16%), las cuales confieren a las enzimas una alta afinidad por el xilano y diversas hemicelulosas, permitiendo una colonización rápida de la pared celular vegetal (68).

No obstante, la arquitectura funcional de este nuevo linaje se complementa con la presencia de CBM3 (13.9%) y CBM37 (7.8%). Mientras que el CBM3 es esencial para el anclaje de las celulasas a la celulosa cristalina mediante la formación de complejos multienzimáticos (69), el CBM37 actúa como un determinante crítico de la adhesión celular al sustrato recalcitrante, una característica distintiva en el género *Ruminococcus* (67).

Esta configuración de CBMs, identificada mediante el análisis combinado de DIAMOND y HMMER contra la base de datos dbCAN v3.0.2 y la sinergia entre los dominios catalíticos sugiere la formación de complejos celulosómicos optimizados para una degradación de biomasa extremadamente rápida, sustentando el potencial de esta posible nueva especie para despolimerizar sustratos complejos con alta especificidad (68).

Adicionalmente, la proximidad genómica entre genes GH5 y dockerinas sugiere la presencia de módulos integrados que formarían parte de complejos celulolíticos (Figura 24). Este patrón, previamente documentado en cepas de *R. flavefaciens* y *Clostridium thermocellum*, ha sido interpretado como un rasgo adaptativo clave para la vida en ambientes ricos en fibra vegetal como el rumen (14,58,70).

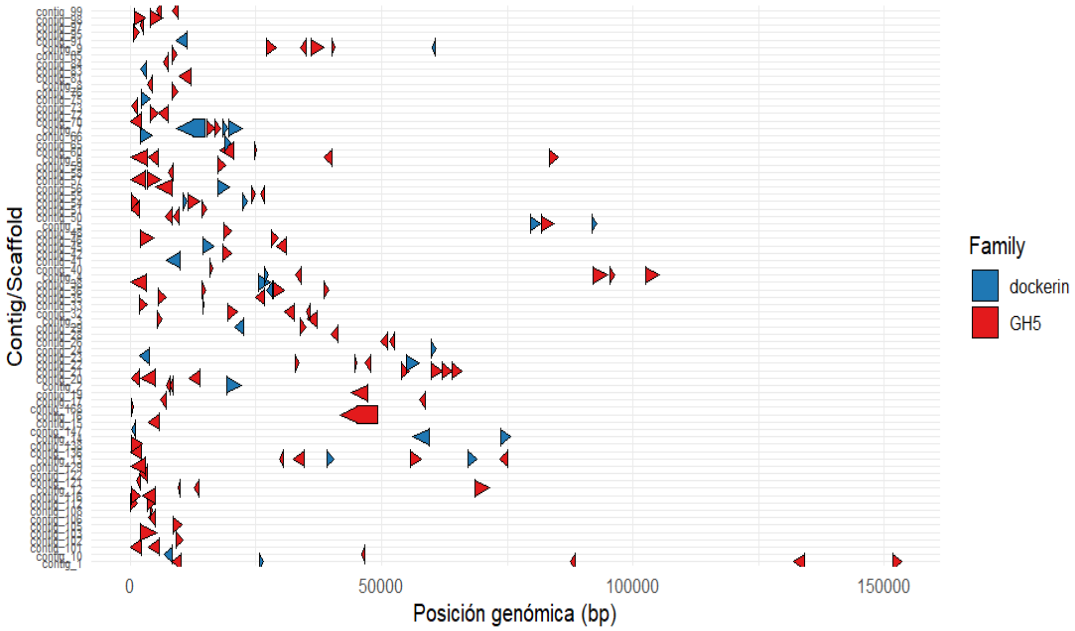

Figura 24. Distribución genómica de genes GH5 y dockerinas en el genoma de la cepa RF. Mapa de genes construido a partir de la anotación con Bakta y la identificación de familias CAZy mediante dbCAN2 (HMMER, DIAMOND y Hotpep). El eje Y representa los contigs del ensamblaje, mientras que el eje X corresponde a la posición genómica en pares de bases (bp). Los triángulos rojos corresponden a genes de la familia GH5, mientras que los azules representan módulos dockerina.

El mapa genómico muestra numerosos loci en los que genes codificantes de GH5 y módulos dockerina se encuentran en proximidad estrecha (Figura 24). Esta co-localización sugiere la presencia de módulos integrados destinados a ensamblarse en complejos celulolíticos extracelulares, una estrategia funcional ampliamente reportada en *Ruminococcus flavefaciens* y *Clostridium thermocellum* (14,58,70).

En conjunto, los resultados sugieren que la cepa RF posee no solo el repertorio enzimático característico de bacterias celulolíticas, sino también una organización modular compatible con la formación de celulosomas. Esto, sumado a las diferencias genómicas y fenotípicas observadas respecto a otras especies del género, refuerza la hipótesis de que RF corresponde

a un linaje potencialmente novedoso dentro de *Ruminococcus* sp con capacidades de degradación de celulosa altamente especializadas.

4.5.1 Análisis de la organización genómica de componentes celulosomales.

La inspección visual del genoma anotado de la cepa RF mediante Artemis permitió identificar que los genes codificantes de dominios cohesina, dockerina y scaffoldin se encuentran frecuentemente flanqueados por múltiples proteínas anotadas como hipotéticas dentro de los mismos contigs. En particular, la visualización del scaffoldin C reveló la presencia de varios ORFs adyacentes sin asignación funcional precisa, tanto corriente arriba como corriente abajo, lo que sugiere la posible existencia de componentes accesorios del celulosoma no descritos previamente (Figura 25).

Figura 25. Organización genómica del scaffoldin celulosomal putativo en la cepa RF. Visualización genómica obtenida mediante Artemis del contig que contiene el gen codificante del scaffoldin celulosomal putativo en la cepa RF. El scaffoldin se muestra resaltado en color magenta, mientras que las proteínas hipotéticas adyacentes se representan en cian. Genes con otras funciones se indican en verde. La proximidad espacial entre el scaffoldin y múltiples proteínas hipotéticas corriente arriba y corriente abajo sugiere la posible presencia de componentes accesorios asociados a la arquitectura del celulosoma, potencialmente específicos de la cepa RF.

Adicionalmente, en el contig_22 se detectó la co-localización de un gen portador de dominio dockerina junto a tres genes anotados como celulasas, un patrón compatible con enzimas periféricas destinadas a integrarse al complejo celulosomal (Figura 26).

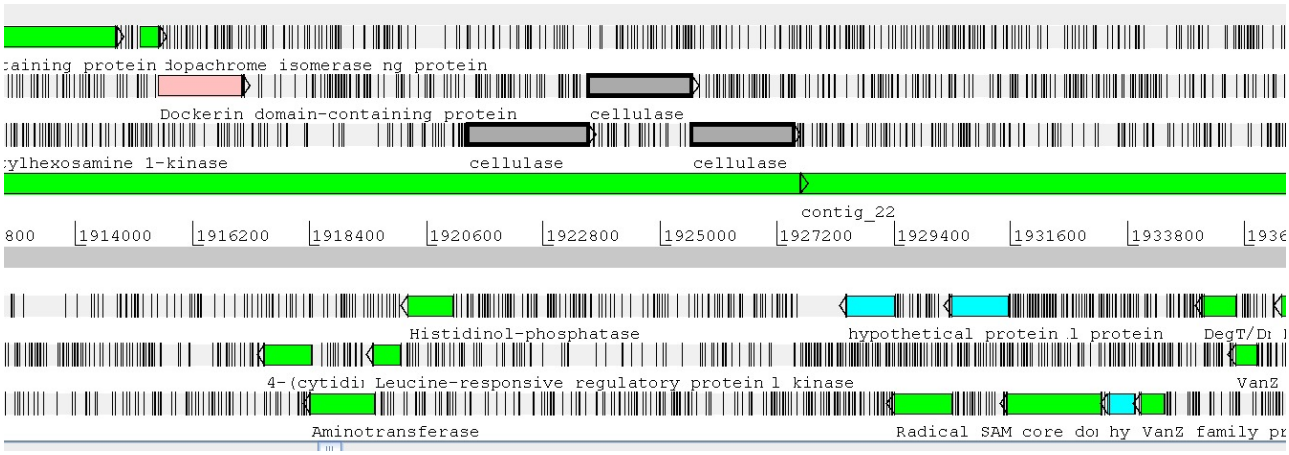

Figura 26. Co-localización de celulasas y dominios dockerina en la cepa RF. Representación genómica de una región del contig 22 obtenida mediante Artemis, en la que se observa la co-localización de un gen codificante de un dominio dockerina (resaltado en rosado) junto a múltiples genes anotados como celulasas (representados en gris). Las proteínas hipotéticas adyacentes se muestran en cian, mientras que otros genes no relacionados se indican en verde. La disposición espacial de celulasas en proximidad inmediata a un dominio dockerina sugiere la presencia de enzimas celulolíticas potencialmente integradas al complejo celulosomal, coherente con la organización modular descrita para bacterias celulolíticas del rumen.

Adicionalmente, la organización genómica resultante del análisis a nivel de contig utilizando el archivo GFF3 en RStudio permitió determinar que los componentes celulosomales en la cepa RF se encuentran distribuidos a lo largo del genoma, con una mayor densidad de genes codificantes de módulos dockerina y proteínas hipotéticas asociadas en regiones cercanas al inicio de múltiples contigs (≈0–25 kb). En contraste, los genes codificantes de scaffoldin y cohesinas son menos frecuentes y se restringen a contigs específicos, lo cual concuerda con su función estructural central dentro del complejo celulosomal (58,71,72).

Esta arquitectura es consistente con un sistema celulosomal de tipo modular y disperso, en el que numerosas enzimas periféricas portadoras de dominios dockerina se ensamblan sobre un número limitado de proteínas scaffoldin a través de interacciones cohesina–dockerina (Figura 27). Este patrón ha sido descrito previamente en bacterias celulolíticas del rumen, como *Ruminococcus flavefaciens* y *Clostridium thermocellum*, donde la expansión de enzimas accesorias confiere una elevada flexibilidad funcional frente a sustratos lignocelulósicos complejos (13,71,73,74).

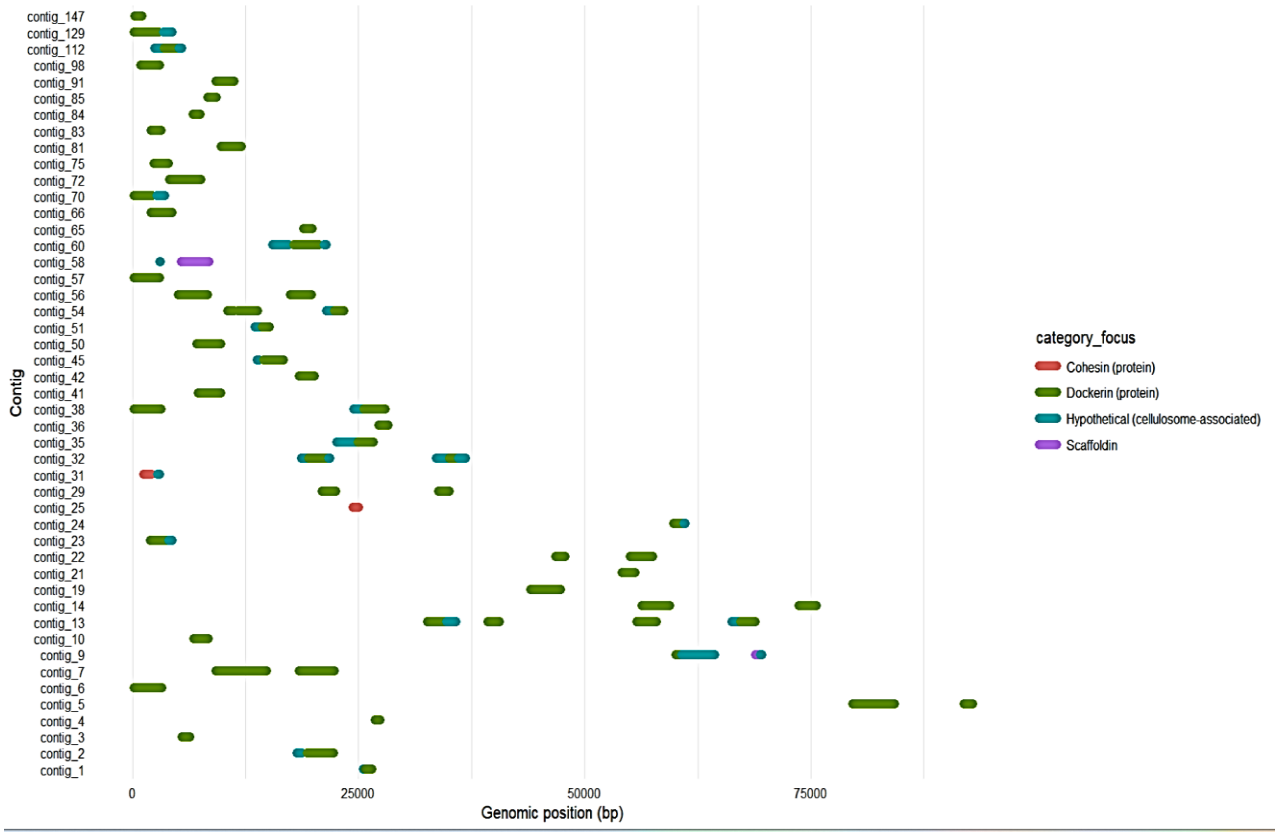

Figura 27. Organización a nivel de contig de los componentes celulosomales putativos en la cepa RF.
Distribución genómica de proteínas scaffoldin (morado), dominios cohesina (rojo), proteínas portadoras de dockerina (verde) y proteínas hipotéticas posiblemente asociadas al celulosoma (cian) a lo largo de distintos contigs del genoma ensamblado de la cepa RF. Los segmentos representan la posición genómica de cada gen dentro de su respectivo contig, permitiendo visualizar patrones de co-localización entre componentes estructurales del celulosoma y proteínas no caracterizadas.

La presencia recurrente de proteínas hipotéticas en proximidad inmediata a scaffoldins, cohesinas y dockerinas sugiere que la cepa RF podría poseer componentes celulosomales específicos de linaje, potencialmente implicados en funciones de anclaje, estabilidad estructural o adaptación a nichos ruminales particulares. Este tipo de organización ha sido asociado previamente a procesos de diversificación funcional y especialización ecológica en bacterias celulolíticas del rumen (72,74,75). Esta observación resulta especialmente relevante considerando la marcada divergencia genómica de la cepa RF frente a genomas de referencia, lo que refuerza la hipótesis de que se trata de un linaje potencialmente novedoso con una arquitectura celulosomal diferenciada.

4.6 Análisis comparativo de conservación proteica para la degradación de celulosa.

4.6.1 Comparación de conservación proteica mediante BLASTp e integración de resultados de anotación funcional y análisis comparativo.

El análisis comparativo del perfil de conservación celulolítica del genoma RF frente a distintas cepas de *Ruminococcus flavefaciens* reveló patrones diferenciados entre las enzimas catalíticas y los componentes estructurales del sistema celulosómico (Figura 28). En general, las familias GH5 y GH9 mostraron una predominancia de identidades medias, lo que indica una conservación funcional parcial entre las cepas analizadas. Este resultado sugiere que, aunque las secuencias proteicas presentan variabilidad, la función celulolítica básica se mantiene conservada dentro del género.

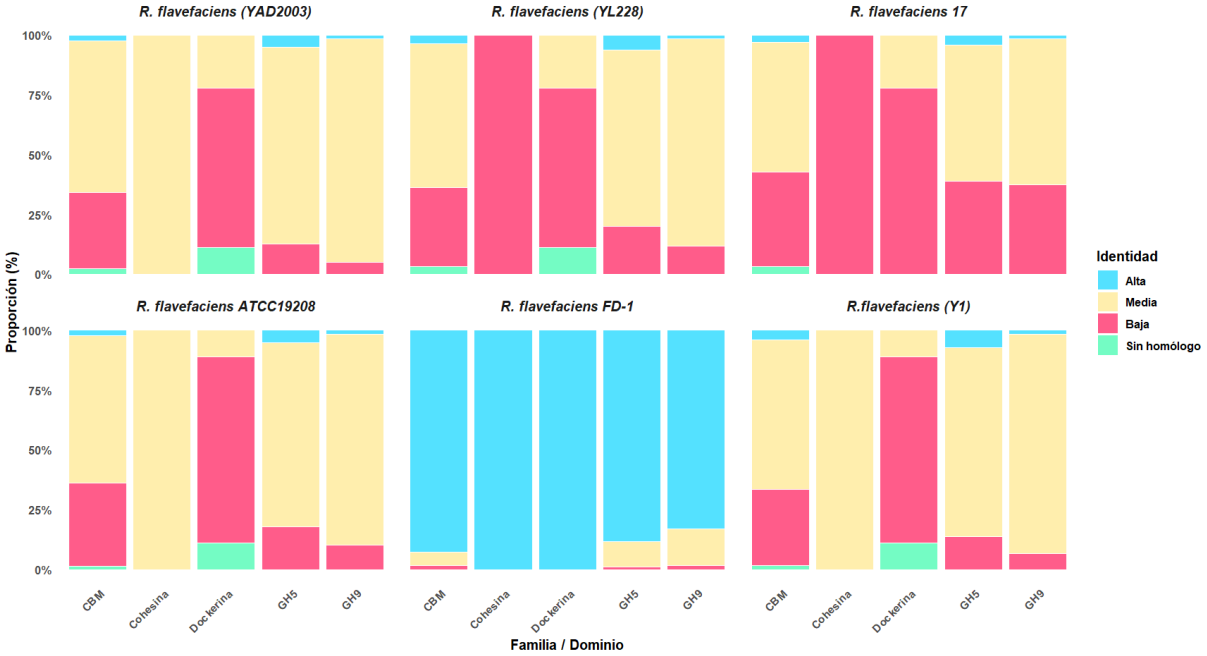

Figura 28. Comparación del perfil de conservación funcional celulolítica entre seis genomas de *Ruminococcus flavefaciens*.
Distribución relativa de los niveles de conservación (alta, media, baja y sin homólogo detectable) de proteínas asociadas a la degradación de celulosa del genoma RF, comparadas mediante alineamientos BLASTp frente a seis cepas de *Ruminococcus flavefaciens* (FD-1, 17, ATCC 19208, Y1, YL228 y YAD2003). El análisis se realizó a nivel de identidad proteica, considerando el mejor hit por proteína, e incluyó enzimas catalíticas (GH5 y GH9), dominios de unión a carbohidratos (CBM), así como dominios estructurales del celulosoma (dockerinas y cohesinas). Los resultados reflejan similitudes y variaciones funcionales entre cepas, independientemente del orden génico u organización genómica.

En cuanto a los dominios de unión a carbohidratos (CBM), se observó un patrón similar, con una mayor proporción de identidades medias y bajas. Esta variabilidad es consistente con el papel de los CBM como módulos adaptativos, cuya diversidad permite la interacción con distintos tipos y estructuras de celulosa, favoreciendo la eficiencia del sistema celulolítico en diferentes condiciones ambientales.

Por otro lado, los dominios dockerina y cohesina mostraron una mayor heterogeneidad en los niveles de conservación, destacándose una elevada proporción de identidades bajas o ausencia de homólogos en varias comparaciones. Este comportamiento refleja la alta especificidad y diversidad estructural de las interacciones cohesina–dockerina, las cuales determinan la arquitectura del celulosoma y suelen variar significativamente entre cepas, incluso dentro de la misma especie.

La comparación con la cepa FD-1 evidenció un mayor grado de conservación para dockerinas y cohesinas, lo que concuerda con su caracterización como una cepa altamente especializada en la degradación de celulosa mediante complejos celulosómicos bien organizados. En contraste, cepas como Y1 y YAD2003 presentaron una mayor proporción de identidades medias y bajas en estos dominios, lo que sugiere diferencias en la composición y organización de sus sistemas celulosómicos.

En conjunto, estos resultados indican que el genoma RF comparte un núcleo funcional celulolítico con otras cepas de *R. flavefaciens*, especialmente a nivel de enzimas catalíticas, mientras que presenta una marcada variabilidad en los componentes estructurales del celulosoma. Esta diversidad podría estar asociada a procesos de adaptación ecológica y a la optimización del sistema celulolítico frente a diferentes sustratos, más que a una pérdida de capacidad degradativa.

5. Conclusiones

- RF corresponde a un microorganismo estrictamente anaerobio con actividad celulolítica robusta, evidenciada por la rápida degradación de papel filtro como única fuente de carbono, lo que confirma que es un fenotipo celulolítico activo y robusto.

- El comportamiento colonial observado, colonias blancas, cremosas y de crecimiento exigente, difiere de lo reportado para otras especies del género *Ruminococcus*, lo que sugiere rasgos fisiológicos particulares que refuerzan la hipótesis de que RF representa un linaje diferenciado dentro del género.

- El análisis del gen 16S rRNA confirmó la pertenencia de RF al género *Ruminococcus* (99 % de similitud con *R. flavefaciens* FD-1). Sin embargo, los análisis genómicos mediante TYGS (dDDH) y ANI mostraron valores por debajo de los umbrales de delimitación de especie, incluso frente a *R. flavefaciens* ATCC 19208, lo que indica que RF representa un linaje potencialmente nuevo dentro del género.

- La anotación funcional mediante RAST, KEGG, CAZy, Bakta y dbCAN2 evidenció un repertorio enzimático amplio asociado a la degradación de celulosa, incluyendo glicosil hidrolasas de las familias GH5 y GH9, β-glucosidasas y módulos de unión a carbohidratos, lo que respalda el potencial celulolítico de la cepa.

- La presencia de múltiples dominios dockerina, cohesina, CBM y proteínas tipo scaffoldin, junto con la organización genómica observada, sugiere la existencia de un sistema celulosomal modular y funcional en la cepa RF.

- El análisis comparativo mediante BLASTp mostró que las enzimas catalíticas (GH5 y GH9) presentan conservación funcional media, lo que indica que RF comparte un núcleo celulolítico común con otras cepas de *R. flavefaciens*.

- El destacado potencial celulolítico de la cepa RF abre la puerta a múltiples líneas futuras, como el aislamiento y caracterización estructural de las proteínas GH5 y GH9, y sus interacciones con dockerinas. Esto podría conducir a la identificación de candidatos para futuros productos biotecnológicos o industriales. Así, RF no solo representa una posible nueva especie, sino una plataforma con gran potencial aplicado.

6. Bibliografía

1. FEDEGAN. Plan estratégico de la ganadería colombiana 2019–2032. Bogotá: Federación Colombiana de Ganaderos; 2019.
2. IDEAM, IGAC. Estudio de la oferta y la demanda de los recursos hídricos en Colombia y su relación con la ganadería. Bogotá: Ministerio de Ambiente y Desarrollo Sostenible; 2020.
3. Martínez R, Pérez J, Gallego J, Carvajal R. La raza bovina Lucerna: origen, características y perspectivas. Rev Col Cienc Pec. 2012;25(1):84-95.
4. Ossa JE, Montoya F, Restrepo LF. Reseña histórica y productiva de la raza bovina Hartón del Valle. Rev MVZ Córdoba. 2011;16(1):2385-93.
5. Instituto Colombiano Agropecuario. Inventario bovino nacional por departamento, 2025. Bogotá: Instituto Colombiano Agropecuario (ICA); 2025. Report No.
6. Isaza C, Castañeda A, Rúa C. Variación de la microbiota ruminal en bovinos de diferentes razas bajo dietas contrastantes en Colombia. Rev Col Cienc Pec. 2018;31(3):177-89.
7. Sánchez J, Gutiérrez J, Rincón F. Efecto de la suplementación alimenticia sobre la microbiota ruminal en bovinos del trópico bajo. Corpoica Cienc Tecnol Agropecu. 2017;18(2):287-98.
8. Montoya CA, Arroyave J, Correa HJ. Adaptación de la microbiota ruminal en sistemas de ganadería tropical. Livest Res Rural Dev. 2016;28(12):1-12.
9. Berg Miller ME, Yeoman CJ, Chia N, White BA, Flint HJ, Lamed R, et al. Phylogenetic analysis of the rumen microbiome reveals the influence of bacteriophages on microbial community structure and function. ISME J. 2012;6(10):1949-60. doi:10.1038/ismej.2012.44
10. Flint H, Bayer E, Rincon M, Lamed R, White B. Polysaccharide utilization by gut bacteria: potential for new insights from genomic analysis. Nat Rev Microbiol. 2008;6(2):121-31. doi:10.1038/nrmicro1817
11. Berg Miller M, Antonopoulos D, Rincon M, Band M, Bari A, Akraiko T, et al. Diversity and strain specificity of plant cell wall degrading enzymes revealed by the draft genome of Ruminococcus flavefaciens FD-1. PLoS One. 2009;4(8):e6650. doi:10.1371/journal.pone.0006650
12. Bule P, Pires VMR, Alves VD, Carvalho AL, Prates JAM, Ferreira LMA, et al. Higher order scaffoldin assembly in Ruminococcus flavefaciens cellulosome is coordinated by a discrete cohesin-dockerin interaction. Sci Rep. 3 de mayo de 2018;8(1):6987. doi:10.1038/s41598-018-25171-8
13. Rincon MT; Cepeljnik T; Martin JC; Lamed R; Barak Y; Bayer EA; et al. Unconventional mode of attachment of the Ruminococcus flavefaciens cellulosome to the cell surface. J Bacteriol. 2009;191(13):4215-25. doi:10.1128/JB.01657-08
14. Dassa B; Borovok I; Ruimy-Isaacson V; Lamed R; Flint HJ; Duncan SH; et al. Rumen cellulosomics: divergent fiber-degrading strategies revealed by comparative

genome-wide analysis of six ruminococcal strains. PLoS One. 2014;9(7):e99221. doi:10.1371/journal.pone.0099221
15. Markowiak P, Śliżewska K. Probiotics, prebiotics and synbiotics: gut and beyond. Gut Pathog. 2017;9:21. doi:10.1186/s13099-017-0165-7
16. Uyeno Y, Shigemori S, Shimosato T. Effects of probiotics on growth performance and health status of calves. J Anim Physiol Anim Nutr. 2015;99(1):139-49. doi:10.1111/jpn.12248
17. Chaucheyras-Durand F, Durand H. Probiotics in ruminant nutrition: a review. J Anim Sci Biotechnol. 2010;1(1):1-10. doi:10.1186/2049-1891-1-5
18. Martín E. Manual de laboratorio para el estudio de microorganismos anaerobios obligados [Internet]. 2011. Disponible en: http://hdl.handle.net/20.500.12324/13270
19. Weisburg W, Barns S, Pelletier D, Lane D. 16S ribosomal DNA amplification for phylogenetic study. J Bacteriol. 1991;173(2):697-703. doi:10.1128/jb.173.2.697-703.1991
20. Lane D. 16S/23S rRNA sequencing. En: Stackebrandt E, Goodfellow M, editores. Nucleic acid techniques in bacterial systematics. Chichester: John Wiley & Sons; 1991. p. 115-75.
21. Thijs S, Op De Beeck M, Beckers B, Truyens S, Stevens V, Van Hamme J, et al. Comparative evaluation of four bacteria-specific primer pairs for 16S rRNA gene surveys. Front Microbiol. 2017;8:494. doi:10.3389/fmicb.2017.00494
22. Andrews S. FastQC [Internet]. 0.11.9. 2019. Disponible en: https://www.bioinformatics.babraham.ac.uk/projects/fastqc/
23. Ewels P. MultiQC [Internet]. 1.13. 2022. Disponible en: https://multiqc.info
24. Chen S. fastp [Internet]. 0.23.2. 2023. Disponible en: https://github.com/OpenGene/fastp
25. Bankevich A. SPAdes [Internet]. 3.15.5. 2021. Disponible en: https://cab.spbu.ru/software/spades/
26. Gurevich A. QUAST [Internet]. 5.2.0. 2023. Disponible en: http://quast.sourceforge.net
27. Li H. BWA [Internet]. 0.7.17. 2019. Disponible en: http://bio-bwa.sourceforge.net/
28. Li H. SAMtools [Internet]. 1.15.1. 2022. Disponible en: http://www.htslib.org/
29. García-Alcalde F. Qualimap [Internet]. 2.3. 2016. Disponible en: http://qualimap.conesalab.org/
30. Meier-Kolthoff JP, Göker M. Type Strain Genome Server (TYGS) [Internet]. Vol. 2023. 2023. Disponible en: https://tygs.dsmz.de
31. Meier-Kolthoff JP, Göker M. TYGS is an automated high-throughput platform for state-of-the-art genome-based taxonomy. Nat Commun. 2019;10:2182. doi:10.1038/s41467-019-10210-3
32. Lee I, Ouk Kim Y, Park SC, Chun J. OrthoANI: An improved algorithm and software for calculating average nucleotide identity. Int J Syst Evol Microbiol. 2016;66(2):1100-3. doi:10.1099/ijsem.0.000760
33. Goris J, Konstantinidis KT, Klappenbach JA, Coenye T, Vandamme P, Tiedje JM. DNA-DNA hybridization values and their relationship to whole-genome sequence similarities. Int J Syst Evol Microbiol. 2007;57(1):81-91. doi:10.1099/ijs.0.64483-0

34. Richter M, Rosselló-Móra R. Shifting the genomic gold standard for the prokaryotic species definition. Proc Natl Acad Sci U S A. 2009;106(45):19126-31. doi:10.1073/pnas.0906412106
35. Aziz RK, Bartels D, Best AA, DeJongh M, Disz T, Edwards RA, et al. RAST: Rapid Annotations using Subsystems Technology [Internet]. 2008. Disponible en: https://rast.nmpdr.org/
36. Kanehisa M, Goto S. KEGG: Kyoto Encyclopedia of Genes and Genomes [Internet]. 2000. Disponible en: https://www.kegg.jp
37. Arkin AP, Cottingham RW, Henry CS, Harris NL. KBase: The Department of Energy Systems Biology Knowledgebase [Internet]. 2018. Disponible en: https://kbase.us
38. Schwengers O. Bakta [Internet]. 1.0. 2023. Disponible en: https://github.com/oschwengers/bakta
39. Anaconda Inc. Conda [Internet]. Vol. 22. 2022. Disponible en: https://docs.conda.io/
40. Yoo A. SLURM Workload Manager [Internet]. Vol. 23. 2023. Disponible en: https://slurm.schedmd.com/
41. Zhang H. dbCAN2 [Internet]. 3.0.2. 2022. Disponible en: https://bcb.unl.edu/dbCAN2/
42. Eddy S. HMMER [Internet]. 3.3. 2020. Disponible en: http://hmmer.org/
43. Buchfink B. DIAMOND [Internet]. 2.0. 2021. Disponible en: https://github.com/bbuchfink/diamond
44. Teufel F. SignalP [Internet]. 6.0. 2022. Disponible en: https://services.healthtech.dtu.dk/service.php?SignalP
45. RStudio Team. RStudio [Internet]. 4.0.2. 2020. Disponible en: https://posit.co/
46. Wickham H. tidyverse [Internet]. 2.0.0. 2023. Disponible en: https://www.tidyverse.org/
47. Wickham H. stringr [Internet]. 1.5.1. 2023. Disponible en: https://stringr.tidyverse.org/
48. Wickham H. ggplot2 [Internet]. 3.4.4. 2023. Disponible en: https://ggplot2.tidyverse.org/
49. Rutherford K, Parkhill J, Crook J, Horsnell T, Rice P, Rajandream MA, et al. Artemis: sequence visualization and annotation. Bioinformatics. 2000;16(10):944-5. doi:10.1093/bioinformatics/16.10.944
50. Camacho C, Coulouris G, Avagyan V, Ma N, Papadopoulos J, Bealer K, et al. BLAST+: architecture and applications. BMC Bioinformatics. 2009;10:421. doi:10.1186/1471-2105-10-421
51. Carhuapoma-Delacruz V, Auqui-Acharte G, Valencia-Mamani N, Gonzales-Huamán T, Guillen-Domínguez H, Esparza M. Bacterias fibrolíticas aisladas de rumen de alpaca, ovino y vacuno con capacidad biodegradadora de celulosa. Rev Cient FCV-LUZ. 2022;32:1-12.
52. Mitsumori M. Isolation of cellulolytic bacteria from the rumen. Methods Mol Biol. 2018;1796:57-65. doi:10.1007/978-1-4939-7877-9_5
53. Boonsaen P, Wanapat M, Cherdthong A, Phesatcha K. Isolation and partial characterization of Ruminococcus flavefaciens from the rumen of swamp buffalo. Vet World. 2020;13(6):1082-8. doi:10.14202/vetworld.2020.1082-1088

54. Collins MD, Lawson PA, Willems A, Cordoba JJ, Fernandez-Garayzabal J, Garcia P. Phylogenetic analysis of the genus Ruminococcus and related bacteria. Int J Syst Bacteriol. 1994;44(4):812-26. doi:10.1099/00207713-44-4-812
55. Parks DH, Chuvochina M, Waite DW, Rinke C, Skarshewski A, Chaumeil PA, et al. A standardized bacterial taxonomy based on genome phylogeny substantially revises the tree of life. Nat Biotechnol. 2018;36(10):996-1004. doi:10.1038/nbt.4229
56. Biddle A, Stewart L, Blanchard J, Leschine S. Untangling the genetic basis of fibrolytic specialization by Lachnospiraceae and Ruminococcaceae in the rumen. Front Microbiol. 2013;4:368. doi:10.3389/fmicb.2013.00368
57. Jain C, Rodriguez-R LM, Phillippy AM, Konstantinidis KT, Aluru S. High throughput ANI analysis of 90,000 prokaryotic genomes reveals clear species boundaries. Nat Commun. 2018;9:5114. doi:10.1038/s41467-018-07641-9
58. Bayer EA, Shoham Y, Lamed R. Cellulosomes—multienzyme machines for degradation of plant cell wall polysaccharides. Annu Rev Microbiol. 2006;60:529-82. doi:10.1146/annurev.micro.60.080805.142223
59. Henderson G, Cox F, Ganesh S, Jonker A, Young W, Janssen PH. Rumen microbial community composition varies with diet and host, but a core microbiome is found across a wide geographical range. Sci Rep. 2015;5:14567. doi:10.1038/srep14567
60. Russell J, Wallace R. Energy-yielding and energy-consuming reactions. En: Hobson P, Stewart C, editores. The rumen microbial ecosystem. 2.ª ed. Dordrecht: Springer; 1997. p. 246-82. doi:10.1007/978-94-009-1453-7_8
61. Thapa B, Li H, Jin Y, Zhang X. Exploring the microbial diversity and characterization of cellulase and xylanase genes in goat rumen. BMC Biotechnol. 2023;23(1):74. doi:10.1186/s12896-023-00821-6
62. Lynd LR, Weimer PJ, van Zyl WH, Pretorius IS. Microbial cellulose utilization: fundamentals and biotechnology. Microbiol Mol Biol Rev. 2002;66(3):506-77. doi:10.1128/MMBR.66.3.506-577.2002
63. Himmel ME, Ding SY, Johnson DK, Adney WS, Nimlos MR, Brady JW, et al. Biomass recalcitrance: engineering plants and enzymes for biofuels production. Science. 2007;315(5813):804-7. doi:10.1126/science.1137016
64. Horn SJ, Vaaje-Kolstad G, Westereng B, Eijsink VGH. Novel enzymes for the degradation of cellulose. Biotechnol Biofuels. 2012;5:45. doi:10.1186/1754-6834-5-45
65. Doerner KC, Howard GT, Mackie RI, White BA. β-Glucanase expression by Ruminococcus flavefaciens FD-1. FEMS Microbiol Lett. 1992;93(2):147-53. doi:10.1111/j.1574-6968.1992.tb05081.x
66. Dai X, Tian Y, Li J, Su X, Wang X, Zhao S. Metatranscriptomic analyses of plant cell wall polysaccharide degradation by microorganisms in the cow rumen. Appl Env Microbiol. 2015;81(4):1375-86. doi:10.1128/AEM.03682-14
67. Fontes CM, Gilbert HJ. Cellulose degradation by Clostridium thermocellum and Ruminococcus albus: Is there a «celulosome» or a «cellulosome-like» mechanism? Crit Rev Microbiol. 2010;36(4):309-32.
68. Zheng J, Ge Q, Yan J, Zhang X, Huang L, Yin Y. dbCAN3: automated carbohydrate-active enzyme annotation. Nucleic Acids Res. 2023;51(W1):W115-21.
69. Boraston AB, Bolam DN, Gilbert HJ, Davies GJ. Carbohydrate-binding modules: structure, function, and exploitation. Annu Rev Biochem. 2004;73:507-47.

70. Brulc JM, Antonopoulos DA, Berg Miller ME, Wilson MK, Yannarell AC, Dinsdale EA. Gene-centric metagenomics of the fiber-adherent bovine rumen microbiome reveals forage specific glycoside hydrolases. Proc Natl Acad Sci U A. 2009;106(6):1948-53. doi:10.1073/pnas.080619110
71. Fontes CMGA, Gilbert HJ. Cellulosomes: highly efficient nanomachines designed to deconstruct plant cell wall complex carbohydrates. Annu Rev Biochem. 2010;79:655-81. doi:10.1146/annurev-biochem-091208-085603
72. Artzi L, Bayer EA, Moraïs S. Cellulosomes: bacterial nanomachines for dismantling plant polysaccharides. Nat Rev Microbiol. 2017;15(2):83-95. doi:10.1038/nrmicro.2016.164
73. Ding SY, Bayer EA, Steiner D, Shoham Y, Lamed R. A novel cellulosome architecture revealed by genomic analysis of Clostridium thermocellum. J Bacteriol. 2000;182(13):3934-43. doi:10.1128/JB.182.13.3934-3943.2000
74. Morrison M, Pope PB, Denman SE, McSweeney CS. Plant biomass degradation by gut microbiomes: more of the same or something new? Curr Opin Biotechnol. 2009;20(3):358-63. doi:10.1016/j.copbio.2009.05.004
75. Thomas F, Barbeyron T, Michel G. Genomic adaptations underlying plant polysaccharide utilization by gut bacteria. Curr Opin Microbiol. 2011;14(3):301-7. doi:10.1016/j.mib.2011.04.006

ANEXOS

ANEXO 1

Para asegurar la transparencia y reproducibilidad de los análisis realizados en esta tesis, se presenta a continuación la documentación completa del pipeline bioinformático utilizado. Esto incluye la estructura metodológica, los scripts empleados y las evidencias de los resultados obtenidos.

El pipeline completo está disponible en Notion en el siguiente enlace→ https://www.notion.so/Pipeline_RF-26f983d81fab80bba666fbf1f3cc85e1?source=copy_link

ANEXO 2

TYPE (STRAIN) GENOME SERVER

JOB SUMMARY

PRINT DATE:	2025-01-17 16:40:39 +0100
JOB ID:	a206ea7b-a389-487f-a8ea-eddf590007d9
RESULT PAGE:	https://tygs.dsmz.de/user_results/show?guid=a206ea7b-a389-487f-a8ea-eddf590007d9

Table 1: Phylogenies

Publication-ready versions of both the genome-scale GBDP tree and the 16S rRNA gene sequence tree can be customized and exported either in SVG (vector graphic) or PNG format from within the phylogeny viewers in your TYGS result page. For publications the **SVG format is recommended** because it is lossless, always keeps its high resolution and can also be easily converted to other popular formats such as PDF or EPS. Please follow the link provided above!

Table 2: Identification

The below list contains the result of the TYGS species identification routine.

Explanation of remarks that might occur in the below table:

remark [R1]: The TYGS type strain database is automatically updated on an almost daily basis. However, if a particular type strain genome is not available in the TYGS database, this can have several reasons which are detailed in the FAQ. You can request an extended 16S rRNA gene analysis via the 16S tree viewer found in your result page to detect **not yet genome-sequenced** type strains relevant for your study.

remark [R2]: > 70% dDDH value (formula d_4) and (almost) minimal dDDH values for gene-content formulae d_0 and d_6 indicate a potentially unreliable identification result and should thus be checked via the 16S rRNA gene sequence similarity. Such strong deviations can, in principle, be caused by sequence contamination.

remark [R3]: G+C content difference of > 1 % indicates a potentially unreliable identification result because within species G+C content varies no more than 1 %, if computed from genome sequences (PMID: 24505073).

Strain	Conclusion	Identification result	Remark
'final_contigs_Hiseq_RF'	potential new species		see [R1]

Table 3: Pairwise comparisons of user genomes vs. type-strain genomes

The following table contains the pairwise dDDH values between your user genomes and the selected type-strain genomes. The dDDH values are provided along with their confidence intervals (C.I.) for the three different GBDP formulas:

- formula d_0 (a.k.a. GGDC formula 1): length of all HSPs divided by total genome length
- formula d_4 (a.k.a. GGDC formula 2): sum of all identities found in HSPs divided by overall HSP length
- formula d_6 (a.k.a. GGDC formula 3): sum of all identities found in HSPs divided by total genome length

Note: Formula d_4 is independent of genome length and is thus robust against the use of incomplete draft genomes. For other reasons for preferring formula d_4, see the FAQ.

Query	Subject	d_0	C.I. d_0	d_4	C.I. d_4	d_6	C.I. d_6	Diff. G+C Percent
'final_contigs_Hiseq_RF.fasta'	*Candidatus* Merdibacter merdavium CHK187-11901	12.5	[9.8 - 15.7]	31.1	[28.7 - 33.6]	12.9	[10.6 - 15.6]	7.73
'final_contigs_Hiseq_RF.fasta'	*Caproicibacter fermentans* DSM 107079 T	12.5	[9.9 - 15.8]	30.7	[28.3 - 33.2]	12.9	[10.6 - 15.7]	6.13
'final_contigs_Hiseq_RF.fasta'	*Butyricicoccus porcorum* DSM 104997	12.6	[9.9 - 15.9]	25.8	[23.5 - 28.3]	13.0	[10.7 - 15.7]	7.46
'final_contigs_Hiseq_RF.fasta'	*Angelakisella massiliensis* Marseille-P3217	12.6	[9.9 - 15.8]	25.3	[23.0 - 27.8]	13.0	[10.6 - 15.7]	8.03
'final_contigs_Hiseq_RF.fasta'	*Jeotgalibacillus alimentarius* YKJ-13	12.5	[9.8 - 15.8]	25.2	[22.9 - 27.7]	12.9	[10.6 - 15.7]	1.97
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus albus* 7	13.2	[10.5 - 16.5]	24.9	[22.6 - 27.4]	13.6	[11.2 - 16.4]	1.48
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus albus* DSM 20455	13.2	[10.4 - 16.5]	24.7	[22.4 - 27.2]	13.5	[11.2 - 16.3]	1.48
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus bicirculans* 80/3	12.9	[10.2 - 16.2]	23.7	[21.4 - 26.1]	13.3	[10.9 - 16.0]	2.47
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus flavefaciens* ATCC 19208	15.7	[12.8 - 19.2]	23.5	[21.2 - 26.0]	15.9	[13.3 - 18.8]	1.92
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus callidus* ATCC 27760	12.8	[10.1 - 16.0]	23.2	[20.9 - 25.6]	13.1	[10.8 - 15.9]	3.98
'final_contigs_Hiseq_RF.fasta'	*Ruminococcus champanellensis* 18P13	12.9	[10.2 - 16.2]	23.1	[20.8 - 25.6]	13.3	[10.9 - 16.0]	8.35
'final_contigs_Hiseq_RF.fasta'	*Clostridium methylpentosum* DSM 5476	12.5	[9.9 - 15.8]	21.9	[19.6 - 24.3]	12.9	[10.6 - 15.7]	6.72
'final_contigs_Hiseq_RF.fasta'	*Anaerocolumna xylanovorans* DSM 12503	12.5	[9.8 - 15.8]	21.4	[19.1 - 23.8]	12.9	[10.6 - 15.6]	4.95
'final_contigs_Hiseq_RF.fasta'	*Cryobacterium melibiosiphilum* CGMCC 1.11212	12.5	[9.8 - 15.7]	21.1	[18.9 - 23.6]	12.9	[10.6 - 15.6]	21.76
'final_contigs_Hiseq_RF.fasta'	*Arthrobacter halodurans* DSM 21081	12.5	[9.8 - 15.7]	20.4	[18.2 - 22.8]	12.9	[10.6 - 15.6]	26.4
'final_contigs_Hiseq_RF.fasta'	*Ligaoa zhengdingensis* NSJ-31	12.5	[9.9 - 15.8]	19.6	[17.4 - 22.0]	12.9	[10.6 - 15.7]	11.94

Table 4: Strains in your dataset

Joint dataset of automatically determined closest type strains (if this mode was chosen), manually selected type strains (if selected accordingly) and the provided user strains, if provided (marked in yellow).

Strain	Authority	Other deposits	Synonyms	Base pairs	Percent G+C	No. proteins	Goldstamp	Bioproject accession	Biosample accession	Assembly accession	IMG OID
Ligaoa zhengdingensis NSJ-31	Liu et al. 2022	CGMCC 1.32804; KCTC 25083	*Ligaoa zhengdingensis*	2945 529	57.0	2688		PRJNA656402	SAMN15805174	GCA_014384885	
Angelakisella massiliensis Marseille-P3217	Mailhe et al. 2017	CSUR P3217	*Angelakisella massiliensis*	4040 678	53.1	3792	Gp0316959	PRJEB16361	SAMEA4519310	GCA_900104675	
Candidatus Merdibacter merdavium CHK187-11901	Gilroy et al. 2021		*Candidatus* Merdibacter merdavium	2123 460	52.8	1943		PRJNA543206	SAMN15816582	GCA_019119715	
Cryobacterium melibiosiphilum CGMCC 1.11212	Liu et al. 2019	NBRC 107884; Hh39	*Cryobacterium melibiosiphilum*	4710 997	66.9	4219		PRJNA492816	SAMN10106139	GCA_003602235	
Ruminococcus flavefaciens ATCC 19208	Sijpesteijn 1948		*Ruminococcus flavefaciens*	3581 378	43.2	3094	Gp0032043	PRJNA204092	SAMN02584965	GCA_000518765	2546825524
Ruminococcus albus DSM 20455	Hungate 1957	7; ATCC 27210; DSM 20455; JCM 14654	*Ruminococcus albus*	4326 490	43.6	3957	Gp0013235	PRJNA221059	SAMN02743985	GCA_000621285	2558860976
Butyricicoccus porcorum DSM 104997	Trachsel et al. 2018	ATCC TSD-102; BB10	*Butyricicoccus porcorum*	2896 625	52.6	2811		PRJNA224116	SAMN06279795	GCF_002157465	
Anaerocolumna xylanovorans DSM 12503	(Mechichi et al. 2000) Ueki et al. 2016	JCM 31057; HESP1	*Anaerocolumna xylanovorans*; *Clostridium xylanovorans*	5415 301	40.1	4656	Gp0013642	PRJNA245658	SAMN02745217	GCA_900143645	2582580727
Ruminococcus albus 7	Hungate 1957	7; ATCC 27210; DSM 20455; JCM 14654	*Ruminococcus albus*	4482 087	43.6	3872	Gp0006447	PRJNA42255	SAMN00016988	GCA_000179635	649633094

Strain	Authority	Other deposits	Synonyms	Base pairs	Percent G+C	No. proteins	Goldstamp	Bioproject accession	Biosample accession	Assembly accession	IMG OID
Jeotgalibacillus alimentarius YKJ-13	Yoon et al. 2001	DSM 18867; JCM 10872; KCCM 80002	*Jeotgalibacillus alimentarius*	3364 745	43.1	3533	Gp0106222	PRJNA259403	SAMN03005142	GCA_000829445	
Ruminococcus callidus ATCC 27760	Holdeman and Moore 1974	VPI 57-31	*Ruminococcus callidus*	3070 687	49.1	3475	Gp0000917	PRJNA18185	SAMN00627105	GCA_000468015	
Ruminococcus bicirculans 80/3	Wegmann et al. 2014		*Ruminococcus bicirculans*	2968 500	42.6	2585		PRJEA88543	SAMEA3139031	GCA_000723465	
Ruminococcus champanellensis 18P13	Chassard et al. 2012	DSM 18848; JCM 17042	*Ruminococcus champanellensis*	2513 381	53.4	2114	Gp0004519	PRJNA39179	SAMEA3138364	GCA_000210095	
Arthrobacter halodurans DSM 21081	Chen et al. 2012	KCTC 19430; JSM 78085	*Arthrobacter halodurans*	3714 898	71.5	3405		PRJNA1156031	SAMN43478435	GCA_041877255	
Caproicibacter fermentans DSM 107079 T	Flaiz et al. 2020	JCM 33110; EA1	*Caproicibacter fermentans*	3880 654	51.2	3702		PRJNA224116	SAMN11585615	GCF_009746625	
Clostridium methylpentosum DSM 5476	Himelbloom and Canale-Parola 1989	ATCC 43829; R2	*Clostridium methylpentosum*	3406 326	51.8	3907	Gp0003366	PRJNA30029	SAMN00008812	GCA_000158655	643886206
final_contigs_Heq_RF.fasta				4536 098	45.1	4159					

Methods, Results and References

The genome sequence data were uploaded to the Type (Strain) Genome Server (TYGS), a free bioinformatics platform available under https://tygs.dsmz.de, for a whole genome-based taxonomic analysis [1]. The analysis also made use of recently introduced methodological updates and features [2]. Information on nomenclature, synonymy and associated taxonomic literature was provided by TYGS's sister database, the List of Prokaryotic names with Standing in Nomenclature (LPSN, available at https://lpsn.dsmz.de) [2]. The results were provided by the TYGS on 2025-01-14. The TYGS analysis was subdivided into the following steps:

Determination of closely related type strains

The determination of closely related type strains did not succeed because not a single 16S rDNA gene sequence was detected in the provided user genomes. The subsequent analyses are thus only based on the provided genome data and the manually selected type strains, if any.

Pairwise comparison of genome sequences

For the phylogenomic inference, all pairwise comparisons among the set of genomes were conducted using GBDP and accurate intergenomic distances inferred under the algorithm 'trimming' and distance formula d_5 [3]. 100 distance replicates were calculated each. A second GBDP phylogenomic analysis was inferred using the amino acid sequences of the entire proteome, promising a better resolved phylogeny in datasets of only remotely related strains. Digital DDH values and confidence intervals were calculated using the recommended settings of the GGDC 4.0 [2,3].

Phylogenetic inference

The resulting intergenomic distances were used to infer a balanced minimum evolution tree with branch support via FASTME 2.1.6.1 including SPR postprocessing [4]. Branch support was inferred from 100 pseudo-bootstrap replicates each. The trees were rooted at the midpoint [5] and visualized with PhyD3 [6].

Type-based species and subspecies clustering

The type-based species clustering using a 70% dDDH radius around each of the 16 type strains was done as previously described [1]. The resulting groups are shown in Table 1 and 4. Subspecies clustering was done using a 79% dDDH threshold as previously introduced [7].

Results

Type-based species and subspecies clustering

The resulting species and subspecies clusters are listed in Table 4, whereas the taxonomic identification of the query strains is found in Table 1. Briefly, the clustering yielded 16 species clusters and the provided query strains were assigned to 1 of these. Moreover, user strains were located in 1 of 16 subspecies clusters.

Figure caption genome tree

Figure 2. Tree inferred with FastME 2.1.6.1 [4] from GBDP distances calculated from genome sequences. The branch lengths are scaled in terms of GBDP distance formula d_5. The numbers above branches are GBDP pseudo-bootstrap support values > 60 % from 100 replications, with an average branch support of 43.1 %. The tree was rooted at the midpoint [5].

Figure caption proteome tree

Figure 3. Tree inferred with FastME 2.1.6.1 [4] from whole-proteome-based GBDP distances. The branch lengths are scaled via GBDP distance formula d_5. Branch values are GBDP pseudo-bootstrap support values > 60 % from 100 replications, with an average branch support of 98.0 %. The tree was midpoint-rooted [5].

References

[1] Meier-Kolthoff JP, Göker M. TYGS is an automated high-throughput platform for state-of-the-art genome-based taxonomy. Nat. Commun. 2019;10: 2182. DOI: 10.1038/s41467-019-10210-3

[2] Meier-Kolthoff JP, Sardà Carbasse J, Peinado-Olarte RL, Göker M. TYGS and LPSN: a database tandem for fast and reliable genome-based classification and nomenclature of prokaryotes. Nucleic Acid Res. 2022;50: D801–D807. DOI: 10.1093/nar/gkab902

[3] Meier-Kolthoff JP, Auch AF, Klenk H-P, Göker M. Genome sequence-based species delimitation with confidence intervals and improved distance functions. BMC Bioinformatics. 2013;14: 60. DOI: 10.1186/1471-2105-14-60

[4] Lefort V, Desper R, Gascuel O. FastME 2.0: A comprehensive, accurate, and fast distance-based phylogeny inference program. Mol Biol Evol. 2015;32: 2798–2800. DOI: 10.1093/molbev/msv150

[5] Farris JS. Estimating phylogenetic trees from distance matrices. Am Nat. 1972;106: 645–667.

[6] Kreft L, Botzki A, Coppens F, Vandepoele K, Van Bel M. PhyD3: A phylogenetic tree viewer with extended phyloXML support for functional genomics data visualization. Bioinformatics. 2017;33: 2946–2947. DOI: 10.1093/bioinformatics/btx324

[7] Meier-Kolthoff JP, Hahnke RL, Petersen J, Scheuner C, Michael V, Fiebig A, et al. Complete genome sequence of DSM 30083^T, the type strain (U5/41^T) of *Escherichia coli*, and a proposal for delineating subspecies in microbial taxonomy. Stand Genomic Sci. 2014;9: 2. DOI: 10.1186/1944-3277-9-2