# Diversidad genómica de “Influenza B” en diferentes regiones climáticas: análisis de variantes y patrones de mutación mediante datos de secuenciación pública.

Titulación:
Máster Universitario en Bioinformática
Curso académico
2025 – 2026

Alumno/a: Ramirez Mendoza, Melissa
D.N.I: 0801-1993-19453

Director/a de TFM: Laura Sabater Olivas

Convocatoria:

Primera

6 marzo 2026

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

# Índice

1. Introducción ..... 6
2. Objetivos ..... 20
   2.1 Objetivo general ..... 20
   2.2 Objetivos específicos ..... 20
3. Metodología ..... 20
4. Resultados y discusión ..... 41
5. Conclusiones ..... 55
6. Referencias bibliográficas ..... 56
7. Anexos ..... 60

## Lista de abreviaturas

**AC:** Allele Count

**BAM:** Binary Alignment/Map

**BWA:** Burrows-Wheeler Aligner

**CDC:** Centers for Disease Control and Prevention

**DP:** Depth of Coverage

**ENA:** European Nucleotide Archive

**FASTQ:** Formato de archivo para secuencias con calidad Phred

**HA:** Hemaglutinina

**IGV:** Integrative Genomics Viewer

**IQ-TREE:** Software para inferencia filogenética por máxima verosimilitud

**MAPQ:** Mapping Quality

**MAFFT:** Multiple Alignment using Fast Fourier Transform

**ML:** Maximun Likelihood (Maxima verosimilitud)

**NA:** Neuraminidasa

**NCBI**: National Center for Biotechnology Information

**NP:** Nucleoproteína

**PA:** Polymerase Acidic protein

**PB1/PB2:** Polymerase Basic proteins 1 y 2

**QUAL:** Quality score de variante

**SNP:** single Nucleotide Polymorphism

**SRA:** Sequence Read Archive

**VCF:** Variant Call Format

## Índice de figuras

**Figura 1** Organización genómica y estructural del virus de la influenza B. El genoma viral está compuesto por ocho segmentos de ARN monocatenario de sentido negativo que codifican las principales proteínas estructurales y no estructurales del virus, incluyendo el complejo de la polimerasa (PB1, PB2 y PA), hemaglutinina (HA), nucleoproteína (NP), neuraminidasa (NA), proteínas de matriz (M1, BM2) y proteínas no estructurales. La figura muestra de forma esquemática la localización y función general de estas partículas en la partícula viral. Fuente: tomado de Ashraf el al., Frontiers in Microbiology, 2024. .....8

**Figura 2** Representación de los niveles de clasificación genética del virus de la influenza B. Elaboración propia basada en CDC. .....11

**Figura 3** Esquema del procesamiento bioinformático para el alineamiento de lecturas frente al genoma de referencia. .....34

**Figura 4** Divergencia genética del virus de la influenza B por muestra, expresada como número total de SNPs respecto al genoma de referencia (linaje Yamagata). La escala cromática representa de manera continua el grado de variabilidad, permitiendo distinguir visualmente divergencia baja de 117-186, intermedia de 385-410 y alta de 739-823 SNPs. .....44

**Figura 5** Densidad de SNPs por segmento genómico del virus de la influenza B, expresada como SNPs por kilobase (SNP/kb). La escala cromática indica la magnitud relativa de variabilidad genética por segmento, con mayor densidad en HA (150 SNP/kb) y menor en NP (58 SNP/kb). .....45

**Figura 6** Visualización en IGV del alineamiento de lecturas correspondiente a la posición 129 del segmento HA del virus de la influenza B. Se observa la sustitución C→T, evidenciada por la presencia del alelo alternativo en múltiples lecturas alineadas. Profundidad de cobertura en la región señalada. Los colores representan las bases nucleotídicas según codificación estándar en IGV y la escala superior la posición genómica en pares de bases. .....47

**Figura 7** Comparación del número total de SNPs por categoría climática según la clasificación de Köppen-Geiger. El grupo templado presenta mayor dispersión en los valores de divergencia genética, mientras que el grupo tropical muestra valores más homogéneos y elevados. Las muestras de clima árido exhiben menor variabilidad relativa. El análisis estadístico mediante Kruskal-Wallis no mostró diferencias estadísticamente significativas entre categorías (p = 0.05768). .....48

**Figura 8** Árbol filogenético construido a partir del alineamiento múltiple de las secuencias consenso completas del virus de la influenza B (Yamagata). Los colores de las etiquetas corresponden a la clasificación climática de Köppen-Geiger. La escala horizontal representa el número de sustituciones por grupo. .....49
**Figura 9** Árbol filogenético construido a partir del alineamiento múltiple de las secuencias consenso completas del virus de la influenza B (Yamagata). Los colores de las etiquetas están coloreados según el continente de procedencia. La escala horizontal indica la distancia genética expresada como sustituciones por grupo. .....50

## Índice de tablas

**Tabla 1.** Clasificación köpper-Geiger en base a región climática y a país. .....26
**Tabla 2.** Especificaciones técnicas y procedencia bio-geográfica de los 16 datasets de influenza B linaje Yamagata, seleccionados para el estudio. .....28
**Tabla 3** Resumen de la calidad por muestra: porcentaje de mapeo al genoma de referencia y proporción del genoma con cobertura ≥ 200X. .....43
**Tabla 4**. Variantes representativas identificadas en el análisis de frecuencia del archivo VCF multi-muestra. .....46

## Anexos

**Anexo 1** Métricas de calidad, mapeo y cobertura obtenida para cada dataset evaluado. Se presentan valores de lecturas iniciales, lecturas supervivientes tras filtrado con fastp, calidad media (Q30, evaluación de calidad por base, porcentaje de lecturas alineadas al genoma de referencia y porcentaje del genoma con cobertura >200X, indicando si cada muestra fue incluida o excluida del análisis final. .....60
**Anexo 2.** Resumen de los principales comandos utilizados en el pipeline bioinformático para el procesamiento, filtrado, llamado de variantes e inferencia filogenética de las secuencias del virus de influenza B (linaje Yamagata). Comandos completos utilizados en entorno Linux (Ubuntu) se representan con fines de reproducibilidad. .....63

## Resumen

El virus de la influenza B del linaje Yamagata ha sido históricamente un componente relevante de la influenza estacional, se encuentra caracterizado por una evolución genética progresiva y una amplia distribución geográfica (1). Aunque no se ha documentado circulación sostenida del linaje Yamagata a nivel global desde 2020, este continúa siendo objeto de vigilancia epidemiológica internacional debido a la ausencia de declaración formal de extinción, su relevancia epidemiológica y formulación vacunal por reemergencia del linaje (2).

Este trabajo tuvo como objetivo caracterizar la variabilidad genómica del virus de la influenza B (Yamagata), mediante análisis comparativo de 16 datasets públicos obtenidos de repositorios de renombre internacional. Se realizó el alineamiento contra genoma de referencia B/Alaska/25/2015, seguido del llamado de variantes multi-muestra y filtrado de alta confianza (QUAL>30; DP>200). Se evaluó la carga de polimorfismos por muestra, la distribución segmentaria de SNPs normalizados por kilo base y la frecuencia de variantes compartidas entre los diferentes datasets. Posteriormente se llevó a cabo un análisis filogenético por máxima verosimilitud a partir de las secuencias consenso completas, incorporando en la evaluación la estratificación climática y geográfica.

Los resultados evidenciaron una variabilidad considerable entre muestras, con diferencias en el número total de SNPs respecto al genoma de referencia. Se identificaron variantes fijas en los 16 datasets, variantes de alta frecuencia y variantes recurrente, destacando la mayor parte de las sustituciones en el segmento HA, gen que codifica la hemaglutinina, principal determinante antigénico viral (3). El análisis filogenético mostró presencia de dos agrupamientos principales definidos por su distancia genética sin una segregación estricta por clima o continente, lo que sugiere circulación interregional y acumulación progresiva de mutaciones. En general estos hallazgos reflejan distintos niveles de conservación y divergencia dentro del linaje Yamagata y aportan información relevante para la comprensión de la dinamita evolutiva durante los años de los datasets incluidos en este trabajo.



## Palabras clave

*Influenza B; Yamagata; diversidad genética; variabilidad climática; bioinformática; Hemaglutinina; Polimorfismo de nucleótido simple; vigilancia genómica.*

# 1. Introducción

## 1.1 Virus de la influenza y su impacto en la salud pública

La influenza es una infección respiratoria aguda de origen viral que representa uno de los principales retos recurrentes para la salud pública, tanto en las Américas como en el resto del mundo. A pesar de la disponibilidad de programas de vacunación el virus continua generando epidemias estacionales anuales las cuales afectan de manera significativa a la población en general con impacto especialmente elevado en los grupos vulnerables como niños, personas mayores y en pacientes con enfermedades crónicas (4,5). Su alta transmisibilidad favorece altamente la rápida propagación en la comunidad traduciéndose en un aumento de consultas médicas, hospitalizaciones y en los casos más graves mortalidad asociada a la enfermedad.  Se caracteriza por su alta transmisibilidad y por la aparición de epidemias estacionales que generan una elevada carga de morbilidad y mortalidad cada año (6,7).

El agente etiológico de la influenza pertenece a la familia *Orthomyxoviridae,* la cual agrupa virus con genoma segmentado de ARN de cadena negativa. Dentro de esta familia los virus de la influenza A y B son los principales responsables de las infecciones humanas y de las epidemias estacionales observadas cada año. Aunque ambos tipos virales comparten características estructurales y mecanismos de transmisión similares estos presentan diferencias relevantes en términos de epidemiología como lo son reservorios y dinámica evolutiva lo cual condiciona su comportamiento a nivel poblacional (8).

Desde el punto de vista epidemiológico, la influenza presenta un patrón de circulación bien definido, cuya manifestación varía según la región geográfica, así como las condiciones climáticas locales, es decir, en regiones templadas, la actividad del virus suele concentrarse durante los meses de invierno, mientras que en regiones tropicales y subtropicales la circulación del virus se puede mantener a lo largo del año o intensificarse durante la temporada de lluvias. Diversos estudios han demostrado que los factores ambientales como la temperatura y la humedad

influyen de forma significativa en la estabilidad del virus así como en la transmisibilidad, siendo más eficiente en climas fríos y secos (9).

El impacto de la influenza en la salud pública a nivel global no se limita únicamente a la clínica directa sino a las epidemias estacionales las que suponen una presión considerable sobre los sistemas sanitarios y la sostenibilidad de la vigilancia debido al incremento de la demanda asistencial y al consumo de los recursos médicos durante los periodos de mayor circulación viral. En tal contexto, la organización panamericana de la Salud estima que las epidemias estacionales de influenza causan millones de casos graves y cientos de miles de muertes cada año a nivel global, lo que da peso e importancia en la relevancia sanitaria y social de esta infección (10).

Uno de los principales desafíos en el control de la influenza radica en la adaptación y la persistencia en la población humana a lo largo del tiempo. Esta capacidad de cambio contribuye a la aparición recurrente de casos y limita la eficacia a largo plazo de las estrategias preventivas aplicadas como las brigadas de vacunación anuales, por ello, la vigilancia epidemiológica y genómica del virus se convierte en un componente esencial de los programas de salud pública, permitiendo monitorizar la circulación, analizar subtipos de interés, detectar cambios relevantes y de importancia clínica urgente, mejorando la comprensión de su comportamiento evolutivo (10).

### 1.2 Influenza B: características y relevancia epidemiológica

A diferencia del virus de la influenza A, el cual es ampliamente estudiado debido a su capacidad para originar pandemias estacionales y a la existencia de múltiples reservorios animales, el virus de la influenza B ha recibido históricamente menos atención científica. Esta menor visibilidad ha contribuido a un conocimiento más limitado sobre la dinámica evolutiva, la diversidad genética así como al comportamiento epidemiológico a pesar de tener una alta relevancia clínica y sanitaria, por lo cual, a nivel mundial ha incrementado la relevancia de reconocer la necesidad de mejorar la vigilancia en la prevención de la infección por el virus de la influenza B (11,12).

El virus de la influenza B infecta principalmente a humanos y presenta un genoma segmentado compuesto por ocho segmentos de ARN monocatenario de polaridad negativa, cada uno asociado a nucleoproteínas y al complejo de la polimerasa viral, dicha organización genómica permite la codificación de proteínas estructurales y no estructurales esenciales para el ciclo replicativo del virus, incluyendo las subunidades de la polimerasa (PB2, PB1 y PA), las glicoproteínas de superficie como la hemaglutinina (HA), la neuraminidasa (NA), la proteína de matriz (M1) y las no estructurales NS1 y NEP. A diferencia de la influenza A, el virus de la influenza B codifica además proteínas específicas como lo son NB y BM2, estas participan en procesos de ensamblaje y liberación viral. La segmentación del genoma facilita la generación de diversidad genética mediante diferentes mecanismos como ser, la acumulación de mutaciones las cuales contribuyen a la variabilidad observada entre cepas circulantes. La *Figura 1* muestra un esquema representativo de la organización genómica del virus de la influenza B (13,14).

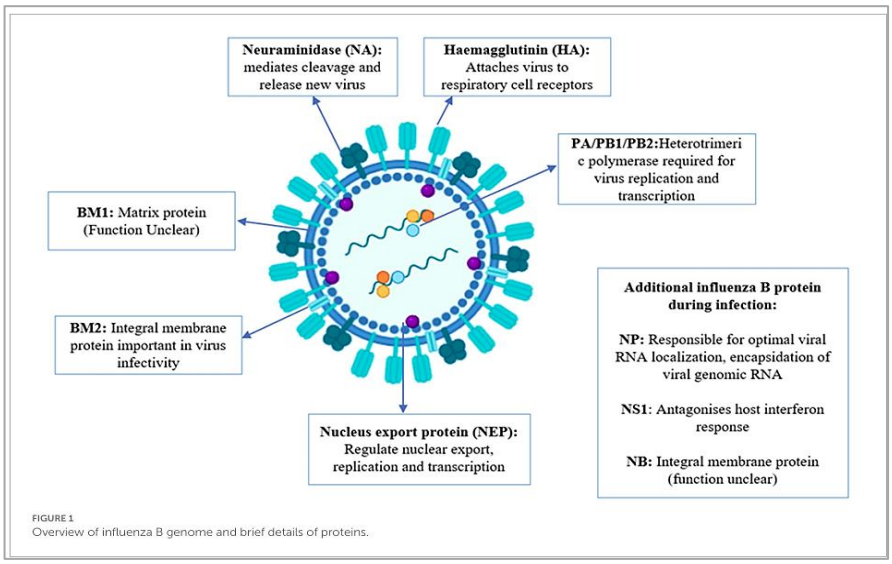


***Figura 1*** Organización genómica y estructural del virus de la influenza B. El genoma viral está compuesto por ocho segmentos de ARN monocatenario de sentido negativo que codifican las principales proteínas estructurales y no estructurales del virus, incluyendo el complejo de la polimerasa (PB1, PB2 y PA), hemaglutinina (HA), nucleoproteína (NP), neuraminidasa (NA), proteínas de matriz (M1, BM2) y proteínas no estructurales. La figura muestra de forma esquemática la localización y función general de estas partículas en la partícula viral. Fuente: tomado de Ashraf el al., Frontiers in Microbiology, 2024.

Además de sus características genómicas, el virus de la influenza B presenta diferencias biológicas relevantes especialmente en cuanto a su interacción con el huésped humano ya que hay estudios recientes que han demostrado tropismo

viral en el tracto respiratorio el cual puede variar entre el virus de la influenza A vs influenza B influenciado por las características estructurales específicas de la hemaglutinina y su afinidad diferencial por glicanos del huésped, dichas variaciones podrían condicionar tanto a la eficiencia de la infección como a la dinámica de transmisión del virus (14).

Junto con la influenza A, la influenza tipo B, es una de las causas principales de infecciones respiratorias agudas graves (IRAG) y enfermedad tipo influenza (ETI), estos dos tipos suelen ocurrir de forma simultánea estacional, afectando de forma severa especialmente a niños menores de 5 años, adultos mayores de 65 años, mujeres en estado de embarazo y personas que padecen comorbilidades como ser cardíacas, pulmonares o enfermedades que causan inmunosupresión, aunque la mortalidad en influenza B suele ser menor que en la influenza A, la influenza B es capaz de provocar complicaciones graves como neumonías, complicaciones neurológicas, miocarditis entre otras y estas complicaciones a menudo necesitan hospitalización (15).

Aunque la influenza B no está asociada a eventos pandémicos, su circulación sostenida a lo largo del tiempo y su contribución a la carga global de la enfermedad hacen evidente la necesidad de profundizar en su estudio. En particular, el linaje Yamagata del virus de la influenza B ha sido históricamente un componente relevante de la influenza estacional, con amplia distribución geográfica (16). La menor diversidad en cuanto a los reservorios no implica una menor capacidad de adaptación, ya que el virus continúa acumulando cambios genéticos que pueden afectar su transmisión, su reconocimiento inmunológico y la efectividad de las vacunas. El análisis genómico del virus de la influenza B constituye una herramienta fundamental para comprender su evolución, identificar patrones de variabilidad genética y comprender las estrategias de vigilancia epidemiológica. La incorporación de enfoques bioinformáticos permite abordar estas cuestiones de manera sistemática, facilitando así el estudio comparativo de muestras procedentes de distintas regiones geográficas y contextos climáticos (12).

### 1.3 Variabilidad genética y evolución del virus de la influenza

El virus de la influenza presenta una elevada variabilidad genética como consecuencia de la acumulación de mutaciones progresivas y puntuales en su genoma de ARN, fenómeno que se conoce como deriva antigénica. Este proceso evolutivo se asocia a la actividad de la ARN polimerasa viral, la cual carece de mecanismos de corrección de errores, favoreciendo así la aparición continua de cambios genéticos durante la replicación. En el caso de la influenza B, las mutaciones se concentran principalmente en regiones del genoma sometidas a una mayor presión selectiva, en especial el gen que codifica la hemaglutinina, en donde, los cambios pueden afectar regiones antigénicas clave. La acumulación de mutaciones permite que el virus pueda adaptarse a la respuesta inmunitaria del huésped y contribuir a la reducción de la protección conferida por infecciones previas o por vacunación, dificultando de esta manera el control sostenido de la enfermedad (13).

En cuanto a la dinámica evolutiva del virus de la influenza esta se manifiesta a escala poblacional a través de patrones de circulación estacional, dichos patrones están modulados por factores ambientales y climáticos como es la temperatura y la humedad. En regiones de clima templado, las condiciones invernales, las cuales se caracterizan por las bajas temperaturas y baja humedad, favorecen a la estabilidad del virus en el ambiente haciendo de esta manera su transmisión más eficiente, contribuyendo a una circulación intensa y estacional que permanece en el tiempo. En contraste, en regiones de climas tropicales y subtropicales en donde las variaciones climáticas son menos marcadas, la circulación puede influir en la dinámica evolutiva del virus al modificar la intensidad en la transmisión relacionada a la inmunidad poblacional, la mayor parte de los estudios que han analizado la relación entre el clima, la estacionalidad y la evolución viral se han centrado principalmente en el virus de la influenza A, existiendo un estudio y conocimiento menor sobre como estos factores influyen específicamente en la diversidad genética, la evolución y la circulación del virus de la influenza B en distintos contextos climáticos (9).

El virus de la influenza B se clasifica en dos linajes evolutivos principales; B/Victoria y B/Yamagata. Estos linajes representan las principales variantes

genéticas del virus de la influenza B las cuales han mostrado co-circulación a nivel global en distintas temporadas epidémicas, con variaciones en su predominio según la región geográfica y el periodo temporal. La variabilidad genética entre ambos linajes se centra principalmente en regiones específicas del genoma, las cuales son sometidas a una elevada presión selectiva, en particular el gen que codifica la hemaglutinina, donde los cambios o mutaciones pueden modificar regiones relevantes, los cambios producto de estas modificaciones tienen implicaciones directas en el reconocimiento inmunológico del virus y en la efectividad de la inmunización por vacunas, implicando así, la necesidad en el seguimiento continuo de linajes circulantes en los programas de vigilancia genómica y de esta manera poder detectar patrones de brotes y temporadas de aparición de nuevos casos estacionales (12,13).

Dentro de cada uno de los dos linajes de influenza B y en cuanto a la diversidad genética el virus se organiza en clados y subclados, estos son definidos a partir de la acumulación de mutaciones específicas, la clasificación es jerárquica y está establecida mediante análisis filogenéticos permitiendo describir con mayor precisión la evolución del virus y su diversificación a lo largo del tiempo. El estudio y seguimiento de clados facilita la identificación de variantes circulantes y la detección de cambios genéticos relevantes, especialmente aquellos que pueden dar lugar a variantes con modificaciones antigénicas (13,17). La *Figura 2* representa la clasificación del virus de la influenza B en linajes, clados y subclados lo que constituye un marco fundamental para interpretar la diversidad genética y la evolución del virus. Esta organización facilita el seguimiento de variantes circulantes y la identificación de cambios relevantes desde el punto de vista epidemiológico. *La Figura 2* presentada se elaboró a partir de la clasificación descrita por el CDC (18).

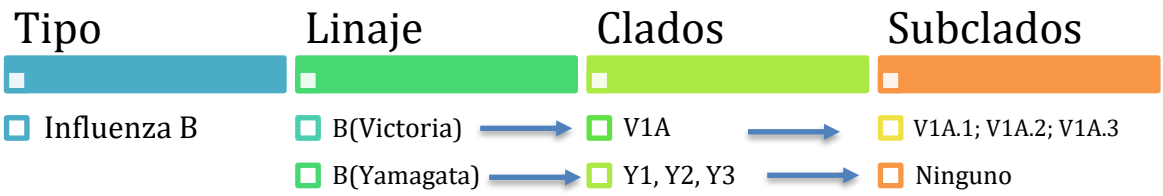


***Figura 2*** Representación de los niveles de clasificación genética del virus de la influenza B. *Elaboración propia basada en CDC.*

A diferencia de la influenza A, la influenza B no se clasifica en subtipos en combinaciones de hemaglutinina y neuraminidasa (HxNy), su clasificación está basada en la descripción en base a su diversidad genética exclusivamente en linajes, clados y subclados los cuales están definidos mediante criterios filogenéticos. Esta forma resulta fundamental en los programas de vigilancia genómica permitiendo evaluar la evolución de cepas circulantes, su relación filogenética y posible impacto en la efectividad de la aplicación vacunas anuales a la población (19,20).

En la práctica, las vacunas estacionales contra la influenza son formuladas cada año en función de las predicciones sobre qué virus serán los más comunes durante cada temporada, incluyendo componentes específicos del virus de la influenza, en el caso de influenza B se incluye el linaje B/Victoria según recomendaciones vigentes de los programas de vacunación (2). Las vacunas disponibles son formulaciones dependientes del grupo etario, incluyendo vacunas inactivadas tradicionales, vacunas recombinantes y formulaciones de dosis alta o adyuvantes para personas de 65 años o más, con el objetivo de aumentar la respuesta inmune en cada uno de los grupos. Cada individuo de 6 meses o más debería recibir una vacuna adecuada según su edad en cada etapa, debido a que, la protección obtenida por la vacunación está basada en el desarrollo de anticuerpos que reconozcan las cepas circulantes y esta correspondencia puede verse afectada por la variabilidad genética del virus (21).

La mayor parte de la variabilidad a nivel genético del virus de la influenza B se concentra en el gen de la hemaglutinina, la cual es una proteína clave en la unión del virus al receptor celular y principal diana de la respuesta inmunitaria humoral. La mutaciones encontradas y acumuladas a nivel de las regiones antigénicas de la hemaglutinina pueden modificar los epítopos reconocidos mediante anticuerpos neutralizantes, facilitando así el escape inmunológico y dando lugar a la aparición de variantes antigénicas. A pesar de que otros genes pueden contribuir a la adaptación viral, los cambios en la hemaglutinina tienen este impacto particularmente el cual se vuelve relevante desde el punto de vista antigénico. Estas variantes antigénicas representan un elemento central en los programas de vigilancia de la influenza B, debido a que su identificación y caracterización

genómica permiten evaluar la concordancia entre las cepas circulantes y las que están incluidas en vacunas, de igual manera, el seguimiento de estas variantes resulta fundamental para anticipar posibles disminuciones en la eficacia vacunal y apoyar a la toma de decisiones para la selección de cepas vacunales globales (12,19).

En comparación con el virus de la influenza A, el virus de la influenza B presenta una evolución más lenta lo que ha sido relacionado con una menor diversidad de reservorios y con una circulación más restringida al huésped humano. La diferencia en la dinámica evolutiva se traduce en una menor tasa de diversificación genética a corto plazo, a su vez, esta menor velocidad de cambio no implica una estabilidad genética absoluta ya que la acumulación de mutaciones antes mencionadas a lo largo del tiempo resulta suficiente para generar diversidad genética con relevancia epidemiológica y clínica, especialmente al analizarlo a escalas temporales largas. Por ello, el seguimiento continuo de la evolución genética del virus de la influenza B continua siendo fundamental en la detección de cambios relevantes en las variantes circulantes (13,20).

En los últimos años, la evolución reciente del virus de la influenza B ha estado marcada por cambios relevantes en los patrones de circulación que siguen sus linajes. Diversos sistemas de vigilancia epidemiológica y genómica han reportado una disminución notable en la detección del linaje B/Yamagata desde la temporada 2020-2021, sin embargo, el linaje B/Victoria ha continuado circulando de forma predominante en distintas regiones del mundo. La circulación sostenida del linaje B/Victoria ha favorecido la aparición de nuevos clados y subclados, debido a la acumulación de mutaciones en regiones antigénicas clave, de igual manera, la ausencia de detecciones del linaje B/Yamagata no permite descartar completamente su posible reemergencia, por lo que es importante continuar la vigilancia genómica para la identificación temprana de cambios en la circulación y reaparición de variantes genéticas con potencial impacto epidemiológico (19,20).

El análisis detallado de la variabilidad genética del virus de la influenza B que incluye la caracterización de linajes, clados, sub clados y variantes antigénicas, constituye un componente fundamental en la vigilancia genómica y en la toma de

decisiones en salud pública. La identificación de cepas circulantes permite mejorar la comprensión de la dinámica evolutiva del virus de la influenza, la optimización de cepas vacunales y ayuda a identificar y evaluar la influencia de los factores ambientales y climáticos en esta variabilidad, de este modo, los enfoques bioinformáticos aplicados al análisis de datos de secuenciación publica se convierten en herramientas clave para el estudio y la vigilancia de influenza B (19,20).

### 1.4 Aplicación de la bioinformática en el estudio de la influenza

En los últimos años las tecnologías de secuenciación de nueva generación han transformado el estudio de virus respiratorios, incluyendo el estudio del virus de la influenza B, al permitir la obtención y la posibilidad de utilizar grandes volúmenes de datos genómicos a partir de muestras clínicas obtenidas en diferentes partes del mundo por instituciones dedicadas a la investigación en salud pública. Estos datos, que incluyen genomas completos y datasets de secuencias parciales o de regiones puntuales del virus, se encuentran disponibles tanto a partir de estudios propios como en repositorios públicos de acceso abierto, tales como NCBI y EMBL, así como repositorios de acceso controlado por medio de correos institucionales de universidades con acreditación en investigación científica. La disponibilidad de esta información genómica ha hecho imprescindible el uso de herramientas bioinformáticas para su almacenamiento, procesamiento y análisis, constituyendo así la base de los estudios genómicos actuales acerca de la influenza.

La bioinformática desempeña un papel central en el análisis de datos de secuenciación viral permitiendo abordar de forma sistemática la diversidad genética del virus, estudiar su evolución y cambios genéticos a lo largo del tiempo. Los datos generados mediante secuenciación se presentan inicialmente en formatos estandarizados específicamente como archivos FASTQ, los cuales contienen información sobre millones de lecturas individuales, como un identificador que caracteriza cada lectura un signo de “@” inicial seguido del identificador único y contiene también información acerca de la calidad de las lecturas en base a valores Phred para cada base codificada con caracteres ASCII (22,23). El procesamiento de estos datos en crudo requiere herramientas y

programas computacionales que permitan llevar a cabo el análisis y la evaluación de su calidad, filtrar las secuencias de baja fiabilidad y preparar los datos para llevar a cabo análisis posteriores con la seguridad de garantizar la robustez de los resultados obtenidos (24).
Uno de los componentes fundamentales del análisis bioinformático en estudios de influenza es el mapeo de las lecturas preprocesadas de secuenciación frente a un genoma de referencia de esta manera se puede llevar a cabo la reconstrucción de la secuencia viral presente en cada muestra facilitando la comparación entre cepas procedentes de distintas regiones geográficas y en diferentes contextos ambientales. El alineamiento constituye la base para la identificación de mutaciones, la obtención de secuencias consenso y el análisis en relación a la variabilidad genética del virus siendo estos aspectos clave para el estudio de la evolución viral y para la caracterización de variantes genéticas (13).

Una vez obtenidos los alineamientos, el enfoque bioinformático permite análisis comparativos a gran escala, incluyendo la identificación de mutaciones puntuales, la detección de patrones de cambio geográfico ambientales y la diversidad genética entre distintas cepas. Estas aproximaciones son especialmente relevantes al tratarse del virus de la influenza B, cuya evolución es más gradual que la del virus de la influenza A, ya que permite detectar cambios realmente sutiles pero que a su vez son potencialmente relevantes desde el punto de vista epidemiológico y vacunal (12).

Además, las herramientas bioinformáticas facilitan la anotación genómica del virus, es decir, permite la identificación y caracterización de las regiones codificantes y no codificantes del genoma viral. La anotación permite contextualizar las mutaciones detectadas en relación con las proteínas virales afectadas y de esta manera evaluar su posible impacto funcional. Esto en conjunto, contribuye al análisis y comprensión profunda de la relación entre la variabilidad genética del virus de la influenza B, su evolución y su comportamiento epidemiológico.

En el ámbito de la vigilancia genómica, la bioinformática permite integrar datos genómicos con información epidemiológica, temporal y geográfica, lo que resulta

primordial para la monitorización de la circulación de linajes, clados y variantes de interés en salud pública. La bioinformática resulta una herramienta clave en los programas de vigilancia de nivel global ya que gracias a estas herramientas se puede apoyar a la selección de cepas vacunales, evaluar la concordancia entre las cepas circulantes y las cepas ya incluidas en las vacunas estacionales actualmente aplicadas. El uso de pipelines de análisis bioinformático estandarizado y reproducible permite garantizar la consistencia de los estudios genómicos y facilita la comparación de resultados entre distintos trabajos. Aunque la implementación completa de los flujos de análisis puede variar en función de la calidad de los datos, el objetivo del estudio, la disponibilidad de las herramientas a utilizar y la decisión del bioinformático a llevar a cabo el análisis, es esencial su aplicación para transformar los datos obtenidos de secuenciación en información biológicamente interpretable. Por ello, el análisis bioinformático de datos genómicos públicos constituye una aproximación ampliamente utilizada y adecuada para el estudio comparativo de la diversidad genética del virus de la influenza B (13).

El flujo de trabajo se apoya en herramientas ampliamente utilizadas y validadas en el análisis de datos de secuenciación de virus ARN. Para la evaluación inicial de la calidad de las lecturas y el filtrado de secuencias de baja fiabilidad se consideraron herramientas como *FastQC* y *fastp*, las cuales permiten detectar posibles problemas en los datos crudos, estas herramientas al utilizarlas proporcionan informes visuales e interactivos en HTML donde podemos analizar medidas como la calidad de las bases, la composición de los nucleótidos, el contenido presente de GC y si hay presencia o no de adaptadores o secuencias que se consideran contaminantes en la corrida y que podrían afectar los análisis posteriores, además con la herramienta *fastp* que es una herramienta rápida para llevar a cabo el filtrado de las lecturas y corrección de las bases de baja calidad, esta herramienta además tiene la capacidad de realizar recorte por poliG por cada lectura, es una herramienta altamente utilizada para datos de illumina single-end y paired-end, *fastp* es muy utilizada debido a que los datos obtenidos suelen ser de mayor calidad en comparación con otras herramientas convencionales, sin embargo, es necesario para poder utilizar estas herramientas un conocimiento previo en lenguajes de programación como Python, Shell scripting o Java (25).

Para el alineamiento de las lecturas frente a un genoma de referencia del virus de la influenza B se llevó a cabo mediante *BWA* (Burrows-Wheeler Aligner), ampliamente empleado en el análisis de datos de secuenciación de lectura corta especialmente provenientes de plataforma como Illumina. *BWA* permite un mapeo eficiente y preciso contra genomas de referencia, optimizando el rendimiento computacional y la exactitud en la identificación de posiciones homologas (26). Una vez terminado el alineamiento es necesario utilizar *SAMtools*, esta es una herramienta de línea de comandos esencial en manipulación de datos en bioinformática que permite el procesamiento, la indexación, la visualización y análisis del alineamiento de las secuencias de ARN del virus de la influenza B de alto rendimiento, es una herramienta altamente utilizada para el descubrimiento y la identificación de variantes y para estudios de secuencias genómica (27). La obtención de secuencias consenso y la identificación de variantes genéticas se lleva a cabo utilizando la herramienta *BCFtools*, esta herramienta ampliamente validada en estudios de genómica viral, se realizó el llamado multi-muestra y el filtrado, posteriormente se reconstruyeron las secuencias consenso individuales para cada muestra (28). Finalmente, las secuencias consenso obtenidas fueron utilizadas para los análisis comparativos y filogenéticos posteriores. Dado que el alineamiento se realizó contra un genoma de referencia completamente anotado (B/Yamagata), la identificación de los segmentos virales y la interpretación de las mutaciones se efectuaron de dicha referencia, permitiendo contextualizar las variantes detectadas dentro de cada segmento del virus.

La selección de estas herramientas responde al uso encontrado en muchos estudios genómicos virales y a su adecuación para el análisis de la diversidad genética del virus de la influenza B. No obstante, la implementación es adaptable según las necesidades de interés de cada estudio y a la calidad de los datos disponibles en los diferentes repositorios y bases de datos actuales.

## 1.5 Justificación

A pesar del notable crecimiento en el conocimiento y la disponibilidad de datos de secuenciación genómica y el desarrollo de herramientas bioinformáticas cada vez más sofisticadas y en continua actualización, el estudio de la diversidad genética del virus de la influenza B sigue siendo limitado en comparación con el virus de la

influenza A. Esta diferencia es especialmente evidente en investigaciones que integran tanto el análisis genómico del virus junto con variables ambientales y geográficas, lo que deja aún espacios por explorar en la comprensión de los procesos evolutivos que condicionan la adaptación y la circulación de este virus en diferentes entornos climáticos y geográficos.

Al presentar la influenza B una variabilidad genética organizada en linajes, clados y subclados influye directamente en su evolución y comportamiento epidemiológico, sin embargo, gran parte de la literatura se ha centrado en describir elementos desde una perspectiva general, sin profundizar de manera sistemática en como esta diversidad se puede manifestar de forma diferente entre regiones con condiciones climáticas contrastantes. Considerando que el virus de la influenza B circula en escenarios ambientales bastante diversos que van desde zonas templadas hasta regiones tropicales y subtropicales, resulta pertinente examinar si existen patrones de mutación o distribución genética que puedan relacionarse en estos contextos.

Teniendo lo antes mencionado en cuenta, la disponibilidad de secuencias genómicas depositadas en los distintos repositorios públicos reconocidos a nivel global, representan una oportunidad valiosa para lograr desarrollar estudios comparativos sin necesidad de generar datos experimentales propios, especialmente cuando se carece de espacios físicos para realizar dichos estudios de forma experimental. El aprovechamiento de estos recursos, junto con pipelines bioinformáticos que contienen herramientas reproducibles y disponibles, permite analizar lecturas de secuenciación, identificar mutaciones de interés en salud pública y reconstruir secuencias virales que facilitan la comparación entre muestras procedentes de distintos orígenes geográficos que divergen también en su tendencia climática. Este enfoque resulta especialmente adecuado para investigaciones orientadas a explorar la diversidad genética y a detectar cambios que pueden tener relevancia biológica o epidemiológica.

Desde una perspectiva en bioinformática, el procesamiento sistemático de grandes volúmenes de datos genómicos es fundamental para transformar información de datos en crudo en resultados interpretables según el interés de

cada estudio. El análisis de variantes genéticas no solo contribuye a entender mejor la evolución del virus de la influenza B, sino también aporta información útil en vigilancia genómica y la evolución de la correspondencia entre cepas circulantes y formulación de vacunas, actualmente se utilizan vacunas diseñadas para proteger contra tres virus, dos virus de la influenza A y un virus de la influenza B/victoria (21). De este modo, la bioinformática se consolida como una rama de la biología indispensable en el estudio moderno de virus ARN de la vigilancia basada en genómica, donde la bioinformática desempeña un papel central.

Por tanto, este trabajo está hecho por la necesidad de aplicar un enfoque bioinformático al análisis comparativo de la diversidad genética del virus de la influenza B, integrando datos de secuenciación publica procedentes de diferentes regiones geográficas y climáticas. El estudio de las mutaciones identificadas, su localización genómica y su frecuencia de aparición en distintos contextos geográficos contribuye a generar una visión más detallada del comportamiento del virus. Asimismo, este trabajo refuerza la utilidad de los enfoques bioinformáticos en el estudio del virus, aportando un marco analítico que puede servir como base para futuras investigaciones en el ámbito de la vigilancia genómica y la salud pública, y que respalda la aplicación de enfoques bioinformáticos en el análisis del virus de la influenza B.

Este trabajo se centró en el linaje Yamagata debido a su particular situación epidemiológica en los últimos años, aunque desde el inicio de 2020 no se ha documentado circulación sostenida de este linaje a nivel global, este no ha sido declarado oficialmente extinto y continua bajo vigilancia internacional. Su posible reemergencia presenta un escenario de interés en salud pública.

# 2. Objetivos

## 2.1 Objetivo general

Analizar la diversidad genética del virus de la influenza B en diferentes regiones climáticas mediante la identificación y comparación de variantes genéticas, con el propósito de evaluar patrones de mutación y su posible asociación con factores ambientales.

## 2.2 Objetivos específicos

2.2.1 Identificar variantes genéticas de interés a partir de las secuencias de influenza B utilizando pipelines bioinformáticos de alineamiento y detección de variantes

2.2.2 Analizar la frecuencia y distribución de mutaciones en función de la región geográfica y el contexto climático mediante el uso de herramientas estadísticas y de visualización.

2.2.3 Interpretar las mutaciones identificadas y discutir su posible relevancia biológica y evolutiva en el contexto de la adaptación del virus a distintos entornos climáticos.

# 3. Metodología

### 3.1 Diseño del estudio

El presente trabajo se planteó como un estudio de tipo descriptivo, transversal y retrospectivo de tipo bioinformático el cual está basado en un enfoque de investigación in silico, enfocado en la caracterización de la diversidad genética del virus de la influenza B. En este trabajo no se requirió la manipulación directa de muestras biológicas ni experimentación en laboratorio físico ya que se fundamenta

en la reutilización de datos de secuenciación de segunda generación de acceso público. El diseño metodológico se estructuró con el propósito de transformar lecturas crudas de secuenciación en información genómica interpretable, permitiendo con dicha información; identificar mutaciones, evaluar su localización en el genoma viral y comparar su distribución entre muestras procedentes de distintos contextos geográficos y climáticos.

La unidad de análisis estuvo constituida por datasets de secuenciación correspondientes a genomas virales de la influenza B generados mediante plataformas de secuenciación de nueva generación. Cada dataset se procesó siguiendo un flujo bioinformático automatizado que integra control de calidad, mapeo de lecturas a un genoma de referencia, el llamado de variantes y obtención de secuencias consenso con el fin de garantizar la consistencia metodológica entre las muestras y reducir la introducción de sesgos derivados de errores técnicos, de esta manera se logró estandarizar el tratamiento de los datos y asegurar la óptima comparabilidad de los resultados.

El componente comparativo del estudio se basó en la clasificación de las muestras en base a su procedencia geográfica y a su contexto climático del cual proceden, agrupándolas en regiones tropicales, áridos, templadas, y frío continental. Dicha clasificación respondió a la necesidad de analizar la estabilidad y transmisibilidad del virus bajo diferentes condiciones de temperatura y humedad, factores que regulan su circulación estacional y que podría asociarse a patrones de variabilidad genética detectables mediante análisis bioinformático. Al contrastar estos entornos climáticos, se buscó identificar si la variabilidad genética y los patrones de mutación presentan particularidades adaptativas según el nicho ecológico del virus. Este trabajo priorizó un enfoque descriptivo orientado a la identificación y a la caracterización de mutaciones encontradas, evitando inferencias causales directas sobre la afluencia ambiental.

Con el fin de mantener la variabilidad técnica del análisis dentro de las limitaciones computacionales propias del entorno de trabajo, se seleccionó un conjunto representativo de datasets que equilibran diversidad geográfica con una alta calidad de secuenciación. Esta selección se fundamentó en criterios técnicos,

priorizando aquellos datasets que presentaban una profundidad de lectura adecuada y puntajes de calidad Phred elevados observados en los distintos repositorios de búsqueda, garantizando así la confiabilidad de cada dataset durante el análisis. Esta selección permitió abordar el análisis comparativo sin comprometer la reproducibilidad del flujo de trabajo ni la coherencia metodológica entre muestras.

El alcance del estudio se delimitó al análisis y comparación de variantes genéticas detectables mediante alineamiento contra un genoma de referencia del virus de la influenza B y en el contexto de la variabilidad climática y geográfica. Se realizaron análisis filogenéticos basados en alineamiento múltiple mediante métodos de máxima verosimilitud. No se incluyeron en el estudio ensamblaje de novo, análisis filo dinámicos avanzados, modelado evolutivo avanzado, el objetivo principal se centró en la identificación y comparación de mutaciones dentro de un marco bioinformático reproducible enfocado en la caracterización comparativa de variantes en función de variables climáticas y geográficas.

### 3.2 Estrategia de búsqueda, criterios de inclusión y curaduría de datasets

La obtención de los datos genómicos para incluir en este estudio se realizó mediante una búsqueda minuciosa en los repositorios públicos especializados que contienen datasets en estado crudo de secuenciación genómica viral. Se priorizaron bases de datos internacional ampliamente reconocidas en investigación en salud pública y en el ámbito de la bioinformática, el repositorio principal en donde se realizó la búsqueda fue el National Center for Biotechnology Information (NCBI), a través del Sequence Read Archive (SRA), y el European Nucleotide Archive (ENA) de EMBL. Estos repositorios fueron seleccionados por su disponibilidad de datasets de secuenciación cruda, metadatos asociados y compatibilidad con flujos de análisis bioinformáticos reproducibles.

Para la gestión y procesamiento de estos datos, así como para los pasos posteriores del pipeline bioinformático completo, se adaptó un entorno de análisis basado en la distribución *Ubuntu* (v24.04.3) LTS (Noble Numbat), operado a través del Windows Subsystems for Linux (WSL2) (29). Dentro de este sistema se implementó el gestor de paquetes y entornos *Miniconda* (V25.11.1) en una de sus

versiones más actuales (30), lo cual permitió la creación de ambientes virtuales aislados según la necesidad del estudio. Este entorno permitió la resolución de las herramientas bioinformáticas utilizadas, garantizando la reproducibilidad técnica del flujo de trabajo al aplicar las versiones empleadas.

La estrategia de búsqueda se centró en la identificación de datasets correspondientes al virus de la influenza B, generados mediante tecnologías de secuenciación de nueva generación de tipo Illumina MiSeq y NovaSeq. Se tomó en cuenta la inclusión de ambas plataformas debido a que Miseq es ampliamente reconocido por su precisión en laboratorios de vigilancia genómica y NovaSeq aporta una muy alta profundidad de lectura, en este caso, ambas plataformas brindan un nivel alto de confiabilidad en que, los archivos crudos (FASTQ) posean una alta calidad técnica, amplio uso en vigilancia genómica y compatibilidad con las herramientas a utilizar en este estudio, siendo necesarios estos criterios para realizar un análisis robusto y confiable (31). Se utilizaron los sistemas internos de búsqueda de cada repositorio utilizando como criterio principal la clasificación taxonómica del virus, illumina como plataforma principal y secuenciación de genoma completo (WGS por sus siglas en inglés). Bajo este enfoque, se excluyeron sistemáticamente aquellas muestras correspondientes a  otros tipos de virus de la influenza (como influenza A) u organismos distintos, con el fin de evitar sesgos en los análisis comparativos y garantizar que la variabilidad detectada fuera específica de la especie objeto de estudio enfocándose en datos de secuenciación de genoma completo, ya que este enfoque permite la caracterización exhaustiva de todos los segmentos del virus de la influenza B y no de áreas puntuales del virus, también se excluyeron datasets que presentaban información incompleta, baja calidad y profundidad de las lecturas, ausencia de metadatos relevantes o inconsistencias en la anotación de los datos. Asimismo, se descartaron los datasets que no disponían de lecturas crudas en formato *FASTQ*, ya que este tipo de archivos es necesario para aplicar el pipeline bioinformático completo, desde el control de calidad hasta la identificación de mutaciones relevantes.

Como parte de los criterios técnicos de inclusión, se priorizaron datasets generados mediante secuenciación paired-end debido a que representan un número elevado de lecturas y un volumen total de bases compatible con la

cobertura del genoma completo del virus de la influenza B. El virus de la influenza B posee un genoma segmentado de aproximadamente 14.5 kb (32), por lo que es esencial disponer de una profundidad de secuenciación adecuada favoreciendo un alineamiento más estable frente al genoma de referencia, la reconstrucción fiable de secuencias consenso y la detección precisa de mutaciones, todas estas consideraciones permitieron asegurar que los datos seleccionados fueran técnicamente apropiados para el análisis bioinformático.

Cada uno de los datasets incluidos en este estudio se evaluó de forma individual con el fin de verificar la disponibilidad y consistencia de los metadatos de interés para este trabajo revisando la información referente al país de origen, fecha de muestreo y características generales del estudio antes mencionadas, elementos necesarios para la posterior clasificación de las muestras según su contexto geográfico y climático fundamentado en una estratificación bioclimática, vinculando las coordenadas geográficas de los metadatos con los criterios de temperatura y humedad de cada región. Este enfoque es especial en este estudio, dado que las condiciones ambientales actúan como presiones selectivas que pueden influir en la estabilidad del virión y de su tasa de mutación (33,34).

Las muestras fueron agrupadas según la clasificación climática de Köppen-Geiger, este tipo de clasificación es ampliamente utilizada en estudios biogeográficos y epidemiológicos por su base termo pluviométrica estandarizada (35). Para este estudio, las categorías originales fueron consolidadas en cuatro macrorregiones climáticas comparativas, con el objetivo de facilitar el análisis evolutivo.
Las zonas incluidas son:

### 3.2.1 Zonas tropicales (categoría Köppen A)

Esta zona incluye regiones con temperatura media mensual > 18 °C durante todo el año y humedad elevada relativamente constante.
Características:

- Transmisión viral menos estacional
- Circulación sostenida anual
- Dinámica evolutiva bajo estabilidad térmica
- Potenciales diferencias en patrones de diversificación genética

### 3.2.2 Zonas áridas (categoría Köppen B)

Comprende regiones con precipitación anual inferior umbral de evapotranspiración, climas desérticos.

Características:

- Baja humedad relativa
- Amplitud térmica diaria elevada
- Estrés ambiental por aridez
- Condiciones que pueden influir en estabilidad ambiental del virus

### 3.2.3 Zonas templadas (categoría Köppen C)

Incluyen regiones con inviernos moderados y veranos templados o cálidos, con marcada estacionalidad térmica, pero sin extremos continentales severos.

Características:

- Adaptación viral a climas con estacionalidad moderada
- Influencia de inviernos templados en la dinámica de transmisión
- Variabilidad asociada a oscilaciones térmicas interanuales
- Posible presión selectiva vinculada a cambios estacionales de humedad absoluta.

### 3.2.4 Zonas frías continentales (categoría Köppen D)

Corresponden a regiones con inviernos prolongados y temperaturas medias del mes más frio < 3 °C, caracterizadas por un fuerte contraste térmico anual.

Características:

- Alta estacionalidad marcada
- Circulación viral predominantemente invernal
- Condiciones de baja humedad absoluta durante los periodos de frio
- Potencial presión selectiva asociada a extremos térmicos (33).

En la *Tabla 1* se muestra el resumen por clasificación Köppen de las regiones categorizadas según el tipo climático:

| Grupo | Tipo climático | País |
|---|---|---|
| **A** | Tropical | Madagascar, Camerún, Nicaragua |
| **B** | Árido | Irán, Argelia |
| **C** | Templado | USA, UK, Luxemburgo, Alemania, Hong Kong, Nueva Zelanda |
| **D** | Frío continental | Finlandia |

***Tabla 1.*** Clasificación köpper-Geiger en base a región climática y a país.

La diversidad climática planteada en estos datasets, asegura que los patrones de mutación identificados no sean específicos de una sola región, lo cual puede ocurrir en la no identificación de datos de interés en este estudio, que no logren reflejar la plasticidad genómica del virus de la influenza B, es decir, a su capacidad de generar mutaciones adaptativas para prevalecer en nichos ecológicos tan diversos a nivel global.

Como resultado del proceso inicial de búsqueda y preprocesamiento, se seleccionó un total de 25 datasets de secuenciación de genoma completo correspondientes al virus de la influenza B, los cuales se obtuvieron mediante un protocolo de descarga híbrido considerando los estándares actuales de reutilización de datos genómicos para asegurar su integridad (36) que incluyó; recuperación directa de los objetos SRA desde los repositorios de Amazon S3 (vía inactiva STRIDES del NCBI) y servidores FTP de la European Nucleotide Archive (ENA) por medio de la herramienta curl, seguida de la herramienta de línea de comandos *SRA Toolkit* (*v3.0.3*) (37,38). Posteriormente tras el análisis de calidad y trimming, se seleccionaron 20 muestras, descartando 5 de ellas por no cumplir con los umbrales de integridad en calidad y profundidad de lectura requeridos.

Este conjunto de 20 muestras se consideró adecuado para realizar un análisis comparativo representativo de distintas regiones geográficas y climáticas, manteniendo la viabilidad computacional a los recursos disponibles durante el

proceso bioinformático, sin embargo al realizar el mapeo al genoma de referencia se encontraron 4 datasets que no eran compatibles con influenza B dando como resultado otros microorganismos revisados por medio de BLAST de NCBI, una vez realizada la revisión de cada datasets en base a mapeo, se obtuvieron 16 datasets finales incluidos para el estudio con resultados variables pero con posibilidad de trabajarlos. Dicha selección buscó equilibrar diversidad geográfica y climática, la integridad de las lecturas a analizar y la coherencia metodológica, permitiendo de esta manera desarrollar un análisis sistemático de la diversidad genética del virus dentro de un alcance realista para este estudio. La *Tabla 2* resume los datasets que superaron los criterios de calidad principales tomados en cuenta y mapeo óptimo a genoma de referencia. Cabe mencionar que la validación final de estas muestras no solo dependió de sus metadatos propios, sino de un proceso de filtro de control de calidad bioinformático, el cual se detalla en la sección 3.3.1 ***(ver Anexo 1)***. Dichos criterios incluyeron:

i. Una supervivencia de lecturas post-filtrado superior al 70%.
ii. Calidad base promedio de Q>25.
iii. Longitud de lectura mínima de 100 pb.
iv. Tasa de duplicación que no comprometiera la representatividad de secuencias únicas.

En la *Tabla 2* se especifican los identificadores de acceso (SRA/ENA), el origen geográfico y clasificación climática correspondiente, plataforma de secuenciación y el año de recolección. Con esta selección se obtiene representatividad necesaria para evaluar la plasticidad genómica del virus frente a diversas presiones selectivas ambientales.

*Tabla 2.* Especificaciones técnicas y procedencia bio-geográfica de los 16 datasets de influenza B linaje Yamagata, seleccionados para el estudio.

| ID de acceso | País / Clima | Plataforma | Fuente de acceso | Año |
|---|---|---|---|---|
| **SRR34884230** | USA/ Templado | Illumina NovaSeq | USA (NCBI) | 2025 |
| **ERR732294** | Reino Unido/ Templado | Illumina MiSeq | Europe (ENA) | 2015 |
| **ERR1857001** | Luxemburgo/ Templado | | Europe (ENA) | 2017 |
| **ERR1856995** | Alemania /Templado | | Europe (ENA) | 2017 |
| **ERR1856989** | Finlandia/ Frío continental | | Europe (ENA) | 2017 |
| **ERR1856998** | Irán / Árido | | Europe (ENA) | 2017 |
| **ERR1856996** | Hong Kong/ Templado | | Europe (ENA) | 2017 |
| **ERR1857000** | Madagascar/ Tropical | | Europe (ENA) | 2017 |
| **ERR1856970** | Camerún/ Tropical | | Europe (ENA) | 2017 |
| **ERR1856966** | Argelia / Árido | | Europe (ENA) | 2017 |
| **SRR10885417** | Reino unido/Templado | | USA (NCBI) | 2017 |
| **SRR8084690** | Nicaragua/ Tropical | | USA (NCBI) | 2016 |
| **SRR8084687** | Nicaragua/ Tropical | | USA (NCBI) | 2016 |
| **SRR7911664** | Nueva Zelanda/ Templado | | USA (NCBI) | 2012 |
| **ERR1856988** | Finlandia/ Frío continental | | Europe (ENA) | 2017 |
| **ERR1856916** | Finlandia/ Frío continental | | Europe (ENA) | 2017 |

**Nota:** *NCBI: National Center for Biotechnology Information ; ENA: European Nucleotide Archive.*

De manera complementaria, se llevó a cabo una revisión bibliográfica mediante la biblioteca virtual de la universidad y bases de datos científicas revisadas por pares, reconocidas para contextualizar el análisis genómico y fundamentar la selección de herramientas bioinformáticas utilizadas en este estudio, priorizando estudios relacionados con la evolución del virus de la influenza B y el cómo afecta la variabilidad climática y geográfica a la que se expone este virus.

## 3.3 Flujo de trabajo bioinformático para el análisis de variantes de interés

Una vez se consolidaron los 16 datasets seleccionados para el estudio, según los criterios mencionados en el punto 3.2, se ejecutó un protocolo computacional para transformar las lecturas crudas en información biológicamente interpretable. Dicho flujo tuvo como objetivo principal garantizar la máxima pureza de las secuencias, eliminando artefactos técnicos, reduciendo errores de secuenciación y bases de baja calidad que pudieran comprometer la precisión en la identificación de variantes genómicas.

El flujo de trabajo se estructuró de manera secuencial, desde un control de calidad riguroso, un filtrado y recorte de las secuencias, el procesamiento de las lecturas y finalizando con la identificación de las variantes encontradas y de interés en salud pública. Este proceso permitió estandarizar los datos provenientes de distintas plataformas de secuenciación (MiSeq, NovaSeq) asegurando que solo la información genética de alta fidelidad fuera utilizada en las etapas posteriores de alineamiento y detección de polimorfismos.

### 3.3.1 Control de calidad inicial de las lecturas crudas

Para evaluar la integridad técnica de los 25 datasets seleccionados inicialmente por medio de sus metadatos propios, se realizó un control de calidad inicial mediante la herramienta *FastQC* (v0.12.1) ***(ver Anexo 2)***. La evaluación de los datos se ejecutó a través de la interfaz de línea de comandos en Bash generando informes detallados en formato HTML. La inspección visual de este reporte permitió validar la calidad de cada dataset, analizando parámetros críticos como la distribución de calidad de las bases (Per base sequence quality), el contenido de GC y la presencia de adaptadores presentes residuales.

Los resultados preliminares revelaron una alta calidad en las muestras a incluir en este estudio a excepción de 5 datasets que presentaban inconsistencias. Todas fueron secuenciadas mediante la plataforma Illumina, mostrando puntuaciones Phred superiores a Q30 en la mayor parte de los datos, de igual manera, se identificó la necesidad de realizar un preprocesamiento en base a lo observado en el módulo “Adapter Content” del informe HTML, en el cual se verificó la presencia de secuencias sintéticas en los extremos de las lecturas adaptadores (e.g.,illumina Universal Adapter). Aunque las muestras en general presentaban una alta resolución, se realizó un proceso de recorte posterior para eliminar la baja calidad en los últimos ciclos de secuenciación de las muestras seleccionadas y asegurar una longitud uniforme que optimice el mapeo contra el genoma de referencia, asegurando así que las etapas posteriores de alineamiento no se vieran sesgadas por secuencias exógenas o bases relacionadas con una reducida fidelidad genómica.

Tras el diagnóstico inicial, se procedió a la limpieza de calidad de las secuencias y eliminación de adaptadores mediante el software *fastp* (v0.23.2). Esta herramienta fue seleccionada por su capacidad para realizar simultáneamente el filtrado de bajas calidades en las lecturas, el recorte de adaptadores y la corrección de errores en lecturas paired-end, optimizando el tiempo de cómputo.

Para garantizar la máxima pureza de los datos posible, se aplicó un protocolo de filtrado basado en los siguientes parámetros:

- **Filtrado de calidad:** se utilizó un corte en los extremos 5´ y 3´ *(--cut_front* y *–cut_tail*) utilizando una estrategia que elimina bases con una calidad media inferior a Q25. Este umbral se estableció para garantizar una alta fidelidad genómica.
- **Detección de adaptadores:** Se activó la función de autodetección de adaptadores para lecturas paired-end *(--detect_adapter_for_pe*), esto permitió identificar y remover secuencias idénticas residuales, en la mayor parte de los datos incluidos adaptadores de tipo Illumina

Universal Adapter, evitando sesgos por contaminación de adaptadores.

- **Longitud mínima de las secuencias:** se descartaron las lecturas que, tras el proceso de limpieza, presentaron una longitud inferior a 100 pb *(--length_requerired 100*), asegurando así un alineamiento más robusto y preciso contra el genoma de referencia a utilizar, reduciendo la ambigüedad en regiones de baja complejidad.

Finalmente, para evaluar la efectividad de este preprocesamiento se incorporó la herramienta *MultiQC* (v1.33). Esta herramienta permitió observar la consolidación y análisis comparativo de los informes generados por *fastp* en un único reporte integrado. Mediante la inspección visual se identificaron 5 muestras que no cumplían con los estándares de calidad a tomar en cuenta en este estudio (presencia alta de contaminación y baja profundidad de cobertura), por lo que fueron excluidas del estudio.

Como resultado, el set de datos se consolidó en 20 muestras durante el preprocesamiento que presentaron una distribución homogénea y una composición nucleotídica (GC content) coherente con el genoma de virus de la influenza B. Esta evaluación de pre-procesado de las muestras garantizó que los datasets resultantes estuvieran optimizados y estandarizados para la fase de alineamiento y detección de variantes.

### 3.3.2 Preparación de secuencias de referencias

La selección de las secuencias de referencia se realizó utilizando bases de datos públicas especializadas en genomas virales (39), con el objetivo de asegurar que los análisis posteriores se apoyaran en información biológicamente representativa. Para ello, se empleó el portal de NCBI virus, se buscaron genomas completos de influenza B correspondientes al linaje Yamagata (B/Alaska/25/2015). La búsqueda se efectuó aplicando filtros de tipo viral como; hospedador humano y secuencias completas, priorizando aislados clínicos naturales y evitando registros experimentales o recombinantes.

Una vez identificados los aislamientos adecuados, se descargaron los 8 segmentos genómicos de cada linaje en formato FASTA. Posteriormente, se verificó la integridad de las secuencias mediante revisión de sus encabezados y la comprobación de sus longitudes, confirmando que corresponda a los rangos esperados para el genoma segmentado de influenza B (aproximadamente entre 1000 y 2400 nucleótidos por segmento) (40), los cuales se compararon con los tamaños observados de manera consistente en genomas completos depositados en bases de datos curadas (41), sirviendo como control de calidad para asegurar que las referencias fueran biológicamente coherentes. Para evitar divergencia genética entre Victoria y Yamagata, se utilizaron ambas referencias de forma individual y específica evaluando el mejor mapeo a la secuencia de referencia favoreciendo a un alineamiento preciso de las lecturas y una interpretación confiable de la variabilidad genómica observada en las muestras en estudio.

### 3.3.3 Alineamiento de lecturas contra genoma de referencia

Se realizó la indexación del genoma de referencia previo al alineamiento, para ello se utilizó la herramienta *BWA* (v 0.7.19-r1273), esta herramienta es utilizada ampliamente y es adecuada para lecturas >100 pb generadas por medio de plataformas como illumina. El proceso consistió en la asignación de cada lectura a su posición más probable dentro del genoma segmentado de influenza B. El algoritmo *BWA-MEM* opera mediante una estrategia basada en la transformación de Burrows-Wheeler (BWT), permitiendo realizar búsquedas rápidas y eficientes dentro de la secuencia de referencia(28).

Para el alineamiento contra el genoma de referencia se ejecutó *bwa mem* que permite realizar búsquedas rápidas y eficientes dentro de la secuencia de referencia. Durante el proceso a cada alineamiento se le asignó una puntuación de calidad de mapeo (Mapping Quality Score, MAPQ), la cual refleja la confianza estadística en la posición asignada a cada lectura y evitar interpretaciones erróneas en etapas posteriores de análisis de

variantes (42). La salida del alineamiento se generó en formato *SAM* (Sequence Alignment/Map), en este formato se encuentra información detallada sobre la posición, orientación y calidad del mapeo de cada lectura frente al genoma de referencia (43).

Los archivos *SAM* obtenidos fueron convertidos a formato *BAM* (Binary Alignment/Map) utilizando la herramienta *SAMtools* (v.1.23) (28), esta herramienta es ampliamente utilizada en el procesamiento estándar de alineamientos de secuenciación masiva, este es un paso esencial en cualquier pipeline moderno bioinformático, ya que mejora la eficiencia computacional sin alterar la información biológica contenida en los alineamientos y permitiendo al mismo tiempo reducir significativamente el tamaño de almacenamiento. Posteriormente los archivos *BAM* fueron ordenados según la coordenada genómica de referencia, el ordenamiento por posición es un requisito indispensable para múltiples análisis posteriores, ya que organiza las lecturas en función de su ubicación dentro del genoma viral garantizando coherencia estructural en el archivo obtenido, una vez ordenados los archivos *BAM*, fueron indexados generando archivos auxiliares .bai (44). Por último, para evaluar la calidad del alineamiento y como control de calidad se calcularon métricas resumidas mediante la función *flagstat* de *SAMtools*. Este análisis permitió evaluar la eficiencia y consistencia del mapeo de cada muestra obteniendo rangos entre 72.20% y 99.5%, lo cual se encuentra dentro del rango aceptable para análisis de virus RNA, mediante secuenciación de alto rendimiento. Esta variabilidad refleja las condiciones reales de los datasets públicos y permite de esta manera una evaluación más representativa de la diversidad genómica del virus de la influenza B, las métricas tomadas en cuenta incluyeron:

- Número total de lecturas procesadas.
- Porcentaje de mapeo
- Proporción de lecturas correctamente pareadas.
- Duplicación de lectura.

En todo este proceso y hasta la evaluación del mapeo mediante los *flagstat* contra el genoma de referencia se detectaron 4 muestras para las cuales no hubo porcentaje de mapeo o este fue demasiado bajo y por tanto se decidió excluirlas del estudio ***(ver Anexo 1)***. Adicionalmente se utilizó el módulo *bamqc* del software *Qualimap2* (v.2.2.2-dev) (45) con esta herramienta se logró evaluar de manera integral la calidad estadística de los alineamientos generados. Para cada archivo se analizaron parámetros como; profundidad de lectura media, distribución de cobertura a lo largo del genoma, calidad de mapeo (MAPQ), posible sesgo asociado al contenido de GC y tasa de duplicación, por ello la lista final de datasets incluye **16 muestras finales** que pasaron los filtros para análisis posteriores. En la *Figura 3* se resume el flujo de los pasos a seguir para el mapeo de las lecturas al genoma de referencia.

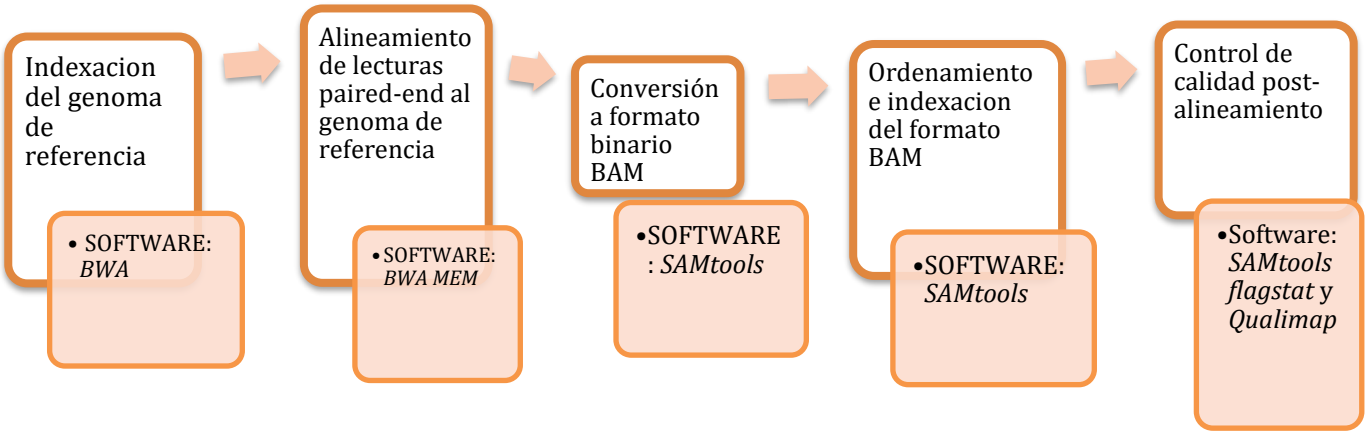


***Figura 3*** Esquema del procesamiento bioinformático para el alineamiento de lecturas frente al genoma de referencia.

### 3.3.4 Detección de variabilidad genómica mediante llamado de variantes y alineamiento múltiple

Para cada archivo BAM previamente alineado y validado, se generó una lista consolidada que incluyó todas las muestras en formato BAM con el fin de realizar un llamado de variantes multi-muestra. Este procedimiento se llevó a cabo utilizando la herramienta *BCFtools* (v.1.23), herramienta ampliamente utilizada en el análisis de genomas virales debido a su eficiencia en organismos con alta cobertura, como influenza B (46), permitiendo integrar las variantes detectadas y la información necesaria

para el análisis comparativo de mutaciones entre los distintos genomas evaluados (28).

Inicialmente, se generó un perfil posicional del genoma viral mediante el módulo *mpileup –ploydi 1* ya que es un virus RNA haploide, el cual calcula para cada posición del genoma, la distribución de nucleótidos observados en las lecturas alineadas. BCFtools permite comparar de forma simultánea cada posición contra el genoma de referencia del linaje Yamagata, integrando información de calidad base y calidad de mapeo.

Posteriormente se realizó el llamado de variantes con la herramienta *BCFtools* en el módulo *--call*, tras el llamado de variantes se realizó un proceso de filtrado para garantizar la calidad y confiabilidad de las mutaciones identificadas, el filtrado se llevó a cabo utilizando el módulo *BCFtools filter*, aplicando criterios de calidad y profundidad de cobertura, se conservaron solo aquellas variantes que cumplían con; valor de calidad de variante (QUAL) > 30 y profundidad de lectura (DP) >200. Estos umbrales fueron utilizados con el objetivo de minimizar falsos positivos derivados de errores de secuenciación o un mal alineamiento, de esta forma asegurar que las variantes retenidas estuvieran respaldadas por una cobertura adecuada.

El filtrado se realizó de forma individual para cada una de las muestras mediante un script en Bash (*Ubuntu*), que automatizó el procesamiento de todos los archivos VCF generados antes del filtrado. Los archivos obtenidos fueron indexados con *bcftools index* para facilitar los análisis posteriores.

A partir de la información posicional obtenida, se identificaron polimorfismos de nucleótido simple (SNPs) y otras variaciones respecto a la referencia. *BCFtools* integra tanto la profundidad de cobertura como las métricas de calidad para determinar la confiabilidad de cada variante detectada. El resultado de este procedimiento fue la generación de un único archivo VCF que resume las diferencias genéticas entre las muestras analizadas y el genoma de referencia constituyendo la base para los análisis posteriores,

comparación genómica y evaluación filogenética (47,48), a partir del archivo VCF multi-muestra filtrado, se extrajo el campo Allele count (AC), este campo indica el número de muestras que presentan el alelo alternativo en una posición determinada, permitiendo cuantificar la frecuencia de cada SNP dentro del conjunto analizado, con base en este valor, las variantes se clasificaron según su nivel de recurrencia: variantes fijas (AC=16), variantes de alta frecuencia (AC=14-15) y variantes recurrentes (AC=11-13), de esta forma se logró identificar posiciones genómicas compartidas por la mayoría de las muestras y evaluar su posible relevancia evolutiva.

Una vez obtenido el archivo en formato VCF multi-muestra filtrado, se generaron las secuencias consenso individuales para cada uno de los 16 datasets, reconstruyendo el genoma viral completo de cada muestra con respecto al genoma de referencia del linaje Yamagata B (B/Alaska/25/2015). Las secuencias consenso fueron posteriormente concatenadas en un único archivo FASTA multi secuencia, el cual fue utilizado para los análisis de alineamiento múltiple, inferencia filogenética y evaluación comparativa geográfica y climática.

Para el alineamiento múltiple de las secuencias consenso se utilizó la herramienta *MAFFT* (v 7.525) (*Multiple Alignmet using Fast Fourier Transform*) (49) mediante línea de comandos. El alineamiento se realizó con el parámetro *--auto*, este parámetro permite al programa seleccionar automáticamente el algoritmo más adecuado en función del número y la longitud de las secuencias, el archivo alineado fue empleado posteriormente para los análisis filogenéticos comparativos, este parámetro permitió identificar posiciones homologas entre las secuencias nucleotídicas a lo largo del genoma viral.

### 3.3.5 Análisis descriptivo, filogenético y visualización

Las variantes genéticas identificadas fueron analizadas inicialmente mediante un enfoque descriptivo a partir del archivo VCF consolidado y previamente filtrado, se realizó el conteo del número total de SNPs por muestra utilizando consultas especificas mediante *bcftools query*. Se

determinó la distribución de variantes por segmento genómico, considerando la información de la columna CHROM correspondiente a cada segmento del genoma de la influenza B, con el fin de evaluar la variabilidad relativa entre los distintos segmentos, el número de SNPs fue normalizado por la longitud total de cada segmento (SNP/kb), utilizando como referencia los tamaños obtenidos del archivo FASTA indexado de referencia de influenza B Yamagata, con el objetivo de evaluar su frecuencia y distribución entre las distintas regiones climáticas incluidas. Se realizó una comparación exploratoria de la presencia y patrón de mutaciones entre grupos de muestras, teniendo en cuenta su procedencia geográfica y su clasificación climática según el sistema Köppen-Geiger. Este análisis permitió identificar posibles tendencias en la distribución de variantes asociadas a contextos ambientales específicos.

Como se mencionó en el punto *3.3.4* se generó un alineamiento múltiple de las secuencias consenso utilizando el software *MAFFT*, esta herramienta optimiza la alineación mediante algoritmos progresivos y refinamiento iterativo automático. El resultado de este alineamiento se empleó como la base utilizada para la inferencia filogenética mediante *IQ-TREE* (v 3.0.1) (50).

La reconstrucción del árbol se realizó bajo el criterio de máxima verosimilitud (Maximum Likelihood), este es un método estadístico que estima la topología y las longitudes de rama que maximizan la probabilidad de observar los datos alineados. El modelo de sustitución nucleotídica fue seleccionado automáticamente por *IQ-TREE* según el mejor ajuste estadístico. La robustez de los nodos se evaluó mediante análisis de Bootstrap con 1000 réplicas, permitiendo estimar el soporte estadístico de las agrupaciones observadas (50).

Adicionalmente, con el objetico de validar visualmente variantes representativas y confirmar su aporte de lectura, los archivos *BAM* alineados y el archivo VCF filtrado fueron inspeccionados mediante el software Integrative *Genomics Viewer IGV (v 2.19.7*). Esta herramienta

permitió examinar manualmente posiciones específicas del genoma, evaluar la profundidad de cobertura y verificar la concordancia entre el llamado de variantes y las lecturas alineadas. La inspección visual se realizó principalmente sobre variantes de alta frecuencia alélica o relevancia comparativa entre las muestras, con el fin de reforzar la confiabilidad de los resultados obtenidos a partir del análisis bioinformático.

Para la visualización y afinamiento del árbol filogenético se utilizó el programa *RStudio* (v R.5.1), se incorporó en el programa el árbol resultante, se emplearon y cargaron las librerías de *ape* (v 5.8-1) y *ggplot2* (v 4.0.2) estas dos librerías instaladas desde CRAN mientras que *ggtree* (v 3.16.3) mediante el repositorio Bioconductor, utilizando la función BiocManager::install().

Los árboles filogenéticos fueron anotados mediante la incorporación de metadatos asociados al continente y clasificación climática, permitiendo la representación estratificada según variables geográficas y ambientales. Este enfoque integrador logró explorar posibles asociaciones entre la estructura evolutiva y variables ambientales sin recurrir a modelado evolutivo avanzado. Para explorar visualmente la distribución del número total de SNPs entre categorías climáticas, se generó un diagrama de cajas (boxplot) en el entorno R. Este grafico permitió representar la mediana, el rango intercuartílico y posibles extremos del número de SNPs por muestra según la clasificación climática del estudio, facilitando una comparación preliminar de la variabilidad genética entre los distintos grupos ambientales.

Con el fin de evaluar de manera formal posibles diferencias en la variabilidad genética entre categorías climáticas, se aplicó el test no paramétrico de Kruskal-Wallis en el entorno de R, esta evaluación se realizó tomando como variable dependiente el número total de SNPs por muestra y como variable independiente la categoría climática según los grupos definidos por la clasificación de Köppen-Geiger.

La elección de este test se fundamentó en el tamaño reducido de muestras por grupo y en la naturaleza discreta de los datos de conteo, condiciones bajo las cuales no se asume normalidad en la distribución. El test de Kruskal-Wallis permite comparar medianas entre múltiples grupos independientes mediante un enfoque basado en rangos, constituyendo una alternativa robusta de análisis de varianza paramétrico (51).

Las visualizaciones incluyeron además gráficos de barras del número de SNPs por muestra, representaciones comparativas por categoría climática y esquemas de densidad de variantes por segmento genómico (SNP/kb). Estas representaciones se generaron con el objetivo de facilitar la comparativa de la variación genética entre muestras y grupos ambientales.

### 3.4 Valoración metodológica

El presente estudio se desarrolló bajo un enfoque bioinformático reproducible, está basado en el procesamiento sistemático de datos de secuenciación pública obtenidos de repositorios internacionales. Se utilizó herramientas ampliamente utilizadas y validadas en el análisis genómico viral, como *FastQC*, *fastp*, *BWA, SAMtools, BCFtools, MAFFT e IQ-TREE,* el uso de estas herramientas permitió construir un flujo de trabajo estructurado y coherente, asegurando que todas las muestras fueran procesadas bajo los mismos criterios técnicos.
El desarrollo del trabajo implicó también un proceso de aprendizaje técnico progresivo en el ámbito del análisis bioinformático aplicado a virus segmentados como Influenza B. Si bien se contaba con bases previas en análisis de datos ómicos, fue necesario profundizar específicamente en herramientas y estrategias orientadas a genomas virales, particularmente en aspectos como el llamado de variantes en organismos haploides, la integración multi-muestra y la interpretación filogenética en contextos epidemiológicos reales.

La selección y configuración de cada herramienta que conforma el pipeline requirió revisión bibliográfica, consulta de documentación técnica y manuales de manejo de los módulos según el enfoque del estudio, así como pruebas iterativas hasta lograr un pipeline funcional y reproducible. Este proceso representó un desafío técnico

relevante que permitió consolidar competencias en análisis genómico viral y fortalecer la comprensión integral del flujo de trabajo implementado.

Una de las principales fortalezas de este trabajo radica en la estandarización del pipeline bioinformático, el cual fue aplicado a los 16 datasets analizados manteniendo el mismo rigor metodológico al total del conjunto de muestras. Al utilizar los mismos parámetros y criterios de filtrado para todas las muestras, se redujo la posibilidad de introducir variabilidad técnica asociada al procesamiento bioinformático, de esta manera, las diferencias observadas en la variabilidad genética pueden interpretarse con mayor confianza como diferencias biológicas reales y no como artefactos derivados de errores o divergencia en el análisis computacional.

La aplicación de filtros de calidad parejos de calidad (QUAL > 30; DP > 200) permitió conservar únicamente aquellas variantes respaldadas por una cobertura adecuada y una alta confiabilidad estadística. Este paso fue fundamental para minimizar la inclusión de mutaciones equivocas que pudieran alterar la interpretación comparativa posterior. Asimismo, el llamado de variantes en formato multi-muestra facilitó la integración de toda la información genética en un único archivo consolidado, esto permitió realizar análisis comparativos persistentes entre muestras y segmentos genómicos.

Es importante reconocer que el tamaño muestral por categoría climática fue relativamente reducido, esto limita el poder estadístico de los análisis comparativos y puede influir en la capacidad para detectar diferencias significativas entre grupos. Este aspecto debe considerarse especialmente al interpretar los resultados estadísticos relacionados con la variabilidad genética del virus en relación al clima.

Desde el punto de vista analítico, este trabajo se basó en un enfoque de mapeo contra genoma de referencia del linaje Yamagata. Si bien esta estrategia es adecuada para estudios comparativos intra linaje y permite evaluar divergencia relativa de manera eficiente, puede presentar limitaciones en la detección de variantes estructurales completas o regiones altamente divergentes respecto a la referencia. Un enfoque complementario basado en ensamblaje de novo podría

aportar mayor resolución estructural, aunque implicaría un incremento considerable de complejidad analítica.

En conjunto este diseño metodológico implementada resulto apropiado para los objetivos planteados, permitiendo caracterizar la variabilidad genética del virus de influenza B en distintos contextos geográficos y climáticos mediante un análisis balanceado entre rigurosidad técnica y viabilidad computacional.

# 4. Resultados y discusión

En esta sección se presentan los resultados obtenidos a partir del análisis bioinformático aplicado a las secuencias del virus de la Influenza B pertenecientes al linaje Yamagata. A partir del llamado de variantes multi-muestra y el posterior filtrado por calidad se caracterizó la variabilidad genética presente en los 16 datasets analizados, evaluando el número total de polimorfismos de nucleótido simple (SNPs) por muestra y su distribución a lo largo de los ocho segmentos del genoma viral. Asimismo, se examinó la densidad relativa de mutaciones por segmento genómico mediante normalización del número de SNPs por kilobase (SNP/kb), con el fin de identificar posibles diferencias en la presión evolutiva entre regiones funcionales del genoma. De forma complementaria, se exploró la distribución de la variabilidad genética según la clasificación climática de las muestras y análisis estadísticos no paramétricos.
Finalmente se presentan los resultados del análisis filogenético basado en máxima verosimilitud que permitió inferir la relación evolutiva entre las secuencias consenso reconstruidas y contextualizar la variabilidad observada en función de su distribución geográfica y climática.

En conjunto todos estos resultados permiten describir la estructura de la diversidad genética del virus en el conjunto de muestras estudiado y explorar posibles asociaciones entre variabilidad genómica y factores ambientales.

## 4.1 Resultados

### 4.1.1 Calidad de mapeo y cobertura de datasets

El análisis de calidad del alineamiento mostró que el porcentaje de mapeo al genoma de referencia del linaje Yamagata (B/Alaska/25/2015) varió entre 72.20% y 99.55% entre las 16 muestras finales evaluadas. La mayoría de los datasets presentaron porcentajes superiores al 80%, lo que indica una adecuada representación del genoma viral en las lecturas alineadas.

En relación con la cobertura (≥ 200X), se observó variabilidad entre muestras con valores que oscilaron entre 46% y 100% del genoma. Varias muestras mostraron cobertura arriba de 200X en prácticamente la totalidad del genoma, mientras que otras presentaron regiones con menor profundidad relativa.

A pesar de esta variabilidad, el conjunto de datos permitió lograr la identificación consistente de variantes a lo largo del genoma viral. No se evidenciaron patrones anómalos en la distribución de SNPs ni agrupamientos filogenéticos que sugirieran sesgos derivados de diferencias en la cobertura entre muestras. Los valores detallados del porcentaje de mapeo y proporción del genoma con cobertura ≥ 200X para cada una de las muestras se presentan en la *Tabla 3.*

*Tabla 3* Resumen de la calidad por muestra: porcentaje de mapeo al genoma de referencia y proporción del genoma con cobertura ≥ 200X.

| Dataset | % Mapeo | %Genoma ≥ 200X |
|---|---|---|
| **SRR34884230** | 98.32 | 100 |
| **ERR732294** | 98.31 | 100 |
| **ERR1857001** | 83.47 | 98 |
| **ERR1856995** | 84.84 | 76 |
| **ERR1856989** | 96.64 | 69 |
| **ERR1856998** | 87.59 | 71 |
| **ERR1856996** | 80.81 | 46 |
| **ERR1857000** | 85.90 | 76 |
| **ERR1856970** | 72.20 | 56 |
| **ERR1856966** | 97.96 | 70 |
| **SRR10885417** | 99.55 | 99 |
| **SRR8084690** | 95.94 | 77 |
| **SRR8084687** | 75.85 | 79 |
| **SRR7911664** | 98.73 | 91 |
| **ERR1856988** | 92.28 | 82 |
| **ERR1856916** | 76.83 | 100 |

### 4.1.2 Variabilidad genética global por muestra

A partir del archivo VCF multi-muestra filtrado (QUAL>=30; DP>=200), se cuantificó el número total de polimorfismos de nucleótidos simple (SNPs) por cada uno de los 16 datasets analizados.

El número total de SNPs respecto al genoma de referencia del linaje Yamagata (B/Alaska/25/2015) osciló entre 117 y 823 variantes por muestra, *Figura 4*. La menor divergencia se observó en la muestra SRR34884230 con 117, mientras que la mayor correspondió a SRR8084687 con 823, seguida de SRR8084690 con 821 SNPs y SRR10885417 con 807 polimorfismos de un solo nucleótido.

Se observaron tres rangos principales de divergencia:

- Un grupo de baja divergencia (<200 SNPs), que incluyó 5 muestras.
- Un grupo intermedio (380-410 SNPs), con cuatro muestras

- Un grupo con alta divergencia (>730 SNPs) por muestra conformado por siete datasets.

Esta distribución sugiere coexistencia de aislamientos con distintos grados de diferenciación genética respecto al genoma de referencia, lo que podría reflejar diferencias temporales de circulación, procesos evolutivos independientes o la pertenencia a distintos sub linajes dentro del mismo linaje Yamagata. Este patrón podría estar influenciado por el año de muestreo de cada aislamiento y su distancia filogenética relativa respecto a la cepa de referencia utilizada.

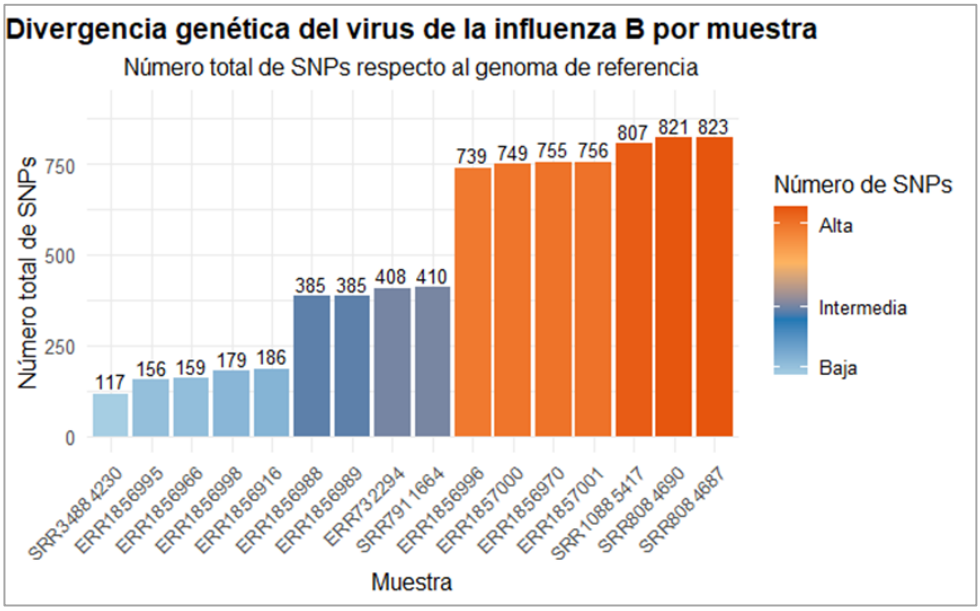


***Figura 4*** Divergencia genética del virus de la influenza B por muestra, expresada como número total de SNPs respecto al genoma de referencia (linaje Yamagata). La escala cromática representa de manera continua el grado de variabilidad, permitiendo distinguir visualmente divergencia baja (azul claro) de 117-186, intermedia (azul oscuro) de 385-410 y alta (anaranjado) de 739-823 SNPs.

### 4.1.3 Distribución y densidad de SNPs por segmento genómico

El análisis de densidad de variantes por segmento genómico del virus de la influenza B reveló una distribución heterogénea de la variabilidad entre los distintos segmentos del genoma, *Figura 5*.

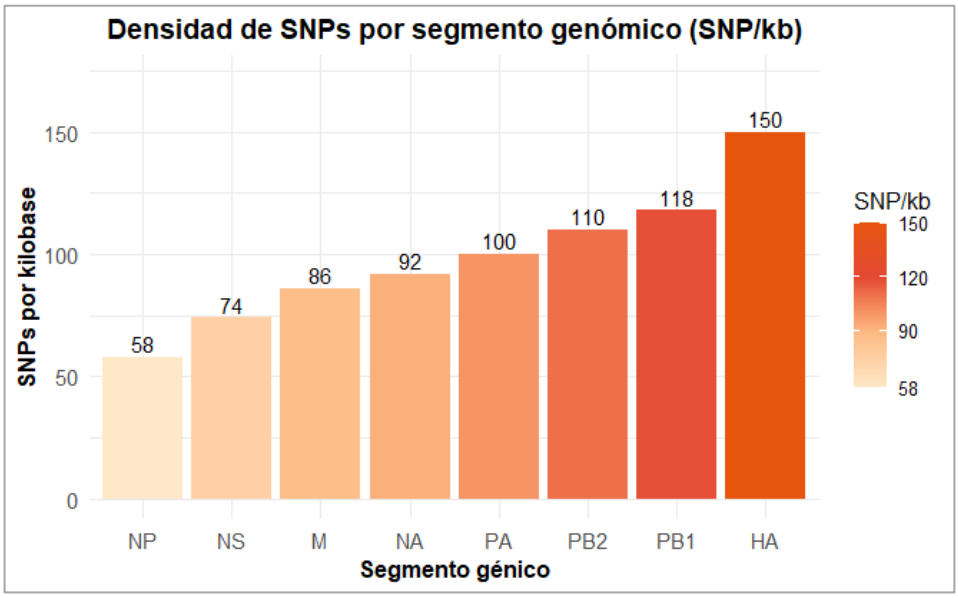


***Figura 5*** Densidad de SNPs por segmento genómico del virus de la influenza B, expresada como SNPs por kilobase (SNP/kb). La escala cromática indica la magnitud relativa de variabilidad genética por segmento, con menor densidad en NP (58 SNP/kb) y con mayor densidad en HA (150 SNP/kb) y

El segmento HA presentó la mayor densidad de SNPs (150 SNP/kb), seguido por PB1 (118 SNP/kb) y PB2 (110 SNP/kb). Se observó que los segmentos PA, NA, M y NS mostraron valores intermedios (100, 92, 86, 74 SNP/kb) respectivamente, mientras que NP presentó la menor densidad de variantes (58 SNP/kb) para completar los 8 segmentos del genoma.

Estos resultados indican que la acumulación de cambios nucleotídicos no se distribuye de manera uniforme en todo el genoma viral. La mayor divergencia relativa observada en HA sugiera una mayor dinámica evolutiva en este segmento, sin embargo, el segmento NP mostró un patrón más conservado dentro del conjunto de muestra analizado.

### 4.1.4 Variantes de alta frecuencia y su distribución genómica

Se evaluó la frecuencia de aparición de los SNPs identificados en el conjunto de muestras, clasificándolos según su nivel de recurrencia. Se identificaron variantes completamente fijadas en el 100% de las muestras, variantes de alta frecuencia 87.5-93.75% y variantes recurrentes en los datasets con un porcentaje de frecuencia ~>68.75%. Entre las mutaciones observadas se observaron mutaciones localizadas en los segmentos HA *Tabla 4*. La fijación completa de estas variantes

sugiere que podría corresponder a diferencias sistemáticas entre los aislamientos analizados y la secuencia de referencia empleada, más que a eventos aislados de variación puntual.

| Segmento | Posición | Cambio | AC | Frecuencia% | Clasificación |
|---|---|---|---|---|---|
| **HA** | 1306 | G→A | 16 | 100 | Fija |
| **PA** | 2061 | G→A | 16 | 100 | Fija |
| **PB1** | 660 | G→A | 16 | 100 | Fija |
| **NS** | 903 | A→G | 15 | 93.75 | Frecuencia alta |
| **HA** | 837 | G→A | 14 | 87.50 | Frecuencia alta |
| **NA** | 1108 | G→A | 14 | 87.50 | Frecuencia alta |
| **HA** | 129 | C→T | 11 | 68.75 | Recurrente |
| **NP** | 741 | C→T | 11 | 68.75 | Recurrente |

***Tabla 4***. Variantes representativas identificadas en el análisis de frecuencia del archivo VCF multi-muestra.

Además de las variantes completamente fijas, se identificaron dos posiciones de alta frecuencia en el segmento HA. La concentración de sustituciones recurrentes en este segmento resulta particularmente relevante desde el punto de vista biológico, dado que HA codifica la hemaglutinina, glicoproteína superficial implicada en el reconocimiento celular y uno de los principales determinantes antigénicos del virus. La presencia de variantes compartidas por la mayoría de las muestras podría reflejar la circulación predominante de un sub linaje especifico o a la acumulación progresiva de cambios asociados a procesos de deriva genética.

Adicionalmente se incluyeron dos variantes clasificadas como recurrentes, una de ellas localizada en la posición 129 del segmento HA. Esta posición fue validada mediante inspección manual en *IGV Figura 6,* confirmando la correcta representación del alelo alternativo en múltiples muestras. Aunque no alcanza el

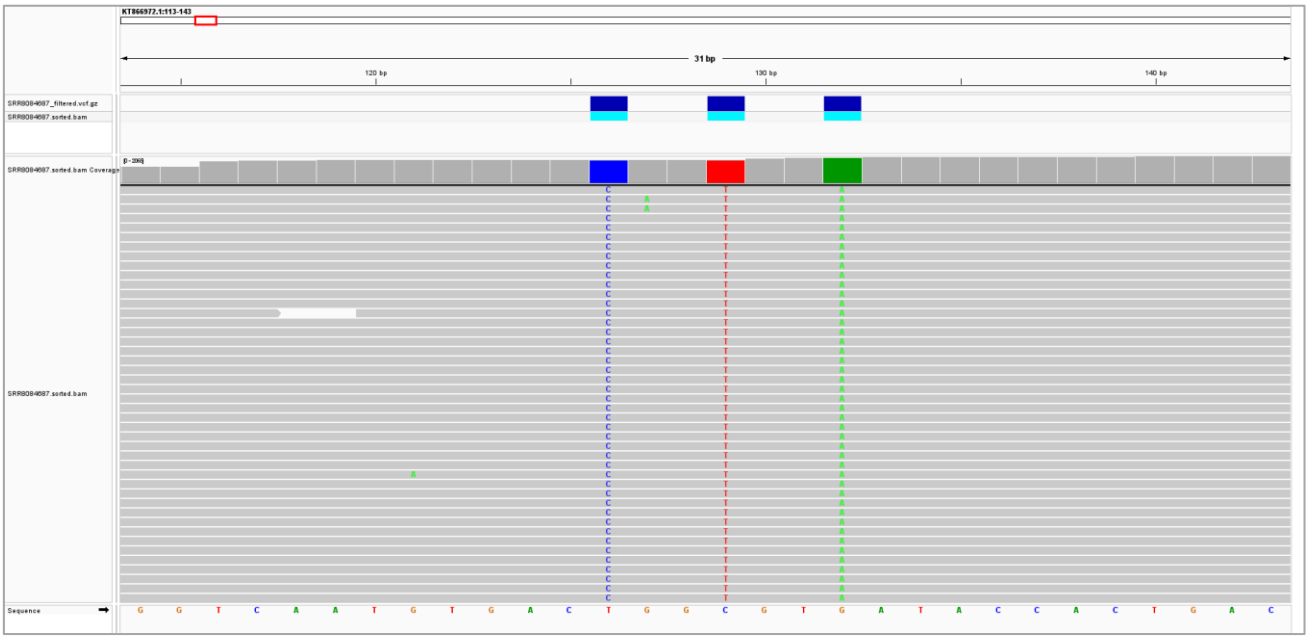


***Figura 6*** Visualización en IGV del alineamiento de lecturas correspondiente a la posición 129 del segmento HA del virus de la influenza B. Se observa la sustitución C→T, evidenciada por la presencia del alelo alternativo en múltiples lecturas alineadas. Profundidad de cobertura en la región señalada. Los colores representan las bases nucleotídicas según codificación estándar en IGV y la escala superior la posición genómica en pares de bases.

umbral definido para alta frecuencia, esta variante tiene una recurrencia alta y su validación visual respaldan su consideración como relevante.

En conjunto la identificación de variantes fijas, de alta frecuencia y recurrentes evidencia la coexistencia de distintos niveles de conservación y variabilidad dentro del conjunto analizado. Mientras que algunas posiciones parecen estar completamente establecidas respecto al genoma de referencia, otras reflejan heterogeneidad parcial entre los aislamientos, lo que sugiere la presencia de ciertas dinámicas evolutivas activas dentro del grupo de datasets.

### 4.1.5 Comparación entre categorías climáticas

Para explorar las diferencias en la variabilidad genética asociadas al contexto climático se comparó el número total de SNPs por muestra según la clasificación climática Köppen-Geiger (tropical, árido, templado y frío continental).

Con el fin de evaluar posibles diferencias en la variabilidad genética entre categorías climáticas, se aplicó el test no paramétrico de Kruskal-Wallis sobre el número total de SNPs. El análisis no evidenció diferencias estadísticamente significativas entre los grupos climáticos ($X^2$=7.4953; gl=3; p=0.0577). No obstante,

el valor de p se aproximó al umbral convencional de significancia (α =0.05), lo que sugiere una posible tendencia marginal hacia diferencias en la distribución del número de SNPs entre categorías climáticas.

Visualmente en la *Figura 7*, las muestras provenientes de regiones tropicales mostraron consistentemente mayores valores de SNPs, mientras que las muestras de climas áridos presentaron menor variabilidad respecto al genoma de referencia. Las muestras de clima templado evidenciaron una mayor dispersión interna en comparación con los otros grupos.

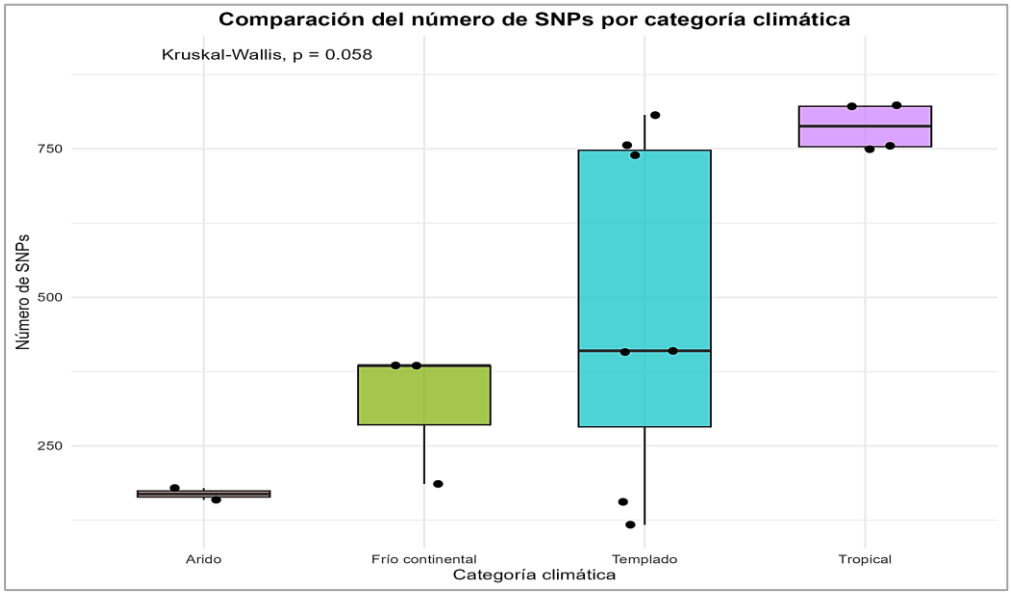


***Figura 7*** Comparación del número total de SNPs por categoría climática según la clasificación de Köppen-Geiger. El grupo templado presenta mayor dispersión en los valores de divergencia genética, mientras que el grupo tropical muestra valores más homogéneos y elevados. Las muestras de clima árido exhiben menor variabilidad relativa. El análisis estadístico mediante Kruskal-Wallis no mostró diferencias estadísticamente significativas entre categorías (*p = 0.05768).*

El tamaño muestral reducido por grupo de categoría climática pudo disminuir la potencia estadística del análisis, por lo que estos resultados deben interpretarse con cautela. Sin embargo, los patrones observados sugieren una posible influencia del contexto ambiental en la variabilidad genética, la cual requeriría un mayor número de muestra por categoría para su confirmación.

### 4.1.6 Análisis filogenético

A partir del alineamiento múltiple de las secuencias consenso completas se realizó la inferencia mediante el método de máxima verosimilitud. El árbol obtenido

permitió evaluar la relación evolutiva entre los 16 datasets analizados con respecto al genoma de referencia.

La topología del árbol evidencio la presencia de agrupamientos diferenciados según la distancia genética acumulada. Se observaron menor divergencia con respecto a la referencia en las ramas representadas con una menor longitud y un conjunto de muestras con mayor número de sustituciones acumuladas con ramas más extensas.

La *Figura 8* muestra el árbol filogenético anotado según la clasificación climática de Köppen-Geiger, no se observó una separación filogenética estricta por la categoría climática, sin embargo; las muestras clasificadas como tropicales se localizaron predominantemente en el clado con mayor distancia genética relativa, mientras que las muestras de clima árido se ubicaron en ramas más cortas y de menor divergencia respecto a la referencia.

Las muestras correspondientes a clima templado y frío continental se distribuyeron en distintos subclados, mostrando así una dispersión más variable dentro de la estructura del árbol.

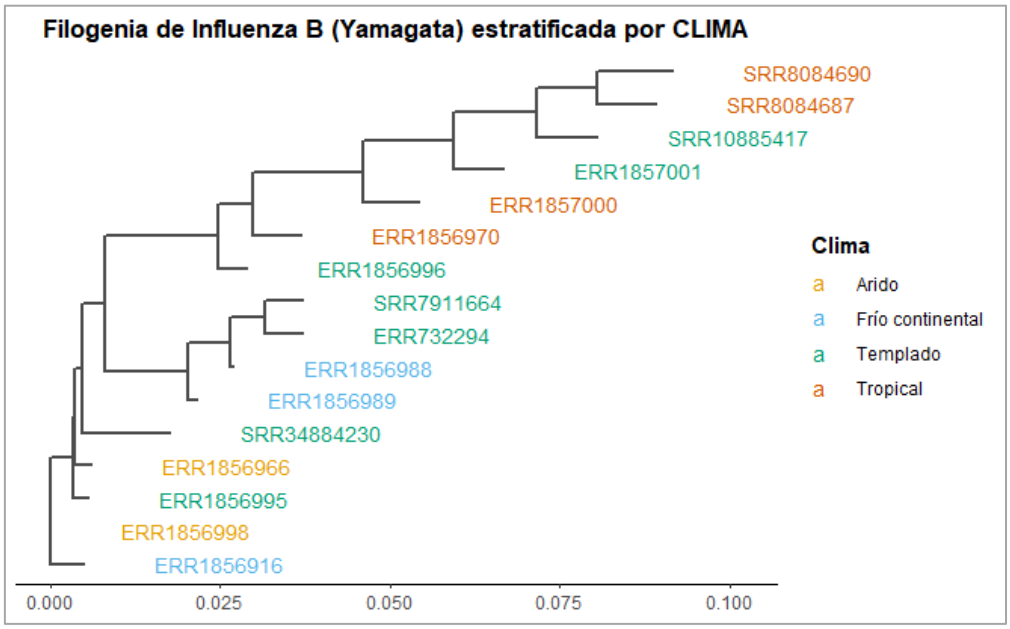


***Figura 8*** Árbol filogenético construido a partir del alineamiento múltiple de las secuencias consenso completas del virus de la influenza B (Yamagata). Los colores de las etiquetas corresponden a la clasificación climática de Köppen-Geiger. La escala horizontal representa el número de sustituciones por grupo.

La *Figura 9* representa el árbol filogenético anotado según el continente de procedencia de cada datasets. De manera similar a la estratificación climática, no

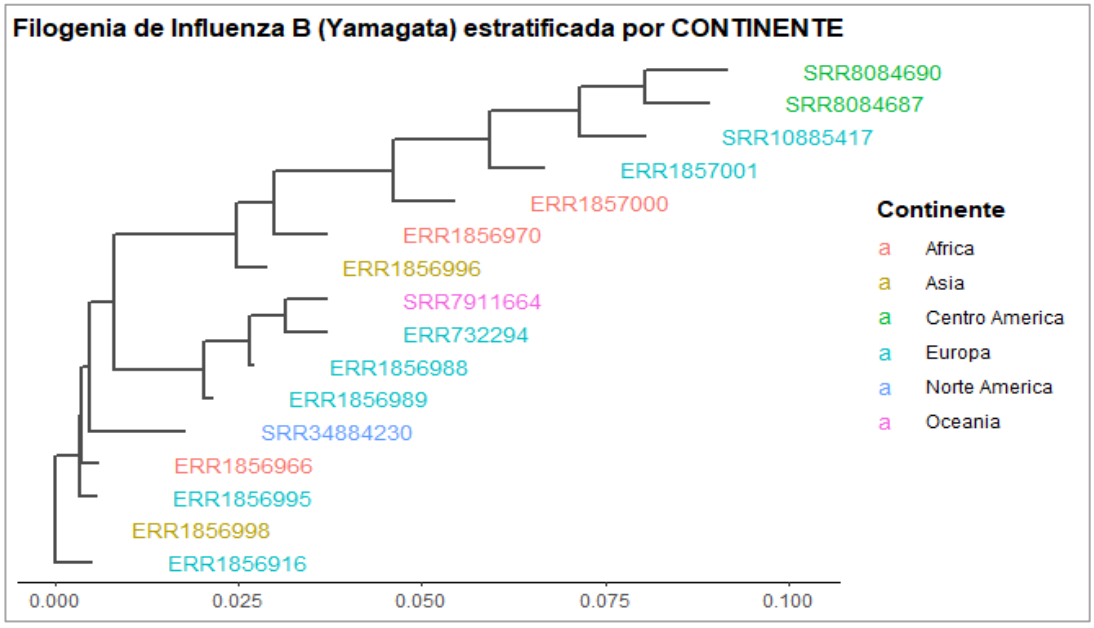


***Figura 9*** Árbol filogenético construido a partir del alineamiento múltiple de las secuencias consenso completas del virus de la influenza B (Yamagata). Los colores de las etiquetas están coloreados según el continente de procedencia. La escala horizontal indica la distancia genética expresada como sustituciones por grupo.

se evidenció una agrupación exclusiva por región geográfica. Datasets provenientes de distintos continentes compartieron clados cercanos dentro del árbol. La distribución geográfica de las muestras no mostró una estructuración filogenética completamente delimitada y marcada con el conjunto de muestras analizado.

En conjunto, el análisis filogenético permitió identificar distintos niveles de divergencia genética entre las muestras incluidas, sin observarse una separación filogenética estricta asociada a la categoría climática o al continente de origen del cual proviene cada una de ellas.

## 4.2 Discusión

El presente trabajó permitió caracterizar la diversidad genética del virus de la influenza B linaje Yamagata mediante análisis comparativo de 16 genomas completos procedentes de distintas regiones geográficas y climáticas. Los resultados evidenciaron la coexistencia de

distintos niveles de divergencia respecto al genoma de referencia, así como una distribución heterogénea de la variabilidad entre segmentos genómicos.

### 4.2.1 Divergencia respecto a la referencia

El rango observado de SNPs por muestra (117-823) refleja una divergencia acumulativa variable dentro del conjunto analizado. Esta heterogeneidad es consistente con la dinámica evolutiva conocida del virus de la influenza B, caracterizada por una deriva genética progresiva impulsada por la actividad de una ARN polimerasa sin mecanismos de corrección de errores (52,53).

Hay es diversos estudios que han demostrado que aunque influenza B presenta una tasa evolutiva menor que influenza, mantiene una acumulación sostenida de mutaciones a lo largo del tiempo (52), con respecto a esto las diferencias observadas entre muestras podrían reflejar variación temporal entre los años de aislamiento incluidas en este trabajo, así como la circulación de subclados distintos dentro del linaje Yamagata.

### 4.2.2 Distribución segmentaria de la variabilidad: predominio de HA

El análisis de densidad de SNPs normalizados por kilo base evidencio una mayor variabilidad relativa relacionada al segmento HA en comparación con otros segmentos como NP. Este hallazgo es coherente con la literatura, que describe a la hemaglutinina como el principal determinante antigénico del virus, por lo tanto, el segmento sometido a mayor presión selectiva inmunológica (54)

La concentración de variantes de alta frecuencia en HA observada en este trabajo respalda la noción de que las regiones antigénicas de esta proteína son puntos críticos de diversidad adaptativa. La acumulación de mutaciones en HA, ha sido ampliamente asociada con este escape inmunológico y con la necesidad de una actualización de cepas vacunales si se requiere (2,55). De acuerdo con los informes de composición de vacunas antigripales de Organización Mundial de la Salud (WHO), la selección de cepas virales para las formulaciones estacionales de vacunas se basa en la vigilancia global de virus circulantes y se actualiza dos veces al año. Las recomendaciones para las temporadasn2024-2025 incluyeron un

componente del linaje B/Yamagata en las vacunas quadrivalentes, aunque los informes recientes señalan que no se considera necesaria su inclusión ante la ausencia de detecciones confirmadas de circulación desde 2020 lo que refuerza su vigilancia genómica.

### 4.2.3 Variantes fijas y de alta frecuencia

La identificación de variantes completamente fijas (AC=16) sugiere la presencia de diferencias sistemáticas entre los aislamientos analizados y la secuencia de referencia utilizada. Este fenómeno puede interpretarse como resultado interpretarse como resultado de divergencia acumulada posterior al aislamiento del genoma B/Alaska/25/2015.

Por otra parte, las variantes de alta frecuencia y recurrentes, particularmente en HA, podrían representar sustituciones características de sub linajes circulantes durante los años incluidos en este trabajo. La persistencia de variantes compartidas entre múltiples muestras es indicativa de transmisión sostenida de genotipos predominantes, más que de mutaciones aisladas o eventos esporádicos.

Estudios previos han descrito que influenza B mantiene patrones de diversificación clonal dentro de cada linaje, con sustituciones que pueden alcanzar alta frecuencia regional antes de su reemplazo por nuevos clados (1).

### 4.2.4 Análisis filogenético y ausencia de segregación estricta por clima

El análisis filogenético basado en máxima verosimilitud no demostró una segregación filogenética estricta en función de la categoría climática ni geográfica. Este patrón es congruente con el modelo de circulación global descrito para virus de influenza y caracterizado por una dinámica meta poblacional con frecuente intercambio interregional. Estudios de filo dinámica global han demostrado que los virus de influenza estacional presentan conectividad elevada entre regiones geográficas, impulsada principalmente por la movilidad humana internacional lo que limita la estructuración genética sostenida por región o clima (3).

En el análisis de patrones globales, Trevor Bedford y colaboradores describieron una red altamente interconectada en la que los linajes virales emergen, se

dispersan y se reintroducen entre continentes en escalas temporales cortas, impidiendo la formación de clados geográficamente aislados de manera estable (3). La ausencia de agrupamiento filogenético estricto por categoría climática sugiere que, aunque las condiciones ambientales pueden influir en la intensidad de transmisión, no parecen generar una presión selectiva suficiente. Este patrón es consistente con estudios de filo dinámica de influenza B que describen la co-circulación de linaje y reemplazo periódico sin una estructuración climática definida. En este contexto, la diversidad genética se mantiene principalmente por procesos de dispersión interregional y acumulación progresiva de mutaciones, más que por adaptación local con respecto al clima (1).

### 4.2.5 Tendencia climática y análisis estadístico

Si bien el test no paramétrico de Kruskal-Wallis no evidencio diferencias estadísticamente significativas entre categorías climática (X=7.49; p=0.0577), el valor marginal cercano al umbral convencional (α = 0305) sugiere la posible existencia de un patrón biológicamente relevante que podría no haberse conectado con plena potencia estadística debido al tamaño muestral limitado por grupo.

En base a la exploración del boxplot, las muestras procedentes de regiones tropicales mostraron en promedio un mayor número de SNPs, respecto al genoma de referencia. Este comportamiento es coherente con la dinámica epidemiológica descrita para influenza en zonas tropicales, donde la circulación viral resulta mantenerse durante periodos prolongados o incluso de forma casi continua a lo largo del año. En contraste con los climas templados, caracterizados por epidemias estacionales más marcadas, la transmisión sostenida en regiones tropicales podría favorecer una acumulación progresiva de sustituciones nucleotídicas en el tiempo (34).

En este sentido, el trabajo de Tamerius JD (34), demostró que los patrones estacionales de influenza varían según condiciones ambientales como temperatura absoluta y humedad, influyendo en la intensidad y persistencia de la transmisión viral. De manera complementaria, estudios posteriores en biometeorología han confirmado que en Influenza variables climáticas como precipitación y humedad relativa pueden modular la dinámica de circulación en regiones tropicales y

subtropicales (56). En conjunto, los hallazgos sugieren que el clima podría actuar como modulador indirecto de la variabilidad genética, influyendo en patrones de transmisión más que en la generación directa de linajes filogenéticamente diferenciados.

## Limitaciones del estudio

Una de las principales limitaciones del presente trabajo estuvo relacionado con la disponibilidad y calidad de datasets públicos en formato FASTQ correspondientes a genomas completos WGS de influenza B, según los años y áreas geográficas variables y los criterios de inclusión. Durante la fase de selección de muestras, se observó que los datasets presentaban cobertura incompleta o muy baja para ser WGS, metadatos no concluyentes de origen y linaje o no cumplían criterios mínimos de calidad para su inclusión en el pipeline bioinformático. En consecuencia, el análisis se restringió a los 16 datasets que cumplían con los requisitos técnicos totales hasta el llamado de variantes confiable. Esta limitación podría influir en la potencia estadística de los análisis comparativos y en la capacidad para detectar patrones filogenéticos o asociaciones climáticas mucho más robustas que las obtenidas.

Futuras investigaciones o proyectos podrían ampliarse mediante la incorporación de nuevos genomas completos en formato FASTq de alta cobertura y calidad provenientes de regiones geográficas subrepresentadas. Una mayor disponibilidad de datasets de alta calidad permitiría aumentar la resolución filogenética y fortalecer los análisis comparativos por contexto climático y geográfico.

# 5. Conclusiones

El presente trabajó cumplió con el objetivo general de analizar la diversidad genética del virus de la influenza B en diferentes regiones climáticas mediante la identificación y comparación de variantes genética a partir de datos de secuencian de genoma completo.

- Se logró identificar variantes genéticas de interés mediante la implementación de un pipeline bioinformático reproducible basado en alineamiento contra referencia, llamado y filtrado de variantes por criterios de calidad (QUAL>30; DP>200). Este enfoque permitió obtener un archivo VCF consolidado a partir del cual se cuantificaron polimorfismos de nucleótido simple (SNPs), clasificadas según sus frecuencias (fijas, alta frecuencia y recurrentes) y se construyeron secuencias consenso completas.
- Se analizó la frecuencia y distribución de mutaciones en función del contexto climático y la procedencia geográfica. El número total de SNPs por muestra mostró heterogeneidad entre aislamientos. El análisis mediante el test de Kruskal-Wallis no evidenció diferencias significativas entre categorías climáticas, aunque se observó una tendencia hacia mayor número de SNPs de regiones tropicales. El análisis filogenético por máxima verosimilitud no mostró segregación estricta ni por clima ni por distribución geográfica, esto sugiere ausencia de estructura genética claramente delimitada por estos factores dentro del conjunto de datasets.
- La interpretación de mutaciones identificadas permitió reconocer patrones relevantes de variabilidad segmentaria. El segmento HA presentó la mayor densidad relativa, coherente con su papel como principal determinante antigénico del virus.

De manera global, los resultados indican que, el conjunto de datos analizado, la diversidad genética del virus de la influenza B responde principalmente a dinámicas de y evolución acumulativa, sin evidencia concluyente de diferenciación genética estructurada hacia la clasificación climática. Sin embargo, la tendencia observada en regiones tropicales sugiere que estudios con mayor tamaño muestras podrían explorar con mayor resolución posibles efectos ambientales sobre la variabilidad viral. Este trabajo demuestra la utilidad de los datos de secuenciación publica y del análisis bioinformático sistemático como

herramientas validad para la caracterización comparativa de la diversidad genética viral en distintos contextos ambientales.

# 6. Referencias bibliográficas


1. Vijaykrishna D, Holmes EC, Joseph U, Fourment M, Su YCF, Halpin R, et al. The contrasting phylodynamics of human influenza B viruses. eLife. 16 de enero de 2015;4:e05055.
2. Recommended composition of influenza virus vaccines for use in the 2024 southern hemisphere influenza season [Internet]. [citado 23 de febrero de 2026]. Disponible en: https://www.who.int/publications/m/item/recommended-composition-of-influenza-virus-vaccines-for-use-in-the-2024-southern-hemisphere-influenza-season
3. Bedford T, Riley S, Barr IG, Broor S, Chadha M, Cox NJ, et al. Global circulation patterns of seasonal influenza viruses vary with antigenic drift. Nature. 9 de julio de 2015;523(7559):217-20.
4. Wu D, Tan Z, Liu Y, Ma M, Chen Z, Wang D, et al. Estimated incidence of influenza in Guangzhou, China, 2019–2022. Infect Med. 1 de diciembre de 2025;4(4):100221.
5. Han J, Yang C, Xiao Y, Li J, Jin N, Li Y. Influenza B virus: Target and acting mechanism of antiviral drugs. Microb Pathog. diciembre de 2024;197:107051.
6. Taubenberger JK, Morens DM. The Pathology of Influenza Virus Infections. Annu Rev Pathol Mech Dis. 1 de febrero de 2008;3(1):499-522.
7. Touré CT, Fall A, Andriamandimby SF, Jallow MM, Goudiaby D, Kiori D, et al. Epidemiology and Molecular Analyses of Influenza B Viruses in Senegal from 2010 to 2019. Viruses. 16 de mayo de 2022;14(5):1063.
8. Krammer F, Smith GJD, Fouchier RAM, Peiris M, Kedzierska K, Doherty PC, et al. Influenza. Nat Rev Dis Primer. 28 de junio de 2018;4(1):3.
9. Lowen AC, Steel J. Roles of Humidity and Temperature in Shaping Influenza Seasonality. Schultz-Cherry S, editor. J Virol. 15 de julio de 2014;88(14):7692-5.
10. World Health Organization. Influenza (Seasonal) [Internet]. Geneva: World Health Organization; 2025 feb. Disponible en: https://www.who.int/news-room/fact-sheets/detail/influenza-(seasonal)
11. van Doorn HR, Yu H. 29 - Viral Respiratory Infections. En: Magill AJ, Hill DR, Solomon T, Ryan ET, editores. Hunter's Tropical Medicine and Emerging Infectious Disease (Ninth Edition) [Internet]. London: W.B. Saunders; 2013. p. 269-74. Disponible en: https://www.sciencedirect.com/science/article/pii/B9781416043904000291
12. Pekarek MJ, Weaver EA. Influenza B Virus Vaccine Innovation through Computational Design. Pathogens. 2 de septiembre de 2024;13(9):755.

13. Petrova VN, Russell CA. The evolution of seasonal influenza viruses. Nat Rev Microbiol. enero de 2018;16(1):47-60.
14. Dumm RE, Heaton NS. The Development and Use of Reporter Influenza B Viruses. Viruses [Internet]. 8 de agosto de 2019 [citado 24 de enero de 2026];11(8). Disponible en: https://www.mdpi.com/1999-4915/11/8/736
15. Gripe (estacional) [Internet]. [citado 6 de febrero de 2026]. Disponible en: https://www.who.int/es/news-room/fact-sheets/detail/influenza-(seasonal)
16. Paget J, Caini S, Del Riccio M, van Waarden W, Meijer A. Has influenza B/Yamagata become extinct and what implications might this have for quadrivalent influenza vaccines? Euro Surveill Bull Eur Sur Mal Transm Eur Commun Dis Bull. septiembre de 2022;27(39):2200753.
17. Poplin R, Ruano-Rubio V, DePristo MA, Fennell TJ, Carneiro MO, Van Der Auwera GA, et al. Scaling accurate genetic variant discovery to tens of thousands of samples [Internet]. Genomics; 2017 [citado 5 de enero de 2026]. Disponible en: http://biorxiv.org/lookup/doi/10.1101/201178
18. CDCespanol. Influenza (Flu). 2025 [citado 5 de febrero de 2026]. Tipos de virus de la influenza. Disponible en: https://www.cdc.gov/flu/es/about/tipos-virus-influenza.html
19. Ashraf MA, Raza MA, Amjad MN, Ud Din G, Yue L, Shen B, et al. A comprehensive review of influenza B virus, its biological and clinical aspects. Front Microbiol. 2024;15:1467029.
20. Langat P, Raghwani J, Dudas G, Bowden TA, Edwards S, Gall A, et al. Genome-wide evolutionary dynamics of influenza B viruses on a global scale. PLoS Pathog. diciembre de 2017;13(12):e1006749.
21. CDCespanol. Influenza (Flu). 2025 [citado 6 de febrero de 2026]. Datos importantes sobre la vacuna contra la influenza estacional. Disponible en: https://www.cdc.gov/flu/es/vaccines/datos-importantes-vacuna-influenza-estacional.html
22. Formato FastQ – Análisis NGS [Internet]. [citado 2 de febrero de 2026]. Disponible en: https://learn.gencore.bio.nyu.edu/ngs-file-formats/fastq-format/
23. Codificación del nivel de calidad [Internet]. [citado 2 de febrero de 2026]. Disponible en: https://support.illumina.com/help/BaseSpace_Sequence_Hub_OLH_009008_2/Source/Informatics/BS/QualityScoreEncoding_swBS.htm
24. Andrews S. s-andrews/FastQC [Internet]. 2026 [citado 2 de febrero de 2026]. Disponible en: https://github.com/s-andrews/FastQC
25. FastQC Tutorial & FAQ - Research Technology Support Facility [Internet]. [citado 4 de febrero de 2026]. Disponible en: https://rtsf.natsci.msu.edu/genomics/technical-documents/fastqc-tutorial-and-faq.aspx
26. Alineador Burrows-Wheeler [Internet]. [citado 23 de febrero de 2026]. Disponible en: https://bio-bwa.sourceforge.net/
27. Shirley. What is samtools and what is it used for? [Internet]. 2025 [citado 5 de febrero de 2026]. Disponible en: https://samtools.org/what-is-samtools-and-what-is-it-used-for/
28. Danecek P, Bonfield JK, Liddle J, Marshall J, Ohan V, Pollard MO, et al. Twelve years of SAMtools and BCFtools. GigaScience. 16 de febrero de 2021;10(2):giab008.
29. Ubuntu 24.04.3 (Noble Numbat) [Internet]. [citado 10 de febrero de 2026]. Disponible en: https://releases.ubuntu.com/noble/
30. Release notes — conda 26.1.1.dev18 documentation [Internet]. [citado 10 de febrero de 2026]. Disponible en: https://docs.conda.io/projects/conda/en/latest/release-notes.html

31. Han H, Lee HJ, Kim KS, Chung J, Na HS. Comparison of the performance of MiSeq and NovaSeq in oral microbiome study. J Oral Microbiol. 16(1):2344293.
32. NCBI [Internet]. [citado 19 de febrero de 2026]. Influenza B virus (B/Lee/1940) genome assembly ViralMultiSegProj14656. Disponible en: https://www.ncbi.nlm.nih.gov/datasets/genome/GCF_000820495.2/
33. Shaman J, Kohn M. Absolute humidity modulates influenza survival, transmission, and seasonality. Proc Natl Acad Sci U S A. 3 de marzo de 2009;106(9):3243-8.
34. Tamerius JD, Shaman J, Alonso WJ, Bloom-Feshbach K, Uejio CK, Comrie A, et al. Environmental predictors of seasonal influenza epidemics across temperate and tropical climates. PLoS Pathog. marzo de 2013;9(3):e1003194.
35. Peel MC, Finlayson BL, McMahon TA. Updated world map of the Köppen-Geiger climate classification. Hydrol Earth Syst Sci. 11 de octubre de 2007;11(5):1633-44.
36. Singh J, Mishra RK, Ayyub SA, Hussain T, Varshney U. The initiation factor 3 (IF3) residues interacting with initiator tRNA elbow modulate the fidelity of translation initiation and growth fitness in Escherichia coli. Nucleic Acids Res. 11 de noviembre de 2022;50(20):11712-26.
37. Burgin J, Ahamed A, Cummins C, Devraj R, Gueye K, Gupta D, et al. The European Nucleotide Archive in 2022. Nucleic Acids Res. 6 de enero de 2023;51(D1):D121-5.
38. Leinonen R, Sugawara H, Shumway M, International Nucleotide Sequence Database Collaboration. The sequence read archive. Nucleic Acids Res. enero de 2011;39(Database issue):D19-21.
39. Influenza virus database - NCBI [Internet]. [citado 12 de febrero de 2026]. Disponible en: https://www.ncbi.nlm.nih.gov/genomes/FLU/Database/nph-select.cgi?go=genomeset
40. Fodor E, te Velthuis AJW. Structure and Function of the Influenza Virus Transcription and Replication Machinery. Cold Spring Harb Perspect Med. septiembre de 2020;10(9):a038398.
41. Bouvier NM, Palese P. THE BIOLOGY OF INFLUENZA VIRUSES. Vaccine. 12 de septiembre de 2008;26(Suppl 4):D49-53.
42. Ajaykumar A, Yang JJ. Integrative Comparison of Burrows-Wheeler Transform-Based Mapping Algorithm with de Bruijn Graph for Identification of Lung/Liver Cancer-Specific Gene. J Microbiol Biotechnol. 28 de febrero de 2022;32(2):149-59.
43. Metagenomics - SAM file format [Internet]. [citado 19 de febrero de 2026]. Disponible en: https://www.metagenomics.wiki/tools/samtools/bam-sam-file-format
44. Metagenomics - SAMtools [Internet]. [citado 19 de febrero de 2026]. Disponible en: https://www.metagenomics.wiki/tools/samtools
45. García-Alcalde F, Okonechnikov K, Carbonell J, Cruz LM, Götz S, Tarazona S, et al. Qualimap: evaluating next-generation sequencing alignment data. Bioinformatics. 15 de octubre de 2012;28(20):2678-9.
46. Lefouili M, Nam K. The evaluation of Bcftools mpileup and GATK HaplotypeCaller for variant calling in non-human species. Sci Rep. 5 de julio de 2022;12:11331.
47. CDCgov/ONT-Seq-analysis [Internet]. Centers for Disease Control and Prevention; 2025 [citado 19 de febrero de 2026]. Disponible en: https://github.com/CDCgov/ONT-Seq-analysis
48. Herramientas bcf - bioconda | Anaconda.org [Internet]. [citado 19 de febrero de 2026]. Disponible en: https://anaconda.org/channels/bioconda/packages/bcftools/overview

49. Katoh K, Misawa K, Kuma K ichi, Miyata T. MAFFT: a novel method for rapid multiple sequence alignment based on fast Fourier transform. Nucleic Acids Res. 15 de julio de 2002;30(14):3059-66.
50. Trifinopoulos J, Nguyen LT, von Haeseler A, Minh BQ. W-IQ-TREE: a fast online phylogenetic tool for maximum likelihood analysis. Nucleic Acids Res. 8 de julio de 2016;44(Web Server issue):W232-5.
51. Ostertagová E, Ostertag O, Kováč J. Methodology and Application of the Kruskal-Wallis Test. Appl Mech Mater. agosto de 2014;611:115-20.
52. Nobusawa E, Sato K. Comparison of the mutation rates of human influenza A and B viruses. J Virol. abril de 2006;80(7):3675-8.
53. Chen R, Holmes EC. The evolutionary dynamics of human influenza B virus. J Mol Evol. junio de 2008;66(6):655-63.
54. Vijaykrishna D, Holmes EC, Joseph U, Fourment M, Su YCF, Halpin R, et al. The contrasting phylodynamics of human influenza B viruses. eLife. 16 de enero de 2015;4:e05055.
55. recommended-composition-of-influenza-virus-vaccines-for-use-in-the-2024-2025-northern-hemisphere-influenza-season.
56. Ma P, Tang X, Zhang L, Wang X, Wang W, Zhang X, et al. Influenza A and B outbreaks differed in their associations with climate conditions in Shenzhen, China. Int J Biometeorol. enero de 2022;66(1):163-73.

# 7. Anexos

## 7.1 Anexo 1: Parámetros de exclusión e inclusión de datasets

Selección y exclusión de datasets utilizados en el presente trabajo, se resume en el *Anexo 1* las principales métricas de calidad obtenidas durante el control de calidad inicial (*FASTQC y fastp*), así como los parámetros de mapeo y cobertura calculados posteriormente.

Se consideraron criterios mínimos de inclusión: calidad media adecuada (Q30 > 85%), lecturas supervivientes tras el filtrado, porcentaje de mapeo al genoma de referencia mayor al 70% y cobertura >200X en una proporción representativa del genoma viral.

***Anexo 1*** Métricas de calidad, mapeo y cobertura obtenida para cada dataset evaluado. Se presentan valores de lecturas iniciales, lecturas supervivientes tras filtrado con fastp, calidad media (Q30, evaluación de calidad por base, porcentaje de lecturas alineadas al genoma de referencia y porcentaje del genoma con cobertura >200X, indicando si cada muestra fue incluida o excluida del análisis final.

| ID acceso | Lecturas iniciales | % Lecturas supervivientes | %Calidad media (Phred Q30 | Pes base sequence quality | %PF | %Mapeo al genoma referencia | % genoma >200X | Incluida/ excluida |
|---|---|---|---|---|---|---|---|---|
| SRR8159111 | 175.004000 K | 23.376000 K | 15.33* | Inadecuada | 13.4* | N/A | N/A | Excluida |
| SRR8159104 | 143.474000 K | 10.256000 K | 9.5* | Inadecuada | 7.1* | N/A | N/A | Excluida |
| SRR5159096 | 196.002000 K | 50.570000 K | 27.7* | Inadecuada | 25.8* | N/A | N/A | Excluida |
| SRR8159085 | 171.294000 K | 64.014000 K | 38.8* | Inadecuada | 37.4* | N/A | N/A | Excluida |
| SRR8159117 | 214.930000 K | 10.734000 K | 6.1* | Inadecuada | 5.0* | N/A | N/A | Excluida |
| *ERR3474676* | 3.523292 M | 2.625986 M | 88.0 | Adecuada | 74.5 | 0.22** | N/A | Excluida |
| *SRR29376859* | 151.678000 K | 146.334000 K | 94.5 | Adecuada | 96.5 | 20** | N/A | Excluida |
| *SRR1928162* | 1.715046 M | 1.604546 M | 96.9 | Adecuada | 93.6 | 16** | N/A | Excluida |
| *SRR1928161* | 1.892698 M | 1.739956 M | 96.9 | Adecuada | 91.9 | 0.69** | N/A | Excluida |

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| **SRR34884230** | 1.993160 M | 1.900036 M | 97.3 | Adecuada | 95.3 | 98.32% | 100 | Incluida |
| **ERR732294** | 738.604000 K | 732.242000 K | 92.8 | Adecuada | 99.1 | 98.31% | 100 | Incluida |
| **ERR1857001** | 1.437812 M | 1.417010 M | 89.6 | Adecuada | 98.6 | 83.47% | 98 | Incluida |
| **ERR1856995** | 1.582868 M | 1.241390 M | 88.4 | Adecuada | 78.4 | 84.84% | 76 | Incluida |
| **ERR1856989** | 1.578610 M | 1.560636 M | 91.1 | Adecuada | 98.9 | 96.64% | 69 | Incluida |
| **ERR1856998** | 1.644464 M | 1.453050 M | 88.8 | Adecuada | 88.4 | 87.59% | 71 | Incluida |
| **ERR1856996** | 1.452406 M | 1.296638 M | 89.1 | Adecuada | 89.3 | 80.81% | 46 | Incluida |
| **ERR1857000** | 1.403600 M | 1.203040 M | 89.8 | Adecuada | 85.7 | 85.90% | 76 | Incluida |
| **ERR1856970** | 1.695506 M | 1.674824 M | 94.9 | Adecuada | 98.8 | 72.20% | 56 | Incluida |
| **ERR1856966** | 1.471644 M | 1.459506 M | 95.2 | Adecuada | 99.2 | 97.96% | 70 | Incluida |
| **SRR10885417** | 875.786000 K | 836.148000 K | 96.8 | Adecuada | 95.11 | 99.55% | 99 | Incluida |
| **SRR8084690** | 432.926000 K | 316.790000 K | 94.8 | Adecuada | 73.20 | 95.94% | 77 | Incluida |
| **SRR8084687** | 521.222000 K | 479.062000 K | 95.0 | Adecuada | 91.9 | 75.85 | 79 | Incluida |
| **SRR7911664** | 490.714000 K | 441.138000 K | 94.2 | Adecuada | 89.9 | 98.73% | 91 | Incluida |
| **ERR1856988** | 1.663108 M | 1.457410 M | 93.3 | Adecuada | 87.6 | 92.28% | 82 | Incluida |
| **ERR1856916** | 1.281990 M | 1.150528 M | 93.4 | Adecuada | 89.7 | 76.83% | 100 | Incluida |

***Nota:*** * indica exclusión por baja calidad post-filtrado.

** indica exclusión por bajo porcentaje de mapeo para confirmar correspondencia con influenza B.

## 7.2 Anexo 2: Comandos utilizados en el pipeline bioinformático

| Paso del pipeline | Scrip/comando |
|---|---|
| a. Control de calidad inicial (FastQC) | *$ fastqc *.fastq.gz* |
| b. Filtrado y trimming (fastp) | *$ for R1 in *_1.fastq.gz*<br>*do*<br>*SAMPLE=${R1%%_1.fastq.gz}*<br>*R2=${SAMPLE}_2.fastq.gz*<br><br>*fastp *<br>*-i "$R1" *<br>*-I "$R2" *<br>*-o "${SAMPLE}_clean_1.fastq.gz" *<br>*-O "${SAMPLE}_clean_2.fastq.gz" *<br>*--html "report_${SAMPLE}.html" *<br>*--json "report_${SAMPLE}.json" *<br>*--detect_adapter_for_pe *<br>*--trim_poly_g *<br>*--cut_front *<br>*--cut_tail *<br>*--qualified_quality_phred 25 *<br>*--length_required 100*<br><br>*done* |
| c. Alineamiento contra genoma de referencia (BWA) | *$ bwa mem ref_yamagata.fasta sample_Clean_1_fastq.gz sample_Clean_2.fastq-gz > sample.sam* |
| d. Conversión y ordenamiento (SAMtools) | *$ samtools view -Sb sample.sam \| samtools sort -o sample.sorted.bam \| samtools indez sample.sorted.bam* |
| e. Evaluación de calidad de alineamiento (Qualimap) | *$ qualimap bamqc -bam sample.sorted.bam -outdir qualimap_report* |
| f. Llamado de variantes multi-muestra (BCFtools) | *$ bcftools mpileup -f ref_yamagata.fasta -b bamlist.txtx -Ou \| bcgtools call -mv –plody 1 -oz -o yamagata_variants.vcf.gz* |
| g. Filtrado de variantes | *$ bcftolls filter -i 'QUAL>=30 && DP>=200' yamagata_variants.vcf.gz -0z -o yamagata_variants_filtered.vcf-gz* |
| h. Generación de secuencias consenso | *$ bcftools consensus -f ref_yamagata.fasta sample.vcf.gz > sample_consensus.fasta* |
| i. Alineamiento múltiple (MAFFT) | *$ mafft –auto consensus_sequences.fasta > alignment.fasta* |

| | |
|---|---|
| **j. Inferencia filogenética (IQ-TREE)** | *$ iqtree3 -s alignment.fasta -m MFP -bb 1000* |
| **k. Cálculo de cobertura >200X** | $ GENOME=$(awk *'{sum+=$2} END {print sum}'* *ref_yamagata.fasta.fai)*<br>For bam in *.sorted.bam<br>do<br>COV=$(samtools Depth -a $bam \| awk *'$3>=200 {count++}* *END {print count}'*<br>PERC=$(echo "scale=2; $COV/$GENOME*100" \| bc)<br>Echo -e "$bam\t$PERC"<br>done |

***Anexo 2.*** Resumen de los principales comandos utilizados en el pipeline bioinformático para el procesamiento, filtrado, llamado de variantes e inferencia filogenética de las secuencias del virus de influenza B (linaje Yamagata). Comandos completos utilizados en entorno Linux (*Ubuntu*) se representan con fines de reproducibilidad.