Universidad Internacional de Valencia

Caracterización Inmunometabólica de *TRIB1* en Hígado por Transcriptómica de Célula Única

Titulación:
Máster en Bioinformática
Curso académico
2025 – 2026

Alumno/a: Ruiz Cantos Miriam
D.N.I: 75121936A

Director/a de TFM: López Zaplana Álvaro

Convocatoria:

Primera

4 Marzo 2026

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Índice

Lista de Abreviaturas 4
Lista de Uniform Resource Locators (URLs) 5
Índice de Tablas 6
Índice de Gráficos y Figuras 6
Resumen y Palabras Clave 7

1. Introducción 1
1.1. Estado del Arte: Tecnologías de Secuenciación de ARN 1
1.2. Introducción al Gen TRIB1 3
1.3. TRIB1 está Implicado en Complejos Sistemas de Regulación Lipídica 5
1.4. Expresión de TRIB1 en el Hígado y sus Poblaciones Celulares 8
1.5. El Análisis de Expresión Génica a Nivel de Célula Única (scRNA-Seq) Permite Identificar TRIB1 en Poblaciones Celulares Hepáticas 11

2. Objetivos 14
3. Metodología 15
3.1. Procedencia de los Datos y Preprocesamiento Inicial 16
3.2. Control de calidad 18
3.3. Normalización y Selección de Características 18
3.4. Reducción de la Dimensionalidad y Agrupamiento No Supervisado 19
3.5. Anotación de Tipos Celulares 19
3.6. Análisis de redes de coexpresión génica ponderada (Weighted Gene Co-expression Network Analysis, WGCNA) 20
3.7. Análisis de Enriquecimiento Funcional de Vías (Gene Ontology) 21
3.8. Análisis de Interacciones Proteína-Proteína 22

4. Resultados y Discusión 23
4.1 Obtención de una Población Celular Robusta 23
4.2 El Atlas Hepático Generado por Azimuth Identifica 19 Subtipos Celulares 25
4.3 Perfil de Expresión de TRIB1: Dualidad Parenquimal-Inmunitaria 27
4.4 El Módulo de Coexpresión de TRIB1 Define una Red de Regulación Inmunológica 28

4.5 La Red de Interacción de TRIB1 Revela un Nodo Central entre el Metabolismo Lipídico y la Regulación Transcripcional....32
4.6 Discusión....34

5. Conclusiones....38
6. Limitaciones y Perspectivas Futuras....39
7. Referencias Bibliográficas....41
8. Anexo....46
8.1 Tablas....46
8.2 Script....59

Lista de Abreviaturas

- **ANN**: Approximate Nearest Neighbors. Vecinos más cercanos aproximados.
- **ARNm**: Ácido ribonucleico mensajero.
- **ATP:** Adenosine Triphosphate. Adenosín trifosfato.
- **BP:** Biological Process. Proceso biológico.
- **bulk RNA-seq:** Bulk RNA sequencing. Secuenciación de ARN en masa (poblacional).
- **cDNA**: Complementary desoxyrribonucleic acid. Ácido desoxirribonucleico complementario.
- **CEBPα/CEBPβ:** CCAAT/enhancer-binding protein alpha/beta. Proteína de unión a la secuencia CCAAT alfa/beta.
- **DC:** Dendritic Cells. Células dendríticas.
- **FDR:** False Discovery Rate. Tasa de falso descubrimiento.
- **GO:** Gene Ontology. Ontología de genes.
- **COP1:** Ubiquitin E3-ligase Constitutive Photomorphogenesis Protein 1.
- **GWAS:** Genome-Wide Association Studies. Estudios de asociación de genoma completo.
- **HLA:** Human Leukocyte Antigen. Antígeno leucocitario humano (complejo mayor de histocompatibilidad humano).
- **HSC:** Hepatic Stellate Cells. Células estrelladas hepáticas.
- **HVGs:** Highly Variable Genes. Genes del alta variabilidad.
- **LDL:** Low-Density Lipoprotein. Lipoproteínas de baja densidad.
- **LSKO**: Liver-Specific Kockout. Truncamiento específico en hígado.
- **MAPK:** Mitogen-Activated Protein Kinase. Proteína quinasa activada por mitógenos.
- **miRNA:** MicroRNA. Micro-ácido ribonucleico.
- **NF-κB:** Nuclear Factor kappa-light-chain-enhancer of activated B cells. Factor nuclear potenciador de las cadenas ligeras kappa de las células B activadas.
- **NK**: Natural Killer. Células linfoides con actividad citotóxica natural.
- **PCA**: Principal Component Analysis. Análisis de components principales.
- **pDC:** Plasmacytoid Dendritic Cells. Células dendríticas plasmocitoides.
- **QC:** Quality Control. Control de Calidad.
- **RNA-seq**: Secuenciación de ARN.

- **STRING:** Search Tool for the Retrieval of Interacting Genes. Herramienta de búsqueda para la recuperación de genes interactuantes.
- **TPM:** Transcripts Per Million. Transcritos por millón.
- **scRNA-seq**: Secuenciación de célula única.
- **SNP**: Single Nucleotide Polymorphisms. Polimorfismos de un solo nucleótido.
- **UMAP:** Uniform Manifold Approximation and Projection. Aproximación y proyección de variedad uniforme.
- **UMI**: Unique Molecular Identifiers. Identificador molecular único.
- **VLDL**: Very Low Density Lipoprotein. Lipoproteínas de muy baja densidad.
- **WGCNA:** Weighted Gene Co-expression Network Analysis. Análisis de redes de coexpresión génica ponderada.

Lista de Uniform Resource Locators (URLs)

1. https://gtexportal.org/home/
2. https://www.biorender.com/
3. https://data.humancellatlas.org/
4. https://github.com/satijalab/azimuth
5. https://azimuth.hubmapconsortium.org/references/#Human%20-%20Liver
6. https://string-db.org/

Universidad Internacional de Valencia

Índice de Tablas

Tabla 1. Paquetes usados para el análisis scRNA-seq en versión de R v4.5.2. 17
Tabla 2. Anexo. Estadísticas de control de calidad por muestra en el conjunto de datos de hígado humano analizado mediante scRNA-seq. 46
Tabla 3. Anexo. Composición y caracterización de las subpoblaciones celulares identificadas. 47
Tabla 4. Anexo. Análisis descriptivo de la expresión de *TRIB1* por linaje celular. 48
Tabla 5. Anexo. Resultados detallados del análisis de enriquecimiento funcional (Gene Ontology: Biological Process).....55
Tabla 6. Anexo. Interacciones proteína-proteína para la red de regulación funcional de TRIB1.....58

Índice de Gráficos y Figuras

Figura 1. Estructura del gen Tribbles..... 3
Figura 2. Secuencia Proteica y Dominios de TRIB1. 4
Figura 3. La Eliminación de *Trib1* Específica en Hígado Altera la Unión de C/EBPα en el Locus de *Trib1*. 7
Figura 4. Niveles de ARN de *TRIB1* en Tejidos Humanos..... 9
Figura 5. Esquema de las Poblaciones Celulares Hepáticas.....10
Figura 6. Esquema general de la metodología scRNA-seq. 13
Figura 7. Esquema del Flujo de Trabajo Bioinformático para el Análisis de Transcriptómica de Célula Única y Redes de Interacción Funcional. 15
Figura 8. Evaluación de la calidad de las bibliotecas de célula única. 23
Figura 9. Análisis de varianza acumulada mediante Elbow Plot. 24
Figura 10. Paisaje transcriptómico del hígado humano a resolución de célula única.....26
Figura 11. Distribución espacial de la expresión de *TRIB1*.....27
Figura 12. Niveles de Expresión de *TRIB1* por Linaje. 28
Figura 13. Dendrograma de agrupación jerárquica de genes y asignación de módulos. ...29
Figura 14. Mapa de calor de la red de coexpresión de *TRIB1*. 30
Figura 15. Enriquecimiento funcional de los procesos biológicos asociados al módulo de co-expresión de *TRIB1*. 31
Figura 16. Red de interacción proteica de TRIB1 humano. 33

Universidad Internacional de Valencia

Resumen y Palabras Clave

El presente trabajo tiene como objetivo esclarecer la incertidumbre existente en torno al origen celular de la señal del gen *Tribbles 1* en el hígado humano. Históricamente, este gen ha sido consolidado como un regulador clave del metabolismo de las grasas y del riesgo cardiovascular; sin embargo, la falta de resolución en los estudios de tejidos completos ha mantenido oculta su distribución específica. El objetivo principal de esta investigación es resolver si la función de este gen es puramente metabólica o si posee un componente inmunitario relevante mediante el mapeo de su señal a nivel de célula individual.

Para abordar este problema, se ha realizado un análisis computacional de datos de secuenciación de ácido ribonucleico de célula única procedentes de un atlas de hígado humano. La metodología emplea la anotación supervisada de tipos celulares, el análisis de redes de co-expresión génica y la modelización de las redes de interacción de proteínas. Este enfoque permite integrar la información de la abundancia del ácido ribonucleico mensajero con la arquitectura física de las proteínas en la célula.

Los resultados muestran un patrón de expresión bimodal. Por una parte, las células hepáticas exhiben la mayor intensidad de expresión, lo que respalda su función metabólica clásica. Por otra parte, los macrófagos inflamatorios y los monocitos presentan una mayor prevalencia y consistencia en la expresión del gen. Además, se ha descubierto que este gen se integra en un módulo funcional coordinado con la maquinaria de presentación de antígenos y con procesos de migración de glóbulos blancos.

Se concluye que el gen objeto de estudio actúa como un sensor inmunometabólico central, cuyo papel en el sistema inmunitario es tan relevante como su función metabólica. Finalmente, se plantea la necesidad de realizar estudios de transcriptómica espacial para validar la comunicación entre las células inmunitarias y metabólicas en contextos de enfermedad.

Palabras clave: Hígado humano**,** Secuenciación de célula única**,** Metabolismo de lípidos, Inmunología hepática, Redes de co-expresión génica, Interacción de proteínas.

1. Introducción

1.1. Estado del Arte: Tecnologías de Secuenciación de ARN

La secuenciación de ARN (RNA-seq) ha supuesto una revolución en el análisis transcriptómico desde su emergencia en 2005 (1), al permitir cuantificar de forma global la expresión génica, detectar variantes de empalme y caracterizar perfiles transcriptómicos completos sin necesidad de conocimientos previos del genoma (2). Sin embargo, su principal limitación deriva de su naturaleza poblacional. La señal obtenida corresponde a un promedio de todos los tipos celulares presentes en un tejido, lo que resulta especialmente problemático en órganos altamente heterogéneos como el hígado, donde coexisten hepatocitos, células de Kupffer, células estrelladas, células endoteliales sinusoidales y múltiples poblaciones linfoides residentes o infiltradas. En estos casos, la interpretación de los niveles de un gen concreto puede inducir a error al no permitir determinar en qué células se expresa realmente.

Este desafío técnico y conceptual impulsó el desarrollo de metodologías capaces de resolver el transcriptoma a nivel de célula individual. La secuenciación de ARN de célula única (scRNA-seq), introducida en 2015 gracias a la microfluídica de gota (3, 4), permite cuantificar miles de transcritos en cada célula, revelando la heterogeneidad intrínseca de los tejidos, identificando poblaciones desconocidas e identificando estados funcionales específicos.

El uso de scRNA-seq ha permitido caracterizar con resolución sin precedentes la diversidad celular de tejidos complejos. Por ejemplo, en la retina humana se ha generado un atlas transcriptómico que identifica todos los tipos celulares neuronales y gliales, revelando subpoblaciones dentro de grupos celulares clásicos y proporcionando firmas moleculares detalladas de cada tipo celular (5). En otro estudio, esta técnica ha posibilitado la identificación de múltiples subtipos celulares y estados transitorios durante la gametogénesis, proporcionando un mapa continuo de desarrollo germinal y revelando nuevos marcadores y transiciones celulares no detectables mediante métodos agregados

(6). Además, la scRNA-seq ha sido clave para reconstruir trayectorias de diferenciación celular y cuantificar la diversidad de estados de desarrollo, como se ha demostrado al emplear medidas de diversidad transcripcional para predecir potenciales de diferenciación en múltiples tipos celulares y tejidos (7). En el contexto de la inmunobiología tumoral, la aplicación de scRNA-seq ha descubierto poblaciones raras de células inmunitarias dentro del microambiente tumoral, incluyendo subtipos de macrófagos y linfocitos con perfiles transcripcionales específicos que se asocian a mecanismos de evasión inmunitaria y progresión de la enfermedad (8). En el hígado, su impacto ha sido relevante: estudios como los de MacParland *et al.*(9) y Aizarani *et al.* (10) han permitido mapear atlas completos de tipos celulares hepáticos, describiendo subpoblaciones zonales de hepatocitos, estados activados de células estrelladas, poblaciones heterogéneas de macrófagos y linfocitos residentes no caracterizados previamente.

El flujo experimental de scRNA-seq incluye la disociación del tejido, el aislamiento de células individuales, la incorporación de códigos de barras moleculares específicos para cada célula (Unique Molecular Identifiers, UMIs), la síntesis de ADN complementario (cDNA) y la construcción de bibliotecas para su secuenciación masiva. En el análisis bioinformático, herramientas como Seurat (11), Scanpy (12) o scvi-tools (13) permiten filtrar calidad, normalizar datos, reducir dimensionalidad, realizar agrupamientos (clustering) y asignar identidades celulares utilizando marcadores conocidos.

Dado que la expresión génica puede variar drásticamente entre tipos celulares, y que genes implicados en inflamación o metabolismo suelen estar representados en subpoblaciones específicas, scRNA-seq se ha convertido en un método esencial para contextualizar la función génica en tejidos complejos. Este es precisamente el caso del gen *TRIB1*, cuyo rol depende de forma crítica del tipo celular donde se exprese, como se detalla en las siguientes secciones.

1.2. Introducción al Gen TRIB1

El primer miembro de la familia de proteínas Tribbles se describió en *Drosophila melanogaster* como un regulador del ciclo celular capaz de bloquear la mitosis mediante la degradación proteosómica de proteínas reguladoras como *String* (14). Heredero de esta familia ancestral, *TRIB1* forma parte, junto con *TRIB2* y *TRIB3*, de una tríada de pseudoquinasas mamíferas altamente conservadas (15). Estudios filogenéticos han mostrado que *TRIB1* y *TRIB2* son más antiguos evolutivamente, mientras que *TRIB3* surgió más tardíamente y presenta características estructurales derivadas, como un intrón adicional en el primer exón (**Figura 1**).

Figura 1. Estructura del gen Tribbles. La forma canónica de este gen contiene 8.046 pares de bases (pb). Las líneas gruesas representan regiones no traducidas (5' y 3' UTR), los rectángulos representan los tres exones y las líneas finas, los dos intrones. Obtenido del ensamblaje del genoma humano GRCh38/hg38.

La proteína TRIB1 está compuesta por tres regiones funcionales bien definidas (**Figura 2**). Su extremo N-terminal contiene un motivo PEST, rico en residuos proclives a la degradación proteica, lo que sugiere que TRIB1 es una proteína de vida media corta sometida a estricta regulación postraduccional (16, 17). En el centro se encuentra el dominio pseudoquinasa, estructuralmente similar a una quinasa serina/treonina pero carente de los residuos esenciales para la unión al adenosín trifosfato (ATP), y por tanto catalíticamente inactivo (18). Este dominio actúa como plataforma de reclutamiento para sustratos proteicos. Finalmente, el dominio C-terminal contiene un motivo QIVPE responsable de la interacción con la ubiquitina E3-ligasa COP1, lo que permite a TRIB1 dirigir a degradación factores de transcripción clave, incluida la proteína C/EBPα (18) y el supresor tumoral TP53 (19).

MRVGPVRSAMSGASQPRGPALLFPATRGVPAKRLLDADDAAAVAAKCPRL
SECSSPPDYLSPPGSPCSPQPPPAAPGAGGGSGSAPGPSRIADYLLLPLA
EREHVSRALCIHTGRELRCKVFPIKHYQDKIRPYIQLPSHSNITGIVEVI
LGETKAYVFFEKDFGDMHSYVRSRKRLREEEAARLFKQIVSAVAHCHQSA
IVLGDLKLRKFVFSTEERTQLRLESLEDTHIMKGEDDALSDKHGCPAYVS
PEILNTTGTYSGKAADVWSLGVMLYTLLVGRYPFHDSDPSALFSKIRRGQ
FCIPEHISPKARCLIRSLLRREPSERLTAPEILLHPWFESVLEPGYIDSE
IGTSDQIVPEYQEDSDISSFFC

Figura 2. Secuencia Proteica y Dominios de TRIB1. Cada línea completa contiene 50 aminoácidos, dibujados a escala, con un total de 372 aminoácidos. Los dominios N-terminal (aminoácidos 1-92) y C-terminal (aminoácidos 340-372) están representados en verde y naranja, respectivamente. Se ha propuesto que el dominio N-terminal afecta su localización celular (*20*). El motivo PEST conservado se representa en violeta. El dominio pseudoquinasa está resaltado en azul. Los aminoácidos (QIVPE) del sitio de unión de la ubiquitin E3-ligase Constitutive Photomorphogenesis Protein 1 (COP1) (*18*) están resaltados en rojo.

La relevancia funcional de TRIB1 se debe a su papel como “andamio molecular” capaz de conectar COP1 con diversas proteínas reguladoras. En el sistema hematopoyético, TRIB1 regula la degradación de C/EBPα y controla la diferenciación de células mieloides (21). Sin embargo, se desconoce si todos los sustratos capturados por el dominio pseudoquinasa de estas proteínas desencadenan un cambio conformacional que promueve su ubiquitinación por COP1 y la posterior degradación a través del proteasoma. En hepatocitos, emergen funciones adicionales relacionadas con el metabolismo lipídico, como se detalla en las secciones siguientes.

1.3. *TRIB1 está Implicado en Complejos Sistemas de Regulación Lipídica*

La primera evidencia que relacionó *TRIB1* con el metabolismo lipídico derivó de estudios de asociación de genoma completo (Genome-Wide Assiciation Studies, GWAS). Entre ellos fueron pioneros Teslovich *et al.*, (22) quienes, analizando más de 100.000 individuos, identificaron polimorfismos de un solo nucleótido (Single Nucleotide Polymorphisms, SNPs) situados 35-60 kilobases aguas abajo de *TRIB1*, como, por ejemplo, el rs2954029, fuertemente asociados a niveles plasmáticos de triglicéridos ($p = 3\times10^{-55}$), así como a variaciones en colesterol de lipoproteínas de alta y baja densidad. Posteriormente, el Global Lipids Genetics Consortium confirmó estas asociaciones en estudios con 188.577 participantes (23). Aunque la función reguladora de estos SNPs aún no ha sido completamente elucidada, se sospecha que podrían influir en elementos reguladores distales implicados en la expresión hepática de *TRIB1*.

La función de *TRIB1* también se extiende a la inflamación. Se ha demostrado que esta proteína juega un papel crucial en el control de citocinas proinflamatorias, como la interleucina-8 (IL-8). Según el estudio realizado por Niespolo *et al.* (24), *TRIB1* actúa como un regulador negativo en las vías de señalización inflamatoria, modulando la expresión de genes asociados a la respuesta inmune. En macrófagos, *TRIB1* regula la producción de IL-8, una citocina clave en la inflamación, mediante un mecanismo de regulación posttranscripcional mediado por microARNs. Estos microARNs actúan sobre la expresión de *TRIB1*, lo que a su vez modula la activación de la cascada inflamatoria. Este mecanismo sugiere que *TRIB1* está implicado no solo en la regulación de la inflamación en células inmunes, sino también, potencialmente, en el control de enfermedades inflamatorias crónicas, en las que la modulación adecuada de citocinas es esencial para una respuesta inmune controlada.

En un estudio publicado por Soubeyrand *et al.* (25), los autores observaron que la supresión de *TRIB1* (porcentaje de supresión no especificado) en hepatocitos humanos primarios conduce a una disminución en la expresión de genes esenciales para el ensamblaje de lipoproteínas de muy baja densidad (VLDL), como la proteína de transferencia de triglicéridos microsomales (MTTP) y apolipoproteína B (APOB). Esto sugiere que *TRIB1* desempeña un papel crucial en la regulación del metabolismo lipídico en hepatocitos

humanos. Aunque la supresión de *TRIB1* disminuye la expresión de estos genes, la secreción de VLDL no se ve significativamente afectada, lo que sugiere la existencia de mecanismos compensatorios en estas células.

Resultados más contundentes provienen de modelos murinos con eliminación específica de *Trib1* en hígado (26). Los ratones *Trib1*-KO presentan aumentos de hasta un 37 % en colesterol total, incrementos de triglicéridos hepáticos del 80 % y hígados más pesados, además de alteraciones en la unión de C/EBPα en el locus de *Trib1*. Estos hallazgos consolidan el papel de *TRIB1* como regulador hepático del metabolismo lipídico. Sin embargo, por el momento se desconoce si los SNPs en el locus de *TRIB1* contribuyen al control de su transcripción.

Evidencia de que *TRIB1* contribuye a la regulación de los niveles de lípidos en plasma proviene de los experimentos realizados por *Bauer et al*. (26), quienes crearon un modelo de ratón denominado *Trib1*-KO (LSKO) por poseer este gen truncado (knockout, KO) específicamente en el hígado (**Figura 3**). En relación con los ratones de tipo salvaje, los ratones macho LSKO tenían un colesterol total plasmático 20-37% más alto dependiendo del sexo. Los hígados (tanto de machos como hembras) de también eran, en promedio, ~25% más pesados y contenían ~80% más de triglicéridos. Sin embargo, los ratones machos no mostraron cambios significativos en los niveles plasmáticos de triglicéridos, mientras que los de los ratones hembra aumentaron en ~50% ($p \leq 0{,}001$). Finalmente, Bauer *et al.*, encontraron diferencias en las cantidades del factor de transcripción C/EBPα unido al locus de *Trib1* en tejido hepático (**Figura 3**). Sin embargo, los autores no plantearon ninguna conclusión sobre la relación entre el aumento de la unión de C/EBPα en estos sitios y la regulación de *Trib1*.

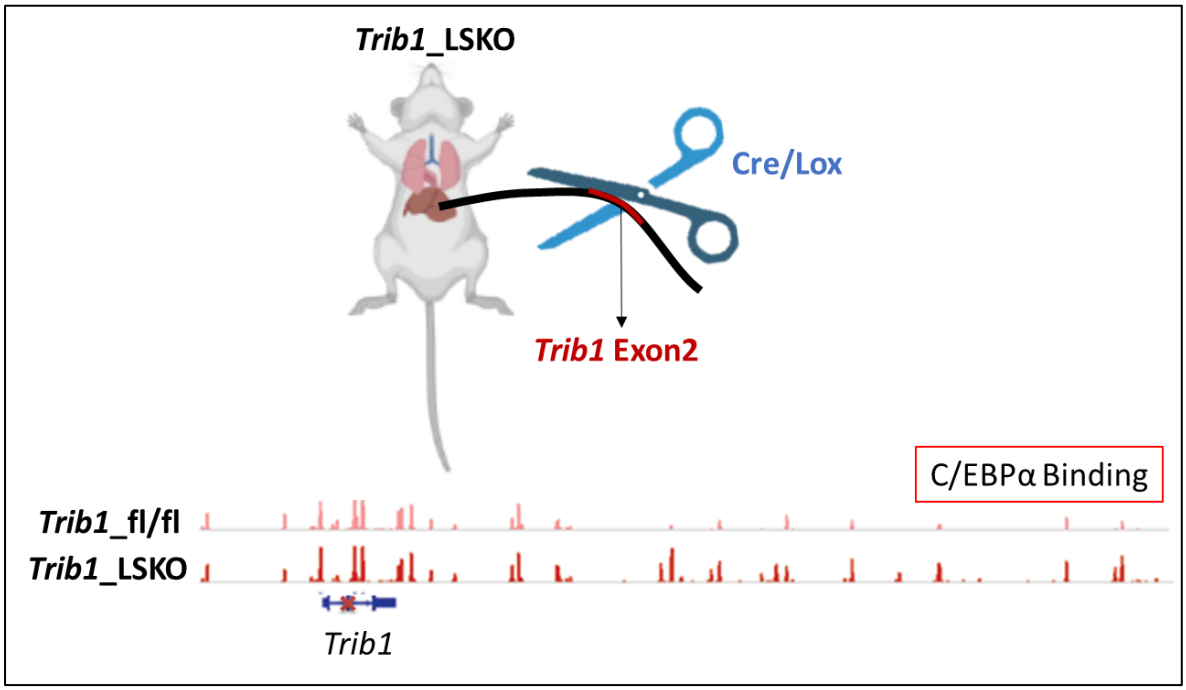

Figura 3. La Eliminación de Trib1 Específica en Hígado Altera la Unión de C/EBPα en el Locus de Trib1. Los ratones con Trib1 truncado específicamente en el hígado (LSKO) se generaron cruzando ratones floxed (fl/fl)-*Trib1 *mediante el sistema de recombinación Cre-Lox. La ocupación de C/EBPα en el locus de Trib1 en muestras de hígado se determinó mediante inmunoprecipitación de cromatina. La cruz roja en Trib1 (5' a 3') indica el exón eliminado (exón 2) en los ratones LSKO. En relación con las muestras de ratones fl/fl, las muestras de hígado de los ratones LSKO muestran diferencias en la cantidad de unión de C/EBPα (líneas rojas) en múltiples ubicaciones corriente abajo de Trib1. La sección de unión de C/EBPα muestra ~100Kb, dibujada a escala. Figura de elaboración propia con adaptaciones de (26).

1.4. Expresión de TRIB1 en el Hígado y sus Poblaciones Celulares

El gen *TRIB1* se aisló inicialmente en tiroides canino (27), lo que coincide con datos del proyecto GTEx, que muestran que la glándula tiroides es el tejido humano con mayor expresión media de *TRIB1* ~155 transcritos por millón de kilobases (Transcripts Per Kilobase Million, TPM) (28). No obstante, el hígado presenta también valores elevados (~35 TPM), comparables a tejidos con actividad metabólica e inmunológica relevante, como sangre periférica, grasa visceral e hígado (**Figura 4**).

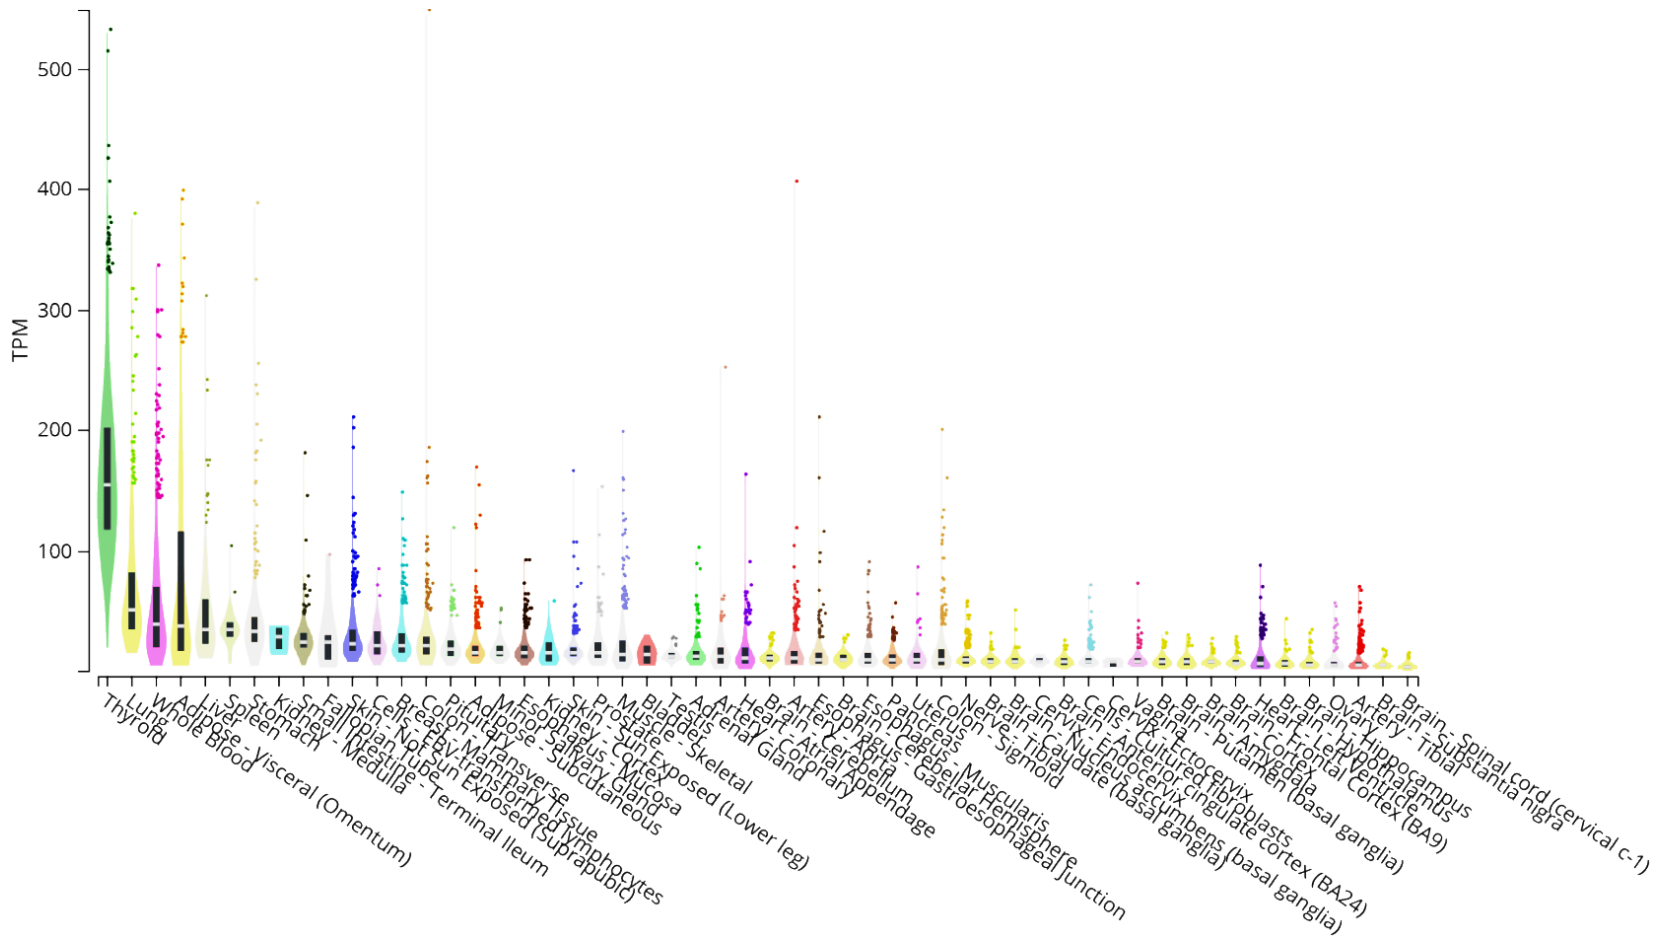

Figura 4. Niveles de ARN de TRIB1 en Tejidos Humanos. Los niveles de ARN de *TRIB1* están ordenados desde el valor medio más alto hasta el más bajo, medidos en transcritos por millón de kilobases (Transcripts Per Kilobase Million, TPM). Los datos se obtuvieron de la base de datos Genotype-Tissue Expression (GTEX, URL1), versión V8, y se muestran utilizando la configuración predeterminada.

En el hígado humano, se ha detectado elevados niveles de ARN de *TRIB1* en múltiples tipos de células, incluidos los hepatocitos, los linfocitos T y los macrófagos asociados a tumores (21, 29-31) y **Figura 5**). Este hecho plantea un problema interpretativo importante: los niveles elevados de *TRIB1* medidos en tejido hepático total pueden reflejar tanto funciones intrínsecas de hepatocitos como la contribución de células inmunes infiltradas. Dado que *TRIB1* regula tanto vías metabólicas como inflamatorias, es esencial determinar qué fracción de su expresión procede de cada población celular. Esta incertidumbre destaca la necesidad de estudios más detallados, como análisis de expresión génica scRNA-seq, para determinar con precisión la contribución relativa de cada población celular a los niveles totales de *TRIB1* en el hígado.

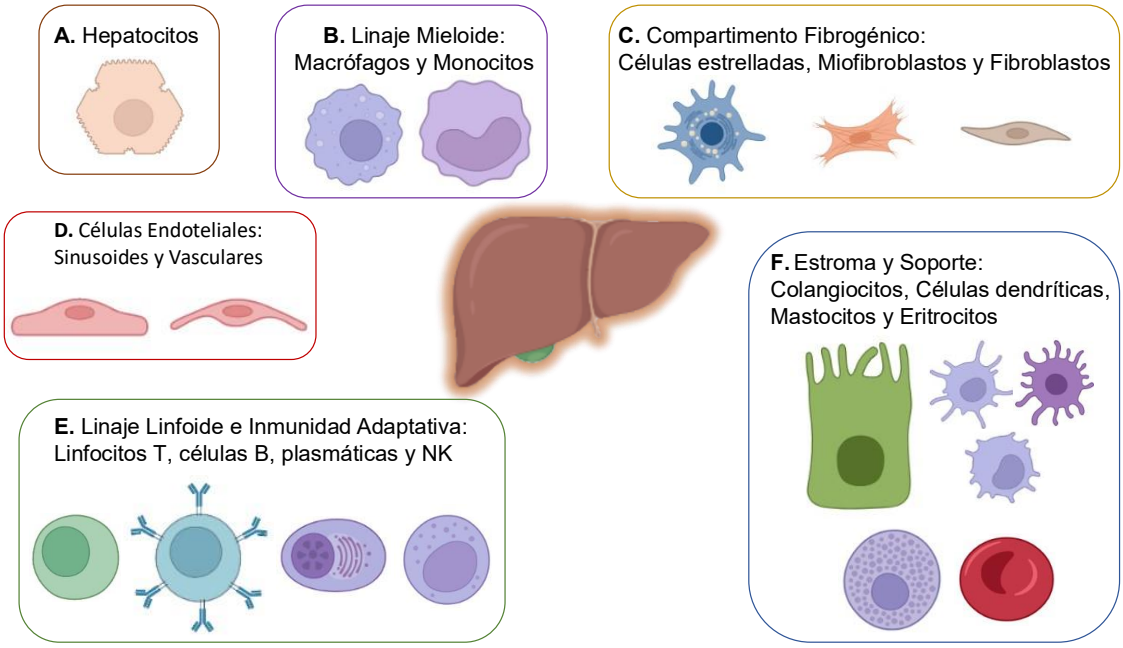

Figura 5. Esquema de las Poblaciones Celulares Hepáticas. A. Hepatocitos: Son las células parenquimales predominantes (70-80% de la masa hepática), responsables de la homeostasis metabólica, incluyendo la síntesis de proteínas plasmáticas y el metabolismo de lípidos y carbohidratos. En estas células, *TRIB1* actúa como un regulador del recambio de lipoproteínas. B. Linaje Mieloide (Macrófagos y Monocitos): Incluye macrófagos inflamatorios, macrófagos no inflamatorios (equivalentes funcionales a las células de Kupffer residentes) y monocitos. Estas

células coordinan la respuesta inmune innata y la eliminación de patógenos. *TRIB1* regula en este compartimento la producción de citocinas pro-inflamatorias, como la interleucina-8, modulando la magnitud de la inflamación tisular (24). C. Compartimento Fibrogénico (Células estrelladas hepáticas (HSC), Miofibroblastos y Fibroblastos Portales): Las HSCs, son los principales reservorios de vitamina A. Junto a los miofibroblastos y fibroblastos portales, estas poblaciones son responsables del remodelado de la matriz extracelular en respuesta al daño crónico. D. Células Endoteliales: El sistema vascular hepático está integrado por células endoteliales sinusoides, que facilitan el intercambio de metabolitos, y células endoteliales vasculares, que revisten los grandes vasos y regulan el flujo sanguíneo y el reclutamiento leucocitario. E. Linaje Linfoide e Inmunidad Adaptativa: Comprende linfocitos T (CD4, CD8 y T/NK proliferantes), células B, células plasmáticas y células NK. La expresión de *TRIB1* en estas células influye en vías de señalización clave como MAPK y NF-κB, afectando la respuesta inflamatoria (32). F. Otras poblaciones del estroma y soporte: Incluye colangiocitos (revestimiento de los conductos biliares), diversas subpoblaciones de células dendríticas (DC1, DC2 y plasmocitoides(pDC)) encargadas de la presentación antigénica, así como mastocitos y eritrocitos. Elaboración propia con imágenes obtenidas de URL2.

1.5. El Análisis de Expresión Génica a Nivel de Célula Única (scRNA-Seq) Permite Identificar TRIB1 en Poblaciones Celulares Hepáticas

A la vista del conocimiento actual, la secuenciación de célula única es la metodología idónea para abordar esta cuestión. El análisis secuenciación masiva de ARN (bulk RNA-seq) no permite resolver si los altos niveles de *TRIB1* se originan en hepatocitos, que lo emplean para regular vías lipogénicas, o en linfocitos y macrófagos infiltrados, donde modula la respuesta inflamatoria. Esta distinción es crucial, ya que la interpretación funcional del gen puede ser diferente según la población celular que domine la señal. La infiltración de células inmunes en el hígado, ya sea por procesos inflamatorios, fibrosis, hígado graso o estados subclínicos, puede alterar de manera sustancial la expresión global de múltiples genes, entre ellos *TRIB1* (33). Sin una resolución celular, no es posible desentrañar estos efectos.

El desarrollo de la secuenciación de ARN de célula única (scRNA-seq) ha revolucionado el estudio de la biología celular al permitir la caracterización detallada de la heterogeneidad celular en tejidos complejos, correlaciones con módulos de coexpresión específicos (metabólicos en hepatocitos e inflamatorios en macrófagos) (9, 34, 35), e identificar regulones y factores de transcripción asociados (36, 37). A diferencia de la secuenciación de ARN en masa (bulk RNA-seq), que proporciona un promedio de la expresión génica en una población celular, scRNA-seq permite capturar y analizar la expresión de genes a nivel individual, facilitando la identificación de subpoblaciones celulares y estados funcionales específicos (38, 39). Esta tecnología, detallada en la **Figura 6,** ha sido fundamental para la caracterización de tejidos como el hígado, donde coexisten múltiples tipos celulares con funciones diferenciadas como los hepatocitos y diversas células inmunitarias infiltradas. En particular, en el estudio publicado por Aizarani *et al.* (10), los investigadores aplicaron la técnica de scRNA-seq para analizar ~10,000 células provenientes de tejido hepático humano normal. Este enfoque les permitió construir un atlas detallado de las células hepáticas, revelando subtipos previamente desconocidos en diferentes compartimentos celulares

Por todo ello, el uso de scRNA-seq constituye la única estrategia capaz de responder con precisión a la pregunta central: ¿de qué tipos celulares proceden los niveles elevados de *TRIB1* observados en el hígado humano? La resolución de esta cuestión permitirá avanzar en la comprensión del papel *TRIB1*, así como en su posible implicación en enfermedades hepáticas, cardiovasculares e inflamatorias.

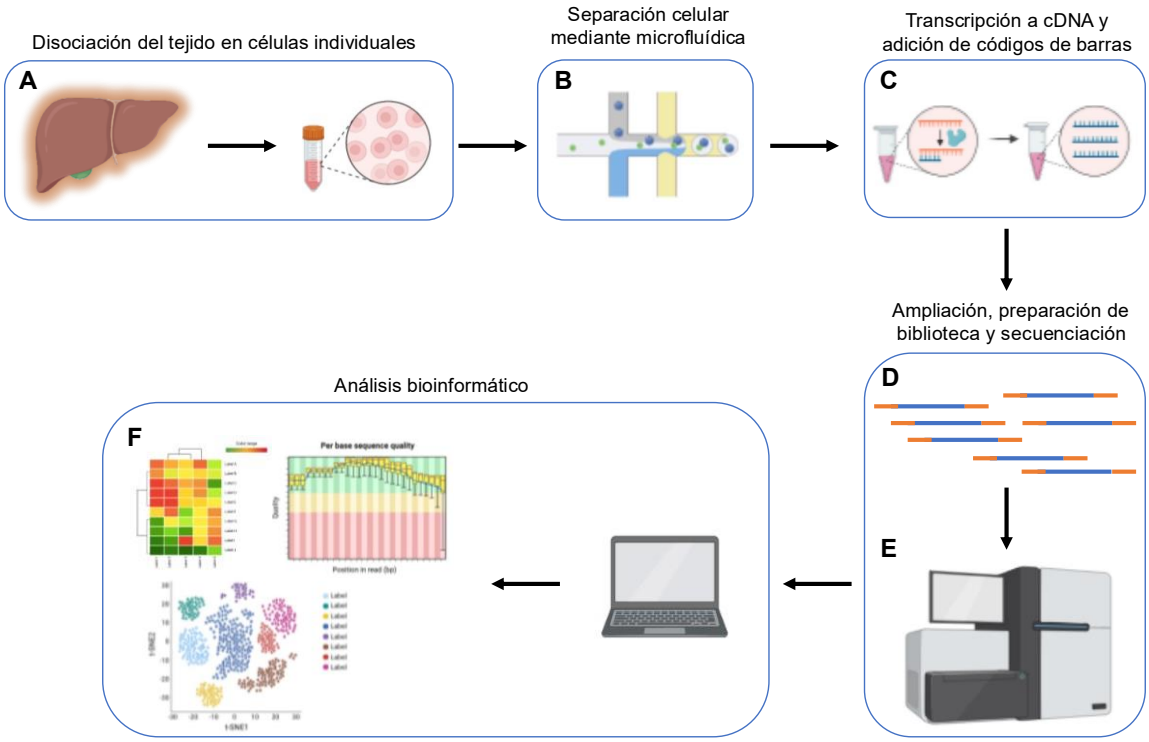

Figura 6. Esquema general de la metodología scRNA-seq. El procedimiento de scRNA-seq consta de varias etapas fundamentales. A. Primero, el tejido de interés se disocia en células individuales mediante digestión enzimática o separación mecánica. B. Posteriormente, se aísla cada célula utilizando tecnologías basadas en microfluidos, captura en gota o citometría de flujo. C. Una vez aisladas, las células son lisadas y su ARN mensajero (ARNm) es convertido en ADN complementario (cDNA) mediante transcripción inversa. En esta fase, se añaden códigos de barras moleculares únicos (Unique Molecular Identifiers, UMIs) para etiquetar el ARNm de cada célula, permitiendo su identificación en análisis posteriores. D, E. Una vez generado el cDNA, se procede a su amplificación y preparación de la biblioteca, seguida de su secuenciación. F. Los datos obtenidos requieren un procesamiento bioinformático extenso, que incluye la eliminación de lecturas de baja calidad, normalización de la expresión génica y reducción de dimensionalidad mediante algoritmos que permite agrupar células en clústeres en función de su perfil transcriptómico (39). Adaptado de (38). Elaboración propia con imágenes obtenidas de URL2.

2. Objetivos

El objetivo principal de este trabajo es dilucidar el perfil de expresión celular del gen *TRIB1* en el tejido hepático mediante el análisis scRNA-seq, con el fin de determinar si su señal transcriptómica proviene predominantemente de hepatocitos o del infiltrado inmunitario. Para llevarlo a cabo, se plantean los siguientes objetivos específicos:

1. **Identificar y cuantificar las poblaciones celulares que expresan *TRIB1*:** Analizar conjuntos de datos de scRNA-seq para determinar qué tipos celulares (hepatocitos, células mieloides, células estrelladas o linfocitos) expresan *TRIB1* y cuantificar la contribución relativa de cada población a la señal global.
2. **Realizar un análisis diferencial de expresión:** Comparar los niveles de transcrito de *TRIB1* entre las distintas poblaciones identificadas para discernir si la expresión es constitutiva de los hepatocitos o inducida en células inmunitarias residentes o infiltradas.
3. **Inferir implicaciones funcionales:** Correlacionar la expresión de *TRIB1* con otros genes marcadores de vías metabólicas e inflamatorias mediante análisis de coexpresión, así como identificar sus interacciones con otras proteínas, con el fin de integrar los hallazgos en el contexto de la fisiopatología hepática y del metabolismo lipídico.

3. Metodología

De manera general, el presente estudio se ha estructurado en las siguientes fases metodológicas (**Figura 7**), diseñadas para transformar los datos transcriptómicos crudos en una caracterización funcional y mecánica de *TRIB1* en el contexto hepático humano:

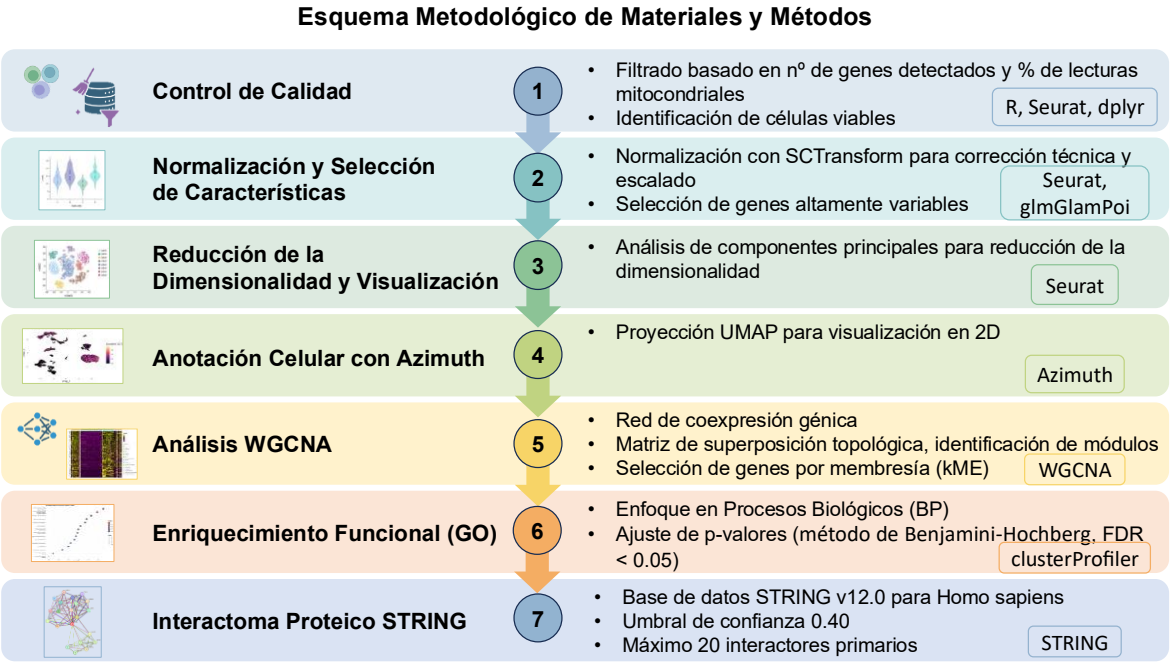

Figura 7. Esquema del Flujo de Trabajo Bioinformático para el Análisis de Transcriptómica de Célula Única y Redes de Interacción Funcional. El procedimiento se inicia con un control de calidad diseñado para identificar células viables mediante parámetros genómicos y metabólicos, seguido de una fase de normalización y estabilización de la varianza técnica empleando el método SCTransform. Posteriormente, se realiza la reducción de dimensionalidad y el agrupamiento celular no supervisado para la visualización de la arquitectura tisular, permitiendo la asignación de identidades celulares sobre atlas de referencia hepáticos validados a través de la herramienta Azimuth. Finalmente, el flujo de trabajo integra el análisis de redes de coexpresión génica ponderada (WGCNA) para la detección de módulos funcionales interconectados, la evaluación de la relevancia biológica mediante el enriquecimiento de ontología (GO) de procesos biológicos y la caracterización del

interactoma proteico mediante la base de datos STRING para definir las asociaciones físicas y funcionales de la proteína de estudio.

3.1. Procedencia de los Datos y Preprocesamiento Inicial

El presente estudio se realizó a partir de datos de secuenciación de ARN de célula única de tejido hepático humano, publicados originalmente por MacParland *et al.* (9), y obtenidos a través del repositorio del Human Cell Atlas (**URL3**). Se accedió al conjunto de datos denominado *HumanLiver.zip*, el cual contenía una matriz de conteos correspondiente a 20.007 genes y 8.444 células derivadas de cinco muestras hepáticas. El procesamiento bioinformático y el análisis estadístico se llevaron a cabo en el entorno R (v4.5.2), empleando principalmente el paquete Seurat (v5.4.0) para el flujo de trabajo de single-cell, junto con ggplot2 para la generación de gráficos avanzados (**Tabla 1**). El script completo se encuentra disponible en el Anexo, apartado 8.2.

Paquete	Versión	Fuente	Funcionalidad y Aplicación
Seurat	5.4.0	CRAN	Análisis principal de datos scRNA-seq: control de calidad, normalización (SCTransform), identificación de genes altamente variables, reducción de dimensionalidad (PCA, UMAP), construcción de grafo de vecinos, clustering y visualización.
glmGlamPoi	1.22.0	R-universe [bioc-release]	Motor estadístico utilizado internamente por SCTransform para ajustar modelos de regresión negativa binomial de forma eficiente.
Patchwork	1.3.2	CRAN	Composición y organización de figuras múltiples en paneles
dplyr	1.1.4	CRAN	Manipulación y transformación de datos (filtrado, agrupación, resumen estadístico para cálculos como el porcentaje de células que expresan *TRIB1*).
ggplot2	4.0.1	CRAN	Generación de gráficos: scatterplots de QC, gráficos de violín y mapas de calor.

Azimuth	0.5.0	GitHub [satijalab/azimuth]	Transferencia supervisada de etiquetas celulares mediante comparación con atlas de referencia hepático.
WGCNA	1.74.0	CRAN	Análisis de redes de coexpresión génica. Construcción de redes y detección de módulos de genes con patrones de expresión coordinados.
clusterProfiler	4.18.4	Bioconductor	Análisis de enriquecimiento funcional. Herramienta estadística para la interpretación biológica de listas de genes.
org.Hs.eg.db	3.22.0	Bioconductor	Base de datos de mapeo integral que contiene información sobre la estructura y función de los genes humanos. Utilizado para transformar los identificadores de tipo Gene Symbol a Entrez ID.

Tabla 1. Paquetes usados para el análisis scRNA-seq en versión de R v4.5.2. *Seurat* es un paquete ampliamente validado para análisis de transcriptómica unicelular. Implementa métodos robustos de modelado de varianza y clustering basados en grafos (40, 41). *GlmGlamPoi* mejora la velocidad y estabilidad numérica del modelado de conteos dispersos típicos de scRNA-seq, especialmente en datasets grandes. *Patchwork* facilita la generación de figuras con paneles en ggplot2, manteniendo consistencia estética entre gráficos. *Dplyr* permite manejo reproducible y eficiente de data frames. *Ggplot2* es un paquete de visualización creador de gráficos, ampliamente utilizado en análisis reproducible en R. *Azimuth* permite anotación automática de tipos celulares utilizando datasets de referencia curados (como los del Human Cell Atlas (URL3)), mediante el algoritmo de transferencia de anclas implementado en Seurat. *WGCNA* facilita la construcción de redes de coexpresión y la identificación de módulos de genes con perfiles de expresión similares. *ClusterProfiler* proporciona un marco estadístico robusto para el análisis de sobre-representación funcional y la interpretación biológica de grupos de genes. *Org.Hs.eg.db* actúa como la base de datos de anotación genómica humana indispensable para el mapeo y conversión de identificadores de genes (Gene Symbols a Entrez IDs), garantizando la interoperabilidad entre las distintas herramientas de análisis.

3.2. Control de calidad

Se implementó un control de calidad riguroso para excluir células de baja viabilidad o artefactos técnicos. Se calcularon tres métricas por célula: el número de genes detectados, el recuento total de UMIs y el porcentaje de lecturas mitocondriales. El porcentaje mitocondrial se determinó manualmente cuantificando la proporción de lecturas asignadas a genes con el prefijo "MT-". El análisis preliminar mostró una distribución de expresión mitocondrial con una media del 15.61% y un máximo del 49.98%. Dado que el hígado es un órgano con alta actividad metabólica, es esperable un contenido mitocondrial basal más alto que en otros tejidos (42); sin embargo, valores extremos (~50%) indican lisis celular o estrés durante la disociación. Por consiguiente, se aplicaron los siguientes criterios de filtrado de acuerdo con las recomendaciones publicadas por Luecken & Theis, 2019 (43):

- Genes detectados: Se retuvieron células con más de 200 genes (para excluir gotas vacías) y menos de 5.000 genes (para minimizar la presencia de dobletes) de acuerdo con las métricas de control de calidad observadas (**Figura 4.1**).
- Contenido mitocondrial: Se estableció un umbral superior del 35% de lecturas mitocondriales. Este corte permitió conservar la población de hepatocitos funcionales (metabólicamente activos) mientras se eliminaban las células con membrana comprometida, los cuales presentan valores atípicos de hasta 50%.

Esto redujo el número de células en el estudio de 8.444 a 7.947, situando el número de células eliminadas por alta actividad mitocondrial y/o dobletes en 497 (**Tabla 2**, Anexo).

3.3. Normalización y Selección de Características

Para corregir las diferencias en la profundidad de secuenciación y estabilizar la varianza, se aplicó el método Seurat::SCTransform (40). Este algoritmo corrige diferencias técnicas entre células y permite la detección de genes altamente variables y el escalado. Durante este paso, se identificaron los 2.000 genes con mayor variabilidad (Highly Variable Genes, HVGs) para guiar la reducción de dimensionalidad.

3.4. Reducción de la Dimensionalidad y Agrupamiento No Supervisado

Se realizó un Análisis de Componentes Principales (Principal Component Analysis, PCA) sobre los resultados de SCTransform para reducir la dimensionalidad del espacio transcriptómico. La selección de componentes principales significativos se basó en el método de diagrama de codo, seleccionándose los primeros 20 componentes principales, los cuales capturaron la mayor parte de la varianza biológica. Para el agrupamiento celular, se construyó un grafo de vecinos más cercanos (*k-Nearest Neighbors*, k-NN) mediante Seurat::FindNeighbors en el espacio reducido del PCA, seguido de la aplicación del algoritmo de optimización de modularidad de Louvain. Se utilizó una resolución de 0.6, lo que permitió una segmentación granular equilibrada de las poblaciones celulares. Finalmente, se utilizó la técnica de Aproximación y Proyección de Variedad Uniforme (Uniform Manifold Approximation and Projection, UMAP) para la visualización en dos dimensiones, preservando la estructura global y local de los datos.

3.5. Anotación de Tipos Celulares

La identificación de los tipos celulares se realizó mediante un enfoque de transferencia de etiquetas basado en referencias, utilizando la herramienta Azimuth (11). Este método proyecta las células del dataset de consulta sobre un atlas de referencia validado de hígado humano (**URL4**). El proceso implica la identificación de "anclas" de transferencia entre el dataset y la referencia, permitiendo la asignación automática y probabilística de identidades celulares con alta precisión, evitando así el sesgo potencial de la anotación manual basada únicamente en marcadores canónicos.

Dado que la referencia específica para tejido hepático humano no se encuentra incluida en la instalación por defecto del paquete de R, fue necesario obtener los recursos de referencia externamente desde el repositorio oficial del HubMAP Consortium (**URL5**), el cual contiene referencias derivadas de nueve publicaciones independientes. Para el presente estudio, se descartó el nivel general (Level 1 o l1), que agrupa las células en linajes amplios (ej. fagocitos mononucleares o células T), y se optó por utilizar el nivel detallado (l2). La anotación l2 permite una caracterización de mayor resolución biológica, distinguiendo 23

subtipos y estados funcionales críticos para el análisis (ej. diferenciando entre células de Kupffer, macrófagos inflamatorios y macrófagos no inflamatorios).

La integración de la referencia se realizó de forma manual mediante la descarga de dos archivos esenciales que constituyen el modelo de predicción:

- ref.Rds: Un objeto Seurat procesado que contiene los perfiles de expresión normalizados, la estructura de reducción de dimensionalidad y los metadatos de las células que conforman el atlas de referencia.
- idx.annoy: Un índice binario de búsqueda de "vecinos más cercanos aproximados" (Approximate Nearest Neighbors, ANN), generado mediante la biblioteca Annoy. Este archivo es crucial computacionalmente, ya que permite mapear rápidamente las células del dataset de consulta contra las células de la referencia sin necesidad de calcular todas las distancias exactas, optimizando el tiempo de ejecución.

El mapeo se ejecutó mediante la función Azimuth::RunAzimuth, especificando en el argumento “reference” la ruta al directorio local donde se alojaron ambos archivos (idx.annoy y ref.Rds). Este procedimiento proyectó las células del presente estudio sobre la referencia, transfiriendo las etiquetas l2 y asignando una puntuación de predicción para validar la confianza de la asignación automática.

3.6. Análisis de redes de coexpresión génica ponderada (Weighted Gene Co-expression Network Analysis, WGCNA)

Para identificar redes de regulación génica y módulos funcionales asociados a *TRIB1*, se realizó un Análisis de Redes de Coexpresión Génica Ponderada (Weighted Gene Co-expression Network Analysis, WGCNA) utilizando el paquete de R “WGCNA” (44). Dado el carácter disperso de los datos de single-cell, el análisis se restringió a los 2.000 genes con mayor variabilidad identificados previamente con Seurat::VariableFeatures. Al no encontrarse *TRIB1* entre ellos, se añadió manualmente a la matriz de entrada.

Primero, se realizó un paso de control de calidad para eliminar células o genes con muchos ceros en la matriz con WGCNA::goodSamplesGenes. Seguidamente, se construyó una red de coexpresión génica "con signo" (signed network) para detectar correlaciones positivas y

negativas entre genes. El objetivo de este paso es alcanzar una topología libre de escala, una característica intrínseca de las redes biológicas donde la mayoría de los genes tienen pocas conexiones y solo unos pocos están conectados. Seqguidamente,se realizó un análisis de barrido de potencias del 1 al 20 utilizando la función WGCNA::pickSoftThreshold. Se estableció un umbral de criterio de ajuste $R^2 > 0.90$. Posteriormente, se calculó la matriz de superposición topológica (Topological Overlap Matrix, TOM) para medir la interconexión entre genes. Este tipo de matrices consideran no solo si dos genes están relacionados directamente, sino también si comparten vecinos comunes en la red para identificar módulos (clústeres) de genes altamente interconectados. La detección de módulos se realizó con WGCNA::blockwiseModules mediante agrupamiento jerárquico con el algoritmo de corte dinámico de ramas (dynamic tree cut), estableciendo una potencia de 7 y un tamaño mínimo de módulo de 30 genes.

Para validar la asignación de los módulos y observar el comportamiento transcripcional de los genes identificados, se generó un dendrograma de agrupamiento jerárquico usando WGCNA::plotDendroAndColors, donde las ramas representan la disimilitud basada en la matriz de solapamiento jerárquico (Topological Overlap Matrix, TOM) y los colores indican los módulos detectados por el algoritmo. Para explorar esta red local, se seleccionaron los 50 genes con mayor valor de membresía (Module Eigengene Connectivity, kME) respecto al perfil de expresión de *TRIB1* con WGCNA::moduleEigengenes. La coexpresión de estos genes se visualizó mediante un heatmap, donde las células se agruparon según su linaje celular. Este enfoque permitió confirmar visualmente si el programa génico asociado a *TRIB1* muestra una especificidad por tipos celulares concretos dentro del atlas hepático, eliminando el ruido de fondo y resaltando las señales de expresión más robustas.

3.7. Análisis de Enriquecimiento Funcional de Vías (Gene Ontology)

Con el fin de interpretar la función biológica de los genes coexpresados con *TRIB1*, se realizó un análisis de enriquecimiento funcional centrado en la ontología de Procesos Biológicos (Biological Process, BP). Este análisis permite identificar si una función biológica concreta está sobrerrepresentada en nuestra lista de genes más allá de lo esperado por el azar. Para ello, se utilizó el paquete de R clusterProfiler (v4.18.4). Dado que las anotaciones de Gene Ontology requieren identificadores estandarizados, se procedió a la conversión de

los identificadores de genes, Gene Symbols, a Entrez IDs mediante la base de datos de anotación genómica humana org.Hs.eg.db con clusterProfiler::bitr. En este proceso se alcanzó una tasa de mapeo exitosa del 94.09%.

El cálculo de la significación estadística del enriquecimiento se realizó mediante un test con múltiples parámetros utilizando clusterProfiler:: enrichGO. Para mitigar el riesgo de obtener falsos positivos debido a las comparaciones múltiples, los p-valores resultantes se ajustaron utilizando el método de Benjamini-Hochberg, también conocido como False Discovery Rate (FDR). Se establecieron como umbrales de significación un p-valor ajustado < 0.05 y un q-valor < 0.05. Los resultados se presentan mediante un dotplot, donde los términos GO se jerarquizan en función de su ratio de genes y su nivel de confianza estadística, permitiendo discernir los procesos biológicos clave en los que TRIB1 ejerce su función reguladora.

3.8. Análisis de Interacciones Proteína-Proteína

Para caracterizar la red de interacciones físicas y funcionales de la proteína TRIB1, se empleó la base de datos STRING (Search Tool for the Retrieval of Interacting Genes, **URL6**) versión 12.0. El análisis se realizó seleccionando como organismo de referencia a *Homo sapiens*. Se configuró una red de interacción completa ("full STRING network") utilizando un umbral de confianza medio (score: 0.40). La red se restringió a un máximo de 20 interactores directos en la primera capa de interacción para facilitar la visualización de los nodos principales. Las interacciones representadas incluyen tanto asociaciones físicas directas como contribuciones funcionales derivadas de bases de datos curadas, experimentos de laboratorio y minado de textos.

4. Resultados y Discusión

4.1 Obtención de una Población Celular Robusta

El control de calidad permitió obtener un dataset final de 7.947 células de alta viabilidad con una expresión detectable de 20.007 genes. La distribución de lecturas mitocondriales mostró una media del 15.61%, con una cola de distribución que alcanzaba el 49,98% en células potencialmente estresadas. Al aplicar el umbral de corte del 35%, se logró un equilibrio entre la eliminación de restos celulares y la retención de células funcionales (**Figura 8**). El filtrado resultó en la eliminación de 497 células (5,8% del total), correspondientes mayoritariamente a dobletes o células con lisis celular avanzada.

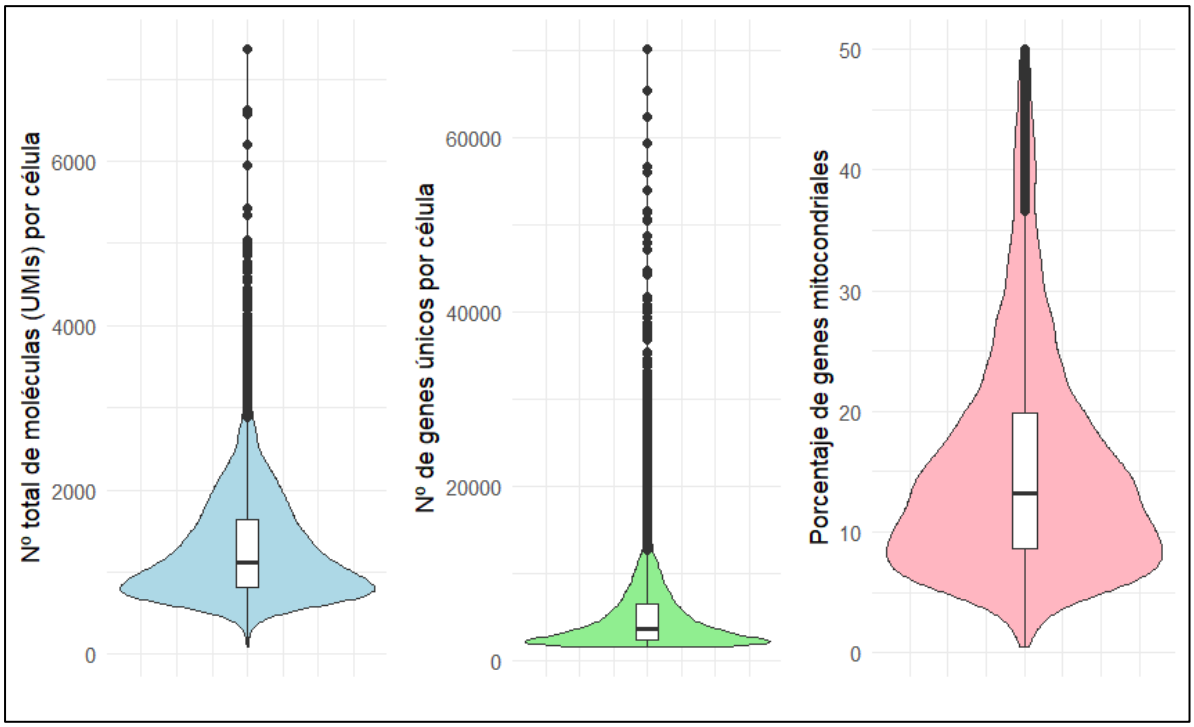

Figura 8. Evaluación de la calidad de las bibliotecas de célula única. Representación mediante diagramas de violín de las tres métricas fundamentales de control de calidad antes del filtrado. Azul: recuento total de moléculas (UMIs), verde: número de

genes detectados por célula y rosa: porcentaje de lecturas mapeadas al genoma mitocondrial. La distribución muestra una alta heterogeneidad mitocondrial, típica de tejido hepático, con una media del 15,61%. Los puntos negros representan células individuales.

El análisis de PCA confirmó que los primeros 20 componentes eran suficientes para explicar la variabilidad biológica, mostrando una saturación clara a partir del componente 15 en el Elbow Plot (**Figura 9**).

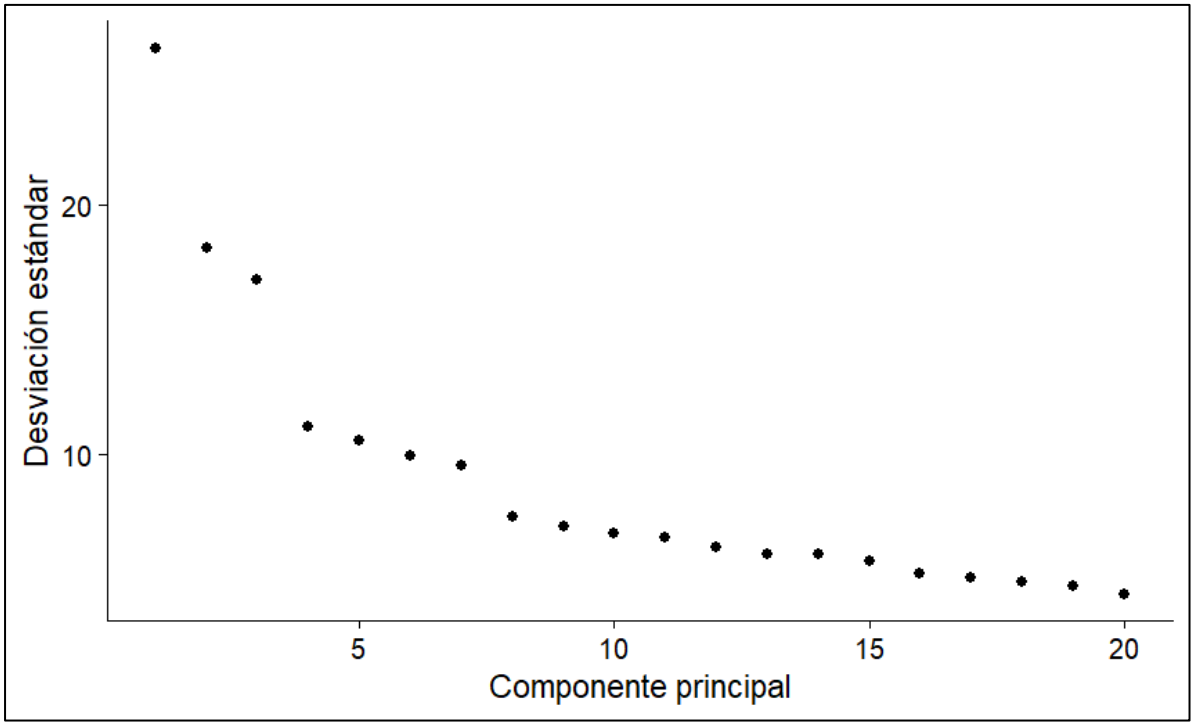

Figura 9. Análisis de varianza acumulada mediante Elbow Plot. Distribución del porcentaje de varianza explicada por cada componente principal derivado de la reducción de dimensionalidad lineal. El "punto de inflexión" o codo se observa en varios puntos (7, 11, 15); no obstante, debido a la elevada complejidad celular del hígado (estimada en 23 subtipos según la referencia de Azimuth), se seleccionaron los primeros 20 componentes para el agrupamiento posterior. El objetivo de esta decisión pretende garantizar la captura de señales biológicas sutiles necesarias para diferenciar subpoblaciones raras del infiltrado inmune.

4.2 El Atlas Hepático Generado por Azimuth Identifica 19 Subtipos Celulares

La reducción de dimensionalidad mediante PCA y la posterior proyección UMAP revelaron una estructura celular altamente compartimentada. La transferencia de etiquetas mediante Azimuth permitió la anotación supervisada de 19 de los 23 tipos celulares presentes en el nivel L2 (**Figura 10**), con una mediana de puntuación de predicción de 0,89. Esto significa que la mitad de las células presentes en el análisis están asignadas a un grupo con casi un 90% de confianza, encontrándose por encima del corte del 0,75 que se considera robusto para un análisis scRNA.seq (45). La distribución celular mostró que los hepatocitos constituyen la población mayoritaria, con un porcentaje del 43,85% (3.485 células), seguidos de los linfocitos CD4 T (14,28%), macrófagos no inflamatorios (6,09%), células plasmáticas (5,96%), NK CD56bright (5,66%) y monocitos (5,21%) (**Tabla 3**, Anexo).

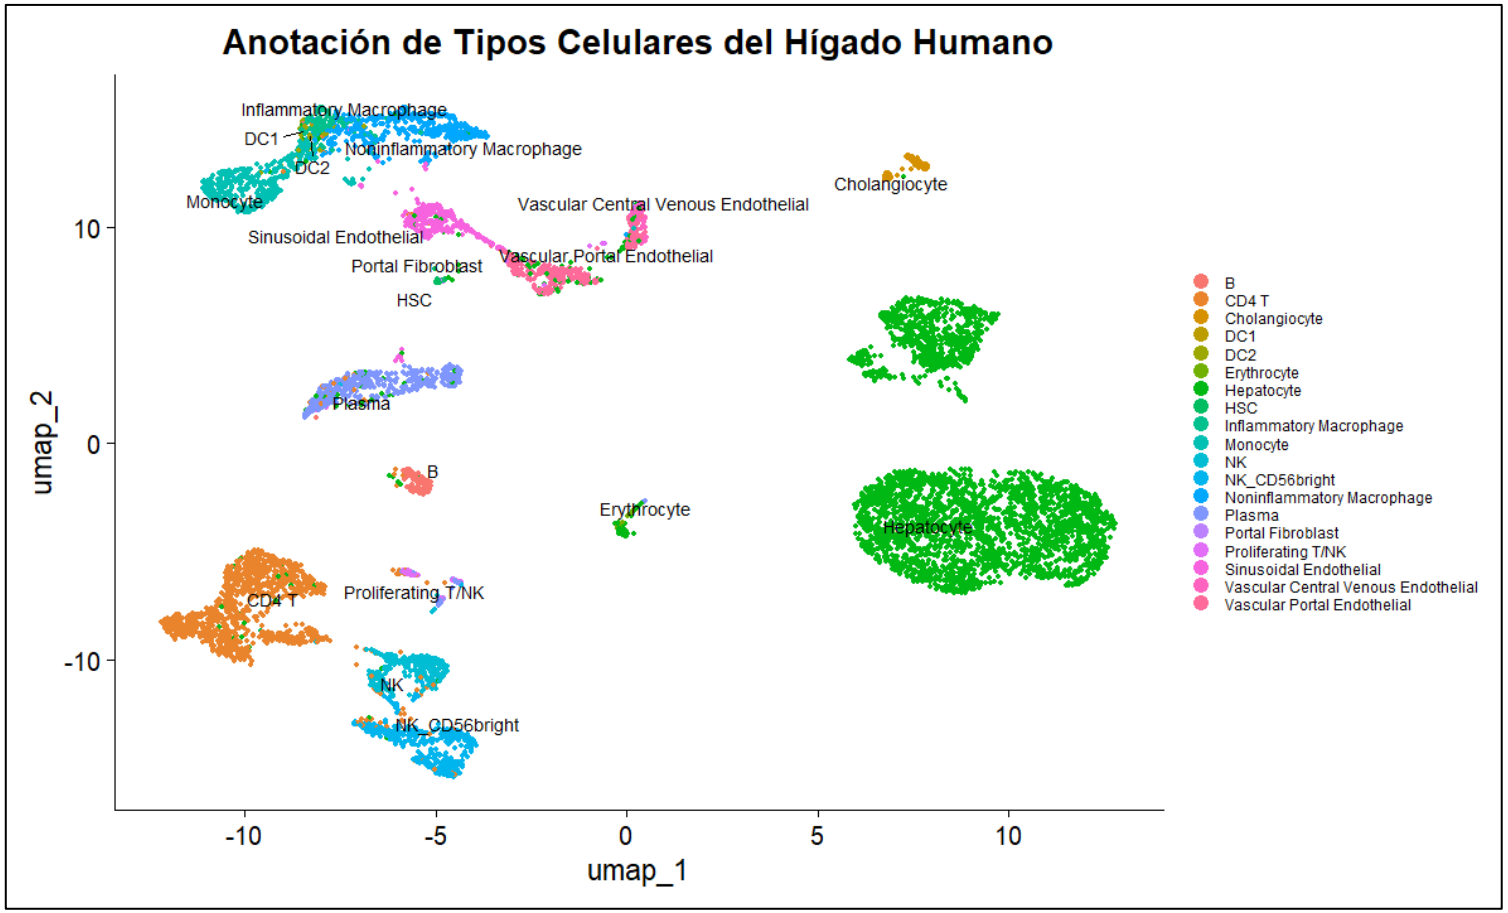

Figura 10. Paisaje transcriptómico del hígado humano a resolución de célula única. Proyección UMAP de 7.947 células tras el control de calidad. Los colores identifican los 19 subtipos celulares anotados mediante la transferencia de etiquetas supervisada de Azimuth (Nivel L2). Se observa una clara separación entre el compartimento parenquimal (hepatocitos) y el sistema inmunitario mieloide y linfoide.

4.3 Perfil de Expresión de TRIB1: Dualidad Parenquimal-Inmunitaria

El análisis de la expresión de *TRIB1* sobre el espacio UMAP y mediante métricas cuantitativas reveló un patrón de expresión bimodal (**Figura 11**). En la población inmunitaria mieloide los macrófagos inflamatorios presentaron la mayor prevalencia de expresión, siendo detectado en un 23,91% de células y una intensidad de expresión máxima de 1,39 (**Figura 12**). Las células plasmáticas (15,19% con 1.39 de expresión) y los macrófagos no inflamatorios (15,91% con 1.39 de expresión) también mostraron señales consistentes. En los hepatocitos, el porcentaje de células expresoras fue ligeramente inferior (20%), aunque la intensidad máxima alcanzó un valor de 1,95, el más alto detectado en todo el dataset (**Tabla 4**, Anexo).

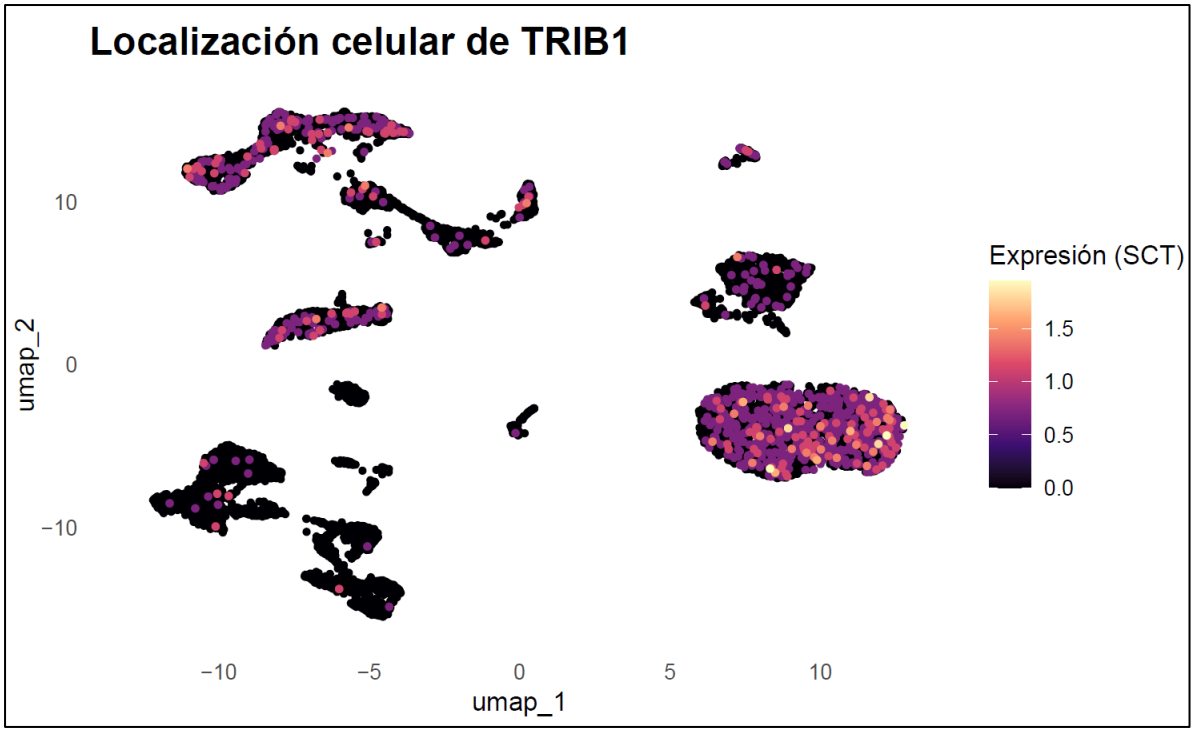

Figura 11. Distribución espacial de la expresión de *TRIB1*. Mapa de expresión donde la intensidad del color representa los niveles log-normalizados de *TRIB1*. La señal se concentra de forma bimodal en el clúster de hepatocitos y en el nicho de macrófagos y monocitos.

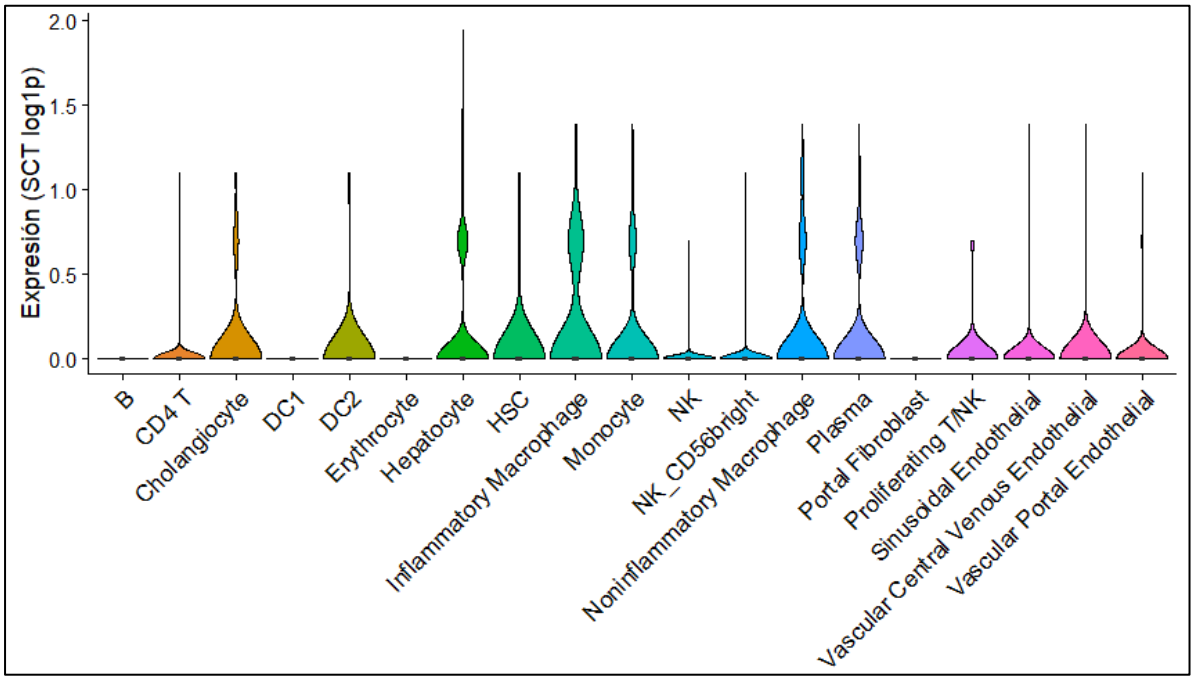

Figura 12. Niveles de Expresión de *TRIB1* por Linaje. Este diagrama representa la distribución de los niveles de ARN mensajero normalizados (SCT log1p) en los 19 subtipos celulares identificados en el tejido hepático. El eje vertical representa la intensidad máxima de la señal y el horizontal, la prevalencia de la expresión dentro de la población.

4.4 El Módulo de Coexpresión de TRIB1 Define una Red de Regulación Inmunológica

El análisis de coexpresión mediante WGCNA integró a *TRIB1* en un módulo regulador (módulo gris), el cual contiene 1.472 genes, caracterizado por la presencia de genes involucrados en inmunidad adaptativa y presentación antigénica (**Figura 13**).

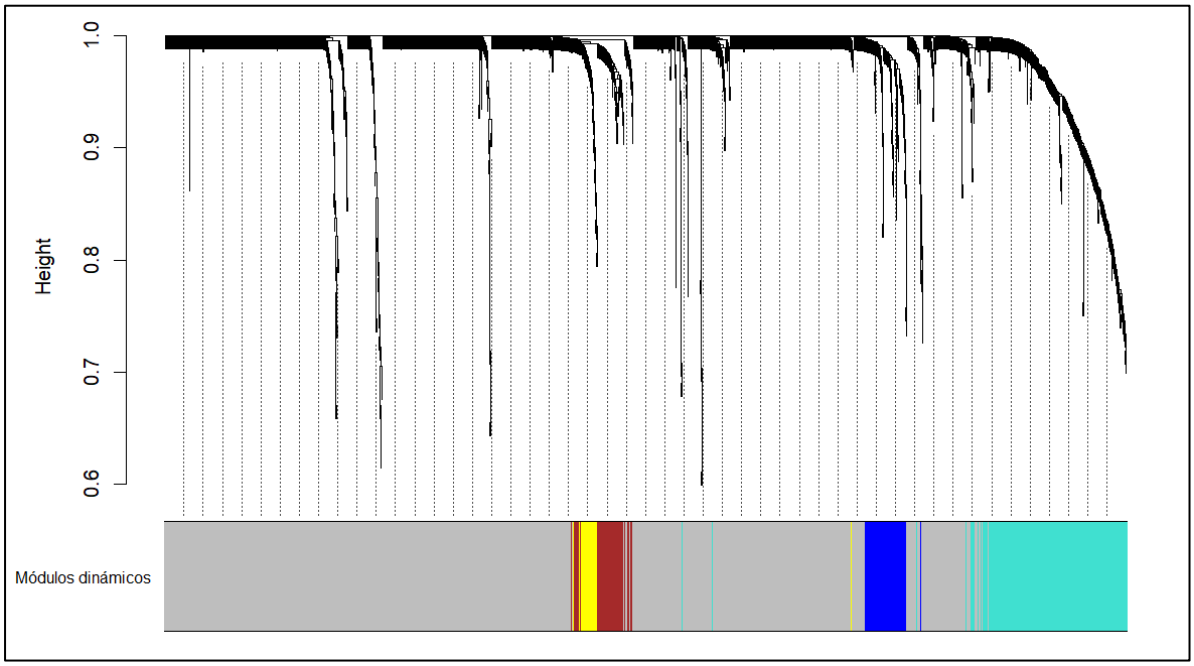

Figura 13. Dendrograma de agrupación jerárquica de genes y asignación de módulos. Representación de la red de coexpresión basada en la topología de solapamiento topológico. En el eje vertical, las "ramas" representan grupos de genes con perfiles de expresión coordinados. La barra inferior indica los colores de los módulos identificados, donde TRIB1 se sitúa en el módulo gris, el cual contiene 1.472 genes. La cantidad de genes para el resto de módulos fue la siguiente: rojo = 81, amarillo = 40, azul = 91 y turquesa = 317.

Entre los 50 genes con mayor conectividad al nodo de *TRIB1* (**Figura 14**), destacaron los componentes del complejo mayor de histocompatibilidad de clase I (*HLA-A, HLA-B, HLA-C y HLA-E*) y la microglobulina *B2M*. Asimismo, se identificaron co-expresores críticos como *SRGN* (Serglicina), implicada en el almacenamiento de mediadores inflamatorios, y *ARHGDIB*, regulador de la migración leucocitaria. Otros nodos importantes de la red incluyeron efectores de adhesión y estructura como *TMSB10 y TMSB4X*, así como una maquinaria de traducción activa (*RPS3, RPL10, EEF1A1*).

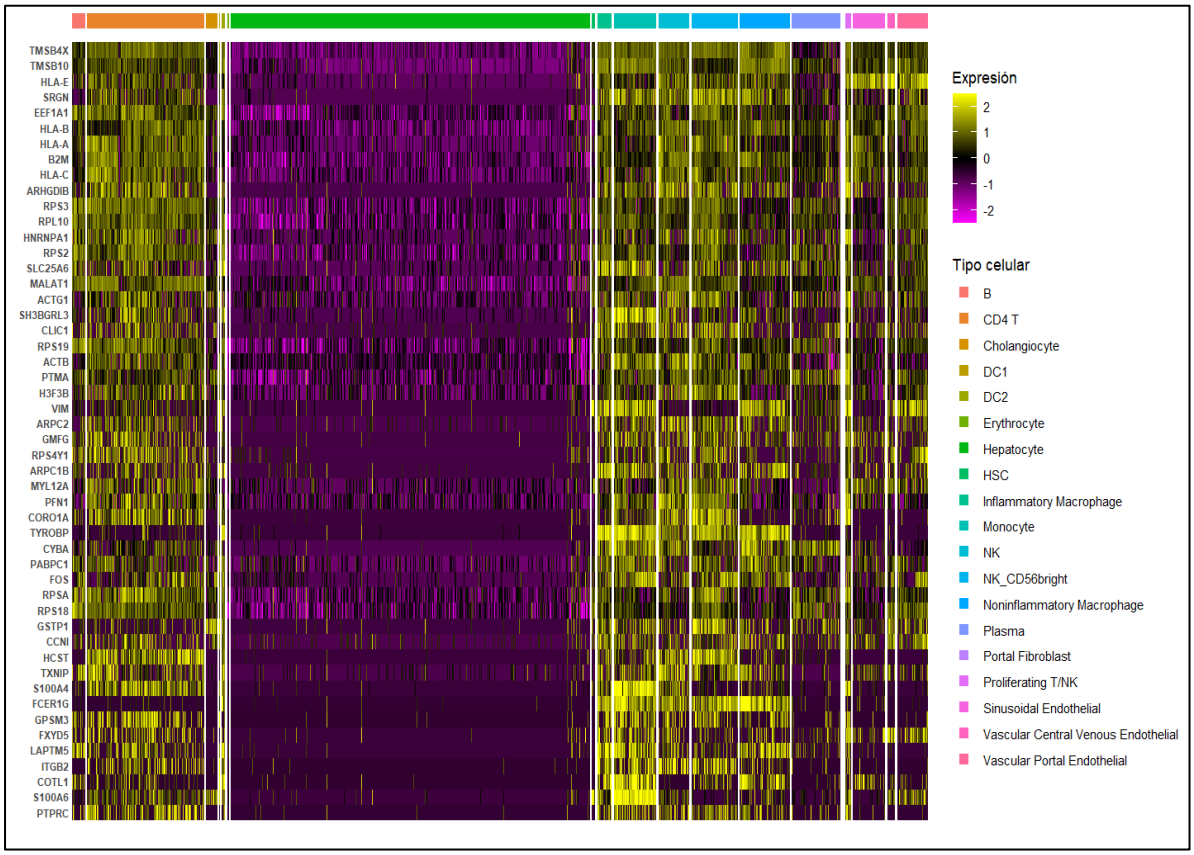

Figura 14. Mapa de calor de la red de coexpresión de *TRIB1*. Visualización de los 50 genes con mayor conectividad dentro del módulo de TRIB1. En el eje vertical se observan genes críticos como HLA-A, HLA-B, HLA-C y B2M (presentación antigénica), así como SRGN (inflamación) y factores de elongación (EEF1A1). La barra superior segmenta la expresión por tipo celular.

El análisis de enriquecimiento de vias ontológicas realizado mediante el paquete *clusterProfiler* reveló que el programa genético coordinado por *TRIB1* está masivamente volcado hacia la inmunidad mediada por receptores de superficie (**Figura 15**). El término más significativo, "vía de señalización del receptor de superficie celular que regula la respuesta inmune", alcanzó una significación estadística (p ajustada = $1.80e^{-36}$) con un contaje de 111 genes (**Tabla 5**, Anexo). Otros términos de interés que hacen participe a este gen en la respuesta inmunitaria incluyen “vía de señalización del receptor de células B” (p ajustada = $8.71e^{-22}$), “inmunidad mediada por leucocitos” (p ajustada = $1.00e^{-17}$) y “activación de linfocitos T alfa-beta” (p ajustada = $2.76e^{-17}$). Esto indica que *TRIB1* forma parte de un engranaje de más de un centenar de genes que regulan cómo la célula responde

a señales externas del microambiente inflamatorio. Otros términos significativos como "respuesta a moléculas de origen bacteriano" (p ajustada = $3.70e^{-16}$) y "respuesta a polisacáridos" (p ajustada = $3.25e^{-16}$) vincula funcionalmente este módulo con la detección de endotoxinas procedentes de la microbiota intestinal a través de la vena porta, un mecanismo clave en la patogénesis de la enfermedad del hígado graso no alcohólico.

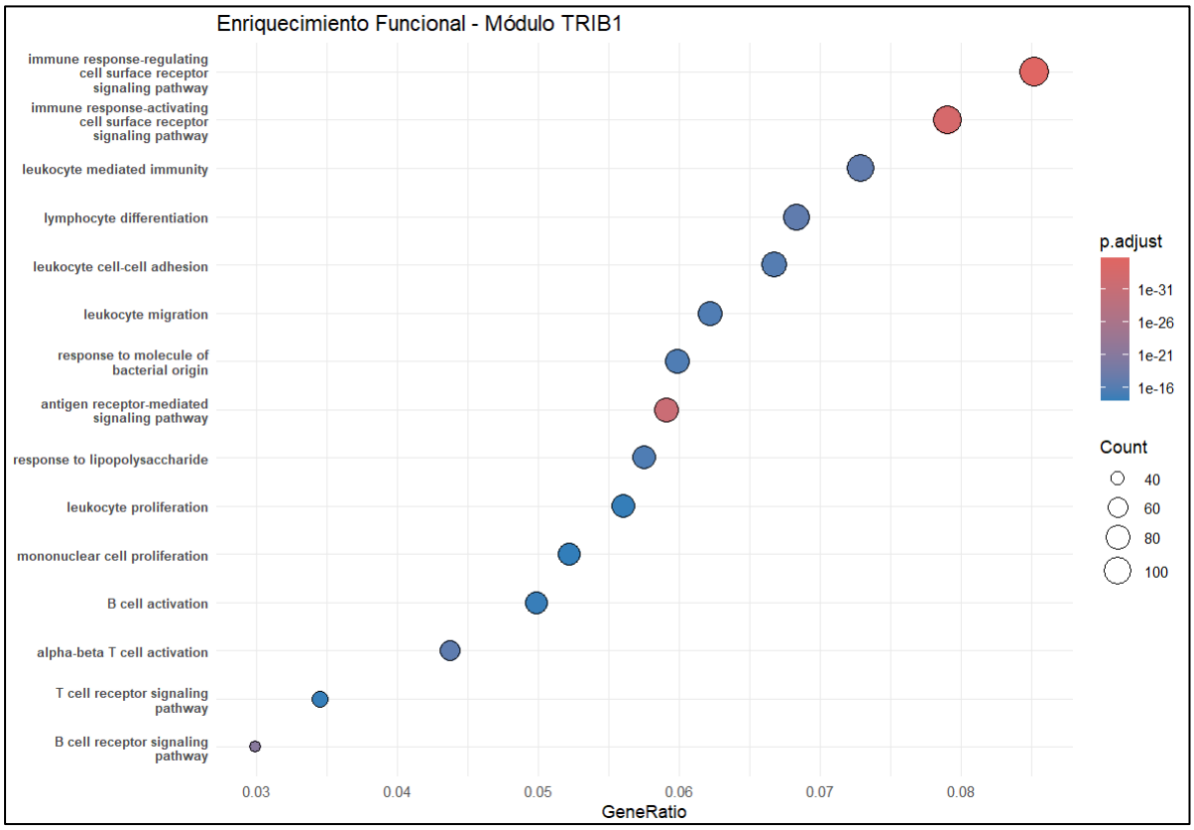

Figura 15. Enriquecimiento funcional de los procesos biológicos asociados al módulo de co-expresión de *TRIB1*. El gráfico de puntos muestra las 15 categorías de ontología génica más significativas obtenidas mediante un análisis de sobre-representación. El eje horizontal refleja la fracción de genes del módulo presentes en cada proceso, mientras que el eje vertical lista los términos biológicos ordenados por su significación estadística. El color de los puntos indica el nivel de p-valor ajustado, destacando en rojo los procesos con más significancia estadística. El tamaño de los puntos representa el número de genes del módulo vinculados a cada término.

4.5 La Red de Interacción de TRIB1 Revela un Nodo Central entre el Metabolismo Lipídico y la Regulación Transcripcional

El análisis del interactoma proteico mediante STRING (**Figura 16**) permitió identificar tres clústeres funcionales distintos que orbitan alrededor de TRIB1, evidenciando su papel como proteína "andamio" multipropósito (**Tabla 6**, Anexo). El clúster más prominente (región superior e izquierda) está compuesto por factores implicados en la vía de la ubiquitina-proteasoma, destacando la interacción con COP1 (RFWD2), DET1 (DET1 Partner Of COP1 E3 Ubiquitin Ligase) y UBE2E1 (Ubiquitin-conjugating enzyme E2 E1). Esta asociación enfatiza el mecanismo fundamental de TRIB1 en la degradación de sustratos específicos.

En estrecha relación con este sistema de degradación, se identificó un clúster de factores de transcripción y reguladores de la expresión génica (región superior derecha), donde TRIB1 interactúa directamente con CEBPA and CEBPB (CCAAT/enhancer-binding protein Alpha y beta, respectivamente), y miembros del complejo AP-1 (activator protein 1) como FOS (Protein c-Fos), FOSB (Protein FosB), FOSL2 (Fos-related antigen 2) y JUNB (Transcription factor JunB). Finalmente, la red reveló un tercer grupo funcional especializado en el metabolismo de lipoproteínas (región inferior), integrado por nodos clave como APOB (Apolipoprotein B-100), APOA5 (Apolipoprotein A-V), ANGPTL3 (Angiopoietin-related protein 3), GALNT2 (Polypeptide N-acetylgalactosaminyltransferase 2) y MLXIPL (ChREBP, Carbohydrate-responsive element-binding protein). Esta red de interacciones físicas proporciona una base mecánica a los resultados de expresión observados en hepatocitos y células mieloides.

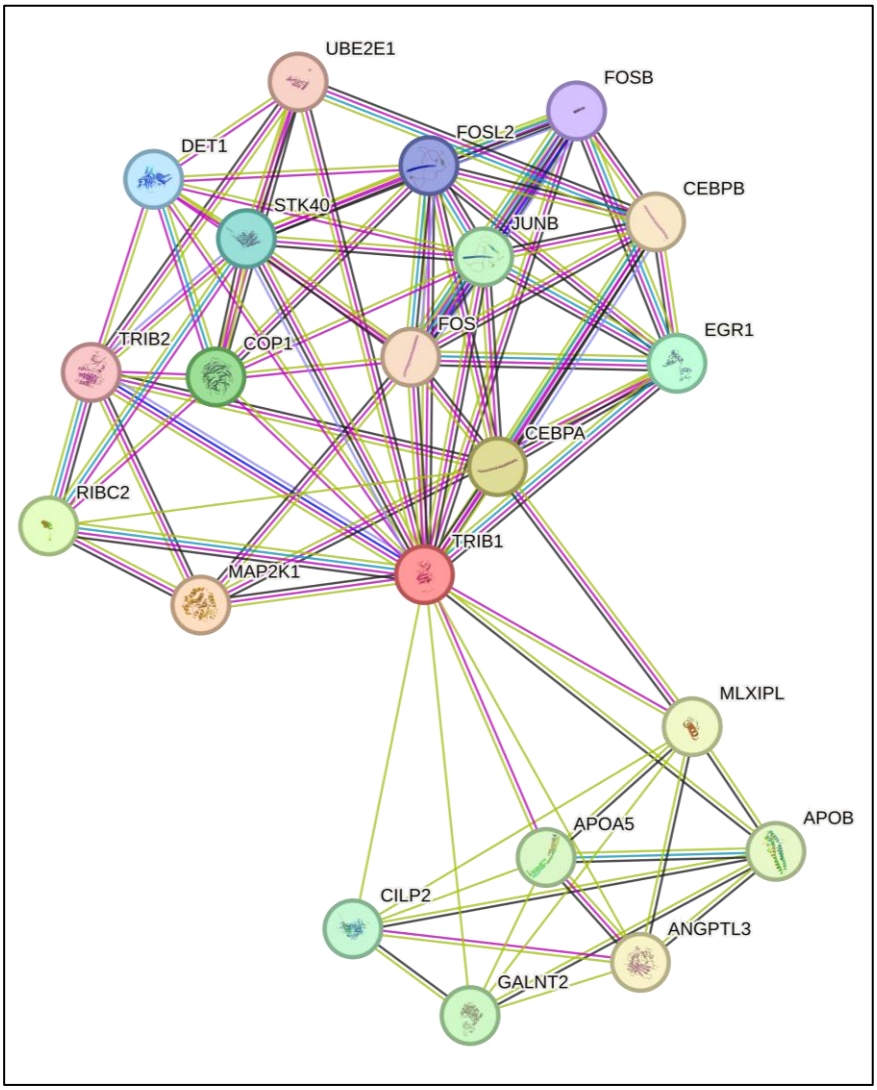

Figura 16. Red de interacción proteica de TRIB1 humano. La imagen muestra los 20 interactores principales de TRIB1. Los nodos representan proteínas y las líneas indican el tipo de evidencia de la interacción. Se distinguen tres dominios funcionales: (i) Maquinaria de ubiquitinación y degradación proteica (clúster con COP1/DET1/STK40), (ii) Control de la transcripción y diferenciación celular (clúster con CEBPA/FOS/JUN) y (iii) Regulación del metabolismo lipídico (clúster inferior con APOB/ANGPTL3). El grosor de las líneas representa la fuerza de la evidencia de la interacción (score medio: 0.40). Las líneas magenta indican evidencia experimental; las cian representan interacciones extraídas de bases de datos curadas; las verdes claras indican que la interacción se extrajo de minado de textos; las negras señalan co-expresión génica; las azules oscuras representan co-ocurrencia genómica; y las púrpuras indican homología proteica. Obtenida mediante STRING v12.0.

4.6 Discusión

La presente investigación se planteó con el objetivo de resolver la incertidumbre sobre la procedencia celular de la señal transcriptómica de *TRIB1* en el hígado humano, un órgano donde la interacción entre el metabolismo parenquimal y la vigilancia inmunitaria es constante.

Históricamente, la literatura basada en estudios de asociación de genoma completo (GWAS) ha consolidado a *TRIB1* como un regulador clave del metabolismo lipídico sistémico, vinculando variantes en su locus con los niveles plasmáticos de triglicéridos y colesterol LDL (22, 23). Sin embargo, la naturaleza poblacional del bulk RNA-seq tradicional ha mantenido oculta la compartimentación de esta señal. Los resultados obtenidos mediante la resolución de célula única revelan un patrón de expresión bimodal, indicando que la expresión de este gen no procede exclusivamente de una subpoblación celular, sino que está involucrado en procesos regulatorios en ambas (17, 21, 29-31, 46). La identificación de una intensidad de expresión máxima en hepatocitos respalda hallazgos previos (26, 47). No obstante, el hallazgo de que la mayor prevalencia de expresión reside en los macrófagos inflamatorios (23,9%) y monocitos sugiere que la señal medida en tejidos totales está fuertemente sesgada por el estado de activación mieloide.

Esta dualidad funcional encuentra apoyo en trabajos que posicionan a *TRIB1* como un regulador crítico de la polarización de macrófagos (48, 49). Este rol inmunomodulador se ve reflejado en nuestra red de co-expresión, donde *TRIB1* se integra en un módulo de extrema significación estadística dominado por la maquinaria de presentación antigénica, incluyendo los genes *HLA-A, -B y -C,* y *B2M*. La robustez de esta asociación, con p-valores ajustados que alcanzan el orden de e^{-36} en vías de señalización de receptores de superficie, sugiere que *TRIB1* no es meramente un espectador, sino un componente activo del sistema de vigilancia inmunológica hepática. Esta interpretación concuerda con la función de *TRIB1* como un "andamio molecular" que facilita la ubiquitinación mediada por COP1. Si bien en hepatocitos este mecanismo regula la degradación de C/EBPα para controlar la lipogénesis, en el contexto mieloide podría estar modulando el recambio de receptores de superficie o de factores de transcripción implicados en la respuesta a citocinas (18, 50).

A pesar de la robustez de la señal detectada en este análisis, existe una divergencia significativa en la literatura respecto a qué subtipo de macrófago es el portador principal de

la función de *TRIB1*. En los resultados obtenidos, la expresión de *TRIB1* es notablemente prevalente en macrófagos inflamatorios, lo que sugiere un papel en la fase activa de la respuesta inmunitaria. No obstante, estudios como el de Satoh *et al*., (49) y Johnston *et al*., (48) proponen un modelo divergente, identificando a *TRIB1* como un interruptor molecular específico para la diferenciación de macrófagos de tipo M2 (antiinflamatorios). Según este modelo, la ausencia de *TRIB1* resultaría en una depleción de macrófagos M2, promoviendo paradójicamente un estado pro-inflamatorio sistémico. Esta discrepancia sugiere que el rol de *TRIB1* podría ser más plástico de lo que se pensaba, actuando no como un marcador de linaje fijo, sino como un regulador de transición entre estados inflamatorios en el hígado humano.

Se ha de mencionar que la asociación de *TRIB1* con la maquinaria de presentación antigénica (HLA) que se ha identificado en el análisis WGCNA también presenta matices divergentes. Mientras que nuestro análisis de enriquecimiento funcional apunta a una activación de la inmunidad adaptativa, trabajos como el de Niespolo *et al*., (46) sugieren que la función primordial de *TRIB1* en macrófagos humanos es la regulación post-transcripcional de citocinas inflamatorias como la IL-8, actuando más como un freno que como un activador de la señalización de receptores de superficie. Esta diferencia en la interpretación funcional, activador de la vigilancia inmunitaria frente a regulador de la estabilidad del ARNm, subraya la necesidad de realizar validaciones funcionales proteicas, ya que la abundancia de transcritos HLA co-expresados con *TRIB1* podría no traducirse necesariamente en una mayor presentación de antígenos, sino en un intento de la célula por coordinar una respuesta de estrés ante el microambiente hepático.

Seguidamente, en las células plasmáticas, donde también detectamos una señal notable de *TRIB1* (1.39), es interesante notar que, aunque existe poca literatura que relacione a esta pseudoquinasa con el linaje de células B (51), el análisis de enriquecimiento identificó vías de activación de células B y T en el módulo de *TRIB1*. Esto refuerza la hipótesis de que este gen es un nodo central en la red de comunicación celular del hígado, posiblemente influyendo en la maduración de la respuesta adaptativa local.

Para validar la estabilidad de la red de coexpresión y los procesos biológicos identificados, se realizó un análisis de sensibilidad comparando la selección estándar de 2.000 HVGs

frente a un conjunto expandido de 3.000. Los resultados confirman una alta robustez del modelo, ya que los ejes centrales de la regulación funcional permanecieron inalterados.

En cuanto a la composición del módulo de coexpresión vinculado a *TRIB1*, 8 de los 10 genes más correlacionados fueron idénticos en ambos análisis. Destaca la presencia constante de genes del complejo mayor de histocompatibilidad clase I (*HLA-A, HLA-B, HLA-C, HLA-E*) y la *B2M*; mientras que las variaciones menores (como la sustitución de *ARHGDIB* por *RPS3A*) sugieren que el incremento de genes introduce principalmente componentes de la maquinaria ribosomal o reguladores citoesqueléticos periféricos.

Esta consistencia se trasladó al enriquecimiento funcional. Los términos de mayor jerarquía, tales como *"immune response-regulating cell surface receptor signaling pathway"* y *"antigen receptor-mediated signaling pathway"*, se mantuvieron como los procesos biológicos más significativos en ambas condiciones. Si bien el análisis con 3.000 genes incluyó términos de regulación positiva y activación de células B, el núcleo funcional de inmunidad mediada por leucocitos y adhesión celular demostró ser independiente del número de HVGs seleccionados. Por tanto, el uso de 2.000 genes se considera suficiente para no incorporar ruido computacional innecesario.

La red de interacciones obtenida mediante STRING proporciona un marco mecánico para interpretar la bimodalidad funcional de TRIB1 obtenida del análisis scRNA-seq. La robusta interacción física con COP1 y la familia C/EBP (CEBPα/β) fundamenta el papel de TRIB1 como regulador de la homeostasis energética. En los hepatocitos, donde observamos los niveles más altos de transcrito, esta interacción facilita la degradación de CEBPA, inhibiendo la síntesis de ácidos grasos y la secreción de VLDL, lo que explica la conexión física directa con APOB y ANGPTL3 observada en la red (18, 25).

Sin embargo, la dimensión más reveladora de la red STRING es su alineación con el programa inmunológico identificado en los macrófagos inflamatorios y células plasmáticas. La interacción con proteínas del complejo FOS/JUN y EGR1 sugiere que TRIB1 actúa como un modulador de las señales de estrés y activación inflamatoria. Esto conecta directamente con los resultados de enriquecimiento funcional, que señalaron una respuesta a lipopolisacáridos y moléculas de origen bacteriano (**Figura 15**). La capacidad de TRIB1 para interactuar con MAP2K1 indica que su función linfoide-mieloide podría estar mediada por el

ajuste de la vía MAPK/ERK, regulando la estabilidad de los ARN mensajeros de citocinas pro-inflamatorias, como se ha propuesto en modelos de respuesta inmunitaria innata (46).

Finalmente, la integración del interactoma físico con la red de coexpresión WGCNA revela un potencial rol de TRIB1 en la vigilancia inmunológica que trasciende lo metabólico. Mientras que el módulo de coexpresión destacó una vinculación con genes HLA de Clase I, la red STRING muestra que TRIB1 posee la capacidad física de interactuar con la maquinaria de ubiquitinación (UBE2E1, COP1, (19)). De esta convergencia se puede hipotetizar que TRIB1 podría estar regulando el recambio de moléculas implicadas en la presentación antigénica en la superficie de los macrófagos hepáticos.

5. Conclusiones

La realización de este trabajo ha permitido desentrañar la complejidad transcriptómica de *TRIB1* en el hígado humano, cumpliendo con los objetivos de identificar su distribución celular y caracterizar sus redes funcionales. Las principales conclusiones derivadas de este estudio son las siguientes:

1.- Confirmación de un patrón de expresión bimodal para *TRIB1*. Mientras que los hepatocitos presentan la mayor intensidad de expresión log-normalizada (1,95), validando su rol metabólico clásico, los macrófagos inflamatorios y monocitos muestran una mayor prevalencia y consistencia en la señal. Este hallazgo cumple el objetivo de mapear el origen celular de la señal detectada en estudios de tejido hepático completo.

2.- Mediante el análisis WGCNA se ha identificado un módulo funcional donde *TRIB1* se coordina estrechamente con la maquinaria de presentación antigénica de Clase I (*HLA-A, HLA-B, HLA-C y B2M*) y genes de respuesta inflamatoria como la Serglicina (*SRGN*). Esto sitúa a *TRIB1* como un componente regulador en la vigilancia inmunológica hepática.

3.- El análisis de enriquecimiento demuestra que la red de *TRIB1* está enfocada a la señalización de receptores de superficie y la maduración y motilidad en leucocitos, con una alta significación en la respuesta a estímulos bacterianos y lipopolisacáridos. Estos resultados alinean la función del gen con la respuesta al estrés inmunometabólico del eje intestino-hígado.

4.- La red STRING confirma que TRIB1 actúa como un puente físico entre la maquinaria de ubiquitinación (COP1, UBE2E1) y reguladores clave del metabolismo (C/EBPα, APOB, ANGPTL3) y de la transcripción (FOS, JUN).

En conjunto, este trabajo transforma la visión de *TRIB1* de un simple regulador de la lipogénesis a un nodo central de comunicación inmunometabólica, esencial para mantener la homeostasis entre el metabolismo del parénquima y la vigilancia inmune hepática.

6. Limitaciones y Perspectivas Futuras

A pesar de la relevancia de los hallazgos, este estudio presenta limitaciones que deben ser consideradas.

La tecnología de scRNA-seq presenta desafíos técnicos y biológicos que condicionan la interpretación de los resultados. Una limitación crítica es el sesgo de disociación tisular. El hígado es un órgano con una matriz extracelular densa y una arquitectura altamente organizada. El proceso de digestión enzimática necesario para obtener una suspensión de células individuales puede comprometer la viabilidad de los hepatocitos, que son células grandes y frágiles, favoreciendo la sobrerrepresentación de poblaciones inmunitarias más resistentes, como los macrófagos y linfocitos. Este fenómeno, descrito por Denisenko *et al.*, (52), sugiere que las proporciones celulares observadas en el podrían no ser un reflejo exacto de las proporciones celulares reales *in vivo*, lo que obliga a interpretar con cautela los porcentajes de expresión.

A este sesgo, se suma el problema del ARN ambiental. Durante la preparación de las bibliotecas en plataformas de microfluídica, la lisis accidental de células frágiles (especialmente hepatocitos cargados de glucógeno y lípidos) libera ARN al medio que puede ser capturado erróneamente en gotas que contienen otras células. En el caso de genes con una expresión bimodal como *TRIB1*, existe el riesgo de que parte de la señal detectada en cúmulos de baja expresión sea producto de esta contaminación cruzada. Aunque se utilizan algoritmos de limpieza, la persistencia de este ruido técnico dificulta la distinción entre una expresión basal verdadera y un artefacto experimental, especialmente en genes reguladores que operan en umbrales bajos. Además, el fenómeno de "*dropout*" o pérdida de señal por baja eficiencia de captura de transcritos sigue siendo el principal obstáculo para caracterizar factores de transcripción y proteínas de andamio como *TRIB1*, cuya abundancia de ARNm suele ser significativamente inferior a la de genes estructurales o metabólicos.

Además, es necesario tener en cuenta la discordancia entre los niveles de ARNm y proteína. Debido a la presencia del motivo PEST de degradación rápida en la estructura de TRIB1, los niveles de transcrito analizados mediante scRNA-seq podrían no reflejar con exactitud la actividad funcional de la proteína en la célula.

Como perspectiva futura, resultaría de gran interés realizar un análisis comparativo de scRNA-seq entre tejido sano y tejido tumoral. La literatura sugiere que *TRIB1* puede actuar como un oncogén en diversos contextos, promoviendo la transición epitelio-mesénquima y la progresión del ciclo celular (29). Comparar la expresión unicelular permitiría determinar si en el tumor existe un desplazamiento de la señal de *TRIB1* hacia los macrófagos asociados a tumores, los cuales podrían estar utilizando esta vía para generar un microambiente inmunosupresor (53). Asimismo, el uso de transcriptómica espacial permitiría validar si los macrófagos que expresan *TRIB1* se localizan físicamente en nichos inflamatorios específicos, interactuando directamente con hepatocitos en estado de esteatosis.

Finalmente, la validación funcional mediante modelos de organoides hepáticos con edición génica (CRISPR/Cas9) sería interesante para confirmar si la modulación de *TRIB1* puede mitigar simultáneamente la acumulación de lípidos y la secreción de citocinas proinflamatorias.

7. Referencias Bibliográficas

1. Margulies M, Egholm M, Altman WE, Attiya S, Bader JS, Bemben LA, et al. Genome sequencing in microfabricated high-density picolitre reactors. Nature. 2005;437(7057):376-80.

2. Wang Z, Gerstein M, Snyder M. RNA-Seq: a revolutionary tool for transcriptomics. Nature reviews Genetics. 2009;10(1):57-63.

3. Klein AM, Mazutis L, Akartuna I, Tallapragada N, Veres A, Li V, et al. Droplet barcoding for single-cell transcriptomics applied to embryonic stem cells. Cell. 2015;161(5):1187-201.

4. Macosko EZ, Basu A, Satija R, Nemesh J, Shekhar K, Goldman M, et al. Highly Parallel Genome-wide Expression Profiling of Individual Cells Using Nanoliter Droplets. Cell. 2015;161(5):1202-14.

5. Menon M, Mohammadi S, Davila-Velderrain J, Goods BA, Cadwell TD, Xing Y, et al. Single-cell transcriptomic atlas of the human retina identifies cell types associated with age-related macular degeneration. Nature communications. 2019;10(1):4902.

6. Green CD, Ma Q, Manske GL, Shami AN, Zheng X, Marini S, et al. A Comprehensive Roadmap of Murine Spermatogenesis Defined by Single-Cell RNA-Seq. Dev Cell. 2018;46(5):651-67.e10.

7. Gulati GS, Sikandar SS, Wesche DJ, Manjunath A, Bharadwaj A, Berger MJ, et al. Single-cell transcriptional diversity is a hallmark of developmental potential. Science (New York, NY). 2020;367(6476):405-11.

8. Li JS, Ji ZZ, Zhang AQ, Ng CS, Qiao G, Zhang D, et al. Tumour Single-Cell Bioinformatics: From Immune Profiling to Molecular Dynamics. J Cell Mol Med. 2025;29(18):e70783.

9. MacParland SA, Liu JC, Ma XZ, Innes BT, Bartczak AM, Gage BK, et al. Single cell RNA sequencing of human liver reveals distinct intrahepatic macrophage populations. Nature communications. 2018;9(1):4383.

10. Aizarani N, Saviano A, Sagar, Mailly L, Durand S, Herman JS, et al. A human liver cell atlas reveals heterogeneity and epithelial progenitors. Nature. 2019;572(7768):199-204.

11. Hao Y, Hao S, Andersen-Nissen E, Mauck WM, 3rd, Zheng S, Butler A, et al. Integrated analysis of multimodal single-cell data. Cell. 2021;184(13):3573-87.e29.

12. Wolf FA, Angerer P, Theis FJ. SCANPY: large-scale single-cell gene expression data analysis. Genome biology. 2018;19(1):15.

13. Gayoso A, Lopez R, Xing G, Boyeau P, Valiollah Pour Amiri V, Hong J, et al. A Python library for probabilistic analysis of single-cell omics data. Nature Biotechnology. 2022;40(2):163-6.

14. Mata J, Curado S, Ephrussi A, Rørth P. Tribbles coordinates mitosis and morphogenesis in Drosophila by regulating string/CDC25 proteolysis. Cell. 2000;101(5):511-22.

15. Hegedus Z, Czibula A, Kiss-Toth E. Tribbles: a family of kinase-like proteins with potent signalling regulatory function. Cellular signalling. 2007;19(2):238-50.

16. Rechsteiner M, Rogers SW. PEST sequences and regulation by proteolysis. Trends in biochemical sciences. 1996;21(7):267-71.

17. Soubeyrand S, Lau P, McPherson R. Regulation of TRIB1 abundance in hepatocyte models in response to proteasome inhibition. Sci Rep. 2023;13(1):9320.

18. Murphy JM, Nakatani Y, Jamieson SA, Dai W, Lucet IS, Mace PD. Molecular Mechanism of CCAAT-Enhancer Binding Protein Recruitment by the TRIB1 Pseudokinase. Structure (London, England : 1993). 2015;23(11):2111-21.

19. Yoshida A, Kato J-y, Nakamae I, Yoneda-Kato N. COP1 targets C/EBPα for degradation and induces acute myeloid leukemia via Trib1. Blood. 2013;122(10):1750-60.

20. Hegedus Z, Czibula A, Kiss-Toth E. Tribbles: novel regulators of cell function; evolutionary aspects. Cellular and molecular life sciences : CMLS. 2006;63(14):1632-41.

21. Rome KS, Stein SJ, Kurachi M, Petrovic J, Schwartz GW, Mack EA, et al. Trib1 regulates T cell differentiation during chronic infection by restraining the effector program. J Exp Med. 2020;217(5).

22. Teslovich TM, Musunuru K, Smith AV, Edmondson AC, Stylianou IM, Koseki M, et al. Biological, clinical and population relevance of 95 loci for blood lipids. Nature. 2010;466(7307):707-13.

23. Willer CJ, Schmidt EM, Sengupta S, Peloso GM, Gustafsson S, Kanoni S, et al. Discovery and refinement of loci associated with lipid levels. Nature genetics. 2013;45(11):1274-83.

24. Niespolo C, Johnston JM, Deshmukh SR, Satam S, Shologu Z, Villacanas O, et al. Tribbles-1 Expression and Its Function to Control Inflammatory Cytokines, Including

Interleukin-8 Levels are Regulated by miRNAs in Macrophages and Prostate Cancer Cells. Front Immunol. 2020;11:574046.

25. Soubeyrand S, Martinuk A, Lau P, McPherson R. TRIB1 Is Regulated Post-Transcriptionally by Proteasomal and Non-Proteasomal Pathways. PloS one. 2016;11(3):e0152346.

26. Bauer RC, Sasaki M, Cohen DM, Cui J, Smith MA, Yenilmez BO, et al. Tribbles-1 regulates hepatic lipogenesis through posttranscriptional regulation of C/EBPα. The Journal of clinical investigation. 2015;125(10):3809-18.

27. Wilkin F, Suarez-Huerta N, Robaye B, Peetermans J, Libert F, Dumont JE, et al. Characterization of a phosphoprotein whose mRNA is regulated by the mitogenic pathways in dog thyroid cells. European journal of biochemistry. 1997;248(3):660-8.

28. The GTEx Consortium atlas of genetic regulatory effects across human tissues. Science (New York, NY). 2020;369(6509):1318-30.

29. Kim T, Johnston J, Castillo-Lluva S, Cimas FJ, Hamby S, Gonzalez-Moreno S, et al. TRIB1 regulates tumor growth via controlling tumor-associated macrophage phenotypes and is associated with breast cancer survival and treatment response. Theranostics. 2022;12(8):3584-600.

30. Sun X, Wang S, Miao X, Zeng S, Guo Y, Zhou A, et al. TRIB1 regulates liver regeneration by antagonizing the NRF2-mediated antioxidant response. Cell Death Dis. 2023;14(6):372.

31. Soubeyrand S, Martinuk A, McPherson R. TRIB1 is a positive regulator of hepatocyte nuclear factor 4-alpha. Sci Rep. 2017;7(1):5574.

32. Danger R, Feseha Y, Brouard S. The Pseudokinase TRIB1 in Immune Cells and Associated Disorders. Cancers (Basel). 2022;14(4).

33. Krenkel O, Tacke F. Liver macrophages in tissue homeostasis and disease. Nat Rev Immunol. 2017;17(5):306-21.

34. Andrews TS, Atif J, Liu JC, Perciani CT, Ma XZ, Thoeni C, et al. Single-Cell, Single-Nucleus, and Spatial RNA Sequencing of the Human Liver Identifies Cholangiocyte and Mesenchymal Heterogeneity. Hepatol Commun. 2022;6(4):821-40.

35. Cheng S, Zou Y, Zhang M, Bai S, Tao K, Wu J, et al. Single-cell RNA sequencing reveals the heterogeneity and intercellular communication of hepatic stellate cells and macrophages during liver fibrosis. MedComm (2020). 2023;4(5):e378.

36. Bravo González-Blas C, Matetovici I, Hillen H, Taskiran, II, Vandepoel R, Christiaens V, et al. Single-cell spatial multi-omics and deep learning dissect enhancer-driven gene regulatory networks in liver zonation. Nat Cell Biol. 2024;26(1):153-67.

37. Liu H, Sima X, Xiao B, Gulizeba H, Zhao S, Zhou T, et al. Integrated analysis of single-cell and bulk RNA sequencing data reveals a myeloid cell-related regulon predicting neoadjuvant immunotherapy response across cancers. Journal of Translational Medicine. 2024;22(1):486.

38. Vandereyken K, Sifrim A, Thienpont B, Voet T. Methods and applications for single-cell and spatial multi-omics. Nature reviews Genetics. 2023;24(8):494-515.

39. Heumos L, Schaar AC, Lance C, Litinetskaya A, Drost F, Zappia L, et al. Best practices for single-cell analysis across modalities. Nature reviews Genetics. 2023;24(8):550-72.

40. Hafemeister C, Satija R. Normalization and variance stabilization of single-cell RNA-seq data using regularized negative binomial regression. Genome biology. 2019;20(1):296.

41. Stuart T, Butler A, Hoffman P, Hafemeister C, Papalexi E, Mauck WM, 3rd, et al. Comprehensive Integration of Single-Cell Data. Cell. 2019;177(7):1888-902.e21.

42. Morio B, Panthu B, Bassot A, Rieusset J. Role of mitochondria in liver metabolic health and diseases. Cell Calcium. 2021;94:102336.

43. Luecken MD, Theis FJ. Current best practices in single-cell RNA-seq analysis: a tutorial. Mol Syst Biol. 2019;15(6):e8746.

44. Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis. BMC Bioinformatics. 2008;9:559.

45. Diaz-Mejia JJ, Meng EC, Pico AR, MacParland SA, Ketela T, Pugh TJ, et al. Evaluation of methods to assign cell type labels to cell clusters from single-cell RNA-sequencing data. F1000Res. 2019;8.

46. Niespolo C, Johnston JM, Deshmukh SR, Satam S, Shologu Z, Villacanas O, et al. Tribbles-1 Expression and Its Function to Control Inflammatory Cytokines, Including Interleukin-8 Levels are Regulated by miRNAs in Macrophages and Prostate Cancer Cells. Frontiers in Immunology. 2020;11(3049).

47. Burkhardt R, Toh SA, Lagor WR, Birkeland A, Levin M, Li X, et al. Trib1 is a lipid- and myocardial infarction-associated gene that regulates hepatic lipogenesis and VLDL production in mice. The Journal of clinical investigation. 2010;120(12):4410-4.

48. Johnston JM, Angyal A. Myeloid Tribbles 1 induces early atherosclerosis via enhanced foam cell expansion. 2019;5(10):eaax9183.

49. Satoh T, Kidoya H, Naito H, Yamamoto M, Takemura N, Nakagawa K, et al. Critical role of Trib1 in differentiation of tissue-resident M2-like macrophages. Nature. 2013;495(7442):524-8.

50. Quiroz-Figueroa K, Vitali C, Conlon DM, Millar JS, Tobias JW, Bauer RC, et al. TRIB1 regulates LDL metabolism through CEBPα-mediated effects on the LDL receptor in hepatocytes. The Journal of clinical investigation. 2021;131(22).

51. Simoni L, Delgado V, Ruer-Laventie J, Bouis D, Soley A, Heyer V, et al. Trib1 Is Overexpressed in Systemic Lupus Erythematosus, While It Regulates Immunoglobulin Production in Murine B Cells. Front Immunol. 2018;9:373.

52. Denisenko E, Guo BB, Jones M, Hou R, de Kock L, Lassmann T, et al. Systematic assessment of tissue dissociation and storage biases in single-cell and single-nucleus RNA-seq workflows. Genome biology. 2020;21(1):130.

53. Kim J, Seki E. Inflammation and Immunity in Liver Neoplasms: Implications for Future Therapeutic Strategies. Mol Cancer Ther. 2025;24(2):188-99.

8. Anexo

8.1 Tablas

Muestras	Células iniciales	Filtro genes	Filtro mitocondrial	Células Eliminadas	% Retención	% Pérdida por genes	% Pérdida por mitocondrial
P1TLH	1068	1065	1033	35	96.72	0.28	3
P2TLH	1219	1219	1183	36	97.05	0	2.95
P3TLH	3127	3127	2899	228	92.71	0	7.29
P4TLH	1325	1318	1217	108	91.85	0.53	7.66
P5TLH	1705	1698	1615	90	94.72	0.41	4.89

Tabla 2. Anexo. Estadísticas de control de calidad por muestra en el conjunto de datos de hígado humano analizado mediante scRNA-seq. Para cada muestra se indica el número total de células iniciales, el número de células retenidas tras aplicar el filtro de número de genes detectados por célula (>200 y <5000), y el número final de células tras aplicar adicionalmente el filtro de porcentaje de lecturas mitocondriales (<35%). Se muestran también el número total de células eliminadas, el porcentaje global de retención respecto al total inicial, el porcentaje de pérdida asociado al filtro de genes y el porcentaje de pérdida adicional asociado al filtro mitocondrial.

Tipo Celular	Nº Células	Porcentaje	Puntuación de predicción media
Hepatocyte	3485	43.85	1
CD4 T	1135	14.28	0.652
Noninflammatory Macrophage	484	6.09	0.861
Plasma	474	5.96	0.606
NK_CD56bright	450	5.66	0.86
Monocyte	414	5.21	0.98
Sinusoidal Endothelial	313	3.94	1
NK	301	3.79	0.656
Vascular Portal Endothelial	298	3.75	0.515
Inflammatory Macrophage	138	1.74	0.573
B	121	1.52	0.866
Cholangiocyte	111	1.4	0.739
Vascular Central Venous Endothelial	76	0.96	0.497
Proliferating T/NK	59	0.74	0.568
HSC	33	0.42	0.672
DC2	32	0.4	0.411
Erythrocyte	19	0.24	0.358
DC1	2	0.03	0.691
Portal Fibroblast	2	0.03	0.375

Tabla 3. Anexo. Composición y caracterización de las subpoblaciones celulares identificadas. La tabla resume la el conjunto de datos tras la fase de control de calidad, clasificada según la resolución de nivel 2 de la herramienta de anotación Azimuth. Para cada uno de los tipos celulares detectados, se detalla el número absoluto de células y su abundancia relativa (porcentaje) respecto al total de la muestra (n = 7.947). Asimismo, se incluye la puntuación de predicción media, una métrica que cuantifica la confianza estadística asignada por el algoritmo durante el proceso de proyección sobre el atlas de referencia.

Tipo Celular	% Células expresoras	Maxima Intensidad	Promedio Expresión
Inflammatory Macrophage	23.91	1.39	0.73
Hepatocyte	20	1.95	0.78
Noninflammatory Macrophage	15.91	1.39	0.82
Plasma	15.19	1.39	0.77
Monocyte	14.98	1.39	0.78
Cholangiocyte	9.91	1.1	0.77
HSC	6.06	1.1	0.9
Proliferating T/NK	3.39	0.69	0.69
DC2	3.12	1.1	1.1
Sinusoidal Endothelial	2.88	1.39	0.86
Vascular Portal Endothelial	2.68	1.1	0.79
Vascular Central Venous Endothelial	2.63	1.39	1.04
CD4 T	1.32	1.1	0.8
NK_CD56bright	0.44	1.1	0.9
NK	0.33	0.69	0.69
B	0	0	NA
DC1	0	0	NA
Erythrocyte	0	0	NA
Portal Fibroblast	0	0	NA

Tabla 4. Anexo. Análisis descriptivo de la expresión de *TRIB1* por linaje celular. Esta tabla resume las métricas de detección del transcrito *TRIB1* en las poblaciones celulares más relevantes identificadas en el dataset. El porcentaje de células expresoras indica la ubicuidad del gen dentro de cada clúster, destacando en los macrófagos inflamatorios (23,91%). El promedio de expresión y la máxima intensidad (log-normalizada) reflejan la señal de ARNm detectada, permitiendo diferenciar entre poblaciones con una expresión basal uniforme y aquellas que presentan picos de actividad transcripcional elevada, como se observa en la población de hepatocitos (1.95).

ID	Description	p,adjust	qvalue	geneID	Count
GO:0002768	immune response-regulating cell surface receptor signaling pathway	1,79E-36	1,23E-36	IGKC,IGHM,IGHG1,IGHG3,IGHA1,IGLC3,IGHG4,IGHG2,IGHA2,PIGR,CD24,IGLC7,FCN1,MNDA,KLRC1,CD3D,TRAC,IGLC6,TRDC,TRBC1,IFNG,TRBC2,CD79A,TRGC2,CD3E,COLEC11,CD160,CD247,CD8A,CD3G,TXK,CD14,C5AR1,LCK,CD8B,FPR1,TRGC1,CD79B,SH2D1A,BTNL9,TNFAIP3,LGALS3,MS4A1,MEF2C,ZAP70,FGR,CLEC4E,RGCC,CD38,NCR3,LAT,PRKCH,FCMR,PRKCB,FCGR2A,ITGAM,MYO1G,BMX,LAT2,FCGR1A,FYN,CD300A,TLR4,S100A14,LILRB2,CMTM3,INPP5D,SKAP1,PTPN6,HCK,C3AR1,DGKZ,MAPK1,NCKAP1L,BTN3A2,PRNP,LCP2,CBLB,FPR3,THEMIS2,ELF1,KLRC2,FOSL2,BLVRA,LPXN,GATA3,CD33,TREM2,LYN,LILRB4,SYK,BAX,TRAT1,PTPN22,PLCG2,PLSCR1,SCIMP,NFKBIZ,BCL2,IRF3,CD47,NFATC2,EZR,RAB29,PTPN2,MAP3K1,CSK,TLR2,PDE4B,FOXP1,IGHD	111
GO:0002429	immune response-activating cell surface receptor signaling pathway	2,03E-34	1,39E-34	IGKC,IGHM,IGHG1,IGHG3,IGHA1,IGLC3,IGHG4,IGHG2,IGHA2,IGLC7,FCN1,MNDA,KLRC1,CD3D,TRAC,IGLC6,TRDC,TRBC1,IFNG,TRBC2,CD79A,TRGC2,CD3E,COLEC11,CD160,CD247,CD8A,CD3G,TXK,CD14,C5AR1,LCK,CD8B,FPR1,TRGC1,CD79B,SH2D1A,BTNL9,TNFAIP3,LGALS3,MS4A1,MEF2C,ZAP70,FGR,RGCC,CD38,NCR3,LAT,PRKCH,FCMR,PRKCB,ITGAM,MYO1G,BMX,LAT2,FYN,CD300A,TLR4,S100A14,CMTM3,INPP5D,SKAP1,PTPN6,HCK,C3AR1,DGKZ,MAPK1,NCKAP1L,BTN3A2,PRNP,LCP2,CBLB,FPR3,THEMIS2,ELF1,KLRC2,FOSL2,BLVRA,LPXN,GATA3,TREM2,LYN,LILRB4,SYK,BAX,TRAT1,PTPN22,PLCG2,PLSCR1,SCIMP,NFKBIZ,BCL2,IRF3,CD47,NFATC2,EZR,RAB29,PTPN2,CSK,TLR2,PDE4B,FOXP1,IGHD	103
GO:0050851	antigen receptor-mediated signaling pathway	4,37E-32	3,00E-32	IGKC,IGHM,IGHG1,IGHG3,IGHA1,IGLC3,IGHG4,IGHG2,IGHA2,IGLC7,MNDA,CD3D,TRAC,IGLC6,TRDC,TRBC1,TRBC2,CD79A,TRGC2,CD3E,CD160,CD247,CD8A,CD3G,TXK,LCK,CD8B,TRGC1,CD79B,SH2D1A,BTNL9,LGALS3,MS4A1,MEF2C,ZAP70,CD38,LAT,PRKCH,FCMR,PRKCB,BMX,LAT2,FYN,CD300A,CMTM3,INPP5D,SKAP1,PTPN6,DGKZ,MAPK1,NCKAP1L,BTN3A2,PRNP,LCP2,CBLB,THEMIS2,ELF1,FOSL2,LPXN,GATA3,LYN,LILRB4,SYK,BAX,TRAT1,PTPN22,PLCG2,NFKBIZ,BCL2,NFATC2,EZR,RAB29,PTPN2,CSK,PDE4B,FOXP1,IGHD	77
GO:0050853	B cell receptor signaling pathway	8,71E-22	5,97E-22	IGKC,IGHM,IGHG1,IGHG3,IGHA1,IGLC3,IGHG4,IGHG2,IGHA2,IGLC7,MNDA,IGLC6,CD79A,LCK,CD79B,MS4A1,MEF2C,CD38,PRKCH,FCMR,PRKCB,BMX,LAT2,CD300A,CMTM3,PTPN6,MAPK1,NCKAP1L,LPXN,LYN,SYK,BAX,PTPN22,PLCG2,NFKBIZ,BCL2,NFATC2,FOXP1,IGHD	39
GO:0002443	leukocyte mediated immunity	1,46E-17	1,00E-17	IGKC,IGHG1,IGHG3,IGHA1,IGLC2,IGLC3,IGHG4,IGHG2,IGHA2,PTGDS,IGLL5,GZMB,IGLC7,IL7R,PRF1,XCL1,KLRC1,IGLC6,CXCL6,IFNG,CD2,IL2RB,IL1B,CD160,SPON2,CD8A,CD27,IGHV1-24,GZMM,TUBB,SH2D1A,IGHV3-15,STXBP2,FGR,IL1R1,CD84,NCR3,TIGIT,IGHV3-23,CD96,LAT,SPN,ICAM1,FCMR,FCGR2A,TNF,ITGAM,MYO1G,NCF1,CD55,LAT2,PTGDR,FCGR1A,CD300A,SASH3,TLR4,TGFB1,INPP5D,PTPN6,HLA-F,SERPINB9,NCKAP1L,WAS,BTN3A2,TNFRSF1B,IL27RA,ARRB2,LYST,KLRC2,GATA3,TCIRG1,TUBB4B,TREM2,LYN,LILRB4,SYK,ARID5A,IGHV3-48,HAVCR2,PLCG2,BATF,SCIMP,NFKBIZ,STX7,VAMP2,ADAM17,SH2D1B,KMT2E,BST2,STX4,SLAMF7,RAB27A,BCR,IGHD,SMAD7	95
GO:0030098	lymphocyte differentiation	1,76E-17	1,20E-17	IGHM,IL7R,LGALS1,KLRC1,CD3D,IFNG,SOX4,CD2,CD79A,IL1B,CD3E,CD8A,CD3G,GPR183,SOCS3,CD27,LCK,EGR1,KLF6,CD79B,POU2AF1,MS4A1,IL2RG,EOMES,ZAP70,IKZF3,ITM2A,PRDM1,CLEC4E,RUNX3,XBP1,SOCS1,GPR65,IRF1,SPN,RHOH,CYP26B1,CD83,TNFSF13B,SASH3,IRF8,IKZF1,TGFB1,PTGER4,LILRB2,INPP5D,PTPN6,GAS6,NCKAP1L,MDK,PRDX2,BMP4,ID2,ATM,MERTK,ITGA4,FOSL2,STAT4,GATA3,TCIRG1,PREX1,LILRB4,SYK,BAX,PTPN22,PLCG2,DOCK2,MFNG,BATF,NFKBIZ,CD86,BCL2,CMTM7,BCL11B,ADAM17,TCF7,RUNX1,LY9,LYL1,PTPN2,JAK1,PNP,CBFB,FOXP1,HDAC9,SMAD7,ZBTB16,SFRP1,PTK2B	89
GO:0046631	alpha-beta T cell activation	2,76E-17	1,89E-17	XCL1,KLRF1,LGALS1,CD3D,TRAC,TRBC1,IFNG,TRBC2,CD3E,CD160,CD247,CD3G,GPR183,SOCS3,LGALS3,IL2RG,EOMES,ZAP70,PRDM1,RUNX3,NCR3,MYC,SOCS1,GPR65,IRF1,SPN,C	57

				D55,CD83,CD300A,SASH3,TLR4,PTGER4,NCKAP1L,RASAL3,CBLB,FOSL2,STAT4,GATA3,TCIRG1,LILRB4,SYK,HSPH1,DOCK2,BATF,NFKBIZ,CD86,BCL2,BCL11B,RUNX1,LY9,JAK1,PNP,TNFRSF14,CBFB,FOXP1,SMAD7,ZBTB16	
GO:0007159	leukocyte cell-cell adhesion	1,23E-16	8,45E-17	S100A8,PLA2G2A,APOA4,CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,KLF4,EFNB1,SELL,LGALS3,IL2RG,ETS1,ZAP70,RUNX3,XBP1,TIGIT,SOCS1,GPR65,IRF1,SPN,ICAM1,RHOH,TNF,CD55,ITGAL,FYN,CD83,CD300A,TNFSF13B,SASH3,TGFB1,LILRB2,STK10,SKAP1,PTPN6,SELP,FERMT3,NCKAP1L,MDK,LRRC32,PRDX2,BMP4,RASAL3,PRNP,SELPLG,CBLB,CD6,SEMA4D,ITGA4,DOCK8,MAP3K8,CLECL1,PAG1,GATA3,LYN,LILRB4,SYK,HSPH1,PTPN22,HAVCR2,NFKBIZ,CD86,CD47,MSN,RUNX1,EZR,PTPN2,ITGA5,CSK,PNP,TNFRSF14,CBFB,SMAD7,ZBTB16	87
GO:0050900	leukocyte migration	3,23E-16	2,21E-16	S100A8,S100A12,CXCL8,XCL1,CXCL3,LYVE1,CCL2,CXCL6,EDN1,IL1B,PPBP,LGMN,THBS1,CCL21,GPR183,CXCL13,PF4,CCL20,C5AR1,LCK,CD34,CXCL10,CXCL16,SELL,LGALS3,IL16,JAML,ZAP70,SERPINE1,IL1R1,CXCL9,CCR1,CSF3R,EDNRB,SPN,ICAM1,TNF,MYO1G,ITGAL,FYN,CD300A,S100A14,TGFB1,PTGER4,STK10,HCK,C3AR1,SELP,MAPK1,GAS6,NCKAP1L,MDK,S1PR1,SELPLG,IL27RA,ITGA4,CKLF,LYST,NEDD9,DOCK8,GATA3,TREM2,RIN3,APOD,MPP1,PREX1,LYN,SYK,PPIB,PLVAP,CNN2,CD47,ADAM17,MSN,GP2,SLC12A2,PDE4B,TNFRSF14,BCR,IL17RA,PTK2B	81
GO:0032496	response to lipopolysaccharide	3,25E-16	2,23E-16	S100A8,CXCL8,LCN2,CCL2,CXCL6,SNCA,EDN1,IL1B,PPBP,SPON2,COL6A1,NR4A1,CXCL13,PF4,CD14,EFNB2,CXCL10,TNFAIP3,NQO1,MEF2C,SERPINE1,XBP1,CXCL9,TSPO,CD96,EDNRB,SLC11A1,PTGER2,TNF,CD55,IL10RA,FGFR2,IRF8,TLR4,S100A14,LILRB2,PDCD4,PTPN6,HCK,SELP,MAPK1,LITAF,PRDX2,THBD,TNFRSF1B,CD6,CASP1,IRAK3,FOSL2,BLVRA,SMAD6,GBP2,TREM2,LYN,CAPN2,ARID5A,PTPN22,HAVCR2,PLCG2,SCIMP,NFKBIZ,CARD8,CD86,IRF3,GBP5,ADAM17,PLSCR4,TLR2,CASP8,PDE4B,FOXP1,BCR,NOTCH1,JUND,TRIB1	75
GO:0002237	response to molecule of bacterial origin	3,69E-16	2,53E-16	S100A8,CXCL8,LCN2,CD24,CCL2,CXCL6,SNCA,EDN1,IL1B,PPBP,SPON2,COL6A1,NR4A1,CXCL2,CXCL13,PF4,CD14,C5AR1,EFNB2,CXCL10,TNFAIP3,NQO1,MEF2C,SERPINE1,XBP1,CXCL9,TSPO,CD96,EDNRB,SLC11A1,PTGER2,TNF,CD55,IL10RA,FGFR2,IRF8,TLR4,S100A14,LILRB2,PDCD4,PTPN6,HCK,SELP,MAPK1,LITAF,PRDX2,THBD,TNFRSF1B,CD6,CASP1,IRAK3,FOSL2,BLVRA,SMAD6,GBP2,TREM2,LYN,CAPN2,ARID5A,PTPN22,HAVCR2,PLCG2,SCIMP,NFKBIZ,CARD8,CD86,IRF3,GBP5,ADAM17,PLSCR4,TLR2,CASP8,PDE4B,FOXP1,BCR,NOTCH1,JUND,TRIB1	78
GO:0042113	B cell activation	6,92E-15	4,74E-15	IGHM,MZB1,IL7R,MNDA,LGALS1,CD79A,GPR183,CD27,KLF6,CD79B,POU2AF1,TNFAIP3,CD320,MS4A1,MEF2C,IL2RG,TBC1D10C,ZAP70,IKZF3,ITM2A,SAMSN1,CD38,XBP1,PRKCB,LAT2,CD300A,TNFSF13B,SASH3,IRF8,TLR4,TGFB1,INPP5D,PTPN6,NCKAP1L,ID2,SKAP2,IL27RA,ATM,THEMIS2,ITGA4,FOSL2,TCIRG1,LYN,SH3KBP1,SYK,BAX,TNFRSF13B,PLCG2,MFNG,BATF,NFKBIZ,CDKN1A,CD86,BCL2,CMTM7,PKN1,ADAM17,NFATC2,LYL1,BST2,PTPN2,CASP8,HDAC9,SFRP1,PTK2B	65
GO:0070661	leukocyte proliferation	9,70E-15	6,64E-15	MZB1,PLA2G2A,CD24,IL7R,MNDA,XCL1,CD79A,IL1B,CD3E,GPR183,TMIGD2,TNFAIP3,EFNB1,LGALS3,CD320,MS4A1,MEF2C,ZAP70,IKZF3,CD38,MYC,IRF1,SPN,SLC11A1,CD55,FYN,CD300A,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,MAPK1,NCKAP1L,LRRC32,PRDX2,BMP4,RASAL3,PRNP,CBLB,TNFRSF1B,CD6,ATM,DOCK8,FOSL2,CLECL1,CD151,TCIRG1,TREM2,LYN,LILRB4,SYK,BAX,TNFRSF13B,PTPN22,HAVCR2,DOCK2,NFKBIZ,CDKN1A,CD86,BCL2,CNN2,PSMB10,PKN1,MSN,NFATC2,BST2,SH2D2A,PNP,TNFRSF14	73
GO:0050852	T cell receptor signaling pathway	9,84E-15	6,74E-15	CD3D,TRAC,TRDC,TRBC1,TRBC2,TRGC2,CD3E,CD160,CD247,CD8A,CD3G,TXK,LCK,CD8B,TRGC1,SH2D1A,BTNL9,LGALS3,ZAP70,LAT,FYN,CD300A,INPP5D,SKAP1,PTPN6,DGKZ,MAPK1	45

				,BTN3A2,PRNP,LCP2,CBLB,THEMIS2,ELF1,FOSL2,GATA3,LILRB4,TRAT1,PTPN22,PLCG2,NFKBIZ,EZR,RAB29,PTPN2,CSK,PDE4B	
GO:0032943	mononuclear cell proliferation	1,31E-14	8,98E-15	MZB1,PLA2G2A,CD24,IL7R,MNDA,XCL1,CD79A,IL1B,CD3E,GPR183,TMIGD2,EFNB1,LGALS3,CD320,MS4A1,MEF2C,ZAP70,IKZF3,CD38,MYC,IRF1,SPN,SLC11A1,CD55,FYN,CD300A,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,NCKAP1L,LRRC32,PRDX2,BMP4,RASAL3,PRNP,CBLB,TNFRSF1B,CD6,ATM,DOCK8,FOSL2,CLECL1,CD151,LYN,LILRB4,SYK,BAX,TNFRSF13B,PTPN22,HAVCR2,DOCK2,NFKBIZ,CDKN1A,CD86,BCL2,CNN2,PSMB10,PKN1,MSN,NFATC2,SH2D2A,PNP,TNFRSF14	68
GO:0046651	lymphocyte proliferation	1,41E-14	9,66E-15	MZB1,PLA2G2A,CD24,IL7R,MNDA,XCL1,CD79A,IL1B,CD3E,GPR183,TMIGD2,EFNB1,LGALS3,CD320,MS4A1,MEF2C,ZAP70,IKZF3,CD38,MYC,IRF1,SPN,SLC11A1,CD55,FYN,CD300A,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,NCKAP1L,LRRC32,PRDX2,BMP4,RASAL3,PRNP,CBLB,TNFRSF1B,CD6,ATM,DOCK8,FOSL2,CLECL1,CD151,LYN,LILRB4,SYK,BAX,TNFRSF13B,PTPN22,HAVCR2,DOCK2,NFKBIZ,CDKN1A,CD86,BCL2,PSMB10,PKN1,MSN,NFATC2,SH2D2A,PNP,TNFRSF14	67
GO:0050867	positive regulation of cell activation	1,41E-14	9,66E-15	ACTA2,CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,CD2,IL1B,CD3E,CD160,THBS1,CCL21,GPR183,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,CD320,IL16,MEF2C,IL2RG,ZAP70,RUNX3,PLEK,CD38,XBP1,SOCS1,GPR65,SPN,FLNA,RHOH,TNF,CD55,FYN,CD83,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,SELP,GAS6,NCKAP1L,MDK,RASAL3,CD6,DOCK8,MAP3K8,CLECL1,GATA3,TREM2,LYN,LILRB4,SH3KBP1,SYK,HSPH1,HAVCR2,NFKBIZ,RPS6KA1,CDKN1A,CD86,BCL2,CD47,RUNX1,NFATC2,LILRA5,CSK,PNP,TNFRSF14,CBFB,JUND,ZBTB16	78
GO:0050863	regulation of T cell activation	7,00E-14	4,80E-14	PLA2G2A,CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,CD2,IL1B,CD3E,CD160,CCL21,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,LGALS3,IL2RG,ZAP70,PRDM1,RUNX3,XBP1,TIGIT,SOCS1,GPR65,IRF1,LAT,SPN,SIT1,RHOH,CYP26B1,CD55,FYN,CD83,CD300A,TNFSF13B,SASH3,TGFB1,LILRB2,PTPN6,NCKAP1L,MDK,LRRC32,PRDX2,BMP4,RASAL3,PRNP,CBLB,TNFRSF1B,CD6,DOCK8,MAP3K8,CLECL1,PAG1,GATA3,LYN,LILRB4,SYK,HSPH1,PTPN22,HAVCR2,BATF,NFKBIZ,CD86,CD47,TCF7,RUNX1,PTPN2,CSK,PNP,TNFRSF14,CBFB,SMAD7,ZBTB16	77
GO:0048872	homeostasis of number of cells	1,74E-13	1,19E-13	HBB,HBA2,HBA1,HBD,AHSP,HBM,ALAS2,PLA2G2A,LGALS2,IL7R,SLC4A1,CXCL6,TNFRSF17,HSPA1A,SOX4,GLUL,COL6A1,HSPA1B,GPR183,PMAIP1,LYAR,TNFAIP3,MEF2C,TUBA1A,ETS1,FSTL1,RHAG,LAT,SIT1,CITED2,CCNB2,KLF1,TNFSF13B,SASH3,IKZF1,TGFB1,EPB42,HIF1A,INPP5D,TRIM58,BPGM,NCKAP1L,PRDX2,BMP4,ID2,ADGRG1,MERTK,BCL2L11,ISG15,G6PD,FOSL2,GATA3,TCIRG1,LYN,PRMT1,BAX,TNFRSF13B,NFKBIZ,HBQ1,BCL2,SOX9,PKN1,SH2B3,ADAM17,RASSF2,KMT2E,SKIL,PTPN2,RB1,PDE4B,BCR,NOTCH1	72
GO:0001906	cell killing	1,74E-13	1,19E-13	IGHG1,GNLY,S100A12,CXCL8,PLA2G2A,GZMB,FCN1,IL7R,CXCL1,PRF1,GZMH,XCL1,GZMK,KLRC1,CXCL3,CXCL6,CFHR1,CD2,PPBP,CD160,CCL21,CXCL2,CXCL13,PF4,GZMM,CCL20,TUBB,SH2D1A,CXCL10,CXCL14,LGALS3,STXBP2,NCR3,CXCL9,TIGIT,CD59,ICAM1,FCGR2A,ITGAM,NCF1,CD55,DEFA3,FCGR1A,NTS,TGFB1,INPP5D,PTPN6,HLA-F,SERPINB9,NCKAP1L,ARRB2,PIM1,LYST,KLRC2,TUBB4B,GBP2,HAVCR2,STX7,GBP5,SLAMF7,RAB27A	61
GO:0006935	chemotaxis	2,25E-13	1,54E-13	S100A8,S100A12,CXCL8,CCL3L3,CXCL1,XCL2,XCL1,CXCL3,CCL2,CXCL6,EDN1,IL1B,PPBP,LGMN,THBS1,NR4A1,CCL21,CXCL2,GPR183,CXCL13,RNASE2,PF4,CCL20,C5AR1,EFNB2,PLAUR,FPR1,CXCR6,CXCL10,CXCL14,CXCL16,LGALS3,IL16,JAML,BIN2,SERPINE1,HGF,HSPB1,CXCL9,CCR1,CSF3R,EDNRB,SPN,PLP2,S100A14,TGFB1,BMPR2,CMTM3,C3AR1,MAPK1,GAS6,NCKAP1L,TYMP,MDK,S1PR1,BMP4,RHOG,FPR3,ARRB2,SEMA4D,CKLF,LYST,NEDD9,BLVR	84

				A,TREM2,RIN3,MPP1,PREX1,LYN,SYK,PPIB,DOCK2,FGFR1,CMTM7,ADAM17,STX4,PTPN2,SLC12A2,CORO1B,PDE4B,AGTR1,IL17RA,NOTCH1,PTK2B	
GO:0042330	taxis	2,77E-13	1,90E-13	S100A8,S100A12,CXCL8,CCL3L3,CXCL1,XCL2,XCL1,CXCL3,CCL2,CXCL6,EDN1,IL1B,PPBP,LGMN,THBS1,NR4A1,CCL21,CXCL2,GPR183,CXCL13,RNASE2,PF4,CCL20,C5AR1,EFNB2,PLAUR,FPR1,CXCR6,CXCL10,CXCL14,CXCL16,LGALS3,IL16,JAML,BIN2,SERPINE1,HGF,HSPB1,CXCL9,CCR1,CSF3R,EDNRB,SPN,PLP2,S100A14,TGFB1,BMPR2,CMTM3,C3AR1,MAPK1,GAS6,NCKAP1L,TYMP,MDK,S1PR1,BMP4,RHOG,FPR3,ARRB2,SEMA4D,CKLF,LYST,NEDD9,BLVRA,TREM2,RIN3,MPP1,PREX1,LYN,SYK,PPIB,DOCK2,FGFR1,CMTM7,ADAM17,STX4,PTPN2,SLC12A2,CORO1B,PDE4B,AGTR1,IL17RA,NOTCH1,PTK2B	84
GO:0034341	response to type II interferon	2,89E-13	1,98E-13	CCL2,SNCA,EDN1,IFNG,GSN,IFITM1,TXK,CXCL16,STXBP2,IRF1,SLC11A1,TNF,IRF8,TLR4,HCK,WAS,CASP1,PIM1,FLNB,GBP4,IFNGR1,GBP2,IFNGR2,ZYX,GBP5,CD47,IFITM2,RAB20,BST2,SP100,STX4,PTPN2,DAPK1,JAK1,TLR2,ACTR3,CDC37,PARP14,ACTR2	39
GO:1903037	regulation of leukocyte cell-cell adhesion	3,76E-13	2,57E-13	PLA2G2A,CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,KLF4,EFNB1,LGALS3,IL2RG,ETS1,ZAP70,RUNX3,XBP1,TIGIT,SOCS1,GPR65,IRF1,SPN,RHOH,TNF,CD55,FYN,CD83,CD300A,TNFSF13B,SASH3,TGFB1,LILRB2,SKAP1,PTPN6,SELP,NCKAP1L,MDK,LRRC32,PRDX2,BMP4,RASAL3,PRNP,CBLB,CD6,ITGA4,DOCK8,MAP3K8,CLECL1,PAG1,GATA3,LYN,LILRB4,SYK,HSPH1,PTPN22,HAVCR2,NFKBIZ,CD86,CD47,RUNX1,PTPN2,CSK,PNP,TNFRSF14,CBFB,SMAD7,ZBTB16	75
GO:0002696	positive regulation of leukocyte activation	7,72E-13	5,29E-13	CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,CD2,IL1B,CD3E,CD160,THBS1,CCL21,GPR183,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,CD320,IL16,MEF2C,IL2RG,ZAP70,RUNX3,CD38,XBP1,SOCS1,GPR65,SPN,RHOH,TNF,CD55,FYN,CD83,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,GAS6,NCKAP1L,MDK,RASAL3,CD6,DOCK8,MAP3K8,CLECL1,GATA3,TREM2,LYN,LILRB4,SH3KBP1,SYK,HSPH1,HAVCR2,NFKBIZ,CDKN1A,CD86,BCL2,CD47,RUNX1,NFATC2,CSK,PNP,TNFRSF14,CBFB,JUND,ZBTB16	72
GO:0022409	positive regulation of cell-cell adhesion	1,29E-12	8,81E-13	CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,CD27,CXCL13,TMIGD2,EFNB2,HLA-DQA2,LCK,PLAUR,EFNB1,IL2RG,ETS1,ZAP70,RUNX3,XBP1,SOCS1,GPR65,SPN,RHOH,CITED2,TNF,CD55,FYN,CD83,TNFSF13B,SASH3,TGFB1,LILRB2,SKAP1,PTPN6,SELP,NCKAP1L,MDK,RASAL3,CD6,ITGA4,DOCK8,MYO10,MAP3K8,CLECL1,GATA3,LYN,LILRB4,SYK,HSPH1,HAVCR2,NFKBIZ,CD86,PODXL,CD47,RUNX1,JAK1,CSK,PNP,TNFRSF14,CBFB,SMAD7,ZBTB16	67
GO:0002449	lymphocyte mediated immunity	1,85E-12	1,27E-12	IGKC,IGHG1,IGHG3,IGHA1,IGLC2,IGLC3,IGHG4,IGHG2,IGHA2,IGLL5,GZMB,IGLC7,IL7R,PRF1,XCL1,KLRC1,IGLC6,IFNG,CD2,IL2RB,IL1B,CD160,CD8A,CD27,IGHV1-24,GZMM,TUBB,SH2D1A,IGHV3-15,IL1R1,NCR3,TIGIT,IGHV3-23,CD96,SPN,ICAM1,FCMR,FCGR2A,TNF,MYO1G,CD55,FCGR1A,SASH3,TGFB1,INPP5D,PTPN6,HLA-F,SERPINB9,NCKAP1L,WAS,BTN3A2,TNFRSF1B,IL27RA,ARRB2,LYST,KLRC2,GATA3,TCIRG1,TUBB4B,TREM2,LILRB4,ARID5A,IGHV3-48,HAVCR2,BATF,NFKBIZ,STX7,SH2D1B,SLAMF7,RAB27A,IGHD,SMAD7	72
GO:1903039	positive regulation of leukocyte cell-cell adhesion	1,85E-12	1,27E-12	CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,IL2RG,ETS1,ZAP70,RUNX3,XBP1,SOCS1,GPR65,SPN,RHOH,TNF,CD55,FYN,CD83,TNFSF13B,SASH3,TGFB1,LILRB2,SKAP1,PTPN6,SELP,NCKAP1L,MDK,RASAL3,CD6,I	60

				TGA4,DOCK8,MAP3K8,CLECL1,GATA3,LYN,LILRB4,SYK,HSPH1,HAVCR2,NFKBIZ,CD86,CD47,RUNX1,CSK,PNP,TNFRSF14,CBFB,ZBTB16	
GO:0060326	cell chemotaxis	1,95E-12	1,34E-12	S100A8,S100A12,CXCL8,CCL3L3,CXCL1,XCL2,XCL1,CXCL3,CCL2,CXCL6,EDN1,IL1B,PPBP,LGMN,THBS1,NR4A1,CCL21,CXCL2,GPR183,CXCL13,PF4,CCL20,C5AR1,CXCR6,CXCL10,CXCL14,CXCL16,LGALS3,IL16,JAML,BIN2,SERPINE1,HGF,HSPB1,CXCL9,CCR1,CSF3R,EDNRB,S100A14,C3AR1,MAPK1,GAS6,NCKAP1L,MDK,S1PR1,RHOG,ARRB2,CKLF,LYST,NEDD9,RIN3,MPP1,PREX1,LYN,SYK,PPIB,FGFR1,ADAM17,SLC12A2,CORO1B,PDE4B,AGTR1,IL17RA,NOTCH1,PTK2B	65
GO:0071222	cellular response to lipopolysaccharide	2,42E-12	1,66E-12	CXCL8,LCN2,CCL2,CXCL6,IL1B,PPBP,SPON2,CXCL13,PF4,CD14,EFNB2,CXCL10,TNFAIP3,MEF2C,SERPINE1,XBP1,CXCL9,TSPO,EDNRB,TNF,CD55,IRF8,TLR4,LILRB2,PDCD4,PTPN6,HCK,MAPK1,LITAF,PRDX2,TNFRSF1B,CD6,CASP1,IRAK3,GBP2,LYN,CAPN2,ARID5A,PTPN22,HAVCR2,PLCG2,SCIMP,NFKBIZ,CARD8,CD86,IRF3,GBP5,PLSCR4,TLR2,PDE4B,BCR,TRIB1	52
GO:0071346	cellular response to type II interferon	5,19E-12	3,55E-12	CCL2,EDN1,IFNG,GSN,TXK,STXBP2,IRF1,TNF,IRF8,TLR4,HCK,WAS,CASP1,PIM1,FLNB,GBP4,IFNGR1,GBP2,IFNGR2,ZYX,GBP5,CD47,RAB20,SP100,STX4,PTPN2,DAPK1,JAK1,TLR2,ACTR3,CDC37,PARP14,ACTR2	33
GO:0051251	positive regulation of lymphocyte activation	5,49E-12	3,76E-12	CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,GPR183,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,CD320,MEF2C,IL2RG,ZAP70,RUNX3,CD38,XBP1,SOCS1,GPR65,SPN,RHOH,CD55,FYN,CD83,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,GAS6,NCKAP1L,MDK,RASAL3,CD6,DOCK8,MAP3K8,CLECL1,GATA3,LYN,LILRB4,SH3KBP1,SYK,HSPH1,HAVCR2,NFKBIZ,CDKN1A,CD86,BCL2,CD47,RUNX1,NFATC2,CSK,PNP,TNFRSF14,CBFB,ZBTB16	66
GO:0030217	T cell differentiation	5,89E-12	4,03E-12	IL7R,LGALS1,KLRC1,CD3D,IFNG,SOX4,CD2,IL1B,CD3E,CD8A,CD3G,GPR183,SOCS3,CD27,LCK,EGR1,IL2RG,EOMES,ZAP70,IKZF3,PRDM1,CLEC4E,RUNX3,XBP1,SOCS1,GPR65,IRF1,SPN,RHOH,CYP26B1,CD83,SASH3,TGFB1,PTGER4,LILRB2,NCKAP1L,MDK,PRDX2,BMP4,FOSL2,STAT4,GATA3,TCIRG1,PREX1,LILRB4,SYK,PTPN22,DOCK2,BATF,NFKBIZ,CD86,BCL2,BCL11B,ADAM17,TCF7,RUNX1,LY9,PTPN2,JAK1,PNP,CBFB,FOXP1,SMAD7,ZBTB16	64
GO:0051250	negative regulation of lymphocyte activation	6,14E-12	4,21E-12	PLA2G2A,MNDA,XCL1,LGALS1,TNFAIP3,LGALS3,TBC1D10C,FGR,RUNX3,SAMSN1,TIGIT,SOCS1,IRF1,SPN,CD300A,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,MDK,LRRC32,PRDX2,BMP4,ID2,PRNP,CBLB,ATM,MERTK,CLEC12A,PAG1,LYN,LILRB4,TNFRSF13B,PTPN22,HAVCR2,CD86,PKN1,RUNX1,PTPN2,CSK,TNFRSF14,CBFB,SMAD7,SFRP1	45
GO:0071216	cellular response to biotic stimulus	6,36E-12	4,36E-12	CXCL8,LCN2,CCL2,CXCL6,IL1B,PPBP,SPON2,CXCL13,PF4,CD14,EFNB2,CXCL10,TNFAIP3,MEF2C,SERPINE1,XBP1,CXCL9,TSPO,EDNRB,TNF,CD55,IRF8,TLR4,HSPA5,LILRB2,PDCD4,PTPN6,HCK,MAPK1,LITAF,PRDX2,TNFRSF1B,CD6,CASP1,IRAK3,DDIT3,GBP2,TREM2,LYN,CAPN2,SYK,ARID5A,PTPN22,HAVCR2,PLCG2,SCIMP,NFKBIZ,CARD8,CD86,IRF3,GBP5,PLSCR4,TLR2,PDE4B,BCR,NOTCH1,TRIB1	57
GO:0006959	humoral immune response	6,98E-12	4,78E-12	IGHM,IGHG1,JCHAIN,IGHG3,IGHA1,IGHG4,GNLY,IGHG2,IGHA2,S100A12,CXCL8,CCL3L3,FCN1,CXCL1,XCL2,XCL1,GZMK,CFHR3,CXCL3,CCL2,IGKV3-20,CXCL6,CFHR1,IFNG,LGALS4,IL1B,PPBP,COLEC11,SPON2,CCL21,CXCL2,GPR183,CXCL13,PF4,CCL20,SH2D1A,CXCL10,POU2AF1,CXCL14,PGC,LGALS3,MS4A1,ADM,MEF2C,CXCL9,CD59,SLC11A1,FCMR,TNF,CD55,DEFA3,CD83,NTS,PTPN6,POU2F2,GATA3,TREM2,BCL2,PSMB10,IGHD,NOTCH1	61
GO:0002460	adaptive immune response based on somatic recombination of	8,96E-12	6,14E-12	IGKC,IGHG1,IGHG3,IGHA1,IGLC2,IGLC3,IGHG4,IGHG2,IGHA2,IGLL5,IGLC7,IL7R,PRF1,XCL1,LGALS1,KLRC1,IGLC6,IFNG,IL2RB,IL1B,CD8A,SOCS3,CD27,CXCL13,IGHV1-24,GZMM,IGHV3-15,TNFAIP3,MEF2C,IL1R1,IGHV3-23,SPN,ICAM1,SLC11A1,FCMR,FCGR2A,TNF,MYO1G,CD55,FCGR1A,TNFSF13B,SASH3,TLR4	72

	immune receptors built from immunoglobulin superfamily domains			,TGFB1,INPP5D,PTPN6,HLA-F,NCKAP1L,WAS,BTN3A2,TNFRSF1B,IL27RA,STAT4,GATA3,TCIRG1,TREM2,LILRB4,ARID5A,IGHV3-48,HAVCR2,BATF,NFKBIZ,STX7,PKN1,ADAM17,LY9,JAK1,RAB27A,IL17RA,IGHD,NOTCH1,SMAD7	
GO:0071219	cellular response to molecule of bacterial origin	1,24E-11	8,52E-12	CXCL8,LCN2,CCL2,CXCL6,IL1B,PPBP,SPON2,CXCL13,PF4,CD14,EFNB2,CXCL10,TNFAIP3,MEF2C,SERPINE1,XBP1,CXCL9,TSPO,EDNRB,TNF,CD55,IRF8,TLR4,LILRB2,PDCD4,PTPN6,HCK,MAPK1,LITAF,PRDX2,TNFRSF1B,CD6,CASP1,IRAK3,GBP2,TREM2,LYN,CAPN2,ARID5A,PTPN22,HAVCR2,PLCG2,SCIMP,NFKBIZ,CARD8,CD86,IRF3,GBP5,PLSCR4,TLR2,PDE4B,BCR,TRIB1	53
GO:0030099	myeloid cell differentiation	2,14E-11	1,46E-11	HBB,HBA2,HBA1,HBD,AHSP,HBM,ALAS2,SLC4A1,HSPA1A,IFNG,GLUL,MAF,HSPA1B,GPR183,PF4,LYAR,EVI2B,MEF2C,ETS1,RHAG,CCR1,CSF3R,MYC,SOCS1,TPM4,FLNA,CITED2,PABPC4,TNF,KLF1,IRF8,TLR4,IKZF1,TGFB1,EPB42,HIF1A,INPP5D,TRIM58,PTPN6,GPR171,BPGM,NCKAP1L,BMP4,ID2,BLVRB,ISG15,NEDD9,TESC,G6PD,FOSL2,GATA3,TCIRG1,P2RX5,TREM2,LYN,LILRB4,PRMT1,PIR,SNRK,BATF,HBQ1,CDKN1C,FLI1,SH2B3,RUNX1,RASSF2,KMT2E,KLF10,CFLAR,PTPN2,GPR137B,TLR2,RB1,CASP8,CBFB,FOXP1,ZBTB16,SFRP1,PTK2B,TRIB1	80
GO:0050866	negative regulation of cell activation	2,18E-11	1,49E-11	PLA2G2A,MNDA,XCL1,LGALS1,TNFAIP3,LGALS3,TBC1D10C,FGR,RUNX3,CD84,SAMSN1,TIGIT,SOCS1,IRF1,SPN,CD300A,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,MDK,LRRC32,PRDX2,THBD,BMP4,ID2,PRNP,CBLB,ATM,MERTK,CLEC12A,PAG1,CD33,TREM2,LYN,LILRB4,TNFRSF13B,PTPN22,HAVCR2,CD86,PKN1,SH2B3,RUNX1,PTPN2,CSK,SERPINE2,TNFRSF14,CBFB,SMAD7,SFRP1	51
GO:0050870	positive regulation of T cell activation	2,34E-11	1,60E-11	CD24,IL7R,XCL1,LGALS1,CCL2,IFNG,SOX4,IL1B,CD3E,CD160,CCL21,CD27,TMIGD2,EFNB2,HLA-DQA2,LCK,EFNB1,IL2RG,ZAP70,RUNX3,XBP1,SOCS1,GPR65,SPN,RHOH,CD55,FYN,CD83,TNFSF13B,SASH3,TGFB1,LILRB2,PTPN6,NCKAP1L,MDK,RASAL3,CD6,DOCK8,MAP3K8,CLECL1,GATA3,LYN,LILRB4,SYK,HSPH1,HAVCR2,NFKBIZ,CD86,CD47,RUNX1,CSK,PNP,TNFRSF14,CBFB,ZBTB16	55
GO:0031589	cell-substrate adhesion	3,09E-11	2,11E-11	COL1A1,COL3A1,LYVE1,AGR2,POSTN,CD3E,THBS1,CCL21,TACSTD2,DAB2,CD34,SPOCK2,COL8A1,SERPINE1,DLC1,MYADM,LIMS2,NID1,CD96,FLNA,ITGAM,MYO1G,RIN2,ITGAL,SKAP1,LIMCH1,TNFRSF12A,FERMT3,GAS6,MDK,STK4,TRIOBP,FBLN2,MERTK,BCL2L11,FZD4,ITGA4,NEDD9,SMAD6,LPXN,APOD,PREX1,PARVG,ARL2,FBLN5,ANKRD28,UTRN,FBLN1,PLEKHA2,ZYX,ADAM15,RRAS,BCL2,CD63,LIMS1,PXN,TIAM1,MACF1,ITGA5,ONECUT2,CLASP1,BCR,CCDC80,NOTCH1,SFRP1,CDH11,PTK2B	67
GO:0002695	negative regulation of leukocyte activation	8,05E-11	5,52E-11	PLA2G2A,MNDA,XCL1,LGALS1,TNFAIP3,LGALS3,TBC1D10C,FGR,RUNX3,CD84,SAMSN1,TIGIT,SOCS1,IRF1,SPN,CD300A,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,MDK,LRRC32,PRDX2,BMP4,ID2,PRNP,CBLB,ATM,MERTK,CLEC12A,PAG1,CD33,LYN,LILRB4,TNFRSF13B,PTPN22,HAVCR2,CD86,PKN1,RUNX1,PTPN2,CSK,TNFRSF14,CBFB,SMAD7,SFRP1	47
GO:0042742	defense response to bacterium	1,00E-10	6,88E-11	IGHM,S100A8,IGHG1,JCHAIN,IGHG3,IGHA1,IGHG4,GNLY,IGHG2,IGHA2,S100A12,PLA2G2A,LCN2,IL7R,AQP1,IGKV3-20,CXCL6,LGALS4,IL1B,PPBP,CD160,SPON2,CXCL13,CCL20,C5AR1,PGC,ADM,SERPINE1,FGR,CLEC4E,SPN,SLC11A1,TNF,NCF1,DEFA3,FCGR1A,IRF8,TLR4,S100A14,HCK,SELP,NAIP,IL27RA,CASP1,PIM1,ISG15,GBP4,LYST,GBP2,TREM2,SYK,CASP4,HAVCR2,NFKBIZ,NAGK,GBP5,ADAM17,NLRP1,MCOLN1,TLR2,OPTN,RNF213,TNFRSF14,FOXP1,IGHD	65
GO:1903706	regulation of hemopoiesis	1,25E-10	8,54E-11	IL7R,LGALS1,HSPA1A,IFNG,SOX4,CD2,GLUL,HSPA1B,CD27,PF4,LCK,EVI2B,MEF2C,IL2RG,ETS1,ZAP70,IKZF3,PRDM1,RUNX3,XBP1,CCR1,CSF3R,MYC,SOCS1,GPR65,IRF1,RHOH,TNF,C	74

				YP26B1,CD83,SASH3,TLR4,TGFB1,HIF1A,LILRB2,INPP5D,PTPN6,GPR171,TSC22D1,GAS6,NCKAP1L,MDK,PRDX2,BMP4,ID2,ISG15,NEDD9,TESC,CLEC12A,GATA3,TREM2,LYN,LILRB4,PRMT1,SYK,BATF,NFKBIZ,CD86,TCF7,RUNX1,RASSF2,KLF10,PTPN2,GPR137B,RB1,PNP,CASP8,CBFB,FOXP1,SMAD7,ZBTB16,SFRP1,PTK2B,TRIB1	
GO:0042060	wound healing	1,35E-10	9,24E-11	HBB,COL3A1,GZMB,MYL9,SLC4A1,EREG,PRF1,AQP1,EDN1,THBS1,TPM1,CLDN4,TSPAN8,PF4,LCK,PLAUR,CD34,TNFAIP3,JAML,TFPI2,SERPINE1,ELK3,PLEK,XBP1,HSPB1,CD59,PROCR,FLNA,SLC11A1,PABPC4,TNF,F13A1,TLR4,RHOC,TGFB1,HIF1A,PTPN6,SELP,TNFRSF12A,FERMT3,DGKZ,RAP2B,GAS6,ANXA5,WAS,PRDX2,THBD,ADGRG1,CLDN3,CASP1,MERTK,AHNAK,ENTPD1,CD151,LYN,SYK,PLCG2,FBLN1,PLSCR1,CDKN1A,CNN2,SH2B3,ADAM17,CSRP1,GNAS,CHMP1B,MACF1,FGFR1OP2,JMJD1C,ITGA5,SLC12A2,SERPINE2,CORO1B,RAB27A,CLASP1	75
GO:0097191	extrinsic apoptotic signaling pathway	1,40E-10	9,62E-11	LCN2,LTB,HSPA1A,IFNG,IL1B,ITM2C,THBS1,HSPA1B,CD27,PMAIP1,PF4,KLF4,TNFAIP3,LGALS3,SERPINE1,HGF,LMNA,ICAM1,TNF,G0S2,FYN,TLR4,TGFB1,TNFRSF12A,ITPRIP,PRDX2,STK4,BMP4,TNFRSF1B,IFI6,BCL2L11,ATF3,BCL2A1,TMC8,BAX,PEA15,NFKBIZ,BCL2,FGFR1,TNFSF12,PHIP,DAXX,SKIL,SP100,STX4,CFLAR,DAPK1,CASP8,TNFSF10,SFRP1	50
GO:0050777	negative regulation of immune response	2,18E-10	1,49E-10	COL3A1,IL7R,XCL1,LGALS1,KLRC1,CD160,LYAR,TNFAIP3,LGALS3,FGR,SAMSN1,TIGIT,CD59,CD96,SPN,CD55,FYN,CD300A,TGFB1,INPP5D,PTPN6,HLA-F,HCK,SERPINB9,NCKAP1L,PLK2,AURKB,IL27RA,ARRB2,PIM1,SAMHD1,IRAK3,ISG15,CLEC12A,TREM2,LYN,LILRB4,DDX39A,SYK,HAVCR2,MCOLN1,GNAS,PTPN2,TNFRSF14,PARP14,BCR,SMAD7,RHBDF2	48
GO:0032944	regulation of mononuclear cell proliferation	2,19E-10	1,50E-10	MZB1,PLA2G2A,CD24,MNDA,XCL1,IL1B,CD3E,GPR183,TMIGD2,EFNB1,LGALS3,CD320,MEF2C,ZAP70,IKZF3,CD38,IRF1,SPN,CD55,CD300A,TNFSF13B,SASH3,TLR4,TGFB1,LILRB2,INPP5D,PTPN6,RASSF5,NCKAP1L,LRRC32,BMP4,RASAL3,PRNP,CBLB,TNFRSF1B,CD6,ATM,CLECL1,LYN,LILRB4,SYK,TNFRSF13B,PTPN22,HAVCR2,CDKN1A,CD86,BCL2,CNN2,PKN1,NFATC2,PNP,TNFRSF14	52
GO:0002366	leukocyte activation involved in immune response	2,27E-10	1,55E-10	PTGDS,LGALS1,IFNG,CD160,GPR183,SOCS3,POU2AF1,LGALS3,STXBP2,EOMES,FGR,ITM2A,CLEC4E,CD84,XBP1,GPR65,LAT,SPN,ICAM1,SLC11A1,TNF,ITGAM,ITGAL,LAT2,PTGDR,CD300A,IRF8,TLR4,TGFB1,PTGER4,PTPN6,HLA-F,NCKAP1L,MDK,IL27RA,CLEC12A,KLRC2,STAT4,GATA3,TREM2,LYN,SYK,HAVCR2,PLCG2,DOCK2,MFNG,BATF,NFKBIZ,APBB1IP,CD86,VAMP2,SH2D1B,LY9,STX4,JAK1,FOXP1,RAB27A,BCR,SMAD7,PTK2B	60

Tabla 5. Anexo. Resultados detallados del análisis de enriquecimiento funcional (Gene Ontology: Biological Process). Se desglosan los 50 términos ontológico más significativo detectado mediante el algoritmo enrichGO. Las métricas incluyen la significación estadística expresada mediante el p.adjust (probabilidad de que el resultado sea por azar bajo la hipótesis nula) y el q-value (confianza que tienes en que ese resultado sea verdadero), ambos corregidos por el método de Benjamini-Hochberg para controlar el FDR. La columna geneID enumera los genes del dataset que pertenecen a cada módulo funcional. Finalmente, el Count indica el número total de genes de la lista que están integrados en cada proceso biológico.

Nodo1	Nodo2	Coexpresión	Interacción determinada Experimentalmente	Minado de Texto Automático	Puntuación Combinada
ANGPTL3	APOB	0.239	0	0.845	0.877
ANGPTL3	CILP2	0	0.053	0.524	0.529
ANGPTL3	TRIB1	0	0	0.703	0.703
ANGPTL3	MLXIPL	0.071	0	0.522	0.537
ANGPTL3	GALNT2	0	0	0.623	0.623
ANGPTL3	APOA5	0.163	0.069	0.865	0.885
APOA5	APOB	0.298	0	0.935	0.986
APOA5	CILP2	0	0	0.447	0.447
APOA5	TRIB1	0	0.070	0.611	0.623
APOA5	MLXIPL	0.062	0	0.522	0.532
APOA5	GALNT2	0	0	0.598	0.598
APOB	CILP2	0.098	0	0.401	0.436
APOB	GALNT2	0.070	0	0.420	0.438
APOB	MLXIPL	0.080	0	0.580	0.597
APOB	TRIB1	0.057	0	0.651	0.656
CEBPA	TRIB2	0.056	0.141	0.545	0.599
CEBPA	EGR1	0.044	0.091	0.450	0.480
CEBPA	FOSL2	0.092	0.102	0.625	0.667
CEBPA	JUNB	0.080	0.094	0.368	0.427
CEBPA	CEBPB	0.153	0.623	0.942	0.990
CEBPA	FOS	0.073	0.275	0.806	0.859
CEBPA	TRIB1	0.081	0.716	0.823	0.949
CEBPA	MLXIPL	0.081	0.061	0.441	0.475
CEBPA	RIBC2	0	0	0.432	0.432
CEBPB	EGR1	0.088	0.535	0.751	0.885
CEBPB	FOSB	0.106	0.102	0.382	0.461
CEBPB	FOSL2	0.221	0.102	0.704	0.775
CEBPB	JUNB	0.316	0.094	0.436	0.620
CEBPB	UBE2E1	0.058	0.073	0.057	0.533
CEBPB	TRIB1	0.196	0.272	0.549	0.713
CEBPB	FOS	0.208	0.102	0.766	0.819
CILP2	MLXIPL	0	0	0.445	0.445
CILP2	TRIB1	0	0	0.580	0.580
CILP2	GALNT2	0.059	0	0.579	0.586
COP1	TRIB2	0	0.787	0.473	0.883
COP1	FOSL2	0.042	0.602	0.056	0.609
COP1	JUNB	0	0.632	0.064	0.641
COP1	UBE2E1	0.062	0.427	0.104	0.477
COP1	FOS	0	0.770	0.056	0.774
COP1	TRIB1	0	0.863	0.425	0.918

COP1	RIBC2	0	0.075	0.714	0.724
COP1	STK40	0.048	0.869	0.226	0.895
COP1	DET1	0	0.873	0.850	0.997
DET1	TRIB2	0	0.695	0.159	0.732
DET1	FOSL2	0	0.561	0.135	0.605
DET1	JUNB	0	0.524	0.063	0.534
DET1	UBE2E1	0	0.796	0.447	0.882
DET1	FOS	0	0.626	0.123	0.658
DET1	TRIB1	0	0.777	0.208	0.815
DET1	STK40	0	0.776	0.212	0.815
EGR1	MAP2K1	0.054	0.075	0.455	0.481
EGR1	FOSL2	0.120	0.436	0.682	0.828
EGR1	TRIB1	0.415	0.091	0.256	0.888
EGR1	JUNB	0.582	0.634	0.657	0.970
EGR1	FOSB	0.798	0.066	0.880	0.987
EGR1	FOS	0.825	0.066	0.951	0.995
FOS	FOSB	0.826	0.359	0.984	0.999
FOS	FOSL2	0.132	0	0.984	0.998
FOS	MAP2K1	0.048	0.095	0.629	0.652
FOS	JUNB	0.809	0.907	0.995	0.999
FOS	TRIB1	0.272	0.363	0.495	0.746
FOS	STK40	0.076	0.801	0.077	0.816
FOSB	STK40	0.055	0.500	0.065	0.520
FOSB	TRIB1	0.263	0.479	0.526	0.802
FOSB	FOSL2	0.176	0	0.984	0.998
FOSB	JUNB	0.659	0.728	0.996	0.999
FOSL2	TRIB1	0.140	0.753	0.165	0.807
FOSL2	STK40	0.103	0.794	0.065	0.812
FOSL2	JUNB	0.224	0.880	0.996	0.999
GALNT2	TRIB1	0	0	0.620	0.620
GALNT2	MLXIPL	0	0	0.447	0.447
JUNB	TRIB1	0.271	0.412	0.123	0.592
JUNB	STK40	0.072	0.742	0.081	0.760
MAP2K1	TRIB2	0.063	0.095	0.557	0.592
MAP2K1	RIBC2	0.086	0.067	0.768	0.784
MAP2K1	TRIB1	0.075	0.331	0.951	0.967
MLXIPL	TRIB1	0	0.292	0.555	0.671
RIBC2	TRIB2	0.055	0.128	0.901	0.922
RIBC2	TRIB1	0.055	0.128	0.929	0.944
RIBC2	STK40	0	0.128	0.489	0.593
STK40	TRIB2	0	0.786	0.156	0.811
STK40	UBE2E1	0.058	0.625	0.041	0.632
STK40	TRIB1	0.058	0.863	0.163	0.882

TRIB1	TRIB2	0	0.786	0.085	0.800
TRIB1	UBE2E1	0.051	0.792	0.041	0.794
TRIB2	UBE2E1	0.051	0.775	0.092	0.789

Tabla 6. Anexo. Interacciones proteína-proteína para la red de regulación funcional de TRIB1. Esta tabla presenta el desglose de las asociaciones funcionales y físicas entre los nodos que conforman el interactoma analizado mediante la base de datos STRING (v12.0). En ella figuran un total de 86 interacciones fundamentadas en diversas fuentes de evidencia bibliográfica, biológica e informática. Las columnas detallan la contribución de la coexpresión de los transcritos en estudios previos, las interacciones determinadas experimentalmente mediante ensayos bioquímicos y el minado de texto derivado del análisis masivo de la literatura científica disponible. La puntuación combinada integra de forma probabilística todas estas fuentes independientes para asignar un grado de confianza a la relación funcional entre cada par de proteínas. Descargada de la página del análisis con opciones por defecto.

8.2 Script

```
##### 0. Carga de Paquetes y Archivo Inicial #####

library(Seurat)
library(glmGamPoi) #Se requiere para Normalización: SCTransform
library(dplyr)
library(ggplot2)
library(patchwork)
library(Azimuth)
library(WGCNA)
library(clusterProfiler)
library(org.Hs.eg.db)

setwd("C:/Users/ASUS/Desktop/aticulos y datos tfm/single cell")
load("C:/Users/ASUS/Desktop/aticulos y datos tfm/single cell/HumanLiver.RData")

##### 1. Preparación y Actualización del Objeto #####

# Actualizar formato antiguo de Seurat a la versión actual
HumanLiverSeurat <- UpdateSeuratObject(HumanLiverSeurat)
#Eliminar objeto con el que no vamos a trabajar
remove(sCVdL)

##### 2. QC: Métricas Básicas y Detección de Genes Mitocondriales #####
# Definición de métricas:
# total_features: Nº de genes únicos detectados. Indica la diversidad transcriptómica.
# total_counts: Nº total de moléculas (UMIs). Indica la profundidad de secuenciación.
# percent.mt: Porcentaje de lecturas que mapean al genoma mitocondrial (indicador de estr
és/muerte celular).

# Se intenta detectar genes mitocondriales por prefijo "MT-" y se calcula el %.
mt_genes <- grep("^MT-", rownames(HumanLiverSeurat), value = TRUE)

percent_mt <- colSums(
  GetAssayData(HumanLiverSeurat, layer="counts")[mt_genes, ]
) / colSums(GetAssayData(HumanLiverSeurat, layer="counts")) * 100

HumanLiverSeurat$percent.mt <- percent_mt

summary(HumanLiverSeurat$percent.mt)

##### 3. Visualización QC con ggplot2 (inspección antes de filtrar) #####
qc_df <- HumanLiverSeurat@meta.data %>%
  dplyr::select(total_features, total_counts, percent.mt) %>%
  tibble::rownames_to_column(var = "cell")

p_vln_nf <- ggplot(qc_df, aes(x = 1, y = total_features)) +
  geom_violin(fill="lightblue") + geom_boxplot(width=0.08) +
  labs(x="", y="Nº total de moléculas (UMIs) por célula") + theme_minimal() + theme(axis.
text.x = element_blank())

p_vln_nc <- ggplot(qc_df, aes(x = 1, y = total_counts)) +
  geom_violin(fill="lightgreen") + geom_boxplot(width=0.08) +
  labs(x="", y="Nº de genes únicos por célula") + theme_minimal() + theme(axis.text.x = e
lement_blank())

p_vln_mt <- ggplot(qc_df, aes(x = 1, y = percent_mt)) +
```

```
  geom_violin(fill="lightpink") + geom_boxplot(width=0.08) +
  labs(x="", y="Porcentaje de genes mitocondriales") + theme_minimal() + theme(axis.text.
x = element_blank())

p_vln_nf + p_vln_nc + p_vln_mt

p_scatter <- ggplot(qc_df, aes(x = total_counts, y = total_features)) +
  geom_point(size=0.5, alpha=0.4) + theme_minimal() +
  labs(x="Nº total de moléculas (UMIs) por célula", y="Nº de genes únicos por célula")
print(p_scatter)

##### 4. Filtrado Inicial #####
# Por qué estos cutoffs:
# - nFeature_RNA > 200: elimina barcodes vacíos.
# - nFeature_RNA < 5000: umbral upper para eliminar posibles dobletes.
# Referencias: Luecken & Theis 2019; 10x Genomics guidelines
min_genes <- 200
max_genes <- 5000
max_mt <- 35

HumanLiver <- subset(HumanLiverSeurat,
                     subset = total_features > min_genes &
                       total_features < max_genes &
                       percent.mt < max_mt)

cat("Células antes del filtrado:", ncol(HumanLiverSeurat), "\n") #8444
cat("Células después del filtrado:", ncol(HumanLiver), "\n") #7947
cat("Células eliminadas por alta mitocondria/dobletes:", ncol(HumanLiverSeurat) - ncol(Hu
manLiver), "\n")#497


#Cálculo de las métricas de control de calidad
meta <- HumanLiverSeurat@meta.data

qc_table <- meta %>%
  mutate( #Se definen los flitros
    pass_genes = total_features > 200 & total_features < 5000,
    pass_mt = percent.mt < 35
  ) %>%
  group_by(Muestra_extraida_barcode) %>%
  summarise( #Se calcula el nº de células iniciales y las que pasan los filtros
    Celulas_iniciales = n(),
    Tras_filtro_genes = sum(pass_genes),
    Tras_filtro_mitocondrial = sum(pass_genes & pass_mt)
  ) %>%
  mutate( #Cálculo de porcentajes
    Celulas_eliminadas = Celulas_iniciales - Tras_filtro_mitocondrial,
    Porcentaje_retencion = round(
      100 * Tras_filtro_mitocondrial / Celulas_iniciales, 2
    ),
    Perdida_por_genes = round(
      100 * (Celulas_iniciales - Tras_filtro_genes) / Celulas_iniciales, 2
    ),
    Perdida_por_mitocondrial = round(
      100 * (Tras_filtro_genes - Tras_filtro_mitocondrial) / Tras_filtro_genes, 2
    ))

write.csv(qc_table, "QC_por_muestra_HumanLiver.csv", row.names = FALSE)
```

```
##### 5. Normalización: SCTransform #####
# Por qué: SCTransform modela la variación técnica y produce datos normalizados más robus
tos
# especialmente en tejidos heterogéneos y cuando hay diferencias de profundidad entre mue
stras.
# Recomendado para análisis downstream (PCA, clustering, integración).
HumanLiver <- SCTransform(HumanLiver,
                          vars.to.regress = "percent.mt", # Se regresa el efecto mitocond
rial
                          verbose = TRUE) #requiere glmGamPoi

##### 6. PCA, Vecinos, Clustering y UMAP #####
HumanLiver <- RunPCA(HumanLiver, verbose = FALSE)
p <- ElbowPlot(HumanLiver)  # inspeccionar para elegir componentes principales
p + labs(
  x = "Componente principal",
  y = "Desviación estándar"
)

# Seleccionado el "codo" en 20 componentes pero se puede ser mas restringente, hasta 15
dims_use <- 1:20

HumanLiver <- FindNeighbors(HumanLiver, dims = dims_use)
HumanLiver <- FindClusters(HumanLiver, resolution = 0.6)  # ajustar resolución según gran
ularidad deseada, 0.6 es un buen estándar
HumanLiver <- RunUMAP(HumanLiver, dims = dims_use)

# Se extrae información UMAP para ggplot2
umap_df <- as.data.frame(Embeddings(HumanLiver, "umap"))
umap_df$cell <- rownames(umap_df)
umap_df$cluster <- Idents(HumanLiver)

p_umap_clusters <- ggplot(umap_df, aes(x = umap_1, y = umap_2, color = cluster)) +
  geom_point(size=0.6, alpha=0.85) + theme_minimal() + labs(color = "Cluster") +
  ggtitle("UMAP - Clusters con SCTransform")
print(p_umap_clusters)

HumanLiverSeurat <- FindVariableFeatures(
  HumanLiverSeurat,
  selection.method = "vst",
  nfeatures = 2000
)

# Los 10 más variables:
top10 <- head(VariableFeatures(HumanLiverSeurat), 10)
top10

##### 7. Anotación de Tipos Celulares con Azimuth #####
# Objetivo: Asignar automáticamente el tipo celular a cada clúster basándonos en un atlas
 de referencia validado. Esto evita el sesgo de la anotación manual.

liver_ref <- "C:/Users/ASUS/Desktop/aticulos y datos tfm/single cell/liver_ref"

HumanLiver <- RunAzimuth(query = HumanLiver, reference = liver_ref)
HumanLiver$predicted.celltype.l2 <- gsub("Vascual", "Vascular", HumanLiver$predicted.cell
type.l2) #Corrección falta de ortografía
```

```
# Se visualiza la predicción en el UMAP
p_azimuth <- DimPlot(HumanLiver,
                     group.by = "predicted.celltype.l2",
                     label = TRUE,
                     label.size = 5,
                     repel = TRUE,
                     pt.size = 0.6) +
  ggtitle("Anotación de Tipos Celulares del Hígado Humano") +
  theme(
    plot.title = element_text(face = "bold", size = 14),
    legend.position = "right",
    legend.text = element_text(size = 8),
    legend.title = element_text(size = 8),
    legend.key.size = unit(0.4, "cm"),
    plot.margin = margin(5, 5, 5, 5) # Eliminamos el margen derecho para que el plot se e
xpanda
  )
print(p_azimuth)

# Calcular la mediana del score de predicción POR CLÚSTER
scores_por_cluster <- tapply(HumanLiver$predicted.celltype.l2.score,
                             HumanLiver$predicted.celltype.l2,
                             median, na.rm = TRUE)

# Se genera una tabla (tipo celular, nº de células por tipo y %)
df_celulas <- data.frame(
  Tipo_Celular = names(freq_table),
  Numero_Celulas = as.numeric(freq_table),
  Porcentaje = round(as.numeric(prop_table), 2),
  Score_Prediccion = round(as.numeric(scores_por_cluster[names(freq_table)]), 3)
)

# Ordenar de mayor a menor porcentaje
df_celulas <- df_celulas[order(-df_celulas$Porcentaje), ]

# Se guarda  la tabla
write.csv(df_celulas, "Tabla_Anotacion_Azimuth.csv", row.names = FALSE)

# Confianza de la predicción
# Se calcula la mediana del score de predicción global
median_score <- median(HumanLiver$predicted.celltype.l2.score, na.rm = TRUE)
cat("La mediana de la puntuación de predicción es:", median_score, "\n")

##### 8. Perfil de Expresión de TRIB1 #####

# Se usan las etiquetas corregidas que creamos antes
Idents(HumanLiver) <- "predicted.celltype.l2"


# Se genera el FeaturePlot
p_trib1_umap <- FeaturePlot(HumanLiver,
                            features = "TRIB1",
                            order = TRUE,
                            pt.size = 0.8,
                            label = FALSE) + # Quitamos el label por defecto para control
arlo nosotros
  scale_color_viridis_c(option = "magma", name = "Expresión (SCT)") +
  theme_minimal() +
  theme(
```

```
    plot.title = element_text(face = "bold", size = 14),
    legend.position = "right",
    panel.grid = element_blank()
  ) +
  ggtitle("Localización celular de TRIB1")

print(p_trib1_umap)

# Se genera el ViolinPlot
# Se calcula la expresión media para poner las etiquetas
datos_plot <- FetchData(HumanLiver, vars = c("TRIB1", "predicted.celltype.l2"))

# Se crea el gráfico manualmente con ggplot2
p_trib1_vln <- ggplot(datos_plot, aes(x = predicted.celltype.l2, y = TRIB1, fill = predic
ted.celltype.l2)) +
  geom_violin(scale = "width", adjust = 1.5, trim = TRUE, color = "black") +
  geom_boxplot(width = 0.1, fill = "white", outlier.shape = NA, alpha = 0.5) +
  theme_classic() +
  theme(
    legend.position = "none",
    axis.text.x = element_text(angle = 45, hjust = 1, size = 10, color = "black"),
    axis.title.x = element_blank()
  ) +
  ylab("Expresión (SCT log1p)") +
  ggtitle("Distribución de TRIB1 (Densidad de Expresión)")
print(p_trib1_vln)

# Esta función calcula qué % de cada cluster tiene expresión > 0 de TRIB1
pct_expresion <- function(seurat_obj, gen) {
  counts <- GetAssayData(seurat_obj, assay = "SCT", layer = "data")[gen, ]
  pct <- tapply(counts > 0, Idents(seurat_obj), mean) * 100
  return(sort(pct, decreasing = TRUE))


tabla_pct <- pct_expresion(HumanLiver, "TRIB1")
write.csv(tabla_pct, file = "Porcentaje de células expresando TRIB1 por tipo celular.csv"
)

###Estadísticas de TRIB1

# 1. Se extraen los datos de expresión de TRIB1 y el tipo celular
data_trib1 <- FetchData(HumanLiver, vars = c("TRIB1", "predicted.celltype.l2"))

# 2. Se calculan las estadísticas por grupo
stats_trib1 <- data_trib1 %>%
  group_by(predicted.celltype.l2) %>%
  summarise(
    # Porcentaje de células que expresan el gen (>0)
    Porcentaje_Expresion = round(sum(TRIB1 > 0) / n() * 100, 2),

    # Valor Máximo de expresión detectado en ese grupo
    Maxima_Intensidad = round(max(TRIB1), 2),

    # Promedio de expresión (solo considerando las células que lo expresan)
    Promedio_Expresion = round(mean(TRIB1[TRIB1 > 0]), 2)
  ) %>%
  arrange(desc(Porcentaje_Expresion)) # Ordenar por mayor % de expresión
```

```
print(stats_trib1)

write.csv(stats_trib1, "Estadisticas_TRIB1_por_Cluster.csv", row.names = FALSE)

##### 9. Análisis de Co-expresión con WGCNA #####

# 1. Preparación de los datos
# WGCNA requiere una matriz con Genes en columnas y Muestras (células) en filas.
# Se usan los datos normalizados de SCTransform.

# Seleccionamos los genes variables (top 2000) para reducir ruido y coste computacional
genes_variables <- VariableFeatures(HumanLiver, nfeatures = 2000)

# ¡CRUCIAL! Para asegurarnos de que TRIB1 esté incluido, aunque no sea variable
# Se adiciona manualmente a la tabla
gen_interes <- "TRIB1"
if(!(gen_interes %in% genes_variables)){
  genes_variables <- c(genes_variables, gen_interes)
}

# Se extrae la matriz de expresión (SCT data) transpuesta
datExpr <- t(as.matrix(GetAssayData(HumanLiver, assay = "SCT", layer = "data")[genes_vari
ables, ]))

# Comprobación de calidad para WGCNA (eliminar genes/células con demasiados ceros)
gsg <- goodSamplesGenes(datExpr, verbose = 3)
if (!gsg$allOK) {
  datExpr <- datExpr[gsg$goodSamples, gsg$goodGenes]
}

# 2. Selección de la Potencia (Soft Thresholding Power)
# WGCNA construye una red "libre de escala". Se necesita encontrar el beta (power) adecua
do.
powers <- c(c(1:10), seq(from = 12, to = 20, by = 2))

sft <- pickSoftThreshold(datExpr, powerVector = powers, verbose = 5, networkType = "signe
d")

# Visualización para elegir la potencia
par(mfrow = c(1, 2))
plot(sft$fitIndices[,1], -sign(sft$fitIndices[,3])*sft$fitIndices[,2],
     xlab="Soft Threshold (power)",ylab="Scale Free Topology Model Fit,signed R^2",type="
n", main = "Scale independence")
text(sft$fitIndices[,1], -sign(sft$fitIndices[,3])*sft$fitIndices[,2],
     labels=powers,cex=0.9,col="red")
abline(h=0.80,col="red") # Buscamos el primer valor que supere 0.8 o 0.9

# POTENCIA SELECIONADA: 7

# 3. Construcción de la red y detección de módulos
# blockwiseModules es la función "todo en uno" eficiente para grandes datos.

cor <- WGCNA::cor # Especificamos de que paquete ha de provenir la función para que no dé
 error
net <- blockwiseModules(datExpr, power = 7,
                        TOMType = "signed",
                        minModuleSize = 30,      # Mínimo de genes por módulo
                        reassignThreshold = 0,
```

```
                        mergeCutHeight = 0.25,   # Unir módulos muy similares (0.25 = 75%
 correlación)
                        numericLabels = TRUE,
                        pamRespectsDendro = FALSE,
                        saveTOMs = FALSE,
                        verbose = 3)

# 3.1 Visualización del Dendrograma de Módulos
# Esta imagen muestra cómo se agruparon los genes y los colores asignados
moduleColors <- labels2colors(net$colors)

plotDendroAndColors(net$dendrograms[[1]], moduleColors[net$blockGenes[[1]]],
                    "Módulos dinámicos",
                    dendroLabels = FALSE, hang = 0.03,
                    addGuide = TRUE, guideHang = 0.05,
                    main = "Dendrograma de Clusters Génicos y Módulos")

# 4. Se relaciona TRIB1 con los módulos
moduleColors <- labels2colors(net$colors)
genes_en_analisis <- colnames(datExpr)

# Se identifica en qué módulo está TRIB1
modulo_TRIB1_color <- moduleColors[which(genes_en_analisis == "TRIB1")]
cat("El gen TRIB1 pertenece al módulo color:", modulo_TRIB1_color, "\n")

# 5. Se extraen genes del mismo módulo (Co-expresados)
genes_del_modulo <- genes_en_analisis[moduleColors == modulo_TRIB1_color]
cat("Hay", length(genes_del_modulo), "genes en el mismo módulo que TRIB1.\n")

### Cálculo de la "Membresía al Módulo" (kME)
# Esto nos dice como de fuerte es la conexión de cada gen con su módulo.
MEs <- moduleEigengenes(datExpr, colors = moduleColors)$eigengenes
geneModuleMembership <- as.data.frame(cor(datExpr, MEs, use = "p"))

# Se filtran los top 50 genes con mayor correlación dentro del módulo de TRIB1
columna_modulo <- paste0("ME", modulo_TRIB1_color)
top_genes_df <- geneModuleMembership %>%
  arrange(desc(!!sym(columna_modulo))) %>% # Ordenar por correlación
  head(50)

top_genes_names <- rownames(top_genes_df)

# Se crea un data frame con los nombres de los genes y su color
genes_y_colores <- data.frame(
  Gene = colnames(datExpr),
  Color = moduleColors
)

# Se guarda la lista para posterior revisión
write.csv(genes_y_colores, "Listado_Completo_Genes_Modulos.csv", row.names = FALSE)


#Tabla con los genes que incluye el módulo de TRIB1
# 1. Calcular p-valores de la membresía (Student Asymptotic p-value)
n_celulas <- nrow(datExpr)
geneModulePvalue <- as.data.frame(corPvalueStudent(as.matrix(geneModuleMembership), n_cel
ulas))
```

```r
# 2. Definir el nombre de la columna del módulo de interés
col_kme <- paste0("ME", modulo_TRIB1_color)

# 3. Ensamblar la Tabla 3 con los datos de conectividad y p-valor
genes_modulo_TRIB1_wgcna <- data.frame(
  Gene = genes_del_modulo,
  kME_Score = geneModuleMembership[genes_del_modulo, col_kme],
  p_value = geneModulePvalue[genes_del_modulo, col_kme]
) %>%
  dplyr::arrange(dplyr::desc(kME_Score))

# Guardar la tabla
write.csv(genes_modulo_TRIB1_wgcna, "Modulo_Completo_TRIB1_kME.csv", row.names = FALSE)


# 6. Visualización de Heatmap de los top 50 genes co-expresados
# Se escalan los datos para el heatmap

p_heatmap <- DoHeatmap(
  HumanLiver,
  features = top_genes_names,
  group.by = "predicted.celltype.l2",
  size = 5,         # Tamaño de letra de los genes
  label = FALSE     # Mantiene limpio el espacio superior
) +
  # CONFIGURACIÓN DE LEYENDAS
  guides(
    # Expresión (fill): order = 1 para que aparezca ARRIBA
    fill = guide_colorbar(title = "Expresión", order = 1),

    # Tipo celular (color): order = 2 para que aparezca DEBAJO
    color = guide_legend(
      title = "Tipo celular",
      order = 2,
      override.aes = list(shape = 15, size = 3, alpha = 1) # Cuadros de color en la leyen
da
    )
  ) +
  theme(

    axis.text.y = element_text(size = 8, face = "bold"), # Ajuste de los nombres de los g
enes
    plot.title = element_text(size = 14, face = "bold", hjust = 0.5)
  ) +
  ggtitle("Módulos WGCNA: Coexpresión con TRIB1")

print(p_heatmap)

ggsave(
  filename = "Heatmap_coexpresión_TRIB1.pdf",
  plot = p_heatmap,
  device = "pdf",
  width = 15,    # Ancho extra para que quepan las leyendas a la derecha
  height = 12,   # Altura extra para que los genes no se pisen
  units = "in",
  limitsize = FALSE
)
```

```
##### 10. Análisis de Enriquecimiento (GO) #####

# 1. Convertir los nombres de genes a IDs de Entrez (necesario para clusterProfiler)
# Se usa la lista 'genes_del_modulo'

genes_entrez <- bitr(genes_del_modulo,
                     fromType = "SYMBOL",
                     toType = "ENTREZID",
                     OrgDb = org.Hs.eg.db)

# 2. Ejecutar el enriquecimiento de Gene Ontology (Biological Process)
GO_analysis <- enrichGO(gene          = genes_entrez$ENTREZID,
                OrgDb         = org.Hs.eg.db,
                ont           = "BP",        # Biological Process
                pAdjustMethod = "BH",        # Benjamini-Hochberg para corregir p-valores
                pvalueCutoff  = 0.05,
                qvalueCutoff  = 0.2,
                readable      = TRUE)        # Para que los resultados muestren nombres d
e genes

# 3. Visualización: Dotplot
# El tamaño del punto es el número de genes y el color es la significancia
p_dotplot <- dotplot(GO_analysis, showCategory=15) +
  ggtitle("Enriquecimiento Funcional - Módulo TRIB1") +
  theme_minimal() +
  theme(axis.text.y = element_text(size = 8, face = "bold"))

print(p_dotplot)

ggsave(filename = "Enriquecimiento_funcional_modulo_TRIB1.pdf", plot = p_dotplot)

# 4. Se guardan los resultados en un archivo
write.csv(as.data.frame(GO_analysis), file = paste0("Enriquecimiento_GO_Modulo_", modulo_
TRIB1_color, ".csv"))
```