Universidad Internacional de Valencia

Análisis del microbioma del oso polar (*Ursus maritimus*) mediante DNA *metabarcoding* en el contexto de su estado de conservación

Titulación:
Máster Universitario en Bioinformática

Curso académico: 2025 – 2026

Alumna: González Castellano, Inés

DNI: 79345327L

Directora de TFM: Lairón Peris, María

Convocatoria:
Primera

Marzo 2026

De:
Planeta Formación y Universidades

ÍNDICE

1. INTRODUCCIÓN 6
2. OBJETIVOS 12
3. METODOLOGÍA 13
3.1. Procedencia de los datos 13
3.2. Recursos informáticos y flujo de trabajo 14
3.3. Obtención y preparación de los datos 15
3.4. Control de calidad de las lecturas crudas 16
3.5. Importación de los datos en QIIME 2 y *denoising* 16
3.6. Asignación taxonómica 18
3.7. Filtrados de ASVs y muestras 19
3.8. Representación de las abundancias relativas 20
3.9. Análisis de alfa y beta diversidad 21
4. RESULTADOS 23
4.1. Control de calidad de las lecturas crudas 23
4.2. Importación de los datos en QIIME 2 y *denoising* 25
4.3. Asignación taxonómica 26
4.4. Filtrados de ASVs y muestras 27
4.5. Representación de las abundancias relativas 29
4.6. Análisis de alfa y beta diversidad 30
5. DISCUSIÓN 34
6. CONCLUSIONES 46
7. REFERENCIAS BIBLIOGRÁFICAS 47

LISTA DE ABREVIATURAS

16S	Gen del RNA ribosomal 16S
18S	Gen del RNA ribosomal 18S
ASV	Secuencia variante de amplicón (*Amplicon Sequence Variant*)
COI	Citocromo c oxidasa subunidad I
DADA2	*Divisive Amplicon Denoising Algorithm 2*
DNA	Ácido desoxirribonucleico (*Deoxyribonucleic Acid*)
eDNA	DNA ambiental (*environmental DNA*)
EG	Población del este de Groenlandia (*East Greenland*)
EMBL-EBI	*European Molecular Biology Laboratory – European Bioinformatics Institute*
EMP	*Earth Microbiome Project*
ENA	*European Nucleotide Archive*
FDR	Tasa de falsos positivos (*False Discovery Rate*)
ITS	Región espaciadora transcrita interna (*Internal Transcribed Spacer*)
IUCN	Unión Internacional para la Conservación de la Naturaleza (*International Union for Conservation of Nature*)
kb	Kilobases
matK	Maturasa K
NCBI	*National Center for Biotechnology Information*
NMDS	Escalamiento multidimensional no métrico (*Non-metric Multidimensional Scaling*)
ONT	*Oxford Nanopore Technologies*
OTU	Unidad taxonómica operativa (*Operational Taxonomic Unit*)
PacBio	*Pacific Biosciences*
pb	Par de bases
PCR	Reacción en cadena de la polimerasa (*Polymerase Chain Reaction*)
PE250	Lecturas *paired-end* de 250 pb
PE300	Lecturas *paired-end* de 300 pb
PERMANOVA	Análisis de varianza multivariante por permutación (*Permutational Multivariate Analysis of Variance*)
PERMDISP	Análisis de dispersión multivariante por permutación (*Permutational Analysis of Multivariate Dispersions*)

Q	Calidad de la base (*Phred score*)
R1 / R2	Lectura *forward* (R1) / *reverse* (R2) de secuenciación *paired-end*
rbcL	Ribulosa-1,5-bisfosfato carboxilasa/oxigenasa, subunidad grande
RESCRIPt	*REference Sequence annotation and CuRatIon Pipeline*
RNA	Ácido ribonucleico (*Ribonucleic Acid*)
rRNA	RNA ribosomal (*ribosomal RNA*)
SBS	Población del sur del mar de Beaufort (*Southern Beaufort Sea*)
SRA	*Sequence Read Archive*
SSU	Subunidad pequeña del ribosoma (*Small Subunit*)
V3-V4	Regiones V3 y V4 del gen 16S rRNA

ÍNDICE DE FIGURAS

Figura 1. Ubicación geográfica de las 19 poblaciones de oso polar (*Ursus maritimus*) y su distribución en las distintas ecorregiones circumpolares del Ártico 13
Figura 2. Esquema del *pipeline* bioinformático de DNA *metabarcoding* desarrollado 15
Figura 3. Gráfica de MultiQC que muestra la calidad media Q (*Phred Score*) de las lecturas crudas por posición (pb) para cada muestra 24
Figura 4. Distribución de tamaños de los amplicones recuperados tras el solapamiento de las lecturas crudas R1 y R2 mediante FLASH2 25
Figura 5. Curvas de rarefacción de las 93 muestras tras los filtrados de ASVs 28
Figura 6. Diagrama de barras apilado (*barplot*) de abundancia relativa en el nivel taxonómico de clase de las 90 muestras tras los filtrados de ASVs y muestras 30
Figura 7. Diagrama de cajas (*boxplot*) de la distribución de la diversidad alfa en las poblaciones de Greenland y Alaska 32
Figura 8. Representación *Non-metric Multidimensional Scaling* (NMDS) de la matriz de distancias de Bray–Curtis entre las muestras de las poblaciones de Greenland y Alaska 33

ÍNDICE DE TABLAS

Tabla 1. Número de ASVs inferidos con DADA2 y su asignación taxonómica contra la base de datos SSU Ref NR99 de SILVA. 27
Tabla 2. Distribución de los ASVs retenidos tras los filtrados de ASVs y muestras en los distintos niveles taxonómicos, mostrando el número de ASVs asignados y el número de taxones detectados, compartidos o exclusivos de cada población. 29
Tabla 3. Recuento de ASVs inferidos con DADA2 y de muestras retenidas tras los filtrados de ASVs por abundancia y taxonomía, el filtrado de muestras por rarefacción, y la normalización al menor número de lecturas por muestra. 31
Tabla 4. Diversidad alfa (media ± SD) de las poblaciones de Greenland y Alaska estimada mediante los índices Shannon (*H'*), Chao1 y Simpson (1–*D*). 31

RESUMEN

El microbioma intestinal es clave para la salud animal, pero su estudio en fauna silvestre es aún muy limitado, a pesar de ser especialmente relevante en especies amenazadas, donde permite evaluar cómo distintas perturbaciones antropogénicas pueden alterarlo y afectar a la salud, eficacia biológica y supervivencia de las poblaciones. En este trabajo se desarrolló un *pipeline* bioinformático completo de DNA *metabarcoding*. Como caso de estudio, se emplearon datos del microbioma de oso polar (*Ursus maritimus*), una especie amenazada por el cambio climático.

Se analizaron lecturas *paired-end* Illumina MiSeq de muestras fecales de dos poblaciones expuestas a distintas condiciones ambientales: Groenlandia, con hielo marino anual, y Alaska, con deshielo estacional, donde la dieta de los osos se ha modificado por el retroceso del hielo. El *pipeline* se implementó en un único *script* de R Markdown, permitiendo su ejecución automática e integrando el control de calidad de las lecturas, la inferencia de ASVs, la asignación taxonómica contra una base de datos de referencia, así como análisis de rarefacción y de diversidad alfa y beta, e incluyendo visualizaciones interactivas.

Se observó una tendencia hacia una mayor diversidad del microbioma en Alaska, aunque sin diferencias estadísticamente significativas. Sin embargo, se detectaron pequeñas diferencias composicionales significativas entre las poblaciones, lo que sugiere que los cambios dietarios derivados de la degradación del hábitat podrían estar influyendo en el microbioma de los osos de Alaska, con posibles consecuencias negativas. Estos resultados coinciden con el estudio original a pesar de notables diferencias metodológicas, lo que valida el *pipeline* desarrollado *de novo*.

Por lo tanto, se aporta un recurso bioinformático reproducible y flexible para el análisis de nuevos datos, poniendo de manifiesto el potencial del microbioma como indicador del estado de conservación en especies amenazadas.

Palabras clave: microbiota, gen 16S rRNA, *pipeline*, ASV, base de datos, diversidad

1. INTRODUCCIÓN

La microbiota se define como la comunidad de microorganismos vivos que habita un determinado ambiente, incluyendo bacterias, arqueas y eucariotas microbianos como hongos y protozoos. Frecuentemente, los términos microbiota y microbioma se utilizan indistintamente, a pesar de que ambos conceptos no son equivalentes. El microbioma hace referencia al conjunto de genomas de todos los microorganismos presentes en un ambiente, así como a sus elementos estructurales y metabolitos, y a las condiciones ambientales circundantes [1-3].

Los animales se consideran huéspedes de consorcios microbianos que residen sobre y dentro de sus organismos. La mayor abundancia y diversidad microbiana se localiza en el tracto digestivo, constituyendo el denominado microbioma intestinal [3]. Numerosos estudios, tanto en humanos como en otros vertebrados, han demostrado que el microbioma intestinal juega un papel central en múltiples procesos que afectan a la salud y a la eficacia biológica (*fitness*) del hospedador, incluyendo la nutrición, digestión, metabolismo, inmunidad, crecimiento, desarrollo, comportamiento o reproducción [4,5].

La composición del microbioma intestinal (en adelante, microbioma) está fuertemente influenciada por factores como la dieta del huésped, su estado reproductivo, sexo e historia evolutiva, y las condiciones ambientales externas. En consecuencia, como todo microbioma, se trata de un sistema dinámico que puede experimentar cambios tanto temporales dentro de los individuos como espaciales entre poblaciones de una misma especie [1,5]. Esta naturaleza dinámica del microbioma puede aumentar el potencial adaptativo de los individuos. No obstante, la estrecha relación entre el microbioma intestinal y la fisiología y salud del hospedador implica que alteraciones en su equilibrio, lo que se conoce como disbiosis, puedan causar o favorecer el desarrollo o progresión de diferentes patologías [3,4]. De hecho, la disbiosis se ha asociado con numerosas enfermedades humanas, lo que ha llevado a que la investigación sobre el microbioma se focalice principalmente en humanos. En contraste, existen relativamente pocos trabajos en vertebrados no humanos y, dentro de estos, la investigación se ha centrado principalmente en animales modelo, de laboratorio o domésticos. Por ello, la información disponible sobre el microbioma de la fauna silvestre o salvaje (*wildlife*) es especialmente limitada, a pesar de su relevancia, particularmente en la conservación de especies amenazadas [4,6,7].

La biología de la conservación tiene como principal objetivo comprender y mitigar los efectos nocivos de las actividades humanas sobre la biodiversidad del medio natural, así como desarrollar estrategias de gestión destinadas a preservarla [8]. En este sentido, las actividades antropogénicas, como los cambios en el uso del suelo, la fragmentación y degradación de los hábitats, la contaminación o, en última instancia, el cambio climático, amenazan directamente a las poblaciones silvestres de más de 46000 especies según la Unión Internacional para la Conservación de la Naturaleza (*International Union for Conservation of Nature*, IUCN) [9]. Estas perturbaciones no solo comprometen la supervivencia de dichas especies, sino que también tienen un impacto directo sobre su microbioma [5,7,10], especialmente cuando la degradación del ecosistema conlleva cambios en la composición y calidad de la dieta, lo que repercute en la salud animal y en su capacidad de respuesta frente a cambios ambientales [5,11]. La acelerada pérdida de biodiversidad que está experimentando el planeta ha puesto de manifiesto la importancia de caracterizar y monitorizar el microbioma de las poblaciones silvestres amenazadas, a fin de evaluar su estado de conservación y promover políticas de conservación eficaces [12].

Durante gran parte del siglo XX, la identificación de los microorganismos presentes en una muestra se basaba exclusivamente en técnicas estándar de cultivo microbiológico. Sin embargo, solo el 1% de las bacterias son cultivables bajo unas condiciones específicas [13], por lo que la inmensa mayoría de la diversidad microbiana no puede ser detectada mediante estos métodos. A finales del siglo pasado, se desarrollaron aproximaciones basadas en el ácido desoxirribonucleico (DNA, por sus siglas en inglés), siendo la más exitosa el DNA *barcoding* [14]. Esta técnica consiste en la amplificación por reacción en cadena de la polimerasa (PCR) y secuenciación Sanger de un gen marcador (DNA *barcode*) para determinar la identidad taxonómica y la diversidad biológica [15,16]. Posteriormente, con el desarrollo de las plataformas de secuenciación masiva surgió el DNA *metabarcoding*, que combina el DNA *barcoding*, la secuenciación de alto rendimiento (*high-throughput sequencing*) y el análisis bioinformático. Esta técnica permite la identificación taxonómica simultánea de múltiples especies presentes en una muestra [17-20]. En la actualidad, el DNA *metabarcoding* es la metodología más extendida para el análisis de la diversidad de muestras complejas (*bulk DNA metabarcoding*) o ambientales (*environmental DNA metabarcoding*, eDNA), incluyendo los estudios de microbioma [21,22]. Concretamente, la estrategia más habitual para describir el microbioma intestinal de la fauna silvestre es aplicar

DNA *metabarcoding* a muestras fecales, ya permite un enfoque no invasivo para estudiar las poblaciones de interés.

Brevemente, la fase experimental del DNA *metabarcoding* consiste en la extracción del DNA total de una muestra, la amplificación de una región *barcode* taxonómicamente informativa y la posterior secuenciación de los amplicones resultantes en un secuenciador de alto rendimiento para obtener de miles a millones de lecturas, un flujo de trabajo que se conoce como *amplicon sequencing*. A partir de las lecturas obtenidas, se aplica un *pipeline* bioinformático para determinar y estudiar el perfil taxonómico de la muestra [18,23,24]. Dentro de este *workflow*, existen varios puntos clave.

En primer lugar, los *primers* seleccionados deben ser universales para el grupo taxonómico a analizar, de modo que permitan amplificar el DNA de todos los organismos pertenecientes a dicho grupo que estén presentes en una muestra. Para ello, deben hibridar en regiones conservadas que flanqueen la región *barcode* variable [22]. Estos genes marcadores son diferentes en función del grupo taxonómico, siendo los más comunes el gen del RNA ribosomal 16S (ácido ribonucleico, RNA por sus siglas en inglés; y RNA ribosomal, rRNA) para bacterias y arqueas, el gen citocromo c oxidasa subunidad I (COI) para metazoos, la región espaciadora transcrita interna (*internal transcribed spacer*, ITS) para hongos, y los genes rbcL (ribulosa-1,5-bisfosfato carboxilasa/oxigenasa, subunidad grande) o matK (maturasa K) para plantas [21,25].

En el análisis de microbioma, el gen del RNA ribosómico 16S (16S rRNA, o solo 16S) se considera el marcador universal para procariotas al estar presente en todos los genomas bacterianos y arqueanos [14,26]. Este gen tiene una longitud aproximada de 1500 pares de bases (pb) y está organizado en nueve regiones hipervariables (V1–V9), que son las regiones *barcode*, intercaladas entre ocho regiones conservadas en las que se diseñan los *primers* universales [4,20,25]. Existen diferentes parejas de *primers* que amplifican una o varias regiones variables. La elección de los *primers* y de la región variable es un paso crítico del diseño experimental, ya que puede introducir sesgos en la detección y en la estimación de la abundancia relativa de los taxones, por lo que deben seleccionarse en función del tipo de microbioma y del dominio o grupo taxonómico diana [23,24]. En este sentido, la región V3-V4 es la que ha mostrado mayor resolución taxonómica a nivel de género y especie [4], siendo además la región utilizada en el *Earth Microbiome Project* (EMP, https://earthmicrobiome.ucsd.edu/). Este proyecto colaborativo tiene como objetivo

caracterizar la vida microbiana del planeta y proporciona protocolos de laboratorio y bioinformáticos estandarizados [27].

En lo que respecta a la etapa de secuenciación, la aproximación más extendida en DNA *metabarcoding* es la secuenciación de lecturas cortas (*short-reads*). Tras quedar obsoletas tecnologías como la secuenciación 454 de Roche o los sistemas Ion Torrent, las plataformas de Illumina dominan este tipo de secuenciación y son las más utilizadas [28]. Esta hegemonía se debe a su alto rendimiento de secuenciación, su baja tasa de error (~0.01% por lectura) y a un coste cada vez más asequible. Así, es posible (y recomendable) la secuenciación paralela de todas las muestras de un estudio en un único *run,* mediante la asignación de diferentes índices discriminatorios (multiplexado), lo que reduce significativamente el coste de secuenciación por muestra. Dentro de las plataformas Illumina, los equipos MiSeq y NovaSeq son los más utilizados para la secuenciación de amplicones de DNA *metabarcoding* al permitir generar lecturas *paired-end* de hasta 2 × 300 pb (PE300) y 2 × 250 pb (PE250), respectivamente. Ambas plataformas ofrecen una resolución taxonómica similar, radicando la principal diferencia entre ellas en la profundidad de secuenciación, considerablemente mayor en NovaSeq [22,29,30]. Con todo, la principal limitación de las lecturas cortas de Illumina es que solo permiten recuperar amplicones pequeños que en ocasiones pueden no ser suficientes para obtener resolución a nivel de especie. Las tecnologías de secuenciación de lecturas largas (*long-reads*), como Oxford Nanopore Technlogies (ONT) y Pacific Biosciences (PacBio), tienen el potencial de aumentar la resolución filogenética al permitir la secuenciación de fragmentos de hasta 10 kilobases (kb), incluyendo el gen 16S rRNA completo. Sin embargo, estas tecnologías presentan una menor profundidad de secuenciación y, sobre todo, una mayor tasa de error en comparación con Illumina (1-10%). Por ello, aunque las lecturas largas ya se están implementando en *workflows* gracias a sus rápidos avances y mejoras, las lecturas cortas de Illumina continúan siendo el estándar en DNA *metabarcoding* [30-32].

En cuanto al análisis bioinformático, en los últimos años se han desarrollado multitud de *pipelines*, haciendo difícil en ocasiones determinar cuál es el más apropiado para cada proyecto. No obstante, existen etapas comunes a todos ellos: las lecturas se demultiplexan por muestra, se hace un pre-procesado filtrándolas según su calidad, se eliminan adaptadores y *primers*, se infieren las secuencias características (*features*), solapando las

lecturas *forward* y *reverse* (*merging*) para finalmente, asignarles su taxonomía contra una base de datos de referencia [19,24,29].

Los *pipelines* bioinformáticos de *DNA metabarcoding* suelen diferenciarse en función de cómo se definen las *features* cuya taxonomía se va a anotar. Estas pueden referirse a *operational taxonomic units* (OTUs) o a *amplicon sequence variants* (ASVs) [33]. Los OTUs se obtienen mediante el agrupamiento (*clustering*) de las secuencias según un umbral de similitud, generalmente entre el 97 y el 99%. En cambio, las herramientas de *denoising* generan ASVs, eliminando el ruido de las lecturas a partir de un modelo de error entrenado con el propio conjunto de datos de secuenciación y basado en la calidad de las lecturas, lo que permite discriminar las variantes reales de aquellas debidas a errores. De este modo, los ASVs representan secuencias únicas, con una resolución de un nucleótido [34]. A pesar de que en los últimos años los ASVs han desplazado en gran medida a los OTUs al permitir una mayor resolución taxonómica y ser más reproducibles [35,36], sigue existiendo debate en torno al uso de ASVs frente a OTUs, sobre todo cuando los marcadores son muy variables, recomendándose incluso en algunos casos el *clustering* de los ASVs [37,38].

Una vez generadas las *features*, su taxonomía se asigna comparándolas con una base de datos de secuencias homólogas. En el caso del gen 16S rRNA, las bases de datos más utilizadas son SILVA [39], Greengenes [40] y Ribosomal Database Project (RDP) [41]. Decidir con qué base de datos realizar la asignación taxonómica depende de cómo de curada y actualizada esté, así como de cuán bien esté representado el ambiente de procedencia de las muestras secuenciadas [42]. De entre ellas, SILVA es la base de datos más grande de secuencias de genes ribosomales de Bacteria, Archaea y Eukarya, está curada semi-manualmente y ha demostrado ser la que comparte un mayor número de entidades taxonómicas con el NCBI [43].

Finalmente, el auge del DNA *metabarcoding* gracias a sus numerosas aplicaciones ha impulsado el desarrollo de *software* bioinformático específico para procesar estos datos, siendo QIIME 2 (*Quantitative Insights Into Microbial Ecology* 2) [44] la herramienta más utilizada. Este programa se ha convertido en la plataforma por antonomasia para analizar datos de DNA *metabarcoding* debido a su arquitectura basada en *plugins*, que permiten desarrollar todo el flujo de trabajo, desde la importación de los datos crudos hasta los análisis de diversidad, y la creación de visualizaciones interactivas [45]. Esta facilidad de uso, versatilidad y reproducibilidad, junto con su rendimiento frente a otros programas,

hacen de QIIME 2 la herramienta predilecta para el análisis de microbioma [46,47]. Dentro de QIIME 2 también está integrado DADA2 (*Divisive Amplicon Denoising Algorithm* 2) [34], el algoritmo de *denoising* más popular, desarrollado originalmente como un paquete de R. Otros programas ampliamente utilizados en el análisis de microbioma son mothur [48], USEARCH y VSEARCH [49], así como diferentes paquetes de R como phyloseq [50], microbiome [51] o vegan [52].

En este contexto, en este Trabajo de Fin de Máster se ha desarrollado un *pipeline* bioinformático para el análisis datos del microbioma del oso polar (*Ursus maritimus*), una especie ártica clasificada como "vulnerable" debido a la pérdida de hielo marino causada por el cambio climático [9]. El oso polar está considerado un bioindicador del ecosistema ártico y una especie modelo para evaluar los efectos de los factores de estrés vinculados al cambio climático [53]. En las distintas ecorregiones del Ártico, existen poblaciones con diferente disponibilidad de hielo marino. Por ejemplo, la población del este de Groenlandia (*East Greenland*, EG) se encuentra en una ecorregión convergente con acceso al hielo marino durante todo el año, lo que les permite a estos osos alimentarse anualmente de su presa predilecta, las focas del hielo. Por su parte, la población del sur del mar de Beaufort (*Southern Beaufort Sea*, SB o SBS), ubicada en el norte de Alaska y parte de Canadá, se encuentra en una ecorregión divergente que ha perdido hielo desde los años 80 debido al calentamiento global. Este retroceso del hielo ha obligado a los osos de SBS a pasar parte del año en la costa, restringiendo su acceso a focas del hielo y provocando cambios en sus hábitos alimentarios, pasando a consumir restos de ballenas cazadas, peces, caribús y aves [54,55].

Dada la estrecha relación entre el ambiente, la dieta, el microbioma y la salud animal, así como sus implicaciones en la conservación de especies amenazadas, resulta fundamental evaluar cómo el cambio climático está afectando al microbioma intestinal del oso polar. Dilucidar si la pérdida de su hábitat impacta en su diversidad y composición es clave para prevenir posibles consecuencias negativas sobre su salud, capacidad de adaptación y supervivencia. El DNA *metabarcoding* a partir de heces permite abordar esta cuestión, por lo que se realizará un análisis *de novo* y ciego de datos previamente publicados, a fin de evaluar si el *pipeline* desarrollado es capaz de recuperar información biológica relevante y, si así fuera, aplicarse a otras especies.

2. OBJETIVOS

El objetivo principal de este Trabajo de Fin de Máster de tipo experimental es desarrollar y validar un *pipeline* de DNA *metabarcoding* para el análisis de microbioma. Para ello, se utilizará como ejemplo el microbioma intestinal del oso polar (*Ursus maritimus*), una especie amenazada por el cambio climático. Este flujo de trabajo permitirá caracterizar su composición taxonómica y diversidad microbiana, evaluando la utilidad del microbioma como fuente de información relevante para la conservación de la especie.

Específicamente, se plantean los siguientes objetivos:

- Desarrollar un *pipeline* bioinformático que incluya control de calidad de lecturas, inferencia de ASVs, asignación taxonómica y análisis de diversidad, a partir de lecturas cortas MiSeq de Illumina.
- Aplicar el *pipeline* desarrollado para caracterizar la composición taxonómica y la diversidad alfa y beta del microbioma intestinal de dos poblaciones de oso polar para determinar si existen diferencias entre ellas.
- Evaluar la consistencia y reproducibilidad del *pipeline* mediante la comparación con los resultados de la publicacion original de los datos analizados, así como el potencial del DNA *metabarcoding* para el estudio del microbioma como herramienta de conservación.

3. METODOLOGÍA

3.1. Procedencia de los datos

Para la obtención de los datos se seleccionó el trabajo de Franz et al. [54], un estudio de DNA *metabarcoding* del microbioma de dos poblaciones de oso polar (**Figura 1**). El diseño experimental previo a la generación de los datos consistió en el muestreo de heces de 34 osos polares de la población del este de Groenlandia (en adelante, EG o Greenland) y de 59 individuos de la población del sur del mar de Beaufort, en Alaska (en adelante, SBS o Alaska).

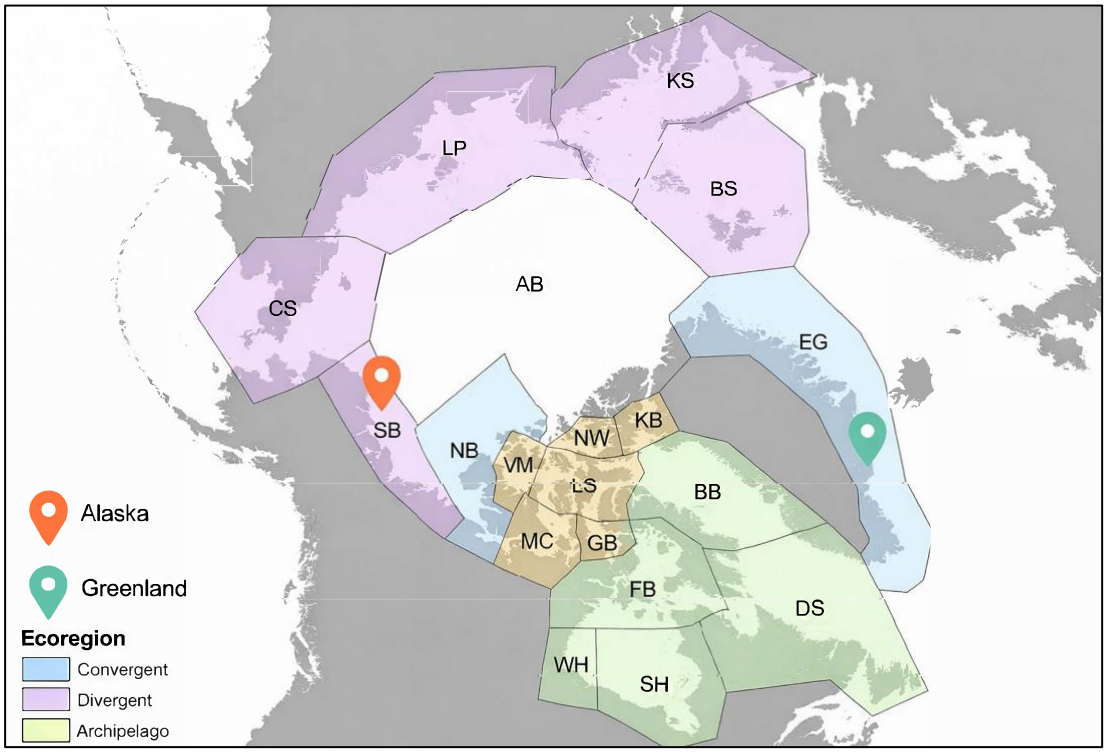

Figura 1. Ubicación geográfica de las 19 poblaciones de oso polar (*Ursus maritimus*) y su distribución en las distintas ecorregiones circumpolares del Ártico. Los datos de microbioma analizados en este trabajo, procedentes de Franz et al. [54], corresponden a la población del sur del mar de Beaufort (*Southern Beaufort Sea*, SB o SBS), en el norte de Alaska, y a la del este de Groenlandia (*East Greenland*, EG). Imagen modificada de la Lista Roja de Especies Amenazadas de la Unión Internacional para la Conservación de la Naturaleza [9], disponible en https://www.iucnredlist.org/es.

A partir de estas muestras se extrajo el DNA total y se amplificó mediante PCR un fragmento de ~460 pb de las regiones V3-V4 del gen 16S rRNA, utilizando la pareja de primers 341F (5′-CCTACGGGNGGCWGCAG-3′) y 805Rmod (5′-GACTACNVGGGTWTCTAATCC-3′), con adaptadores Illumina añadidos en los extremos 5'. Las muestras se secuenciaron en un equipo Illumina MiSeq, generándose lecturas *paired-end* de 300 pb. Todos los detalles experimentales se encuentran descritos en el artículo original [54]. Las lecturas de secuenciación resultantes y los metadatos asociados están disponibles en el European Nucleotide Archive (ENA) del EMBL-EBI y en el Sequence Read Archive (SRA) del NCBI, bajo el BioProject PRJNA773176.

3.2. Recursos informáticos y flujo de trabajo

En este Trabajo de Fin de Máster los datos fueron analizados en un ordenador local con sistema operativo Debian GNU/Linux 12 con 12 procesadores i5, 16GiB de RAM y 1 TB de disco duro. Estas características proporcionaron la capacidad computacional suficiente para procesar los datos originales, tanto en términos del número de muestras como del número total de lecturas. Todo el código del *pipeline* bioinformático desarrollado para este trabajo se recopiló en un archivo R Markdown (.Rmd) y se encuentra disponible en el repositorio público de GitHub https://github.com/ines-gonzalezcastellano/TFM2026_VIU y resumido en la **Figura 2.** El análisis se realizó de forma completamente ciega, sin consultar la metodología bioinformática aplicada en Franz et al. [54], con el objetivo de comparar los resultados obtenidos en este trabajo con los del artículo original.

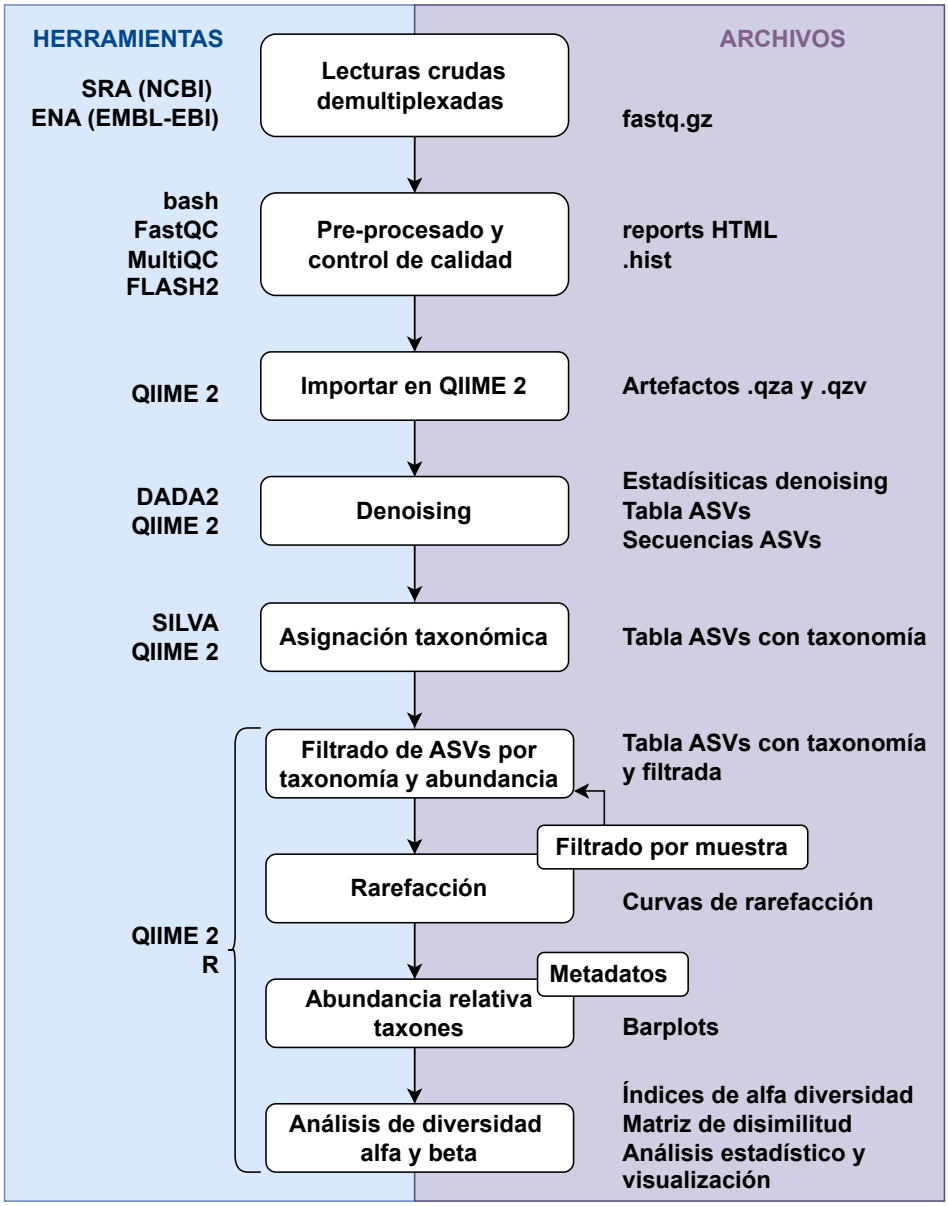

Figura 2. Esquema del *pipeline* bioinformático de DNA *metabarcoding* desarrollado. Se representan las distintas etapas del análisis, los programas y herramientas utilizadas y los archivos de entrada y salida resultantes.

3.3. Obtención y preparación de los datos

En primer lugar, los archivos fastq.gz descargados con las lecturas demultiplexadas e identificados según la nomenclatura original del *run* de secuenciación fueron recodificados según el *library name*, que se corresponde con el nombre de la muestra e incluye el código de la población de origen (EG o SBS). Asimismo, para cada muestra, los archivos se

nombraron con los sufijos _R1 y _R2 para identificar las lecturas *forward* y *reverse*, respectivamente. Para renombrar los archivos se utilizó código de bash (ver apartado 00_RAW_DATA, en Bioinformatic_pipeline.Rmd) a partir de la tabla de metadatos.

A partir del archivo de metadatos original disponible en el SRA asociado al BioProject PRJNA773176, se generó una versión reducida (apartado 01_METADATA, en Bioinformatic_pipeline.Rmd), conservando únicamente la columna correspondiente al nombre de la muestra (coincidente con el utilizado para renombrar los archivos fastq.gz) y la columna *geo_loc_name_country*, que identifica la población de procedencia de las muestras (Greenland o Alaska). Las dos poblaciones de procedencia son los grupos que se emplearán para agrupar las muestras en los gráficos y análisis de diversidad.

3.4. Control de calidad de las lecturas crudas

Una vez descargados y preparados los archivos de las lecturas crudas, se evaluó su calidad mediante FastQC 0.11.9 [56]. Los informes HTML de todas las muestras se agruparon utilizando MultiQC 1.26 [57] por separado para las lecturas R1 y R2. A continuación, se utilizó FLASH 2.2.00 (FLASH2) [58] para evaluar el solapamiento de las lecturas R1 y R2 de cada muestra e identificar los tamaños de los amplicones secuenciados. Dado que distintos microorganismos procariotas pueden presentar variabilidad en el tamaño del fragmento 16S amplificado, es importante examinar la distribución de tamaños de los amplicones secuenciados en el total de muestras. Para ello, se representó la distribución de tamaños de los amplicones mediante R 4.5.1 [59]. Estos pasos se incluyen en el apartado 02_QC, en Bioinformatic_pipeline.Rmd.

3.5. Importación de los datos en QIIME 2 y *denoising*

Las lecturas crudas se importaron en QIIME 2 [44], versión 2025.4, donde se llevó a cabo la mayor parte del análisis. Al importar los datos en QIIME 2 se generó un artefacto .qza y su correspondiente archivo visualizable .qzv, que contiene estadísticas de calidad de las lecturas por muestra, de forma similar a los informes generados por FastQC (apartado 03_DEMUX, en Bioinformatic_pipeline.Rmd).

A continuación, dentro de QIIME 2, se utilizó DADA2 [34] para el *denoising* de las lecturas. En esta etapa se eliminaron los *primers* por tamaño, es decir, recortando en las lecturas la longitud equivalente a los *primers* (i.e., 17 pb del *primer forward* en el extremo 5′ de las R1 y 21 pb del *primer reverse* en el extremo 5’ de las R2). DADA2 aplica un filtrado por calidad

a las lecturas crudas y aprende un modelo de error basado en un subset de 1 millón de lecturas del total de lecturas filtradas. A partir de este modelo de error entrenado, DADA2 lleva a cabo el *denoising* de las lecturas, el solapamiento de las lecturas *denoised* R1 y R2 (*merging*) y la inferencia de los ASVs mediante el *core sample inference algorithm*. Finalmente, se colapsan los ASVs con secuencias idénticas (derreplicado) y se eliminan las secuencias quiméricas (artefactos derivados de la PCR y de la secuenciación). Como resultado, se obtuvieron las estadísticas del *denoising*, las secuencias representativas de los ASVs inferidos y la tabla de ASVs con los conteos de cada ASV por muestra. En este primer *denoising* no se aplicó ningún truncado de las lecturas (apartado 04_DADA2_notrunc, en Bioinformatic_pipeline.Rmd). Por lo que, teniendo en cuenta el tamaño de las lecturas (300 pb) y que DADA2 requiere un solapamiento mínimo de 12 pb entre las R1 y las R2 para hacer el *merging,* el tamaño máximo de amplicón recuperable con estos parámetros sería de 588 pb (300+300-12=588 pb). Descontando, la longitud de los *primers* eliminados de las R1 y R2, el tamaño máximo de amplicón quedaría en 550 pb (300+300-12-17-21=550 pb).

Sin embargo, dada la disminución de calidad de las lecturas R1 y R2 de todas las muestras en 3' observada con MultiQC, se probó un segundo *denoising* truncando las lecturas, es decir, recortándolas por los extremos 3' a una longitud fija. Para definir el truncado se tuvo en cuenta a partir de qué posición comenzaba a bajar la calidad de las lecturas y la distribución de tamaños de los amplicones de todas las muestras reportada por FLASH2. El tamaño máximo de amplicón recuperado por FLASH2 fue de 470 pb (incluyendo los *primers*), por lo que el truncado de las lecturas debía permitir recuperar amplicones de este tamaño. Se aplicó cierto margen para poder recuperar un amplicón de hasta 476 pb, truncando las lecturas R1 y R2 a 244 pb (244+244-12=476 pb). Restando la longitud de los *primers* eliminados, el tamaño máximo de amplicón recuperable sin *primers* sería de 438 pb (244+244-12-17-21=438 pb). Con este segundo *denoising* con truncado (apartado 04_DADA2_244-244, en Bioinformatic_pipeline.Rmd) se descartaron menos lecturas por mala calidad en el filtrado de DADA2, lo que permitió retener más lecturas por muestra y, en consecuencia, recuperar un mayor número de ASVs. Por este motivo, se optó por los resultados de este *denoising* para continuar con la asignación taxonómica.

3.6. Asignación taxonómica

La asignación taxonómica de los ASVs inferidos con DADA2 (apartado 05_ASSIGNMENT, en Bioinformatic_pipeline.Rmd) se realizó utilizando la base de datos SILVA versión 138.2 [39]. Para ello, se descargó y formateó la base de datos utilizando el *plugin* RESCRIPt (*REference Sequence annotation and CuRatIon Pipeline*) implementado dentro de QIIME 2 [60]. A partir de la versión 138.2 de SILVA (https://www.arb-silva.de/documentation/release-1382) se descargaron las secuencias correspondientes a la subunidad ribosomal pequeña (*small subunit*, SSU), es decir, las secuencias de 16S y 18S rRNA. Concretamente, se utilizó el subconjunto SSU Ref NR99, que contiene secuencias de SSU no redundantes con un umbral de identidad máxima del 99%. Así, se generaron dos artefactos .qza: uno con las secuencias de referencia en formato RNA y otro con la taxonomía asociada a dichas secuencias, incorporando las etiquetas a nivel de especie si estaban disponibles. Las secuencias de RNA se retrotranscribieron a DNA y esta base de datos ya en artefacto .qza de QIIME 2 se curó aplicando los parámetros por defecto de RESCRIPt, eliminando las secuencias con 5 o más bases ambiguas y con homopolímeros de 8 o más nucleótidos.

Las secuencias se filtraron por longitud en función de su taxonomía, dado que el tamaño de las secuencias de la SSU varía en función del dominio. Así, en este filtrado se retuvieron únicamente las secuencias con una longitud mínima de 900 pb para Archaea (16S), 1200 pb para Bacteria (16S) y 1400 pb para Eukarya (18S). Aunque se trata de una base de datos no redundante con un umbral de identidad ≤99% de identidad, la documentación de esta versión de SILVA advierte de la posible presencia de secuencias con identidades superiores al 99% y con taxonomías idénticas o distintas (https://www.arb-silva.de/overview/ssu-ref-nr). Por este motivo, y con el fin de reducir la redundancia residual y el esfuerzo computacional durante la asignación taxonómica, se recomienda derreplicar la base de datos, conservando únicamente secuencias idénticas con taxonomías diferentes, utilizando para ello el modo *uniq* por defecto de RESCRIPt.

Con esta base de datos curada y derreplicada se entrenó un clasificador taxonómico, empleando el clasificador bayesiano *naïve* implementado en QIIME 2 [61]. Si bien es posible restringir el entrenamiento del clasificador al fragmento del gen 16S procariota amplificado con los *primers* utilizados en Franz et al. [54] (véase el tutorial de RESCRIPt en QIIME 2: https://forum.qiime2.org/t/processing-filtering-and-evaluating-the-silva-database-and-other-reference-sequence-data-with-rescript/15494), esta estrategia limitaría la aplicabilidad del

clasificador a otras regiones de la SSU, incluidos otros amplicones del 16S. Por ello, se optó por entrenar el clasificador utilizando las secuencias completas de la SSU de los tres dominios.

Con este clasificador entrenado se realizó la asignación taxonómica de las secuencias representativas de los ASVs inferidos con DADA2, estimándose la probabilidad (*confidence*) de que cada ASV pertenezca a un taxón específico basándose en su similitud con las secuencias de la base de datos. Para comparar cada ASV con la base de datos y computar la asignación taxonómica se empleó el algoritmo de *machine learning* scikit-learn [62], implementado en QIIME 2 a través del enfoque basado en *classify-sklearn*. Como resultado de este proceso se obtuvo la tabla de ASVs con la taxonomía asignada a cada uno de ellos.

3.7. Filtrados de ASVs y muestras

Sobre la tabla de ASVs asignados se realizaron una serie de filtrados basados su abundancia y taxonomía. En primer lugar, se eliminaron los *singletons* (apartado 06_FILTERING/01_singletons, en Bioinformatic_pipeline.Rmd), es decir, ASVs con un solo recuento en el total de muestras. Para ello, se filtró la tabla de ASVs con QIIME 2 eliminando todos los ASVs con frecuencia menor de 2 (función *feature-table filter-features* con opción *--p-min-frequency* 2).

Seguidamente, se aplicó un filtro de *mistagging* (apartado 06_FILTERING/02_misstagging, en Bioinformatic_pipeline.Rmd). El *mistagging* (también conocido como *index misassignment* o *index hopping*) es un fenómeno reportado por Illumina mediante el cual lecturas procedentes de una muestra pueden asignarse erróneamente a otra [63]. Este artefacto se produce a una frecuencia máxima del 0.01% por muestra. Por lo tanto, se eliminaron los ASVs cuya frecuencia relativa por muestra era inferior a 0.0001. Dado que QIIME 2 solo permite manejar conteos absolutos, y no frecuencias relativas, este filtrado se realizó en R empleando los paquetes phyloseq 1.52.0 [64] y biomformat 1.39.0 [65]. Puesto que no existe un comando específico para aplicar este filtrado, se escribió el código necesario para importar la tabla de ASVs en R y convertir en ceros todos los recuentos de ASVs que se correspondiesen con una frecuencia relativa por muestra menor de 0.0001. Esta tabla transformada se volvió a importar en QIIME 2 y se eliminaron todos los ASVs cuyos conteos fuesen exclusivamente 0 con *feature-table filter-features* y la opción *--p-min-frequency* 1.

Se eliminaron los ASVs no asignados (*"Unassigned"*), los asignados solo a nivel de dominio (*d__Bacteria*), y los asignados a taxones no objetivo (dominios Archaea y Eukaryota) o de origen organular (mitocondrial o plastídico). Para ello, los identificadores de estos ASVs se incluyeron en una lista mediante bash para eliminarlos con QIIME 2 con el comando *feature-table filter-features* y, en este caso, la opción *--p-exclude-ids* sobre dicha lista de *featureIDs* (apartado 06_FILTERING/03_coamp_lowresolution, en Bioinformatic_pipeline.Rmd).

Se generaron las curvas de rarefacción a partir de la tabla de ASVs obtenida tras el *denoising* de DADA2 (antes del filtrado) y de la tabla final de ASVs tras aplicar los filtros de *singletons, mistagging*, coamplificación y baja resolución taxonómica (después del filtrado), a fin de valorar si la profundidad de secuenciación fue suficiente para recuperar toda la diversidad presente en las muestras (apartado 07_VISUALIZATION/01_rarefaction, en Bioinformatic_pipeline.Rmd). Se construyeron las curvas de rarefacción con QIIME 2 empleando la función *diversity alpha-rarefaction*. Se utilizó como profundidad máxima el máximo de lecturas por muestra (190527 antes del filtrado y 189940 después del filtrado), con 50 pasos de remuestreo y 10 iteraciones por paso. Si bien QIIME 2 permite visualizar las curvas de rarefacción mediante archivos .qvz, la representación gráfica se llevó a cabo con código de R, utilizando los paquetes tidyverse 2.0.0 [66] y ggplot2 4.0.0 [67]. Para cada muestra se representó el número medio de ASVs recuperados con la profundidad de secuenciación correspondiente a cada paso. Se crearon gráficas interactivas en formato HTML con los paquetes de R plotly 4.11.0 [68] y htmlwidgets 1.6.4 [69].

Tras aplicar los filtros, se observó que en tres muestras las curvas de rarefacción no alcanzaban la saturación, lo que indica una profundidad de secuenciación insuficiente. Dado que esto podría sesgar los análisis posteriores, se generó una nueva tabla de ASVs excluyendo dichas muestras. Este filtrado adicional se realizó en QIIME 2 mediante *feature-table filter-samples* y la opción *--p-exclude-ids* sobre la lista con las *sampleIDs* de las tres muestras a eliminar (06_FILTERING/04_rarefaction en Bioinformatic_pipeline.Rmd). En este punto se obtuvo la tabla definitiva de ASVs filtrada con la taxonomía asignada.

3.8. Representación de las abundancias relativas

Los *barplots* de abundancia relativa de cada taxón por muestra se generaron en QIIME 2 con la función *taxa barplot*, obteniéndose un archivo de visualización .qzv interactivo con todas las muestras junto con el metadato correspondiente a su localidad de procedencia (Greenland o Alaska). Adicionalmente, los *barplots* se representaron gráficamente con

código de R, empleando los paquetes tidyverse y ggplot2, a partir de los archivos exportados desde QIIME 2, para todos los niveles taxonómicos (desde dominio hasta especie). Los *barplots* se exportaron en formato interactivo empleando los paquetes plotly y htmlwidgets (ver apartado 07_VISUALIZATION/02_barplots en Bioinformatic_pipeline.Rmd).

3.9. Análisis de alfa y beta diversidad

Se estudió la diversidad alfa y beta de las dos poblaciones de procedencia de las muestras. Antes de computar las métricas de diversidad, se normalizaron los conteos de ASVs al menor número de lecturas por muestra (8965 lecturas). Para ello, se utilizó la función *diversity core-metrics* de QIIME 2 sobre la tabla de ASVs filtrada, especificando la opción *--p-sampling-depth*, con el fin de obtener una tabla de ASVs filtrada y rarificada (apartado 08_ALPHA_BETA/01_normalization, en Bioinformatic_pipeline.Rmd).

Se calcularon los índices de diversidad alfa a partir de esta tabla de ASVs normalizada (apartado 08_ALPHA_BETA/02_alpha_diversity, en Bioinformatic_pipeline.Rmd). La diversidad alfa mide la diversidad presente dentro de una muestra y puede estimarse mediante distintos índices basados en la riqueza (*richness*, número de taxones presentes) y/o la equitatividad (*evenness*, que tiene en cuenta la abundancia relativa de cada taxón). En este trabajo se estimaron los índices de Shannon [70], Chao1 [71] y Simpson [72] para cada muestra con QIIME 2, mediante la función *diversity alpha* y la opción *--p-metric* con los valores *shannon*, *chao1* y *simpson*, respectivamente. QIIME 2 permite agrupar las muestras según metadatos, en este caso la población de origen (Greenland o Alaska), y evaluar la distribución de los índices de diversidad alfa entre grupos, así como realizar pruebas estadísticas para detectar posibles diferencias entre poblaciones. No obstante, la distribución de los tres índices de diversidad alfa por población se representó mediante *boxplots* en R, empleando los paquetes ggplot2 y ggpubr 0.6.2 [73]. Para determinar si la alfa diversidad de Greenland y Alaska difiere significativamente se aplicó el test no paramétrico de Mann–Whitney–Wilcoxon (suma de rangos de Wilcoxon) [74]. Los p-valores obtenidos se corrigieron mediante el método de Benjamini–Hochberg [75] para controlar la tasa de falsos positivos (*False Discovery Rate*, FDR) debida al testeo múltiple. Para cada índice se calculó su media en cada población y su desviación estándar.

Se calculó la diversidad beta (apartado 08_ALPHA_BETA/03_beta_diversity, en Bioinformatic_pipeline.Rmd), que mide la diversidad entre grupos. En otras palabras, la diversidad beta permite comparar la similitud en la composición microbiana entre las dos

poblaciones (Greenland y Alaska), evaluando su solapamiento en términos de taxones compartidos y sus abundancias relativas. Para ello, se utilizó QIIME 2 para calcular la matriz de Bray–Curtis [76] mediante la función *diversity beta* con la opción *--p-metric braycurtis*, obteniéndose la matriz de distancias que refleja la disimilitud entre las muestras de ambas poblaciones. Esta matriz se importó en R para realizar un análisis *Non-metric Multidimensional Scaling* (NMDS) [77], un método multivariante que reduce la dimensionalidad de la matriz a dos coordenadas para representarla gráficamente. Para computar el NMDS se utilizó el paquete vegan 2.7-2 [78] y para representar gráficamente las coordenadas de las muestras por población se utilizaron los paquetes ggplot2 y dplyr 1.1.4 [79]. Además, también se utilizó vegan para llevar a cabo el test no paramétrico PERMANOVA (*Permutational Multivariate Analysis of Variance*) [80] con 999 permutaciones, para determinar si existen diferencias significativas en la composición microbiana entre Greenland y Alaska. La homogeneidad de la dispersión multivariante entre las poblaciones se evaluó mediante el análisis PERMDISP (*Permutational Analysis of Multivariate Dispersions*) [81] con 999 permutaciones, también implementado en vegan, con el fin de garantizar una correcta interpretación de los resultados del PERMANOVA.

4. RESULTADOS

4.1. Control de calidad de las lecturas crudas

En este trabajo se analizaron íntegramente los datos de Franz et al. [54], siendo lecturas *paired-end* de 300 pb de la secuenciación de un fragmento del gen 16S rRNA (región V3–V4), y procedentes de un total de 93 muestras. El número total de lecturas crudas fue de 11381264, y la profundidad de secuenciación presentó una gran variabilidad entre muestras, con un máximo de 280820 lecturas por muestra y un mínimo de 6968 lecturas. Se analizó la calidad de las lecturas crudas mediante FastQC, y los informes de todas las muestras fueron posteriormente agrupados con MultiQC. Los informes están disponibles en MultiQC reports, separados para las lecturas R1 y R2. Se observó que las lecturas de todas las muestras presentaban una bajada progresiva de la calidad hacia el extremo 3'. En las lecturas R1, la calidad comienza a descender aproximadamente entre las posiciones 220–230 pb, mientras que en las R2 la caída en la calidad empieza a ocurrir a partir de la posición 190 pb de forma más acusada. A su vez, tanto las R1 como las R2 muestran una ligera disminución de la calidad en las primeras posiciones (hasta aproximadamente 10–20 pb), lo cual es esperable dado que esta región se corresponde con la secuencia de los *primers.* La gráfica de calidad por posición (*Mean Quality Score*) para las lecturas R1 y R2 de todas las muestras, obtenida a partir de los informes de MultiQC, se muestra en la **Figura 3**, y su versión interactiva está disponible en los informes HTML de MultiQC accesibles en el enlace de GitHub indicado anteriormente. Respecto al control de calidad de los datos crudos, se reportó un elevado porcentaje de duplicados y de secuencias sobrerrepresentadas, un resultado esperado en flujos de *amplicon sequencing*. No obstante, no se detectó un contenido significativo de adaptadores, ni la presencia de dímeros de *primers* ni de *read-through*. Estas observaciones, junto con el hecho de que algunas lecturas tengan un tamaño de 180 pb sugiere que las lecturas depositadas en el Bioproject PRJNA77317 podrían haber sido pre-procesadas, probablemente eliminando los adaptadores.

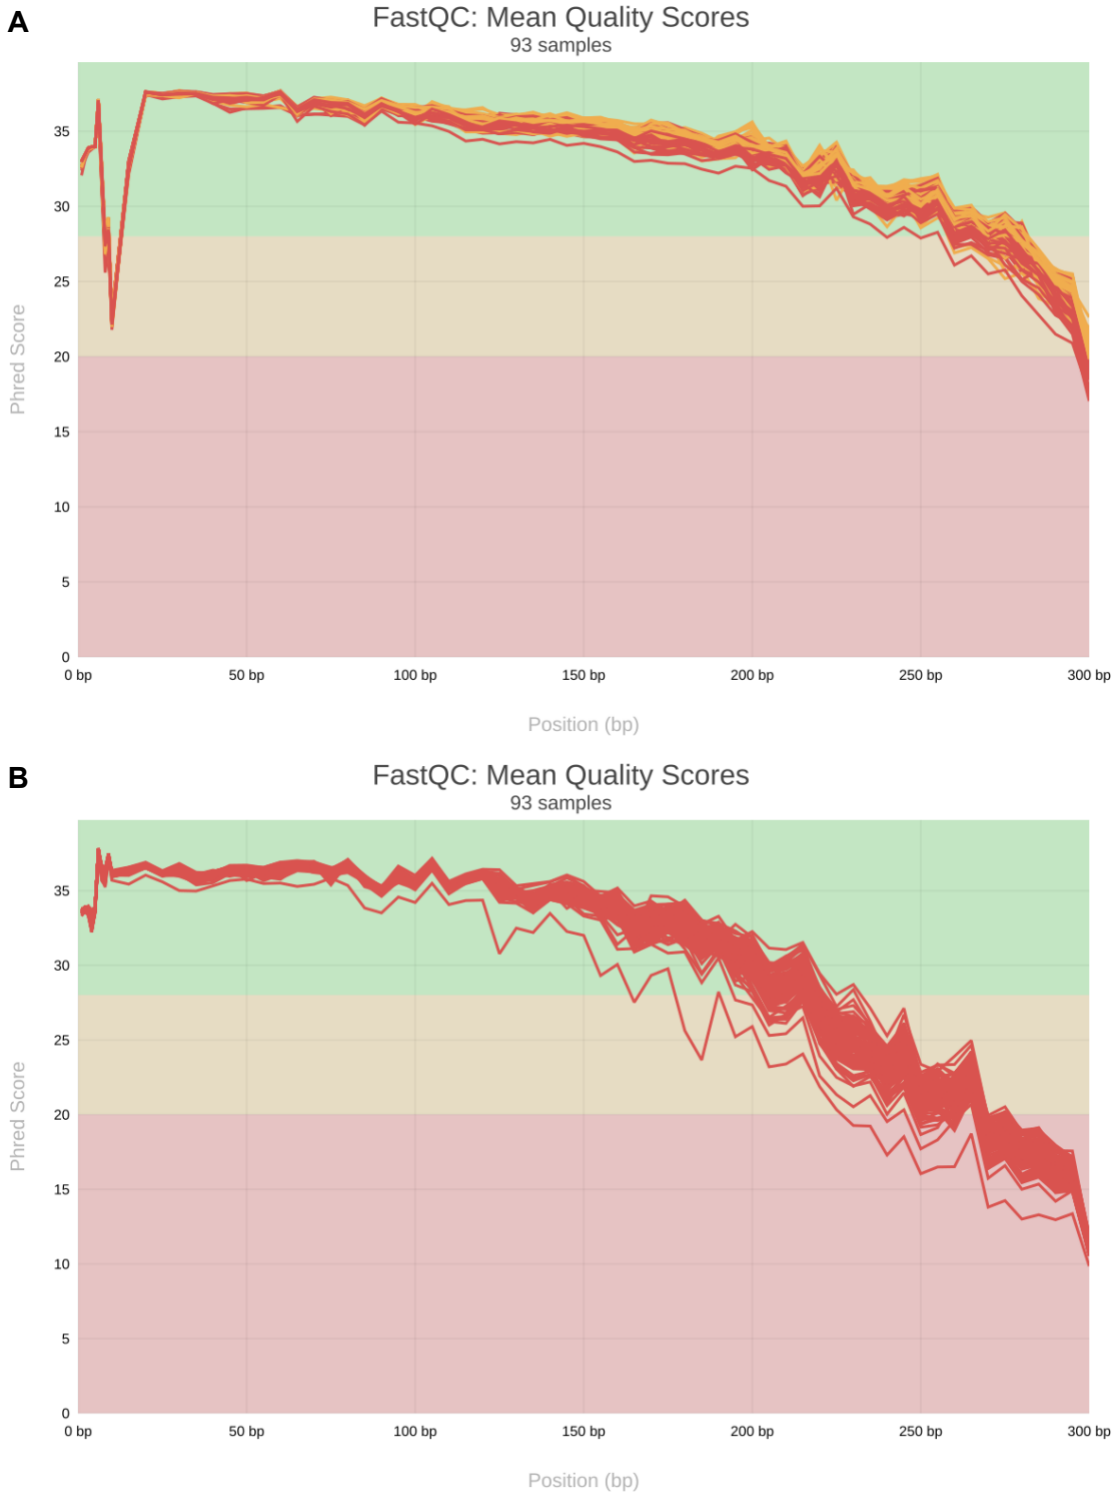

Figura 3. Gráfica de MultiQC que muestra la calidad media Q (*Phred Score*) de las lecturas crudas por posición (pb) para cada muestra. Cada línea representa una muestra. **A:** lecturas R1; **B:** lecturas R2.

Antes de importar las secuencias crudas en QIIME 2 y llevar a cabo la etapa de *denoising*, se utilizó el programa FLASH2 para solapar las lecturas R1 y R2 de cada muestra. La **Figura 4** representa la distribución de tamaños de los amplicones reconstruidos en el conjunto de muestras. Como se puede observar, la mayoría de los amplicones presentan entre 430 y 470 pb, el tamaño esperado para la región amplificada. De nuevo, con esta gráfica se descarta la presencia de dímeros de *primers*.

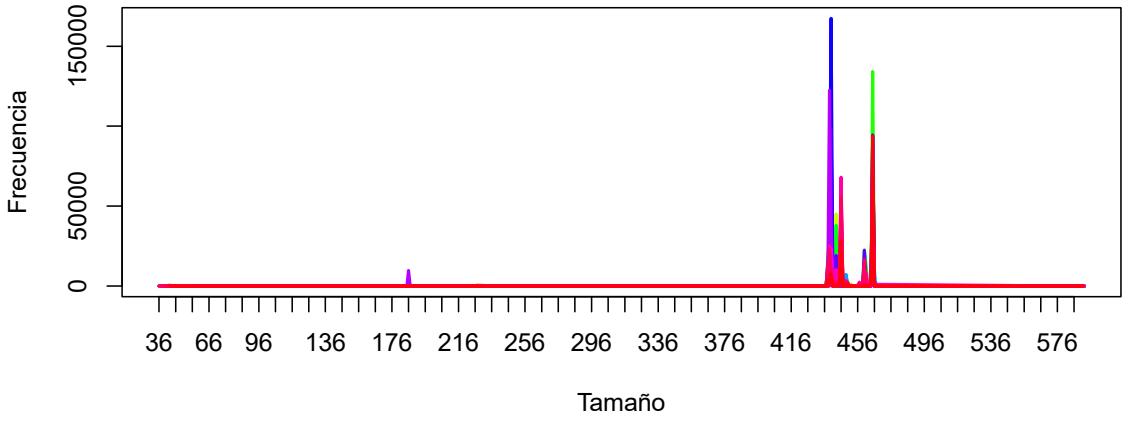

Figura 4. Distribución de tamaños de los amplicones recuperados tras el solapamiento de las lecturas crudas R1 y R2 mediante FLASH2. Cada línea de distinto color corresponde a una muestra y representa la frecuencia absoluta de los tamaños de amplicón (pb) detectados.

4.2. Importación de los datos en QIIME 2 y *denoising*

Las lecturas crudas fastq.gz demultiplexadas se importaron en QIIME 2, junto con los metadatos referentes a la población de origen de las muestras, generándose los artefactos .qza y .qzv de QIIME 2. A continuación, se llevó a cabo un primer *denoising* con DADA2 dentro de QIIME 2, en el que únicamente se eliminó de las lecturas la longitud equivalente a los *primers,* sin aplicar ningún truncado adicional. Las estadísticas asociadas a este *denoising* sin truncado están disponibles en DADA2/DADA2stats_notrunc.tsv. Brevemente, con este primer *denoising* se infirieron 2073 ASVs, con tamaños comprendidos entre 71 y 550 pb. Sin embargo, al final del proceso de *denoising* se retuvieron únicamente entre el 3.12% y el 39.39% de las lecturas iniciales por muestra. Esto se debe a que la mayoría de las lecturas fueron descartadas durante el primer paso del *denoising*, correspondiente al filtrado por calidad de DADA2. Solo superaron dicho filtrado entre el 3.28% y el 41.56% de las lecturas crudas por muestra. En vista de estos resultados, se decidió probar un segundo *denoising* aplicando un truncado de las lecturas crudas R1 y R2 a 244 pb, basado tanto en

la disminución de la calidad observada en las lecturas (**Figura 3**) como en el hecho de que este truncado permitía recuperar el tamaño máximo de amplicón observado con FLASH2 (**Figura 4**). Las métricas de este segundo *denoising* con truncado se encuentran disponibles en DADA2/DADA2stats_trunc244-244.tsv. Con este segundo *denoising* se infirieron 3742 ASVs, con longitudes entre 227 y 430 pb, y se retuvo un mayor porcentaje de lecturas por muestra en comparación con el *denoising* sin truncado, entre el 41.15 y el 75.24% de las lecturas iniciales. Esto se debe a que un mayor número de lecturas superó el filtrado de calidad. A pesar de que se seguían perdiendo muchas lecturas iniciales, las estadísticas mejoraron sustancialmente al aplicar el truncado, ya que este permitió eliminar las regiones 3' de menor calidad de las lecturas crudas, recuperando así un mayor número de ASVs y en un rango de tamaños más acorde con lo esperado para la región amplificada.

4.3. Asignación taxonómica

La tabla de ASVs totales, con los recuentos de cada ASV por muestra, y con su taxonomía asociada está disponible en ASV_tables/asv-table_with_tax_unfiltered.tsv. Las secuencias representativas de los 3742 ASVs se asignaron utilizando QIIME 2 contra la base de datos SILVA-SSU Ref NR 99 formateada y curada. Como resultado, 3715 ASVs pudieron ser asignados a algún nivel taxonómico (99.3% de los ASVs inferidos), quedando únicamente 27 ASVs sin asignar ("*Unassigned*"). La gran mayoría de los ASVs asignados correspondió al dominio Bacteria (99.8%), mientras que solo 3 ASVs se asignaron a Archaea y 3 a Eukarya, debidos a coamplificación inespecífica durante la PCR. De los ASVs bacterianos, 3 se clasificaron como secuencias procedentes de mitocondria y 12 de cloroplasto. Entre los ASVs bacterianos no organulares, el 85% recibió asignación hasta el nivel de género y el 30% pudo asignarse hasta el nivel de especie. En conjunto, estas estadísticas, resumidas en la **Tabla 1**, indican una asignación taxonómica muy exitosa utilizando la base de datos seleccionada.

Tabla 1. Número de ASVs inferidos con DADA2 y su asignación taxonómica contra la base de datos SSU Ref NR99 de SILVA.

			Número de ASVs
Inferidos:			3742
	No asignados		27
	Asignados:		3715
	Bacteria:		3709
		Mitocondria	3
		Cloroplasto	12
		Dominio	3709
		Filo	3685
		Clase	3674
		Orden	3633
		Familia	3589
		Género	3158
		Especie	1129
	Archaea		3
	Eukaryota		3

4.4. Filtrados de ASVs y muestras

A esta tabla de ASVs con taxonomía asignada se le aplicaron varios pasos de filtrado. En primer lugar, se eliminaron 19 ASVs *singletons*. En segundo lugar, se excluyeron los ASVs presentes en cada muestra con una frecuencia inferior al 0.01%. Estos ASVs en muy baja abundancia pueden deberse al fenómeno de *misstagging,* el cual Illumina estima que puede ocurrir a una frecuencia máxima de 0.01% de las lecturas de cada muestra. Por ello, se aplicó un enfoque conservador, eliminando los ASVs cuyos recuentos constituían menos de este umbral en cada muestra, lo que resultó en la exclusión de un total de 1905 ASVs. En tercer lugar, se eliminaron los ASVs que permanecían tras los filtrados anteriores asignados a Archaea (1 ASV) y a cloroplasto (7 ASVs), al no ser taxones objetivo de este estudio, así como 2 ASVs que únicamente estaban asignados hasta el nivel de dominio Bacteria, por lo que tenían baja resolución taxonómica. Tras la aplicación de estos filtrados, se retuvieron 1807 de los 3742 ASVs iniciales. La tabla de ASVs filtrada con la taxonomía está disponible en ASV_tables/sv-table_with_tax_filtered.tsv.

Tras la aplicación de los filtrados basados en la abundancia y en la taxonomía, se representaron las curvas de rarefacción. En Rarefaction_curves se encuentran disponibles las curvas interactivas correspondientes a las 93 muestras, considerando tanto el total de

ASVs inferidos antes del filtrado (3742 ASVs) como con el total de ASVs retenidos tras los filtrados (1807 ASVs). Las curvas de rarefacción permiten evaluar si la profundidad de secuenciación ha sido suficiente, es decir, si el número de lecturas por muestra permite recuperar toda la diversidad presente. Si la curva de una muestra "se cierra" (i.e., llega al *plateau*), significa que, aunque la muestra se hubiese secuenciado a una mayor profundidad, no se habrían detectado más ASVs. Por el contrario, si la curva queda abierta, sugiere que podrían haberse detectado más ASVs de haberse generado más secuencias de esa muestra, por lo que se concluye que la muestra no fue suficientemente secuenciada y debe excluirse del análisis. En la **Figura 5** se muestran las curvas de rarefacción de las 93 muestras tras los filtrados de ASVs. Las curvas de tres muestras (SBS-56-MK, EG-12-MK y SBS-5-MK) no alcanzaron el *plateau*, por lo que estas muestras se eliminaron en un paso adicional de filtrado. Dichas muestras presentaban el menor número de secuencias tras los filtrados (4766, 4808 y 5838 recuentos de ASVs totales, respectivamente), y su eliminación implicó la pérdida de 49 ASVs exclusivos de estas muestras.

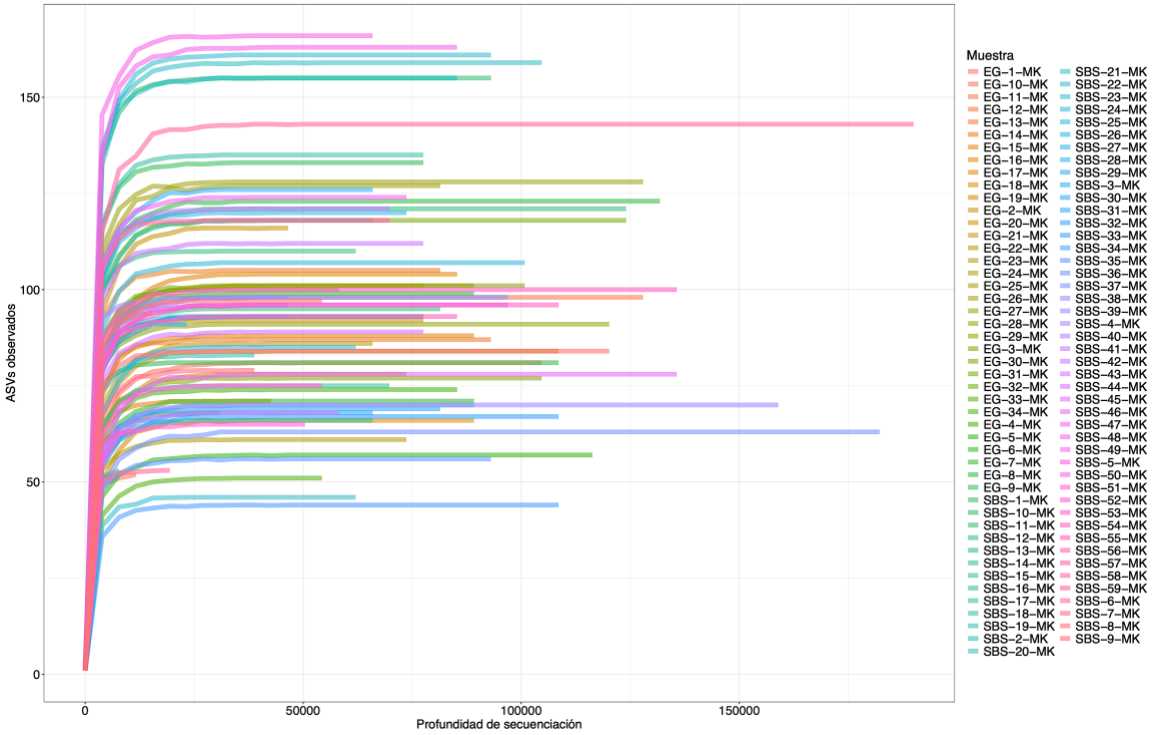

Figura 5. Curvas de rarefacción de las 93 muestras tras los filtrados de ASVs. Se representa el número medio de ASVs observados en función de la profundidad de secuenciación (número de lecturas), considerando 50 pasos de muestreo aleatorio entre 1 lectura y el número máximo de lecturas (189940), con 10 iteraciones por cada paso. Cada línea corresponde a una muestra procedente de Greenland (EG) o de Alaska (SBS).

La tabla definitiva de ASVs tras los fitrados de ASVs y muestras está compuesta por 90 muestras y 1758 ASVs, y está accesible en ASV_tables/asv-table_with_tax_filtered_raref.tsv, así como su correspondiente formato BIOM. Todos los 1758 ASVs pudieron asignarse al menos hasta el nivel de clase y el 90.38% llegó al nivel de género y el 36.46% al de especie. En la **Tabla 2** se muestra el recuento de ASVs asignados en cada nivel taxonómico (desde dominio hasta especie) así como el número de taxones distintos dentro de cada nivel. Por ejemplo, 1589 ASVs pudieron asignarse a nivel de género, correspondiendo a 237 géneros diferentes. De estos, 118 géneros estaban compartidos entre Greenland y Alaska, mientras que 26 fueron exclusivos de Greenland y 93 exclusivos de Alaska. Como se observa, el número de taxones únicos de Alaska fue mayor que el de Greenland.

Tabla 2. Distribución de los ASVs retenidos tras los filtrados de ASVs y muestras en los distintos niveles taxonómicos, mostrando el número de ASVs asignados y el número de taxones detectados, compartidos o exclusivos de cada población.

	ASVs asignados	Taxones totales	Compartidos	Exclusivos Greenland	Exclusivos Alaska
ASVs (totales)	1758	–	419	382	957
Dominio	1758	1	1	0	0
Filo	1758	18	10	1	7
Clase	1758	27	15	2	10
Orden	1744	67	35	8	24
Familia	1738	120	69	10	41
Género	1589	237	118	26	93
Especie	641	148	62	15	71

4.5. Representación de las abundancias relativas

La abundancia relativa de los distintos ASVs identificados en cada muestra se representó mediante diagramas de barras apilados (*barplots*). En Barplots se encuentran disponibles los *barplots* interactivos correspondientes a los siete niveles taxonómicos para las 90 muestras retenidas, y en la **Figura 6** se presenta, a modo de ejemplo, el *barplot* a nivel de clase. El *barplot* con mayor número de taxones corresponde al nivel de género, con un total de 237 taxones diferentes (**Tabla 2**).

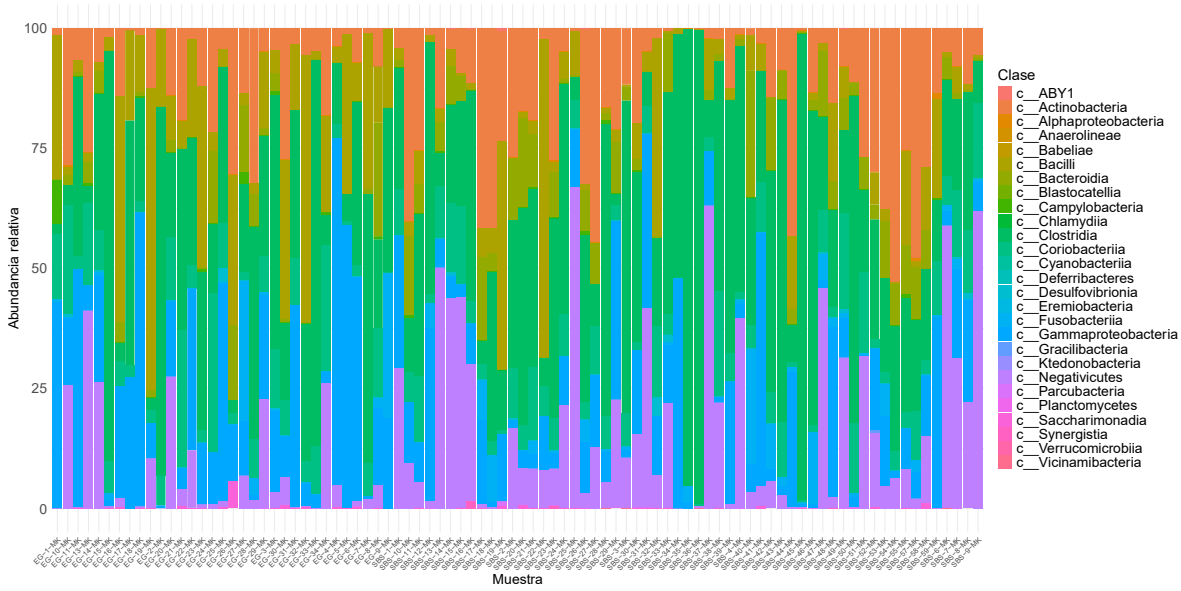

Figura 6. Diagrama de barras apilado (*barplot*) de abundancia relativa en el nivel taxonómico de clase de las 90 muestras tras los filtrados de ASVs y muestras. Cada barra representa una muestra procedente de Greenland (EG) o de Alaska (SBS), y cada color corresponde a una clase taxonómica asignada.

4.6. Análisis de alfa y beta diversidad

Para los análisis de diversidad intra- e inter-poblacional, primero se normalizaron las muestras al menor número de lecturas por muestra tras los filtrados. Es decir, se rarificaron todas las muestras a 8965 lecturas (correspondientes a la muestra SBS-10-MK) para evitar sesgos debidos a diferencias en la profundidad de secuenciación. Esta normalización resultó en la pérdida de 96 ASVs, pero no se eliminó ninguna muestra. Como consecuencia, de los 3742 ASVs iniciales inferidos por DADA2 en 93 muestras, se conservaron 1758 ASVs (el 46.98%) y 90 muestras tras todos los filtrados de ASVs y muestras, y 1662 ASVs (el 44.41%) y las mismas 90 muestras tras la normalización al menor número de lecturas por muestra. En la **Tabla 3** se resumen los recuentos de ASVs y muestras obtenidos tras cada paso de filtrado y normalización.

Tabla 3. Recuento de ASVs inferidos con DADA2 y de muestras retenidas tras los filtrados de ASVs por abundancia y taxonomía, el filtrado de muestras por rarefacción, y la normalización al menor número de lecturas por muestra.

	ASVs	Muestras
Inferidos	3742	93
Filtro de *singletons*	3723	93
Filtro de *misstagging*	1818	93
Filtro de coamplificación y baja resolución	1807	93
Filtro por rarefacción	1758	90
Normalización	1662	90

Para cada muestra se calcularon tres índices de diversidad alfa: Chao1, Simpson y Shannon. Sus valores para cada muestra se encuentran en Alpha_beta_diversity/Indexes_alpha_per_sample.txt. Para determinar si existían diferencias significativas en la diversidad alfa entre las poblaciones de Greenland y Alaska, se agruparon las muestras de cada población y se aplicó el test no paramétrico de Wilcoxon-Mann-Whitney (suma de rangos de Wilcoxon) para cada índice. En la **Tabla 4** se presentan la media y la desviación estándar de los tres índices de diversidad alfa por población, mientras que en la **Figura 7** se muestra su distribución junto con los p-valores ajustados del test. Aunque los valores de los tres índices de diversidad alfa fueron ligeramente superiores en la población de Alaska en comparación con Greenland, lo que podría apuntar a una mayor diversidad en Alaska, todos los p-valores resultaron no significativos (>0.1).

Tabla 4. Diversidad alfa (media ± SD) de las poblaciones de Greenland y Alaska estimada mediante los índices Shannon (*H'*), Chao1 y Simpson (1–*D*).

	Greenland (media±SD)	Alaska (media±SD)
Shannon (*H'*)	3.79±0.65	3.96±0.81
Chao1	88.07±21.46	95.41±32.58
Simpson (1-*D*)	0.84±0.09	0.85±0.10

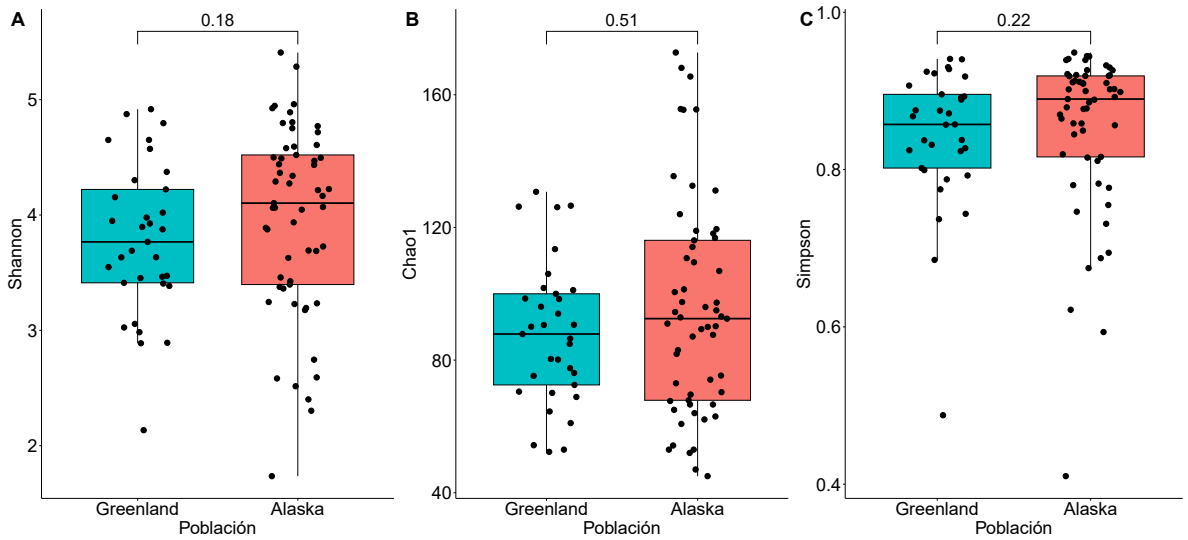

Figura 7. Diagrama de cajas (*boxplot*) de la distribución de la diversidad alfa en las poblaciones de Greenland y Alaska. A: índice de Shannon (*H'*); **B:** índice de Chao1; **C:** índice de Simpson (1–*D*). Se indica el p-valor ajustado del test de suma de rangos de Wilcoxon para comparar la distribución de cada índice entre ambas poblaciones.

El análisis de la diversidad entre las dos poblaciones (diversidad beta) reveló que sí existen diferencias significativas en la composición del microbioma entre Greenland y Alaska. Para ello, se calculó la matriz de distancias de Bray–Curtis entre pares de muestras. Esta matriz de disimilitud por pares entre las 90 muestras está disponible en Alpha_beta_diversity/BC-distance-matrix.tsv. El análisis NMDS permitió reducir la multidimensionalidad de esta matriz para poder representarla en dos dimensiones (**Figura 8**). Aunque se observó cierto solapamiento en la composición microbiana de ambas poblaciones, el test no paramétrico PERMANOVA reveló diferencias significativas entre el microbioma de los osos SBS y EG ($R^2 = 0.0266$; $p = 0.004$), indicando que el factor "población" explica una fracción pequeña (2.66%) pero significativa de la variación composicional observada. Dado que variaciones en la dispersión interna de las poblaciones podrían sesgar el PERMANOVA (el test asume dispersiones similares entre los grupos comparados), se realizó un análisis de homogeneidad de dispersión (PERMDISP) basado en la distancia de Bray–Curtis. Este test mostró que la dispersión interna de Greenland y Alaska no difiere significativamente ($F=2.87$, $p=0.096$), lo que confirma que la diferencia significativa detectada por PERMANOVA en la composición microbiana entre las poblaciones se debe a cambios reales en los taxones presentes y no a variaciones en la heterogeneidad de los grupos.

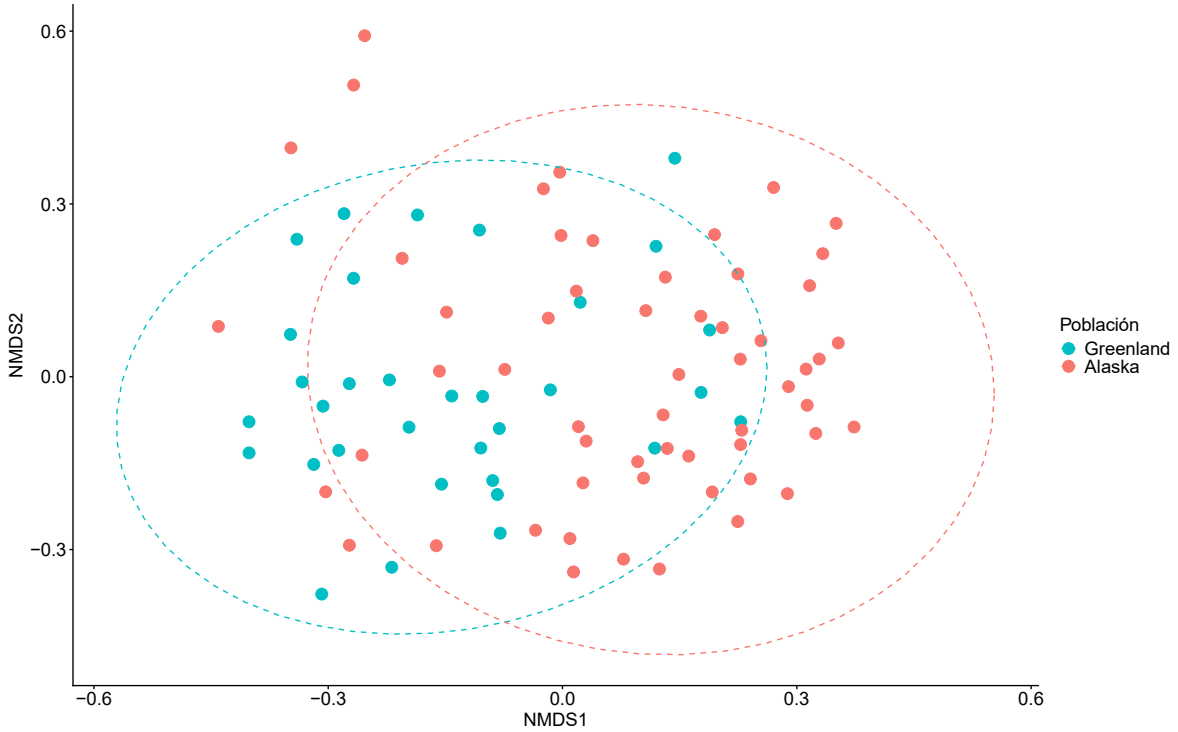

Figura 8. Representación *Non-metric Multidimensional Scaling* (NMDS) de la matriz de distancias de Bray–Curtis entre las muestras de las poblaciones de Greenland y Alaska. Cada punto corresponde a una muestra, y las elipses representan la dispersión de las muestras dentro de cada población, englobando aproximadamente el 95% de ellas.

Por lo tanto, el análisis de diversidad alfa no reveló diferencias significativas entre las poblaciones de Greenland y Alaska. Aunque los índices fueron ligeramente superiores en Alaska, estas diferencias no fueron estadísticamente significativas, por lo que no se puede afirmar que el microbioma de los osos SBS sea significativamente más diverso que el de los osos EG. En contraste, el análisis de diversidad beta sí indicó diferencias significativas en la composición microbiana entre ambas poblaciones, indicando que, si bien presentan un grado de diversidad similar, difieren en los taxones que conforman su microbioma.

5. DISCUSIÓN

El objetivo principal de este trabajo fue desarrollar un *pipeline* bioinformático completo de DNA *metabarcoding* para el análisis de microbioma. Como caso de estudio, se emplearon los datos publicados por Franz et al. [54], procedentes de muestras fecales de oso polar, una especie emblemática cuya conservación se ve amenazada por los efectos del cambio climático. Las muestras procedían de dos poblaciones sometidas a distintas condiciones ambientales derivadas de la pérdida de hielo marino: Alaska, donde el hielo desaparece estacionalmente, y Greenland, donde persiste durante todo el año. La pérdida estacional de hielo en Alaska ha obligado a estos osos a vivir en la costa durante parte del año, con la consiguiente modificación de su dieta respecto a poblaciones con acceso continuo al hielo marino. El artículo original pretendía evaluar si estos cambios dietarios estaban impactando en la diversidad y composición del microbioma intestinal de los osos de Alaska en comparación con los de Greenland. Para ello, se caracterizaron sus microbiomas mediante DNA *metabarcoding* de la región V3–V4 del gen 16S rRNA empleando secuenciación Illumina MiSeq PE300.

En el presente Trabajo de Fin de Máster se partió de las lecturas crudas de dicha publicación y se desarrolló un *pipeline* bioinformático de forma independiente, sin consultar la metodología analítica original. Este planteamiento permitió analizar en qué medida distintas decisiones bioinformáticas pueden influir o no en los resultados y conclusiones y, por tanto, evaluar la consistencia del flujo de trabajo desarrollado *de novo*.

La herramienta central de este *pipeline* es el programa QIIME 2. Este *software* de código abierto escrito en Python se considera actualmente el estándar en el análisis de microbioma al integrar múltiples *plugins* con distintas funcionalidades [45,47,82], incluyendo el algoritmo de *denoising* DADA2 y un clasificador taxonómico bayesiano basado en el algoritmo de *machine learning* scikit-learn, ambos implementados en el *pipeline* desarrollado. Así, es posible integrar todo el *workflow* bioinformático de DNA *metabarcoding* dentro de QIIME 2. Una diferencia muy importante respecto al trabajo original es que en Franz et al. [54] no se utilizó QIIME 2. En su lugar, las lecturas crudas se procesaron directamente mediante el paquete original de R de DADA2 para inferir los ASVs. Una vez inferidos los ASVs, los análisis posteriores no se realizaron en QIIME 2, sino mediante MicrobiomeAnalyst, tanto en su versión web como a través de su paquete en R [83], para el filtrado de ASVs y los

análisis de diversidad. MicrobiomeAnalyst es una plataforma web (https://www.microbiomeanalyst.ca/) que permite importar datos y ejecutar distintos flujos de trabajo para procesarlos, incluyendo el análisis de DNA *metabarcoding* con el gen marcador 16S rRNA (módulo *Marker Data Profiling*). Según la propia descripción de la herramienta, su objetivo es facilitar un análisis accesible y comprensivo para investigadores con poca o ninguna formación bioinformática [84]. En su segunda versión [85], la plataforma ya integra DADA2 para la inferencia de ASVs, permitiendo incluso la carga directa de archivos fastq.gz para evitar aún más la necesidad de trabajar en línea de comandos, si bien con un límite de 100 archivos y 100 MB. Por tanto, aunque MicrobiomeAnalyst es una herramienta más básica que QIIME 2, puede considerarse útil y accesible para el análisis exploratorio de datos de microbioma o para usuarios con menor experiencia, mientras que QIIME 2 constituye una solución más completa y ampliamente extendida en flujos de trabajo bioinformáticos, al ofrecer una mayor capacidad de procesamiento de datos, versatilidad en los análisis y una estructura modular reproducible mediante línea de comandos. A día de hoy, QIIME 2 cuenta con soporte estable y al menos cuatro actualizaciones anuales (https://qiime2.org/), por lo que se trata de un *software* en constante mejora. Ahora bien, el *pipeline* desarrollado en este trabajo es altamente depediente de QIIME 2, de modo que, si esta herramienta dejase de contar con soporte activo en el futuro, sería necesario adaptar el *pipeline* para ejecutar de forma independiente los distintos programas que actualmente integra QIIME 2. En este sentido, el uso de otros programas de código abierto, principalmente basados en paquetes de R, permitiría superar cómodamente esta limitación.

Otra diferencia a destacar es que en Franz et al. [54] no se menciona que se haya llevado a cabo un control de calidad de las lecturas crudas antes de la inferencia de los ASVs con DADA2. Es muy común y recomendable realizar un control de calidad de los datos crudos para detectar la presencia de adaptadores, dímeros de *primers* o *read-through* que deban eliminarse, empleando programas como cutadapt [86], también integrado en QIIME 2, AdapterRemoval [87] o Trimmomatic [88]. Asimismo, como se discutirá posteriormente, en las lecturas obtenidas con MiSeq es crítico evaluar la habitual disminución de calidad hacia el extremo 3' de las lecturas, más pronunciada en las R2 que en las R1 [89], ya que estas regiones de baja calidad pueden provocar la pérdida de muchas lecturas durante el filtrado de DADA2, reduciendo así la inferencia de ASVs y perdiendo información relevante. El enfoque más habitual, e implementado en este *pipeline*, consiste en utilizar primero FastQC para inspeccionar la calidad de las lecturas y después MultiQC para agrupar los informes

generados e identificar tendencias entre las muestras, lo que permitirá establecer umbrales de calidad adecuados y detectar artefactos a eliminar antes del *denoising* [19,30,90]. Curiosamente, en los informes de MultiQC se observó una pequeña población de lecturas crudas de aproximadamente 180 pb en algunas muestras. Esto podría indicar que, de algún modo, las lecturas depositadas en el SRA ya habían sido pre-procesadas, probablemente recortando adaptadores. Todo esto es especulativo, ya que el artículo no proporciona información al respecto y el análisis bioinformático comienza directamente con el *denoising* con DADA2.

El *pipeline* desarrollado incluyó dos estrategias de *denoising* con DADA2: una en la que únicamente se eliminaba la longitud correspondiente a los *primers*, sin truncar adicionalmente las lecturas, y otra en la que, además, se truncaban las lecturas a 244 pb. Sin el truncado se recuperaron 2073 ASVs, reteniéndose de media únicamente el 27.23% de las lecturas iniciales por muestra, ya que la mayoría se descartaban en la primera etapa de filtrado debido a su baja calidad. En cambio, al incluir el truncado para eliminar las regiones 3' de menor calidad, el número de ASVs inferidos aumentó hasta 3742, casi el doble, conservándose de media el 64.93% de las lecturas de las muestras. Por este motivo, se optó por emplear este set de ASVs en los análisis posteriores. Esta diferencia ilustra la importancia de ajustar adecuadamente los parámetros de DADA2, para lo que resulta imprescindible disponer de la información sobre la calidad proporcionada por FastQC.

Además, en el *pipeline* se incluyó el solapamiento entre las lecturas R1 y R2 mediante FLASH2 con el objetivo de examinar la distribución de tamaño de los amplicones de 16S secuenciados y así ayudar a afinar más los parámetros del *denoising*. Aunque sería posible evaluar múltiples truncados para optimizar aún más la inferencia de ASVs, este proceso depende de las características específicas de cada conjunto de datos. De hecho, en Franz et al. [54] únicamente se indica que "*Sequencing data was filtered, trimmed, de-replicated, and paired ends were merged using DADA2*", por lo que se deduce que no se aplicó ningún truncado específico más allá del recorte (*trimming*) de las secuencias correspondientes a los *primers*.

La elección de los parámetros de truncado en DADA2 constituye un paso crítico y no automatizado, ya que varía en función de la calidad de los datos y del gen marcador. Su objetivo es maximizar la retención de secuencias e información tras el *trimming* y/o truncado, minimizando al mismo tiempo los errores de secuenciación. Para determinar los parámetros

óptimos suelen probarse diferentes truncados, como se realizó en este *pipeline*. Con el fin de automatizar esta etapa, se ha desarrollado la herramienta FIGARO [91], que permite estimar automáticamente los parámetros de truncado óptimos para DADA2 en función de la calidad de las lecturas. Sin embargo, su implementación aún es limitada y no se encuentra disponible como *plugin* en QIIME 2. De hecho, actualmente FIGARO solo está integrado en AmpWrap [92], un *workflow* independiente de QIIME 2, y ni AmpWrap ni FIGARO constituyen herramientas extendidas a día de hoy. Por ello, a pesar de su escasa automatización, la selección de los parámetros de truncado continúa realizándose de forma manual en la mayoría de los análisis.

La tabla con los 3742 ASVs inferidos en las 93 muestras con el *denoising* con truncado fue posteriormente filtrada. En primer lugar, se eliminaron los *singletons*, es decir, aquellos ASVs que aparecían con una única lectura en el conjunto total de muestras. Si bien estos pueden corresponder a taxones raros presentes en muy baja abundancia, suelen eliminarse al ser probablemente consecuencia de errores de secuenciación, al igual que las quimeras (eliminadas durante el *denoising*), que pueden inflar las estimas de diversidad [32,34]. A continuación, se aplicó un filtro para minimizar el posible misstagging entre muestras, eliminando aquellos ASVs con una frecuencia relativa inferior al 0.01% de los conteos totales. El multiplexado, que consiste en marcar los amplicones de las distintas muestras con índices específicos durante la preparación de las librerías de secuenciación, permite reducir los costes al posibilitar la secuenciación simultánea de varias muestras en una misma *flowcell*. Durante el demultiplexado, las lecturas se asignan a las diferentes muestras gracias a dichos índices (*tags*). Aún así, en plataformas Illumina puede producirse el fenómeno del *misstagging* como consecuencia de artefactos o errores durante la preparación de las librerías, la secuenciación o el demultiplexado [93-95], lo que puede dar lugar a que una pequeña fracción de las lecturas asignadas a una muestra proceda en realidad de otra. Por tanto, es importante eliminar los ASVs en baja abundancia, ya que podrían estar originados por *misstagging* e inflar artificialmente la diversidad alfa. En un tercer filtrado, se eliminaron ASVs originados por coamplificación inespecífica (asignados a arqueas y eucariotas), ASVs bacterianos cuya asignación taxonómica se quedó a nivel de dominio (baja resolución taxonómica) y ASVs asignados a mitocondrias y cloroplastos, ambos de origen bacteriano, pero no objetivos en un estudio del microbioma. Las mitocondrias se originaron a partir de proteobacterias y los cloroplastos derivan de cianobacterias y, aunque sus genomas organulares se han reducido a lo largo de la

evolución, aún conservan genes de origen bacteriano como el 16S rRNA [96,97]. Como resultado, en estudios de *metabarcoding* basados en este gen, es común que los *primers* universales también amplifiquen, aunque en menor medida, el DNA organular [98].

Tras aplicar todos estos filtrados conservadores, los 3742 ASVs iniciales se redujeron a 1807. Cabe destacar que, aunque en Franz et al. [54] únicamente se filtraron los ASVs *singletons*, se recuperó un menor número de ASVs que mediante este *pipeline*, con un total de 1129. Puesto que no se cuenta con todos los detalles y parámetros empleados por Franz et al. [54] en el *denoising*, no es posible comparar ambos resultados ni dictaminar por qué en el trabajo original se obtuvieron menos ASVs a pesar de aplicar parámetros y filtrados menos estrictos. Una posible explicación es que en Franz et al. [54] se eliminaron los ASVs contaminantes presentes en las muestras, ya que se secuenciaron los controles negativos de extracción y los blancos de PCR. Se han identificado contaminantes bacterianos típicos asociados a kits de extracción, reactivos de PCR, de preparación de librerías y de secuenciación en *workflows* de *amplicon sequencing* de 16S rRNA, por lo que es recomendable secuenciar los controles negativos junto con las muestras para trazarlos y eliminarlos [99]. Eliminar directamente los ASVs presentes en los blancos no es correcto, ya que dichos taxones también pueden estar realmente presentes en las muestras. Algunas estrategias de descontaminación pasan por tener en cuenta la abundancia relativa de estos ASVs entre blancos y muestras e incluso cuantificarla mediante PCR cuantitativa [100]. Alternativamente, los contaminantes pueden eliminarse completamente *in silico* empleando herramientas como el paquete de R decontam [101], que discrimina estadísticamente entre ASVs contaminantes y no contaminantes mediante métodos basados en la frecuencia y/o prevalencia de los ASVs entre muestras y blancos, y que, además, tiene en cuenta la cuantificación del DNA total de las muestras y blancos. Este paquete fue utilizado por Franz et al. [54], pero dado que las secuencias de los blancos no están disponibles en el BioProject en el SRA, no fue posible incluir este paso de filtrado en el presente *pipeline*.

En lo relativo a la asignación taxonómica, Franz et al. [54] indican que se realizó dentro de DADA2 utilizando como base de referencia la versión 132 de SILVA, aunque no se especifican detalles sobre las estadísticas de la asignación obtenida. La función *assignTaxonomy()* de DADA2 implementa el clasificador bayesiano desarrollado por el RDP [102] y se basa en comparar el perfil de k-mers de los ASVs con los de las secuencias de la base de datos. Por el contrario, en este *pipeline* se utilizó la versión 138.2 de SILVA, la

más reciente disponible (última consulta 20 de febrero de 2026), concretamente el subconjunto Ref NR99 de la SSU (contiene 510495 secuencias, https://www.arb-silva.de/documentation/release-1382), y el clasificador bayesiano *naïve* de QIIME 2 basado en el algoritmo de *machine learning* scikit-learn. Para ello, se descargó, formateó y curó la base de datos indicada y se entrenó el clasificador. De este modo, el clasificador queda disponible para su uso en otros análisis de DNA *metabarcoding* que utilicen cualquier amplicón de la SSU. Con el clasificador basado en SILVA entrenado se asignó la taxonomía de los ASVs. Cabe destacar que, además del clasificador de scikit-learn, más sofisticado pero que requiere ser pre-entrenado, el plugin *q2-feature-classifier* [61] de QIIME 2 también permite asignar la taxonomía mediante métodos basados en alineamientos de secuencias, como VSEARCH [49] o BLAST+ [103]. La asignación con el clasificador basado en scikit-learn entrenado con una versión de SILVA más actual permitió asignar el 99.3% de los ASVs filtrados, el 85% de ellos con asignación hasta el nivel de género y el 30% hasta especie.

Con todo, es necesario interpretar con cautela las asignaciones a nivel de especie, ya que SILVA no está curada a este nivel taxonómico en bacterias, por lo que la asignación más fiable es hasta género. De hecho, resulta evidente al examinar el *barplot* de especies que la asignación a este nivel no es consistente, ya que incluye etiquetas como *uncultured, unidentified* o *sp*., que representan el 52.73% de las 641 asignaciones diferentes obtenidas. Por tanto, es necesario remarcar que, debido a la limitada resolución taxonómica alcanzable con lecturas cortas del gen SSU como marcador [104], la base de datos SILVA —tal y como advierten sus autores y los desarrolladores de RESCRIPt— no contiene asignaciones curadas a nivel de especie. En este sentido, aproximadamente el 72% de las especies en SILVA corresponden a entradas *uncultured, unidentified* o *unknown*, y alrededor del 2.5% presentan inconsistencias entre la especie y el género asignado, estimándose que solo cerca del 25% de las asignaciones a nivel de especie son realmente informativas y confiables [60,105]. En consecuencia, las asignaciones de especie observadas en este trabajo son coherentes con las limitaciones conocidas de la base de datos SILVA. Además, conviene tener en cuenta que, aunque SILVA constituye la base de datos más grande de secuencias de la SSU [43], como en cualquier base de datos existen asignaciones erróneas, incluso en niveles curados como el género [105,106], así como taxones infrarrepresentados o no representados [107] debido a que aún no se han secuenciado.

Por otra parte, cada vez más estudios demuestran que las lecturas largas, especialmente las obtenidas mediante secuenciación ONT, pueden aumentar la resolución taxonómica de la SSU como marcador [108,109], particularmente a nivel de especie. Aunque las continuas mejoras en la química de ONT están reducidendo sustancialmente la tasa de error de su secuenciación (1–10%; 7.5% en Mittelstrass et al. [32]), la calidad de estas lecturas largas sigue siendo inferior a la de las lecturas cortas de Illumina, lo que puede generar un mayor número de falsos positivos en estudios de DNA *metabarcoding* [30]. Por este motivo, a pesar del prometedor potencial de las lecturas largas, las lecturas cortas continúan dominando los flujos de DNA *metabarcoding*, razón por la que este *pipeline* se desarrolló y validó a partir de un trabajo [54] basado en este tipo de datos.

Otro punto contradictorio en Franz et al. [54] es que indican que no se realizó un análisis de rarefacción previo a los análisis de diversidad, dado que todas las muestras presentaban más de 10000 lecturas. Sin embargo, en los informes de MultiQC puede observarse que tres muestras tenían menos de 10000 lecturas crudas (entre 6968 y 9672). Estas tres muestras fueron precisamente las que se eliminaron en este *pipeline* tras observar que sus curvas de rarefacción, construidas con los ASVs filtrados, no alcanzaban la saturación, lo que indica que el número de secuencias generado fue insuficiente para recuperar toda su diversidad. Además, el análisis de rarefacción es necesario independientemente del número inicial de lecturas por muestra, incluso cuando este supera las 10000, ya que esta profundidad de secuenciación no garantiza necesariamente una cobertura adecuada de la diversidad en muestras altamente diversas. Es esencial comprobar si el esfuerzo de secuenciación ha sido suficiente examinando las curvas de rarefacción. Así, en este *pipeline* se ha incluido el análisis de rarefacción antes y después de filtrar los ASVs, incluyendo curvas interactivas para poder inspeccionarlas fácilmente muestra a muestra. Las muestras cuya curva “no se cerró” fueron excluidas de los análisis posteriores de diversidad.

La referencia citada en Franz et al. [54] para justificar que “*As recommended, data rarefaction was not performed*” no se refiere al análisis de rarefacción (i.e., curvas de rarefacción), que no fue llevado a cabo, sino a que no se normalizaron los tamaños de las librerías de las muestras mediante rarefacción o rarificación, ya que McMurdie y Holmes [110] lo consideran estadísticamente inadmisible al implicar la omisión de información válida. Brevemente, el tamaño de las librerías de *amplicon sequencing* suele ser muy variable, pero no se correlaciona necesariamente con la diversidad biológica de las

muestras. Muestras con un mayor número de secuencias pueden aparentar una mayor diversidad simplemente debido a un mayor esfuerzo de secuenciación. Como consecuencia, tamaños de librería desiguales pueden sesgar artificialmente tanto la diversidad alfa como la beta [111], por lo que es necesario normalizar el tamaño de las librerías antes de los análisis de diversidad para poder extraer conclusiones biológicas con significado. Existen diferentes estrategias de normalización y una de ellas es la rarefacción, que consiste en muestrear aleatoriamente las lecturas de cada muestra hasta igualarlas a un número de lecturas determinado. Desde el trabajo de McMurdie y Holmes [110] se ha evaluado el impacto de la rarefacción y se han propuesto métodos alternativos de normalización. Una revisión reciente [112] demuestra que la rarefacción es el método que mejor corrige el sesgo asociado a la profundidad de secuenciación dispar en los índices de diversidad, por lo que en este *pipeline* las muestras se normalizaron rarificando al menor número de lecturas por muestra. Aunque existen otras transformaciones posibles para la normalización, en Franz et al. [54] no se especifica cuál se utilizó en lugar de la rarefacción, a pesar de que la normalización entre muestras es un paso previo ineludible a los análisis de diversidad.

En este *pipeline*, las curvas de rarefacción, los *barplots* de abundancia relativa y los índices de diversidad alfa y beta se obtuvieron con QIIME 2 y los resultados se importaron a R para su representación gráfica y la realización de los análisis estadísticos necesarios. Los archivos visualizables .qzv de QIIME 2 son útiles para inspeccionar los resultados, pero son limitados y no permiten personalización avanzada, por lo que todas las representaciones se realizaron en R utilizando paquetes de la familia ggplot2. Además, se incluyó el código necesario para generar en R tanto las curvas de rarefacción como los *barplots* de abundancia relativa en formato interactivo HTML.

Para la diversidad alfa se calcularon tres índices para cada muestra, se obtuvo su promedio poblacional, se representó su distribución entre las dos poblaciones y se llevó a cabo el test de la suma de rangos de Wilcoxon para determinar si existían diferencias significativas. En cuanto a los índices analizados, pueden consultarse revisiones sobre los distintos estimadores de diversidad alfa y beta en Kers y Saccenti [113] o en Cassol et al. [114]. El índice de Chao1 es un estimador de riqueza (*richness*) de especies o ASVs que corrige el hecho de que algunas especies presentes en una muestra podrían no ser observadas por ser muy raras, debido a limitaciones de secuenciación. Su cálculo se basa en la frecuencia

de ASVs raros, específicamente en la proporción entre *singletons* (ASVs observados una sola vez en una muestra) y *doubletons* (ASVs observados dos veces). Una mayor proporción de *singletons* sugiere la presencia de ASVs no detectados, por lo que un valor más alto de Chao1 indica una mayor diversidad en la muestra. Por su parte, el índice de Simpson (*D*) es un estimador de dominancia o equidad (*evenness*) que mide la probabilidad de que dos secuencias seleccionadas al azar pertenezcan al mismo ASV. Valores cercanos a 1 indican baja diversidad (un ASV domina la muestra) mientras que valores cercanos a 0 indican alta diversidad. Dado que esta interpretación puede resultar poco intuitiva, en la práctica se utiliza la transformación 1–*D*, implementada en QIIME 2 y aplicada en este *pipeline*, de modo que valores más altos del índice reflejan mayor diversidad. Finalmente, el índice más usado es el de Shannon (*H*'), que combina tanto la riqueza como la equidad de los ASVs en una muestra. Cuantos más ASVs estén presentes y más equilibradas sean sus abundancias, mayor será el valor de *H*'. Se calcularon estos tres índices al ser complementarios y proporcionar una visión global de la diversidad alfa de cada muestra. Sería posible incluir otros estimadores de diversidad alfa, que podrían calcularse también con QIIME 2 o mediante paquetes de R como vegan, phyloseq o microbiome.

Para la diversidad beta, en este *pipeline* se calculó en QIIME 2 la matriz de distancias de Bray-Curtis, que mide la disimilitud composicional entre comunidades microbianas en función de los recuentos de ASVs observados en cada muestra. Esta matriz se representó en R mediante NMDS, y se evaluó la diferenciación composicional entre las poblaciones mediante el test PERMANOVA, ambos incluidos en el paquete vegan. Respecto a Franz et al. [54], todos los índices de diversidad se calcularon con MicrobiomeAnalyst en lugar de QIIME 2, pero también se utilizó R para las representaciones y los test estadísticos mediante los mismos paquetes phyloseq y vegan.

En síntesis, a pesar de las notables diferencias en la metodología bioinformática empleada para las distintas etapas, el *pipeline* desarrollado permitió llegar a la misma conclusión principal que Franz et al. [54]. En los dos estudios se detectó un mayor número de ASVs únicos en Alaska que en Greenland y los índices promedio de diversidad alfa fueron ligeramente superiores en la población de Alaska, lo que podría sugerir un microbioma más diverso en los osos de esta región, aunque estas diferencias no fueron estadísticamente significativas entre ambas poblaciones. La ausencia de significación podría deberse a la elevada variabilidad intrapoblacional, sumado a que se analizaron 59 muestras de Alaska

frente a 34 de Greenland. Sí se detectaron diferencias composicionales pequeñas pero significativas en la diversidad beta. En otras palabras, aunque la riqueza y la equidad de los ASVs sean similares entre poblaciones, la estructura taxonómica del microbioma difiere ligeramente entre ellas. El factor "población" explicó únicamente una pequeña fracción (2.66%) de la variación total observada, lo que sugiere que otros factores biológicos —como el sexo, la edad, la historia vital o la filogenia del hospedador— podrían contribuir también a las diferencias en la composición microbiana. Además, aunque el cambio en la dieta de los osos SBS podría estar conduciendo a un microbioma más diverso, esto no necesariamente se traduciría en un microbioma más saludable para los individuos. En las especies especialistas, la composición del microbioma puede haberse adaptado evolutivamente al nicho ecológico [115] y, en el caso de los osos polares que se alimentan principalmente de focas de hielo, con alto contenido en grasas, los osos EG mostraron una mayor abundancia relativa de clases bacterianas implicadas en el metabolismo lipídico en comparación con los osos SBS [54,55].

Por lo tanto, se plantea que la degradación del nicho ecológico de los osos de Alaska, junto con los consiguientes cambios en su dieta, podría estar influyendo en la composición de su microbioma. La reducción en el consumo de sus presas habituales podría derivar en alteraciones en su microbioma con posibles consecuencias negativas para su salud y, en última instancia, para la conservación de la población [53-55]. De hecho, en Franz et al. [54] se incluyeron análisis ANCOM-BC (*Analysis of Compositions of Microbiomes with Bias Correction* [116], que permitieron identificar que aproximadamente el 9% de los taxones compartidos entre ambas poblaciones presentaban diferencias significativas en su abundancia relativa. Se evaluó si estos taxones podían explicar o estar correlacionados con la variación composicional observada, considerando las diferencias dietarias entre poblaciones. Además, se integró información dietaria, estimada mediante el análisis de ácidos grasos de cadena corta, en modelos de regresión junto con los índices de diversidad, con el objetivo de analizar su asociación con la dieta. Este tipo de análisis tan específicos no fueron incorporados en el *pipeline* desarrollado en el presente trabajo, ya que excedían su objetivo principal. Es importante también remarcar que el DNA *metabarcoding* no es una técnica cuantitativa, sino que permite determinar qué taxones están presentes en una muestra y en qué abundancia relativa. Es decir, que un mayor número de secuencias se asigne a un taxón (o ASV) no implica necesariamente que este sea más abundante en una muestra en comparación con otro taxón con menor número de conteos. Esto se debe,

principalmente, a que los distintos taxones pueden no presentar la misma afinidad por los *primers* universales utilizados en *metabarcoding*, lo que introduce sesgos en la PCR que impiden correlacionar directamente el número de lecturas de un taxón con su abundancia absoluta (biomasa) [117-119]. En cualquier caso, dado que este sesgo afecta de forma similar a todas las muestras, sí es legítimo comparar la abundancia relativa de un mismo taxón entre muestras o grupos de muestras analizadas conjuntamente, como se realizó en Franz et al. [54] mediante el ANCOM-BC.

El caso de las poblaciones de oso polar de Greenland y Alaska investigado en Franz et al. [54] demuestra la utilidad del DNA *metabarcoding* para estudiar el microbioma y comprender cómo la pérdida de hábitat puede estar impactando sobre el mismo. Esta información puede ser relevante para evaluar y monitorizar el estado de conservación en el contexto del cambio climático que amenaza a esta especie. Pese a ello, el microbioma de la fauna silvestre se ha estudiado mucho menos que el de los humanos o el de animales domésticos o modelo. En una revisión de 2017 sobre el microbioma intestinal animal, solo el 14.3% de las investigaciones se habían realizado en especies silvestres [120]. Desde entonces, el estudio del microbioma de distintas especies salvajes mediante técnicas ómicas, incluyendo DNA *metabarcoding*, ha ido aumentando paulatinamente [121]. Específicamente, en el ámbito de la biología de la conservación se considera que estudiar el microbioma de especies silvestres amenazadas es clave, ya que alteraciones en la microbiota podrían derivar en problemas de salud, *fitness* y, en última instancia, en la supervivencia de estas especies [122]. Así, además del oso polar [53-55], se ha analizado de forma similar el microbioma de otras especies amenazadas, como el koala [123] o el caribú boreal [124]. Integrar esta información podría ayudar a desarrollar estrategias de gestión eficaces [7] y, en este sentido, el *pipeline* desarrollado en este trabajo podría representar un recurso bioinformático de gran utilidad.

El *pipeline* creado integra de manera completa todas las etapas del procesamiento bioinformático estándar de un análisis de DNA *metabarcoding*, desde las lecturas crudas hasta los análisis de diversidad alfa y beta, en un único *script* de R Markdown que permite su ejecución automática. El código se basa principalmente en QIIME 2 y en R, combinando este lenguaje con código en bash y Python a través de QIIME 2, lo que garantiza la reproducibilidad del análisis. Dado que se obtuvieron las mismas conclusiones biológicas que en la publicación original, se concluye que el *pipeline* queda validado a nivel analítico y

puede aplicarse a otros estudios de microbioma, o incluso a otros tipos de muestras (*bulk*) o de DNA ambiental (eDNA). Gracias a su estructura modular, el *pipeline* se adaptaría fácilmente a diferentes contextos, solo sería necesario: (i) ajustar las opciones de importación en QIIME 2 si se han generado lecturas largas en lugar de cortas o lecturas cortas *single-end*; (ii) modificar los parámetros de *denoising* según la calidad de los datos crudos y la distribución de tamaños de los amplicones secuenciados; (iii) entrenar una base de datos de referencia distinta de SILVA si se prefiere o si se ha utilizado un marcador diferente a la SSU; (iv) emplear algoritmos de asignación taxonómica alternativos al clasificador bayesiano *naïve* si se desea, como VSEARCH o BLAST+; (v) filtrar ASVs contaminantes si se han secuenciado controles negativos, y los asignados a taxones no objetivo del estudio; (vi) agrupar las muestras según los metadatos de interés para los análisis de diversidad; (vii) calcular otras métricas de diversidad alfa o beta si se requieren; y (viii) personalizar los parámetros estéticos de los gráficos generados en R. Una vez adaptado a las características de los datos y a la idiosincrasia de cada proyecto, este *pipeline* resultaría especialmente útil para proyectos que analicen series temporales de muestras del mismo tipo, procesadas en lotes o cohortes (por ejemplo, muestras de EG o SBS de otros años o de distintas poblaciones de osos polares), ya que garantizaría mantener la reproducibilidad y ejecutarse directamente sin necesidad de modificaciones adicionales.

En conclusión, el *pipeline* desarrollado está disponible como recurso abierto en un repositorio público accesible para la comunidad científica. Representa una herramienta reproducible y flexible que puede aplicarse a otros estudios de microbioma, facilitando de este modo futuros trabajos en especies amenazadas que contribuyan a su conservación.

6. CONCLUSIONES

- Se ha desarrollado un *pipeline* bioinformático completo de DNA *metabarcoding*, automatizado en un único *script*, reproducible e incluyendo representaciones interactivas de los resultados. Está basado principalmente en QIIME 2, R y bash, e incorpora el control de calidad de los datos crudos, la optimización del *denoising* con DADA2, la asignación taxonómica mediante un clasificador entrenado con la base de datos SILVA, el filtrado de ASVs y muestras, y los análisis de rarefacción y de diversidad alfa y beta.
- Se ha validado empíricamente la aplicabilidad del *pipeline* mediante el re-análisis de lecturas cortas Illumina MiSeq de la región V3–V4 del gen 16S rRNA, correspondientes al microbioma de dos poblaciones de oso polar (*Ursus maritimus*) bajo distintas condiciones ambientales derivadas del cambio climático.
- Se han obtenido resultados similares a los publicados y se han alcanzado las mismas conclusiones biológicas, a pesar de que el *pipeline* presenta diferencias bioinformáticas sustanciales respecto al análisis original, al incorporar herramientas más avanzadas, recursos más completos y criterios más estrictos.
- Se observó una tendencia hacia una mayor diversidad en el microbioma de los osos de Alaska en comparación con los de Greenland, aunque estas diferencias no resultaron estadísticamente significativas. No obstante, sí se detectaron diferencias composicionales pequeñas pero significativas entre ambas poblaciones, lo que sugiere que los cambios dietarios derivados del deshielo podrían estar influyendo en la composición del microbioma intestinal de los osos de Alaska, con posibles implicaciones sobre su salud, eficacia biológica y supervivencia.
- Este trabajo respalda el potencial del DNA *metabarcoding* como herramienta para estudiar el microbioma en especies silvestres amenazadas, ya que permite detectar posibles alteraciones asociadas a cambios ambientales y aportar información de interés en el ámbito de la biología de la conservación.
- El *pipeline* desarrollado constituye un recurso bioinformático consistente para caracterizar el microbioma en otras especies, y presenta la flexibilidad necesaria para su adaptación a distintos tipos de lecturas, marcadores y bases de datos.

7. REFERENCIAS BIBLIOGRÁFICAS

1. Berg G, Rybakova D, Fischer D, Cernava T, Vergès MC, Charles T, et al. Correction to: Microbiome definition re-visited: old concepts and new challenges. Microbiome. 2020;8:119. https://doi.org/10.1186/s40168-020-00905-x.
2. Forcina G, Pérez-Pardal L, Carvalheira J, Beja-Pereira A. Gut microbiome studies in livestock: achievements, challenges, and perspectives. Animals. 2022;12(23):3375. https://doi.org/10.3390/ani12233375.
3. Hou K, Wu ZX, Chen XY, Wang JQ, Zhang D, Xiao C, et al. Microbiota in health and diseases. Signal Transduct Target Ther. 2022;7:135. https://doi.org/10.1038/s41392-022-00974-4.
4. Combrink L, Humphreys IR, Washburn Q, Arnold HK, Stagaman K, Kasschau KD, et al. Best practice for wildlife gut microbiome research: A comprehensive review of methodology for 16S rRNA gene investigations. Front Microbiol. 2023;14:1092216. https://doi.org/10.3389/fmicb.2023.1092216.
5. Dallas JW, Warne RW. Captivity and animal microbiomes: potential roles of microbiota for influencing animal conservation. Microb Ecol. 2023;85(3):820-838. https://doi.org/10.1007/s00248-022-01991-0.
6. Bahrndorff S, Alemu T, Alemneh T, Lund Nielsen J. The microbiome of animals: implications for conservation biology. Int J Genomics. 2016;2016:5304028. https://doi.org/10.1155/2016/5304028.
7. Trevelline BK, Fontaine SS, Hartup BK, Kohl KD. Conservation biology needs a microbial renaissance: a call for the consideration of host-associated microbiota in wildlife management practices. Proc Biol Sci. 2019;286(1895):20182448. https://doi.org/10.1098/rspb.2018.2448.
8. Soulé ME. What is conservation biology? A new synthetic discipline addresses the dynamics and problems of perturbed species, communities, and ecosystems. BioScience. 1985;35(11):727-734. https://doi.org/10.2307/1310054.
9. IUCN. The IUCN Red List of Threatened Species. Version 2025-1. [Internet]. 2025 [cited 2026 Jan 26]. Available from: https://www.iucnredlist.org

10. Fountain-Jones NM, Giraud T, Zinger L, Bik H, Creer S, Videvall E. Molecular Liecology of microbiomes in the wild: common pitfalls, methodological advances and future directions. Mol Ecol. 2024;33(2):e17223. https://doi.org/10.1111/mec.17223.

11. Ingala MR, Becker DJ, Bak Holm J, Kristiansen K, Simmons NB. Habitat fragmentation is associated with dietary shifts and microbiota variability in common vampire bats. Ecol Evol. 2019;9(11):6508-6523. https://doi.org/10.1002/ece3.5228.

12. Zhu L, Wang J, Bahrndorff S. The wildlife gut microbiome and its implication for conservation biology. Front Microbiol. 2021;12:697499. https://doi.org/10.3389/fmicb.2021.697499.

13. Hofer U. The majority is uncultured. Nat Rev Microbiol. 2018;16:716-717. https://doi.org/10.1038/s41579-018-0097-x.

14. Hiergeist A, Gläsner J, Reischl U, Gessner A. Analyses of intestinal microbiota: culture versus sequencing. ILAR J. 2015;56(2):228-240. https://doi.org/10.1093/ilar/ilv017.

15. Hebert PDN, Ratnasingham S, de Waard JR. Barcoding animal life: cytochrome c oxidase subunit 1 divergences among closely related species. Proc Biol Sci. 2003;270(Suppl 1):S96-S99. https://doi.org/10.1098/rsbl.2003.0025.

16. Ramesh M, Sen A, Vachher M, Nigam A. Delineating bacteria using DNA barcoding. Mol Genet Microbiol Virol. 2021;36(Suppl 1):S65-S73. https://doi.org/10.3103/S0891416821050128.

17. Taberlet P, Coissac E, Pompanon F, Brochmann C, Willerslev E. Towards next-generation biodiversity assessment using DNA metabarcoding. Mol Ecol. 2012;21(8):2045-2050. https://doi.org/10.1111/j.1365-294X.2012.05470.x.

18. Staats M, Arulandhu AJ, Gravendeel B, Holst-Jensen A, Scholtens I, Peelen T, et al. Advances in DNA metabarcoding for food and wildlife forensic species identification. Anal Bioanal Chem. 2016;408:4615–4630. https://doi.org/10.1007/s00216-016-9595-8

19. Deiner K, Bik HM, Mächler E, Seymour M, Lacoursière-Roussel A, Altermatt F, et al. Environmental DNA metabarcoding: Transforming how we survey animal and plant communities. Mol Ecol. 2017;26(21):5872-5895. https://doi.org/10.1111/mec.14350.

20. Weinroth MD, Belk AD, Dean C, Noyes N, Dittoe DK, Rothrock MJ, et al. Considerations and best practices in animal science 16S ribosomal RNA gene sequencing microbiome studies. J Anim Sci. 2022;100(2):skab346. https://doi.org/10.1093/jas/skab346.

21. Francioli D, Lentendu G, Lewin S, Kolb S. DNA metabarcoding for the characterization of terrestrial microbiota—pitfalls and solutions. Microorganisms. 2021;9(2):361. https://doi.org/10.3390/microorganisms9020361.

22. van Der Loos LM, Nijland R. Biases in bulk: DNA metabarcoding of marine communities and the methodology involved. Mol Ecol. 2021;30(13):3270-3288. https://doi.org/10.1111/mec.15592.

23. Ruppert KM, Kline RJ, Rahman MS. Past, present, and future perspectives of environmental DNA (eDNA) metabarcoding: A systematic review in methods, monitoring, and applications of global eDNA. Glob Ecol Conserv. 2019;17:e00547. https://doi.org/10.1016/j.gecco.2019.e00547.

24. Regueira-Iglesias A, Balsa-Castro C, Blanco-Pintos T, Tomás I. Critical review of 16S rRNA gene sequencing workflow in microbiome studies: From primer selection to advanced data analysis. Mol Oral Microbiol. 2023;38(5):347-399. https://doi.org/10.1111/omi.12434.

25. Antil S, Abraham JS, Sripoorna S, Maurya S, Dagar J, Makhija S, et al. DNA barcoding, an effective tool for species identification: a review. Mol Biol Rep. 2023;50:761-775. https://doi.org/10.1007/s11033-022-08015-7.

26. Woese CR, Fox GE. Phylogenetic structure of the prokaryotic domain: the primary kingdoms. Proc Natl Acad Sci USA. 1977;74(11):5088-5090. https://doi.org/10.1073/pnas.74.11.5088.

27. Thompson L, Sanders J, McDonald D, Amir A, Ladau J, Locey KJ, et al. A communal catalogue reveals Earth's multiscale microbial diversity. Nature. 2017;551:457-463. https://doi.org/10.1038/nature24621.

28. Pollock J, Glendinning L, Wisedchanwet T, Watson M. The madness of microbiome: attempting to find consensus "best practice" for 16S microbiome studies. Appl Environ Microbiol. 2018;84:e02627-17. https://doi.org/10.1128/AEM.02627-17.

29. Hakimzadeh A, Abdala Asbun A, Albanese D, Bernard M, Buchner D, Callahan BJ, et al. A pile of pipelines: an overview of the bioinformatics software for metabarcoding data analyses. Mol Ecol Resour. 2024;24(5):e13847. https://doi.org/10.1111/1755-0998.13847.

30. Rousseau C, Henry N, Rousvoal S, Tanguy G, Legeay E, Leblanc C, et al. A practical comparison of short- and long-read metabarcoding sequencing: challenges and solutions for plastid read removal and microbial community exploration of seaweed samples. Mol Ecol Resour. 2025;e14129. https://doi.org/10.1111/1755-0998.14129.

31. Santos A, van Aerle R, Barrientos L, Martinez-Urtaza J. Computational methods for 16S metabarcoding studies using Nanopore sequencing data. Comput Struct Biotechnol J. 2020;18:296-305. https://doi.org/10.1016/j.csbj.2020.01.005.

32. Mittelstrass J, Heinzelmann R, Eschen R, Hartmann M, Kupper Q, Schneider S, et al. Metabarcoding with Illumina and Oxford Nanopore Technologies provides complementary insights into tree seed mycobiota. Environ Microbiome. 2025;20:53. https://doi.org/10.1186/s40793-025-00712-7.

33. Chiarello M, McCauley M, Villéger S, Jackson CR. Ranking the biases: the choice of OTUs vs. ASVs in 16S rRNA amplicon data analysis has stronger effects on diversity measures than rarefaction and OTU identity threshold. PLoS One. 2022;17(2):e0264443. https://doi.org/10.1371/journal.pone.0264443.

34. Callahan BJ, McMurdie P, Rosen M, Han AW, Johnson AJA, Holmes SP. DADA2: high-resolution sample inference from Illumina amplicon data. Nat Methods. 2016;13:581-583. https://doi.org/10.1038/nmeth.3869.

35. Callahan BJ, McMurdie PJ, Holmes SP. Exact sequence variants should replace operational taxonomic units in marker-gene data analysis. ISME J. 2017;11(12):2639-2643. https://doi.org/10.1038/ismej.2017.119.

36. Cardoni S, Piredda R, Grimm GW, Santorsola M, Schulze ED, Denk T, et al. Pruning the tree: comparing OTUs and ASVs in high-throughput sequencing of 5S-IGS nuclear ribosomal DNA in phylogenetic studies. Ecol Evol. 2025;15(10):e72242. https://doi.org/10.1002/ece3.72242.

37. Antich A, Palacin C, Wangensteen OS, Turon X. To denoise or to cluster, that is not the question: optimizing pipelines for COI metabarcoding and metaphylogeography. BMC Bioinformatics. 2021;22:177. https://doi.org/10.1186/s12859-021-04115-6.

38. Schloss PD. Amplicon sequence variants artificially split bacterial genomes into separate clusters. mSphere. 2021;6:e00191-21. https://doi.org/10.1128/msphere.00191-21.

39. Quast C, Pruesse E, Yilmaz P, Gerken J, Schweer T, Yarza P, et al. The SILVA ribosomal RNA gene database project: improved data processing and web-based tools. Nucleic Acids Res. 2013;41(D1):D590-D596. https://doi.org/10.1093/nar/gks1219.

40. DeSantis TZ, Hugenholtz P, Larsen N, Rojas M, Brodie EL, Keller K, et al. Greengenes, a chimera-checked 16S rRNA gene database and workbench compatible with ARB. Appl Environ Microbiol. 2006;72. https://doi.org/10.1128/AEM.03006-05.

41. Cole JR, Wang Q, Fish JA, Chai B, McGarrell DM, Sun Y, et al. Ribosomal Database Project: data and tools for high throughput rRNA analysis. Nucleic Acids Res. 2014;42(D1):D633-D642. https://doi.org/10.1093/nar/gkt1244.

42. Keck F, Couton M, Altermatt F. Navigating the seven challenges of taxonomic reference databases in metabarcoding analyses. Mol Ecol Resour. 2023;23(4):742-755. https://doi.org/10.1111/1755-0998.13746.

43. Balvočiūtė M, Huson DH. SILVA, RDP, Greengenes, NCBI and OTT — how do these taxonomies compare? BMC Genomics. 2017;18(Suppl 2):114. https://doi.org/10.1186/s12864-017-3501-4.

44. Bolyen E, Rideout JR, Dillon MR, Bokulich NA, Abnet CC, Al-Ghalith GA, et al. Reproducible, interactive, scalable and extensible microbiome data science using QIIME 2. Nat Biotechnol. 2019;37:852-857. https://doi.org/10.1038/s41587-019-0209-9.

45. Srivastava A, Akhter Y, Verma D. A step-by-step procedure for analysing the 16S rRNA-based microbiome diversity using QIIME 2 and comprehensive PICRUSt2 illustration for functional prediction. Arch Microbiol. 2024;206:467. https://doi.org/10.1007/s00203-024-04177-z.

46. Almeida A, Mitchell AL, Tarkowska A, Finn RD. Benchmarking taxonomic assignments based on 16S rRNA gene profiling of the microbiota from commonly sampled environments. GigaScience. 2018;7(5):giy054. https://doi.org/10.1093/gigascience/giy054.

47. Dubois B, Debode F, Hautier L, Hulin J, San Martin G, Delvaux A, et al. A detailed workflow to develop QIIME2-formatted reference databases for taxonomic analysis of DNA metabarcoding data. BMC Genom Data. 2022;23:53. https://doi.org/10.1186/s12863-022-01067-5.

48. Schloss PD, Westcott SL, Ryabin T, Hall JR, Hartmann M, Hollister EB, et al. Introducing mothur: open-source, platform-independent, community-supported software for describing and comparing microbial communities. Appl Environ Microbiol. 2009;75. https://doi.org/10.1128/AEM.01541-09.

49. Rognes T, Flouri T, Nichols B, Quince C, Mahé F. VSEARCH: a versatile open source tool for metagenomics. PeerJ. 2016;4:e2584. https://doi.org/10.7717/peerj.2584.

50. McMurdie PJ, Holmes S. phyloseq: an R package for reproducible interactive analysis and graphics of microbiome census data. PLoS One. 2013;8(4):e61217. https://doi.org/10.1371/journal.pone.0061217.

51. Lahti L, Shetty S. microbiome R package. Bioconductor. 2017. https://doi.org/10.18129/B9.bioc.microbiome.

52. Oksanen J, Simpson G, Blanchet F, Kindt R, Legendre P, Minchin P, et al. vegan: Community Ecology Package. R package version 2.8-0. 2025. https://vegandevs.github.io/vegan/.

53. Watson SE, Hauffe HC, Bull MJ, Atwood TC, McKinney MA, Pindo M, et al. Global change-driven use of onshore habitat impacts polar bear faecal microbiota. ISME J. 2019;13(12):2916-2926. https://doi.org/10.1038/s41396-019-0480-2.

54. Franz M, Whyte L, Atwood TC, Laidre KL, Roy D, Watson SE, et al. Distinct gut microbiomes in two polar bear subpopulations inhabiting different sea ice ecoregions. Sci Rep. 2022;12:522. https://doi.org/10.1038/s41598-021-04340-2.

55. Franz M, Whyte L, Atwood TC, Menning D, Sonsthagen SA, Talbot SL, et al. Fecal DNA metabarcoding shows credible short-term prey detections and explains

variation in the gut microbiome of two polar bear subpopulations. Mar Ecol Prog Ser. 2023;704:131-147. https://doi.org/10.3354/meps14228.

56. Andrews S. FastQC: A quality control tool for high throughput sequence data. 2010. Available from: http://www.bioinformatics.babraham.ac.uk/projects/fastqc/
57. Ewels P, Magnusson M, Lundin S, Käller M. MultiQC: summarize analysis results for multiple tools and samples in a single report. Bioinformatics. 2016;32(19):3047–8. https://doi.org/10.1093/bioinformatics/btw354
58. Magoč T, Salzberg SL. FLASH: fast length adjustment of short reads to improve genome assemblies. Bioinformatics. 2011;27(21):2957–63. https://doi.org/10.1093/bioinformatics/btr507
59. R Core Team. R: a language and environment for statistical computing [R software]. Version 4.2.0; 2022. Available from: https://www.R-project.org/
60. Robeson MS, O'Rourke DR, Kaehler BD, Ziemski M, Dillon MR, Foster JT, et al. RESCRIPt: reproducible sequence taxonomy reference database management. PLoS Comput Biol. 2021;17(11):e1009581. https://doi.org/10.1371/journal.pcbi.1009581
61. Bokulich NA, Kaehler BD, Rideout JR, Dillon M, Bolyen E, Knight R, et al. Optimizing taxonomic classification of marker-gene amplicon sequences with QIIME 2's q2-feature-classifier plugin. Microbiome. 2018;6(1):90. https://doi.org/10.1186/s40168-018-0470-z
62. Pedregosa F, Varoquaux G, Gramfort A, Michel V, Thirion B, Grisel O, et al. Scikit-learn: machine learning in Python. J Mach Learn Res. 2011;12:2825–30.
63. Illumina. Effects of index misassignment on multiplexing and downstream analysis. 2017. Available from: https://www.illumina.com/
64. McMurdie PJ, Holmes S. phyloseq: reproducible interactive analysis and graphics of microbiome census data [R package]. Version 1.52.0; 2025. Available from: https://cran.r-project.org/package=phyloseq
65. McMurdie PJ, Paulson JN. biomformat: an interface package for the BIOM file format [R package]. Version 1.39.0; 2025. Available from: https://doi.org/10.18129/B9.bioc.biomformat
66. Wickham H, Averick M, Bryan J, Chang W, McGowan LD, François R, et al. tidyverse: easily install and load the tidyverse [R package]. Version 2.0.0; 2023. Available from: https://cran.r-project.org/package=tidyverse

67. Wickham H. ggplot2: Elegant Graphics for Data Analysis [R package]. Version 4.0.0; 2016. Available from: https://ggplot2.tidyverse.org
68. Sievert C. plotly: create interactive web graphics via plotly.js [R package]. Version 4.11.0; 2024. Available from: https://cran.r-project.org/package=plotly
69. Vaidyanathan R, Xie Y, Allaire J, Cheng J, Sievert C, Russell K. htmlwidgets: HTML widgets for R [R package]. Version 1.6.4; 2025. Available from: https://cran.r-project.org/package=htmlwidgets
70. Shannon CE. A mathematical theory of communication. Bell Syst Tech J. 1948;27(3):379–423. https://doi.org/10.1002/j.1538-7305.1948.tb01338.x
71. Chao A. Nonparametric estimation of the number of classes in a population. Scand J Stat. 1984;11:265–70. https://www.jstor.org/stable/4615964
72. Simpson EH. Measurement of diversity. Nature. 1949;11(4):163-688. https://doi.org/10.1038/163688a0
73. Kassambara A. ggpubr: ggplot2-based publication ready plots [R package]. Version 0.6.2; 2025. Available from: https://cran.r-project.org/package=ggpubr
74. Wilcoxon F. Individual comparisons by ranking methods. Biometrics. 1945;1(6):80–3. https://doi.org/10.2307/3001968
75. Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. J R Stat Soc Ser B. 1995;57(1):289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x
76. Bray JR, Curtis JT. An ordination of upland forest communities of southern Wisconsin. Ecol Monogr 1957;27(4):325–49. https://doi.org/10.2307/1942268
77. Kruskal JB. Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. Psychometrika. 1964;29(1):1–27. https://doi.org/10.1007/BF02289565
78. Oksanen J, Blanchet FG, Friendly M, Kindt R, Legendre P, McGlinn D, et al. vegan: community ecology package [R package]. Version 2.7-2; 2025. Available from: https://cran.r-project.org/package=vegan
79. Wickham H, François R, Henry L, Müller K, Vaughan D. dplyr: a grammar of data manipulation [R package]. Version 1.1.4; 2026. Available from: https://cran.r-project.org/package=dplyr
80. Anderson MJ. A new method for non-parametric multivariate analysis of variance. Austral Ecol. 2001;26:32–46. https://doi.org/10.1111/j.1442-9993.2001.01070.pp.x
81. Anderson MJ. Distance-based tests for homogeneity of multivariate dispersions. Biometrics. 2006;62(1):245–53. https://doi.org/10.1111/j.1541-0420.2005.00440.x

82. Estaki M, Jiang L, Bokulich NA, McDonald D, González A, Kosciolek T, et al. QIIME 2 enables comprehensive end-to-end analysis of diverse microbiome data and comparative studies with publicly available data. Curr Protoc Bioinformatics. 2020;70(1):e100. https://doi.org/10.1002/cpbi.100
83. Dhariwal A, Chong J, Habib S, King IL, Agellon LB, Xia J. MicrobiomeAnalyst: a web-based tool for comprehensive statistical, visual and meta-analysis of microbiome data. Nucleic Acids Res. 2017;45(W1):W180-8. https://doi.org/10.1093/nar/gkx295
84. Chong J, Liu P, Zhou G, Xia J. Using MicrobiomeAnalyst for comprehensive statistical, functional, and meta-analysis of microbiome data. Nat Protoc. 2020;15(3):799-821. https://doi.org/10.1038/s41596-019-0264-1
85. Lu Y, Zhou G, Ewald J, Pang Z, Shiri T, Xia J. MicrobiomeAnalyst 2.0: comprehensive statistical, functional and integrative analysis of microbiome data. Nucleic Acids Res. 2023;51(W1):W310-8. https://doi.org/10.1093/nar/gkad407
86. Martin M. Cutadapt removes adapter sequences from high-throughput sequencing reads. EMBnet J. 2011;17(1):10-2. https://doi.org/10.14806/ej.17.1.200
87. Lindgreen S. AdapterRemoval: easy cleaning of next-generation sequencing reads. BMC Res Notes. 2012;5:337. https://doi.org/10.1186/1756-0500-5-337
88. Bolger AM, Lohse M, Usadel B. Trimmomatic: a flexible trimmer for Illumina sequence data. Bioinformatics. 2014;30(15):2114-20. https://doi.org/10.1093/bioinformatics/btu170
89. Han H, Lee HJ, Kim KS, Chung J, Na HS. Comparison of the performance of MiSeq and NovaSeq in oral microbiome study. J Oral Microbiol. 2024;16(1):2344293. https://doi.org/10.1080/20002297.2024.2344293
90. Bharti R, Grimm DG. Current challenges and best-practice protocols for microbiome analysis. Brief Bioinform. 2021;22(1):178-93. https://doi.org/10.1093/bib/bbz155
91. Weinstein MM, Prem A, Jin M, Tang S, Bhasin JM. FIGARO: an efficient and objective tool for optimizing microbiome rRNA gene trimming parameters. bioRxiv. 2019;610394. https://doi.org/10.1101/610394
92. Doni L, Marotta A, Vezzulli L, Bosi E. AmpWrap: a one-line fully automated amplicon metabarcoding 16S and 18S rRNA gene analysis. Bioinform Adv. 2025;5(1):vbaf312. https://doi.org/10.1093/bioadv/vbaf312
93. Esling P, Lejzerowicz F, Pawlowski J. Accurate multiplexing and filtering for high-throughput amplicon-sequencing. Nucleic Acids Res. 2015;43(5):2513-24. https://doi.org/10.1093/nar/gkv107

94. Schnell IB, Bohmann K, Gilbert MTP. Tag jumps illuminated. Mol Ecol Resour. 2015;15(6):1289-303. https://doi.org/10.1111/1755-0998.12402
95. Bartram J, Mountjoy E, Brooks T, Hancock J, Williamson H, Wright G, et al. Accurate sample assignment in a multiplexed sequencing assay. J Mol Diagn. 2016;18(4):494-506. https://doi.org/10.1016/j.jmoldx.2016.02.008
96. Martin WF, Garg S, Zimorski V. Endosymbiotic theories for eukaryote origin. Philos Trans R Soc Lond B Biol Sci. 2015;370(1678). https://doi.org/10.1098/rstb.2014.0330
97. Smith DR, Keeling PJ. Mitochondrial and plastid genome architecture. Proc Natl Acad Sci USA. 2015;112(33):10177-84. https://doi.org/10.1073/pnas.1422049112
98. Beckers B, Op De Beeck M, Thijs S, Truyens S, Weyens N, Boerjan W, et al. Performance of 16S rDNA primer pairs. Front Microbiol. 2016;7:650. https://doi.org/10.3389/fmicb.2016.00650
99. Salter SJ, Cox MJ, Turek EM, Calus ST, Cookson WO, Moffatt MF, et al. Reagent contamination can impact microbiome analyses. BMC Biol. 2014;12:87. https://doi.org/10.1186/s12915-014-0087-z
100. Lazarevic V, Gaïa N, Girard M, Schrenzel J. Decontamination of 16S rRNA datasets. BMC Microbiol. 2016;16:73. https://doi.org/10.1186/s12866-016-0689-4
101. Davis NM, Proctor DM, Holmes SP, Relman DA, Callahan BJ. Removal of contaminant sequences. Microbiome. 2018;6(1):226. https://doi.org/10.1186/s40168-018-0605-2
102. Wang Q, Garrity GM, Tiedje JM, Cole JR. Naive Bayesian classifier. Appl Environ Microbiol. 2007;73(16):5261-7. https://doi.org/10.1128/AEM.00062-07
103. Camacho C, Coulouris G, Avagyan V, Ma N, Papadopoulos J, Bealer K, et al. BLAST+. BMC Bioinformatics. 2009;10:421. https://doi.org/10.1186/1471-2105-10-421
104. Buetas E, Jordán-López M, López-Roldán A, D'Auria G, Martínez-Priego L, De Marco G, et al. Full-length 16S rRNA gene sequencing by PacBio. BMC Genomics. 2024;25(1):310. https://doi.org/10.1186/s12864-024-10213-5
105. Chuvochina M, Gerken J, Frentrup M, Sandikci Y, Goldmann R, Freese HM, et al. SILVA in 2026: a global core biodata resource for rRNA within the DSMZ digital diversity. Nucleic Acids Res. 2026;54(D1):D334–41. https://doi.org/10.1093/nar/gkaf1247

106. Edgar RC. Taxonomy annotation and guide tree errors in 16S rRNA databases. PeerJ. 2018;6:e5030. https://doi.org/10.7717/peerj.5030

107. Commichaux S, Luan T, Muralidharan HS, Pop M. Database size positively correlates with the loss of species-level taxonomic resolution for the 16S rRNA and other prokaryotic marker genes. PLoS Comput Biol. 2024;20(8):e1012343. https://doi.org/10.1371/journal.pcbi.1012343

108. Latz MA, Grujcic V, Brugel S, Lycken J, John U, Karlson B, et al. Short- and long-read metabarcoding of the eukaryotic rRNA operon: evaluation of primers and comparison to shotgun metagenomics sequencing. Mol Ecol Resour. 2022;22(6):2304-18. https://doi.org/10.1111/1755-0998.13623

109. Chwalińska M, Karlicki M, Romac S, Not F, Karnkowska A. From short to long reads: enhanced protist diversity profiling via Nanopore metabarcoding. Metabarcoding Metagenomics. 2025;9:e163750. https://doi.org/10.3897/mbmg.9.163750

110. McMurdie PJ, Holmes S. Waste not, want not. PLoS Comput Biol. 2014;10(4):e1003531. https://doi.org/10.1371/journal.pcbi.1003531

111. Cameron ES, Schmidt PJ, Tremblay BJM, Emelko MB, Müller KM. Enhancing diversity analysis. Sci Rep. 2021;11(1):22302. https://doi.org/10.1038/s41598-021-01636-1

112. Schloss PD. Rarefaction is currently the best approach. mSphere. 2024;9(2):e00354-23. https://doi.org/10.1128/msphere.00354-23

113. Kers JG, Saccenti E. The power of microbiome studies: some considerations on which alpha and beta metrics to use and how to report results. Front Microbiol. 2022;12:796025. https://doi.org/10.3389/fmicb.2021.796025

114. Cassol I, Ibañez M, Bustamante JP. Key features and guidelines for the application of microbial alpha diversity metrics. Sci Rep. 2025;15(1):622. https://doi.org/10.1038/s41598-024-77864-y

115. Wang L, Huang G, Li G, Yuan S, Wei F. Updating conservation metagenomics on the gut microbiome of threatened mammals. iScience. 2025;28(7):113000. https://doi.org/10.1016/j.isci.2025.113000

116. Lin H, Peddada SD. Analysis of compositions of microbiomes with bias correction. Nat Commun. 2020;11(1):3514. https://doi.org/10.1038/s41467-020-17041-7

117. Schloss PD, Gevers D, Westcott SL. Reducing the effects of PCR amplification and sequencing artifacts on 16S rRNA-based studies. PLoS One. 2011;6(12):e27310. https://doi.org/10.1371/journal.pone.0027310

118. Matesanz S, Pescador DS, Pías B, Sánchez AM, Chacón-Labella J, Illuminati A, et al. Estimating belowground plant abundance with DNA metabarcoding. Mol Ecol Resour. 2019;19(5):1265–1277. https://doi.org/10.1111/1755-0998.13049

119. Compson ZG, McClenaghan B, Singer GA, Fahner NA, Hajibabaei M. Metabarcoding from microbes to mammals: comprehensive bioassessment on a global scale. Front Ecol Evol. 2020;8:581835. https://doi.org/10.3389/fevo.2020.581835.

120. Pascoe EL, Hauffe HC, Marchesi JR, Perkins SE. Network analysis of gut microbiota literature: an overview of the research landscape in non-human animal studies. ISME J. 2017;11(12):2644-2651. https://doi.org/10.1038/ismej.2017.133

121. Worsley SF, Videvall E, Harrison XA, Björk JR, Mazel F, Wanelik KM. Probing the functional significance of wild animal microbiomes using omics data. Funct Ecol. 2024;38(11):2329-2349. https://doi.org/10.1111/1365-2435.14650

122. West AG, Waite DW, Deines P, Bourne DG, Digby A, McKenzie VJ, et al. The microbiome in threatened species conservation. Biol Conserv. 2019;229:85-98. https://doi.org/10.1016/j.biocon.2018.11.016

123. Littleford-Colquhoun BL, Weyrich LS, Hohwieler K, Cooper A, Austin JJ, Sherratt E, et al. How microbiomes can help inform conservation: landscape characterisation of gut microbiota helps shed light on additional population structure in a specialist folivore. Anim Microbiome. 2022;4:12. https://doi.org/10.1186/s42523-021-00122-3

124. Nagati M, Bergeron MJ, Gagné P, Arsenault A, Droit A, Wilson P, et al. Exploring winter diet, gut microbiota and parasitism in caribou using multi marker metabarcoding of fecal DNA. Sci Rep. 2024;14:27960. https://doi.org/10.1038/s41598-024-76594-5