Análisis del perfil transcriptómico unicelular de células B circulantes en cáncer de pulmón no microcítico.

Titulación:
Máster Universitario en Bioinformática
Curso académico
2025 – 2026

Alumno/a: Gutiérrez Escobedo, Juan Manuel
D.N.I: 78768898Q

Director de TFM: López Zaplana, Álvaro

Convocatoria:

Primera

9 Mar 2026

De:
Planeta Formación y Universidades

Quiero agradecer al grupo de Microambiente Tumoral en el Hospital Universitario Puerta del Hierro, al que pertenezco, por el apoyo y el buen ambiente de trabajo. En especial, gracias a Alberto Cruz Bermúdez por la confianza y orientación, y a Marta Molina, Cristina Martínez y Belén Sierra por su ayuda y cercanía. Agradezco también a los técnicos Ana Isabel, Daniel y Sergio por su apoyo diario.

Un agradecimiento muy especial a Ángeles Gil, cuya ayuda al inicio fue fundamental. Gracias a los artículos y libros que me facilitó, pude empezar a comprender el análisis de datos de célula única y sentar las bases de este trabajo.

ÍNDICE

1. Introducción 6

1.1. Cáncer de pulmón 6
1.2. Estudios NADIM 7
1.3. Células B 9
1.4. Ciencias ómicas: tecnología de célula única 11
1.5. Justificación del trabajo 12

2. Objetivos 13

2.1. Generales 13
2.2. Específicos 13

3. Metodología 14

3.1. Diseño experimental y obtención de datos. 14
3.1.1. Selección de muestras y estrategia de secuenciación 14

3.2. Análisis bioinformático 15
3.2.1. Procesamiento de los datos crudos 15
3.2.2. Control de calidad: Detección y eliminación de dobletes. 17
3.2.3. Control de calidad: Filtrado de células de baja calidad 18
3.2.4. Normalización y reducción de dimensionalidad, ... 19
3.2.5. Análisis de agrupamiento y anotación 20
3.2.6. Células B 22

4. Resultados y Discusión 24

4.1. Preanálisis 24
4.2. Representación PBMCs 26
4.3. Anotación 29
4.4. Representación células B 34
4.5. Análisis en la proporción de número de células 38
4.6. Análisis de los genes diferentemente expresados 39
4.7. Análisis de las rutas diferentemente expresadas 42

5. Conclusiones 48
6. Limitaciones y perspectivas futuras 49
7. Bibliografía 50

Lista de abreviaturas

NSCLC Cáncer de pulmón de célula no pequeña o no microcítico (de sus siglas en inglés).

TNM Tumor – Nodo – Metástasis. Estadificación para pacientes con NSCLC

NADIM Acrónimo en inglés de "*Neoadjuvant chemotherapy and immunotherapy in resectable stage IIIA non-small cell lung cancer".*

PD-1 Acrónimo en ingles de "*Programmed death-1*".

PD-L1 Acrónimo en ingles de "*Programmed death-Ligand-1*".

ICP Imagen de creación propia.

CPR Respuesta patológica completa (de sus siglas en inglés).

NCPR No respuesta patológica completa (de sus siglas en inglés).

TLS Estructuras linfoides terciarias.

CBn Células B naïve.

CB mem Células B de memoria.

CB mem C Células B de memoria con cambio de clase.

CB mem NC Células B de memoria sin cambio de clase.

ScRNA-seq Secuenciación del ARN de células única (de sus siglas en inglés).

PBMC Células mononucleares de sangre periférica (de sus siglas en inglés).

C Comando.

PRE Pretratamiento.

POST Postneoadyuvancia.

N.E. No Evaluable

PCA Análisis de componentes principales (de sus siglas en inglés).

UMAP Aproximación y proyección uniforme de variedades (de sus siglas en inglés).

NK Células "*Natural Kiler*".

GSEA Análisis de enriquecimiento de conjuntos de genes (de sus siglas en inglés).

NcRNAs ARN largos no codificantes.

NES Puntaje de enriquecimiento normalizado (de sus siglas en inglés).

Índice de tablas

Tabla 1: Tratamiento, Respuesta, Umbral de corte y Porcentaje filtrado de células por muestra. ICP. 18
Tabla 2: Genes utilizados para la anotación de los diferente tipos células tanto en células PBMC como en células B. ICP. 22

Índice de gráficos

Gráfico 1: Ejemplo de la representación del valor de probabilidad de dobletes calculado por Scrublet. Imagen obtenida de la documentación Scrublet (pincha aquí) 17
Gráfico 2: Ejemplo del comando “ElbowPlot()”. ICP. 20
Gráfico 3: Gráfico de violines de Nº. Genes, Nº.Lecturas y Porcentaje de genes Mitocondriales por muestra. ICP. 25
Gráfico 4: Gráfico de burbujas que muestra los 10 genes con mayor expresión diferencial entre los distintos grupos de células B. ICP. 35
Gráfico 5: Gráfico de violines según el porcentaje de células en relación con su progenitor más cercano respecto a los diferentes tipos celulares de CB. ICP. 38
Gráfico 6: Gráfico de volcanes por los diferentes tipos celulares de células B tanto en pretratamiento como en postneoadyuvancia. ICP. 41

Índice de figuras

Figura 1: Esquema resumen de los estudios NADIM. Imagen de creación propia (ICP). 8
Figura 2: Evolución de las células B. ICP. 10

Figura 3: Flujo de procesamiento de datos de scRNA-seq. ICP. 16
Figura 4: Representación UMAP de todas las células coloreado por muestra (A y B). ICP. 26
Figura 5: Representación UMAP coloreada por paciente, por extracción, por respuesta y por sexo. ICP. 28
Figura 6: Representación UMAP coloreada según el resultado de análisis de agrupamiento. ICP. 29
Figura 7: Representación UMAP coloreada según la distribución de los tipos celulares. ICP. 30
Figura 8: Gráfico de violines según el nivel de expresión de algunos genes respecto a los diferentes tipos celulares. ICP. 31
Figura 9: Representación UMAP de 12 genes representativos de los diferentes tipos celulares. ICP. 33
Figura 10: Representación UMAP coloreada según los resultados de análisis de agrupamiento sin ajustar con regresión de los genes ribosómicos. ICP. 34
Figura 11: Representación UMAP coloreada según los resultados de análisis de agrupamiento ajustado con regresión de los genes ribosómicos. ICP. 36
Figura 12: Representación UMAP coloreada según la distribución de los tipos celulares en células B. ICP. 36
Figura 13: Representación UMAP de 7 genes representativos de los diferentes tipos subtipos de células B. ICP. 37
Figura 14: Representación del análisis de GSEA en las Células B. ICP. 42
Figura 15: Representación del análisis de GSEA en las Células B memoria. ICP. 43
Figura 16: Representación del análisis de GSEA en las Células B memoria con cambio de clase. ICP. 44
Figura 17: Representación del análisis de GSEA en las Células B memoria sin cambio de clase. ICP. 45
Figura 18: Representación del análisis de GSEA en las Células B naïve. ICP. 46

Resumen y palabras clave

El cáncer de pulmón de células no pequeñas representa aproximadamente el 80 % de los cánceres de pulmón y es una de las principales causas de mortalidad por cáncer a nivel mundial. Los ensayos clínicos NADIM evalúan la combinación de quimioterapia e inmunoterapia con el objetivo de mejorar la respuesta terapéutica en pacientes en estadios avanzados. En este contexto, las células B podrían desempeñar un papel relevante en la respuesta al tratamiento.

Con el objetivo de identificar diferencias inmunológicas en las células B, se realiza un análisis de transcriptómica de célula única en células mononucleares de sangre periférica de pacientes antes del tratamiento y tras la neoadyuvancia, utilizando tecnología 10x Genomics. El análisis bioinformático incluye control de calidad, normalización, análisis estadístico y funcional.

Aunque no se observan diferencias significativas en la abundancia de los subtipos de células B entre pacientes con tumores con respuesta patológica completa y no completa, sí se identifican diferencias en la expresión génica y en la activación de rutas inmunológicas en ambos momentos temporales. Los pacientes con tumores con respuesta patológica completa muestran una mayor activación de rutas relacionadas con la respuesta inmunitaria, especialmente tras el tratamiento, lo que sugiere la existencia de una predisposición inmunológica asociada a una mayor actividad funcional de las células B.

Palabras clave: cáncer de pulmón de células no pequeñas, scRNA-seq, células B, PBMCs, inmunoterapia

1.Introducción

1.1. Cáncer de pulmón

El cáncer de pulmón es la principal causa de mortalidad por cáncer a nivel mundial. El 85% de todos estos casos pertenecen al cáncer de pulmón de célula no pequeña o no microcítico (NSCLC, de sus siglas en inglés) (1–4). El NSCLC es una enfermedad heterogénea, tanto desde el punto de vista histológico como molecular, lo cual tiene implicaciones directas en el pronóstico y en las opciones terapéuticas disponibles. El adenocarcinoma es el subtipo más frecuente y suele originarse en la periferia del pulmón; es también el tipo más habitual en personas no fumadoras. El carcinoma de células escamosas, por el contrario, se asocia fuertemente al consumo de tabaco y tiende a localizarse en regiones centrales, como los bronquios principales. El carcinoma de células grandes representa un porcentaje menor y se diagnostica por exclusión cuando el tumor carece de características glandulares o escamosas definidas (5).

La estadificación del NSCLC se basa en el sistema TNM (Tumor, Nodo, Metástasis), propuesto por la *International Association for the Study of Lung Cancer*. Este sistema permite clasificar la extensión anatómica de la enfermedad considerando el tamaño tumoral y su invasión local (T), la afectación de ganglios linfáticos regionales (N) y la presencia o ausencia de metástasis a distancia (M). Las combinaciones de estos parámetros se agrupan en estadios clínicos que van desde el estadio I, enfermedad localizada hasta el estadio IV, enfermedad metastásica. Los estadios I y II corresponden a tumores confinados al pulmón o con afectación ganglionar limitada y suelen ser candidatos a cirugía con intención curativa (supervivencia del 92,8% y 78,7% a un año y 68,4% y 45,1% a 5 años respectivamente). El estadio III se considera localmente avanzado, con afectación ganglionar mediastínica o estructuras adyacentes (supervivencia de un 54,3% a un año y 17,3% a 5 años), mientras que el estadio IV implica metástasis a distancia (supervivencia del 31,3% a un año y 5,8% a 5 años) (5–7).

La operabilidad y la resecabilidad son criterios clave en el manejo del NSCLC, ya que determinan la viabilidad del tratamiento quirúrgico. La primera evalúa la capacidad del

paciente para tolerar la cirugía, mientras que la segunda valora la posibilidad técnica de extirpar completamente el tumor. En general, los estadios I, II y algunos IIIA pueden ser operables si el paciente presenta buen estado funcional. Por el contrario, los estadios IIIB, IIIC y IV se consideran no operables, tratándose habitualmente con combinaciones de quimioterapia y radioterapia (8,9).

El manejo del estadio IIIA del NSCLC es particularmente complejo, ya que puede considerarse potencialmente operable en determinados casos seleccionados, especialmente cuando la resección completa del tumor es factible tras una evaluación multidisciplinaria. La cirugía suele combinarse con quimioterapia, inmunoterapia y radioterapia, administradas de forma neoadyuvante, antes de la intervención para reducir el tamaño del tumor y aumentar la probabilidad de resección completa, o adyuvante, tras la cirugía, para eliminar células tumorales residuales y disminuir el riesgo de recurrencia (10,11).

1.2. Estudios NADIM

La cirugía y la quimioterapia adyuvante o neoadyuvante constituían las estrategias estándar para los pacientes con NSCLC en estadio IIIA resecable. Sin embargo, los resultados seguían siendo subóptimos: incluso con resecciones completas y quimioterapia, la mayoría de los pacientes en estadio IIIA recaían debido a la presencia de enfermedad micrometastásica no detectable al diagnóstico. Esto planteo a los clínicos la necesidad de explorar terapias sistémicas más eficaces. Los inhibidores de puntos de control inmunitario, como el nivolumab, habían demostrado una mejora significativa en la supervivencia global en pacientes con enfermedad metastásica, lo que impulsó su evaluación en etapas más tempranas del cáncer, donde el sistema inmunitario del huésped aún conserva una capacidad funcional más robusta (12,13)

Es por ello que surgen los estudios NADIM (acrónimo en inglés de *Neoadjuvant chemotherapy and immunotherapy in resectable stage IIIA non-small cell lung cancer*) un estudio de fase II, multicéntrico y abierto, que incluyó pacientes con NSCLC en estadio clínico IIIA resecable, con buen estado funcional y sin mutaciones activadoras de EGFR ni

reordenamientos de ALK, dado que estos subgrupos presentan un comportamiento biológico distinto y responden mejor a terapias dirigidas específicas. Los participantes recibieron tres ciclos de quimioterapia (paclitaxel y carboplatino) combinados con inmunoterapia (nivolumab) como tratamiento neoadyuvante, seguidos de cirugía radical y posteriormente nivolumab adyuvante durante un año (***Figura 1***) (14,15).

Nivolumab es un anticuerpo monoclonal IgG4 humano dirigido contra el receptor PD-1 (acrónimo en ingles de programmed death-1), expresado en la superficie de los linfocitos T activados. Al unirse a PD-1, nivolumab bloquea su interacción con los ligandos PD-L1 y PD-L2, que suelen estar sobreexpresados en las células tumorales y en células inmunosupresoras del microambiente tumoral. Este bloqueo impide la señal inhibitoria que normalmente reduce la actividad de los linfocitos T, restaurando así su capacidad de proliferar, producir citocinas y destruir las células tumorales. En consecuencia, nivolumab reactiva la respuesta inmune antitumoral que el cáncer había suprimido mediante la vía PD-1/PD-L1 (15,16).

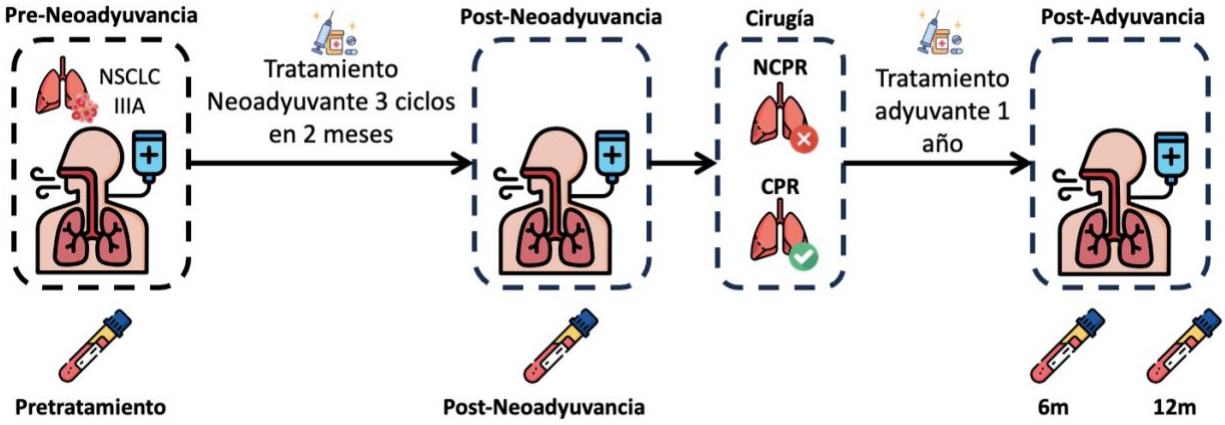

Figura 1: Esquema resumen de los estudios NADIM. Imagen de creación propia (ICP).

El diagrama muestra el proceso de tratamiento de pacientes con NSCLC en estadio IIIA: tras la inclusión, los pacientes reciben quimioterapia e inmunoterapia neoadyuvante durante 3 ciclos en 2 meses, seguida de cirugía para resecar el tumor y evaluar la respuesta patológica completa (CPR) o no completa (NCPR). Posteriormente, los pacientes reciben tratamiento adyuvante durante 1 año. Se recogen muestras de sangre periférica en diferentes momentos: antes del tratamiento neoadyuvante, tras la neoadyuvancia, así como a los 6 y 12 meses post cirugía, para el análisis inmunológico y molecular.

Los resultados de este ensayo clínicos fueron publicados en *The Lancet Oncology* (2020). La combinación de nivolumab con quimioterapia neoadyuvante logró resultados clínicos sin precedentes, con una supervivencia libre de progresión del 77,1 % y una supervivencia global a 24 meses del 90 %, superando ampliamente las cifras históricas obtenidas con quimioterapia sola (15).

En los estudios NADIM, la respuesta patológica completa (CPR, de sus siglas en inglés), definida como la ausencia total de células tumorales viables en la pieza quirúrgica tras la terapia neoadyuvante, se consolidó como un fuerte predictor de beneficio clínico y supervivencia a largo plazo, en contraste con los pacientes que no alcanzaron dicha respuesta (NCPR, de sus siglas en inglés), quienes presentaron mayores tasas de recaída y peor pronóstico. Esta diferencia entre CPR y NCPR refleja la capacidad del tratamiento combinado de nivolumab y quimioterapia para inducir una erradicación tumoral más profunda y una respuesta inmunitaria más eficaz, confirmando el valor de la CPR como biomarcador pronóstico clave en el cáncer de pulmón localmente avanzado resecable (14,15).

1.3. Células B

Las células B son linfocitos fundamentales del sistema inmunitario adaptativo, tradicionalmente conocidas por su capacidad de producir anticuerpos, presentar antígenos y modular la respuesta de linfocitos T. En los últimos años, han emergido como actores clave en la inmunidad antitumoral, particularmente mediante su participación en la formación de estructuras linfoides terciarias (TLS) dentro de los tumores. Estos TLS actúan como microambientes organizados que facilitan la interacción entre células B, células T y células dendríticas, promoviendo respuestas inmunes efectivas. La evidencia creciente sugiere que la presencia de células B y TLS en el tumor se correlaciona con una mayor probabilidad de alcanzar una respuesta patológica completa tras tratamientos neoadyuvantes como la combinación de quimioterapia e inmunoterapia, lo que resalta la importancia de estudiar este subconjunto celular para entender los mecanismos de eficacia terapéutica y potencialmente identificar biomarcadores predictivos de respuesta (17).

Las células B presentan diversos estados de diferenciación y funciones especializadas (***Figura 2***). Las células naïve (CBn) son linfocitos vírgenes que aún no han encontrado su antígeno específico y circulan principalmente por ganglios y sangre periférica, listas para activarse frente a nuevas amenazas. Las células memoria (CB mem) se generan tras la activación antigénica y permiten respuestas más rápidas y robustas en reexposiciones; se

clasifican en memoria con cambio de isotipo (CB mem C), que han cambiado la clase de inmunoglobulina y producen anticuerpos especializados como IgG o IgA, y memoria sin cambio de isotipo (CB mem NC) que conservan IgM y sirven como reserva rápida de activación inicial. Por otro lado, los plasmablastos son células B efectoras activas en secreción de anticuerpos y son clave para la eliminación de antígenos, aunque su vida útil es relativamente corta, tras ellos estas se diferencian en células plasmáticas. En el contexto tumoral, el análisis de estos subtipos de células B en sangre periférica permite evaluar de manera accesible y dinámica el estado del sistema inmunitario del paciente, proporcionando información sobre la activación, expansión y memoria de las células B que podría correlacionarse con la respuesta al tratamiento y la probabilidad de alcanzar CPR, sin necesidad de recurrir exclusivamente a muestras tumorales invasivas (17–19).

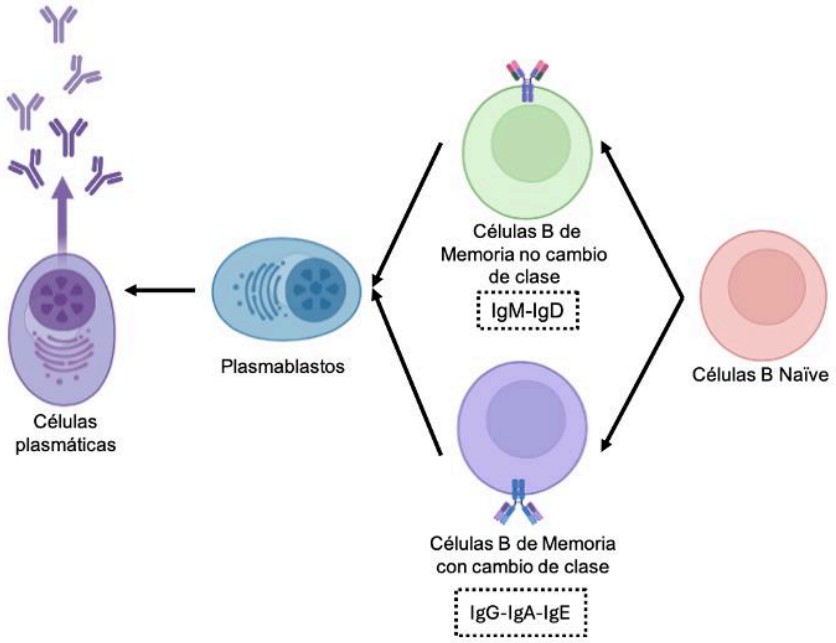

Figura 2: Evolución de las células B. ICP.

Esquema que representa los diferentes subtipos de células B y su evolución tras la exposición a un antígeno. Se inicia con células B naïve, que aún no han encontrado antígeno, y progresan hacia células B de memoria: las células B de memoria con cambio de clase producen IgG, IgA o IgE, mientras que las células B de memoria sin cambio de clase conservan IgM e IgD. Posteriormente, las células B se diferencian en plasmablastos y finalmente en células plasmáticas, responsables de la secreción sostenida de anticuerpos.

1.4. Ciencias ómicas: tecnología de célula única

Las ciencias ómicas son disciplinas que permiten el estudio global y sistemático de distintos componentes biológicos en células, tejidos u organismos, incluyendo genómica, transcriptómica, proteómica, epigenómica y metabolómica, entre otras. Su objetivo es comprender de manera integral la complejidad biológica, identificando patrones moleculares, redes de regulación y biomarcadores asociados a procesos fisiológicos o patológicos. En el contexto del cáncer y la inmunología, las aproximaciones ómicas han permitido caracterizar la heterogeneidad tumoral, los subtipos celulares y la interacción entre el microambiente tumoral y el sistema inmunitario, ofreciendo nuevas oportunidades para identificar predictores de respuesta terapéutica y desarrollar estrategias personalizadas (20,21).

Dentro de este marco, las técnicas de célula única han revolucionado la biología moderna al permitir el estudio de la heterogeneidad celular de manera individual, algo que los análisis convencionales de tejido completo no pueden ofrecer. Estas técnicas incluyen, entre otras, *single-cell RNA sequencing* (scRNA-seq), que analiza la expresión génica a nivel individual; *single-cell ATAC-seq*, que evalúa la accesibilidad cromática; y *mass cytometry* (CyTOF) o CITE-seq, que combinan análisis proteico y transcriptómico en células individuales. Cada enfoque proporciona información complementaria sobre la identidad celular, el estado funcional y la dinámica de activación, diferenciación o respuesta a estímulos (20).

El análisis de datos de célula única implica varias etapas. En primer lugar, se realiza la aislación de células individuales, que puede lograrse mediante microfluídica, FACS (*fluorescence-activated cell sorting*) o emulsiones en gotitas. Posteriormente, se realiza la captura de moléculas de interés (ARN, ADN, proteínas), que se preparan para secuenciación o medición por espectrometría de masas. Finalmente, los datos se procesan mediante bioinformática y herramientas estadísticas, incluyendo normalización, reducción de dimensionalidad, *clustering* y anotación de tipos celulares, así como análisis de trayectorias de diferenciación y redes de interacción. Este flujo permite identificar

subpoblaciones raras, estados funcionales específicos y correlaciones con fenotipos clínicos o respuestas terapéuticas (20,21).

El uso de scRNA-seq en células mononucleares de sangre periférica (PBMC, de sus siglas en inglés) permite caracterizar linfocitos B, T y otras células inmunitarias circulantes a nivel individual, identificando subpoblaciones, estados de activación. Esta aproximación proporciona un mapa detallado del sistema inmune periférico, facilitando la correlación de características moleculares con los pacientes con tumores CPR o NCPR y la comprensión de la eficacia de la quimioinmunoterapia perioperatoria (22,23).

1.5. Justificación del trabajo

El presente trabajo se centra en el análisis de transcriptómica de célula única de células B procedentes de PBMCs de pacientes incluidos en los ensayos NADIM, con el objetivo de identificar diferencias inmunológicas periféricas entre pacientes con tumores respondedores y no respondedores al tratamiento. Para ello, se realizará un análisis bioinformático de 30 muestras, integrando distintas herramientas computacionales para caracterizar la composición celular, los subtipos de células B y sus perfiles de expresión génica. Además, este enfoque ofrece la oportunidad de identificar rutas biológicas y procesos inmunitarios asociados a la eficacia terapéutica, así como posibles biomarcadores predictivos, contribuyendo a una mejor comprensión de los mecanismos moleculares implicados y al desarrollo de estrategias más personalizadas de tratamiento en pacientes con cáncer de pulmón de células no pequeña.

2. Objetivos

2.1. Generales

El objetivo general de este trabajo es analizar y discernir las diferencias inmunológicas en las PBMCs de pacientes con tumores CPR y NCPR en el contexto del estudio NADIM, con el fin de comprender los mecanismos inmunitarios asociados a la respuesta terapéutica y contribuir a la identificación de posibles biomarcadores inmunológicos predictivos que permitan optimizar la selección y el seguimiento de pacientes en futuras estrategias de inmunoterapia.

2.2. Específicos

Para llevar a cabo el objetivo general, este se ha desgranado en los siguientes objetivos específicos:

1) Diseñar y aplicar un pipeline bioinformático que integre distintas herramientas y lenguajes de programación para el análisis de datos de transcriptómica de célula única procedentes de 30 muestras de PBMCs.
2) Caracterizar la composición celular global de las muestras analizadas, evaluando la distribución de los principales tipos celulares en pacientes con tumores respondedores y no respondedores al tratamiento.
3) Analizar la distribución y abundancia de los subtipos de células B en CPR y NCPR.
4) Identificar diferencias en los perfiles de expresión génica de las células B entre pacientes respondedores y no respondedores, tanto en condiciones pretratamiento como postneoadyuvancia.
5) Evaluar las rutas biológicas y procesos inmunitarios asociados a las células B mediante análisis funcionales de enriquecimiento, con el fin de relacionarlos con la respuesta al tratamiento.

3. Metodología

3.1. Diseño experimental y obtención de datos.

Nota: Para mejorar la comprensión del texto se han añadido hipervínculos tanto internos como externos marcados en naranja a lo largo de todo el trabajo. El diseño experimental y la generación de las muestras de estudio fueron desarrollados por el grupo experimental del Dr. Alberto Cruz Bermúdez, perteneciente al Instituto de Investigación Sanitaria Puerta de Hierro. Este grupo centra su labor en el estudio del microambiente tumoral en el contexto del NSCLC, con el objetivo de comprender los mecanismos inmunológicos y moleculares que determinan la respuesta terapéutica de los pacientes. Dentro de este equipo, mi contribución se ha enfocado en el análisis bioinformático de los datos generados, incluyendo el procesamiento, análisis e interpretación de los resultados. En particular, he participado en el análisis de datos de scRNA-seq de pacientes del estudio NADIM, con el propósito de identificar diferencias inmunológicas entre CPR y NCPR, a partir de PBMCs. Todas la consideraciones éticas e información adicional del estudio NADIM se encuentra en el link de esta ***página*** (ID del ensayo clínico NCT03081689).

3.1.1. Selección de muestras y estrategia de secuenciación

Se llevó a cabo un análisis transcriptómico a nivel de célula única en un total de 30 muestras de PBMCs procedentes de 15 pacientes, recolectadas en dos momentos distintos: antes y después del tratamiento neoadyuvante. Para los análisis estadísticos se utilizaron únicamente 26 muestras, dado que dos pacientes no fueron intervenidos quirúrgicamente y, por tanto, no pudieron ser clasificados como CPR o NCPR. Las PBMCs fueron aisladas mediante un procedimiento de gradiente de densidad utilizando Ficoll, con el fin de separar las fracciones celulares de interés a partir de muestras de sangre total.

Para el análisis de transcriptómica de célula única se empleó la tecnología de 10x Genomics, utilizando la plataforma Chromium Next GEM Single Cell 5´. Las suspensiones celulares se encapsularon en microgotas denominadas GEMs (*Gel Beads-in-Emulsion*) mediante el instrumento Chromium X, garantizando la separación física de cada célula. Se estimó una media de aproximadamente 10.000 células recuperadas por muestra.

Posteriormente, se llevó a cabo la construcción de las bibliotecas de secuenciación. Todos los cebadores necesarios para la síntesis de ADNc y la preparación de las bibliotecas de expresión génica (GEX 5´), así como el protocolo experimental, fueron suministrados por 10x Genomics. La elección de la tecnología 5' permitió caracterizar con mayor precisión las regiones variables de receptor de las células T y el receptor de las células B. La secuenciación se realizó en la plataforma Illumina, utilizando un flujo de trabajo de lectura pareada e indexación dual (Read 1: 26 ciclos, índice i7: 10 ciclos, índice i5: 10 ciclos, Read 2: 90 ciclos), alcanzando una profundidad aproximada de 20.000 lecturas por célula, lo que supuso un total de alrededor de 200 millones de lecturas por muestra. La longitud de las secuencias fue entre 300-600 pares de bases.

3.2. Análisis bioinformático

3.2.1. Procesamiento de los datos crudos

Los archivos FASTQ obtenidos tras la secuenciación con las lecturas en bruto, junto con el genoma de referencia GRCh38-2020-A (***Figura 3***), fueron procesados de manera independiente para cada muestra utilizando el software *Cell Ranger (v6.0.1) (Comando(C): "cellranger count")*, con el objetivo de generar la matriz de conteos necesaria para el análisis posterior. Este programa procesa los archivos FASTQ identificando las células individuales a través de los *barcode* y asociando a cada una de ellas las lecturas de ARN correspondientes. Posteriormente, las secuencias se alinean al genoma de referencia para anotar los genes expresados en cada célula, produciendo como resultado los archivos matriz.mtx; la matriz de expresión génica, barcodes.tsv; lista de los códigos de cada célula que identifican cada columna de la matriz y features.tsv; la lista de los genes que identifican cada fila, juntos conforman la matriz de conteos por célula (***Figura 3***).

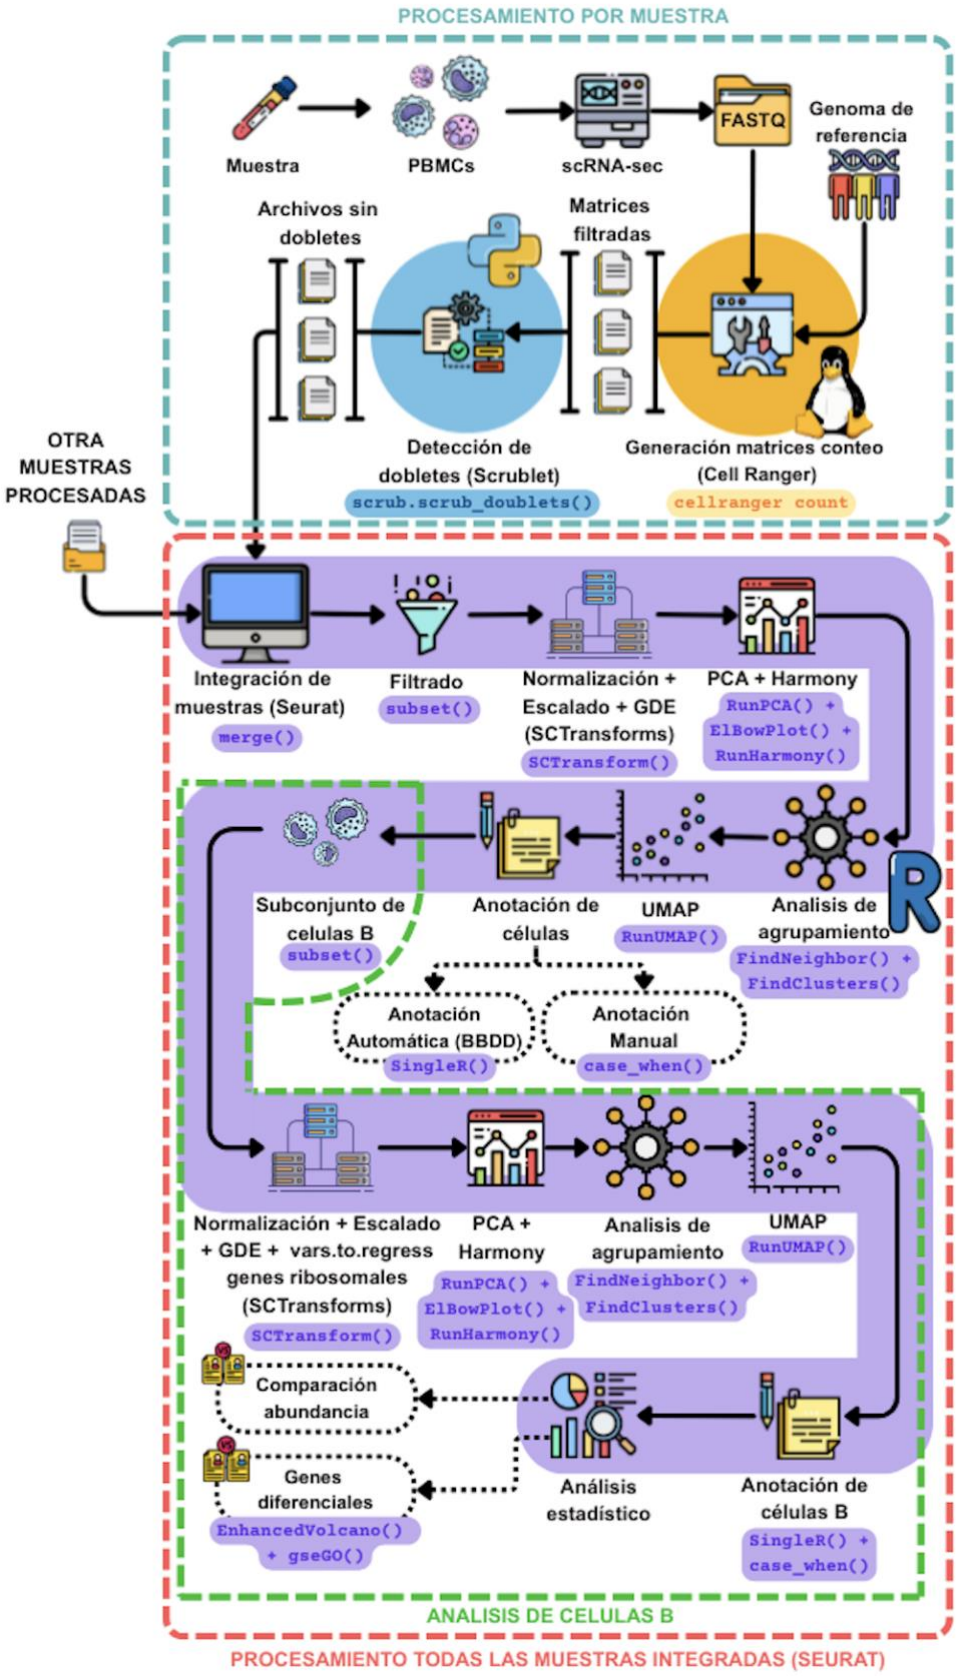

Figura 3: Flujo de procesamiento de datos de scRNA-seq. ICP.

Abarca desde las muestras iniciales hasta el análisis estadístico. El esquema se divide en dos secciones principales: La primera, delimitada por líneas discontinuas turquesa, muestra el procesamiento individual de cada muestra hasta la obtención de los archivos libres de dobletes. La segunda, delimitada por líneas discontinuas rojas, representa el procesamiento conjunto de todas las muestras integradas hasta el análisis estadístico de las células B. Dentro de esta zona, el análisis de las células B comienza en el área delimitada por líneas discontinuas verdes, que abarca desde la obtención del subconjunto de células B hasta su análisis estadístico. Las líneas continuas indican el flujo principal del proceso, mientras que las líneas punteadas señalan procesamientos paralelos. Los distintos sombreados reflejan el lenguaje de programación utilizado: amarillo para Linux, azul para Python y morado para R. Los comandos empleados en cada paso se muestran debajo de los respectivos puntos del flujo. ICP.

Además de los archivos en bruto, *Cell Ranger* genera automáticamente archivos filtrados, en los que se incluyen únicamente las células de alta calidad que superan los criterios de control, lo que permite disponer tanto de datos completos como de datos depurados para análisis posteriores. Este software elimina lecturas con un Phred menor de 20, lecturas sin barcode, barcode que estén por debajo del punto de inflexión en el número de identificadores moleculares únicos; eliminando las gotas vacias, filtra genes no expresados y mantiene solo aquellas lecturas que mapeen de forma única. Todo el procesamiento se llevó a cabo en Bash. Los scripts de procesamiento se encuentran disponibles en el repositorio de GitHub NADIM_SingleCell asociado al proyecto (***Hipervínculo***) y para link directo al punto de CellRanger (***Hipervínculo***)

3.2.2. Control de calidad: Detección y eliminación de dobletes.

Para garantizar la eliminación de dobletes se empleó la herramienta Scrublet (v0.2.3) (C:scrub.scrub_doublets()) (***Figura 3***). la cual simula y predice computacionalmente los dobletes. A partir de los archivos filtrados generados por Cell Ranger, las matrices de conteo de cada muestra fueron analizadas individualmente por Scrublet estableciendo un umbral de corte específico para cada muestra con el fin de descartar aquellos eventos que no correspondieran a una célula única, el corte para muestra se puede observar en la ***Tabla 1***. Con el objetivo de escarificar, la selección del punto de corte, en el ***Gráfico 1***, se puede observar la distribución del índice de dobletes de todas las células analizadas en una muestra, en el que se distinguieron dos poblaciones. Se observó un pico principal de células con valores bajos, correspondiente a los singletes, mientras que otra fracción apareció desplazada hacia valores altos, indicando los dobletes potenciales. Entre

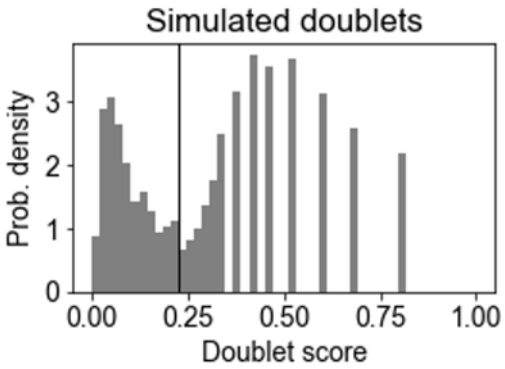

Gráfico 1: Ejemplo de la representación del valor de probabilidad de dobletes calculado por Scrublet. Imagen obtenida de la documentación Scrublet (pincha aquí)

En el eje X se muestra el valor de probabilidad de ser doblete, que varía entre 0 y 1; a mayor valor, mayor es la probabilidad de que la célula sea un doblete. En el eje Y se representa la densidad de células. De esta manera se observan dos regiones: una con la mayoría de células con baja probabilidad de ser dobletes y otra donde se concentra la densidad de células con alta probabilidad. La línea divisoria indica el umbral elegido para clasificar las células como singletes o dobletes. Este umbral es seleccionado en cada muestra.

ambas poblaciones se observó un valle que reflejó la transición entre singletes y dobletes, y en esta región se estableció el umbral de corte. Este punto definió la frontera a partir de la cual las células situadas a la derecha fueron consideradas dobletes y por lo tanto eliminadas. Todo este proceso se llevó a cabo utilizando el lenguaje de programación Python. (Carpeta Doublets en GitHub del proyecto (***Hipervínculo***) y repositorio del algoritmo (***Hipervínculo***).

Tabla 1: Tratamiento, Respuesta, Umbral de corte y Porcentaje filtrado de células por muestra. ICP.

En esta tabla se muestra el tratamiento (PRE, pretratamiento, y POST, post-neoadjuvancia), la respuesta al tratamiento (NCPR (0), No Repuesta Patológica Completa, CPR (1), Respuesta Patológica Completa y N.E, No evaluado ya que no fueron operados), el umbral de corte y el porcentaje de células filtrado (Al final de estas dos columnas la media de todas las muestras).

Muestras	Tratamiento	Respuesta al tratamiento	Umbral de corte	Porcentaje filtrado de células
M1	PRE	1	0,27	4,19%
M2	POST	1	0,24	2,03%
M3	PRE	0	0,13	2,60%
M4	POST	0	0,3	3,30%
M5	POST	0	0,3	4,43%
M6	PRE	0	0,28	5,93%
M7	POST	1	0,29	12,85%
M8	PRE	1	0,25	6,83%
M9	PRE	0	0,27	3,78%
M10	POST	0	0,29	10,87%
M11	PRE	0	0,17	4,03%
M12	POST	0	0,23	1,45%
M13	PRE	0	0,26	2,05%
M14	POST	0	0,04	0,72%
M15	PRE	1	0,23	2,73%
M16	POST	1	0,19	1,08%
M17	POST	1	0,3	5,47%
M18	PRE	1	0,25	4,07%
M19	PRE	1	0,28	6,22%
M20	POST	1	0,27	12,76%
M21	PRE	0	0,2	3,76%
M22	POST	0	0,3	4,13%
M23	POST	N.E	0,33	3,12%
M24	PRE	N.E	0,1	8,55%
M25	PRE	0	0,35	5,90%
M26	POST	0	0,17	0,64%
M27	POST	1	0,32	1,69%
M28	PRE	1	0,21	2,40%
M29	POST	N.E	0,3	1,73%
M30	PRE	N.E	0,25	2,57%
TOTAL/MEDIA			**0,2457**	**3,97%**

Una vez eliminados los eventos identificados como dobletes, se procedió a una segunda fase de depuración para asegurar la calidad de las células. En esta etapa, las matrices de conteo filtradas fueron cargadas individualmente en R (v4.5.0), utilizando la librería Seurat (v5.3.0) (***Figura 3***). Durante la carga de cada muestra se añadió sus correspondientes metadatos (Muestra, paciente, tipo de respuesta al tratamiento, sexo y progresión), lo que permitió conservar y relacionar esta información en los análisis posteriores. (Carpeta Seurat/1_multi_sample_merge.R en ***GitHub***).

Tras la incorporación de los medatados, las diferentes muestras fueron integradas en un único objeto de Seurat (C:merge()), manteniendo la trazabilidad de cada célula dentro de su muestra original. A continuación, se aplicaron criterios de filtrado estrictos para descartar células de dudosa calidad, como células muertas o restos celulares con la función "subset()". Específicamente, se eliminaron las células que no cumplían con los siguientes criterios de calidad: aquellas que presentaban un número de genes detectados fuera del rango de 400 a 5.500, un número de moléculas detectadas fuera de 1.000 a 40.000, o que mostraran un porcentaje de genes mitocondriales superior al 20% (***Figura 3***). (Carpeta Seurat/2_QC_Norm_DimRedu_Cluster_UMAP.R en ***GitHub***)

3.2.4. Normalización y reducción de dimensionalidad,

Una vez obtenidas las células de alta calidad y libres de dobletes se procedió a la normalización y escalado de los datos con el fin de permitir la comparación equitativa entre muestras. Para ello, se empleó la función SCTransform (v0.4.2) (24) (C:SCTransform()), que corrige las diferencias técnicas entre células, la detección de genes altamente variables y el escalado. Este método ajusta la expresión de cada gen mediante un modelo de regresión, lo que permite una comparación más precisa entre las células. En este análisis, se utilizó como modelo de regresión glmGamPoi; del paquete "glmGamPoi", un modelo lineal generalizado con distribución Gamma-Poisson, que mejora la estimación de la varianza y optimiza la eficiencia computacional, especialmente en conjuntos de datos de gran tamaño. Si no se utilizara este tipo de función, sería necesario realizar de forma independiente los tres grandes pasos que realiza, normalización con la función

"NormalizeData()", detección de los genes altamente variables con la función "FindVariableFeature()" y el escalado con "ScaleData()". Además, para realizar esta normalización con el total de las muestras fue necesario incrementar el límite de memoria a 50 GB y para ello se utilizó el comando "future.globals.maxSize" del paquete "Future".

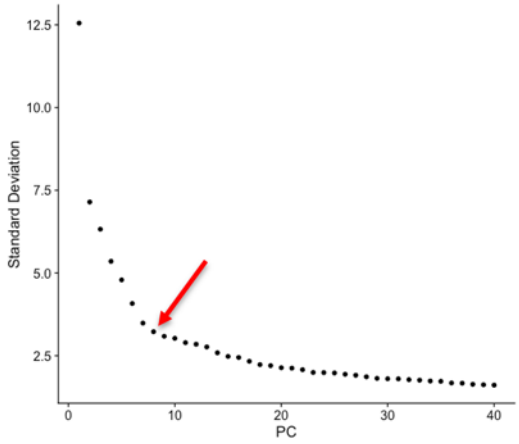

Gráfico 2: Ejemplo del comando "ElbowPlot()". ICP.
En este gráfico se representa la desviación estándar en los diferentes componentes principales calculados con la función "RunPCA". De esta forma podemos elegir donde se encuentra el codo (Flecha roja) y seleccionar el número de componentes que explican la variabilidad biológica.

Posteriormente, para visualizar la estructura global de los datos y reducir su dimensionalidad, se realizó un análisis de componentes principales (PCA) con los genes altamente variables (25). Empleando la función "ElbowPlot()" se representó la varianza explicada por cada componente principal para determinar el número óptimo de componentes a incluir en los análisis posteriores. Este es un paso crucial, ya que de la correcta elección del número de componentes principales permite capturar la variabilidad biológica real y evitar la inclusión de ruido técnico. El resultado del comando "ElbowPlot()" se puede ver en el ***Gráfico 2***, donde la fecha roja señala el componente principal a partir del cual la variabilidad explicada empieza a estabilizarse.

3.2.5. Análisis de agrupamiento y anotación

Después de haber elegido el número de componentes principales, con la función "FindNeighbors()" se construye un grafo de vecinos que relaciona las células en función de su proximidad en el espacio de expresión. El valor del parámetro K fue 20, un parámetro que establece por cada célula el número de células cercanas con la que se creara conexión. Sobre este grafo, se aplicó el algoritmo de Leiden, que permite dividir las células en clústeres, de modo que las células dentro de un mismo clúster presentan una mayor similitud entre ellas que con las de otros grupos, esto se realizó con la función "FindClusters()". En esta función se utilizó una resolución de 1.5, este parámetro establece

el número de clústeres que se hacen, de forma que mayor resolución mayor número de clústeres. Para poder visualizar los clústeres y como quedaron representados se utilizó la función “RunUMAP()”. Con esta función se obtiene una aproximación y proyección uniforme de variedades (UMAP, de sus siglas en ingles), donde cada célula se proyecta en dos dimensiones utilizando como entrada un conjunto de componentes principales previamente calculadas.

Para corregir la segregación por muestra observada en las proyecciones iniciales, los datos se integraron usando Harmony. Harmony toma los PCA y aplica un ajuste iterativo basado en agrupamiento suave para re-alinear las coordenadas celulares de modo que células con perfiles biológicos similares se acerquen independientemente de su origen de lote o paciente; de esta forma reduce efectos técnicos sin modificar directamente los recuentos de expresión subyacentes. El algoritmo es rápido y escalable a conjuntos de datos grandes y puede tener en cuenta múltiples variables de lote simultáneamente, por lo que resulta adecuado para integrar varias muestras por paciente (26)

Una vez definidos los clústeres, se procedió a la anotación de los tipos celulares utilizando dos estrategias complementarias. En primer lugar, se realizó una anotación automática mediante el paquete SingleR (v 2.11.0), empleando como referencia el conjunto de datos HumanPrimaryCellAtlasData (v “2024-02-26”) (27) y el conjunto de datos BlueprintEncodeData (28) (v “2024-02-26”) del paquete celldex, que contienen perfiles transcriptómicos de células humanas obtenidos mediante single-cell RNA-seq. *La función utilizada fue “SingleR” del paquete “SingleR”* . En segundo lugar, se llevó a cabo una anotación manual, basada en la expresión de genes marcadores característicos de cada tipo celular, para confirmar y refinar la clasificación obtenida. Por un lado se sacaban los genes diferentemente expresados para cada clúster con la función “FindAllMarkers()” y por otro se representaba en el UMAP la expresión de diferentes genes marcadores con la función “FeaturePlot()”. Los genes que se utilizaron para cada tipo celular anotado se encuentra en la ***Tabla 2***. (Carpeta Seurat/3_Annotation.R en ***GitHub***)

Tabla 2: Genes utilizados para la anotación de los diferente tipos células tanto en células PBMC como en células B. ICP.

En esta tabla se establecen los Genes en alta expresión y los genes de baja expresión utilizados por tipo células para confirmar la anotación realizada de forma automática por las dos bases de datos.

Tipos Celulares	Genes Alta Expresión	Genes Baja Expresión
NK	NKG7 - GZMB - GNLY	MS4A1 - CD4 - IL7R
T CD8+	CD3D - CD3E - CD3G -CD8A - CD8B - GZMK	MS4A1 - CD4
T CD4+	CD3D - CD3E - CD3G -CD4 - IL7R - ICOS - CCR7	CD8A - CD8B
Monocitos	LYZ - FCGR3A - ITGAX	CD3D - CD3E - CD3G
Dendriticas	FCER1A - LYZ - ITGAX - CD1C	CD3D - CD3E - CD3G
B	MS4A1 - JCHAIN	CD3D - CD3E - CD3G
Progenitoras	ALAS2 - GATA1- HBA1 - HBB	CD3D - CD3E - CD3G - MS4A1
CBn	FCER2 - IGHD - IGHM - TCL1A	JCHAIN - CD27
CB mem	CD27 - MS4A1	JCHAIN - TCL1A
CB mem C	MS4A1 - CD27	IGHD - IGHM
CB mem NC	MS4A1 - IGHD - IGHM	TCL1A - JCHAIN
Plasmablastos	JCHAIN - CD27	MS4A1 -TCL1A

3.2.6. Células B

Para poder analizar en mayor detalle los grupos de células se decidió tratarlos individualmente, es por ello que se creó un nuevo objeto Seurat con la función “subset()” donde todas las células que lo componían habían sido anotadas con células B. A este objeto Seurat se repitió todo el flujo de análisis desde el ***punto 3.2.4*** (normalización, reducción de dimensionalidad, agrupamiento y anotación) con el objetivo de caracterizar de forma más precisa los subtipos de células B. La elección de las células B frente a otros subtipos se debe a su menor número relativo, lo que permite un análisis más sencillo y rápido, así como a la menor diversidad de subtipos que presentan.

El procedimiento fue análogo al análisis general, pero en esta ocasión fue necesario ajustar el proceso de normalización debido a que, en un primer análisis, los genes ribosomales dominaban la variabilidad de los datos y dificultaban la correcta representación de las poblaciones celulares. Para abordar este problema, se calculó el porcentaje de genes ribosomales por célula con la función “PercentageFeatureSet” y como patrón de búsqueda de los genes ribosomales la expresión regular "^RP[SL]", que posteriormente se incorporó como variable de regresión en la función de normalización (SCTransform) mediante el parámetro “*vars.to.regress”*. De esta forma se pudo minimizar el efecto de estos genes

sobre la variabilidad global, facilitando un agrupamiento más representativo de los tipos celulares reales. (Carpeta Seurat/4_B_CELL en ***GitHub***).

De forma análoga a lo descrito en el ***apartado 3.2.5***, se procedió a la anotación de los distintos subgrupos de células B identificados. La única diferencia fue la resolución empleada, que en este caso fue de 0.1. En la ***Tabla 2*** se muestran los genes característicos de cada grupo celular. Además, se llevaron a cabo dos análisis estadísticos principales para la caracterización de estos subgrupos. En primer lugar, se comparó la abundancia de cada tipo celular entre los grupos CPR y NCPR mediante la prueba de Mann–Whitney U, una prueba no paramétrica adecuada para comparar distribuciones entre dos grupos independientes. En segundo lugar, se identificaron los genes diferencialmente expresados para cada subgrupo con la función "FindMarkers()". Por un lado se realizaron gráficos de volcanes con la función "EnhancedVolcano()", los criterios de corte fue un valor ajustado de $p < 0.05$ y un cambio en la expresión absoluta superior a 0.5 en $\log_2$. Por otro lado también los resultados se representaron mediante análisis de enriquecimiento de conjunto de genes (GSEA) utilizando la función "gseGO()" con la base de datos "org.Hs.eg.db" en formato SYMBOL y se seleccionó la ontología biológica de procesos biológicos (BP), además se estableció como valor de significancia un valor ajustado de $p < 0.05$ por el método Benjamini-Hochberg y no se representaron aquellos subgrupos de tipos celulares con menor de 200 células por grupo (Carpeta Seurat/5_Statistical_analysis en ***GitHub***).

4. Resultados y Discusión

4.1. Preanálisis

Antes de proceder a la representación y análisis del conjunto completo de células, se llevó a cabo una visualización exploratoria previa con el objetivo de evaluar la distribución del número de lecturas y del número de genes detectados por célula en cada una de las muestras. Este paso resulta fundamental para comprobar la calidad de los datos y garantizar que presentan una distribución adecuada antes de aplicar análisis posteriores.

Como se observa en el ***Gráfico 3***, tanto el número de genes como el número de lecturas por célula se mantienen relativamente similares y homogéneos entre las distintas muestras, sin apreciarse diferencias marcadas ni sesgos evidentes. Esta uniformidad sugiere que los datos han sido correctamente normalizados y que las muestras son comparables entre sí. Además, esta inspección preliminar permite validar que los filtros de calidad aplicados previamente son coherentes y adecuados en relación con la estructura de los datos obtenidos.

De manera complementaria, también se analizó la expresión de genes ribosómicos por célula en cada muestra. Tal como se muestra en el ***Gráfico 3***, la distribución del porcentaje de genes ribosómicos es muy similar entre las diferentes muestras, sin desviaciones significativas. Este resultado indica que no existen muestras con un enriquecimiento anómalo de genes ribosómicos, lo cual podría ser indicativo de células de baja calidad o de procesos técnicos no deseados.

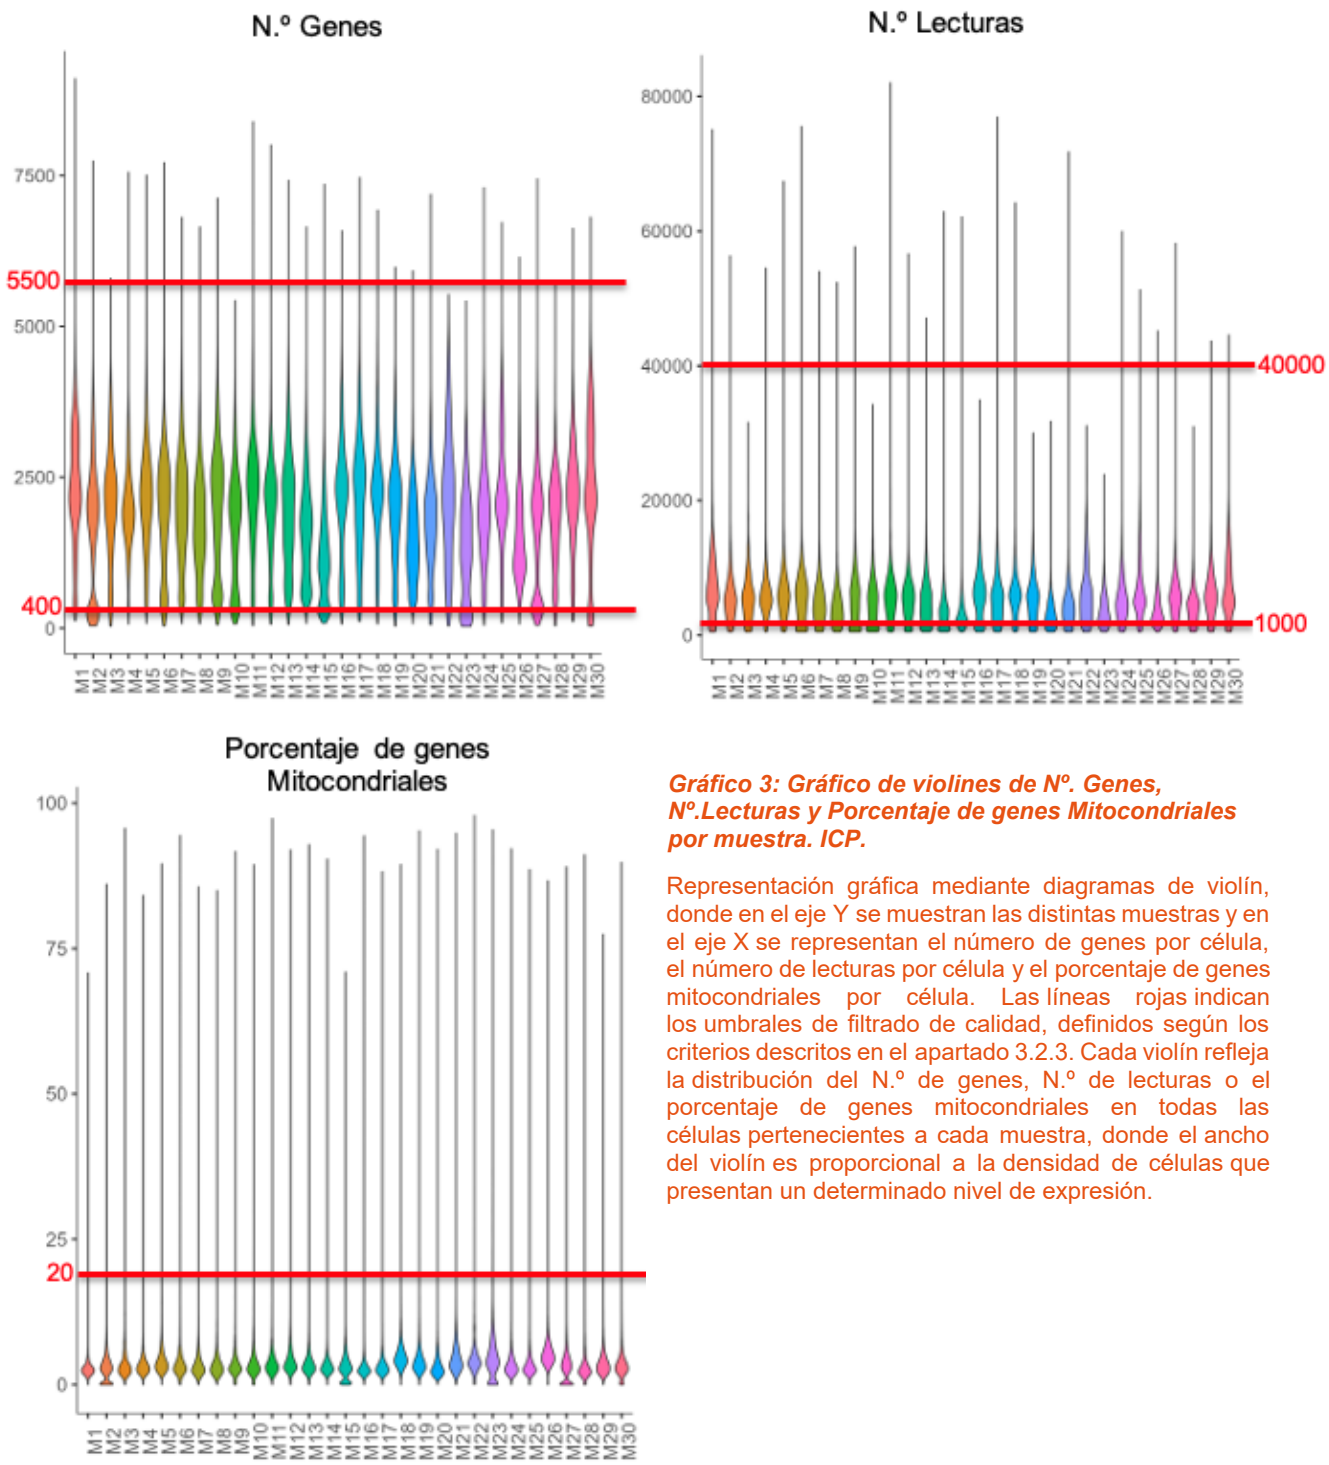

Gráfico 3: Gráfico de violines de Nº. Genes, Nº.Lecturas y Porcentaje de genes Mitocondriales por muestra. ICP.

Representación gráfica mediante diagramas de violín, donde en el eje Y se muestran las distintas muestras y en el eje X se representan el número de genes por célula, el número de lecturas por célula y el porcentaje de genes mitocondriales por célula. Las líneas rojas indican los umbrales de filtrado de calidad, definidos según los criterios descritos en el apartado 3.2.3. Cada violín refleja la distribución del N.º de genes, N.º de lecturas o el porcentaje de genes mitocondriales en todas las células pertenecientes a cada muestra, donde el ancho del violín es proporcional a la densidad de células que presentan un determinado nivel de expresión.

En conjunto, estos análisis exploratorios permiten concluir que la distribución de los datos es razonablemente homogénea entre todas las muestras, tanto en términos del número de genes detectados por células, el número de lecturas por célula y el porcentaje de genes

ribosómicos por células. Por lo tanto, los datos presentan una calidad adecuada para continuar con los análisis posteriores del estudio.

4.2. Representación PBMCs

De las 30 muestras correspondientes a 15 pacientes analizadas mediante secuenciación de ARN de célula única, se obtuvieron un total de 228 465 células tras el control de calidad. Estas células se representaron mediante reducción de dimensionalidad utilizando UMAP, coloreando las proyecciones según diferentes variables técnicas y clínicas con el objetivo de evaluar posibles efectos de lote y explorar la estructura global de los datos. En la proyección inicial, el UMAP mostraba bloques claramente asociados a cada muestra, como se observa en la ***Figura 4A*** en la zona redondeada, lo que indicaba que la variabilidad debida al origen de la muestra dominaba la estructura global del conjunto de datos. Tras aplicar el método de integración Harmony, dichas agrupaciones por paciente desaparecieron y emergieron agrupamientos coherentes con la biología esperada, lo que sugiere que la corrección mitigó eficazmente los efectos técnicos y permitió visualizar señales biológicas reales (***Figura 4B***).

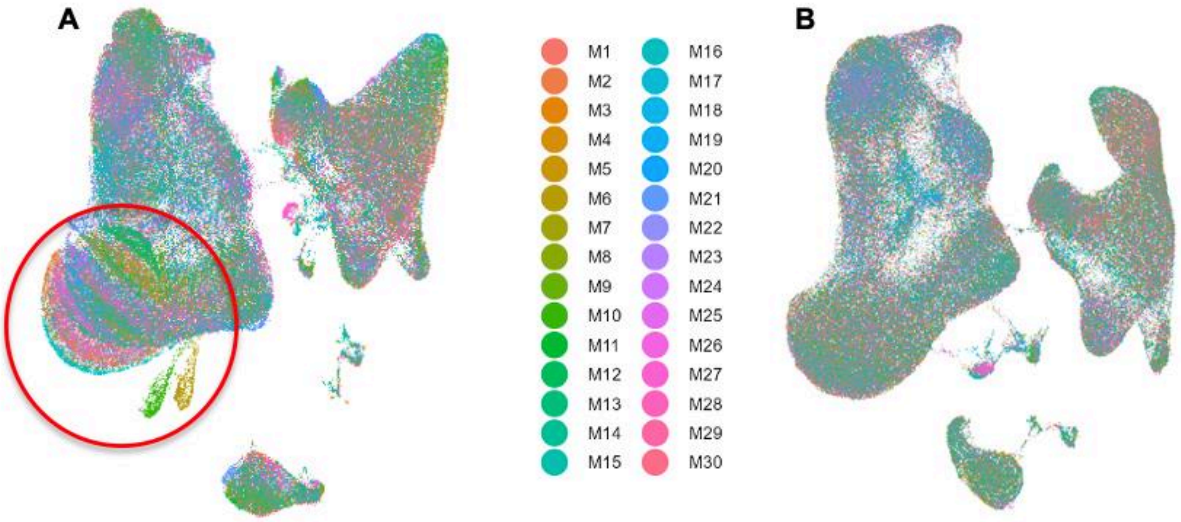

Figura 4: Representación UMAP de todas las células coloreado por muestra (A y B). ICP.
Se muestra la representación UMAP coloreada por muestras antes de aplicar Harmony (A) y después de la corrección por Harmony (B). La región señada en rojo muestra la zona donde se puede observar con mejor detalle las zonas que se distribuyen por muestra antes de aplicar Harmony.

Con el fin de comprobar que los bloques observados en los análisis no se debían a la influencia de otros factores ajenos al objetivo principal del estudio, como el sexo, los pacientes, momentos de la extracción o la respuesta de la enfermedad, se procedió a la representación de los UMAP correspondientes. Estas representaciones permiten evaluar de manera visual si la agrupación de las células está condicionada por este tipo variables. En la ***Figura 5*** se muestran los UMAP obtenidos, donde el panel A corresponde a la representación previa a la aplicación del método de integración Harmony, mientras que el panel B muestra el resultado tras su aplicación. En el UMAP previo a Harmony se aprecia una clara separación de las células en distintos bloques, lo que sugiere la presencia de efectos de lote o sesgos asociados a variables técnicas o individuales. En contraste, en el panel B, tras la aplicación de Harmony por muestra, dichos bloques desaparecen, observándose una distribución más homogénea de las células en la mayor parte de la representación UMAP.

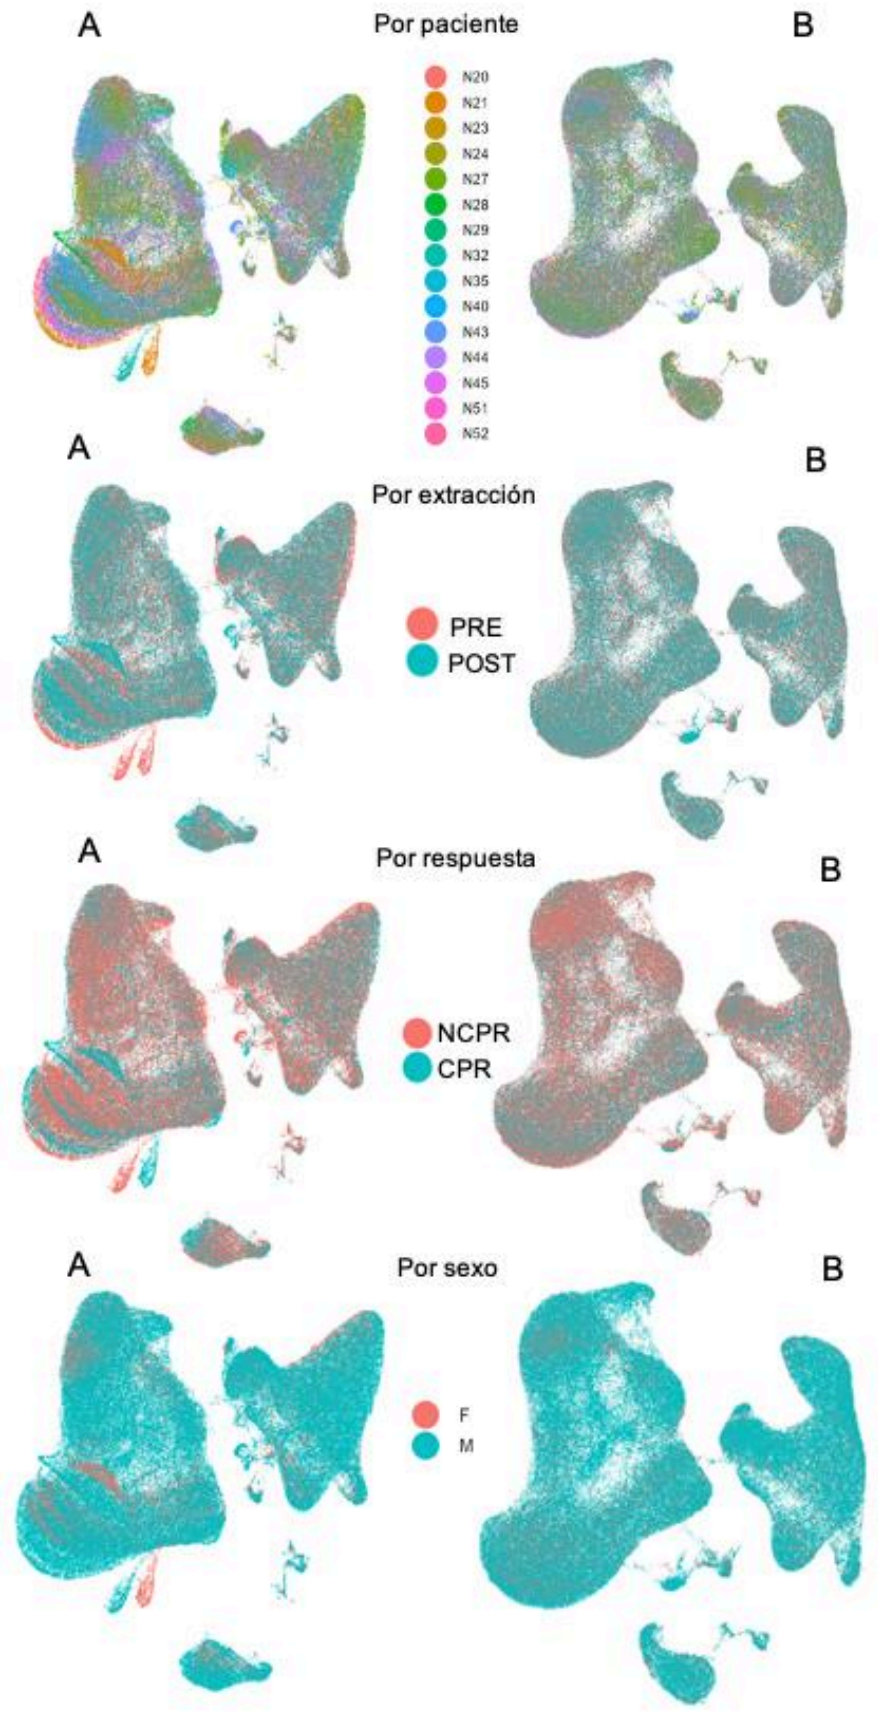

Figura 5: Representación UMAP coloreada por paciente, por extracción, por respuesta y por sexo. ICP.

Se representan UMAP coloreados según las variables paciente, extracción, respuesta y sexo, con el objetivo de identificar posibles efectos técnicos asociados a estas variables. Como se observa en los paneles A, tanto de esta figura como de la figura 4, se aprecian regiones dominadas por muestras específicas, lo que sugiere la presencia de sesgos técnicos. Sin embargo, en el panel B dichas regiones desaparecen, observándose una distribución más homogénea de las muestras en el espacio UMAP tras aplicar Harmony.

4.3. Anotación

Tras la visualización de los datos mediante UMAP y la aplicación del método Harmony para la corrección de los efectos de lote, se procedió a la construcción de los clústeres celulares, cuyo resultado se muestra en la ***Figura 6*** como se explica en el ***apartado 3.2.5***. Posteriormente, se realizó un proceso de anotación automática por clúster utilizando como referencias las bases de datos *Human Primary Cell Atlas Data* y *Blueprint Encode Data*. El resultado de esta anotación automática, que permite asignar una identidad celular a cada clúster, se presenta en la ***Figura 7***.

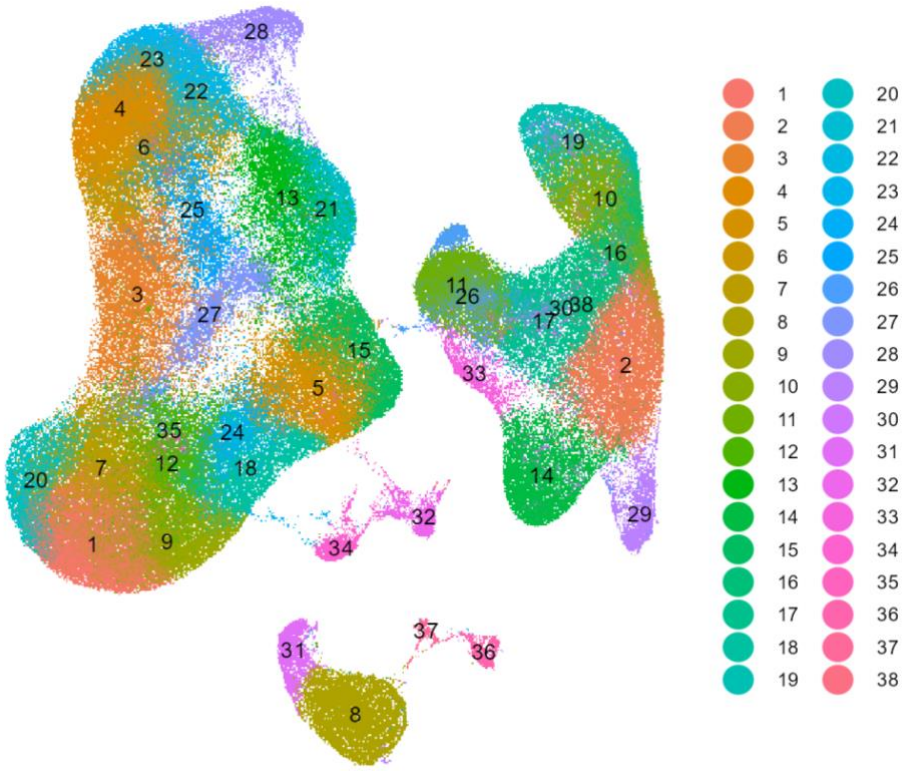

Figura 6: Representación UMAP coloreada según el resultado de análisis de agrupamiento. ICP.

Se muestra la representación UMAP coloreada según los distintos grupos (clústeres) obtenidos con una resolución de 1.5. Cada uno de estos clústeres agrupa células con perfiles de expresión génica similares, y por tanto puede considerarse una unidad biológicamente coherente. Estos grupos constituyen la base para el proceso de anotación celular, ya que permiten asignar un tipo celular a cada conjunto de células en función de la expresión de genes marcadores característicos.

Posteriormente, se realizó una validación de las anotaciones obtenidas mediante el análisis de la expresión de genes marcadores característicos de cada tipo celular, con el objetivo de

confirmar la correcta correlación entre clústeres y tipos celulares (29). Por su parte, las células T CD4+ muestran una elevada expresión de IL7R (30) e ICOS (31) además de la expresión de CD3G, CD3D y CD3E, genes que codifican para los antígenos CD3, los cuales se expresan exclusivamente en células T (32). Asimismo, las células T CD8+ presentan una alta expresión de los genes que codifican para CD3, junto con una elevada expresión de CD8A y CD8B, genes característicos de las células T CD8+ (33). Finalmente, se identifican claramente otros tres grupos bien definidos: las células NK, caracterizadas por la expresión de NKG7 (34) y GZMB (35); los monocitos, identificados por la expresión de LYZ; y las células dendríticas (CD), caracterizadas por la expresión conjunta de LYZ y FCER1A (36) (Ver ***Figura 8***).

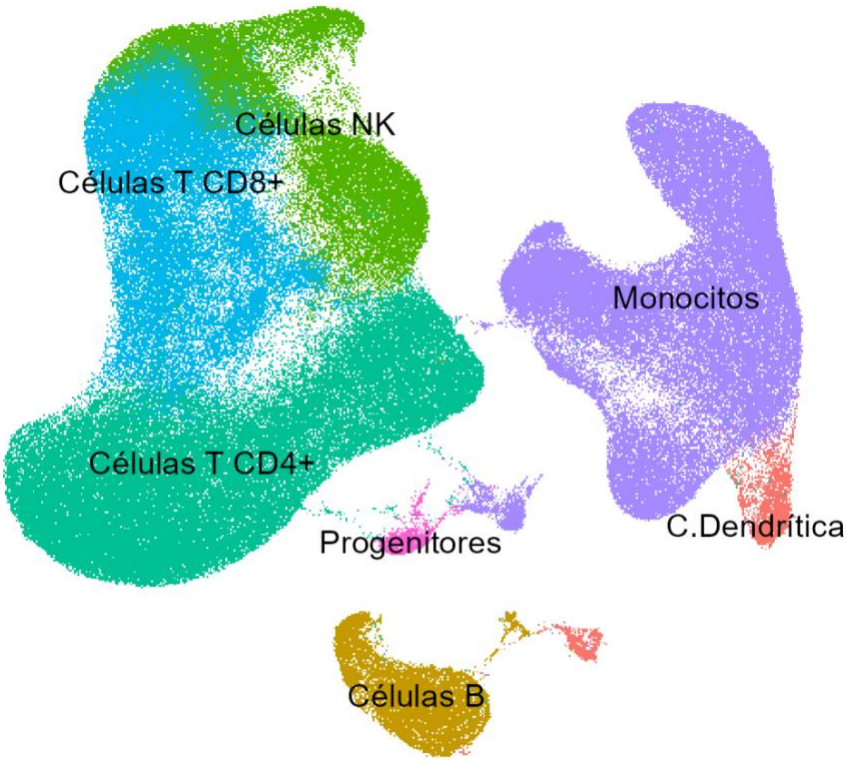

Figura 7: Representación UMAP coloreada según la distribución de los tipos celulares. ICP.

Se muestra la representación UMAP coloreada según la distribución de los distintos tipos celulares (células B, células T CD4$^+$, células T CD8$^+$, células NK, monocitos y células dendríticas), de acuerdo con los resultados obtenidos mediante la anotación basada en Human Primary Cell Atlas Data y Blueprint Encode Data, y tras su revisión y validación mediante la expresión de genes marcadores específicos para cada tipo celular.

Además, en la ***Figura 9*** de la distribución espacial en el UMAP de algunos de los genes recogidos en la ***Tabla 2***, que recoge los principales genes marcadores asociados a cada tipo celular identificado. Esta representación permite visualizar directamente la localización y el patrón de expresión de cada gen dentro del espacio reducido definido por el análisis UMAP, facilitando la interpretación de la anotación celular realizada.

En estos mapas de expresión, cada célula se representa según su nivel de expresión génica, donde el color rojo indica una alta expresión del gen de interés, mientras que el color gris corresponde a células en las que dicho gen no se expresa o lo hace a niveles bajos. De este modo, es posible evaluar de forma visual y comparativa la correspondencia entre la expresión de genes marcadores específicos y los clústeres celulares previamente anotados.

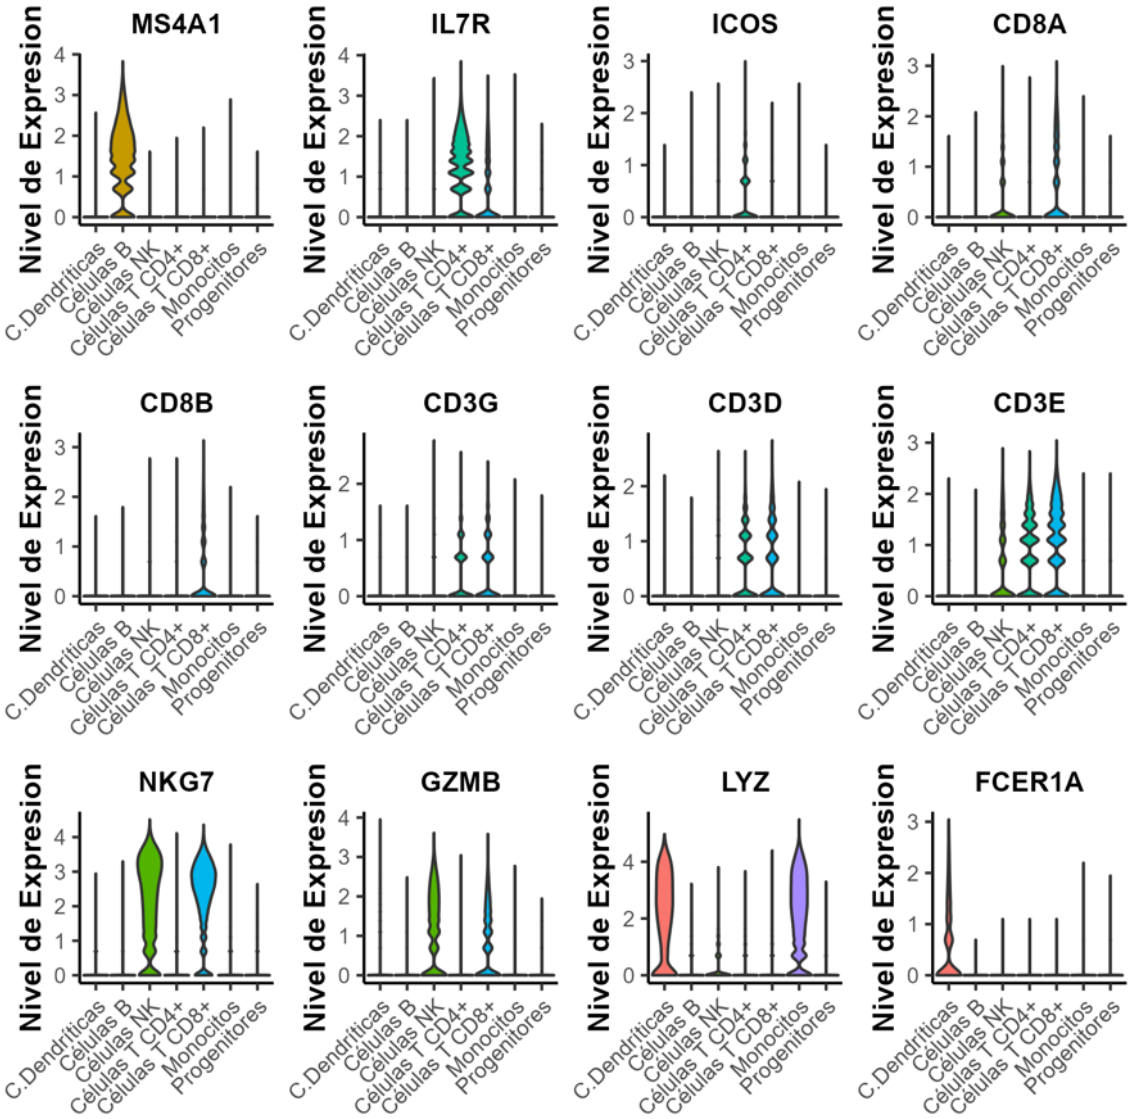

Figura 8: Gráfico de violines según el nivel de expresión de algunos genes respecto a los diferentes tipos celulares. ICP.

Se representan 12 genes característicos de los distintos tipos celulares mediante gráficos de violín, en los que el eje Y indica el nivel de expresión génica y el eje X los diferentes tipos celulares. Cada violín refleja la distribución de la expresión del gen en todas las células pertenecientes a cada tipo celular, donde el ancho del violín es proporcional a la densidad de células que presentan un determinado nivel de expresión. De este modo, estos gráficos permiten evaluar tanto la intensidad como la variabilidad de la expresión génica dentro y entre los distintos tipos celulares, facilitando la identificación de genes marcadores específicos.

La superposición de estos patrones de expresión sobre el UMAP permite comprobar que algunos de los genes marcadores definidos en la ***Tabla 2*** se expresan de manera consistente y localizada en los clústeres correspondientes a cada tipo celular. Esta concordancia espacial refuerza la validez de la anotación automática realizada a partir de las bases de datos de referencia, ya que los clústeres identificados muestran un perfil de expresión acorde con los marcadores conocidos para cada población celular.

Por tanto, la visualización conjunta de la tabla de genes marcadores y los UMAPs de expresión génica constituye una evidencia adicional que respalda la correcta asignación de identidades celulares. Esta aproximación permite no solo confirmar la anotación obtenida por las bases de datos empleadas, sino también descartar posibles solapamientos o errores de clasificación, asegurando una caracterización robusta y coherente de las distintas poblaciones celulares presentes en el conjunto de datos analizado.

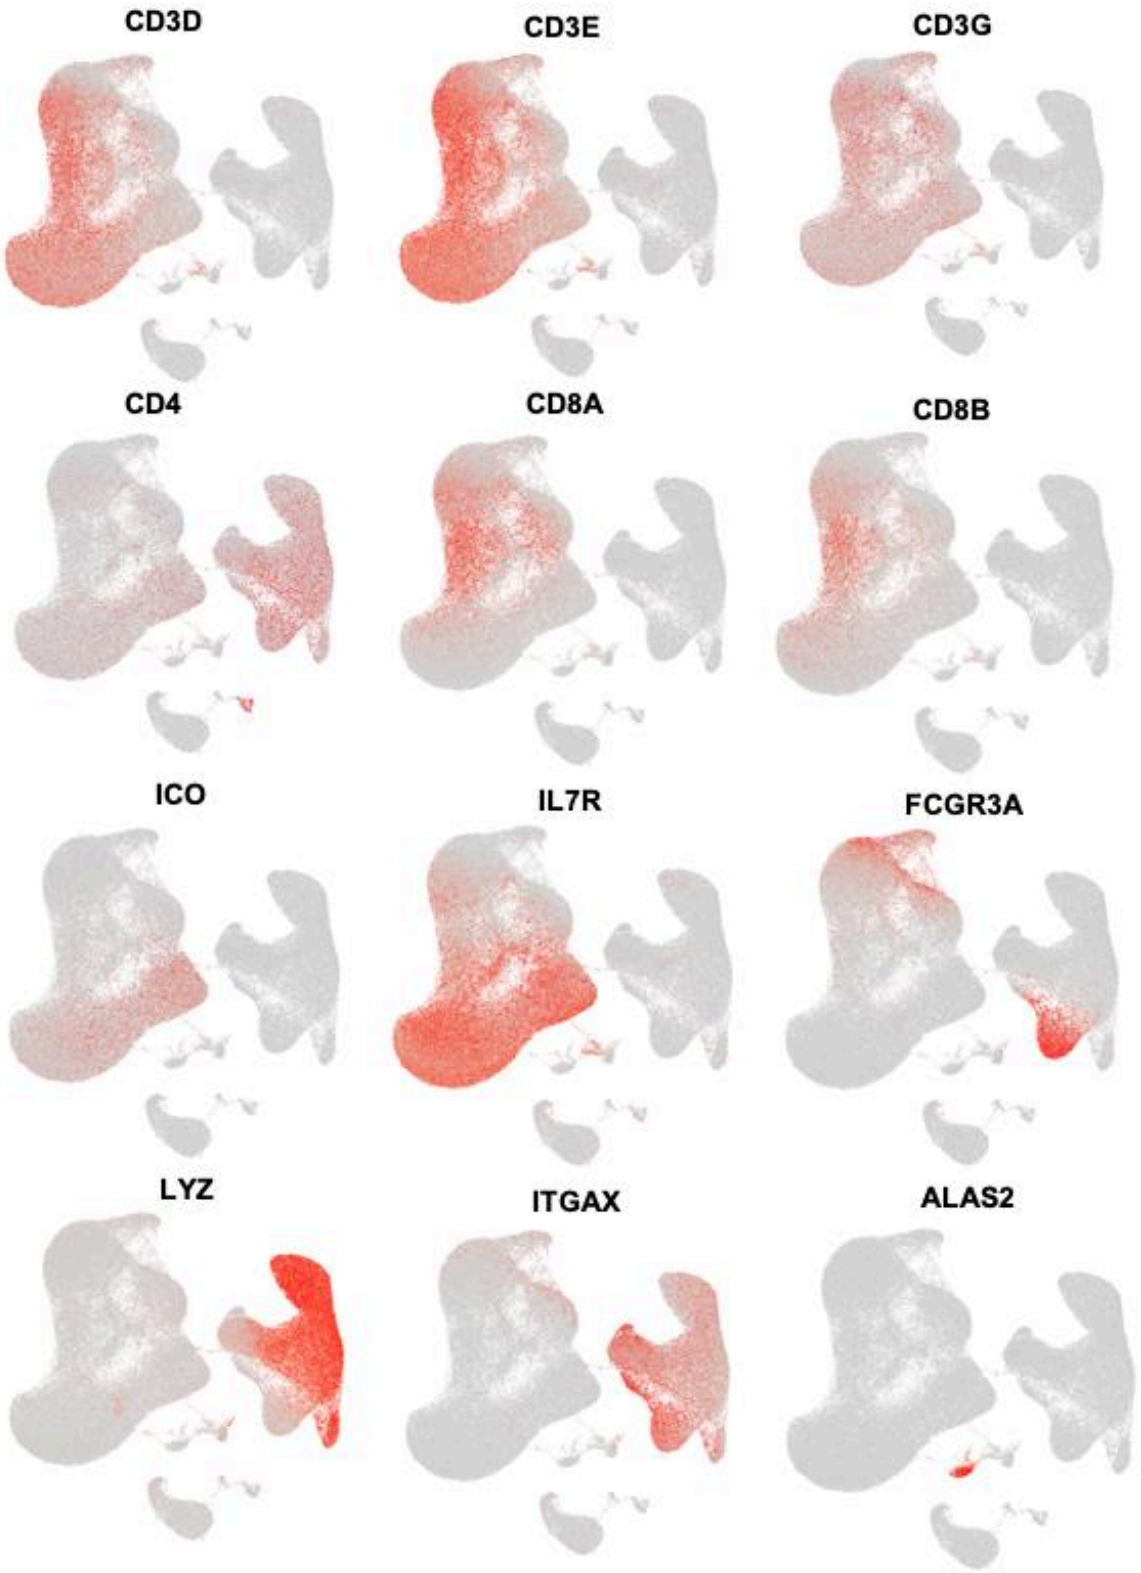

Figura 9: Representación UMAP de 12 genes representativos de los diferentes tipos celulares. ICP.
Se muestran 12 representaciones UMAP, cada una correspondiente a un gen diferente. En cada proyección, el color rojo indica las células en las que el gen se encuentra expresado, mientras que el color gris representa aquellas en las que no se detecta expresión. La intensidad del color rojo refleja el nivel de expresión génica, de modo que tonalidades más intensas indican una mayor expresión. Estas representaciones permiten analizar la distribución espacial y los patrones de expresión de los distintos genes a lo largo del UMAP.

4.4. Representación células B

Una vez anotados los principales grupos celulares, se decidió extraer las células B (11.053 células B) y analizarlas de forma independiente. Para ello, se realizó nuevamente la construcción de clústeres, cuyo resultado se muestra en la ***Figura 10***. En dicha representación se distinguen claramente dos regiones bien definidas, una correspondiente al clúster representado en color verde y otra al clúster representado en color rojo.

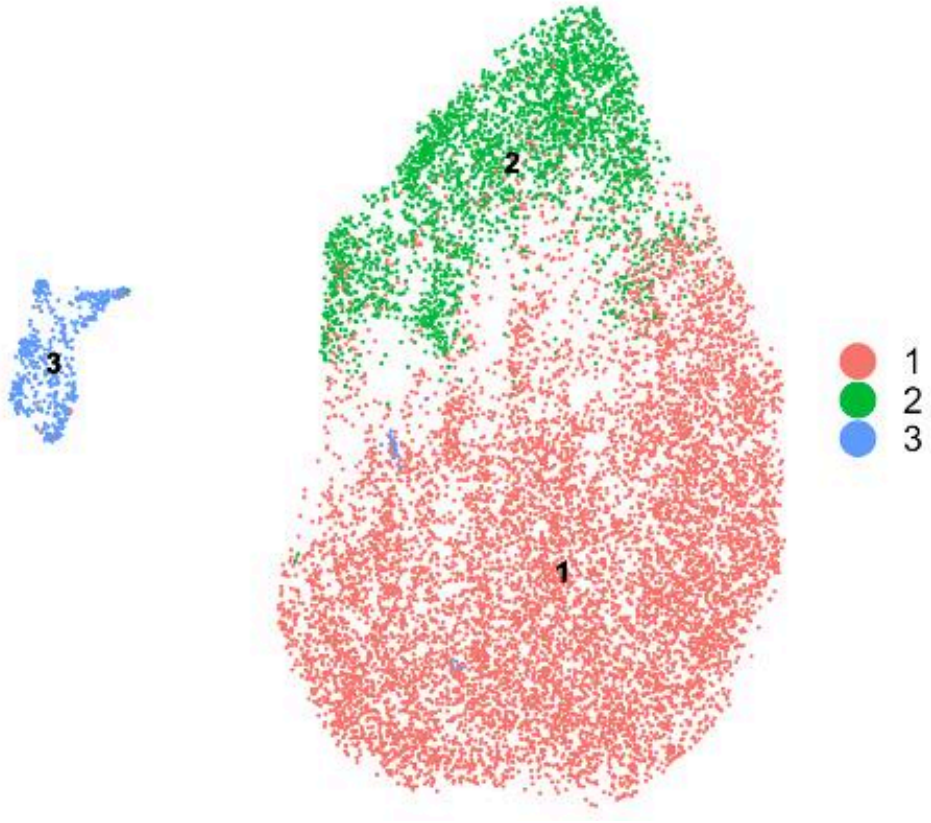

Figura 10: Representación UMAP coloreada según los resultados de análisis de agrupamiento sin ajustar con regresión de los genes ribosómicos. ICP.

Representación UMAP de las células B, coloreadas según los grupos obtenidos tras el análisis de agrupamiento con una resolución de 0,1, previo al ajuste por la variable asociada a los genes ribosómicos. Se identifican tres grupos bien definidos. El grupo 3 muestra un perfil claramente diferenciado respecto a los grupos 1 y 2. Por último, aunque los grupos 1 y 2 se encuentran próximos entre sí en el espacio UMAP, presentan diferencias que permiten distinguirlos como poblaciones separadas.

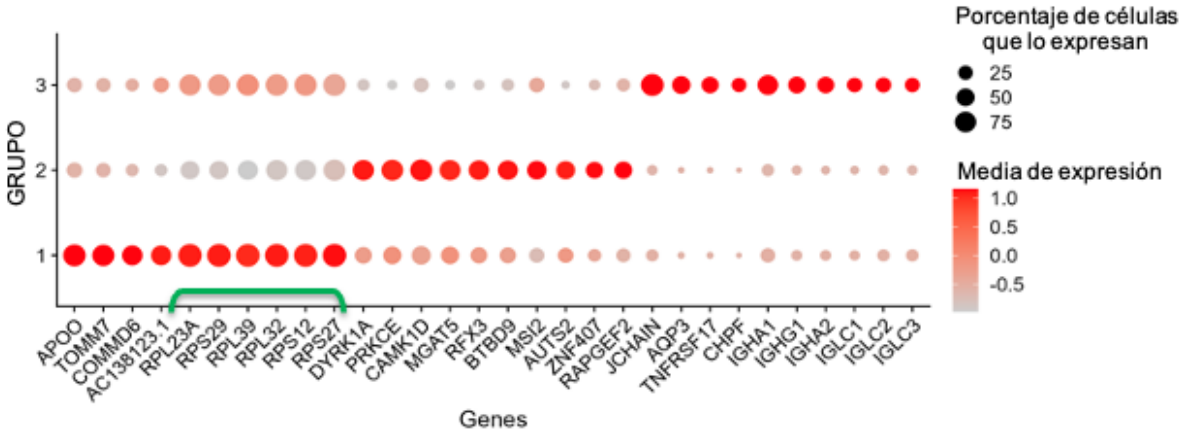

Gráfico 4: Gráfico de burbujas que muestra los 10 genes con mayor expresión diferencial entre los distintos grupos de células B. ICP.

Se presenta un gráfico de burbujas en la que el eje X representa los distintos grupos de células B, mientras que el eje Y muestra los 10 genes con mayor expresión diferencial entre dichos grupos. La intensidad del color indica la media de expresión de cada gen, y el tamaño de las burbujas refleja el porcentaje de células dentro de cada grupo que expresan ese gen. Se marcan en verde los genes ribosomales.

Con el fin de comprender el origen de esta separación, se elaboró un gráfico de burbujas (***Gráfico 4***) en el que se muestran los diez genes diferencialmente expresados en cada clúster. Como se observa, en el clúster 1 una gran proporción de estos genes corresponde a genes ribosómicos, identificables por comenzar con el prefijo *RPL* o *RPS* (marcados con un corchete de color verde en el ***Gráfico 4***). Debido a la influencia que este tipo de genes puede ejercer sobre la distribución celular, se decidió realizar una regresión de la expresión de genes ribosómicos durante el proceso de normalización, evitando así que afectaran a la representación de las células B en el UMAP. El resultado de esta corrección se presenta en la ***Figura 11***, tras obtener los grupos.

Tras la obtención de los clústeres, se recalculó la anotación por clúster utilizando como referencia las bases de datos HumanPrimaryCellAtlasData y *BlueprintEncodeData*. Los resultados de esta nueva anotación se muestran en ***Figura 12***. Al igual que en el análisis del conjunto celular global, se verificó que los clústeres identificados expresaran genes característicos coherentes con la anotación asignada por dichas bases de datos. Los genes empleados para esta validación se detallan en ***Tabla 2***, mientras que su patrón de expresión en el espacio UMAP se representa en las ***Figura 13***.

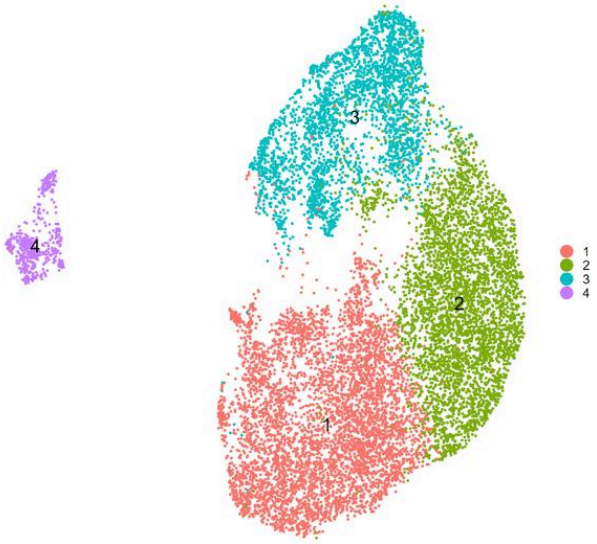

Figura 11: Representación UMAP coloreada según los resultados de análisis de agrupamiento ajustado con regresión de los genes ribosómicos. ICP.

Representación UMAP de las células B, coloreadas según los grupos obtenidos tras el análisis de agrupamiento con una resolución de 0,1, después al ajuste por la variable asociada a los genes ribosómicos. Se identifican cuatro grupos bien definidos. El grupo 4 muestra un perfil claramente diferenciado respecto a los grupos 1, 2 y 3. Por último, el grupo 2 se encuentra relacionado con expresión tanto con el grupo 3 como con el 1.

A partir de este análisis, se identificaron tres grandes grupos de células B: células B naïve (CBn), células B de memoria (CB mem) y plasmablastos. A su vez, las células B de memoria se subdividen en células de memoria con cambio de clase (CB mem C) y células de memoria sin cambio de clase (CB mem NC), lo que refleja distintos estados funcionales dentro de este linaje celular.

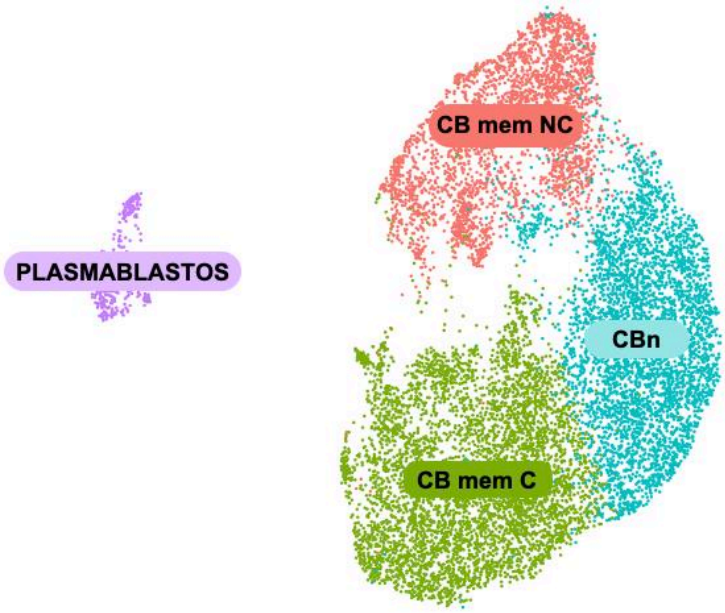

Figura 12: Representación UMAP coloreada según la distribución de los tipos celulares en células B. ICP.

Se muestra la representación UMAP coloreada según la distribución de los distintos tipos celulares de las células B (CBn (Células B Naïve), CB mem NC (Células B de memoria no cambio de clase), CB mem C (Celulas B de memoria con cambio de calse) y plasmablastos), de acuerdo con los resultados obtenidos mediante la anotación basada en Human Primary Cell Atlas Data y Blueprint Encode Data, y tras su revisión y validación mediante la expresión de genes marcadores específicos para cada tipo celular.

Figura 13: Representación UMAP de 7 genes representativos de los diferentes tipos subtipos de células B. ICP.

Se muestran seis representaciones UMAP, cada una correspondiente a un gen diferente. En cada proyección, el color rojo indica las células en las que el gen se encuentra expresado, mientras que el color gris representa aquellas en las que no se detecta expresión. La intensidad del color rojo refleja el nivel de expresión génica, de manera que tonalidades más intensas indican una mayor expresión. Estas representaciones permiten analizar la distribución espacial y los patrones de expresión de los distintos genes a lo largo del UMAP.
El gen MS4A1 (CD20) se expresa de forma general en las células B. CD27 es un marcador característico de células B de memoria y plasmablastos. IGHD se expresa tanto en células B naïve como en células B de memoria sin cambio de clase. FCER2 muestra una expresión específica en células B naïve. Por su parte, IGHM se expresa en células B naïve y en células B de memoria sin cambio de clase. Finalmente, TCL1A es característico de las células B naïve, mientras que JCHAIN se expresa exclusivamente en plasmablastos.

4.5. Análisis en la proporción de número de células

En el análisis de las subpoblaciones de células B entre CPR y NCPR, se evaluaron si existían diferencias en la composición relativa de tipos celulares tanto en pretratamiento como en postneoadyuvancia. Para ello, se calcularon el porcentaje de cada tipo celular en función del total de células (para células B totales respecto al total de células) y dentro de cada linaje (por ejemplo, células B naïve, células de memoria y plasmablastos con respecto al total de células B, y memoria sin cambio de clase, memoria con cambio de clase con respecto al total de células de memoria). En el ***Gráfico 5*** se muestran estas comparaciones. Los resultados no revelan diferencias estadísticamente significativas en la distribución de subtipos de células B entre los grupos de pacientes (respondedores vs no respondedores), ni en muestras pretratamiento ni en postneoadyuvancia. Sin embargo, sí identificamos una tendencia (p=0.101) observable tras el tratamiento: los NCPR tienden a tener una proporción mayor de células de memoria sin cambio de clase, mientras que los CPR

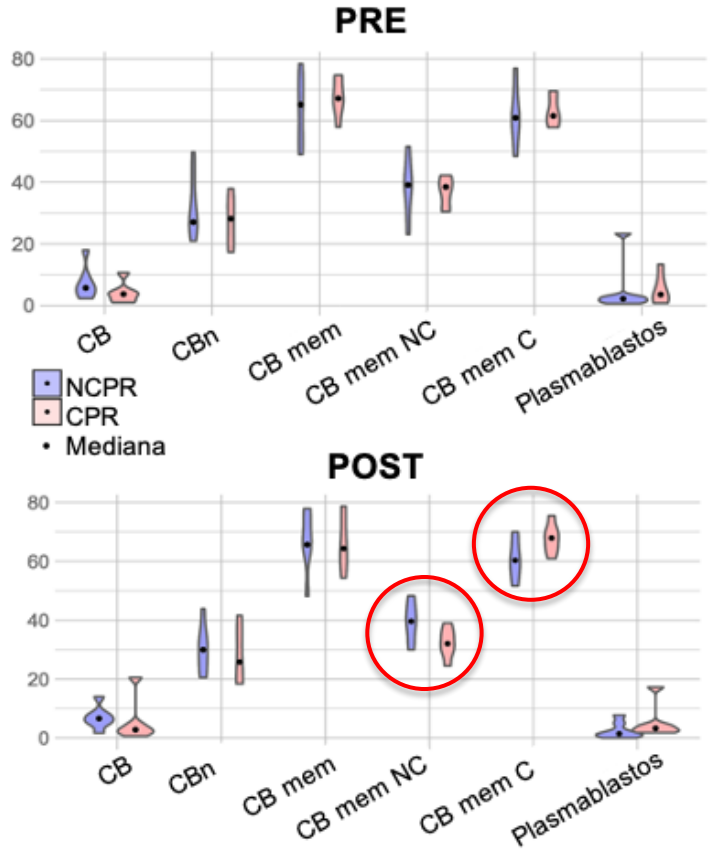

Gráfico 5: Gráfico de violines según el porcentaje de células en relación con su progenitor más cercano respecto a los diferentes tipos celulares de CB. ICP.

Se presenta dos gráficos de violines en el que se representan, para cada paciente y tipo celular, el porcentaje de células en relación con su progenitor más cercano, diferenciando entre los grupos NCPR (azul) y CPR (rojo) en pretratamiento (PRE) y en postneoadyuvancia (POST). El punto negro representa la mediana. No se observaron diferencias estadísticamente significativas entre ambos grupos. No obstante, en postneoadyuvancia se aprecia una tendencia al aumento de las células B de memoria sin cambio de clase en el grupo NCPR (p = 0,101), así como una tendencia al incremento de las células B con cambio de clase en el grupo CPR (p = 0,101) (Rodeado de color rojo).

muestran una proporción mayor de células de memoria con cambio de clase. Aunque estas tendencias no alcanzan significación estadística, podrían indicar cambios biológicamente relevantes en la composición de células B asociados a la respuesta al tratamiento.

Estas observaciones sugieren la hipótesis de que la diferenciación y maduración de células B podría estar vinculada a la eficacia del tratamiento anticancerígeno. En particular, una mayor proporción de células de memoria con cambio de clase en respondedores puede reflejar una respuesta humoral más eficaz o un mayor desarrollo de memoria inmunológica adaptativa tras tratamiento, mientras que una mayor presencia de memoria sin cambio de clase en no respondedores podría estar asociada a una respuesta menos eficaz del sistema inmune adaptativo. Por ejemplo, Flippot et al. (2024) (37) observaron que la infiltración de células de memoria B con cambio de clase se correlaciona con mayores tasas de respuesta a inhibidores de puntos de control inmunitario en melanoma y carcinoma de células renales, lo que sugiere que un perfil de maduración de las células B más completo y humoralmente activo puede facilitar la eficacia terapéutica.

4.6. Análisis de los genes diferentemente expresados

Además de analizar las diferencias en el número de los diferentes tipos de células B entre CPR y NCPR en pretratamiento y postneoadyuvancia, se realizaron análisis de expresión diferencial de genes en cada subtipo de célula B entre estos dos grupos en pretratamiento y postneoadyuvancia. Los gráficos de volcanes que resumen estos resultados se muestran en el ***Gráfico 6***, divididos por subtipo celular y por comparación pretratamiento y postneoadyuvancia entre respondedores y no respondedores.

Los genes que tienen mayor expresión en pacientes con tumores NCPR y se repiten en varios vulcanos son NRG1, PIGR y AC090125.1. El gen NRG1 (neuregulin 1) codifica un factor de crecimiento que se une a receptores como HER3/ERBB3, modulando vías de señalización de proliferación y supervivencia celular; se ha implicado en mecanismos

de resistencia terapéutica en tumores que expresan su receptor, sugiriendo que niveles elevados pueden contribuir a un fenotipo resistente al tratamiento (38,39).

El gen PIGR (polymeric immunoglobulin receptor) facilita el transporte de inmunoglobulinas (IgA e IgM) a través de epitelios y su expresión en diversos tumores ha sido relacionada con cambios en el microambiente inmunológico y características clínicas, aunque sus efectos pueden variar según el contexto tumoral (40,41). En nuestro análisis, PIGR aparece más expresado en pacientes no respondedores, lo que podría reflejar diferencias en la regulación de respuestas humorales o inflamatorias entre los grupos.

Además, en los pacientes CPR se observa una mayor expresión de genes asociados a inmunoglobulinas, lo que sugiere una respuesta humoral activa y madura. Estudios previos han demostrado que niveles elevados de genes como IGKC y otras cadenas ligeras de inmunoglobulina se asocian con una mejor respuesta a terapias inmunológicas, incluyendo inhibidores de puntos de control inmunitario (42). La expansión clonal del repertorio de inmunoglobulinas y la expresión de genes del segmento IGHV se han relacionado con pronóstico favorable y estados funcionales activos en linajes B (43). Estos resultados podrían apoyar que una mayor activación de células B productoras de inmunoglobulinas puede ser un marcador de respuesta eficaz al tratamiento.

El gen MYO3B ha sido descrito como un promotor de la progresión tumoral y de mal pronóstico en distintos contextos oncológicos (44). Sin embargo, su mayor expresión en el grupo CPR podría reflejar un papel dependiente del contexto celular, asociado a estados celulares más activos que, aunque favorezcan la progresión tumoral, también podrían ser más sensibles al tratamiento.

Por último, AC090125.1, predominante en el grupo NCPR, y AL021155.5, AC239799.2 y AL034397.3, predominantes en el grupo CPR, corresponden a transcripciones no codificantes largas (lncRNAs). Aunque estos lncRNAs se encuentran aún poco caracterizados a nivel funcional, numerosos estudios han demostrado que este tipo de transcritos se asocian con firmas transcripcionales relacionadas con la respuesta al tratamiento y con la heterogeneidad tumoral. Esto sugiere que los lncRNAs podrían actuar como marcadores regulatorios del estado celular o como potenciales indicadores de respuesta terapéutica (45).

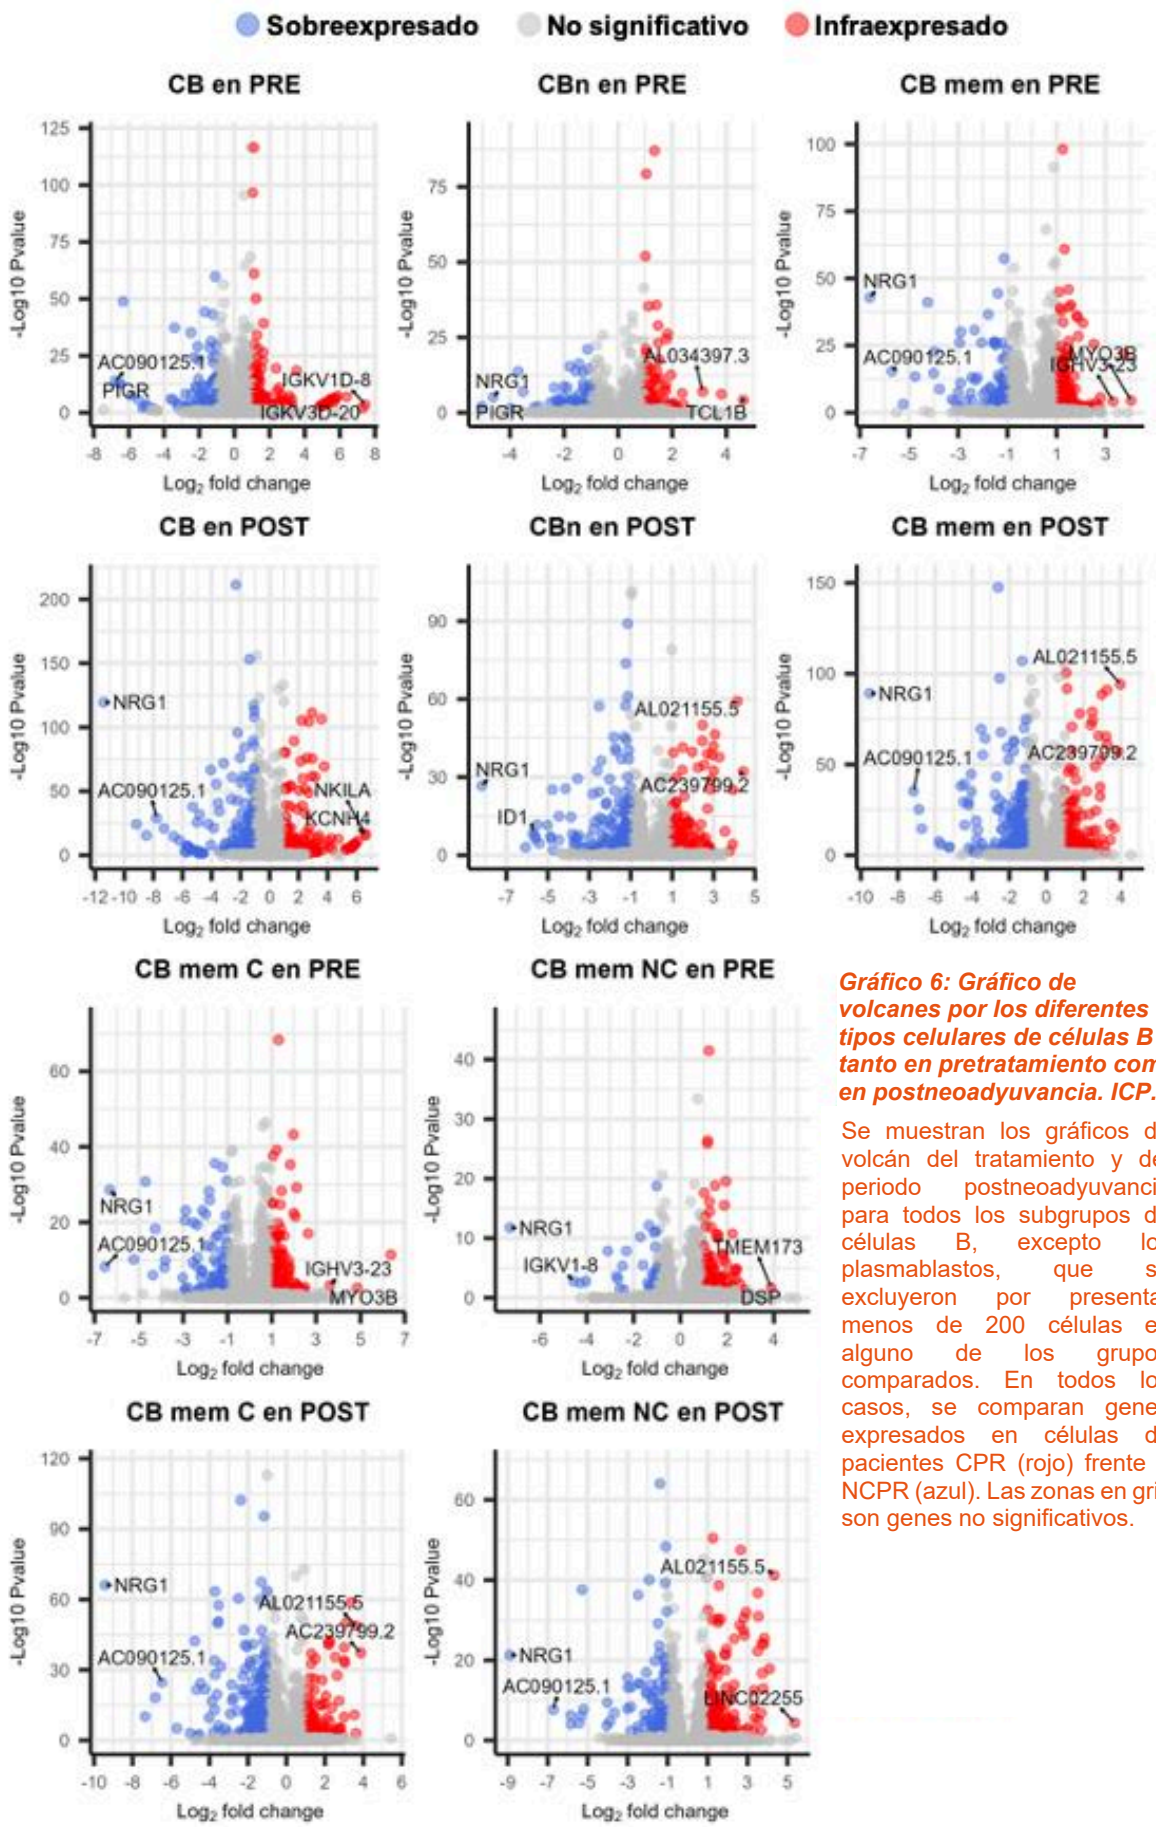

Gráfico 6: Gráfico de volcanes por los diferentes tipos celulares de células B tanto en pretratamiento como en postneoadyuvancia. ICP.

Se muestran los gráficos de volcán del tratamiento y del periodo postneoadyuvancia para todos los subgrupos de células B, excepto los plasmablastos, que se excluyeron por presentar menos de 200 células en alguno de los grupos comparados. En todos los casos, se comparan genes expresados en células de pacientes CPR (rojo) frente a NCPR (azul). Las zonas en gris son genes no significativos.

4.7. Análisis de las rutas diferentemente expresadas

Tras la identificación de los genes diferencialmente expresados entre CPR y NCPR, tanto en muestras pretratamiento como postneoadyuvancia, se llevó a cabo un análisis de GSEA con el objetivo de identificar las rutas biológicas significativamente enriquecidas en cada condición. Este enfoque permitió evaluar diferencias funcionales entre ambos grupos de pacientes y analizar cómo estas varían tras la administración del tratamiento.

En la ***Figura 14***, al analizar específicamente las células B, se observan diferencias claras entre CPR y NCPR, tanto en condiciones basales como tras el tratamiento. En el pre-tratamiento, los pacientes que CPR presentan un enriquecimiento significativo exclusivamente en rutas relacionadas con la respuesta inmune adaptativa, lo que sugiere un estado basal del sistema inmune más preparado o predispuesto a responder. En el postneoadyuvancia, estos pacientes no solo mantienen el enriquecimiento de dicha ruta, sino que además muestran una activación adicional de rutas relacionadas con la respuesta inmune mediada por inmunoglobulinas, lo que indica una mayor activación funcional de las células B inducida por la intervención terapéutica.

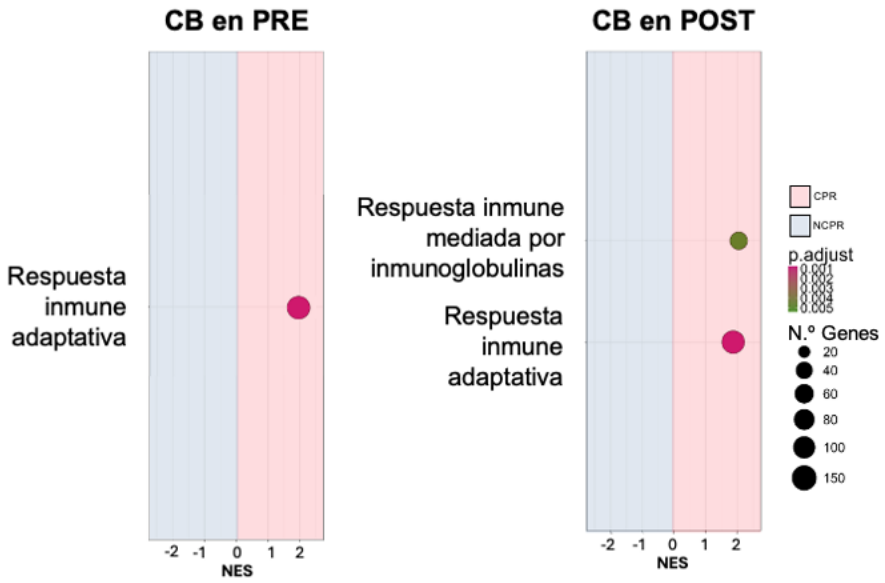

Figura 14: Representación del análisis de GSEA en las Células B. ICP.

Se muestra el análisis GSEA en células B generales en condiciones de pretratamiento (PRE) y postneoadyuvancia (POST). En el eje Y se representan las rutas significativamente enriquecidas y en el eje X el NES (Normalized Enrichment Score), que indica tanto la dirección como la intensidad del enriquecimiento de cada ruta: valores positivos reflejan rutas más activas en CPR (zona rojiza), mientras que valores negativos indican mayor actividad en NCPR (zona azulada). El tamaño del círculo representa el número de genes implicados en cada ruta y el color del punto el valor de *p* ajustado (p.adjust).

Las células B de memoria totales muestran un patrón muy similar (***Figura 15***). En el pretratamiento, los CPR presentan un enriquecimiento de rutas asociadas al sistema inmune, lo que refuerza la idea de un estado basal inmunológicamente activo. Tras el tratamiento, en estos mismos pacientes se observa un aumento tanto en el número como en la diversidad de rutas inmunitarias enriquecidas, lo que indica una activación inmune más intensa y compleja. Por el contrario, en los NCPR predominan, en el pretratamiento, rutas relacionadas con procesos de desarrollo celular, mientras que en el postneoadyuvancia se observa un enriquecimiento de rutas asociadas a la regulación y al procesamiento de ARNm, lo que podría reflejar una mayor actividad ribosomal y una respuesta centrada en procesos celulares básicos más que en funciones inmunitarias efectivas.

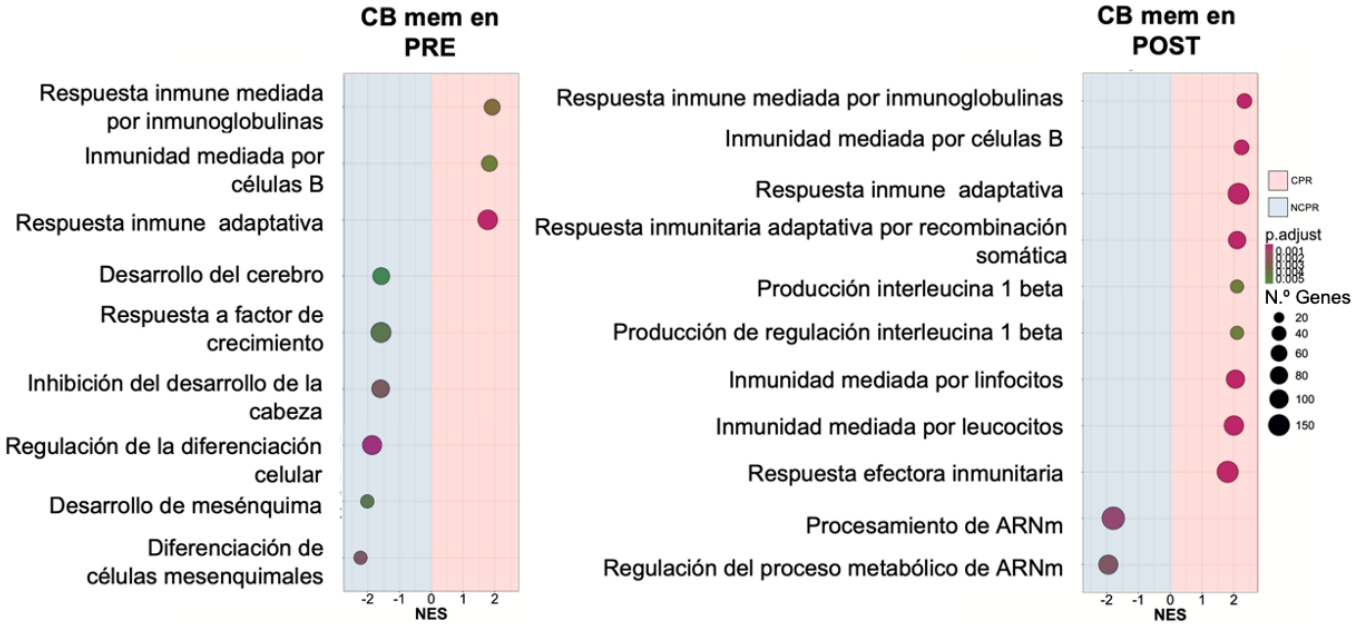

Figura 15: Representación del análisis de GSEA en las Células B memoria. ICP.

Se muestra el análisis GSEA en células B memoria en condiciones de pretratamiento (PRE) y postneoadyuvancia (POST). En el eje Y se representan las rutas significativamente enriquecidas y en el eje X el NES, que indica tanto la dirección como la intensidad del enriquecimiento de cada ruta: valores positivos reflejan rutas más activas en CPR (zona rojiza), mientras que valores negativos indican mayor actividad en NCPR (zona azulada). El tamaño del círculo representa el número de genes implicados en cada ruta y el color del punto el valor de *p* ajustado (p.adjust).

Un patrón comparable se observa en las células B de memoria con cambio de clase (***Figura 16***). En el pretratamiento, los CPR presentan nuevamente un mayor enriquecimiento de rutas asociadas a la respuesta inmune adaptativa. En postneoadyuvancia, estas células

muestran un enriquecimiento más amplio y diverso de rutas inmunitarias, incluyendo inmunidad mediada por leucocitos, inmunidad mediada por linfocitos, procesos efectores inmunitarios, respuesta inmune mediada por inmunoglobulinas e inmunidad mediada por células B, entre otras. Este aumento en la complejidad de las rutas enriquecidas sugiere una activación más robusta y coordinada del compartimento de células B en los pacientes respondedores. En contraste, en los NCPR, este tipo celular presenta en el pretratamiento rutas relacionadas principalmente con desarrollo y diferenciación celular, mientras que en el postneoadyuvancia predominan rutas asociadas a la actividad ribosomal y al procesamiento de ARNm, lo que podría indicar una falta de activación inmunitaria funcional incluso tras la administración del tratamiento.

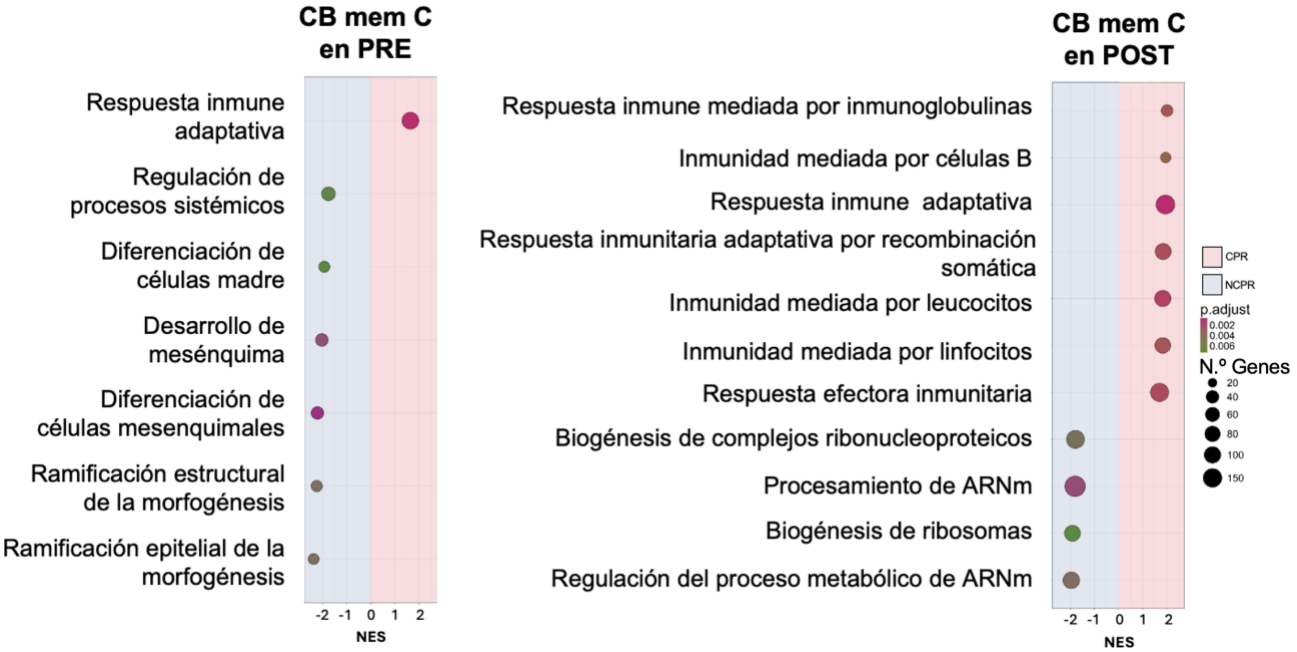

Figura 16: Representación del análisis de GSEA en las Células B memoria con cambio de clase. ICP.

Se muestra el análisis GSEA en células B memoria con cambio de clase en condiciones de pretratamiento (PRE) y postneoadyuvancia (POST). En el eje Y se representan las rutas significativamente enriquecidas y en el eje X el NES, que indica tanto la dirección como la intensidad del enriquecimiento de cada ruta: valores positivos reflejan rutas más activas en CPR (zona rojiza), mientras que valores negativos indican mayor actividad en NCPR (zona azulada). El tamaño del círculo representa el número de genes implicados en cada ruta y el color del punto el valor de *p* ajustado (p.adjust).

En las células B de memoria sin cambio de clase se observa un patrón coherente con los resultados descritos anteriormente (***Figura 17***). En el pretratamiento, únicamente se detectan rutas significativamente enriquecidas en los pacientes respondedores, todas ellas relacionadas con la actividad inmunitaria, lo que refuerza la hipótesis de un estado basal de

activación inmune en este grupo. En el postneoadyuvancia, estas rutas no solo se mantienen, sino que aumentan tanto en número como en intensidad, indicando una mayor activación funcional de este subtipo celular tras la terapia. Adicionalmente, en NCPR, se observa el enriquecimiento de rutas relacionadas con cilios y microtúbulos, lo que podría estar vinculado a procesos de reorganización del citoesqueleto y a cambios en la dinámica celular necesarios para la activación, proliferación o migración de las células inmunes inducidas por el tratamiento.

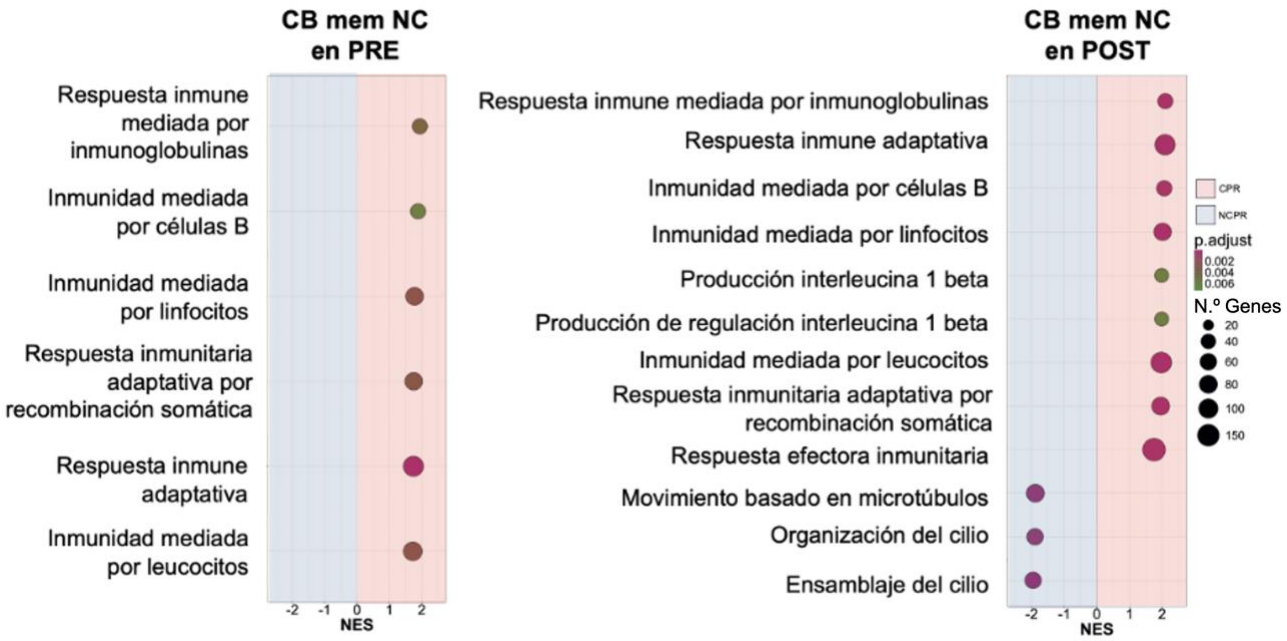

Figura 17: Representación del análisis de GSEA en las Células B memoria sin cambio de clase. ICP.

Se muestra el análisis GSEA en células B memoria sin cambio de clase en condiciones de pretratamiento (PRE) y postneoadyuvancia (POST). En el eje Y se representan las rutas significativamente enriquecidas y en el eje X el NES, que indica tanto la dirección como la intensidad del enriquecimiento de cada ruta: valores positivos reflejan rutas más activas en CPR (zona rojiza), mientras que valores negativos indican mayor actividad en NCPR (zona azulada). El tamaño del círculo representa el número de genes implicados en cada ruta y el color del punto el valor de *p* ajustado (p.adjust).

En el caso de las células B naïve, no se obtuvieron resultados significativos en la condición de pretratamiento (***Figura 18***). Sin embargo, en el postneoadyuvancia se observó que los CPR presentan un enriquecimiento de rutas relacionadas principalmente con la inmunidad adaptativa, en comparación con los NCPR. Este hallazgo sugiere que la activación de este subtipo celular podría ser inducida por el tratamiento en aquellos pacientes con capacidad

de respuesta terapéutica. En los NCPR, se volvieron a repetir rutas relacionadas con cilios pudiendo apoyar la hipótesis sobre la reorganización del citoesqueleto o cambios en la dinámica celular. Por su parte, los plasmablastos no fueron incluidos en este análisis debido a que el número total de células identificadas fue inferior a 200 por algún grupo comparado, lo que limita la robustez estadística del GSEA para este tipo celular.

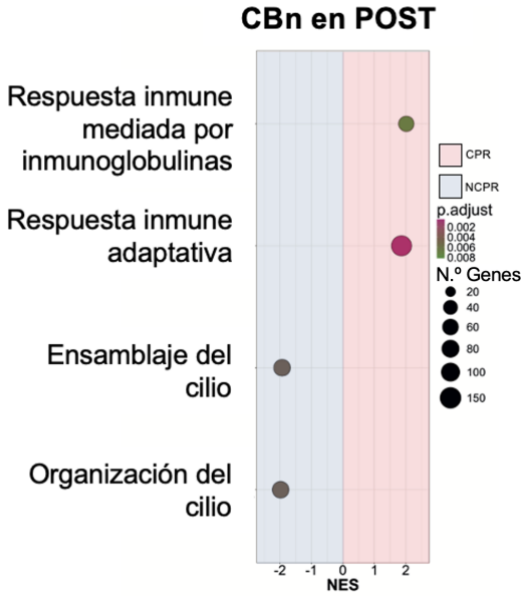

Figura 18: Representación del análisis de GSEA en las Células B naïve. ICP.

Se muestra el análisis GSEA en células B naïve en condiciones de pretratamiento (PRE) y postneoadyuvancia (POST). En el eje Y se representan las rutas significativamente enriquecidas y en el eje X el NES, que indica tanto la dirección como la intensidad del enriquecimiento de cada ruta: valores positivos reflejan rutas más activas en CPR (zona rojiza), mientras que valores negativos indican mayor actividad en NCPR (zona azulada). El tamaño del círculo representa el número de genes implicados en cada ruta y el color del punto el valor de *p* ajustado (p.adjust).

En conjunto, los resultados muestran que los CPR presentan un enriquecimiento significativo de rutas relacionadas con el sistema inmune, como la respuesta inmune adaptativa, la inmunidad mediada por leucocitos y la inmunidad mediada por células B. Un análisis más detallado revela que, antes del tratamiento, estos pacientes ya presentan un sistema inmune más predispuesto a responder, caracterizado por la activación basal de rutas inmunitarias clave. En postneoadyuvancia, estas rutas no solo se mantienen, sino que aumentan en intensidad y diversidad, lo que sugiere una potenciación de la respuesta inmune inducida por la terapia. En contraste, los pacientes no respondedores muestran un perfil dominado por rutas relacionadas con procesos celulares básicos, como el desarrollo, la diferenciación celular o la actividad ribosomal, incluso tras el tratamiento.

Estos resultados son coherentes con estudios previos que compararon tumores de pacientes respondedores y no respondedores a inhibidores de puntos de control inmunitario en melanoma. En dichos trabajos, los respondedores mostraron un enriquecimiento significativo de rutas asociadas a la activación del sistema inmune, incluyendo vías mediadas por citocinas y por receptores de células T y B, mientras que los no

respondedores presentaron un enriquecimiento en procesos no inmunitarios, como la actividad ribosomal. Estos hallazgos, confirmados mediante análisis de GSEA, apoyan la hipótesis de que un microambiente tumoral inmunológicamente activo se asocia con una mejor respuesta al tratamiento (46).

Otro estudio emplea transcriptómica espacial para caracterizar el microambiente tumoral en pacientes con cáncer de pulmón no microcítico tratados con inhibidores de puntos de control inmunitario. Los autores describen que los pacientes respondedores presentan una activación significativa de rutas inmunitarias, incluyendo aquellas mediadas por células B, así como una mayor organización espacial de poblaciones inmunes funcionalmente activas dentro del tumor. Estos hallazgos concuerdan con los resultados, en los que los pacientes respondedores presentan un enriquecimiento de rutas relacionadas con la inmunidad adaptativa y mediada por células B, tanto antes como después del tratamiento, lo que refuerza la importancia de la activación funcional del sistema inmune en la eficacia de la inmunoterapia (47).

5. Conclusiones

Una vez finalizado este trabajo, las conclusiones que hemos podido extraer son las siguientes:

1. Se diseñó y aplicó con éxito un pipeline bioinformático reproducible para el análisis de datos de transcriptómica de célula única (scRNA-seq) de 30 muestras de PBMCs, integrando diferentes herramientas y lenguajes de programación, lo que permitió un análisis robusto y sistemático de los datos.
2. El análisis específico de la distribución y abundancia de los subtipos de células B no reveló diferencias cuantitativas significativas entre CPR y NCPR, sugiriendo que la respuesta al tratamiento no está asociada a cambios en la proporción celular.
3. El estudio de los perfiles de expresión génica de las células B permitió identificar genes diferencialmente expresados entre CPR y NCPR tanto en condiciones de pretratamiento como de postneoadyuvancia.
4. El análisis funcional de enriquecimiento mostró que los CPR presentan una mayor activación de rutas biológicas relacionadas con la respuesta inmunológica y la función de las células B, especialmente tras el tratamiento neoadyuvante, lo que indica una potenciación de la respuesta inmunitaria asociada a una mejor respuesta terapéutica.
5. En conjunto, los resultados sugieren que la actividad funcional e inmunológica de las células B, más que su abundancia, podría desempeñar un papel clave en la respuesta al tratamiento neoadyuvante, aportando información relevante para la identificación futura de biomarcadores inmunológicos predictivos en el contexto del estudio NADIM.

6. Limitaciones y perspectivas futuras

Limitaciones de este estudio son:

1. El tamaño muestral limitado (26 muestras de PBMCs) reduce la potencia estadística para detectar diferencias entre CPR y NCPR, especialmente en los análisis de abundancia celular, y puede verse afectado por la heterogeneidad clínica de los pacientes.
2. El estudio se ha realizado únicamente sobre sangre periférica, lo que impide evaluar directamente los procesos inmunológicos del microambiente tumoral.
3. El uso de scRNA-seq presenta limitaciones técnicas inherentes, como *dropouts*, variabilidad en la profundidad de secuenciación y posibles sesgos técnicos entre muestras.
4. Los resultados obtenidos son observacionales y no permiten establecer relaciones causales entre la activación inmunológica de las células B y la respuesta al tratamiento.

Las perspectivas futuras de este estudio son:

1. La ampliación de la cohorte permitiría validar los resultados y aumentar la robustez estadística.
2. La integración de datos del microambiente tumoral y técnicas espaciales aportaría una visión más completa de la respuesta inmunitaria.
3. El desarrollo de análisis multiómicos y el estudio de otros tipos celulares inmunitarios más allá de las células B permitirían profundizar en los mecanismos implicados en la respuesta al tratamiento.
4. La validación experimental de los genes y rutas identificadas y el análisis de las interacciones entre células B y otros compartimentos inmunitarios reforzarían su potencial como biomarcadores predictivos.

7. Bibliografía

1. Sierra-Rodero B, Cruz-Bermúdez A, Nadal E, Garitaonaindía Y, Insa A, Mosquera J, et al. Clinical and molecular parameters associated to pneumonitis development in non-small-cell lung cancer patients receiving chemoimmunotherapy from NADIM trial. J Immunother Cancer [Internet]. 2021 [citado 10 de noviembre de 2025];9:2804. Disponible en: https://jitc.bmj.com
2. Provencio M, Nadal E, Insa A, García-Campelo MR, Casal-Rubio J, Dómine M, et al. Neoadjuvant chemotherapy and nivolumab in resectable non-small-cell lung cancer (NADIM): an open-label, multicentre, single-arm, phase 2 trial. Lancet Oncol [Internet]. 1 de noviembre de 2020 [citado 10 de noviembre de 2025];21(11):1413-22. Disponible en: https://pubmed.ncbi.nlm.nih.gov/32979984/
3. Cascone T, Awad MM, Spicer JD, He J, Lu S, Sepesi B, et al. Perioperative Nivolumab in Resectable Lung Cancer. New England Journal of Medicine [Internet]. 16 de mayo de 2024 [citado 10 de noviembre de 2025];390(19):1756-69. Disponible en: https://www.nejm.org/doi/pdf/10.1056/NEJMoa2311926
4. Sierra Rodero B, Martínez-Toledo C, Nadal E, Molina-Alejandre M, García Campelo R, Gil-González Á, et al. Peripheral memory B cell population maintenance and long-term survival after perioperative chemoimmunotherapy in NSCLC (NADIM trial). Oncoimmunology [Internet]. 31 de diciembre de 2025 [citado 10 de noviembre de 2025];14(1). Disponible en: https://www.tandfonline.com/doi/pdf/10.1080/2162402X.2025.2513109
5. Sridhar A, Khan H, Yohannan B, Chan KH, Kataria N, Jafri SH. A Review of the Current Approach and Treatment Landscape for Stage III Non-Small Cell Lung Cancer. J Clin Med [Internet]. 1 de mayo de 2024 [citado 10 de noviembre de 2025];13(9). Disponible en: https://pubmed.ncbi.nlm.nih.gov/38731161/
6. Son JW, Lee J, Jeon JH, Cho S, Jung W, Shih BCH, et al. Validation of IASLC 9th edition TNM classification for lung cancer: focus on N descriptor. BMC Cancer [Internet]. 1 de diciembre de 2024 [citado 10 de noviembre de 2025];24(1). Disponible en: https://pubmed.ncbi.nlm.nih.gov/39604857/

7. Ganti AK, Klein AB, Cotarla I, Seal B, Chou E. Update of Incidence, Prevalence, Survival, and Initial Treatment in Patients With Non–Small Cell Lung Cancer in the US. JAMA Oncol [Internet]. 1 de diciembre de 2021 [citado 9 de febrero de 2026];7(12):1824-32. Disponible en: https://jamanetwork.com/journals/jamaoncology/fullarticle/2784988
8. Jeon H, Wang S, Song J, Gill H, Cheng H. Update 2025: Management of Non-Small-Cell Lung Cancer. Lung 2025 203:1 [Internet]. 25 de marzo de 2025 [citado 10 de noviembre de 2025];203(1):1-15. Disponible en: https://link.springer.com/article/10.1007/s00408-025-00801-x
9. Li T, He W, Zhang X, Zhou Y, Wang D, Huang S, et al. Survival outcomes of segmentectomy and lobectomy for early stage non-small cell lung cancer: a systematic review and meta-analysis. Journal of Cardiothoracic Surgery 2024 19:1 [Internet]. 22 de junio de 2024 [citado 10 de noviembre de 2025];19(1):1-9. Disponible en: https://cardiothoracicsurgery.biomedcentral.com/articles/10.1186/s13019-024-02832-6
10. Provencio M, Nadal E, González-Larriba JL, Martínez-Martí A, Bernabé R, Bosch-Barrera J, et al. Perioperative Nivolumab and Chemotherapy in Stage III Non–Small-Cell Lung Cancer. New England Journal of Medicine [Internet]. 10 de agosto de 2023 [citado 10 de noviembre de 2025];389(6):504-13. Disponible en: https://www.nejm.org/doi/pdf/10.1056/NEJMoa2215530
11. Planchard D, Jänne PA, Cheng Y, Yang JCH, Yanagitani N, Kim SW, et al. Osimertinib with or without Chemotherapy in EGFR -Mutated Advanced NSCLC . New England Journal of Medicine [Internet]. 23 de noviembre de 2023 [citado 10 de noviembre de 2025];389(21):1935-48. Disponible en: https://www.nejm.org/doi/pdf/10.1056/NEJMoa2306434
12. Brahmer J, Reckamp KL, Baas P, Crinò L, Eberhardt WEE, Poddubskaya E, et al. Nivolumab versus Docetaxel in Advanced Squamous-Cell Non–Small-Cell Lung Cancer. New England Journal of Medicine [Internet]. 9 de julio de 2015 [citado 13 de noviembre de 2025];373(2):123-35. Disponible en: https://www.nejm.org/doi/pdf/10.1056/NEJMoa1504627
13. Gettinger SN, Horn L, Gandhi L, Spigel DR, Antonia SJ, Rizvi NA, et al. Overall Survival and Long-Term Safety of Nivolumab (Anti-Programmed Death 1 Antibody, BMS-936558, ONO-4538) in Patients With Previously Treated Advanced Non-Small-

Cell Lung Cancer. J Clin Oncol [Internet]. 20 de junio de 2015 [citado 13 de noviembre de 2025];33(18):2004-12. Disponible en: https://pubmed.ncbi.nlm.nih.gov/25897158/

14. Provencio M, Nadal E, Insa A, García Campelo R, Casal J, Dómine M, et al. Perioperative chemotherapy and nivolumab in non-small-cell lung cancer (NADIM): 5-year clinical outcomes from a multicentre, single-arm, phase 2 trial. Lancet Oncol [Internet]. 1 de noviembre de 2024 [citado 13 de noviembre de 2025];25(11):1453-64. Disponible en: https://www.thelancet.com/action/showFullText?pii=S1470204524004984
15. Provencio M, Nadal E, Insa A, García-Campelo MR, Casal-Rubio J, Dómine M, et al. Neoadjuvant chemotherapy and nivolumab in resectable non-small-cell lung cancer (NADIM): an open-label, multicentre, single-arm, phase 2 trial. Lancet Oncol [Internet]. 1 de noviembre de 2020 [citado 13 de noviembre de 2025];21(11):1413-22. Disponible en: https://www.thelancet.com/action/showFullText?pii=S1470204520304538
16. Lin X, Kang K, Chen P, Zeng Z, Li G, Xiong W, et al. Regulatory mechanisms of PD-1/PD-L1 in cancers. Molecular Cancer 2024 23:1 [Internet]. 18 de mayo de 2024 [citado 13 de noviembre de 2025];23(1):1-50. Disponible en: https://molecular-cancer.biomedcentral.com/articles/10.1186/s12943-024-02023-w
17. Sierra Rodero B, Martínez-Toledo C, Nadal E, Molina-Alejandre M, García Campelo R, Gil-González Á, et al. Peripheral memory B cell population maintenance and long-term survival after perioperative chemoimmunotherapy in NSCLC (NADIM trial). Oncoimmunology [Internet]. 2025 [citado 13 de noviembre de 2025];14(1). Disponible en: /doi/pdf/10.1080/2162402X.2025.2513109?download=true
18. Massoni-Badosa R, Aguilar-Fernández S, Nieto JC, Soler-Vila P, Elosua-Bayes M, Marchese D, et al. An atlas of cells in the human tonsil. Immunity [Internet]. 13 de febrero de 2024 [citado 13 de noviembre de 2025];57(2):379-399.e18. Disponible en: https://www.cell.com/action/showFullText?pii=S1074761324000311
19. Pernes JI, Alsayah A, Tucci F, Bashford-Rogers RJM. Unravelling B cell heterogeneity: insights into flow cytometry-gated B cells from single-cell multi-omics data. Front Immunol. 18 de abril de 2024;15:1380386.
20. Le J, Dian Y, Zhao D, Guo Z, Luo Z, Chen X, et al. Single-cell multi-omics in cancer immunotherapy: from tumor heterogeneity to personalized precision treatment. Molecular Cancer 2025 24:1 [Internet]. 25 de agosto de 2025 [citado 13 de noviembre

de 2025];24(1):221-. Disponible en: https://molecular-cancer.biomedcentral.com/articles/10.1186/s12943-025-02426-3

21. Liu J, Qu S, Zhang T, Gao Y, Shi H, Song K, et al. Applications of Single-Cell Omics in Tumor Immunology. Front Immunol [Internet]. 2021 [citado 13 de noviembre de 2025];12:697412. Disponible en: https://pubmed.ncbi.nlm.nih.gov/34177965/
22. Kim GD, Shin SI, Sun P, Lee JE, Chung C, Kang YE, et al. Single-cell RNA sequencing of baseline PBMCs predicts ICI efficacy and irAE severity in patients with NSCLC. J Immunother Cancer [Internet]. 22 de mayo de 2025 [citado 13 de noviembre de 2025];13(5). Disponible en: https://pubmed.ncbi.nlm.nih.gov/40404203/
23. Bai Z, Su G, Fan R. Single-cell Analysis Technologies for Immuno-oncology Research: from Mechanistic Delineation to Biomarker Discovery. Genomics Proteomics Bioinformatics [Internet]. 1 de abril de 2021 [citado 13 de noviembre de 2025];19(2):191-207. Disponible en: https://pubmed.ncbi.nlm.nih.gov/34000441/
24. Hafemeister C, Satija R. Normalization and variance stabilization of single-cell RNA-seq data using regularized negative binomial regression. Genome Biology 2019 20:1 [Internet]. 23 de diciembre de 2019 [citado 2 de febrero de 2026];20(1):296-. Disponible en: https://link.springer.com/article/10.1186/s13059-019-1874-1
25. Tsuyuzaki K, Sato H, Sato K, Nikaido I. Benchmarking principal component analysis for large-scale single-cell RNA-sequencing. Genome Biology 2020 21:1 [Internet]. 20 de enero de 2020 [citado 2 de febrero de 2026];21(1):9-. Disponible en: https://link.springer.com/article/10.1186/s13059-019-1900-3
26. Korsunsky I, Millard N, Fan J, Slowikowski K, Zhang F, Wei K, et al. Fast, sensitive and accurate integration of single-cell data with Harmony. Nat Methods [Internet]. 1 de diciembre de 2019 [citado 8 de enero de 2026];16(12):1289-96. Disponible en: https://pubmed.ncbi.nlm.nih.gov/31740819/
27. Mabbott NA, Baillie JK, Brown H, Freeman TC, Hume DA. An expression atlas of human primary cells: inference of gene function from coexpression networks. BMC Genomics 2013 14:1 [Internet]. 20 de septiembre de 2013 [citado 2 de febrero de 2026];14(1):632-. Disponible en: https://link.springer.com/article/10.1186/1471-2164-14-632
28. Dunham I, Kundaje A, Aldred SF, Collins PJ, Davis CA, Doyle F, et al. An Integrated Encyclopedia of DNA Elements in the Human Genome. Nature [Internet]. 6 de

septiembre de 2012 [citado 2 de febrero de 2026];489(7414):57. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC3439153/

29. Pavlasova G, Mraz M. The regulation and function of CD20: an “enigma” of B-cell biology and targeted therapy. Haematologica [Internet]. 1 de junio de 2020 [citado 8 de enero de 2026];105(6):1494. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC7271567/
30. Azizi G, Van den Broek B, Ishikawa LLW, Naziri H, Yazdani R, Zhang GX, et al. IL-7Rα on CD4+ T cells is required for their survival and the pathogenesis of experimental autoimmune encephalomyelitis. Journal of Neuroinflammation 2024 21:1 [Internet]. 8 de octubre de 2024 [citado 8 de enero de 2026];21(1):253-. Disponible en: https://link.springer.com/article/10.1186/s12974-024-03224-2
31. Marafioti T, Paterson JC, Ballabio E, Chott A, Natkunam Y, Rodriguez-Justo M, et al. The inducible T-cell co-stimulator molecule is expressed on subsets of T cells and is a new marker of lymphomas of T follicular helper cell-derivation. Haematologica [Internet]. marzo de 2010 [citado 8 de enero de 2026];95(3):432. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC2833073/
32. Menon AP, Moreno B, Meraviglia-Crivelli D, Nonatelli F, Villanueva H, Barainka M, et al. Modulating T Cell Responses by Targeting CD3. Cancers (Basel) [Internet]. 1 de febrero de 2023 [citado 8 de enero de 2026];15(4):1189. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC9953819/
33. Oshi M, Asaoka M, Tokumaru Y, Yan L, Matsuyama R, Ishikawa T, et al. CD8 T Cell Score as a Prognostic Biomarker for Triple Negative Breast Cancer. Int J Mol Sci [Internet]. 2 de septiembre de 2020 [citado 8 de enero de 2026];21(18):1-16. Disponible en: https://pubmed.ncbi.nlm.nih.gov/32971948/
34. Turiello R, Ng SS, Tan E, van der Voort G, Salim N, Yong MCR, et al. NKG7 is a Stable Marker of Cytotoxicity Across Immune Contexts and Within the Tumor Microenvironment. Eur J Immunol [Internet]. 1 de junio de 2025 [citado 8 de enero de 2026];55(6). Disponible en: https://pubmed.ncbi.nlm.nih.gov/40538191/
35. Shi W, Wu W, Wang J, Meng X. Single-cell transcriptomics reveals comprehensive microenvironment and highlights the dysfuntional state of NK cells in endometrioid carcinoma. Medicine (United States) [Internet]. 29 de marzo de 2024 [citado 8 de enero de 2026];103(13):E37555. Disponible en: https://journals.lww.com/md-journal/fulltext/2024/03290/single_cell_transcriptomics_reveals_comprehensive.23.aspx

36. Ma M, Liu C, Jiang L, Liu D, Zhang P, Tao M, et al. Exploring the therapeutic efficacy difference in claudin18.2-targeted cell therapy revealed by single-cell sequencing. iScience [Internet]. 21 de febrero de 2025 [citado 14 de enero de 2026];28(2):111768. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC11804729/
37. Flippot R, Teixeira M, Rey-Cardenas M, Carril-Ajuria L, Rainho L, Naoun N, et al. B cells and the coordination of immune checkpoint inhibitor response in patients with solid tumors. J Immunother Cancer [Internet]. 16 de abril de 2024 [citado 20 de enero de 2026];12(4). Disponible en: https://pubmed.ncbi.nlm.nih.gov/38631710/
38. Yang L, Li Y, Shen E, Cao F, Li L, Li X, et al. NRG1-dependent activation of HER3 induces primary resistance to trastuzumab in HER2-overexpressing breast cancer cells. Int J Oncol [Internet]. 1 de noviembre de 2017 [citado 21 de enero de 2026];51(5):1553-62. Disponible en: https://pubmed.ncbi.nlm.nih.gov/29048656/
39. Schwarz LJ, Hutchinson KE, Rexer BN, Estrada MV, Gonzalez Ericsson PI, Sanders ME, et al. An ERBB1-3 Neutralizing Antibody Mixture With High Activity Against Drug-Resistant HER2+ Breast Cancers With ERBB Ligand Overexpression. J Natl Cancer Inst [Internet]. 1 de noviembre de 2017 [citado 21 de enero de 2026];109(11). Disponible en: https://pubmed.ncbi.nlm.nih.gov/29059433/
40. Chae J, Choi J, Chung J. Polymeric immunoglobulin receptor (pIgR) in cancer. J Cancer Res Clin Oncol [Internet]. 1 de diciembre de 2023 [citado 21 de enero de 2026];149(19):17683-90. Disponible en: https://pubmed.ncbi.nlm.nih.gov/37897659/
41. Ohkuma R, Yada E, Ishikawa S, Komura D, Kubota Y, Hamada K, et al. High expression levels of polymeric immunoglobulin receptor are correlated with chemoresistance and poor prognosis in pancreatic cancer. Oncol Rep [Internet]. 1 de julio de 2020 [citado 21 de enero de 2026];44(1):252. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC7251687/
42. Onieva JL, Xiao Q, Berciano-Guerrero MÁ, Laborda-Illanes A, de Andrea C, Chaves P, et al. High IGKC-Expressing Intratumoral Plasma Cells Predict Response to Immune Checkpoint Blockade. Int J Mol Sci [Internet]. 1 de agosto de 2022 [citado 21 de enero de 2026];23(16). Disponible en: https://pubmed.ncbi.nlm.nih.gov/36012390/
43. Wang Z, Cheng Z, Lu S, Chard Dunmall LS, Wang J, Guo Y, et al. Characterization of the Intra-tumoral B Cell Immunoglobulin Repertoire Is of Prognostic Value for Esophageal Squamous Cell Carcinoma. Front Immunol [Internet]. 22 de junio de 2022 [citado 21 de enero de 2026];13:896627. Disponible en: https://pmc.ncbi.nlm.nih.gov/articles/PMC9257635/

44. Zhang C, Zhang H, Yang X, Li S, Wang L, Su H, et al. MYO3B promotes cancer progression in endometrial cancer by mediating the calcium ion-RhoA/ROCK1 signaling pathway. Journal of Cancer Research and Clinical Oncology 2024 150:9 [Internet]. 19 de septiembre de 2024 [citado 3 de febrero de 2026];150(9):424-. Disponible en: https://link.springer.com/article/10.1007/s00432-024-05940-x

45. Bach DH, Lee SK. Long noncoding RNAs in cancer cells. Cancer Lett [Internet]. 10 de abril de 2018 [citado 21 de enero de 2026];419:152-66. Disponible en: https://www.sciencedirect.com/science/article/abs/pii/S0304383518300843?via%3Dihub

46. Wen J, Wang Y, Wang S, Liang Y, Hu X, Ou Q, et al. Genetic and transcriptional insights into immune checkpoint blockade response and survival: lessons from melanoma and beyond. Journal of Translational Medicine 2025 23:1 [Internet]. 23 de abril de 2025 [citado 28 de enero de 2026];23(1):467-. Disponible en: https://link.springer.com/article/10.1186/s12967-025-06467-6

47. Kim J, Yong SH, Jang G, Kim Y, Park R, Koh HH, et al. Spatial profiling of non-small cell lung cancer provides insights into tumorigenesis and immunotherapy response. Communications Biology 2024 7:1 [Internet]. 2 de agosto de 2024 [citado 28 de enero de 2026];7(1):930-. Disponible en: https://www.nature.com/articles/s42003-024-06568-w

USO DE DATOS EXPERIMENTALES EN EL TFM

Yo, D Alberto Cruz Bermúdez, con NIF 47289880V como persona que proporciona los datos a D Juan Manuel Gutiérrez Escobedo con NIF 78768898Q, estudiante del Máster Bioinformática de la Universidad Internacional de Valencia, en el curso académico abril 2025-2026.

PONGO EN CONOCIMIENTO DE QUIEN LO REQUIERA QUE,

el mencionado alumno puede emplear con libertad los datos experimentales obtenidos en el grupo en el cual participo con el fin de elaborar su Trabajo Fin de Máster en la titulación y curso académico indicado anteriormente.

En Madrid, a 13 de Noviembre de 2025

Firmado: Alberto Cruz Bermúdez
La persona que proporciona los datos al alumno