Inteligencia Artificial y Medicina personalizada.

Diseño de pipelines y modelos de predicción farmacogenómica

Titulación:
Máster Universitario en Bioinformática

Curso académico
2025-2026

Alumno/a: Hamed Outmani, Adrim
D.N.I: 45314907P

Director/a de TFM: Torres del Moral, Teresa

Convocatoria:

Primera

09 Marzo 2026

De:
Planeta Formación y Universidades

Índice

1. Introducción 3
2. Objetivos 6
3. Materiales y Métodos 7
3.1 Flujo y entorno de trabajo. 7
3.2 Fase I. Pipeline bioinformático 8
3.3 Fase II. Desarrollo del modelo de clasificación 11

Obtención de datos de entrenamiento 11
Preprocesamiento e Ingeniería de Características (Feature Engineering) 11
Diseño de la arquitectura de red neuronal 16
Entrenamiento y estrategia de optimización 19
Optimización de hiperparámetros 21

4. Resultados y discusión 23

Rendimiento global y métricas por tarea 24
Análisis arquitectónico y genético 25
Gestión del desbalance clínico (Focal Loss) 26
Desafíos en el procesamiento y preprocesamiento de datos 27
Estaticidad del modelo y barreras de acceso 27
Implicaciones clínicas y marco regulatorio traslacional 28

5. Trabajo futuro 30

Implementación de biblioteca de grafos farmacogenómicos 30
Arquitectura "Twin-Tower" con Atención Dinámica (GATv2) 34
Validación de la integridad topológica y estado actual 35

6. Conclusiones 35
7. Bibliografía 37
Anexo 1. Repositorio GitHub del Proyecto 39
Anexo 2. Criterios de selección de bases de datos 40

Lista de abreviaturas

5-FU → 5-Fluorouracilo

ADME → Absorción, Distribución, Metabolismo y Excreción

ATC → Anatomical Therapeutic Chemical (Clasificación Anatómica, Terapéutica y Química)

CID → Compound Identifier

CYP → Citocromo P450

DPYD → Dihidropirimidina deshidrogenasa

PD → Farmacodinamia (Pharmacodynamics)

PK → Farmacocinética (Pharmacokinetics)

MedDRA → Medical Dictionary for Regulatory Activities

BAM → Binary Alignment Map

dbSNP → Database of Short Genetic Variations

GFF → General Feature Format

HGVS → Human Genome Variation Society

Indel → Inserción/Deleción (Insertion/Deletion)

NGS → Next-Generation Sequencing (Secuenciación de Nueva Generación)

PCR → Polymerase Chain Reaction (Reacción en Cadena de la Polimerasa)

rsID → Reference SNP Cluster ID

SNP → Single Nucleotide Polymorphism (Polimorfismo de Nucleótido Único)

SNV → Single Nucleotide Variant (Variante de Nucleótido Único)

VCF → Variant Call Format

VEP → Variant Effect Predictor

CV → Cross-Validation (Validación Cruzada)

DNN → Deep Neural Network (Red Neuronal Profunda)

FM → Factorization Machines (Máquinas de Factorización)

GAT → Graph Attention Network

GELU → Gaussian Error Linear Unit

GNN → Graph Neural Networks (Redes Neuronales de Grafos)

ML → Machine Learning (Aprendizaje Automático)

MLP → Multilayer Perceptron (Perceptrón Multicapa)

MTL → Multi-Task Learning (Aprendizaje Multitarea)

PyG → PyTorch Geometric

CPU → Central Processing Unit (Unidad Central de Procesamiento)

GPU → Graphics Processing Unit (Unidad de Procesamiento Gráfico)

HPC → High-Performance Computing (Computación de Alto Rendimiento)

Índice de tablas

Tabla 1. Estructura de los archivos base usados para el entrenamiento del modelo……15

Índice de gráficos y figuras

Figura 1. Diseño del flujo de trabajo 8
Figura 2. Funcionamiento interno del modelo.....17
Figura 3. Comparativa de funciones de pérdida 21
Figura 4. Evolución de loss en Optuna. 22
Figura 5. Nodos de la molécula (Átomos) 31
Figura 6. Matriz de adyacencia Lorazepam (Enlaces).....32
Figura 7. Molécula de Lorazepam 32
Figura 8. Representación del grafo correspondiente al exón 3 del gen *CYP2D6*. 33

Resumen

Introducción: La transición hacia la medicina personalizada se ve obstaculizada por la complejidad biológica, la falta de estandarización en repositorios genómicos y la incapacidad de la farmacología clásica para modelar la variabilidad interindividual. La Inteligencia Artificial (IA) surge como solución para integrar estos datos de alta dimensionalidad.

Objetivos: Diseñar y validar un flujo de trabajo computacional integral que aúne el procesamiento de datos masivos de secuenciación (NGS) y modelos de aprendizaje profundo para predecir fenotipos y resultados farmacogenómicos.

Materiales y Métodos: Se desarrolló un pipeline bioinformático orquestado en Python para la extracción estandarizada de variantes genéticas. Posteriormente, se diseñó una arquitectura de red neuronal híbrida (Máquinas de Factorización y *Transformers* con mecanismo de atención) entrenada sobre datos curados de *ClinPGx* y *dbSNP*. Se implementaron estrategias de ingeniería de características (*PubChem CID* y variables sintéticas alélicas) y optimización hiperparamétrica para gestionar el desbalance de clases clínico mediante *Adaptative Focal Loss* y *Asymmetric Loss*.

Resultados: El modelo alcanzó una precisión del 86.89% en la clasificación de la categoría fenotípica del efecto farmacológico (toxicidad, eficacia y alteraciones farmacocinéticas). No obstante, la precisión descendió en la tipología específica del evento (46.73%) debido a la elevada dispersión ontológica de las bases de datos biomédicas actuales y las limitaciones de los *embeddings* tabulares.

Conclusiones: La integración de pipelines genómicos y redes neuronales permite predecir el impacto de interacciones gen-fármaco con alta fiabilidad, demostrando una sólida aplicabilidad traslacional. El abordaje futuro requiere transicionar hacia arquitecturas topológicas como las Redes Neuronales de Grafos (GNN) para modelar de forma nativa la complejidad molecular y genómica.

Palabras clave: Farmacogenómica, Medicina de Precisión, Inteligencia Artificial, Secuenciación de Nucleótidos de Alto Rendimiento, Aprendizaje profundo

Términos MeSH: *Pharmacogenomics, Precision Medicine, Artificial Intelligence, Deep Learning, High-Throughput Nucleotide Sequencing.*

Abstract

Background: The transition toward personalized medicine is currently constrained by biological complexity, a lack of standardization across genomic repositories, and the limitations of classical pharmacology in modeling inter-individual variability. Artificial Intelligence (AI) has emerged as a pivotal paradigm for integrating these high-dimensional datasets.

Objectives: To design and validate a comprehensive computational framework that leverages Next-Generation Sequencing (NGS) data processing alongside deep learning architectures to predict pharmacogenomic phenotypes and clinical outcomes.

Materials and Methods: We developed a bioinformatic pipeline, orchestrated via Python, for the standardized extraction of genetic variants. This was followed by the implementation of a hybrid neural network architecture—combining Factorization Machines and Attention-based Transformers—trained on curated datasets from ClinPGx and dbSNP. Feature engineering strategies, including PubChem CIDs and synthetic allelic variables, were employed. To mitigate clinical class imbalance, we utilized hyperparameter optimization and advanced loss functions, specifically Adaptive Focal Loss and Asymmetric Loss.

Results: The model achieved an accuracy of 86.89% in classifying phenotypic categories of pharmacological effects (toxicity, efficacy, and pharmacokinetic alterations). Conversely, performance declined regarding specific event typologies (46.73%), a result attributed to the high ontological dispersion within current biomedical databases and the inherent constraints of tabular embeddings.

Conclusions: The integration of genomic pipelines with neural networks enables highly reliable predictions of gene-drug interactions, demonstrating robust translational potential. Future research should pivot toward topological architectures, such as Graph Neural Networks (GNNs), to natively capture the underlying molecular and genomic complexity.

Keywords: *Pharmacogenomics, Precision Medicine, Artificial Intelligence, Deep Learning, High-Throughput Nucleotide Sequencing.*

1. Introducción

Desde que se descifró la primera secuencia del genoma humano (1), la Farmacia y la Medicina han perseguido una idea que, hasta hace poco, parecía ciencia ficción: dejar atrás la medicina reactiva para abrazar una medicina predictiva y personalizada. Las técnicas de secuenciación masiva (NGS) no solo nos entregaron un mapa biológico con una resolución sin precedentes, sino que sembraron una pregunta fundamental en la comunidad científica: ¿Es posible anticiparnos al fracaso terapéutico antes de administrar la primera dosis?

La premisa, que busca alinear la terapia con las características únicas de cada paciente, ha transformado nuestra comprensión teórica de la enfermedad y el tratamiento. Este cambio de paradigma es indispensable debido a la falacia biológica de la "dosificación estándar". La farmacología poblacional asume curvas de Gauss en el metabolismo hepático, ignorando que fenotipos extremos —como los metabolizadores ultrarrápidos o los metabolizadores pobres— pueden representar el grueso de los fracasos terapéuticos, especialmente en grupos poblacionales concretos.

Este riesgo se exacerba drásticamente en fármacos de estrecho margen terapéutico, donde la concentración tóxica y la dosis mínima eficaz se solapan peligrosamente. Un ejemplo paradigmático es el de los anticoagulantes orales (acenocumarol, warfarina), donde polimorfismos en los genes *CYP2C9* (metabolismo de fase I) y *VKORC1* (diana farmacodinámica) dictan el riesgo de hemorragia mortal frente al riesgo de trombosis. En este contexto, prescribir sin un perfil genómico no es una limitación tecnológica, sino una barrera de seguridad clínica. Nos encontramos ante una paradoja tecnológica.

Sin embargo, la transición de esta idea a la práctica clínica real ha sido desigual. Mientras que en campos punteros como la oncología (terapias dirigidas) o el manejo post-infarto agudo de miocardio (IAM) la farmacogenómica ya dicta protocolos (2), en la Atención Primaria su aplicación sigue siendo anecdótica y en escalafones superiores se aplica tras la observación de fracasos terapéuticos previos. Nos encontramos ante una paradoja tecnológica: disponemos de la capacidad para generar terabytes de datos genómicos por

paciente, pero carecemos de la infraestructura, los especialistas y las herramientas para integrarlos de forma efectiva en la toma de decisiones diaria (3).

Esta desconexión entre el avance técnico y la realidad clínica es multifactorial:

- **Inercia de la Medicina Poblacional:** Los sistemas de salud continúan operando bajo la estadística de la "talla única" y el ensayo-error, ignorando la variabilidad individual en pos de la estandarización masiva por eficiencia de tiempo y recursos.

- **Complejidad Biológica no Abordada:** Aunque el exoma (la parte que codifica proteínas) está ampliamente caracterizado, representa una fracción minoritaria del genoma. Las regiones no codificantes y reguladoras (promotores, enhancers, transposones) juegan un papel crítico en la transcripción y estabilidad del ADN (4), pero su análisis presenta una complejidad superior y a menudo se ignora en los estudios farmacogenómicos tradicionales focalizados.

- **Brecha de Habilidades:** El perfil del investigador biomédico se encuentra en plena metamorfosis. Ya no basta con el conocimiento biológico profundo; es imperativo dominar el análisis de Big Data y las herramientas computacionales capaces de procesar bases de datos con millones de entradas (dbSNP, ClinVar, etc.) (5)

Es en este punto de inflexión donde la Inteligencia Artificial (IA) deja de ser una herramienta auxiliar para convertirse en el motor del cambio. Su capacidad para el reconocimiento de patrones en espacios de alta dimensionalidad supera con creces la capacidad de procesamiento humano, permitiendo identificar tumores malignos en mamografías (6) o integrar variables genómicas complejas y relaciones no lineales que escapan a la estadística clásica (7).

Aplicada a la farmacogenómica, la IA ofrece la posibilidad de evaluar *in silico* el impacto farmacológico o farmacocinético de tratamientos antes de su exposición biológica. El potencial traslacional de esta herramienta es transversal; desde las fases tempranas de descubrimiento de fármacos (identificando variantes de toxicidad preclínica), pasando por la optimización de ensayos clínicos (estratificación de pacientes para reducir fallos en Fases

II/III), hasta su implementación final en la práctica asistencial. En este último escenario, su utilidad no se limitaría a la atención especializada, sino que permitiría escalar la medicina de precisión hasta la Atención Primaria, democratizando el acceso a tratamientos seguros y eficaces.

No obstante, el ritmo vertiginoso de la innovación tecnológica genera nuevos desafíos, particularmente en la estandarización. La falta de consenso universal en la nomenclatura de variantes (uso dispar de rsIDs, haplotipos estelares como *CYP2D6*4* o notación HGVS) y la heterogeneidad en las bases de datos clínicas dificultan la interoperabilidad (8). A menudo, la información crítica se encuentra dispersa en silos o requiere procesos manuales de curación, lo que ralentiza la adopción de estas herramientas en el flujo de trabajo clínico real.

El presente proyecto aborda esta problemática mediante el diseño de un modelo de IA predictivo, integrando el mismo en un flujo de trabajo bioinformático unificado, capaz de procesar desde el dato crudo de secuenciación hasta la predicción clínica, superando las barreras de la medicina tradicional y promoviendo la accesibilidad de los datos (9).

Hipótesis general

“La integración de datos de secuenciación masiva y tratamiento farmacológico mediante modelos de aprendizaje automático permite predecir la respuesta farmacológica de forma más precisa que aproximaciones basadas únicamente en variables aisladas o reglas clínicas simplificadas”

Subhipótesis 1

La integración conjunta de información genética del paciente y del fármaco en un mismo modelo predictivo mejora la capacidad de predicción de *outcomes* farmacogenómicos respecto al uso de cada fuente de datos por separado.

Subhipótesis 2

La normalización y unificación semántica de variantes genéticas y fármacos en un espacio de características estructurado mejora la estabilidad del entrenamiento y la capacidad de generalización del modelo.

Subhipótesis 3

Las predicciones intermedias del modelo pueden integrarse en una variable de resultado clínico interpretable que permita inferir la probabilidad de éxito o fracaso terapéutico, facilitando su potencial uso como herramienta de apoyo a la decisión clínica.

2. Objetivos

Objetivo general

Desarrollo y validación de un flujo de trabajo computacional integral. Integración y unificación del procesamiento de datos de secuenciación masiva (NGS) y algoritmos de aprendizaje automático supervisado con el fin de predecir fenotipos farmacogenómicos y resultados farmacológicos a partir de la información genética del individuo y el tratamiento a instaurar.

Objetivos específicos

- **Implementar un pipeline de preprocesamiento bioinformático** para la obtención de variantes a partir de los datos crudos de la secuenciación.
- **Diseño del procesado de "*features*"** para la transformación y codificación de las variantes genómicas en vectores numéricos. "*Feature engineering*"
- **Desarrollo de la arquitectura del algoritmo.** Evaluar las opciones y programar un modelo que prediga efectos a partir del fármaco y genotipo del paciente.
- **Optimización del modelo.** Optimización de hiperparámetros del modelo mediante Optuna, estrategias para el desbalance de clases y cálculo de pérdida.
- **Validar la precisión y capacidad predictiva.** Uso de validación cruzada y métodos estadísticos para evaluar la precisión en la tarea.

3. Materiales y Métodos

3.1 Flujo y entorno de trabajo.

El entorno de trabajo elegido fue GNU/Linux 13, concretamente Debian 13 (Trixie) y la versión de Python 3.10.19 como orquestador de todo el software y para la gestión de los entornos virtuales se ha utilizado ***uv***, sustituto de *pip*. Sin embargo, los entrenamientos del modelo han sido realizados en un ordenador diferente cuyas características son:

- SO: Windows 11
- GPU: NVIDIA RTX 4070 Ti Super (16 GB VRAM)
- RAM: 32 GB
- CPU: AMD Ryzen 7 7800X 3D

Se seleccionó Python como lenguaje para orquestar el flujo de trabajo con la finalidad de evitar problemas de compatibilidad al ejecutar los entrenamientos en Windows o el resto del pipeline en GNU/Linux.

Para la elaboración del algoritmo de Machine Learning (ML) se utilizaron las librerías de PyTorch porque permiten un mayor modularidad en la construcción del algoritmo respecto a sus equivalentes y, al estar construido en Python, se asegura una compatibilidad completa con el entorno de trabajo.

Se diseñó un flujo de trabajo conceptual basado en dos fases (Figura 1). En la **fase I** se agrupó el procesamiento de las lecturas crudas del individuo hasta la obtención del archivo de variantes, por otro lado, la fase II consistió en el desarrollo de los algoritmos de aprendizaje (modelos) y la evaluación de sus resultados.

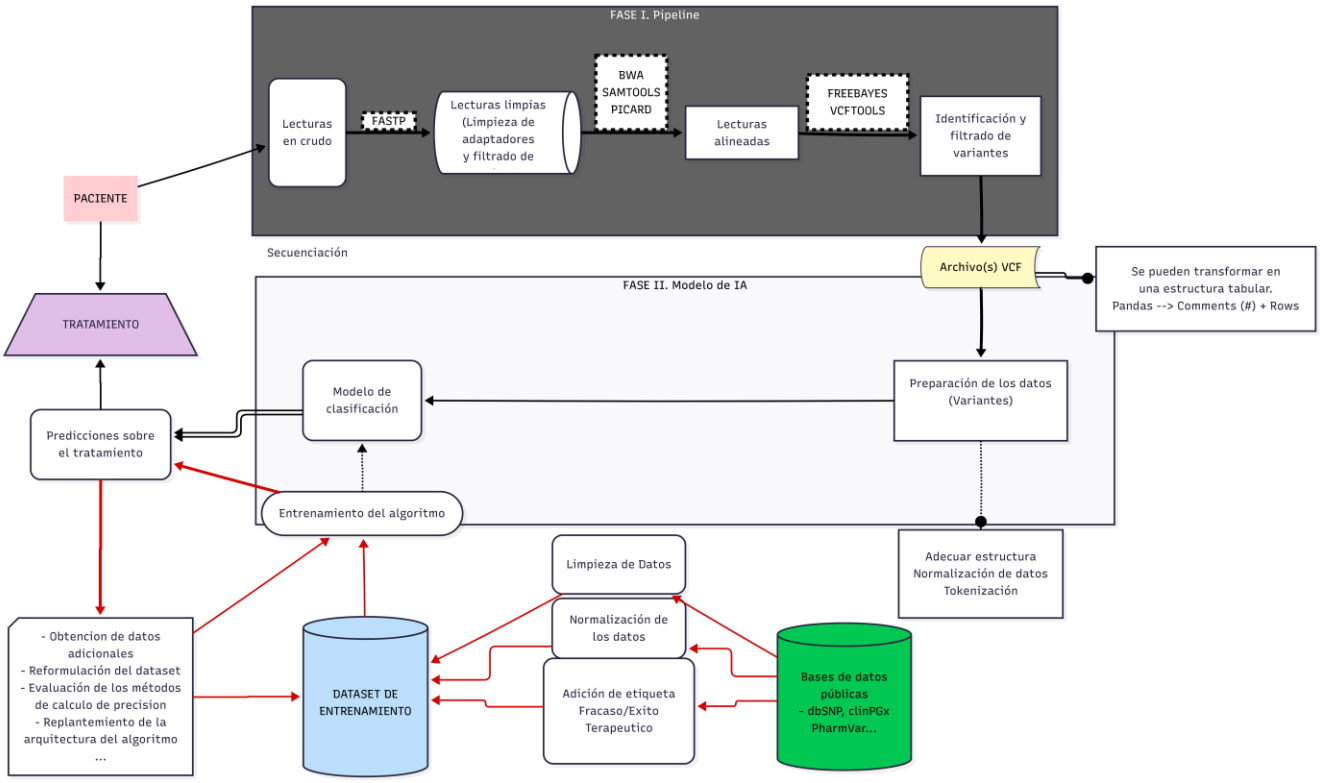

Figura 1. Diseño del flujo de trabajo. Flechas de color: negro (objetivo de uso); rojo (Flujo del desarrollo).

3.2 Fase I. Pipeline bioinformático

El pipeline se desarrolló mediante la concatenación de una serie de herramientas externas utilizando Python como orquestador. El script que orquesta todo el pipeline realiza también la creación de los reportes de cada herramienta y ordenado de los mismos mediante los parámetros de cada herramienta.

El pipeline debía ser capaz no solo de realizar de forma precisa el flujo de trabajo, sino también crear un entorno virtual, agregarle las dependencias requeridas y obtener el archivo fasta correspondiente al genoma humano. Esto se consiguió mediante la estructuración en módulos del script, concretamente cuatro clases heredadas para cada paso del pipeline, una clase para centralizar la obtención del genoma de referencia y dos funciones finales que orquestan el funcionamiento del script.

GenomeManager

Esta clase se estructuró para seguir un algoritmo de operaciones. Iniciando con la verificación del genoma de referencia y si se encontraba presente en la estructura del proyecto.
En su ausencia, se procede a su descarga (Versión GRCh38 de la base de datos de *Ensembl*) y posterior descompresión e indexado utilizando **samtools**. Además, se realiza una verificación adicional comprobando los metadatos del archivo presente en el servidor.

Si se detecta que es más nuevo, se procede a la descarga del nuevo y sustitución del presente en local, asegurando que el alineamiento siempre trabaje con la versión de referencia más actualizada.

Clase base para ejecución de herramientas.

Para garantizar la robustez del flujo de trabajo y evitar fallos silenciosos durante la ejecución secuencial de las herramientas bioinformáticas, se diseñó una superclase base denominada **BioToolExecutor (Véase Anexo 1)**. Esta clase actúa como un *wrapper* seguro para las llamadas al sistema operativo mediante subprocesos (*subprocess*). Su función principal es capturar de forma íntegra los flujos de salida estándar (*stdout*) y de error (*stderr*), proporcionando un control de excepciones estricto.

De este modo, si una herramienta concreta falla por problemas de formato o falta de memoria, el orquestador aborta la ejecución y reporta el origen exacto del fallo, impidiendo la propagación de datos corruptos a las fases posteriores.
Apoyándose en esta infraestructura, el procesamiento de las lecturas crudas se dividió en cuatro módulos secuenciales:

1. **Fase de Control de Calidad y Limpieza (ProcessRawGenome)**
   Se inicia el procesamiento sobre los archivos FASTQ crudos. Se ejecuta la herramienta FastQC para establecer una métrica de calidad base y, posteriormente, FastP para el recorte de adaptadores de secuenciación (*trimming*) y filtrado de lecturas de baja calidad térmica. Se genera un nuevo informe de control post-

limpieza para validar la idoneidad de los datos emparejados (Paired-End) antes de su alineamiento.

2. **Fase de Alineamiento (MappingAlignmentAnalysis)**
   Las lecturas limpias se mapean contra el genoma de referencia (GRCh38) utilizando el algoritmo de alineamiento de Burrows-Wheeler (BWA-MEM), optimizado para lecturas cortas de plataformas de alto rendimiento. El resultado es un archivo binario BAM que es posteriormente ordenado. A continuación, mediante las utilidades de Picard (*MarkDuplicates*), se identifican y marcan los duplicados de PCR generados durante la preparación de la librería genómica. Este paso es un cuello de botella crítico, ya que su omisión generaría sesgos en la cuantificación alélica introduciendo falsos positivos durante la llamada de variantes.

3. **Fase de Identificación de Variantes (VariantIdentificationAnalysis)**
   Para la extracción de polimorfismos, se integró Freebayes, un "*variant caller"* basado en haplotipos. A diferencia de los algoritmos tradicionales que evalúan el genoma posición por posición, Freebayes detecta SNPs e Indels considerando el contexto del alineamiento local (haplotipos cortos), lo que reduce drásticamente el ruido en regiones genómicas complejas. El archivo VCF resultante es sometido a un filtrado de calidad estricto mediante **VCFtools**, descartando variantes con baja profundidad de lectura (minDP < 10) o puntuación de calidad deficiente (minQ < 20).

4. **Fase de Anotación Funcional (VariantAnnotator)**
   Finalmente, el VCF filtrado se procesa con el *Variant Effect Predictor* (VEP) de Ensembl. Para maximizar el rendimiento y evitar cortes por latencia de red, la herramienta se ejecuta en modo *offline* haciendo uso de la caché local. Este paso cruza las coordenadas de las variantes identificadas con bases de datos genómicas consolidadas, anotando su impacto funcional a nivel transcripcional (consecuencias moleculares, cambios de aminoácidos, impacto en *splicing*).

El archivo VCF funcionalmente anotado devuelto por esta última fase constituye la materia prima estructurada y estandarizada que actúa como puente hacia la Fase II.

3.3 Fase II. Desarrollo del modelo de clasificación

El modelo debía recibir datos acerca del tratamiento farmacológico a instaurar y la información genética del paciente para predecir el resultado clínico. Para ello, se definió una estructura tabular de *inputs* (datos de entrada) y *outputs* (predicciones), abordando desde el inicio el desafío de la heterogeneidad de las fuentes biológicas.

Obtención de datos de entrenamiento

La Fase II se inició con la adquisición de los conjuntos de datos necesarios para el entrenamiento del modelo. Se precisaba de bases de datos donde se hubiesen corroborado vínculos entre variantes genéticas (SNPs/indels) y la respuesta al tratamiento farmacológico, al menos de forma cualitativa. Las bases de datos idóneas para esta tarea y los criterios para su selección se detallan en el Anexo 1. Principalmente, se utilizaron **ClinPGx** y **dbSNP**, ambas de acceso público.

Uno de los principales desafíos en esta etapa fue la heterogeneidad estructural de la base de datos ClinPGx. Aunque los archivos principales (var_drug_ann, var_fa_ann, var_pheno_ann) comparten una taxonomía común, presentaban divergencias semánticas significativas que impedían una concatenación directa. Para resolver esto, se diseñó un esquema de mapeo semántico orientado a unificar las variables predictoras bajo una estructura común.

Preprocesamiento e Ingeniería de Características (Feature Engineering)

Una vez unificados los datos crudos, se procedió a la etapa crítica de ingeniería de características. Dado que la calidad del modelo de IA depende directamente de la calidad y consistencia de los datos de entrada, se desarrollaron estrategias específicas de normalización para los dominios farmacológico y genotípico, así como una redefinición de las variables objetivo.

Estandarización del dominio farmacológico

La representación de los fármacos en los estudios originales presentaba una inconsistencia notable. Se observó que para referirse a una misma entidad terapéutica se utilizaban indistintamente nombres comerciales, nombres de sales, metabolitos activos o agrupaciones farmacológicas genéricas.

Durante el diseño del pipeline de datos, se evaluó la idoneidad de utilizar la clasificación ATC (*Anatomical Therapeutic Chemical*) como estándar unificador. Sin embargo, desde una perspectiva puramente farmacodinámica y farmacocinética, agrupar las moléculas por su diana terapéutica o sistema anatómico introducía un sesgo letal para un modelo de Inteligencia Artificial. Dos fármacos pertenecientes a la misma familia ATC (por ejemplo, los antidepresivos Fluoxetina y Citalopram) comparten indicación clínica, pero poseen arquitecturas químicas distintas que determinan afinidades inhibitorias divergentes sobre las isoenzimas hepáticas (como el *CYP2D6*).

Las enzimas y los receptores codificados por el genotipo del paciente mutan e interactúan en base a configuraciones estéricas y propiedades fisicoquímicas moleculares (anillos bencénicos, puentes de hidrógeno), no en base a "indicaciones terapéuticas" abstractas dictadas por un código ATC.

Por tanto, se optó por una normalización estricta basada en los identificadores *PubChem Compound ID* (**CID**). Al obligar a la IA a trabajar sobre la entidad química pura (o sus metabolitos activos identificados), se eliminó el ruido semántico y se garantizó que los vectores de características o embeddings generados reflejasen el comportamiento químico-estructural real de la molécula frente a las proteínas transcritas por el paciente. Para los casos donde el dato de entrada refería a un "Grupo Farmacológico" genérico sin especificación, se implementó una estrategia de sustitución por muestreo representativo para no perder el registro.

Adaptación de características genómicas.

La información genética original se presentaba en formatos dispares: identificadores rsID, notaciones de haplotipos estelares (ej. *CYP2C9*17*) y nomenclaturas HGVS. La falta de un patrón único impedía que el modelo pudiera inferir relaciones consistentes. Además, variables como "Tipo de Metabolizador" presentaban una tasa de valores vacíos superior al 80%, por lo que su inclusión habría introducido un ruido inaceptable por la necesidad de imputación masiva.

Para sintetizar esta información de manera robusta, se creó una variable sintética denominada “Genalle”. Esta variable nace de la fusión del identificador de la variante y su alelo específico.
Para su construcción, se desarrolló un script en Python que iteró sobre el volcado completo XML de la base de datos dbSNP, permitiendo recuperar rsIDs faltantes y estandarizar la notación de los alelos. El resultado fue una columna con la estructura [rsID: HGVS_Notation], que actúa como un identificador único y compacto para cada variante específica.
Adicionalmente, se tomaron decisiones de diseño pragmáticas:

- **Imputación de Genes:** Para los casos donde el gen no estaba explícito (variantes intergénicas o intrónicas), se utilizó la etiqueta “__INTRONIC__” para preservar la información posicional relativa sin alucinar datos inexistentes.

- **Descarte de Variables con Alta Tasa de Nulos:** Se excluyó deliberadamente la variable "Tipo de Población" (*Population Type*), a pesar de contener categorías clínicamente relevantes como “*Pediatric”* o *“Healthy”*. Su tasa de valores ausentes era crítica, y su inclusión habría forzado al modelo a aprender sesgos basados en el ruido de imputación en lugar de en la biología real, condicionando negativamente la calidad de las predicciones globales.

- **Descarte de Coordenadas Cromosómicas:** Se evaluó utilizar las posiciones genómicas (chr: pos) como *input*. Sin embargo, se descartaron para evitar introducir complejidad innecesaria. Un modelo de Deep Learning no pre-entrenado en secuencias genómicas masivas (**tipo DNABERT**) no es capaz de interpretar la

semántica de la "proximidad posicional" de forma eficiente, por lo que el uso de identificadores categóricos únicos (“Genalle”) resultó computacionalmente más eficiente y biológicamente más preciso para esta arquitectura.

Definición de variables objetivo (Target engineering)

La definición de qué debía predecir el modelo fue tan crucial como la limpieza de los *inputs*. Los datos crudos contenían descripciones de efectos clínicos en texto libre, inmanejables para la inferencia estadística de un clasificador. Se estructuró la salida en tres niveles de abstracción clínica orientados a la Farmacocinética (PK) y Farmacodinamia (PD):

1. **Targets Primarios (Phenotype_Outcome):** Se consolidaron las múltiples etiquetas en 5 clases maestras multietiqueta: *Toxicity, Efficacy, Metabolism/PK, Dosage* y *Other*. Esta clasificación no es arbitraria; constituye la traducción matemática del sistema ADME (Absorción, Distribución, Metabolismo, Excreción). Cuando el modelo clasifica una interacción como "*Toxicity* + *Increased Risk*", está ejecutando un análogo predictivo de, por ejemplo, el acúmulo tóxico citotóxico provocado por un déficit enzimático en la dihidropirimidina deshidrogenasa (DPYD) al administrar 5-Fluorouracilo (5-FU). Permite al clínico situar instantáneamente en qué punto del eje PK/PD fallará la terapia.

2. **Dirección del Efecto (Effect_Direction):** Se normalizó en tres estados (*Increased, Decreased* y __UNDETERMINED__). Indica matemáticamente hacia dónde se desplaza la curva concentración-tiempo o la afinidad del receptor.

3. **Subtipo de Efecto (Effect_Type):** Mediante expresiones regulares se depuró la semántica del evento exacto a predecir (Riesgo, Severidad, Concentración, etc.).

4. **Variable de Valor Clínico (Therapeutic_Outcome):** Dado que el objetivo final es la prescripción en la práctica asistencial, se diseñó un Algoritmo de Decisión Clínica estricto.

Esta nueva variable binaria de salida (LIKELIHOOD_THERAPEUTICAL_SUCCESS vs LIKELIHOOD_THERAPEUTICAL_FAILURE) se infiere por lógica de las predicciones anteriores. Si el modelo predice, por ejemplo, *Efficacy* + *Decreased*, el algoritmo asigna directamente un riesgo de fracaso por defecto de diana terapéutica o metabolismo ultrarrápido, dotando al sistema de una capacidad ejecutiva de "Semáforo Rojo" para la ayuda inmediata en la Atención Primaria o Especializada.

– **Ejemplo de inferencia:** Si el modelo predice Toxicity + Increased + Risk, el sistema asigna automáticamente *LIKELIHOOD_THERAPEUTICAL_FAILURE*.
Esta variable dota al sistema de capacidad ejecutiva ("Semáforo Rojo/Verde") para la ayuda a la prescripción.

ARCHIVO FINAL	var_drug_ann	var_pheno_ann	var_fa_ann
1	Drug(s)	Drug(s)	Drug(s)
2	Variant/Haplotypes	Variant/Haplotypes	Variant/Haplotypes
3	Gene	Gene	Gene
4	Alleles	Alleles	Alleles
5	Phenotype Category	Phenotype Category	Phenotype Category
6	Direction of effect	Direction of effect	Direction of effect
7	----------	----------	Functional terms
7	PD/PK terms	----------	----------
7	----------	Side effect/efficacy/other	----------
8	----------	----------	Gene/gene product
8	----------	Phenotype	----------
9	Population types	Population types	----------
10	Population Phenotypes or diseases	Population Phenotypes or diseases	----------
11	Notes	Notes	Notes
12	Sentence	Sentence	Sentence
13	PMID	PMID	PMID

Tabla 1. Estructura de los archivos base usados para el entrenamiento del modelo

Limitaciones Asumidas

Se intentó predecir el detalle del efecto adverso (*Effect_subtype*, ej. Síndrome de Stevens-Johnson), pero la falta de estandarización ontológica (ausencia de MedDRA en las fuentes) y la extrema dispersión de clases hicieron inviable su predicción fiable. Se optó por mantener la predicción al nivel de "Aumento de Riesgo/Severidad de Efectos Adversos/Enfermedad…", que funciona como una alerta temprana eficaz sin incurrir en falsos positivos específicos.

Diseño de la arquitectura de red neuronal

Para procesar estos datos estructurados, se optó por el diseño de una arquitectura híbrida. Esta decisión se fundamentó en la naturaleza intrínseca de los datos genómicos: alta dispersidad y no linealidad de las interacciones biológicas (10)

El uso de una Red Neuronal Profunda (DNN) convencional sobre vectores One-Hot habría generado un espacio de características ineficiente y excesivamente vacío, dada la baja frecuencia de ciertas variantes genéticas. Por otro lado, los modelos lineales tradicionales carecen de la capacidad para modelar la epistasis (dependencia no aditiva entre genes) y las interacciones complejas fármaco-gen. Para superar estas limitaciones, la arquitectura se estructuró en dos componentes paralelos que convergen en un perceptrón multicapa (MLP) final en configuración Multi-Task.

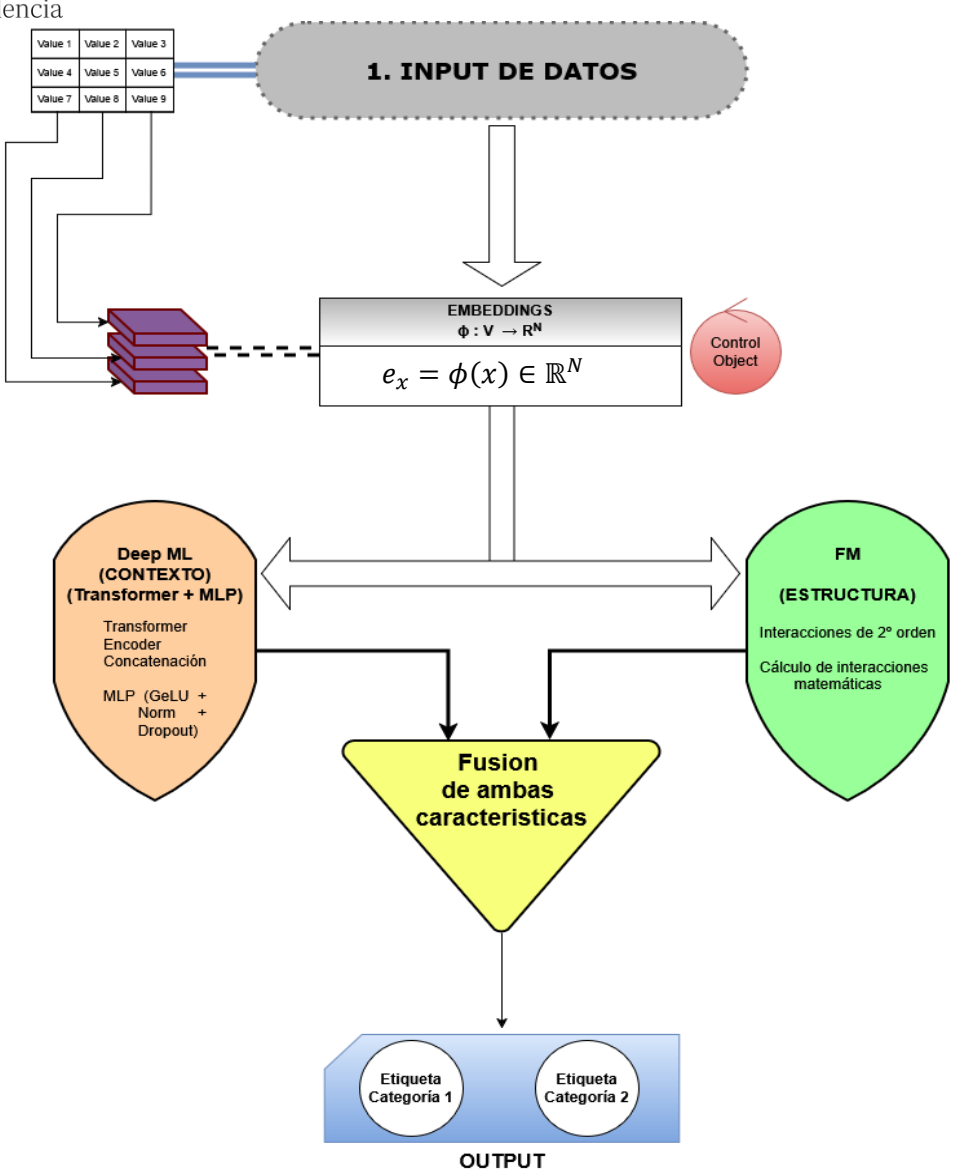

Figura 2. Funcionamiento interno del modelo

Componente de Factorización (FM): captura de interacciones explícitas

Para modelar las relaciones directas (gen-fármaco) de manera eficiente, se implementó un módulo de Máquinas de Factorización (11). En lugar de tratar cada variante aislada, este componente proyecta cada característica (*Drug*, *Genalle*) en un espacio vectorial denso mediante "*Embeddings*".

Esto permite al modelo calcular el producto escalar entre vectores, inferir comportamientos similares entre fármacos o genes relacionados y manejar la dispersidad de los datos sin

necesidad de haber observado todas las combinaciones posibles durante el entrenamiento (11).

Componente Profundo con Atención (Transformer Encoder)

Para capturar la complejidad contextual del sistema biológico, se incorporó un Encoder de Transformers basado en mecanismos de Self-Attention (12).

La elección de esta arquitectura frente a perceptrones multicapa (**MLP**) tradicionales rígidos obedece a la necesidad de simular un fenómeno genético fundamental: la epistasia. Los polimorfismos biológicos no operan en un vacío termodinámico ni sus efectos patológicos son simples sumatorios aditivos. El impacto de una mutación en una enzima de Fase I o de transporte puede verse silenciado (*downregulated*) o potenciado en función de mutaciones compensatorias presentes en genes interreguladores.

Esta capacidad de enfoque dinámico permite capturar relaciones no lineales y dependencias a largo alcance, superando las limitaciones de las redes neuronales estándar (13,14).

A diferencia de las capas densas, el mecanismo de *Self-Attention* permite al modelo "observar" todos los alelos codificados y las propiedades químicas del fármaco de manera simultánea antes de emitir un vector de salida. La red pondera dinámicamente la importancia de cada gen (etiqueta): asignará un peso crítico a una variante específica solo cuando interaccione sinérgicamente con el fármaco de entrada, ignorándola de forma activa en contextos donde su vía metabólica resulta irrelevante.

Decisiones de diseño arquitectural:

- **Función de Activación (GELU):** Se seleccionó la ***Gaussian Error Linear Unit* (GELU)** como función de activación no lineal ($x\Phi(x)$), en detrimento de la tradicional **ReLU**. A diferencia de **ReLU**, que anula el gradiente para valores negativos ("neuronas muertas"), la naturaleza probabilística y suave de GELU permite el flujo de gradientes pequeños en la zona negativa. Esto resultó crucial para garantizar la

convergencia del componente Transformer, facilitando el modelado de no-linealidades sutiles en los datos biológicos.

- **Normalización:** Se aplicó "***Layer Normalization***" y/o *"**Batch Normalization**"* preactivación para estabilizar la distribución de las entradas en las capas profundas.

Entrenamiento y estrategia de optimización

El conjunto de datos de entrenamiento, se introduce en el modelo mediante una función de lectura y conversión a dataframe utilizando la librería ***Pandas***. Se dividen los datos en dos dataframes, uno para entrenamiento y otro para validación, con un 80% y 20% de los datos iniciales respectivamente.
Esta separación se realiza para asegurar la representación total de las posibles variables en los datos de validación, para lo cual se selecciona una columna de estratificación.

Así, el algoritmo de entrenamiento realizará una serie de "iteraciones" o *epochs.* Cada epoch está formado por una fase de entrenamiento y una fase de validación; en la fase de entrenamiento se busca afinar un patrón que permita inferir los resultados correspondientes a las features, en la fase de validación se intenta inferir el resultado a partir de únicamente las features.

Toda predicción del modelo consta de dos valores principales, la confianza del modelo en la predicción y la precisión de la respuesta. Así tras cada epoch, se pasa un algoritmo de cálculo de pérdida (loss). Este parámetro es un valor numérico que se calcula a partir de la seguridad del modelo en su predicción y de cómo de correcta es.

Según la forma en que se quiera modular el entrenamiento podemos penalizar al modelo simplemente aciertos/errores o penalizar también aquellos casos que acierte, pero sin estar seguro de su predicción.

Cálculo de métricas

La función de pérdida (Loss Function) actúa como el eje rector del gradiente de optimización. Dada la naturaleza del problema (desbalance de clases y clasificación

multietiqueta), el uso de una función de pérdida estándar resultó insuficiente. Se evaluaron y compararon cuatro algoritmos para determinar su impacto en la convergencia:

- **BCELogitLoss**: Estándar para clasificación binaria/multietiqueta. Combina una capa Sigmoide y la Entropía Cruzada en una sola clase numéricamente estable.
- **Focal Loss**: Introduce un factor de modulación $(1 - p_t)^\gamma$ a la entropía cruzada. Su objetivo es reducir la importancia relativa de los ejemplos fáciles de clasificar (que constituyen la mayoría) y centrar el aprendizaje en los casos difíciles (clases raras), mitigando el impacto del desbalance.

$$FL(p_t) = -(1 - p_t)^\gamma \, log(p_t)$$

  - **Adaptative Focal Loss**: Variante dinámica desarrollada durante la experimentación, donde el hiperparámetro de enfoque γ no es estático, sino que se adapta en función de la distribución de las predicciones o la dificultad intrínseca del lote de datos actual.

- **Asymmetric Loss**: Desacopla la penalización de los positivos y negativos. Permite suprimir fuertemente la contribución de los negativos fáciles (fondo) mientras mantiene el gradiente de los positivos intacto. Esta función resultó ser la más prometedora para priorizar la sensibilidad en la detección de efectos adversos poco frecuentes.

- **Polynomial Loss**: Descompone la función de pérdida tradicional en una serie de polinomios de Taylor, permitiendo ajustar la importancia de cada término para refinar la sensibilidad del modelo ante diferentes márgenes de error.

Como se ilustra en la **Figura 3**, cada función modela el gradiente (aprendizaje) de forma distinta ante la incertidumbre (confianza del modelo en su predicción). La elección final de la función de pérdida no se realizó arbitrariamente, sino que se integró como un hiperparámetro más a optimizar

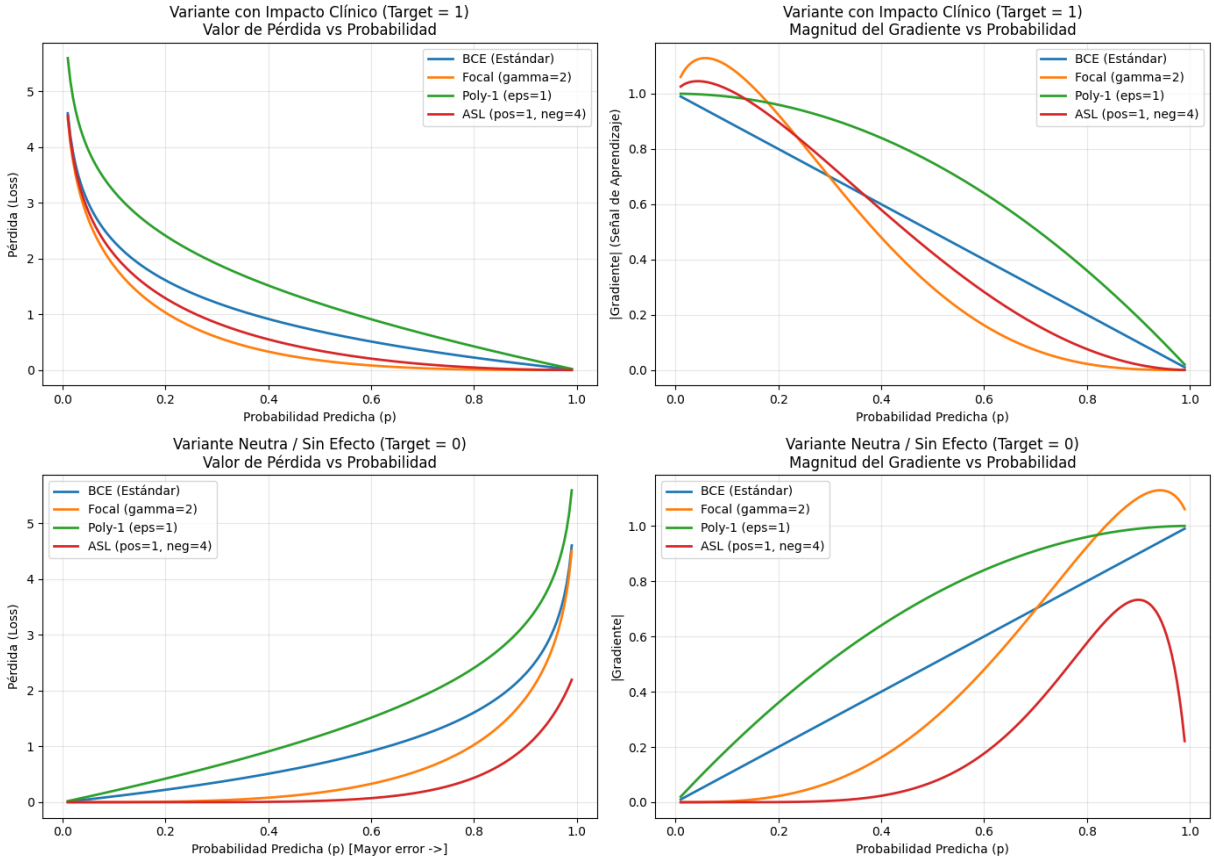

Figura 3. Comparativa de funciones de pérdida.

Eje X: Probabilidad predicha de efecto 0 (Ausencia) – 1 (Certeza)

Eje Y: Loss (Penalización aplicada) / Gradiente (Cambio de modelos de predicción)

Las gráficas del eje superior corresponden a aquellos casos en los que la variable a predecir tiene impacto clínico y las del eje inferior a aquellas sin efecto.

Se puede observar una relación proporcional para casos de alta confianza y ausencia de efecto y una relación inversa en el caso contrario, ocurriendo de igual forma en los gradientes.

Optimización de hiperparámetros

La búsqueda del espacio óptimo de hiperparámetros se automatizó mediante el framework Optuna, ejecutando aproximadamente 40 estudios completos de optimización. Cada estudio

se compuso de múltiples *Trials* (ciclos completos de entrenamiento/validación), siguiendo una estrategia en dos fases:

1. **Fase de exploración (Búsqueda Amplia)**: Se definieron espacios de búsqueda extensos para hiperparámetros críticos (tasa de aprendizaje, dimensión de *embeddings*, capas de atención, *dropout*). En esta fase, se implementaron algoritmos de **Poda (Pruning)** con baja tolerancia (agresivos), configurados para detener prematuramente aquellos Trials que no mostrasen una curva de aprendizaje prometedora en los primeros epochs. Esto permitió descartar rápidamente arquitecturas inviables y ahorrar coste computacional.

2. **Fase de explotación (Afinado Local):** Tras identificar las regiones óptimas, se ejecutaron estudios con intervalos acotados y *Pruners* más tolerantes, permitiendo que los modelos convergiesen completamente para afinar la precisión decimal.

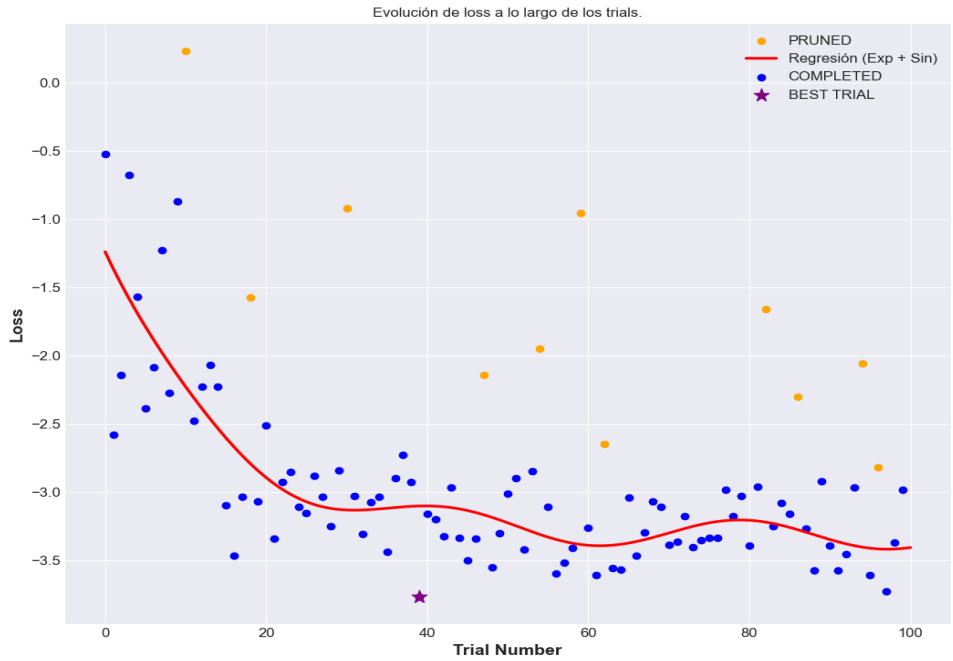

Figura 4. Evolución de loss en Optuna.

Se puede observar una mejora inicial con una tendencia a comportamiento trigonométrico. Esta tendencia se justifica por el funcionamiento del optimizador, el cual permite ciertos cambios “aleatorios” en los parámetros hasta que la variación con el mejor Trial supere un umbral, tras el cual se penalizará y favorece volver a la configuración previa.

Entrenamiento final

Para garantizar la reproducibilidad y descartar el efecto estocástico de la inicialización de pesos, el modelo final no se seleccionó únicamente del mejor *Trial*.

Se procedió a un entrenamiento definitivo utilizando **Validación Cruzada de 5 iteraciones (5-Fold CV)** con semillas de aleatoriedad fijas (*Fixed Seeds*). Este enfoque asegura que las métricas reportadas (Precisión Global ~89% para *Phenotype Outcome*) sean representativas de la capacidad de generalización real del modelo y no artefactos del particionado de datos.

4. Resultados y discusión

El rendimiento de la arquitectura fue evaluado bajo un esquema de configuración *Multi-Task Learning* (MTL), en el cual el perceptrón multicapa final se bifurca para predecir simultáneamente tres niveles de resolución clínica: la categoría fenotípica del efecto (*Phenotype_outcome*), la dirección del impacto (*Effect Direction*) y la tipología específica del evento adverso o farmacocinético (*Effect Type*).

Tras el proceso de optimización estocástica de hiperparámetros y validación cruzada (5-Fold CV), el modelo convergió hacia su óptimo local en el espacio proporcionado por los datos tabulares. Los resultados obtenidos revelan una capacidad predictiva asimétrica, altamente condicionada por la naturaleza matemática de la tarea, la biología subyacente y la calidad ontológica de las bases de datos de entrenamiento (ClinPGx).

Rendimiento global y métricas por tarea

El mejor modelo estabilizado, seleccionado tras más de 40 estudios en Optuna, arrojó una pérdida de validación (*Validation Loss*) global de 2.7921, con una precisión promedio (*Average Accuracy*) a través de las tres tareas del **66.57%**. La desagregación de esta métrica por capas de salida revela el comportamiento clínico del sistema: (Reporte HTML en Anexo 1)

1. Categoría Fenotípica (Phenotype Outcome):

Esta tarea constituye el éxito principal de la arquitectura. En la predicción de las 5 categorías clínicas maestras, el modelo alcanzó una precisión del 86.89%. Sin embargo, al aplicar un análisis de ***Balanced Accuracy Macro*** **(0.7058)**, se observa que la capacidad de generalización es asimétrica según el dominio funcional:

- **Impacto traslacional**: El sistema demuestra una alta fiabilidad en las categorías de **Dosage (*Balanced Accuracy*: 0.8328)** y **PK (*Balanced Accuracy*: 0.8037)**. Desde una perspectiva farmacológica, esto permite inferir con precisión cuándo una variante alélica compromete la vía metabólica o la eliminación de un fármaco.

- **Aplicación clínica**: Esta capacidad es fundamental en fármacos de estrecho margen terapéutico o profármacos que requieren bioactivación. Por ejemplo, predecir un fallo en la categoría **Metabolismo/Eficacia** alerta al clínico sobre fenotipos metabolizadores ultrarrápidos que podrían no alcanzar la **CME** (Concentración Mínima Eficaz), o metabolizadores pobres de un profármaco (como clopidogrel mediante el gen ***CYP2C19***), evitando fallos terapéuticos críticos como isquemias post-stent.

- **Limitaciones**: La etiqueta **PD** (Farmacodinamia) registró el rendimiento más bajo (Balanced Accuracy: 0.4795; F1: 0.0), lo que sugiere una escasez de ejemplos positivos o una complejidad de interacción receptor-ligando que supera la capacidad de los embeddings tabulares actuales.

2. **Dirección del Efecto (Effect Direction)**

   La precisión para clasificar si el impacto es **Incrementado** o **Disminuido** se sitúa en un 66.07%. Al evaluar el **F1-weighted (0.6434)**, se confirma que el modelo gestiona con solvencia la dirección del riesgo, especialmente en la clase "*increased*" (F1: 0.72).

   Biológicamente, la variabilidad restante se justifica por el fenómeno de la **epistasia** y la falta de un contexto fenotípico integral. El efecto aislado de un Polimorfismo de Nucleótido Simple (SNP) sobre la expresión génica no es siempre aditivo; mutaciones en enzimas de Fase I hepática (como la familia del citocromo P450, ej. ***CYP2D6*** o ***CYP2C9***) pueden verse compensadas por rutas metabólicas alternativas no registradas en los datos de entrada. Asimismo, la ausencia de variables cuantitativas clave (función renal, edad o índice de masa corporal) sitúa la predicción exacta en una zona de penumbra matemática que penaliza la confianza del gradiente

3. **Subtipo de Efecto Específico (Effect Type):**

   La predicción del evento clínico exacto obtuvo la precisión más baja (46.73%) y un F1-weighted de 0.4549. No obstante, subcategorías críticas como **Response** (F1: 0.58) y **Risk** (F1: 0.51) mantienen una capacidad predictiva útil para la alerta temprana.

   Este resultado no refleja un fallo arquitectónico, sino la dispersión ontológica de los repositorios farmacogenómicos actuales. La terminología clínica en las bases de datos de entrenamiento es heterogénea y carece de normalización bajo ontologías robustas como MedDRA. Descripciones como "aumento del riesgo de sangrado" o "alteración en el tiempo de coagulación" (relacionadas con genes como VKORC1) suelen codificarse como entidades distintas, fragmentando el aprendizaje y diluyendo la señal en las clases minoritarias.

Análisis arquitectónico y genético

La exploración estocástica del espacio de búsqueda mediante Optuna, permitió consolidar una configuración de parámetros especializada en la mitigación del ruido genómico y el desbalance de clases. El proceso de entrenamiento alcanzó la convergencia empleando el optimizador **AdamW** con una tasa de aprendizaje de 0.003 y un *weight decay* de 0.0012,

parámetros que aseguran una regularización robusta sin comprometer la velocidad de aprendizaje.
A diferencia de configuraciones previas, la arquitectura óptima ha estabilizado sus niveles de **dropout** en un 14.94% (0.1494) para las capas densas y un 7.4% para los *embeddings* de dimensión, lo que sugiere que la capacidad de generalización del modelo ya no depende exclusivamente de una desactivación neuronal extrema como ocurría en anteriores ciclos, sino de una gestión sofisticada de la función de pérdida.

Este equilibrio se ve reforzado por la implementación de funciones de pérdida avanzadas como **Asymmetric Loss (ASL)** y **Adaptative Focal Loss**. Desde una perspectiva farmacogenómica, esta asimetría es fundamental para abordar el desbalance de clases intrínseco a las variantes raras; al penalizar de forma mucho más estricta los errores en la clase negativa (mayoritaria) y suavizar el gradiente para las muestras positivas, el modelo evita el sesgo hacia las frecuencias poblacionales caucásicas dominantes en las bases de datos. En esta arquitectura, el módulo de **Máquinas de Factorización (FM)**, con una capa de 96 "neuronas", asume el rol crítico de modelar las interacciones bi-lineales explícitas entre el fármaco y el gen.
La decisión de prescindir de capas adicionales de *Transformer* en esta configuración final resalta la eficiencia de las FM para capturar la lógica combinatoria fármaco-variante sin introducir una complejidad computacional innecesaria.

Gestión del desbalance clínico (Focal Loss)

Finalmente, desde la óptica de la seguridad del paciente, el abordaje algorítmico del desbalance de clases mereció una atención especial. Los efectos adversos graves (como el Síndrome de Stevens-Johnson inducido por carbamazepina en portadores de HLA-B*15:02) son estadísticamente raros (clases minoritarias), mientras que la ausencia de efecto o reacciones leves conforman el grueso del *dataset*.

El uso del algoritmo "*Adaptative Focal Loss*" ($\gamma = 1.16$, $\alpha = 1.34$) fue fundamental. El algoritmo estándar, *"CrossEntropy Loss"*, habría optimizado el modelo para acertar a la mayoría silenciando a la minoría crítica. Sin embargo, *Focal Loss* restó gradiente a las predicciones fáciles y obligó a la red a actualizar sus pesos específicamente para detectar

estas interacciones raras. Esto garantiza que el modelo priorice la **sensibilidad** ante toxicidades graves.

Limitaciones de las arquitecturas basadas en atención

No obstante, se han identificado limitaciones críticas inherentes a las arquitecturas actuales. Los modelos basados en **mecanismos de atención y transformadores** (fundamento de los modelos de lenguaje contemporáneos) presentan una capacidad restringida para la **inferencia de relaciones semánticas biológicas** y sus implicaciones funcionales. Asimismo, su rendimiento está estrictamente supeditado a la disponibilidad de volúmenes masivos de datos con un alto grado de estructuración, requisito a menudo incompatible con la heterogeneidad de los repositorios farmacogenómicos actuales.

Desafíos en el procesamiento y preprocesamiento de datos

A pesar de la implementación de protocolos de **ingeniería de características *(feature engineering)***, el entrenamiento se vio condicionado por un acusado **desbalance de clases**, tanto en términos de frecuencia alélica como en la heterogeneidad de la nomenclatura genómica. En este escenario, el curado de datos trasciende la automatización convencional; la complejidad intrínseca de las variantes exige una **supervisión experta y una revisión exhaustiva**, dado que mínimas fluctuaciones en los datos de entrada (ruido biológico o técnico) inducen alteraciones significativas en la convergencia del modelo y su capacidad de generalización.

Estaticidad del modelo y barreras de acceso

Un factor determinante es la **ausencia de aprendizaje incremental o dinámico**. Bajo estas arquitecturas, la incorporación de nuevos biomarcadores o evidencia clínica requiere ciclos de reentrenamiento adicionales. Si bien la optimización de hiperparámetros puede mantenerse constante mientras la estructura del *input* sea estable, el coste computacional de la actualización es sustancial. A esto se suma la persistente **fragmentación y las restricciones de acceso** a bases de datos de variantes farmacogenómicas, lo que representa un cuello de botella crítico para el entrenamiento de modelos robustos.

Implicaciones clínicas y marco regulatorio traslacional

Bajo una perspectiva estrictamente traslacional, la robustez predictiva alcanzada por el modelo en la categoría *Phenotype_outcome* (~87%) adquiere una relevancia crítica al contrastarse con los estándares de seguridad vigentes de la **FDA** y el consorcio **CPIC**. En este escenario, la capacidad de la red para inferir alteraciones farmacocinéticas y farmacodinámicas permite una convergencia real entre la bioinformática de alto rendimiento y la práctica asistencial, transformando datos genómicos masivos en variables de decisión ejecutables.

Un ejemplo paradigmático de esta utilidad se observa en el manejo de la terapia antiagregante con clopidogrel. Mientras que la farmacología poblacional ignora la variabilidad del gen *CYP2C19*, una predicción del modelo que indique "Eficacia disminuida" permitiría al clínico anticipar un fallo en la bioactivación del profármaco, facilitando la transición hacia alternativas terapéuticas (como prasugrel o ticagrelor, que se bioactivan por distintos citocromos) antes de la aparición de eventos isquémicos graves. Del mismo modo, en el ámbito de la oncología, la detección proactiva de variantes de pérdida de función en *DPYD* resulta imperativa para evitar cuadros de toxicidad letal asociados al 5-Fluorouracilo (15), alineando el gradiente de optimización de la red con el principio de seguridad del paciente que exigen las guías clínicas actuales.

Asimismo, la literatura más reciente de 2024 y 2025 subraya que la integración de arquitecturas híbridas y modelos de lenguaje para el refinado ontológico es el vector necesario para superar la fragmentación de datos que aún persiste en los repositorios genómicos (16). Por consiguiente, los resultados obtenidos en este proyecto no solo validan la hipótesis técnica inicial, sino que posicionan a estas herramientas como sistemas de soporte a la decisión clínica (CDSS) capaces de gestionar la complejidad biológica que la estadística de "talla única" suele omitir.

No obstante, la implementación de este tipo de sistemas en la práctica clínica no solo enfrenta desafíos técnicos, sino que está supeditada a un estricto marco legal y ético, especialmente bajo el paraguas del **Reglamento de Inteligencia Artificial de la UE (AI Act)** y el **RGPD** (17). Dado que el modelo procesa datos genómicos —considerados por el artículo 9 del RGPD como categorías especiales de datos de alta sensibilidad—, el riesgo

de reidentificación y la vulnerabilidad de la privacidad del paciente constituyen una barrera crítica que deben cumplir estándares de compartición segura (8). En este escenario, el software se clasificaría probablemente como **IA de alto riesgo**, lo que exige niveles máximos de ciberseguridad, trazabilidad algorítmica y supervisión humana para evitar sesgos discriminatorios en la prescripción. Asimismo, la naturaleza inmutable de la información genética implica que cualquier brecha de seguridad tendría consecuencias permanentes para el individuo, lo que obliga a transicionar hacia protocolos de **encriptación homomórfica** o entornos de ejecución federados. Bajo esta óptica, el cumplimiento del **Reglamento (UE) 2017/745 (MDR)** resulta imperativo, ya que, al proporcionar recomendaciones diagnósticas y terapéuticas automáticas, el sistema debe ser validado no solo como un modelo matemático, sino como un dispositivo médico con una gestión de riesgos que priorice, por encima de la precisión diagnóstica, la integridad del dato biológico del paciente.

En conclusión, la convergencia de un pipeline de secuenciación de nueva generación (NGS) con la arquitectura optimizada Pharmagen DeepFM demuestra una robusta capacidad traslacional, alcanzando no solo una precisión del 87% en la categoría *Phenotype Outcome*, sino un **Balanced Accuracy de 0.7058** que confirma la eficacia del modelo ante el desbalance intrínseco de los datos clínicos. Bajo esta óptica, esta clase arquitecturas trascienden la bioinformática teórica para posicionarse como un catalizador de la medicina personalizada, alineado con los estándares de la **FDA**, el **CPIC** y las exigencias de seguridad y privacidad del **AI Act** y el **RGPD**.

No obstante, la variabilidad detectada en la tipología específica del evento (46.73%) y las limitaciones de los embeddings tabulares para capturar la epistasis compleja subrayan que el rendimiento actual se encuentra en el límite de la representación lineal. Por consiguiente, los resultados obtenidos no constituyen un punto de llegada, sino la base empírica indispensable para transicionar hacia una arquitectura topológica basada en **Redes Neuronales de Grafos (GNN)**, orientada a modelar de forma nativa la complejidad molecular y genómica que no logran capturar las estructuras tradicionales.

5. Trabajo futuro

Durante la fase final del desarrollo experimental (Noviembre 2025), y tras identificar las limitaciones intrínsecas de los modelos de lenguaje basados en representaciones tabulares y embeddings aprendidos (Learnable Embeddings), se inició una línea de investigación paralela orientada a un cambio de paradigma: la migración completa de la arquitectura hacia **Redes Neuronales de Grafos (GNN).**

Esta evolución, conceptualizada como una versión 2.0, parte de la hipótesis de que la estructura molecular de los fármacos y la topología secuencial del genoma pueden ser representadas de manera nativa como grafos matemáticos, capturando propiedades fisicoquímicas y biológicas que se pierden en la vectorización categórica tradicional.

Implementación de biblioteca de grafos farmacogenómicos

Para viabilizar este enfoque con los recursos que se tenían, se desarrolló un pipeline de preprocesamiento avanzado (*Library Creador*) utilizando Polars para la gestión eficiente de datos y **RDKit** junto con **PyTorch Geometric (PyG)** para la construcción de los grafos.
La meta fue crear una biblioteca local de grafos para todos los fármacos existentes no biológicos y, por otro lado, grafos cromosómicos. Estos últimos, por limitaciones computacionales, se descartaron y se optó por crear grafos para las variantes conocidas actualmente.

A. Representación molecular (Fármacos)

Los identificadores *PubChem CID* y las cadenas *SMILES* se transformaron en grafos moleculares no dirigidos $G = (V, E)$, donde:

- **Nodos (Átomos):** Cada átomo se codificó mediante un vector de características de 25 dimensiones, integrando propiedades atómicas fundamentales extraídas mediante RDKit:
    - Número Atómico (normalizado).
    - Grado del átomo, Valencia e Hibridación (One-Hot Encoding).

- Carga formal, Número total de Hidrógenos implícitos y Quiralidad.
- Aromaticidad y Masa atómica.

● 21 atoms (nodes) ● 24 features per atom ● one-hot + continuous encoding

aN atom index 1 feature present 0 feature absent 0.xxx continuous value

	Atomic	Degree						Formal Charge					Hybridisation	
Atom *index*	Z / 100 *continuous*	Degree *raw*	d=0 *one-hot*	d=1 *one-hot*	d=2 *one-hot*	d=3 *one-hot*	d=4 *one-hot*	FC −2 *one-hot*	FC −1 *one-hot*	FC 0 *one-hot*	FC +1 *one-hot*	FC +2 *one-hot*	SP *hybridis.*	S *hyb*
a0	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a1	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a2	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a3	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a4	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a5	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a6	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a7	0.070	0	0	1	0	0	0	0	1	0	0	0	1	
a8	0.060	0	0	0	1	0	0	0	1	0	0	0	0	
a9	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a10	0.080	0	1	0	0	0	0	0	1	0	0	0	1	
a11	0.070	0	0	1	0	0	0	0	1	0	0	0	1	
a12	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a13	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a14	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a15	0.060	0	0	0	1	0	0	0	1	0	0	0	1	
a16	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a17	0.060	0	0	1	0	0	0	0	1	0	0	0	1	
a18	0.170	0	1	0	0	0	0	0	1	0	0	0	0	
a19	0.080	0	1	0	0	0	0	0	1	0	0	0	0	
a20	0.170	0	1	0	0	0	0	0	1	0	0	0	0	

Continuous features: **Z / 100** *= atomic number ÷ 100;* **M × 0.01** *= atomic mass × 0.01. All other features are binary one-hot encoded (mutually exclusive within each group).*
Hybridisation: SP = linear, SP^2 = trigonal planar, SP^3 = tetrahedral.

Figura 5. Nodos de la molécula (Átomos)

- **Aristas (Enlaces Químicos):** Las conexiones interatómicas se caracterizaron mediante vectores de 9 atributos, codificando el tipo de enlace (Simple, Doble, Triple, Aromático), su estado de conjugación, pertenencia a anillos y estereoquímica.

Adjacency matrix $A \in \mathbb{R}^{21\times21}$ — *3958_lorazepam*

● 21 atoms ● 46 non-zero entries ● graph density 10.4% ● symmetric · no self-loops

— Single = Double ≡ Triple ⊙ Aromatic · No bond

atom	a_0	a_1	a_2	a_3	a_4	a_5	a_6	a_7	a_8	a_9	a_{10}	a_{11}	a_{12}	a_{13}	a_{14}	a_{15}	a_{16}	a_{17}	a_{18}	a_{19}	a_{20}
a0	·	⊙	·	·	·	⊙	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·
a1	⊙	·	⊙	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·
a2	·	⊙	·	⊙	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·
a3	·	·	⊙	·	⊙	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	—
a4	·	·	·	⊙	·	⊙	—	·	·	·	·	·	·	·	·	·	·	·	·	·	·
a5	⊙	·	·	·	⊙	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·
a6	·	·	·	·	—	·	·	=	·	·	·	·	·	—	·	·	·	·	·	·	·
a7	·	·	·	·	·	·	=	·	—	·	·	·	·	·	·	·	·	·	·	·	·
a8	·	·	·	·	·	·	·	—	·	—	·	·	·	·	·	·	·	·	·	—	·
a9	·	·	·	·	·	·	·	·	—	·	=	—	·	·	·	·	·	·	·	·	·
a10	·	·	·	·	·	·	·	·	·	=	·	·	·	·	·	·	·	·	·	·	·
a11	·	·	·	·	·	·	·	·	·	—	·	·	—	·	·	·	·	·	·	·	·
a12	·	·	·	·	·	·	·	·	·	·	·	—	·	⊙	·	·	·	⊙	·	·	·
a13	·	·	·	·	·	·	—	·	·	·	·	·	⊙	·	⊙	·	·	·	·	·	·
a14	·	·	·	·	·	·	·	·	·	·	·	·	·	⊙	·	⊙	·	·	·	·	·
a15	·	·	·	·	·	·	·	·	·	·	·	·	·	·	⊙	·	⊙	·	—	·	·
a16	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	⊙	·	⊙	·	·	·
a17	·	·	·	·	·	·	·	·	·	·	·	·	⊙	·	·	·	⊙	·	·	·	·
a18	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	—	·	·	·	·	·
a19	·	·	·	·	·	·	·	·	—	·	·	·	·	·	·	·	·	·	·	·	·
a20	·	·	·	—	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·	·

The matrix is symmetric (A[i,j] = A[j,i]) and has zero diagonal (no self-loops). Cell values encode bond order (1–4). Hover over a cell to see the bond type name.

Figura 6. Matriz de adyacencia Lorazepam (Enlaces)

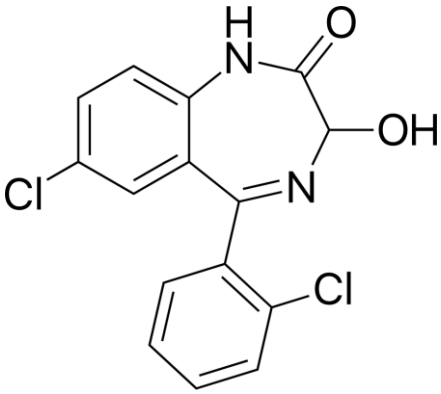

Las tablas mostradas como ejemplo corresponden a la molécula del fármaco Lorazepam, perteneciente al grupo de las benzodiazepinas.

B. Representación genómica (variantes)

Figura 7. Molécula de Lorazepam

Dado el coste computacional prohibitivo de modelar el genoma completo como un grafo, se diseñó una estrategia de **Grafos Posicionales Contextuales**. Utilizando el genoma de referencia (GRCh38) y archivos de anotación GFF, se construyeron grafos dirigidos que modelan la topología específica de cada variante:

- **Estructura Topológica:** Se definieron nodos funcionales de tipo *Backbone* (secuencia de referencia), *Split* (bifurcación), *Merge* (unificación) y nodos de *Alelo* (Referencia vs Alternativo). Esta estructura permite representar nativamente inserciones, deleciones (Indels) y sustituciones (SNVs) como caminos alternativos en el grafo, preservando la lógica secuencial del ADN.
- **Atributos de Nodo:** Cada nodo genómico fue enriquecido con metadatos funcionales procesados:
    - *Activity Score:* Puntuación de impacto funcional (ej. 0 para *No Function*, 1 para *Normal*).
    - *Flags Funcionales:* Vectores binarios indicando la región de impacto (*Coding, Regulatory, Splicing, Intergenic*).

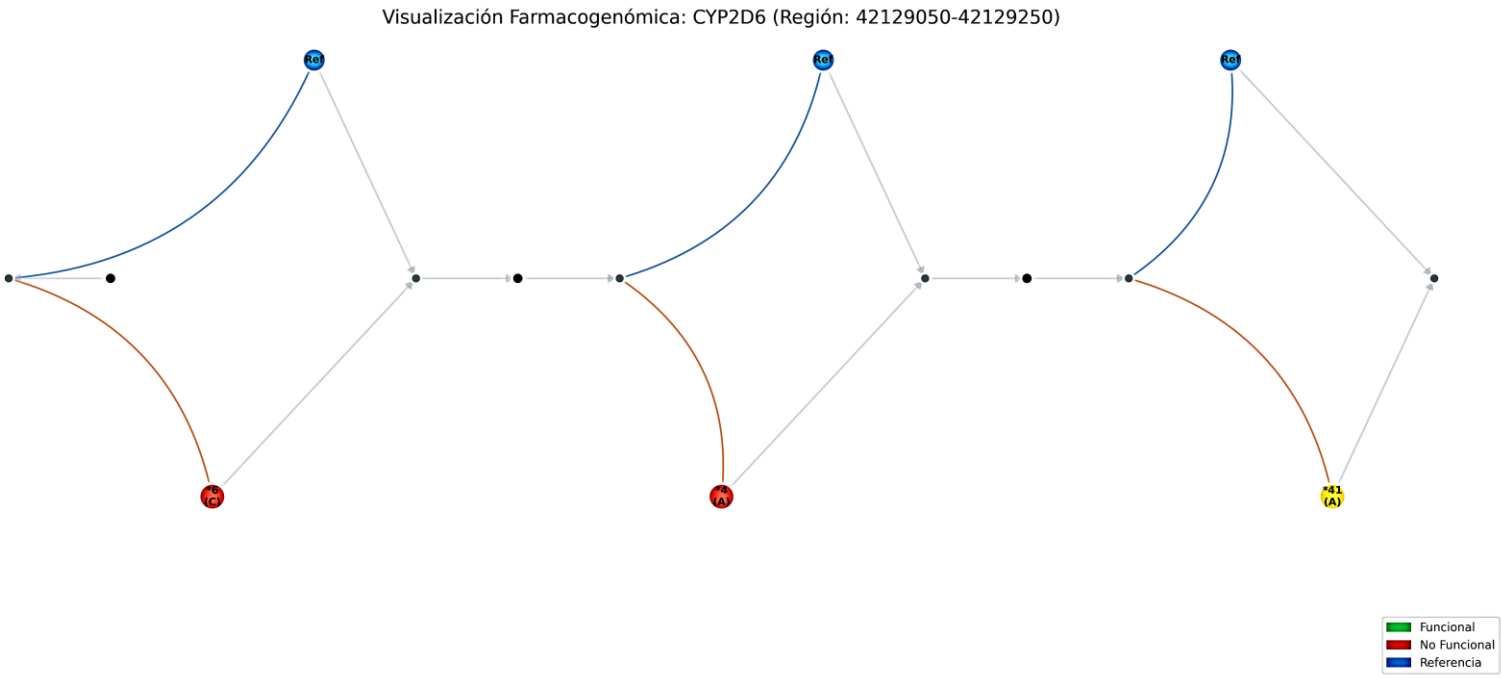

Figura 8. Representación del grafo correspondiente al exón 3 del gen CYP2D6.

Arquitectura "Twin-Tower" con Atención Dinámica (GATv2)

La arquitectura diseñada para procesar estos inputs, denominada **PharmagenTwoTower**, implementa un enfoque siamés (*Twin-Tower*) inspirado en sistemas de recomendación neuronales avanzados. A diferencia de procesar una entrada concatenada, el modelo procesa cada dominio (Farmacológico y Genómico) en torres independientes especializadas antes de su interacción.

A. Componente GATv2 (Graph Attention Network v2)

Cada torre está constituida por bloques de **GATv2Conv**, una evolución del mecanismo de atención en grafos que corrige las limitaciones de atención estática del GAT original.

- **Atención Dinámica:** Permite al modelo ponderar la importancia de cada conexión (ej. un enlace químico específico o una relación posicional entre variantes) en función del contexto de los nodos vecinos.
- **Conexiones Residuales y Normalización:** Se implementaron *Skip Connections* ($x = x + x_{in}$) y capas de GraphNorm entre bloques para facilitar el flujo de gradientes y permitir el entrenamiento de arquitecturas profundas sin degradación de la señal.

B. Estrategias de "*pooling*" diferenciadas

Un aspecto innovador del diseño es la aplicación de funciones de lectura (*Readout/Pooling*) específicas para la naturaleza biológica de cada dominio:

- **Torre Fármaco (GlobalMeanPool):** Se utiliza el promedio de los nodos para obtener una representación latente suave de la molécula completa.
- **Torre Genotipo (GlobalAddPool):** Se utiliza la suma de las representaciones. Esta decisión de diseño permite modelar el **efecto acumulativo** de múltiples variantes. A diferencia del promedio, que podría diluir el impacto de una mutación rara pero crítica en un gen largo, la suma preserva y acumula la magnitud del impacto funcional de todas las variantes presentes.

Validación de la integridad topológica y estado actual

Para garantizar la fiabilidad de la conversión de datos **(SMILES/VCF → Grafos .pt),** se desarrollaron scripts de validación que realizan la reconstrucción inversa y visualización de los grafos generados. Estas pruebas confirmaron que la topología química y la información posicional genómica se preservan íntegramente en los tensores de PyTorch Geometric.

Barreras Computacionales

A pesar de que la implementación del pipeline de datos y la definición de la arquitectura (PharmagenTwoTower) están finalizadas y funcionales, su validación estadística masiva enfrentó una barrera tecnológica.

La complejidad del entrenamiento de GNNs sobre grafos de alta fidelidad, sumada a la necesidad de optimización de hiperparámetros (Búsqueda Amplia en Optuna), incrementó exponencialmente el coste computacional. Se estimó que un solo ciclo completo de optimización requeriría >140 horas (~6 días) en el hardware disponible (NVIDIA RTX 4070 Ti Super).

Por ello, se priorizó la defensa de la arquitectura *PharmagenDeepFM* (validada y robusta), reservando la arquitectura GNN como base sólida para la continuación del proyecto en entornos de computación de alto rendimiento (HPC).

6. Conclusiones

A partir del trabajo desarrollado y los resultados obtenidos en el presente proyecto, se establecen las siguientes conclusiones:

1. **Viabilidad del Flujo Traslacional Integral:** Se concluye la factibilidad de integrar en un único entorno automatizado el preprocesamiento bioinformático de datos crudos NGS y la inferencia clínica mediante Inteligencia Artificial. Este enfoque elimina cuellos de

botella operativos y acerca el uso de la secuenciación masiva a la práctica asistencial en tiempo real.

2. **Relevancia crítica de la Ingeniería de Características:** La sustitución de categorizaciones médicas clásicas (como el código ATC) por identificadores moleculares puros (*PubChem CID*), así como la normalización alélica estricta, son fundamentales. Los modelos de aprendizaje profundo requieren representaciones que reflejen interacciones fisicoquímicas y estéricas reales, no agrupaciones terapéuticas abstractas, para garantizar la validez biológica de las predicciones.

3. **Gestión del riesgo clínico y desbalance de Clases:** En el ámbito farmacogenómico, donde los efectos adversos severos constituyen la minoría estadística pero la prioridad clínica, el uso de funciones de pérdida avanzadas (*Adaptative Focal Loss* y *Asymmetric Loss*) ha resultado imperativo. Su implementación permite penalizar drásticamente los falsos negativos en toxicidad, alineando el gradiente de optimización de la red con el principio de seguridad del paciente.

4. **Capacidad predictiva frente a dispersión semántica:** La arquitectura híbrida propuesta (Máquinas de Factorización acopladas a un codificador *Transformer*) alcanzó una precisión del ~87% en la predicción de fallos en rutas farmacocinéticas y farmacodinámicas (*Phenotype Outcome*). Sin embargo, el descenso de rendimiento al inferir el evento adverso específico (~46%) evidencia una fragmentación ontológica estructural en las bases de datos actuales, subrayando la urgencia de estandarizar la nomenclatura clínica bajo protocolos rigurosos.

5. **Transición hacia representaciones topológicas:** Las limitaciones inferenciales detectadas en los *embeddings* tabulares frente a fenómenos complejos como la epistasia, determinan que la evolución natural del campo pase por abandonar el procesamiento secuencial lineal. Las Redes Neuronales de Grafos (GNN) se perfilan como el próximo estándar necesario, al permitir codificar de forma nativa tanto la estructura química de los fármacos como la topología del ADN. Adicionalmente, dado el funcionamiento de los grandes modelos de lenguaje, podría ser posible utilizarse estos para el procesamiento y refinado de datos que posteriormente se utilizarán para construir los grafos en un proceso anidado.

7. Bibliografía

1. Lander ES, Linton LM, Birren B, Nusbaum C, Zody MC, Baldwin J, et al. Initial sequencing and analysis of the human genome. Nature. febrero de 2001;409(6822):860-921. doi:10.1038/35057062
2. Lee CR, Luzum JA, Sangkuhl K, Gammal RS, Sabatine MS, Stein CM, et al. Clinical Pharmacogenetics Implementation Consortium Guideline for CYP2C19 Genotype and Clopidogrel Therapy: 2022 Update. Clin Pharmacol Ther. noviembre de 2022;112(5):959-67. doi:10.1002/cpt.2526 PubMed PMID: 35034351; PubMed Central PMCID: PMC9287492.
3. van der Wouden CH, Cambon-Thomsen A, Cecchin E, Cheung KC, Dávila-Fajardo CL, Deneer VH, et al. Implementing Pharmacogenomics in Europe: Design and Implementation Strategy of the Ubiquitous Pharmacogenomics Consortium. Clin Pharmacol Ther. marzo de 2017;101(3):341-58. doi:10.1002/cpt.602 PubMed PMID: 28027596.
4. Dunham I, Kundaje A, Aldred SF, Collins PJ, Davis CA, Doyle F, et al. An integrated encyclopedia of DNA elements in the human genome. Nature. septiembre de 2012;489(7414):57-74. doi:10.1038/nature11247
5. Arndt D, Marcu A, Liang Y, Wishart DS. PHAST, PHASTER and PHASTEST: Tools for finding prophage in bacterial genomes. Brief Bioinform. 19 de julio de 2019;20(4):1560-7. doi:10.1093/bib/bbx121
6. Ahn JS, Shin S, Yang SA, Park EK, Kim KH, Cho SI, et al. Artificial Intelligence in Breast Cancer Diagnosis and Personalized Medicine. J Breast Cancer. 17 de octubre de 2023;26(5):405-35. doi:10.4048/jbc.2023.26.e45 PubMed PMID: 37926067; PubMed Central PMCID: PMC10625863.
7. Topol EJ. High-performance medicine: the convergence of human and artificial intelligence. Nat Med. enero de 2019;25(1):44-56. doi:10.1038/s41591-018-0300-7
8. Rehm HL, Page AJH, Smith L, Adams JB, Alterovitz G, Babb LJ, et al. GA4GH: International policies and standards for data sharing across genomic research and healthcare. Cell Genomics. 10 de noviembre de 2021;1(2):100029. doi:10.1016/j.xgen.2021.100029
9. Wilkinson MD, Dumontier M, Aalbersberg IjJ, Appleton G, Axton M, Baak A, et al. The FAIR Guiding Principles for scientific data management and stewardship. Sci Data. 15 de marzo de 2016;3(1):160018. doi:10.1038/sdata.2016.18
10. Cheng HT, Koc L, Harmsen J, Shaked T, Chandra T, Aradhye H, et al. Wide & Deep Learning for Recommender Systems. En: Proceedings of the 1st Workshop on Deep Learning for Recommender Systems [Internet]. Boston MA USA: ACM; 2016 [citado 29 de enero de 2026]. p. 7-10. Disponible en: https://dl.acm.org/doi/10.1145/2988450.2988454 doi:10.1145/2988450.2988454
11. Guo H, Tang R, Ye Y, Li Z, He X. DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. En. 2017. p. 1725-31. doi:10.24963/ijcai.2017/239
12. Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, et al. Attention is all you need. En: Advances in neural information processing systems. 2017. p. 5998-6008. doi:10.48550/arXiv.1706.03762
13. AlQuraishi M. Machine learning in protein structure prediction. Curr Opin Chem Biol. diciembre de 2021;65:1-8. doi:10.1016/j.cbpa.2021.04.005 PubMed PMID: 34015749.

14. Avsec Ž, Agarwal V, Visentin D, Ledsam JR, Grubert F, Kasowski M, et al. Effective gene expression prediction from sequence by integrating long-range interactions. Nat Methods. 2021;18(10):1196-203. doi:10.1038/s41592-021-01252-x
15. Pratt VM, Cavallari LH, Fulmer ML, Gaedigk A, Hachad H, Ji Y, et al. DPYD Genotyping Recommendations: A Joint Consensus Recommendation of the Association for Molecular Pathology, American College of Medical Genetics and Genomics, Clinical Pharmacogenetics Implementation Consortium, College of American Pathologists, Dutch Pharmacogenetics Working Group of the Royal Dutch Pharmacists Association, European Society for Pharmacogenomics and Personalized Therapy, Pharmacogenomics Knowledgebase, and Pharmacogene Variation Consortium. J Mol Diagn JMD. octubre de 2024;26(10):851-63. doi:10.1016/j.jmoldx.2024.05.015 PubMed PMID: 39032821; PubMed Central PMCID: PMC12813241.
16. Empey PE, Karnes JH, Johnson JA. Pharmacogenetics: Opportunities for the All of Us Research Program and Other Large Data Sets to Advance the Field. Annu Rev Pharmacol Toxicol. 23 de enero de 2025;65(Volume 65, 2025):111-30. doi:10.1146/annurev-pharmtox-061724-080718
17. Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos y por el que se deroga la Directiva 95/46/CE (Reglamento general de protección de datos). Diario Oficial de la Unión Europea, L 119, (4 de mayo de 2016). Disponible en: http://data.europa.eu/eli/reg/2016/679/oj

Anexo 1. Repositorio GitHub del Proyecto

El código fuente íntegro del proyecto, los scripts de orquestación y los archivos de configuración se encuentran disponibles en el repositorio público de GitHub bajo el nombre Pharmagen. Este repositorio centraliza tanto el pipeline bioinformático como los modelos de aprendizaje desarrollados.

- **Enlace al repositorio: https://github.com/Aderfi/Pharmagen**

Anexo 2. Criterios de selección de bases de datos

1. Criterios de Inclusión de Evidencia Genotipo-Fenotipo

La selección de las fuentes de datos se fundamentó en la necesidad de identificar asociaciones robustas entre variantes genómicas y la variabilidad en la respuesta farmacológica. Se priorizaron estudios que analizaran la correlación entre **polimorfismos de nucleótido único (SNPs)** y alteraciones en los perfiles **farmacocinéticos (ADME)**, con especial énfasis en aquellos polimorfismos que inducen un fenotipo metabólico con relevancia clínica directa.

El **fracaso terapéutico** se definió como un constructo multifactorial, integrando variables como el incremento de la comorbilidad, la severidad de las reacciones adversas a medicamentos (RAM), el desarrollo de resistencias y la falta de adherencia secundaria a efectos indeseados.

2. Relevancia Clínica y Especificidad de las Variantes

Para asegurar la solidez del modelo de predicción, se establecieron criterios estrictos de **utilidad clínica**. No todas las variantes genómicas poseen una repercusión farmacológica validada; por tanto, se seleccionaron exclusivamente polimorfismos cuya correlación con el fenotipo ya hubiera sido demostrada en cohortes clínicas o recogida en guías de implementación. Este enfoque garantiza que el modelo trabaje sobre **biomarcadores accionables** y no sobre ruido estadístico.

3. Integración de Fuentes: clinPGx y dbSNP

Tras una evaluación sistemática de los repositorios disponibles, se seleccionó la base de datos **clinPGx** como fuente primaria para la construcción del *dataset* de entrenamiento. La elección de clinPGx se justifica por su estructura de datos multidimensional, que permite mapear de forma unívoca la tríada **fármaco-variante-patología**, facilitando la integración de la historia clínica del paciente en la correlación farmacogenómica.

4. Protocolo de Enriquecimiento y Mapeo de Variantes

Debido a la existencia de valores ausentes (*missing data*) en ciertos registros originales — principalmente relacionados con la nomenclatura de haplotipos (*star alleles*) o coordenadas

genómicas— se implementó un protocolo de **enriquecimiento de datos** mediante la integración con **dbSNP (Database of Short Genetic Variations)**.

Este proceso de normalización se ejecutó de la siguiente manera:

Mapeo sistemático: Se utilizaron los identificadores de referencia (**rsID**) como clave primaria para la interoperabilidad entre bases de datos.

Recuperación de metadatos: Se extrajeron coordenadas genómicas precisas, frecuencias alélicas y consecuencias funcionales desde los archivos maestros de dbSNP.

Consolidación del Dataframe: El resultado final es un conjunto de datos estructurado y curado, donde cada entrada de entrenamiento posee una anotación biológica completa y verificada, minimizando los sesgos derivados de la inconsistencia en la nomenclatura genómica.